Métodos de descenso para sistemas lineales

Clase 8 · Capítulo 5

Análisis Numérico (LMA) · Métodos Numéricos II (LCD)

11 de septiembre de 2026

Facultad de Ingeniería Química · UNL

Plan de la clase

Clase 8

1. Funcional de energía: $Ax = b \iff \min \phi$.
2. Steepest descent: idea, algoritmo y convergencia.
3. Gradiente conjugado: construcción y espacios de Krylov.
4. Cotas de error: polinomios residuales y Chebyshev.

5.1 Métodos de descenso para matrices sdp

El funcional de energía

Sea A sdp y $b \in \mathbb{R}^n$. Definimos

$$\phi(x) = \tfrac{1}{2} x^T A x - x^T b.$$

Teorema

El mínimo de ϕ en $\mathbb{R}^n$ se alcanza **únicamente** *en la solución x_* de $Ax = b$. El valor mínimo es $-\frac{1}{2} b^T x_*$.*

Idea: $\phi(y) = \phi(x_*) + \frac{1}{2}\|y - x_*\|_A^2 \geq \phi(x_*)$, con igualdad solo si $y = x_*$.

El funcional de energía

Sea A sdp y $b \in \mathbb{R}^n$. Definimos

$$\phi(x) = \tfrac{1}{2} x^T A x - x^T b.$$

Teorema

El mínimo de ϕ en $\mathbb{R}^n$ se alcanza **únicamente** *en la solución x_* de $Ax = b$. El valor mínimo es $-\frac{1}{2} b^T x_*$.*

Idea: $\phi(y) = \phi(x_*) + \frac{1}{2}\|y - x_*\|_A^2 \geq \phi(x_*)$, con igualdad solo si $y = x_*$.

Gradiente de ϕ

$$\nabla \phi(x) = Ax - b.$$

(Verificar en clase.) El residuo $r_k = b - Ax_k = -\nabla \phi(x_k)$ apunta al máximo descenso.

Lema de caracterización (clave para los métodos)

Lema

Sean A sdp, $b \in \mathbb{R}^n$, x_* solución de $Ax = b$, y $S \subset \mathbb{R}^n$. Entonces, $y \in S$ **minimiza** ϕ **sobre** S *si y solo si $y \in S$* **minimiza** $\|\cdot - x_*\|_A$ **sobre** S.

Demostración: De $\phi(y) = \phi(x_*) + \frac{1}{2}\|y - x_*\|_A^2$ se sigue directamente.

Lema de caracterización (clave para los métodos)

Lema

Sean A sdp, $b \in \mathbb{R}^n$, x_* solución de $Ax = b$, y $S \subset \mathbb{R}^n$. Entonces, $y \in S$ **minimiza** ϕ **sobre** S *si y solo si $y \in S$* **minimiza** $\|\cdot - x_*\|_A$ **sobre** S.

Demostración: De $\phi(y) = \phi(x_*) + \frac{1}{2}\|y - x_*\|_A^2$ se sigue directamente.

Consecuencia: resolver $Ax = b$ es equivalente a minimizar ϕ, y cada iteración que minimiza ϕ sobre un subespacio está minimizando la A-distancia a la solución.

5.1.1 Método del descenso más pronunciado

Idea del Steepest descent

Dado x_k, nos movemos en la dirección $r_k = b - Ax_k$ minimizando ϕ:

$$x_{k+1} = x_k + \alpha\, r_k, \qquad \alpha = \underset{\alpha \in \mathbb{R}}{\operatorname{argmin}}\ \phi(x_k + \alpha r_k).$$

Idea del Steepest descent

Dado x_k, nos movemos en la dirección $r_k = b - Ax_k$ minimizando ϕ:

$$x_{k+1} = x_k + \alpha\, r_k, \qquad \alpha = \operatorname*{argmin}_{\alpha \in \mathbb{R}} \phi(x_k + \alpha r_k).$$

Minimizando $h(\alpha) := \phi(x_k + \alpha r_k)$ sobre α:

$$\boxed{\alpha = \frac{r_k^T r_k}{r_k^T A r_k}.}$$

(Verificar en clase: $h'(\alpha) = 0$.)

Idea del Steepest descent

Dado x_k, nos movemos en la dirección $r_k = b - Ax_k$ minimizando ϕ:

$$x_{k+1} = x_k + \alpha\, r_k, \qquad \alpha = \operatorname*{argmin}_{\alpha \in \mathbb{R}} \phi(x_k + \alpha r_k).$$

Minimizando $h(\alpha) := \phi(x_k + \alpha r_k)$ sobre α:

$$\boxed{\alpha = \frac{r_k^T r_k}{r_k^T A r_k}.}$$

(Verificar en clase: $h'(\alpha) = 0$.)

Observación

Más en general, para minimizar $\phi(x_k + \alpha\, d)$ con dirección d arbitraria: $\alpha = d^T r_k / (d^T A d)$.

Algoritmo Steepest descent

Versión básica (2 mat-vec/it.)

$r_0 = b - Ax_0; \quad k = 0$

mientras $\|r_k\| > \text{tol}$

$\alpha = \dfrac{r_k^T r_k}{r_k^T A r_k}$

$x_{k+1} = x_k + \alpha\, r_k$

$r_{k+1} = b - Ax_{k+1}$

$k = k + 1$

fin

Algoritmo Steepest descent

Versión básica (2 mat-vec/it.)

$r_0 = b - Ax_0; \quad k = 0$

mientras $\|r_k\| > \text{tol}$

$$\alpha = \frac{r_k^T r_k}{r_k^T A r_k}$$

$x_{k+1} = x_k + \alpha\, r_k$

$r_{k+1} = b - Ax_{k+1}$

$k = k + 1$

fin

Versión eficiente (1 mat-vec/it.)

Observar que

$$r_{k+1} = r_k - \alpha A r_k.$$

Basta guardar $v = Ar_k$ y reutilizarlo:

$$\alpha = \frac{r_k^T r_k}{r_k^T v}, \quad r_{k+1} = r_k - \alpha v.$$

Solo se necesita la acción $x \mapsto Ax$, no las entradas de A.

Steepest descent como Richardson adaptativo

Richardson: $x_{k+1} = x_k + \alpha\, r_k$ con α **fijo**. SD: α **óptimo en cada paso**.

Steepest descent como Richardson adaptativo

Richardson: $x_{k+1} = x_k + \alpha\, r_k$ con α **fijo**. SD: α **óptimo en cada paso**.

Teorema (Convergencia del Steepest descent)

Sea A sdp, x_* solución de $Ax = b$. Para todo x_0:

$$\|x_{k+1} - x_*\|_A \;\leq\; \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1}\, \|x_k - x_*\|_A.$$

Steepest descent como Richardson adaptativo

Richardson: $x_{k+1} = x_k + \alpha\, r_k$ con α **fijo**. SD: α **óptimo en cada paso**.

Teorema (Convergencia del Steepest descent)

Sea A sdp, x_* solución de $Ax = b$. Para todo x_0:

$$\|x_{k+1} - x_*\|_A \;\leq\; \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1}\, \|x_k - x_*\|_A.$$

Ventaja sobre Richardson: no se necesita conocer λ_{min}, λ_{max}.

Steepest descent como Richardson adaptativo

Richardson: $x_{k+1} = x_k + \alpha\, r_k$ con α **fijo**. SD: α **óptimo en cada paso**.

Teorema (Convergencia del Steepest descent)

Sea A sdp, x_* solución de $Ax = b$. Para todo x_0:

$$\|x_{k+1} - x_*\|_A \;\leq\; \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1}\, \|x_k - x_*\|_A.$$

Ventaja sobre Richardson: no se necesita conocer $\lambda_{\min}$, $\lambda_{\max}$.

Limitación

Matrices mal condicionadas ($\kappa_2 \gg 1$): convergencia muy lenta. Curvas de nivel de ϕ muy alargadas $\Rightarrow$ muchos zigzag.

5.1.2 Método del gradiente conjugado

¿Se puede mejorar?

En el Steepest descent, en cada paso se minimiza ϕ sobre

$$\{x_k + \alpha r_k \mid \alpha \in \mathbb{R}\}.$$

¿Se puede mejorar?

En el Steepest descent, en cada paso se minimiza ϕ sobre

$$\{x_k + \alpha r_k \mid \alpha \in \mathbb{R}\}.$$

Idea: al llegar a x_{k+1}, no olvidar las direcciones anteriores. Minimizar ϕ sobre *todo el afín* acumulado hasta el paso k:

$$x_{k+1} \text{ minimiza } \phi \text{ sobre } x_0 + \operatorname{span}\{r_0, r_1, \ldots, r_k\}.$$

(GC es estrictamente mejor que SD en cada iteración.)

¿Se puede mejorar?

En el Steepest descent, en cada paso se minimiza ϕ sobre

$$\{x_k + \alpha r_k \mid \alpha \in \mathbb{R}\}.$$

Idea: al llegar a x_{k+1}, no olvidar las direcciones anteriores. Minimizar ϕ sobre *todo el afín* acumulado hasta el paso k:

$$x_{k+1} \text{ minimiza } \phi \text{ sobre } x_0 + \operatorname{span}\{r_0, r_1, \ldots, r_k\}.$$

(GC es estrictamente mejor que SD en cada iteración.)

Por el lema de caracterización, esto equivale a

$$\|x_{k+1} - x_*\|_A = \min_{x \in x_0 + \operatorname{span}\{r_0, \ldots, r_k\}} \|x - x_*\|_A.$$

Algoritmo GC (versión preliminar)

Gradiente conjugado — Versión 1

Sean A sdp, $b \in \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$. $r_0 = b - Ax_0$; $k = 0$.

mientras $r_k \neq 0$: $\quad x_{k+1} = \underset{x \in x_0 + \mathsf{span}\{r_0, \ldots, r_k\}}{\operatorname{argmin}} \phi(x); \quad r_{k+1} = b - Ax_{k+1}; \quad k = k + 1.$

fin

Algoritmo GC (versión preliminar)

Gradiente conjugado — Versión 1

Sean A sdp, $b \in \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$. $r_0 = b - Ax_0$; $k = 0$.

mientras $r_k \neq 0$: $x_{k+1} = \underset{x \in x_0 + \mathrm{span}\{r_0, \ldots, r_k\}}{\operatorname{argmin}} \phi(x)$; $r_{k+1} = b - Ax_{k+1}$; $k = k + 1$.

fin

Preguntas pendientes:

- ¿Existe siempre el argmin?
- ¿Hay forma computacionalmente eficiente de calcularlo?

Los residuos son ortogonales

Lema

Sea $\{r_k\}$ *la sucesión de residuos del GC. Entonces*

$$r_k \perp \operatorname{span}\{r_0, r_1, \ldots, r_{k-1}\}, \qquad k \geq 1.$$

Los residuos son ortogonales

Lema

Sea $\{r_k\}$ la sucesión de residuos del GC. Entonces

$$r_k \perp \text{span}\{r_0, r_1, \ldots, r_{k-1}\}, \qquad k \geq 1.$$

Idea: x_k minimiza ϕ sobre $x_0 + \text{span}\{r_0, \ldots, r_{k-1}\}$, luego para todo ξ en ese subespacio,

$$\frac{d}{dt}\phi(x_k + t\xi)\Big|_{t=0} = \xi^T \nabla\phi(x_k) = -\xi^T r_k = 0.$$

Los residuos son ortogonales

Lema

Sea $\{r_k\}$ la sucesión de residuos del GC. Entonces

$$r_k \perp \text{span}\{r_0, r_1, \ldots, r_{k-1}\}, \qquad k \geq 1.$$

Idea: x_k minimiza ϕ sobre $x_0 + \text{span}\{r_0, \ldots, r_{k-1}\}$, luego para todo ξ en ese subespacio,

$$\frac{d}{dt}\phi(x_k + t\xi)\Big|_{t=0} = \xi^T \nabla\phi(x_k) = -\xi^T r_k = 0.$$

Consecuencia

Si $r_k \neq 0$ entonces $\{r_0, r_1, \ldots, r_k\}$ es linealmente independiente. En particular, el GC termina en a lo sumo n pasos.

Espacios de Krylov

Definición (Espacio de Krylov)

$\mathcal{K}_{k+1} := \text{span}\{r_0, Ar_0, \ldots, A^k r_0\}$.

Espacios de Krylov

Definición (Espacio de Krylov)

$\mathcal{K}_{k+1} := \text{span}\{r_0, Ar_0, \ldots, A^k r_0\}$.

Lema

Si $r_k \neq 0$, *entonces para todo* $k \geq 0$: $\text{span}\{r_0, r_1, \ldots, r_k\} = \mathcal{K}_{k+1}$.

Espacios de Krylov

Definición (Espacio de Krylov)

$\mathcal{K}_{k+1} := \text{span}\{r_0, Ar_0, \ldots, A^k r_0\}$.

Lema

Si $r_k \neq 0$, *entonces para todo* $k \geq 0$*:* $\text{span}\{r_0, r_1, \ldots, r_k\} = \mathcal{K}_{k+1}$.

Idea (inducción): $r_{k+1} = r_0 - A\xi_k$ con $\xi_k \in \mathcal{K}_{k+1}$, luego $r_{k+1} \in \mathcal{K}_{k+2}$; la ortogonalidad de residuos garantiza que la dimensión sube en 1 en cada paso.

Espacios de Krylov

Definición (Espacio de Krylov)

$\mathcal{K}_{k+1} := \text{span}\{r_0, Ar_0, \ldots, A^k r_0\}$.

Lema

Si $r_k \neq 0$, entonces para todo $k \geq 0$: $\text{span}\{r_0, r_1, \ldots, r_k\} = \mathcal{K}_{k+1}$.

Idea (inducción): $r_{k+1} = r_0 - A\xi_k$ con $\xi_k \in \mathcal{K}_{k+1}$, luego $r_{k+1} \in \mathcal{K}_{k+2}$; la ortogonalidad de residuos garantiza que la dimensión sube en 1 en cada paso.

En consecuencia:

$$x_{k+1} \text{ minimiza } \phi \text{ sobre } x_0 + \mathcal{K}_{k+1}.$$

GC es un método de subespacios de Krylov.

5.1.3 Cotas de error para el GC

El punto de partida: minimización sobre $x_0 + \mathcal{K}_k$

Por definición, x_k minimiza ϕ sobre $x_0 + \mathcal{K}_k$. Por el lema de caracterización, esto ocurre si y solo si

$$\|x_k - x_*\|_A \;\leq\; \|w - x_*\|_A, \qquad \forall\, w \in x_0 + \mathcal{K}_k.$$

El punto de partida: minimización sobre $x_0 + \mathcal{K}_k$

Por definición, x_k minimiza ϕ sobre $x_0 + \mathcal{K}_k$. Por el lema de caracterización, esto ocurre si y solo si

$$\|x_k - x_*\|_A \;\leq\; \|w - x_*\|_A, \qquad \forall\, w \in x_0 + \mathcal{K}_k.$$

Ahora bien, como $\mathcal{K}_k = \operatorname{span}\{r_0, Ar_0, \ldots, A^{k-1}r_0\}$, si $w \in x_0 + \mathcal{K}_k$ entonces

$$w = x_0 + \sum_{i=0}^{k-1} \gamma_i A^i r_0, \qquad \gamma_0, \ldots, \gamma_{k-1} \in \mathbb{R}.$$

El punto de partida: minimización sobre $x_0 + \mathcal{K}_k$

Por definición, x_k minimiza ϕ sobre $x_0 + \mathcal{K}_k$. Por el lema de caracterización, esto ocurre si y solo si

$$\|x_k - x_*\|_A \ \leq \ \|w - x_*\|_A, \qquad \forall\, w \in x_0 + \mathcal{K}_k.$$

Ahora bien, como $\mathcal{K}_k = \text{span}\{r_0, Ar_0, \ldots, A^{k-1}r_0\}$, si $w \in x_0 + \mathcal{K}_k$ entonces

$$w = x_0 + \sum_{i=0}^{k-1} \gamma_i A^i r_0, \qquad \gamma_0, \ldots, \gamma_{k-1} \in \mathbb{R}.$$

Observación clave: $r_0 = b - Ax_0 = Ax_* - Ax_0 = -A(x_0 - x_*)$.

El punto de partida: minimización sobre $x_0 + \mathcal{K}_k$

Por definición, x_k minimiza ϕ sobre $x_0 + \mathcal{K}_k$. Por el lema de caracterización, esto ocurre si y solo si

$$\|x_k - x_*\|_A \ \leq \ \|w - x_*\|_A, \qquad \forall\, w \in x_0 + \mathcal{K}_k.$$

Ahora bien, como $\mathcal{K}_k = \text{span}\{r_0, Ar_0, \ldots, A^{k-1}r_0\}$, si $w \in x_0 + \mathcal{K}_k$ entonces

$$w = x_0 + \sum_{i=0}^{k-1} \gamma_i A^i r_0, \qquad \gamma_0, \ldots, \gamma_{k-1} \in \mathbb{R}.$$

Observación clave: $r_0 = b - Ax_0 = Ax_* - Ax_0 = -A(x_0 - x_*)$.

En el pizarrón: sustituir y agrupar para llegar a

$$w - x_* \ = \ \Big(I - \sum_{i=0}^{k-1} \gamma_i A^{i+1}\Big)(x_0 - x_*).$$

Polinomios residuales

Todo $w \in x_0 + \mathcal{K}_k$ verifica

$$w - x_* = p(A)(x_0 - x_*), \qquad p(z) = 1 - \sum_{i=0}^{k-1} \gamma_i z^{i+1},$$

con $p \in \mathcal{P}_k$ y, muy importante, $p(0) = 1$ (y recíprocamente).

Polinomios residuales

Todo $w \in x_0 + \mathcal{K}_k$ verifica

$$w - x_* = p(A)(x_0 - x_*), \qquad p(z) = 1 - \sum_{i=0}^{k-1} \gamma_i z^{i+1},$$

con $p \in \mathcal{P}_k$ y, muy importante, $p(0) = 1$ (y recíprocamente).

Definición (Polinomios residuales)

$\overline{\mathcal{P}}_k := \{p \in \mathcal{P}_k \mid p(0) = 1\}$.

Polinomios residuales

Todo $w \in x_0 + \mathcal{K}_k$ verifica

$$w - x_* = p(A)(x_0 - x_*), \qquad p(z) = 1 - \sum_{i=0}^{k-1} \gamma_i z^{i+1},$$

con $p \in \mathcal{P}_k$ y, muy importante, $p(0) = 1$ (y recíprocamente).

Definición (Polinomios residuales)

$\overline{\mathcal{P}}_k := \{p \in \mathcal{P}_k \mid p(0) = 1\}$.

Teorema (Cota óptima del GC — Teo. 5.13)

$$\|x_k - x_*\|_A = \min_{p \in \overline{\mathcal{P}}_k} \|p(A)(x_0 - x_*)\|_A, \qquad k \geq 0.$$

Polinomios residuales

Todo $w \in x_0 + \mathcal{K}_k$ verifica

$$w - x_* = p(A)(x_0 - x_*), \qquad p(z) = 1 - \sum_{i=0}^{k-1} \gamma_i z^{i+1},$$

con $p \in \mathcal{P}_k$ y, muy importante, $p(0) = 1$ (y recíprocamente).

Definición (Polinomios residuales)

$\overline{\mathcal{P}}_k := \{p \in \mathcal{P}_k \mid p(0) = 1\}$.

Teorema (Cota óptima del GC — Teo. 5.13)

$$\|x_k - x_*\|_A = \min_{p \in \overline{\mathcal{P}}_k} \|p(A)(x_0 - x_*)\|_A, \qquad k \geq 0.$$

Interpretación: el GC elige implícitamente el mejor polinomio residual de grado k.

Corolario: cota espectral

Corolario

Para todo $p \in \overline{\mathcal{P}}_k$*:*

$$\|x_k - x_*\|_A \leq \max_{\lambda \in \sigma(A)} |p(\lambda)| \cdot \|x_0 - x_*\|_A.$$

Corolario: cota espectral

Corolario

Para todo $p \in \overline{\mathcal{P}}_k$*:*

$$\|x_k - x_*\|_A \leq \max_{\lambda \in \sigma(A)} |p(\lambda)| \cdot \|x_0 - x_*\|_A.$$

Idea: $A = V\Lambda V^T \Rightarrow p(A) = Vp(\Lambda)V^T$, luego
$\|p(A)\|_A \leq \|p(A)\|_2 = \rho(p(A)) = \max_{\lambda \in \sigma(A)} |p(\lambda)|$.

Corolario: cota espectral

Corolario

Para todo $p \in \overline{\mathcal{P}}_k$*:*

$$\|x_k - x_*\|_A \leq \max_{\lambda \in \sigma(A)} |p(\lambda)| \cdot \|x_0 - x_*\|_A.$$

Idea: $A = V\Lambda V^T \Rightarrow p(A) = Vp(\Lambda)V^T$, luego
$\|p(A)\|_A \leq \|p(A)\|_2 = \rho(p(A)) = \max_{\lambda \in \sigma(A)} |p(\lambda)|$.

Utilidad práctica

Si $\sigma(A) \subset [\lambda_{\min}, \lambda_{\max}]$, se construye $p \in \overline{\mathcal{P}}_k$ que sea pequeño en $[\lambda_{\min}, \lambda_{\max}]$ para acotar el error. (Ejemplo: polinomios de Chebyshev.)

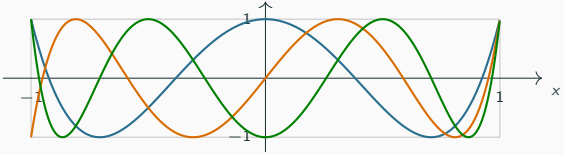
Polinomios de Tchebychev

Definición (Polinomios de Tchebychev)

$$T_0(x) = 1, \qquad T_1(x) = x, \qquad T_k(x) = 2x\,T_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Equivalentemente, $T_k(x) = \cos\big(k \arccos x\big)$ para $x \in [-1, 1]$. En particular

$$\max_{x \in [-1,1]} |T_k(x)| = 1, \qquad \text{y } |T_k| \text{ crece muy rápido fuera de } [-1, 1].$$

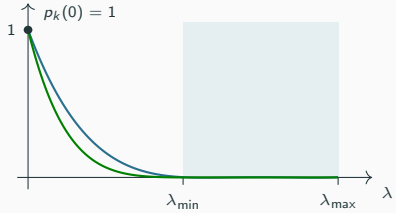


T_4, T_5, T_6: T_k *equioscila* entre -1 y 1, alcanzando ± 1 exactamente $k+1$ veces en $[-1, 1]$.

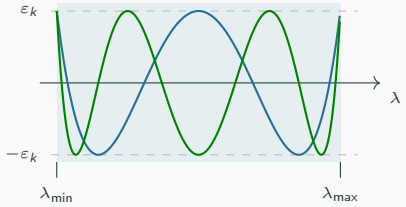
Construcción de p_k: ejemplo $\lambda_{\min} = 1$, $\lambda_{\max} = 2$

$$x(\lambda) = \frac{\lambda - \frac{\lambda_{\max}+\lambda_{\min}}{2}}{\frac{\lambda_{\max}-\lambda_{\min}}{2}} = 2\lambda - 3, \quad p_k(\lambda) := \frac{T_k(x(\lambda))}{T_k(x(0))} = \frac{T_k(2\lambda-3)}{T_k(-3)}, \quad \varepsilon_k := \frac{1}{|T_k(-3)|}.$$

Vista global: p_4, p_6



Zoom en $[\lambda_{\min}, \lambda_{\max}]$, en unidades de ε_k



Cada p_k dividida por su propio ε_k: equioscila entre $\pm\varepsilon_k$, tocando el máximo $k+1$ veces.

$\varepsilon_4 = 1/577$, $\varepsilon_5 = 1/3363$, $\varepsilon_6 = 1/19\,601$. Aquí $\kappa_2(A) = 2$: factor ≈ 0.17 por iteración.

Convergencia del GC vía Chebyshev

Teorema

Sea A sdp, x_* solución de $Ax = b$. Para todo x_0:

$$\|x_k - x_*\|_A \;\leq\; 2\left(\frac{\sqrt{\kappa_2(A)}-1}{\sqrt{\kappa_2(A)}+1}\right)^k \|x_0 - x_*\|_A, \qquad k \geq 0.$$

Convergencia del GC vía Chebyshev

Teorema

Sea A sdp, x_* solución de $Ax = b$. Para todo x_0:

$$\|x_k - x_*\|_A \;\leq\; 2\left(\frac{\sqrt{\kappa_2(A)}-1}{\sqrt{\kappa_2(A)}+1}\right)^k \|x_0 - x_*\|_A, \qquad k \geq 0.$$

Idea: Se elige $p_k(\lambda) = T_k(x(\lambda))/T_k(x(0)) \in \overline{\mathcal{P}}_k$ con T_k los polinomios de Chebyshev. Como $|T_k| \leq 1$ en $[-1, 1]$ y

$$|T_k(x(0))| \geq \tfrac{1}{2}\left(\tfrac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1}\right)^k,$$

se obtiene la cota del corolario anterior.

GC vs. SD: comparación de tasas

Tasas de convergencia (A sdp)

Método	**Factor de reducción**	$\kappa_2 = 100$
Richardson / SD	$\dfrac{\kappa - 1}{\kappa + 1}$	0.980
GC (Chebyshev)	$2\left(\dfrac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\right)^k$	$2 \times (0.818)^k$

GC vs. SD: comparación de tasas

Tasas de convergencia (A sdp)

Método	**Factor de reducción**	$\kappa_2 = 100$
Richardson / SD	$\dfrac{\kappa - 1}{\kappa + 1}$	0.980
GC (Chebyshev)	$2\left(\dfrac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\right)^k$	$2 \times (0.818)^k$

- Para $\kappa = 100$: SD necesita ~ 100 iteraciones para reducir el error en 10^{-2}; GC necesita ~ 10.
- GC converge mucho más rápido para matrices mal condicionadas.
- La constante 2 delante desaparece asintóticamente.

Para recordar

1. Para A sdp: resolver $Ax = b \iff$ minimizar $\phi(x) = \frac{1}{2}x^T Ax - x^T b$.
2. **Steepest descent:** mueve en dirección $r_k = b - Ax_k$ con $\alpha = r_k^T r_k / r_k^T A r_k$. Misma tasa que Richardson óptimo, pero sin necesitar el espectro.
3. **GC (preliminar):** x_{k+1} minimiza ϕ sobre $x_0 + \mathcal{K}_{k+1}$. Los residuos son ortogonales; termina en $\leq n$ pasos.
4. Los subespacios de búsqueda son los espacios de Krylov $\mathcal{K}_{k+1} = \text{span}\{r_0, Ar_0, \ldots, A^k r_0\}$.
5. **Cota de error del GC:** $\|x_k - x_*\|_A = \min_{p \in \overline{\mathcal{P}}_k} \|p(A)e_0\|_A$.
6. Con Chebyshev: factor $\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$ vs. $\left(\frac{\kappa-1}{\kappa+1}\right)$ de SD. Para $\kappa = 100$: GC necesita $\sim 10\times$ menos iteraciones.