Gradiente conjugado: cotas de error

Clase 9 · Capítulo 5 · Secciones 5.1.2–5.1.4

Análisis Numérico (LMA) · Métodos Numéricos II (LCD)

15 de septiembre de 2026

Facultad de Ingeniería Química · UNL

Plan de la clase

Clase 9

1. **Repaso:** el funcional de energía y el lema de caracterización.
2. **Repaso (5.1.2):** GC, ortogonalidad de los residuos, espacios de Krylov.
3. **5.1.3** Cotas de error: polinomios residuales y Tchebychev.
4. **5.1.4** El GC como método directo.

Punto de partida: veníamos de demostrar el Lema 5.12 (los residuos generan el espacio de Krylov).

Repaso El funcional de energía

Resolver $Ax = b$ = minimizar ϕ

Sea $A \in \mathbb{R}^{n \times n}$ sdp y $b \in \mathbb{R}^n$. Definimos el *funcional de energía*

$$\phi(x) = \tfrac{1}{2} x^T A x - b^T x, \qquad x \in \mathbb{R}^n.$$

Teorema

El mínimo de ϕ en $\mathbb{R}^n$ se alcanza **únicamente** *en la solución x_* de $Ax = b$, y el valor mínimo es $-\frac{1}{2} b^T x_*$.*

Resolver $Ax = b$ = minimizar ϕ

Sea $A \in \mathbb{R}^{n \times n}$ sdp y $b \in \mathbb{R}^n$. Definimos el *funcional de energía*

$$\phi(x) = \tfrac{1}{2} x^T A x - b^T x, \qquad x \in \mathbb{R}^n.$$

Teorema

El mínimo de ϕ en $\mathbb{R}^n$ se alcanza **únicamente** *en la solución x_* de $Ax = b$, y el valor mínimo es $-\frac{1}{2} b^T x_*$.*

Gradiente de ϕ

$$\nabla\phi(x) = Ax - b \qquad \Longrightarrow \qquad r_k = b - Ax_k = -\nabla\phi(x_k).$$

El residuo es la dirección de máximo descenso de ϕ en x_k.

La identidad clave

Para todo $y \in \mathbb{R}^n$

$$\phi(y) \;=\; \phi(x_*) \;+\; \tfrac{1}{2}\,\|y - x_*\|_A^2, \qquad \|z\|_A := \sqrt{z^T A z}.$$

La identidad clave

Para todo $y \in \mathbb{R}^n$

$$\phi(y) \;=\; \phi(x_*) \;+\; \tfrac{1}{2}\,\|y - x_*\|_A^2, \qquad \|z\|_A := \sqrt{z^T A z}.$$

Verificación (en el pizarrón): escribir $y = x_* + e$ y usar $Ax_* = b$:

$$\phi(x_* + e) = \tfrac{1}{2}(x_* + e)^T A(x_* + e) - b^T(x_* + e) = \phi(x_*) + e^T \underbrace{(Ax_* - b)}_{=0} + \tfrac{1}{2} e^T A e.$$

La identidad clave

Para todo $y \in \mathbb{R}^n$

$$\phi(y) \;=\; \phi(x_*) \;+\; \tfrac{1}{2}\,\|y - x_*\|_A^2, \qquad \|z\|_A := \sqrt{z^T A z}.$$

Verificación (en el pizarrón): escribir $y = x_* + e$ y usar $Ax_* = b$:

$$\phi(x_* + e) = \tfrac{1}{2}(x_* + e)^T A(x_* + e) - b^T(x_* + e) = \phi(x_*) + e^T \underbrace{(Ax_* - b)}_{=0} + \tfrac{1}{2} e^T A e.$$

Lectura: ϕ y $\frac{1}{2}\|\cdot - x_*\|_A^2$ difieren en una constante (no depende de y). Son *la misma* función, corrida verticalmente.

Lema de caracterización (Lema 5.3)

Lema

Sean A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$, y sea $S \subset \mathbb{R}^n$ un conjunto cualquiera (en particular, un subespacio o un espacio afín). Entonces, para $y \in S$:

$$y \text{ minimiza } \phi \text{ sobre } S \iff y \text{ minimiza } \|\cdot - x_*\|_A \text{ sobre } S.$$

Lema de caracterización (Lema 5.3)

Lema

Sean A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$, y sea $S \subset \mathbb{R}^n$ un conjunto cualquiera (en particular, un subespacio o un espacio afín). Entonces, para $y \in S$:

$$y \text{ minimiza } \phi \text{ sobre } S \iff y \text{ minimiza } \|\cdot - x_*\|_A \text{ sobre } S.$$

Demostración: inmediata de $\phi(y) = \phi(x_*) + \frac{1}{2}\|y - x_*\|_A^2$, porque $t \mapsto \phi(x_*) + \frac{1}{2}t^2$ es creciente en $t \geq 0$.

Lema de caracterización (Lema 5.3)

Lema

Sean A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$, y sea $S \subset \mathbb{R}^n$ un conjunto cualquiera (en particular, un subespacio o un espacio afín). Entonces, para $y \in S$:

$$y \text{ minimiza } \phi \text{ sobre } S \iff y \text{ minimiza } \|\cdot - x_*\|_A \text{ sobre } S.$$

Demostración: inmediata de $\phi(y) = \phi(x_*) + \frac{1}{2}\|y - x_*\|_A^2$, porque $t \mapsto \phi(x_*) + \frac{1}{2}t^2$ es creciente en $t \geq 0$.

Esta es la herramienta de toda la clase

Cada iteración que *minimiza ϕ sobre un afín* está, en realidad, buscando el punto de ese afín más cercano a x_* en norma A. Así se traducen preguntas de optimización en preguntas de aproximación.

5.1.2 Gradiente conjugado: repaso

La definición del método (Versión preliminar 1)

En el Steepest descent, x_{k+1} minimiza ϕ sobre la *recta* $\{x_k + \alpha r_k\}$: se "olvida" de las direcciones anteriores.

La definición del método (Versión preliminar 1)

En el Steepest descent, x_{k+1} minimiza ϕ sobre la *recta* $\{x_k + \alpha r_k\}$: se "olvida" de las direcciones anteriores.

Idea del GC: acumular las direcciones

$$x_{k+1} = \operatorname*{argmin}_{x \in x_0 + \operatorname{span}\{r_0, r_1, \ldots, r_k\}} \phi(x), \qquad k \geq 0, \qquad r_i = b - Ax_i.$$

La definición del método (Versión preliminar 1)

En el Steepest descent, x_{k+1} minimiza ϕ sobre la *recta* $\{x_k + \alpha r_k\}$: se "olvida" de las direcciones anteriores.

Idea del GC: acumular las direcciones

$$x_{k+1} = \operatorname*{argmin}_{x \in x_0 + \operatorname{span}\{r_0, r_1, \ldots, r_k\}} \phi(x), \qquad k \geq 0, \qquad r_i = b - Ax_i.$$

Por el lema de caracterización, esto equivale a

$$\|x_{k+1} - x_*\|_A = \min_{x \in x_0 + \operatorname{span}\{r_0, \ldots, r_k\}} \|x - x_*\|_A,$$

es decir, x_{k+1} es el punto del afín más cercano a x_* en norma A.

La definición del método (Versión preliminar 1)

En el Steepest descent, x_{k+1} minimiza ϕ sobre la *recta* $\{x_k + \alpha r_k\}$: se "olvida" de las direcciones anteriores.

Idea del GC: acumular las direcciones

$$x_{k+1} = \operatorname*{argmin}_{x \in x_0 + \operatorname{span}\{r_0, r_1, \ldots, r_k\}} \phi(x), \qquad k \geq 0, \qquad r_i = b - Ax_i.$$

Por el lema de caracterización, esto equivale a

$$\|x_{k+1} - x_*\|_A = \min_{x \in x_0 + \operatorname{span}\{r_0, \ldots, r_k\}} \|x - x_*\|_A,$$

es decir, x_{k+1} es el punto del afín más cercano a x_* en norma A.

Consecuencia inmediata: GC es, en cada paso, al menos tan bueno como SD (el afín de SD está contenido en el del GC).

Lo que ya demostramos

Lema (Lema 5.10 — ortogonalidad de los residuos)

$r_k \perp \operatorname{span}\{r_0, r_1, \ldots, r_{k-1}\}$, *para todo* $k \geq 1$.

(Porque $t \mapsto \phi(x_k + t\xi)$ tiene un mínimo en $t = 0$, luego $\xi^T \nabla\phi(x_k) = -\xi^T r_k = 0$.)

Lo que ya demostramos

Lema (Lema 5.10 — ortogonalidad de los residuos)

$r_k \perp \operatorname{span}\{r_0, r_1, \ldots, r_{k-1}\}$, *para todo* $k \geq 1$.

(Porque $t \mapsto \phi(x_k + t\xi)$ tiene un mínimo en $t = 0$, luego $\xi^T \nabla\phi(x_k) = -\xi^T r_k = 0$.)

Observación 5.11

Si $r_k \neq 0$, entonces $\{r_0, r_1, \ldots, r_k\}$ es linealmente independiente.

Lo que ya demostramos

Lema (Lema 5.10 — ortogonalidad de los residuos)

$r_k \perp \operatorname{span}\{r_0, r_1, \ldots, r_{k-1}\}$, *para todo* $k \geq 1$.

(Porque $t \mapsto \phi(x_k + t\xi)$ tiene un mínimo en $t = 0$, luego $\xi^T \nabla\phi(x_k) = -\xi^T r_k = 0$.)

Observación 5.11

Si $r_k \neq 0$, entonces $\{r_0, r_1, \ldots, r_k\}$ es linealmente independiente.

Lema (Lema 5.12 — espacios de Krylov)

Si $r_k \neq 0$, *entonces para todo* $k \geq 0$

$$\operatorname{span}\{r_0, r_1, \ldots, r_k\} = \operatorname{span}\{r_0, Ar_0, \ldots, A^k r_0\} =: \mathcal{K}_{k+1}.$$

Lo que ya demostramos

Lema (Lema 5.10 — ortogonalidad de los residuos)

$r_k \perp \text{span}\{r_0, r_1, \ldots, r_{k-1}\}$, *para todo* $k \geq 1$.

(Porque $t \mapsto \phi(x_k + t\xi)$ tiene un mínimo en $t = 0$, luego $\xi^T \nabla\phi(x_k) = -\xi^T r_k = 0$.)

Observación 5.11

Si $r_k \neq 0$, entonces $\{r_0, r_1, \ldots, r_k\}$ es linealmente independiente.

Lema (Lema 5.12 — espacios de Krylov)

Si $r_k \neq 0$, *entonces para todo* $k \geq 0$

$$\text{span}\{r_0, r_1, \ldots, r_k\} = \text{span}\{r_0, Ar_0, \ldots, A^k r_0\} =: \mathcal{K}_{k+1}.$$

Reformulación del método

$$x_k = \operatorname*{argmin}_{x \in x_0 + \mathcal{K}_k} \phi(x) \qquad \Longleftrightarrow \qquad \|x_k - x_*\|_A = \min_{w \in x_0 + \mathcal{K}_k} \|w - x_*\|_A.$$

GC es un *método de subespacios de Krylov*.

5.1.3 Cotas de error para el GC

De un afín a un conjunto de polinomios

Si $w \in x_0 + \mathcal{K}_k$, entonces

$$w = x_0 + \sum_{i=0}^{k-1} \gamma_i A^i r_0, \qquad \gamma_0, \ldots, \gamma_{k-1} \in \mathbb{R}.$$

De un afín a un conjunto de polinomios

Si $w \in x_0 + \mathcal{K}_k$, entonces

$$w = x_0 + \sum_{i=0}^{k-1} \gamma_i A^i r_0, \qquad \gamma_0, \ldots, \gamma_{k-1} \in \mathbb{R}.$$

Observación clave: $r_0 = b - Ax_0 = Ax_* - Ax_0 = -A(x_0 - x_*)$.

De un afín a un conjunto de polinomios

Si $w \in x_0 + \mathcal{K}_k$, entonces

$$w = x_0 + \sum_{i=0}^{k-1} \gamma_i A^i r_0, \qquad \gamma_0, \ldots, \gamma_{k-1} \in \mathbb{R}.$$

Observación clave: $r_0 = b - Ax_0 = Ax_* - Ax_0 = -A(x_0 - x_*)$.

En el pizarrón: sustituyendo y agrupando,

$$w - x_* = (x_0 - x_*) + \sum_{i=0}^{k-1} \gamma_i A^{i+1}(x_* - x_0) = \Big(I - \sum_{i=0}^{k-1} \gamma_i A^{i+1}\Big)(x_0 - x_*).$$

De un afín a un conjunto de polinomios

Si $w \in x_0 + \mathcal{K}_k$, entonces

$$w = x_0 + \sum_{i=0}^{k-1} \gamma_i A^i r_0, \qquad \gamma_0, \ldots, \gamma_{k-1} \in \mathbb{R}.$$

Observación clave: $r_0 = b - Ax_0 = Ax_* - Ax_0 = -A(x_0 - x_*)$.

En el pizarrón: sustituyendo y agrupando,

$$w - x_* = (x_0 - x_*) + \sum_{i=0}^{k-1} \gamma_i A^{i+1}(x_* - x_0) = \Big(I - \sum_{i=0}^{k-1} \gamma_i A^{i+1}\Big)(x_0 - x_*).$$

Es decir

$$w - x_* = p(A)\,(x_0 - x_*), \qquad p(z) = 1 - \sum_{i=0}^{k-1} \gamma_i z^{i+1},$$

con $p \in \mathcal{P}_k$ y $p(0) = 1$. Y recíprocamente: todo tal p da un w del afín.

Polinomios residuales y la cota óptima

Definición (Polinomios residuales)

$$\overline{\mathcal{P}}_k := \{\, p \in \mathcal{P}_k \;\mid\; p(0) = 1 \,\}.$$

Polinomios residuales y la cota óptima

Definición (Polinomios residuales)

$$\overline{\mathcal{P}}_k := \{\, p \in \mathcal{P}_k \;\mid\; p(0) = 1 \,\}.$$

Teorema (Teorema 5.13)

Sean A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$ y $\{x_k\}$ la sucesión del GC a partir de x_0. Entonces

$$\|x_k - x_*\|_A \;=\; \min_{p \in \overline{\mathcal{P}}_k} \|p(A)(x_0 - x_*)\|_A, \qquad k \geq 0.$$

Polinomios residuales y la cota óptima

Definición (Polinomios residuales)

$$\overline{\mathcal{P}}_k := \{\, p \in \mathcal{P}_k \;\mid\; p(0) = 1 \,\}.$$

Teorema (Teorema 5.13)

Sean A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$ y $\{x_k\}$ la sucesión del GC a partir de x_0. Entonces

$$\|x_k - x_*\|_A \;=\; \min_{p \in \overline{\mathcal{P}}_k} \|p(A)(x_0 - x_*)\|_A, \qquad k \geq 0.$$

Interpretación: el GC elige implícitamente el mejor polinomio residual de grado $\leq k$. No hay que calcularlo: el algoritmo lo hace "gratis".

Polinomios residuales y la cota óptima

Definición (Polinomios residuales)

$$\overline{\mathcal{P}}_k := \{\, p \in \mathcal{P}_k \;\mid\; p(0) = 1 \,\}.$$

Teorema (Teorema 5.13)

Sean A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$ y $\{x_k\}$ la sucesión del GC a partir de x_0. Entonces

$$\|x_k - x_*\|_A \;=\; \min_{p \in \overline{\mathcal{P}}_k} \|p(A)(x_0 - x_*)\|_A, \qquad k \geq 0.$$

Interpretación: el GC elige implícitamente el mejor polinomio residual de grado $\leq k$. No hay que calcularlo: el algoritmo lo hace "gratis".

¿Y para qué sirve? Para *acotar*: cualquier $p \in \overline{\mathcal{P}}_k$ que propongamos da una cota superior del error.

Corolario 5.14: cota espectral

Corolario

En las hipótesis anteriores,

$$\|x_k - x_*\|_A \leq \left(\max_{\lambda \in \sigma(A)} |p(\lambda)| \right) \|x_0 - x_*\|_A, \qquad \forall\, p \in \overline{\mathcal{P}}_k.$$

Corolario 5.14: cota espectral

Corolario

En las hipótesis anteriores,

$$\|x_k - x_*\|_A \;\leq\; \Big(\max_{\lambda\in\sigma(A)} |p(\lambda)|\Big)\, \|x_0 - x_*\|_A, \qquad \forall\, p \in \overline{\mathcal{P}}_k.$$

Demostración (dos pasos).

1. $\|p(A)\|_A \leq \|p(A)\|_2$: usando $A^{1/2}$ y que $p(A)$ conmuta con $A^{1/2}$,
$$\|p(A)x\|_A = \|A^{1/2}p(A)x\|_2 = \|p(A)A^{1/2}x\|_2 \leq \|p(A)\|_2\, \|A^{1/2}x\|_2 = \|p(A)\|_2\, \|x\|_A.$$

Corolario 5.14: cota espectral

Corolario

En las hipótesis anteriores,

$$\|x_k - x_*\|_A \;\leq\; \Big(\max_{\lambda\in\sigma(A)} |p(\lambda)|\Big)\, \|x_0 - x_*\|_A, \qquad \forall\, p \in \overline{\mathcal{P}}_k.$$

Demostración (dos pasos).

1. $\|p(A)\|_A \leq \|p(A)\|_2$: usando $A^{1/2}$ y que $p(A)$ conmuta con $A^{1/2}$,
$$\|p(A)x\|_A = \|A^{1/2}p(A)x\|_2 = \|p(A)A^{1/2}x\|_2 \leq \|p(A)\|_2\, \|A^{1/2}x\|_2 = \|p(A)\|_2\, \|x\|_A.$$

2. $\|p(A)\|_2 = \max_{\lambda\in\sigma(A)} |p(\lambda)|$: si $A = V\Lambda V^T$ con V ortogonal, entonces $p(A) = Vp(\Lambda)V^T$, luego $\sigma(p(A)) = \{p(\lambda) : \lambda \in \sigma(A)\}$; y como $p(A)$ es simétrica, $\|p(A)\|_2 = \rho(p(A))$.

Corolario 5.14: cota espectral

Corolario

En las hipótesis anteriores,

$$\|x_k - x_*\|_A \;\leq\; \Big(\max_{\lambda\in\sigma(A)} |p(\lambda)|\Big)\, \|x_0 - x_*\|_A, \qquad \forall\, p \in \overline{\mathcal{P}}_k.$$

Demostración (dos pasos).

1. $\|p(A)\|_A \leq \|p(A)\|_2$: usando $A^{1/2}$ y que $p(A)$ conmuta con $A^{1/2}$,
$$\|p(A)x\|_A = \|A^{1/2}p(A)x\|_2 = \|p(A)A^{1/2}x\|_2 \leq \|p(A)\|_2\, \|A^{1/2}x\|_2 = \|p(A)\|_2\, \|x\|_A.$$

2. $\|p(A)\|_2 = \max_{\lambda\in\sigma(A)} |p(\lambda)|$: si $A = V\Lambda V^T$ con V ortogonal, entonces $p(A) = Vp(\Lambda)V^T$, luego $\sigma(p(A)) = \{p(\lambda) : \lambda \in \sigma(A)\}$; y como $p(A)$ es simétrica, $\|p(A)\|_2 = \rho(p(A))$.

Estrategia

Si $\sigma(A) \subset [\lambda_{\min}, \lambda_{\max}]$, buscamos $p \in \overline{\mathcal{P}}_k$ chico en ese intervalo (y que valga 1 en 0).

Dos ejemplos de uso del corolario

(a) Espectro agrupado. Si $\sigma(A) \subset [1-\delta, 1+\delta]$ con $\delta < 1$, tomamos $p(\lambda) = (1-\lambda)^k \in \overline{\mathcal{P}}_k$. Entonces

$$\max_{\lambda \in \sigma(A)} |p(\lambda)| \leq \delta^k \qquad \Longrightarrow \qquad \|x_k - x_*\|_A \leq \delta^k \|x_0 - x_*\|_A.$$

Dos ejemplos de uso del corolario

(a) Espectro agrupado. Si $\sigma(A) \subset [1-\delta, 1+\delta]$ con $\delta < 1$, tomamos $p(\lambda) = (1-\lambda)^k \in \overline{\mathcal{P}}_k$. Entonces

$$\max_{\lambda \in \sigma(A)} |p(\lambda)| \leq \delta^k \qquad \Longrightarrow \qquad \|x_k - x_*\|_A \leq \delta^k \|x_0 - x_*\|_A.$$

(b) Un autovalor aislado. Si $\sigma(A) \subset [1-\delta, 1+\delta] \cup \{\Lambda\}$, tomamos

$$p(\lambda) = \left(1 - \frac{\lambda}{\Lambda}\right)(1-\lambda)^{k-1} \in \overline{\mathcal{P}}_k,$$

que anula el autovalor aislado. Entonces $\|x_k - x_*\|_A \leq C\, \delta^{k-1} \|x_0 - x_*\|_A$.

Dos ejemplos de uso del corolario

(a) Espectro agrupado. Si $\sigma(A) \subset [1-\delta, 1+\delta]$ con $\delta < 1$, tomamos $p(\lambda) = (1-\lambda)^k \in \overline{\mathcal{P}}_k$. Entonces

$$\max_{\lambda \in \sigma(A)} |p(\lambda)| \leq \delta^k \qquad \Longrightarrow \qquad \|x_k - x_*\|_A \leq \delta^k \|x_0 - x_*\|_A.$$

(b) Un autovalor aislado. Si $\sigma(A) \subset [1-\delta, 1+\delta] \cup \{\Lambda\}$, tomamos

$$p(\lambda) = \left(1 - \frac{\lambda}{\Lambda}\right)(1-\lambda)^{k-1} \in \overline{\mathcal{P}}_k,$$

que anula el autovalor aislado. Entonces $\|x_k - x_*\|_A \leq C\, \delta^{k-1} \|x_0 - x_*\|_A$.

Moraleja

Lo que importa no es solo $\kappa_2(A)$, sino cómo está distribuido el espectro. Unos pocos autovalores "molestos" cuestan unas pocas iteraciones extra. (Esta es la idea que después motiva el *precondicionamiento*.)

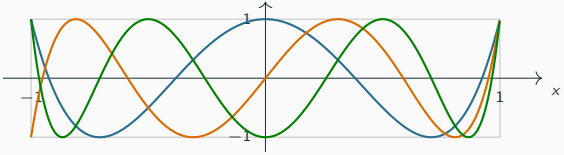
Polinomios de Tchebychev

Definición

$$T_0(x) = 1, \qquad T_1(x) = x, \qquad T_k(x) = 2x\,T_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Equivalentemente, $T_k(x) = \cos\big(k \arccos x\big)$ para $x \in [-1, 1]$. En particular

$$\max_{x\in[-1,1]} |T_k(x)| = 1, \qquad \text{y } |T_k| \text{ crece muy rápido fuera de } [-1, 1].$$

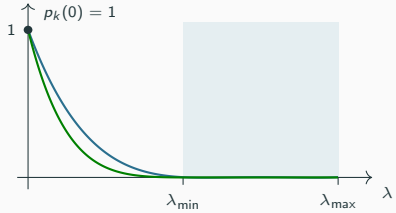


T_4, T_5, T_6: T_k *equioscila* entre -1 y 1, alcanzando ± 1 exactamente $k + 1$ veces en $[-1, 1]$.

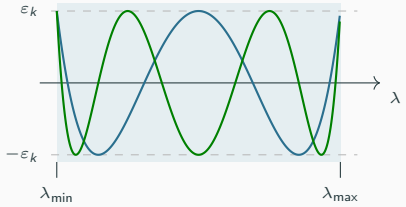
Construcción de p_k: ejemplo $\lambda_{\min} = 1$, $\lambda_{\max} = 2$

$$x(\lambda) = \frac{\lambda - \frac{\lambda_{\max}+\lambda_{\min}}{2}}{\frac{\lambda_{\max}-\lambda_{\min}}{2}} = 2\lambda - 3, \quad p_k(\lambda) := \frac{T_k(x(\lambda))}{T_k(x(0))} = \frac{T_k(2\lambda-3)}{T_k(-3)}, \quad \varepsilon_k := \frac{1}{|T_k(-3)|}.$$

Vista global: p_4, p_6



Zoom en $[\lambda_{\min}, \lambda_{\max}]$, en unidades de ε_k



Cada p_k dividida por su propio ε_k: equioscila entre $\pm\varepsilon_k$, tocando el máximo $k+1$ veces.

$\varepsilon_4 = 1/577$, $\varepsilon_5 = 1/3363$, $\varepsilon_6 = 1/19\,601$. Aquí $\kappa_2(A) = 2$: factor ≈ 0.17 por iteración.

Teorema 5.15: convergencia del GC vía Tchebychev

Teorema

Sea A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$. Para todo $x_0 \in \mathbb{R}^n$,

$$\|x_k - x_*\|_A \;\leq\; 2\left(\frac{\sqrt{\kappa_2(A)}-1}{\sqrt{\kappa_2(A)}+1}\right)^k \|x_0 - x_*\|_A, \qquad k \geq 0.$$

Teorema 5.15: convergencia del GC vía Tchebychev

Teorema

Sea A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$. Para todo $x_0 \in \mathbb{R}^n$,

$$\|x_k - x_*\|_A \;\leq\; 2\left(\frac{\sqrt{\kappa_2(A)}-1}{\sqrt{\kappa_2(A)}+1}\right)^k \|x_0 - x_*\|_A, \qquad k \geq 0.$$

Demostración (esquema). Tomamos $p_k(\lambda) = T_k(x(\lambda))/T_k(x(0)) \in \overline{\mathcal{P}}_k$. Como $|T_k| \leq 1$ en $[-1,1]$,

$$\max_{\lambda\in\sigma(A)} |p_k(\lambda)| \;\leq\; \frac{1}{|T_k(x(0))|}.$$

Teorema 5.15: convergencia del GC vía Tchebychev

Teorema

Sea A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$. Para todo $x_0 \in \mathbb{R}^n$,

$$\|x_k - x_*\|_A \;\leq\; 2\left(\frac{\sqrt{\kappa_2(A)}-1}{\sqrt{\kappa_2(A)}+1}\right)^k \|x_0 - x_*\|_A, \qquad k \geq 0.$$

Demostración (esquema). Tomamos $p_k(\lambda) = T_k(x(\lambda))/T_k(x(0)) \in \overline{\mathcal{P}}_k$. Como $|T_k| \leq 1$ en $[-1,1]$,

$$\max_{\lambda\in\sigma(A)} |p_k(\lambda)| \;\leq\; \frac{1}{|T_k(x(0))|}.$$

Resta acotar $|T_k(x(0))|$ *por debajo*. Con $c = \kappa_2(A)$,

$$x(0) = -\frac{c+1}{c-1} = \frac{z+z^{-1}}{2}, \qquad z = -\frac{\sqrt{c}-1}{\sqrt{c}+1}.$$

Teorema 5.15: el cierre de la cuenta

Ejercicio (en el pizarrón)

Si $x = \dfrac{z + z^{-1}}{2}$ con $z \neq 0$, entonces $T_k(x) = \dfrac{z^k + z^{-k}}{2}$.

Sugerencia: verificarlo para $k = 0, 1$ y usar la recurrencia $T_k = 2xT_{k-1} - T_{k-2}$.

Teorema 5.15: el cierre de la cuenta

Ejercicio (en el pizarrón)

Si $x = \dfrac{z + z^{-1}}{2}$ con $z \neq 0$, entonces $T_k(x) = \dfrac{z^k + z^{-k}}{2}$.

Sugerencia: verificarlo para $k = 0, 1$ y usar la recurrencia $T_k = 2xT_{k-1} - T_{k-2}$.

Con $z = -\frac{\sqrt{c}-1}{\sqrt{c}+1}$ (notar $|z| < 1$, $|z^{-1}| > 1$):

$$T_k(x(0)) = (-1)^k \frac{1}{2}\left[\left(\frac{\sqrt{c}-1}{\sqrt{c}+1}\right)^k + \left(\frac{\sqrt{c}+1}{\sqrt{c}-1}\right)^k\right] \quad \Longrightarrow \quad |T_k(x(0))| \geq \frac{1}{2}\left(\frac{\sqrt{c}+1}{\sqrt{c}-1}\right)^k.$$

Teorema 5.15: el cierre de la cuenta

Ejercicio (en el pizarrón)

Si $x = \dfrac{z + z^{-1}}{2}$ con $z \neq 0$, entonces $T_k(x) = \dfrac{z^k + z^{-k}}{2}$.

Sugerencia: verificarlo para $k = 0, 1$ y usar la recurrencia $T_k = 2xT_{k-1} - T_{k-2}$.

Con $z = -\frac{\sqrt{c}-1}{\sqrt{c}+1}$ (notar $|z| < 1$, $|z^{-1}| > 1$):

$$T_k(x(0)) = (-1)^k \frac{1}{2}\left[\left(\frac{\sqrt{c}-1}{\sqrt{c}+1}\right)^k + \left(\frac{\sqrt{c}+1}{\sqrt{c}-1}\right)^k\right] \quad \Longrightarrow \quad |T_k(x(0))| \geq \frac{1}{2}\left(\frac{\sqrt{c}+1}{\sqrt{c}-1}\right)^k.$$

Y por lo tanto

$$\max_{\lambda \in \sigma(A)} |p_k(\lambda)| \leq \frac{1}{|T_k(x(0))|} \leq 2\left(\frac{\sqrt{c}-1}{\sqrt{c}+1}\right)^k.$$

El Corolario 5.14 concluye la demostración. ■

GC vs. SD: comparación de tasas

Factor de reducción del error en norma A (A sdp, $\kappa = \kappa_2(A)$)

Método	**Cota**	$\kappa = 100$
Richardson óptimo / SD	$\left(\frac{\kappa-1}{\kappa+1}\right)^k$	$(0.980)^k$
GC (Tchebychev)	$2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$	$2\,(0.818)^k$

GC vs. SD: comparación de tasas

Factor de reducción del error en norma A (A sdp, $\kappa = \kappa_2(A)$)

Método	**Cota**	$\kappa = 100$
Richardson óptimo / SD	$\left(\frac{\kappa-1}{\kappa+1}\right)^k$	$(0.980)^k$
GC (Tchebychev)	$2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$	$2\,(0.818)^k$

- Reducir el error en 10^{-2}: SD necesita ~ 230 iteraciones; GC, ~ 30.
- κ vs. $\sqrt{\kappa}$: la diferencia crece al empeorar el condicionamiento.
- La constante 2 es asintóticamente irrelevante.
- Ojo: la del GC es solo una cota (usa un p particular). El GC suele andar mejor, sobre todo si el espectro está agrupado.

5.1.4 El GC como método directo

Termina en a lo sumo n pasos

Argumento

Si $r_n \neq 0$, entonces $\{r_0, r_1, \ldots, r_n\}$ sería un conjunto de $n+1$ vectores ortogonales y no nulos en $\mathbb{R}^n$: imposible. Luego $r_n = 0$, es decir, $x_n = x_*$.

Termina en a lo sumo n pasos

Argumento

Si $r_n \neq 0$, entonces $\{r_0, r_1, \ldots, r_n\}$ sería un conjunto de $n+1$ vectores ortogonales y no nulos en $\mathbb{R}^n$: imposible. Luego $r_n = 0$, es decir, $x_n = x_*$.

Teorema

Sea A sdp y $b \in \mathbb{R}^n$. Si A tiene k autovalores **distintos**, *el GC converge a x_* en a lo sumo k pasos, cualquiera sea x_0.*

Termina en a lo sumo n pasos

Argumento

Si $r_n \neq 0$, entonces $\{r_0, r_1, \ldots, r_n\}$ sería un conjunto de $n+1$ vectores ortogonales y no nulos en $\mathbb{R}^n$: imposible. Luego $r_n = 0$, es decir, $x_n = x_*$.

Teorema

Sea A sdp y $b \in \mathbb{R}^n$. Si A tiene k autovalores **distintos**, *el GC converge a x_* en a lo sumo k pasos, cualquiera sea x_0.*

Demostración. Sean $\lambda_1, \ldots, \lambda_k$ los autovalores distintos. Tomamos

$$p(z) := \frac{(\lambda_1 - z)(\lambda_2 - z)\cdots(\lambda_k - z)}{\lambda_1 \lambda_2 \cdots \lambda_k} \in \overline{\mathcal{P}}_k.$$

Entonces $\max_{\lambda \in \sigma(A)} |p(\lambda)| = 0$ y, por el Corolario 5.14, $\|x_k - x_*\|_A \leq 0$. ■

Un segundo resultado de terminación finita

Teorema

Sea A sdp y $b \in \mathbb{R}^n$. Si b es combinación lineal de k autovectores de A, entonces el GC aplicado a $Ax = b$ **partiendo de** $x_0 = 0$ *converge en a lo sumo k pasos.*

Un segundo resultado de terminación finita

Teorema

Sea A sdp y $b \in \mathbb{R}^n$. Si b es combinación lineal de k autovectores de A, entonces el GC aplicado a $Ax = b$ **partiendo de** $x_0 = 0$ *converge en a lo sumo k pasos.*

Demostración: *ejercicio.*

Sugerencia: usar el Teorema 5.13. Si $x_* = \sum_{j \in J} c_j v_j$ con $|J| = k$ y $Av_j = \lambda_j v_j$, y $x_0 = 0$, tomar el $p \in \overline{\mathcal{P}}_k$ que anula $\{\lambda_j\}_{j \in J}$ y calcular $p(A)(x_0 - x_*)$.

Un segundo resultado de terminación finita

Teorema

Sea A sdp y $b \in \mathbb{R}^n$. Si b es combinación lineal de k autovectores de A, entonces el GC aplicado a $Ax = b$ **partiendo de** $x_0 = 0$ *converge en a lo sumo k pasos.*

Demostración: *ejercicio.*

Sugerencia: usar el Teorema 5.13. Si $x_* = \sum_{j \in J} c_j v_j$ con $|J| = k$ y $Av_j = \lambda_j v_j$, y $x_0 = 0$, tomar el $p \in \overline{\mathcal{P}}_k$ que anula $\{\lambda_j\}_{j \in J}$ y calcular $p(A)(x_0 - x_*)$.

En la práctica

La terminación finita no se observa: los errores de redondeo destruyen la ortogonalidad de los residuos. Para n grande ($n = 10^5$, 10^6) tampoco se pretende hacer n iteraciones.

El GC se usa como método iterativo, con un criterio de parada asociado a una tolerancia. *(Lo vemos la clase que viene.)*

Para recordar

1. $\phi(y) = \phi(x_*) + \frac{1}{2}\|y - x_*\|_A^2$: minimizar ϕ sobre cualquier conjunto = minimizar la A-distancia a x_* sobre ese conjunto.
2. x_k minimiza ϕ sobre $x_0 + \mathcal{K}_k$, con $\mathcal{K}_k = \text{span}\{r_0, Ar_0, \ldots, A^{k-1}r_0\}$.
3. **Teo. 5.13:** $\|x_k - x_*\|_A = \min_{p \in \overline{\mathcal{P}}_k} \|p(A)(x_0 - x_*)\|_A$: el GC elige el *mejor* polinomio residual.
4. **Cor. 5.14:** $\|x_k - x_*\|_A \leq \max_{\lambda \in \sigma(A)} |p(\lambda)| \, \|x_0 - x_*\|_A$ para *todo* $p \in \overline{\mathcal{P}}_k$. Nos da libertad para elegir p.
5. Con Tchebychev: factor $\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$ frente a $\left(\frac{\kappa-1}{\kappa+1}\right)^k$ de SD.
6. Lo que manda es la distribución del espectro, no solo $\kappa_2(A)$: k autovalores distintos $\Rightarrow \leq k$ pasos.
7. **Próxima clase:** cómo calcular los x_k de manera económica (1 mat-vec y 4 vectores por iteración).