Gradiente conjugado: Tchebychev, terminación finita e implementación

Clase 10 · Capítulo 5 · Secciones 5.1.3–5.1.5

Análisis Numérico (LMA) · Métodos Numéricos II (LCD)

16 de septiembre de 2026

Facultad de Ingeniería Química · UNL

Dónde quedamos

Teorema 5.13 y Corolario 5.14

$$\|x_k - x_*\|_A = \min_{p \in \overline{\mathcal{P}}_k} \|p(A)(x_0 - x_*)\|_A \quad \Longrightarrow \quad \|x_k - x_*\|_A \leq \left(\max_{\lambda \in \sigma(A)} |p(\lambda)| \right) \|x_0 - x_*\|_A$$

para *todo* $p \in \overline{\mathcal{P}}_k = \{p \in \mathcal{P}_k : p(0) = 1\}$.

Dónde quedamos

Teorema 5.13 y Corolario 5.14

$$\|x_k - x_*\|_A = \min_{p \in \overline{\mathcal{P}}_k} \|p(A)(x_0 - x_*)\|_A \quad \Longrightarrow \quad \|x_k - x_*\|_A \leq \left(\max_{\lambda \in \sigma(A)} |p(\lambda)| \right) \|x_0 - x_*\|_A$$

para *todo* $p \in \overline{\mathcal{P}}_k = \{p \in \mathcal{P}_k : p(0) = 1\}$.

La pregunta abierta: ¿qué $p \in \overline{\mathcal{P}}_k$ conviene elegir si lo único que sabemos es que $\sigma(A) \subset [\lambda_{\min}, \lambda_{\max}]$?

Queremos p chico en todo el intervalo y con $p(0) = 1$: es un problema de aproximación *minimax*. Respuesta: Tchebychev.

Plan de la clase

1. **Fin de 5.1.3:** polinomios de Tchebychev y la cota $\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$ (Teo. 5.15). Comparación con SD.
2. **5.1.4** El GC como método directo: terminación finita.
3. **5.1.5** Implementación:
   - el paso del GC es un paso en *una* dirección d_{k+1};
   - las direcciones son A-ortogonales (*conjugadas*);
   - recurrencia de dos términos y fórmulas económicas;
   - criterio de parada y algoritmo final.

5.1.3 Cotas de error: la elección de Tchebychev

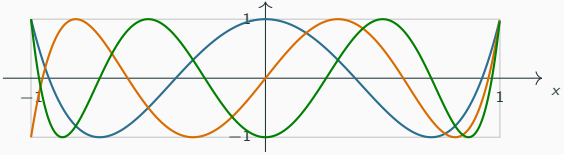
Polinomios de Tchebychev

Definición

$$T_0(x) = 1, \qquad T_1(x) = x, \qquad T_k(x) = 2x\,T_{k-1}(x) - T_{k-2}(x), \quad k \geq 2.$$

Equivalentemente, $T_k(x) = \cos\big(k \arccos x\big)$ para $x \in [-1, 1]$. En particular

$$\max_{x\in[-1,1]} |T_k(x)| = 1, \qquad \text{y } |T_k| \text{ crece muy rápido fuera de } [-1, 1].$$

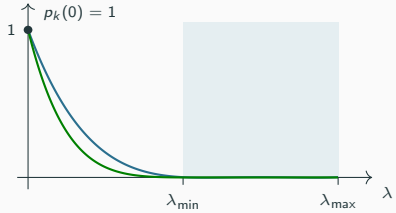


T_4, T_5, T_6: T_k *equioscila* entre -1 y 1, alcanzando ± 1 exactamente $k + 1$ veces en $[-1, 1]$.

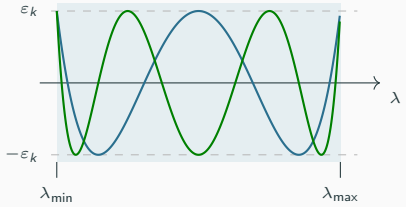
Construcción de p_k: ejemplo $\lambda_{\min} = 1$, $\lambda_{\max} = 2$

$$x(\lambda) = \frac{\lambda - \frac{\lambda_{\max}+\lambda_{\min}}{2}}{\frac{\lambda_{\max}-\lambda_{\min}}{2}} = 2\lambda - 3, \quad p_k(\lambda) := \frac{T_k(x(\lambda))}{T_k(x(0))} = \frac{T_k(2\lambda-3)}{T_k(-3)}, \quad \varepsilon_k := \frac{1}{|T_k(-3)|}.$$

Vista global: p_4, p_6



Zoom en $[\lambda_{\min}, \lambda_{\max}]$, en unidades de ε_k



Cada p_k dividida por su propio ε_k: equioscila entre $\pm\varepsilon_k$, tocando el máximo $k+1$ veces.

$\varepsilon_4 = 1/577$, $\varepsilon_5 = 1/3363$, $\varepsilon_6 = 1/19\,601$. Aquí $\kappa_2(A) = 2$: factor ≈ 0.17 por iteración.

Teorema 5.15: convergencia del GC vía Tchebychev

Teorema

Sea A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$. Para todo $x_0 \in \mathbb{R}^n$,

$$\|x_k - x_*\|_A \;\leq\; 2\left(\frac{\sqrt{\kappa_2(A)}-1}{\sqrt{\kappa_2(A)}+1}\right)^k \|x_0 - x_*\|_A, \qquad k \geq 0.$$

Teorema 5.15: convergencia del GC vía Tchebychev

Teorema

Sea A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$. Para todo $x_0 \in \mathbb{R}^n$,

$$\|x_k - x_*\|_A \;\leq\; 2\left(\frac{\sqrt{\kappa_2(A)}-1}{\sqrt{\kappa_2(A)}+1}\right)^k \|x_0 - x_*\|_A, \qquad k \geq 0.$$

Demostración (esquema). Tomamos $p_k(\lambda) = T_k(x(\lambda))/T_k(x(0)) \in \overline{\mathcal{P}}_k$. Como $|T_k| \leq 1$ en $[-1,1]$,

$$\max_{\lambda\in\sigma(A)} |p_k(\lambda)| \;\leq\; \frac{1}{|T_k(x(0))|}.$$

Teorema 5.15: convergencia del GC vía Tchebychev

Teorema

Sea A sdp, $b \in \mathbb{R}^n$, x_* la solución de $Ax = b$. Para todo $x_0 \in \mathbb{R}^n$,

$$\|x_k - x_*\|_A \;\leq\; 2\left(\frac{\sqrt{\kappa_2(A)}-1}{\sqrt{\kappa_2(A)}+1}\right)^k \|x_0 - x_*\|_A, \qquad k \geq 0.$$

Demostración (esquema). Tomamos $p_k(\lambda) = T_k(x(\lambda))/T_k(x(0)) \in \overline{\mathcal{P}}_k$. Como $|T_k| \leq 1$ en $[-1,1]$,

$$\max_{\lambda\in\sigma(A)} |p_k(\lambda)| \;\leq\; \frac{1}{|T_k(x(0))|}.$$

Resta acotar $|T_k(x(0))|$ *por debajo*. Con $c = \kappa_2(A)$,

$$x(0) = -\frac{c+1}{c-1} = \frac{z+z^{-1}}{2}, \qquad z = -\frac{\sqrt{c}-1}{\sqrt{c}+1}.$$

Teorema 5.15: el cierre de la cuenta

Ejercicio (en el pizarrón)

Si $x = \dfrac{z + z^{-1}}{2}$ con $z \neq 0$, entonces $T_k(x) = \dfrac{z^k + z^{-k}}{2}$.

Sugerencia: verificarlo para $k = 0, 1$ y usar la recurrencia $T_k = 2xT_{k-1} - T_{k-2}$.

Teorema 5.15: el cierre de la cuenta

Ejercicio (en el pizarrón)

Si $x = \dfrac{z + z^{-1}}{2}$ con $z \neq 0$, entonces $T_k(x) = \dfrac{z^k + z^{-k}}{2}$.

Sugerencia: verificarlo para $k = 0, 1$ y usar la recurrencia $T_k = 2xT_{k-1} - T_{k-2}$.

Con $z = -\frac{\sqrt{c}-1}{\sqrt{c}+1}$ (notar $|z| < 1$, $|z^{-1}| > 1$):

$$T_k(x(0)) = (-1)^k \frac{1}{2}\left[\left(\frac{\sqrt{c}-1}{\sqrt{c}+1}\right)^k + \left(\frac{\sqrt{c}+1}{\sqrt{c}-1}\right)^k\right] \quad \Longrightarrow \quad |T_k(x(0))| \geq \frac{1}{2}\left(\frac{\sqrt{c}+1}{\sqrt{c}-1}\right)^k.$$

Teorema 5.15: el cierre de la cuenta

Ejercicio (en el pizarrón)

Si $x = \dfrac{z + z^{-1}}{2}$ con $z \neq 0$, entonces $T_k(x) = \dfrac{z^k + z^{-k}}{2}$.

Sugerencia: verificarlo para $k = 0, 1$ y usar la recurrencia $T_k = 2xT_{k-1} - T_{k-2}$.

Con $z = -\frac{\sqrt{c}-1}{\sqrt{c}+1}$ (notar $|z| < 1$, $|z^{-1}| > 1$):

$$T_k(x(0)) = (-1)^k \frac{1}{2}\left[\left(\frac{\sqrt{c}-1}{\sqrt{c}+1}\right)^k + \left(\frac{\sqrt{c}+1}{\sqrt{c}-1}\right)^k\right] \quad \Longrightarrow \quad |T_k(x(0))| \geq \frac{1}{2}\left(\frac{\sqrt{c}+1}{\sqrt{c}-1}\right)^k.$$

Y por lo tanto

$$\max_{\lambda \in \sigma(A)} |p_k(\lambda)| \leq \frac{1}{|T_k(x(0))|} \leq 2\left(\frac{\sqrt{c}-1}{\sqrt{c}+1}\right)^k.$$

El Corolario 5.14 concluye la demostración. ■

GC vs. SD: comparación de tasas

Factor de reducción del error en norma A (A sdp, $\kappa = \kappa_2(A)$)

Método	**Cota**	$\kappa = 100$
Richardson óptimo / SD	$\left(\frac{\kappa-1}{\kappa+1}\right)^k$	$(0.980)^k$
GC (Tchebychev)	$2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$	$2\,(0.818)^k$

GC vs. SD: comparación de tasas

Factor de reducción del error en norma A (A sdp, $\kappa = \kappa_2(A)$)

Método	**Cota**	$\kappa = 100$
Richardson óptimo / SD	$\left(\frac{\kappa-1}{\kappa+1}\right)^k$	$(0.980)^k$
GC (Tchebychev)	$2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k$	$2\,(0.818)^k$

- Reducir el error en 10^{-2}: SD necesita ~ 230 iteraciones; GC, ~ 30.
- κ vs. $\sqrt{\kappa}$: la diferencia crece al empeorar el condicionamiento.
- La constante 2 es asintóticamente irrelevante.
- Ojo: la del GC es solo una cota (usa un p particular). El GC suele andar mejor, sobre todo si el espectro está agrupado.

5.1.4 El GC como método directo

Termina en a lo sumo n pasos

Argumento

Si $r_n \neq 0$, entonces $\{r_0, r_1, \ldots, r_n\}$ sería un conjunto de $n+1$ vectores ortogonales y no nulos en $\mathbb{R}^n$: imposible. Luego $r_n = 0$, es decir, $x_n = x_*$.

Termina en a lo sumo n pasos

Argumento

Si $r_n \neq 0$, entonces $\{r_0, r_1, \ldots, r_n\}$ sería un conjunto de $n+1$ vectores ortogonales y no nulos en $\mathbb{R}^n$: imposible. Luego $r_n = 0$, es decir, $x_n = x_*$.

Teorema

Sea A sdp y $b \in \mathbb{R}^n$. Si A tiene k autovalores **distintos**, *el GC converge a x_* en a lo sumo k pasos, cualquiera sea x_0.*

Termina en a lo sumo n pasos

Argumento

Si $r_n \neq 0$, entonces $\{r_0, r_1, \ldots, r_n\}$ sería un conjunto de $n+1$ vectores ortogonales y no nulos en $\mathbb{R}^n$: imposible. Luego $r_n = 0$, es decir, $x_n = x_*$.

Teorema

Sea A sdp y $b \in \mathbb{R}^n$. Si A tiene k autovalores **distintos**, *el GC converge a x_* en a lo sumo k pasos, cualquiera sea x_0.*

Demostración. Sean $\lambda_1, \ldots, \lambda_k$ los autovalores distintos. Tomamos

$$p(z) := \frac{(\lambda_1 - z)(\lambda_2 - z)\cdots(\lambda_k - z)}{\lambda_1 \lambda_2 \cdots \lambda_k} \in \overline{\mathcal{P}}_k.$$

Entonces $\max_{\lambda \in \sigma(A)} |p(\lambda)| = 0$ y, por el Corolario 5.14, $\|x_k - x_*\|_A \leq 0$. ■

Un segundo resultado de terminación finita

Teorema

Sea A sdp y $b \in \mathbb{R}^n$. Si b es combinación lineal de k autovectores de A, entonces el GC aplicado a $Ax = b$ **partiendo de** $x_0 = 0$ *converge en a lo sumo k pasos.*

Un segundo resultado de terminación finita

Teorema

Sea A sdp y $b \in \mathbb{R}^n$. Si b es combinación lineal de k autovectores de A, entonces el GC aplicado a $Ax = b$ **partiendo de** $x_0 = 0$ *converge en a lo sumo k pasos.*

Demostración: *ejercicio.*

Sugerencia: usar el Teorema 5.13. Si $x_* = \sum_{j \in J} c_j v_j$ con $|J| = k$ y $Av_j = \lambda_j v_j$, y $x_0 = 0$, tomar el $p \in \overline{\mathcal{P}}_k$ que anula $\{\lambda_j\}_{j \in J}$ y calcular $p(A)(x_0 - x_*)$.

Un segundo resultado de terminación finita

Teorema

Sea A sdp y $b \in \mathbb{R}^n$. Si b es combinación lineal de k autovectores de A, entonces el GC aplicado a $Ax = b$ **partiendo de** $x_0 = 0$ *converge en a lo sumo k pasos.*

Demostración: *ejercicio.*

Sugerencia: usar el Teorema 5.13. Si $x_* = \sum_{j \in J} c_j v_j$ con $|J| = k$ y $Av_j = \lambda_j v_j$, y $x_0 = 0$, tomar el $p \in \overline{\mathcal{P}}_k$ que anula $\{\lambda_j\}_{j \in J}$ y calcular $p(A)(x_0 - x_*)$.

En la práctica

La terminación finita no se observa: los errores de redondeo destruyen la ortogonalidad de los residuos. Para n grande ($n = 10^5$, 10^6) tampoco se pretende hacer n iteraciones.

El GC se usa como método iterativo, con un criterio de parada asociado a una tolerancia. *(Lo vemos en la segunda parte de esta clase.)*

Hacia la implementación

Lo que sabemos del GC

$$x_{k+1} = \underset{x \in x_0 + \mathcal{K}_{k+1}}{\operatorname{argmin}} \phi(x), \qquad \mathcal{K}_{k+1} = \operatorname{span}\{r_0, \ldots, r_k\} = \operatorname{span}\{r_0, Ar_0, \ldots, A^k r_0\}.$$

Residuos ortogonales; termina en $\leq n$ pasos; cotas de error óptimas vía polinomios residuales.

Hacia la implementación

Lo que sabemos del GC

$$x_{k+1} = \underset{x \in x_0 + \mathcal{K}_{k+1}}{\operatorname{argmin}} \ \phi(x), \qquad \mathcal{K}_{k+1} = \operatorname{span}\{r_0, \ldots, r_k\} = \operatorname{span}\{r_0, Ar_0, \ldots, A^k r_0\}.$$

Residuos ortogonales; termina en $\leq n$ pasos; cotas de error óptimas vía polinomios residuales.

Lo que no sabemos

Cómo calcular ese argmin sin resolver un problema de $k+1$ incógnitas en cada iteración, y sin almacenar una base de $\mathcal{K}_{k+1}$.

Hacia la implementación

Lo que sabemos del GC

$$x_{k+1} = \underset{x \in x_0 + \mathcal{K}_{k+1}}{\operatorname{argmin}} \ \phi(x), \qquad \mathcal{K}_{k+1} = \operatorname{span}\{r_0, \ldots, r_k\} = \operatorname{span}\{r_0, Ar_0, \ldots, A^k r_0\}.$$

Residuos ortogonales; termina en $\leq n$ pasos; cotas de error óptimas vía polinomios residuales.

Lo que no sabemos

Cómo calcular ese argmin sin resolver un problema de $k+1$ incógnitas en cada iteración, y sin almacenar una base de $\mathcal{K}_{k+1}$.

Meta: llegar a un algoritmo con 1 producto mat-vec, 2 productos escalares, 3 axpy y 4 vectores en memoria por iteración.

5.1.5 Implementación del gradiente conjugado

El paso del GC es un paso en una sola dirección

Lema (5.19)

Para todo $k \in \mathbb{N}$,

$$x_{k+1} - x_k \in \mathcal{K}_{k+1} \qquad y \qquad (x_{k+1} - x_k)^T A \xi = 0, \quad \forall \xi \in \mathcal{K}_k.$$

El paso del GC es un paso en una sola dirección

Lema (5.19)

Para todo $k \in \mathbb{N}$,

$$x_{k+1} - x_k \in \mathcal{K}_{k+1} \qquad y \qquad (x_{k+1} - x_k)^T A\xi = 0, \quad \forall \xi \in \mathcal{K}_k.$$

Demostración. $x_k = x_0 + w_k$ con $w_k \in \mathcal{K}_k$, y $x_{k+1} = x_0 + w_{k+1}$ con $w_{k+1} \in \mathcal{K}_{k+1}$. Como $\mathcal{K}_k \subset \mathcal{K}_{k+1}$,

$$x_{k+1} - x_k = w_{k+1} - w_k \in \mathcal{K}_{k+1}.$$

El paso del GC es un paso en una sola dirección

Lema (5.19)

Para todo $k \in \mathbb{N}$,

$$x_{k+1} - x_k \in \mathcal{K}_{k+1} \qquad y \qquad (x_{k+1} - x_k)^T A\xi = 0, \quad \forall \xi \in \mathcal{K}_k.$$

Demostración. $x_k = x_0 + w_k$ con $w_k \in \mathcal{K}_k$, y $x_{k+1} = x_0 + w_{k+1}$ con $w_{k+1} \in \mathcal{K}_{k+1}$. Como $\mathcal{K}_k \subset \mathcal{K}_{k+1}$,

$$x_{k+1} - x_k = w_{k+1} - w_k \in \mathcal{K}_{k+1}.$$

Y si $\xi \in \mathcal{K}_k$,

$$(x_{k+1} - x_k)^T A\xi = \xi^T \big(\underbrace{Ax_{k+1} - b}_{=-r_{k+1}} + \underbrace{b - Ax_k}_{=r_k} \big) = \xi^T (r_k - r_{k+1}) = 0,$$

porque r_k y r_{k+1} son ambos $\perp \mathcal{K}_k = \operatorname{span}\{r_0, \ldots, r_{k-1}\}$. ■

La dirección d_{k+1}: existencia y unicidad

Argumento de dimensión

$\mathcal{K}_k \subset \mathcal{K}_{k+1}$, con $\dim \mathcal{K}_k = k$ y $\dim \mathcal{K}_{k+1} = k+1$: el complemento A-ortogonal de $\mathcal{K}_k$ *dentro de* $\mathcal{K}_{k+1}$ tiene dimensión 1, o sea, hay una única dirección (salvo múltiplos).

La dirección d_{k+1}: existencia y unicidad

Argumento de dimensión

$\mathcal{K}_k \subset \mathcal{K}_{k+1}$, con $\dim \mathcal{K}_k = k$ y $\dim \mathcal{K}_{k+1} = k+1$: el complemento A-ortogonal de $\mathcal{K}_k$ *dentro de* $\mathcal{K}_{k+1}$ tiene dimensión 1, o sea, hay una única dirección (salvo múltiplos).

Definición (Dirección de búsqueda)

$d_1 := r_0$ y, para $k \in \mathbb{N}$, $d_{k+1} := r_k + w_k$ donde $w_k \in \mathcal{K}_k$ es el **único** vector tal que $d_{k+1} \perp_A \mathcal{K}_k$.

La dirección d_{k+1}: existencia y unicidad

Argumento de dimensión

$\mathcal{K}_k \subset \mathcal{K}_{k+1}$, con $\dim \mathcal{K}_k = k$ y $\dim \mathcal{K}_{k+1} = k+1$: el complemento A-ortogonal de $\mathcal{K}_k$ *dentro de* $\mathcal{K}_{k+1}$ tiene dimensión 1, o sea, hay una única dirección (salvo múltiplos).

Definición (Dirección de búsqueda)

$d_1 := r_0$ y, para $k \in \mathbb{N}$, $d_{k+1} := r_k + w_k$ donde $w_k \in \mathcal{K}_k$ es el **único** vector tal que $d_{k+1} \perp_A \mathcal{K}_k$.

Corolario (5.20)

Si $k \in \mathbb{N}_0$ *y* $r_k \neq 0$, *entonces*

$$x_{k+1} = x_k + \alpha_{k+1} d_{k+1}, \qquad \alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}}.$$

La dirección d_{k+1}: existencia y unicidad

Argumento de dimensión

$\mathcal{K}_k \subset \mathcal{K}_{k+1}$, con $\dim \mathcal{K}_k = k$ y $\dim \mathcal{K}_{k+1} = k+1$: el complemento A-ortogonal de $\mathcal{K}_k$ *dentro de* $\mathcal{K}_{k+1}$ tiene dimensión 1, o sea, hay una única dirección (salvo múltiplos).

Definición (Dirección de búsqueda)

$d_1 := r_0$ y, para $k \in \mathbb{N}$, $d_{k+1} := r_k + w_k$ donde $w_k \in \mathcal{K}_k$ es el **único** vector tal que $d_{k+1} \perp_A \mathcal{K}_k$.

Corolario (5.20)

Si $k \in \mathbb{N}_0$ y $r_k \neq 0$, entonces

$$x_{k+1} = x_k + \alpha_{k+1} d_{k+1}, \qquad \alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}}.$$

Idea: por el Lema 5.19, $x_{k+1} - x_k$ está en $\mathcal{K}_{k+1}$ y es A-ortogonal a $\mathcal{K}_k$: luego es múltiplo de d_{k+1}. El valor de α_{k+1} sale de la Observación 5.4 (minimizar $\phi(x_k + \alpha d)$ da $\alpha = d^T r_k / d^T A d$).

Método del gradiente conjugado (Versión preliminar 2)

Sean A sdp, $b \in \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$. $\quad r_0 = b - Ax_0; \quad k = 0;$

mientras $r_k \neq 0$

calcular la dirección de búsqueda d_{k+1}; ← *¿cómo?*

$$\alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}}; \quad x_{k+1} = x_k + \alpha_{k+1} d_{k+1};$$

$$r_{k+1} = b - Ax_{k+1}; \quad k = k + 1;$$

fin

Método del gradiente conjugado (Versión preliminar 2)

Sean A sdp, $b \in \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$. $\quad r_0 = b - Ax_0; \quad k = 0;$

mientras $r_k \neq 0$

calcular la dirección de búsqueda d_{k+1}; ← *¿cómo?*

$$\alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}}; \quad x_{k+1} = x_k + \alpha_{k+1} d_{k+1};$$

$$r_{k+1} = b - Ax_{k+1}; \quad k = k + 1;$$

fin

Avance: ya no hay que resolver un problema de minimización en $k+1$ variables.

Falta: una fórmula barata para d_{k+1}. *A priori*, $d_{k+1} = r_k + \sum_{i=1}^{k} \gamma_i d_i$ costaría $O(k)$ productos escalares y guardar k vectores.

Las direcciones también generan el Krylov

Lema (5.21)

Sea $k \in \mathbb{N}$. *Si* $r_{k-1} \neq 0$, *entonces* $\{d_1, \ldots, d_k\}$ *es A-ortogonal y*

$$\mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}.$$

Las direcciones también generan el Krylov

Lema (5.21)

Sea $k \in \mathbb{N}$. *Si* $r_{k-1} \neq 0$, *entonces* $\{d_1, \ldots, d_k\}$ *es A-ortogonal y*

$$\mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}.$$

Demostración (inducción en k).

- $k = 1$: $d_1 = r_0$, luego $\mathcal{K}_1 = \text{span}\{d_1\}$.

Las direcciones también generan el Krylov

Lema (5.21)

Sea $k \in \mathbb{N}$. *Si* $r_{k-1} \neq 0$, *entonces* $\{d_1, \ldots, d_k\}$ *es A-ortogonal y*

$$\mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}.$$

Demostración (inducción en k).

- $k = 1$: $d_1 = r_0$, luego $\mathcal{K}_1 = \text{span}\{d_1\}$.
- Hip. ind.: $\mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}$, A-ortogonal. Por definición, $d_{k+1} \in \mathcal{K}_{k+1}$ y $d_{k+1} \perp_A \mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}$; luego $\{d_1, \ldots, d_{k+1}\}$ es A-ortogonal y está contenido en $\mathcal{K}_{k+1}$.

Las direcciones también generan el Krylov

Lema (5.21)

Sea $k \in \mathbb{N}$. Si $r_{k-1} \neq 0$, entonces $\{d_1, \ldots, d_k\}$ es A-ortogonal y

$$\mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}.$$

Demostración (inducción en k).

- $k = 1$: $d_1 = r_0$, luego $\mathcal{K}_1 = \text{span}\{d_1\}$.
- Hip. ind.: $\mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}$, A-ortogonal. Por definición, $d_{k+1} \in \mathcal{K}_{k+1}$ y $d_{k+1} \perp_A \mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}$; luego $\{d_1, \ldots, d_{k+1}\}$ es A-ortogonal y está contenido en $\mathcal{K}_{k+1}$.
- Si $r_k \neq 0$, los d_i son no nulos; un conjunto A-ortogonal de vectores no nulos es linealmente independiente. Son $k+1$ vectores dentro de $\mathcal{K}_{k+1}$, que tiene dimensión $k+1$: generan todo. ■

Las direcciones también generan el Krylov

Lema (5.21)

Sea $k \in \mathbb{N}$. Si $r_{k-1} \neq 0$, entonces $\{d_1, \ldots, d_k\}$ es A-ortogonal y

$$\mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}.$$

Demostración (inducción en k).

- $k = 1$: $d_1 = r_0$, luego $\mathcal{K}_1 = \text{span}\{d_1\}$.
- Hip. ind.: $\mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}$, A-ortogonal. Por definición, $d_{k+1} \in \mathcal{K}_{k+1}$ y $d_{k+1} \perp_A \mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}$; luego $\{d_1, \ldots, d_{k+1}\}$ es A-ortogonal y está contenido en $\mathcal{K}_{k+1}$.
- Si $r_k \neq 0$, los d_i son no nulos; un conjunto A-ortogonal de vectores no nulos es linealmente independiente. Son $k+1$ vectores dentro de $\mathcal{K}_{k+1}$, que tiene dimensión $k+1$: generan todo. ■

De aquí sale el nombre

Las direcciones de búsqueda son conjugadas ($=$ A-ortogonales).

Teorema 5.22: recurrencia de dos términos

Teorema

Sea $k \in \mathbb{N}$. *Si* $r_{k-1} \neq 0$, *entonces*

$$d_{k+1} = r_k + \beta_{k+1}\, d_k, \qquad \beta_{k+1} = -\frac{r_k^T A d_k}{d_k^T A d_k}.$$

Teorema 5.22: recurrencia de dos términos

Teorema

Sea $k \in \mathbb{N}$. *Si* $r_{k-1} \neq 0$, *entonces*

$$d_{k+1} = r_k + \beta_{k+1}\, d_k, \qquad \beta_{k+1} = -\frac{r_k^T A d_k}{d_k^T A d_k}.$$

Demostración. Por el Lema 5.21, $d_{k+1} = r_k + \sum_{i=1}^{k} \gamma_i d_i$. Imponiendo $d_{k+1}^T A d_j = 0$ y usando la A-ortogonalidad,

$$0 = r_k^T A d_j + \gamma_j\, d_j^T A d_j \qquad \Longrightarrow \qquad \gamma_j = -\frac{r_k^T A d_j}{d_j^T A d_j}, \quad j = 1, \ldots, k.$$

Teorema 5.22: recurrencia de dos términos

Teorema

Sea $k \in \mathbb{N}$. *Si* $r_{k-1} \neq 0$, *entonces*

$$d_{k+1} = r_k + \beta_{k+1}\, d_k, \qquad \beta_{k+1} = -\frac{r_k^T A d_k}{d_k^T A d_k}.$$

Demostración. Por el Lema 5.21, $d_{k+1} = r_k + \sum_{i=1}^{k} \gamma_i d_i$. Imponiendo $d_{k+1}^T A d_j = 0$ y usando la A-ortogonalidad,

$$0 = r_k^T A d_j + \gamma_j\, d_j^T A d_j \qquad \Longrightarrow \qquad \gamma_j = -\frac{r_k^T A d_j}{d_j^T A d_j}, \quad j = 1, \ldots, k.$$

El milagro: $\gamma_j = 0$ para $j < k$

Para $j \leq k-1$: $\quad A d_j \in \mathcal{K}_{j+1} \subset \mathcal{K}_k, \quad$ y $\quad r_k \perp \mathcal{K}_k. \quad$ Luego $r_k^T A d_j = 0$.

Teorema 5.22: recurrencia de dos términos

Teorema

Sea $k \in \mathbb{N}$. *Si* $r_{k-1} \neq 0$, *entonces*

$$d_{k+1} = r_k + \beta_{k+1}\, d_k, \qquad \beta_{k+1} = -\frac{r_k^T A d_k}{d_k^T A d_k}.$$

Demostración. Por el Lema 5.21, $d_{k+1} = r_k + \sum_{i=1}^{k} \gamma_i d_i$. Imponiendo $d_{k+1}^T A d_j = 0$ y usando la A-ortogonalidad,

$$0 = r_k^T A d_j + \gamma_j\, d_j^T A d_j \qquad \Longrightarrow \qquad \gamma_j = -\frac{r_k^T A d_j}{d_j^T A d_j}, \quad j = 1, \ldots, k.$$

El milagro: $\gamma_j = 0$ para $j < k$

Para $j \leq k-1$: $\quad A d_j \in \mathcal{K}_{j+1} \subset \mathcal{K}_k, \quad$ y $\quad r_k \perp \mathcal{K}_k. \quad$ Luego $r_k^T A d_j = 0$.

(Que $A d_j \in \mathcal{K}_{j+1}$ sale de $d_j \in \mathcal{K}_j = \text{span}\{r_0, \ldots, A^{j-1} r_0\}$.) ■

Método del gradiente conjugado (Versión preliminar 3)

Sean A sdp, $b \in \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$. $\quad r_0 = b - Ax_0; \quad k = 0;$

mientras $r_k \neq 0$

si $k = 0$: $\quad d_1 = r_0; \quad$ **si no**: $\quad \beta_{k+1} = -\dfrac{r_k^T A d_k}{d_k^T A d_k}, \quad d_{k+1} = r_k + \beta_{k+1} d_k;$

$$\alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}}; \quad x_{k+1} = x_k + \alpha_{k+1} d_{k+1};$$

$$r_{k+1} = b - Ax_{k+1}; \quad k = k + 1;$$

fin

Método del gradiente conjugado (Versión preliminar 3)

Sean A sdp, $b \in \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$. $\quad r_0 = b - Ax_0; \quad k = 0;$

mientras $r_k \neq 0$

si $k = 0$: $\quad d_1 = r_0; \quad$ **si no**: $\quad \beta_{k+1} = -\dfrac{r_k^T A d_k}{d_k^T A d_k}, \quad d_{k+1} = r_k + \beta_{k+1} d_k;$

$$\alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}}; \quad x_{k+1} = x_k + \alpha_{k+1} d_{k+1};$$

$$r_{k+1} = b - Ax_{k+1}; \quad k = k + 1;$$

fin

Muy importante: solo hace falta la dirección anterior d_k. No hay que almacenar una base del espacio de Krylov.

Método del gradiente conjugado (Versión preliminar 3)

Sean A sdp, $b \in \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$. $\quad r_0 = b - Ax_0; \quad k = 0;$

mientras $r_k \neq 0$

si $k = 0$: $\quad d_1 = r_0; \quad$ **si no**: $\quad \beta_{k+1} = -\dfrac{r_k^T A d_k}{d_k^T A d_k}, \quad d_{k+1} = r_k + \beta_{k+1} d_k;$

$$\alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}}; \quad x_{k+1} = x_k + \alpha_{k+1} d_{k+1};$$

$$r_{k+1} = b - Ax_{k+1}; \quad k = k + 1;$$

fin

Muy importante: solo hace falta la dirección anterior d_k. No hay que almacenar una base del espacio de Krylov.

Todavía se puede mejorar: contemos los productos mat-vec y escalares...

Lema 5.23: fórmulas económicas

Lema

Si $r_k \neq 0$, *entonces*

$$\alpha_{k+1} = \frac{\|r_k\|_2^2}{\|d_{k+1}\|_A^2} = \frac{r_k^T r_k}{d_{k+1}^T A d_{k+1}}, \qquad \beta_{k+1} = \frac{\|r_k\|_2^2}{\|r_{k-1}\|_2^2} = \frac{r_k^T r_k}{r_{k-1}^T r_{k-1}}.$$

Lema 5.23: fórmulas económicas

Lema

Si $r_k \neq 0$, *entonces*

$$\alpha_{k+1} = \frac{\|r_k\|_2^2}{\|d_{k+1}\|_A^2} = \frac{r_k^T r_k}{d_{k+1}^T A d_{k+1}}, \qquad \beta_{k+1} = \frac{\|r_k\|_2^2}{\|r_{k-1}\|_2^2} = \frac{r_k^T r_k}{r_{k-1}^T r_{k-1}}.$$

Para α_{k+1}**:** como $d_k \in \mathcal{K}_k$ y $r_k \perp \mathcal{K}_k$,

$$d_{k+1}^T r_k = (r_k + \beta_{k+1} d_k)^T r_k = r_k^T r_k + \beta_{k+1} \underbrace{d_k^T r_k}_{=0} = r_k^T r_k.$$

Lema 5.23: fórmulas económicas

Lema

Si $r_k \neq 0$, *entonces*

$$\alpha_{k+1} = \frac{\|r_k\|_2^2}{\|d_{k+1}\|_A^2} = \frac{r_k^T r_k}{d_{k+1}^T A d_{k+1}}, \qquad \beta_{k+1} = \frac{\|r_k\|_2^2}{\|r_{k-1}\|_2^2} = \frac{r_k^T r_k}{r_{k-1}^T r_{k-1}}.$$

Para α_{k+1}: como $d_k \in \mathcal{K}_k$ y $r_k \perp \mathcal{K}_k$,

$$d_{k+1}^T r_k = (r_k + \beta_{k+1} d_k)^T r_k = r_k^T r_k + \beta_{k+1} \underbrace{d_k^T r_k}_{=0} = r_k^T r_k.$$

Para β_{k+1}: de $r_k = r_{k-1} - \alpha_k A d_k$ sale $A d_k = \frac{1}{\alpha_k}(r_{k-1} - r_k)$; usando $\alpha_k = \frac{r_{k-1}^T r_{k-1}}{d_k^T A d_k}$ y $r_k \perp r_{k-1}$,

$$\beta_{k+1} = -\frac{r_k^T A d_k}{d_k^T A d_k} = -\frac{r_k^T (r_{k-1} - r_k)}{\alpha_k \, d_k^T A d_k} = \frac{r_k^T r_k}{r_{k-1}^T r_{k-1}}. \qquad \blacksquare$$

Lema 5.23: fórmulas económicas

Lema

Si $r_k \neq 0$, *entonces*

$$\alpha_{k+1} = \frac{\|r_k\|_2^2}{\|d_{k+1}\|_A^2} = \frac{r_k^T r_k}{d_{k+1}^T A d_{k+1}}, \qquad \beta_{k+1} = \frac{\|r_k\|_2^2}{\|r_{k-1}\|_2^2} = \frac{r_k^T r_k}{r_{k-1}^T r_{k-1}}.$$

Para α_{k+1}: como $d_k \in \mathcal{K}_k$ y $r_k \perp \mathcal{K}_k$,

$$d_{k+1}^T r_k = (r_k + \beta_{k+1} d_k)^T r_k = r_k^T r_k + \beta_{k+1} \underbrace{d_k^T r_k}_{=0} = r_k^T r_k.$$

Para β_{k+1}: de $r_k = r_{k-1} - \alpha_k A d_k$ sale $A d_k = \frac{1}{\alpha_k}(r_{k-1} - r_k)$; usando $\alpha_k = \frac{r_{k-1}^T r_{k-1}}{d_k^T A d_k}$ y $r_k \perp r_{k-1}$,

$$\beta_{k+1} = -\frac{r_k^T A d_k}{d_k^T A d_k} = -\frac{r_k^T (r_{k-1} - r_k)}{\alpha_k \, d_k^T A d_k} = \frac{r_k^T r_k}{r_{k-1}^T r_{k-1}}. \qquad \blacksquare$$

Ganancia

Un solo escalar nuevo por iteración: $\rho_k := \|r_k\|_2^2$ (que ya se calcula para el criterio de parada). β sale *gratis*.

Versión final (con subíndices)

Método del gradiente conjugado (versión final, con subíndices)

Sean A sdp, $b \in \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$. $\quad r_0 = b - Ax_0; \quad \rho_0 = \|r_0\|_2^2; \quad k = 0;$

mientras $\rho_k \neq 0$

si $k = 0$: $\quad d_1 = r_0; \quad$ **si no**: $\quad \beta_{k+1} = \dfrac{\rho_k}{\rho_{k-1}}, \quad d_{k+1} = r_k + \beta_{k+1} d_k;$

$w_{k+1} = Ad_{k+1}; \quad \alpha_{k+1} = \dfrac{\rho_k}{d_{k+1}^T w_{k+1}};$ % único mat-vec

$x_{k+1} = x_k + \alpha_{k+1} d_{k+1}; \quad r_{k+1} = r_k - \alpha_{k+1} w_{k+1};$ $\% = b - Ax_{k+1}$

$\rho_{k+1} = \|r_{k+1}\|_2^2; \quad k = k + 1;$

fin

Versión final (con subíndices)

Método del gradiente conjugado (versión final, con subíndices)

Sean A sdp, $b \in \mathbb{R}^n$, $x_0 \in \mathbb{R}^n$. $\quad r_0 = b - Ax_0; \quad \rho_0 = \|r_0\|_2^2; \quad k = 0;$

mientras $\rho_k \neq 0$

si $k = 0$: $\quad d_1 = r_0; \quad$ **si no**: $\quad \beta_{k+1} = \dfrac{\rho_k}{\rho_{k-1}}, \quad d_{k+1} = r_k + \beta_{k+1} d_k;$

$w_{k+1} = Ad_{k+1}; \quad \alpha_{k+1} = \dfrac{\rho_k}{d_{k+1}^T w_{k+1}};$ % único mat-vec

$x_{k+1} = x_k + \alpha_{k+1} d_{k+1}; \quad r_{k+1} = r_k - \alpha_{k+1} w_{k+1};$ $\% = b - Ax_{k+1}$

$\rho_{k+1} = \|r_{k+1}\|_2^2; \quad k = k + 1;$

fin

Aún no es implementable: todo tiene subíndices. Pero ningún vector viejo se usa más de un paso hacia atrás $\Rightarrow$ se pueden sobrescribir.

Criterio de parada

Sabemos que

$$\frac{\|x_k - x_*\|_2}{\|x_*\|_2} \leq \kappa_2(A) \frac{\|\overbrace{b - Ax_k}^{= r_k}\|_2}{\|b\|_2}.$$

Criterio de parada

Sabemos que

$$\frac{\|x_k - x_*\|_2}{\|x_*\|_2} \leq \kappa_2(A) \frac{\|\overbrace{b - Ax_k}^{= r_k}\|_2}{\|b\|_2}.$$

Criterio usual

Dada una tolerancia tol, se itera hasta que

$$\|r_k\|_2 < \mathrm{tol}\, \|b\|_2 \qquad \Longleftrightarrow \qquad \rho_k < \mathrm{tol}^2\, b^T b.$$

(Comparar cuadrados evita calcular raíces.)

Criterio de parada

Sabemos que

$$\frac{\|x_k - x_*\|_2}{\|x_*\|_2} \leq \kappa_2(A) \frac{\|\overbrace{b - Ax_k}^{= r_k}\|_2}{\|b\|_2}.$$

Criterio usual

Dada una tolerancia tol, se itera hasta que

$$\|r_k\|_2 < \mathrm{tol}\,\|b\|_2 \qquad \Longleftrightarrow \qquad \rho_k < \mathrm{tol}^2\, b^T b.$$

(Comparar cuadrados evita calcular raíces.)

A la salida, el error relativo satisface

$$\frac{\|x_k - x_*\|_2}{\|x_*\|_2} \leq \kappa_2(A)\,\mathrm{tol}.$$

Criterio de parada

Sabemos que

$$\frac{\|x_k - x_*\|_2}{\|x_*\|_2} \leq \kappa_2(A) \frac{\|\overbrace{b - Ax_k}^{= r_k}\|_2}{\|b\|_2}.$$

Criterio usual

Dada una tolerancia tol, se itera hasta que

$$\|r_k\|_2 < \mathrm{tol}\, \|b\|_2 \qquad \Longleftrightarrow \qquad \rho_k < \mathrm{tol}^2\, b^T b.$$

(Comparar cuadrados evita calcular raíces.)

A la salida, el error relativo satisface

$$\frac{\|x_k - x_*\|_2}{\|x_*\|_2} \leq \kappa_2(A)\, \mathrm{tol}.$$

Ojo: el factor $\kappa_2(A)$. Residuo chico *no* significa error chico si la matriz está mal condicionada.

Conviene además un tope `maxiter`.

El algoritmo del gradiente conjugado

Gradiente conjugado

Sean A sdp, $b \in \mathbb{R}^n$, y $x \in \mathbb{R}^n$ (iterando inicial), $\mathrm{tol} \in \mathbb{R}_+$, $\texttt{maxiter} \in \mathbb{N}$.

$r = b - Ax$; $\quad \rho = r^T r$; $\quad \mathrm{TOL} = \mathrm{tol}^2\, b^T b$; $\quad k = 0$; $\qquad$ % $\rho = \|r\|_2^2$, $\mathrm{TOL} = \mathrm{tol}^2 \|b\|_2^2$

mientras ($\rho > \mathrm{TOL}$ **y** $k <$ `maxiter`) $\qquad$ % $\|r\|_2 / \|b\|_2 > \mathrm{tol}$

  si $k = 0$: $\quad d = r$; $\quad$ **si no**: $\quad \beta = \rho / \rho_{old}$; $\quad d = r + \beta d$;

  $w = Ad$; $\qquad \alpha = \rho / (d^T w)$; $\qquad x = x + \alpha d$;

  $r = r - \alpha w$; $\qquad$ % $r_{k+1} = r_k - \alpha_{k+1} A d_{k+1}$

  $\rho_{old} = \rho$; $\quad \rho = r^T r$; $\quad k = k + 1$;

fin

El algoritmo del gradiente conjugado

Gradiente conjugado

Sean A sdp, $b \in \mathbb{R}^n$, y $x \in \mathbb{R}^n$ (iterando inicial), $\mathrm{tol} \in \mathbb{R}_+$, $\texttt{maxiter} \in \mathbb{N}$.

$r = b - Ax$; $\quad \rho = r^T r$; $\quad \mathrm{TOL} = \mathrm{tol}^2\, b^T b$; $\quad k = 0$; $\qquad$ % $\rho = \|r\|_2^2$, $\mathrm{TOL} = \mathrm{tol}^2 \|b\|_2^2$

mientras ($\rho > \mathrm{TOL}$ **y** $k <$ `maxiter`) $\qquad$ % $\|r\|_2 / \|b\|_2 > \mathrm{tol}$

  si $k = 0$: $\quad d = r$; $\quad$ **si no**: $\quad \beta = \rho / \rho_{old}$; $\quad d = r + \beta d$;

  $w = Ad$; $\qquad \alpha = \rho / (d^T w)$; $\qquad x = x + \alpha d$;

  $r = r - \alpha w$; $\qquad$ % $r_{k+1} = r_k - \alpha_{k+1} A d_{k+1}$

  $\rho_{old} = \rho$; $\quad \rho = r^T r$; $\quad k = k + 1$;

fin

Cuatro vectores en memoria: x, r, d, w. Todo lo demás son escalares.

Implementación en matlab/octave

```
function [x, k, resrel] = gc(A, b, x, tol, maxiter)
% Gradiente conjugado para A sdp.  A: matriz o function handle que calcula A*d.
  if isa(A,'function_handle'), Av = A; else, Av = @(v) A*v; end
  r = b - Av(x);  rho = r'*r;   TOL = tol^2*(b'*b);   k = 0;   d = 0*x;
  while rho > TOL && k < maxiter
    if k == 0,  d = r;
    else        d = r + (rho/rho_old)*d;        % beta = rho/rho_old
    end
    w     = Av(d);                              % unico producto matriz-vector
    alpha = rho/(d'*w);
    x = x + alpha*d;
    r = r - alpha*w;                            % = b - A*x
    rho_old = rho;   rho = r'*r;   k = k + 1;
  end
  resrel = sqrt(rho)/norm(b);
end
```

Por iteración: 1 mat-vec, 2 productos escalares, 3 *axpy*.

Observaciones finales

1. **No hace falta almacenar** A**.** Alcanza con una rutina que calcule $d \mapsto Ad$. (Igual que en Steepest descent.)

Observaciones finales

1. **No hace falta almacenar** A**.** Alcanza con una rutina que calcule $d \mapsto Ad$. (Igual que en Steepest descent.)
2. **Almacenamiento:** 4 vectores: x, r, d, w.

Observaciones finales

1. **No hace falta almacenar A.** Alcanza con una rutina que calcule $d \mapsto Ad$. (Igual que en Steepest descent.)
2. **Almacenamiento:** 4 vectores: x, r, d, w.
3. **Costo por iteración:**
   - 1 producto matriz–vector (Ad);
   - 2 productos escalares ($d^T w$ y $r^T r$);
   - 3 operaciones *axpy* ($d = r + \beta d$, $x = x + \alpha d$, $r = r - \alpha w$).

Observaciones finales

1. **No hace falta almacenar A.** Alcanza con una rutina que calcule $d \mapsto Ad$. (Igual que en Steepest descent.)
2. **Almacenamiento:** 4 vectores: x, r, d, w.
3. **Costo por iteración:**
   - 1 producto matriz–vector (Ad);
   - 2 productos escalares ($d^T w$ y $r^T r$);
   - 3 operaciones *axpy* ($d = r + \beta d$, $x = x + \alpha d$, $r = r - \alpha w$).
4. **No se guarda una base de $\mathcal{K}_k$.** Esta es una ventaja específica de que A sea sdp: la recurrencia es de dos términos.

   Para matrices no sdp existen métodos de Krylov (p. ej. GMRes), pero ahí *sí* hay que ir guardando todas las direcciones de búsqueda: el costo y la memoria crecen con k.

Para recordar

1. **Tchebychev:** $\|x_k - x_*\|_A \leq 2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k \|x_0 - x_*\|_A$; $\sqrt{\kappa}$ en lugar del κ de SD. Y si A tiene k autovalores distintos, el GC termina en $\leq k$ pasos.
2. El paso del GC es un paso en *una* dirección: $x_{k+1} = x_k + \alpha_{k+1} d_{k+1}$, con d_{k+1} la única dirección de $\mathcal{K}_{k+1}$ que es A-ortogonal a $\mathcal{K}_k$.
3. Las direcciones son conjugadas (A-ortogonales) y generan los espacios de Krylov: $\mathcal{K}_k = \text{span}\{d_1, \ldots, d_k\}$.
4. **Recurrencia de dos términos:** $d_{k+1} = r_k + \beta_{k+1} d_k$. Los demás coeficientes se anulan porque $r_k \perp \mathcal{K}_k$.
5. **Fórmulas finales:** $\beta_{k+1} = \dfrac{\rho_k}{\rho_{k-1}}, \quad \alpha_{k+1} = \dfrac{\rho_k}{d_{k+1}^T A d_{k+1}}, \quad$ con $\rho_k = \|r_k\|_2^2$.
6. $r = r - \alpha w$ evita el segundo mat-vec.
7. **Parada:** $\|r_k\|_2 < \text{tol}\|b\|_2$, que garantiza error relativo $\leq \kappa_2(A)\,\text{tol}$.
8. **Próxima:** el condicionamiento manda $\Rightarrow$ precondicionamiento (Sección 5.1.6).