Multigrid en 1D: un precondicionador basado en la estructura

Clase 12 · Capítulo 5 · Sección 5.1.7

Análisis Numérico (LMA) · Métodos Numéricos II (LCD)

25 de septiembre de 2026

Facultad de Ingeniería Química · UNL

Dónde quedamos

Gradiente conjugado precondicionado

Con M sdp tal que $c_1 \leq \frac{x^T M x}{x^T A^{-1} x} \leq c_2$,

$$\|x_k - x_*\|_A \leq 2 \left(\frac{\sqrt{\frac{c_2}{c_1}} - 1}{\sqrt{\frac{c_2}{c_1}} + 1} \right)^k \|x_0 - x_*\|_A.$$

Precondicionadores genéricos (Jacobi, Gauss–Seidel simétrico, Cholesky incompleta): se construyen mirando solo *las entradas* de A.

Mejoran la constante, rara vez el orden: si $\kappa_2(A) = O(h^{-2})$, queda $\frac{c_2}{c_1} = C\,h^{-2}$ con $C < 1$. El exponente sigue ahí.

Hoy

Un precondicionador que usa de dónde viene A, y consigue $\frac{c_2}{c_1} = O(1)$: acotado *independientemente de* h.

Plan de la clase

1. **El problema modelo:** de dónde sale la matriz $A_h = \frac{1}{h^2}\mathrm{tridiag}(-1, 2, -1)$, y por qué está mal condicionada.
2. **La propiedad de suavizado:** la relajación no resuelve, pero *suaviza* el error.
3. **Corrección en malla gruesa:** lo que es suave en una malla es oscilatorio en otra más gruesa.
4. **Transferencia entre mallas** y el **ciclo en V**.
5. **Multigrid como precondicionador** del gradiente conjugado.
6. **Resultados numéricos** y ejercicios.

Aviso: el problema modelo viene de una ecuación diferencial, pero *no hace falta saber nada de ecuaciones diferenciales*: solo la definición de derivada. A partir del punto 2, todo es álgebra lineal.

El problema modelo

De dónde sale la matriz

Buscamos $u : [0,1] \to \mathbb{R}$ de la que conocemos los valores en los extremos y su derivada segunda:

$$-u''(x) = f(x) \text{ en } (0,1), \qquad u(0) = u(1) = 0.$$

(Temperatura estacionaria de una barra; forma de una cuerda tensa con carga f. Se llama *problema de valores de borde*.)

Idea: reemplazar derivadas por cocientes incrementales. Malla $x_i = ih$, $h = \frac{1}{n+1}$, incógnitas $u_i \approx u(x_i)$, con $u_0 = u_{n+1} = 0$.

La derivada es la pendiente de un segmento:

$$\frac{u_{i+1} - u_i}{h} \approx u'\left(x_i + \tfrac{h}{2}\right), \qquad \frac{u_i - u_{i-1}}{h} \approx u'\left(x_i - \tfrac{h}{2}\right),$$

y u'' es la razón de cambio de esas pendientes:

$$\boxed{u''(x_i) \approx \frac{1}{h}\left(\frac{u_{i+1} - u_i}{h} - \frac{u_i - u_{i-1}}{h}\right) = \frac{u_{i-1} - 2u_i + u_{i+1}}{h^2}}$$

(Diferencia centrada; por Taylor, el error es $O(h^2)$.)

El sistema lineal

Imponiendo $-u''(x_i) = f(x_i)$ en cada nodo interior:

$$\frac{-u_{i-1} + 2u_i - u_{i+1}}{h^2} = f_i, \qquad i = 1, \ldots, n, \qquad u_0 = u_{n+1} = 0,$$

es decir

$$A_h u = f, \qquad A_h = \frac{1}{h^2} \begin{pmatrix} 2 & -1 & & \\ -1 & 2 & -1 & \\ & \ddots & \ddots & \ddots \\ & & -1 & 2 \end{pmatrix} \in \mathbb{R}^{n \times n}.$$

De acá en adelante

Olvidamos el problema continuo. El objetivo es resolver este sistema.

La misma matriz aparece en splines cúbicos (Cap. 3) y en incontables aplicaciones: es el ejemplo canónico de matriz rala, sdp y mal condicionada.

Autovalores y autovectores: los conocemos exactamente

Para $k = 1, \dots, n$, sea $\varphi^{(k)} \in \mathbb{R}^n$ el vector que se obtiene muestreando $\operatorname{sen}(k\pi x)$ en los nodos:

$$\varphi_i^{(k)} = \operatorname{sen}\left(\frac{ki\pi}{n+1}\right) = \operatorname{sen}(k\pi x_i), \qquad i = 1, \dots, n.$$

Usando $\operatorname{sen}(\theta - \psi) + \operatorname{sen}(\theta + \psi) = 2 \operatorname{sen}\theta \cos\psi$:

$$A_h \varphi^{(k)} = \lambda_k \varphi^{(k)}, \qquad \lambda_k = \frac{2}{h^2}\big(1 - \cos(k\pi h)\big) = \frac{4}{h^2} \operatorname{sen}^2\left(\frac{k\pi h}{2}\right).$$

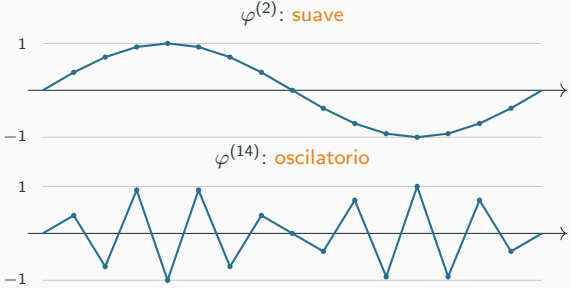
Dos consecuencias

- Todos los $\lambda_k > 0$: A_h es sdp.
- Los λ_k son distintos $\Rightarrow$ los $\varphi^{(k)}$ son ortogonales y forman una base de $\mathbb{R}^n$.

Esta base es la herramienta central de toda la clase. El índice k es la *frecuencia*: k chico = modo suave, k grande = modo oscilatorio. (Siempre *relativo a* n.)

Cómo se ven los modos

Un vector $v \in \mathbb{R}^n$ se dibuja como los puntos (x_i, v_i). Para $n = 15$:



El problema: el condicionamiento

De $\lambda_k = \frac{4}{h^2}\operatorname{sen}^2\left(\frac{k\pi h}{2}\right)$, para h chico:

$$\lambda_1 \approx \pi^2, \qquad \lambda_n \approx \frac{4}{h^2} \qquad \Longrightarrow \qquad \kappa_2(A_h) \approx \frac{4}{\pi^2 h^2} = O(h^{-2}) = O(n^2).$$

Consecuencia para el GC (Observación 5.20)

$$\#\text{iteraciones} = O\left(\sqrt{\kappa_2(A_h)}\right) = O(h^{-1}) = O(n), \qquad \text{costo/iteración} = O(n)$$

$$\Longrightarrow \qquad \text{costo total } = O(n^2).$$

La meta de hoy

Resolver este sistema con costo óptimo $O(n)$.

La propiedad de suavizado

Jacobi amortiguado

Con $D = \frac{2}{h^2} I$ la diagonal de A_h y $\omega \in (0, 1]$:

$$u_{m+1} = u_m + \omega D^{-1}\big(f - A_h u_m\big), \qquad e_m := u_m - u_*.$$

Restando $u_* = u_* + \omega D^{-1}(f - A_h u_*)$:

$$e_{m+1} = R_\omega \, e_m, \qquad R_\omega := I - \omega \tfrac{h^2}{2} A_h.$$

La clave: R_ω tiene los mismos autovectores que A_h

$$R_\omega \varphi^{(k)} = \mu_k \varphi^{(k)}, \qquad \mu_k = 1 - \omega \tfrac{h^2}{2} \lambda_k = 1 - 2\omega \, \operatorname{sen}^2\left(\frac{k\pi h}{2}\right).$$

Escribiendo el error en la base de modos, $e_0 = \sum_k c_k \varphi^{(k)}$:

$$e_m = \sum_{k=1}^{n} c_k \, \mu_k^m \, \varphi^{(k)}.$$

Cada modo se amortigua por su propio factor μ_k, independientemente de los demás.

El factor μ_k según la frecuencia

Modos suaves (k chico):

$$\mu_k \approx 1 - 2\omega\left(\frac{k\pi h}{2}\right)^2 \approx 1.$$

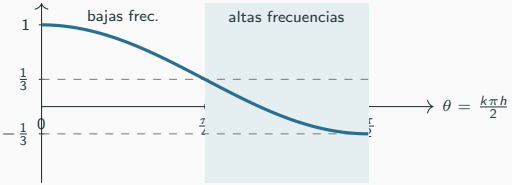
Casi no se reducen.

Modos oscilatorios ($\frac{n+1}{2} \leq k \leq n$):

$$\theta := \tfrac{k\pi h}{2} \in \left[\tfrac{\pi}{4}, \tfrac{\pi}{2}\right] \;\Rightarrow\; \operatorname{sen}^2\theta \in \left[\tfrac{1}{2}, 1\right].$$

Los μ_k quedan lejos de 1.

Esto explica por qué los métodos estacionarios del Cap. 4 son tan lentos acá: $\rho(R_\omega) = \max_k |\mu_k| \approx 1$, gobernado por los modos suaves.



μ_k para $\omega = \frac{2}{3}$.

La elección $\omega = \frac{2}{3}$

Definición (Factor de suavizado)

$$\mu_{\text{suav}}(\omega) := \max_{\frac{n+1}{2} \le k \le n} |\mu_k| = \max_{\frac{\pi}{4} \le \theta \le \frac{\pi}{2}} \left|1 - 2\omega \operatorname{sen}^2 \theta\right|.$$

Cuenta: con $s = \operatorname{sen}^2 \theta \in [\frac{1}{2}, 1]$, la función $1 - 2\omega s$ es lineal decreciente en s; su módulo se maximiza en un extremo:

$$\mu_{\text{suav}}(\omega) = \max\left\{|1 - \omega|,\ |1 - 2\omega|\right\}.$$

Para $\omega \in (0, 1]$ el primero crece y el segundo decrece: el mínimo está donde coinciden, $1 - \omega = 2\omega - 1$.

Resultado

$$\omega = \frac{2}{3}, \qquad \mu_{\text{suav}}\left(\tfrac{2}{3}\right) = \frac{1}{3}, \qquad \text{independientemente de } h.$$

Qué hace realmente la relajación

error inicial $e^{(0)}$



luego de 3 barridos



Lo esencial

El error no se hizo chico: cambió de forma. (Misma escala vertical.) La relajación no resuelve el sistema, pero suaviza el error.

Corrección en malla gruesa

La observación central

Un modo suave en la malla fina se ve oscilatorio en una malla más gruesa.

Sea n impar y tomemos la *malla gruesa*: los nodos de índice par x_{2j}, $j = 1, \dots, n_c$, con $n_c = \frac{n-1}{2}$ y paso $2h$. Muestreando $\varphi^{(k)}$ ahí:

$$\varphi^{(k)}_{2j} = \operatorname{sen}\left(\frac{k\,(2j)\,\pi}{n+1}\right) = \operatorname{sen}\left(\frac{k\,j\,\pi}{n_c+1}\right), \qquad \text{pues } n_c + 1 = \frac{n+1}{2}.$$

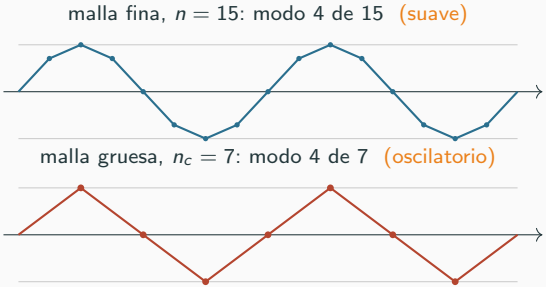
Lectura

Esa es *exactamente* la fórmula del modo número k de la malla gruesa.

El modo k de la malla fina $\longmapsto$ el modo k de la malla gruesa.

Pero la malla gruesa tiene la mitad de modos ($n_c \approx n/2$): la frecuencia *relativa* se duplicó.

El mismo modo, en dos mallas



Son *los mismos valores*. Lo que cambió es la malla desde la que se los mira: en la gruesa, el modo cambia de signo de un nodo al siguiente, y por lo tanto la relajación sí lo reduce.

La ecuación residual

Un problema: la incógnita es u, no el error. **Solución:** el error satisface un sistema con *la misma matriz*.

Ecuación residual

Si u es una aproximación cualquiera y $e = u_* - u$, entonces

$$A_h\, e = A_h u_* - A_h u = f - A_h u =: r.$$

El residuo r sí lo podemos calcular.

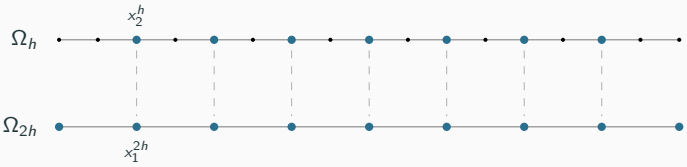
El esquema

1. Suavizar $\Rightarrow$ el error e queda suave.
2. Llevar r a la malla gruesa y resolver ahí $A_{2h} e_{2h} = r_{2h}$: problema de la misma forma, con la mitad de incógnitas, y donde e ya no es suave.
3. Interpolar la corrección a la malla fina: $u \leftarrow u + e$.

Transferencia entre mallas y ciclo en V

Las dos mallas

Suponemos $n+1 = 2^L$ (así n es impar y el proceso se puede repetir). El punto grueso j es el punto fino $2j$.



Prolongación $I_{2h}^h : \mathbb{R}^{n_c} \to \mathbb{R}^n$

$$\left(I_{2h}^h v\right)_{2j} = v_j, \quad \left(I_{2h}^h v\right)_{2j+1} = \tfrac{1}{2}(v_j + v_{j+1})$$

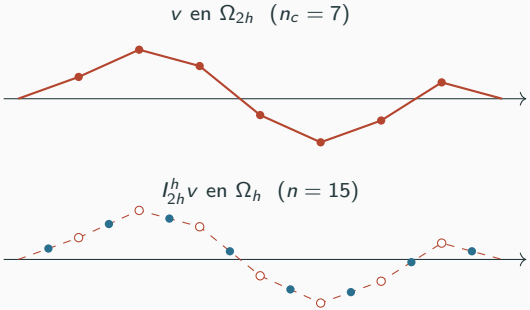
Interpolación lineal: copiar y promediar.

Restricción $I_h^{2h} : \mathbb{R}^n \to \mathbb{R}^{n_c}$

$$\left(I_h^{2h} w\right)_j = \tfrac{1}{4}\left(w_{2j-1} + 2w_{2j} + w_{2j+1}\right)$$

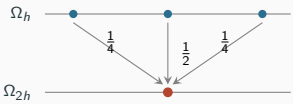
Ponderación completa (*full weighting*).

Prolongación: interpolar

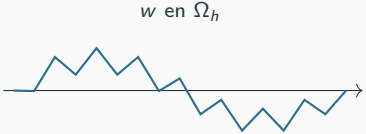


En los nodos comunes (círculos blancos) se *copia*; en los intermedios (puntos llenos) se promedia. Los valores nuevos caen exactamente sobre los segmentos que unen a los viejos: eso es interpolar linealmente.

Restricción: promediar, no copiar



El *estarcido* $\frac{1}{4}(1,2,1)$.



Acá w = parte suave + oscilación $(-1)^i$. El promedio pesado cancela exactamente la oscilación. Si en cambio se copiara w_{2j}, la oscilación aparecería en la malla gruesa disfrazada de componente suave.

Además: $I_h^{2h} = \frac{1}{2}\left(I_{2h}^h\right)^T$ (relación *variacional*: es la que hace simétrico al operador de dos mallas).

El esquema de dos mallas

Una iteración, partiendo de una aproximación u

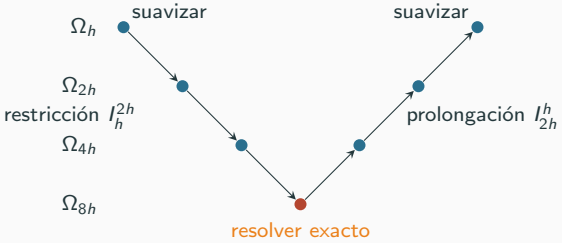
1. *Pre-suavizado:* ν_1 barridos de Jacobi amortiguado a $A_h u = f$.
2. *Residuo:* $r = f - A_h u$.
3. *Restricción:* $r_{2h} = I_h^{2h} r$.
4. *Corrección gruesa:* resolver $A_{2h} e_{2h} = r_{2h}$.
5. *Prolongación y corrección:* $u \leftarrow u + I_{2h}^{h} e_{2h}$.
6. *Post-suavizado:* ν_2 barridos de Jacobi amortiguado.

- (1) elimina los modos oscilatorios; (4) se ocupa de los suaves; (6) limpia lo oscilatorio que introduce la interpolación.
- Queda un punto: el paso (4) es un sistema *de la misma forma*, con la mitad de incógnitas...

$\Longrightarrow$ Recursión

En vez de resolverlo, le aplicamos el mismo esquema. Y así hasta una malla tan chica (un solo punto) que se resuelve de manera directa.

El ciclo en V



Costo

Cada nivel tiene la mitad de puntos:

$$c\,n\left(1+\tfrac{1}{2}+\tfrac{1}{4}+\cdots\right) \le 2cn = O(n).$$

Convergencia (Teorema 5.34)

El factor de reducción del error en norma A_h está acotado por $\rho < 1$ independiente de h y del número de niveles.

$\Longrightarrow$ cantidad de ciclos independiente de n, cada uno $O(n)$: costo total óptimo $O(n)$.

Implementación: el ciclo en V es recursivo

```
function u = vciclo(u,f,h,nu1,nu2)
% Un ciclo en V para el sistema A_h u = f.
n = length(u);
if n == 1
   u = f * h^2 / 2;                        % malla mas gruesa: A_h es el escalar 2/h^2
   return
end
u  = jacobiamortiguado(u,f,h,nu1);         % (1) pre-suavizado
Au = (2*u - [u(2:n);0] - [0;u(1:n-1)]) / h^2;
r  = f - Au;                               % (2) residuo
rc = restringir(r);                        % (3) restriccion
ec = zeros(length(rc),1);
ec = vciclo(ec,rc,2*h,nu1,nu2);            % (4) correccion gruesa (RECURSIVA)
u  = u + prolongar(ec);                    % (5) prolongacion y correccion
u  = jacobiamortiguado(u,f,h,nu2);         % (6) post-suavizado
```

Iterando `vciclo` hasta que el residuo sea chico se obtiene un método iterativo de costo óptimo.

(`jacobiamortiguado`, `restringir` y `prolongar`: ver el apunte.)

Multigrid como precondicionador

$M =$ "un ciclo en V con dato inicial nulo"

Definición

Dado ξ, aplicamos *un* ciclo en V a $A_h e = \xi$ partiendo de $e = 0$; el resultado es $M\xi$.

Las dos propiedades de un buen precondicionador

- **Acción barata:** $\xi \mapsto M\xi$ cuesta $O(n)$.
- $M \approx A_h^{-1}$**:** con $\frac{c_2}{c_1}$ acotado independientemente de h.

Para que M **sea sdp:** simetrizar el ciclo ($\nu_1 = \nu_2$, suavizador simétrico). El Jacobi amortiguado ya lo es, y la relación variacional $I_h^{2h} = \frac{1}{2}(I_{2h}^h)^T$ hace lo demás.

La cadena (Sección 5.1.7 del apunte)

1. El ciclo en V es *estacionario*: $u \mapsto u + M(f - A_h u)$, con matriz de iteración $E = I - MA_h$.
2. MA_h es autoadjunta en $\langle \cdot, \cdot \rangle_{A_h}$; con $\|E\|_{A_h} \leq \rho$ resulta $\sigma(MA_h) \subset [1 - \rho, 1 + \rho]$.
3. $c_1 = \lambda_{\text{mín}}(MA_h)$, $c_2 = \lambda_{\text{máx}}(MA_h)$, y $SA_hS \sim MA_h$.

El resultado

$$\kappa_2(SA_hS) = \frac{c_2}{c_1} \;\leq\; \frac{1+\rho}{1-\rho} \qquad \text{independiente de } h.$$

El espectro del sistema precondicionado está agrupado alrededor de 1: es exactamente la situación ideal que buscábamos.

En la práctica

Con un $\rho = 0.1$ típico: $\frac{c_2}{c_1} \leq 1.22$ y factor de reducción por iteración

$$\frac{\sqrt{\frac{c_2}{c_1}} - 1}{\sqrt{\frac{c_2}{c_1}} + 1} \;<\; 0.05.$$

Unas 5 iteraciones para ganar seis cifras, cualquiera sea n.

Comparar: el GC sin precondicionar necesita $O(n)$ iteraciones para esta matriz.

Los números

Iteraciones para $\|r\|/\|b\| < 10^{-10}$

n	GC	GCP-Jacobi	Multigrid solo	GCP-MG (ν=1)	GCP-MG (ν=2)
31	16	16	15	8	6
127	64	64	15	8	6
511	256	256	16	8	6
2047	1024	1024	16	8	6
4095	2049	2049	17	8	5

- GC: al duplicar n se duplican las iteraciones: $O(n)$, como predice la teoría.
- GCP-Jacobi = GC, exactamente. ¿Por qué? Porque $D = \frac{2}{h^2} I$ es múltiplo de la identidad: acá el precondicionador diagonal no hace nada.
- Multigrid y GCP-MG: constante en n. Y GCP-MG usa la mitad de ciclos que multigrid solo: el GC actúa como *acelerador* de multigrid.
- Verificación del Paso 2: para $n = 31$, $\nu = 1$ se mide $\rho = 0.190$ y $\sigma(MA_h) \subset [0.810,\ 1.000] \subset [1 - \rho, 1 + \rho]$. Ajustado.

Para hacer: Problemas 5.18–5.20

5.18 Multigrid como método iterativo

Implementar `jacobiamortiguado`, `restringir`, `prolongar`, `vciclo`.
Tests primero: (i) si se parte de u_*, el ciclo devuelve u_*; (ii) verificar $I_h^{2h} = \frac{1}{2}(I_{2h}^h)^T$ numéricamente.
Después: ciclos vs. n, medir ρ para $\nu = 1, 2, 3$, y comparar con el suavizador solo.

5.19 Multigrid como precondicionador

Verificar que M es simétrica si $\nu_1 = \nu_2$ y que deja de serlo si no. Calcular $\sigma(MA_h)$ y comparar $\frac{c_2}{c_1}$ con $\frac{1+\rho}{1-\rho}$.

5.20 Comparación

Reproducir la tabla de la slide anterior; graficar en escala log-log e identificar pendiente 1 vs. horizontal. Explicar lo del precondicionamiento diagonal.

Tomar $f = A_h u_*$ con u_* elegido: así se conoce la solución *exacta* del sistema discreto y se puede medir el error verdadero, no solo el residuo.

Para recordar

1. **El problema modelo:** $A_h = \frac{1}{h^2}\mathrm{tridiag}(-1, 2, -1)$, con autovectores $\varphi_i^{(k)} = \mathrm{sen}(k\pi x_i)$ y $\lambda_k = \frac{4}{h^2}\,\mathrm{sen}^2\,\frac{k\pi h}{2}$. $\kappa_2(A_h) = O(h^{-2})$.
2. **Suavizado:** el Jacobi amortiguado con $\omega = \frac{2}{3}$ reduce los modos oscilatorios en un factor $\frac{1}{3}$ *independiente de h*, y deja intactos los suaves. No resuelve: suaviza.
3. **Corrección gruesa:** lo que es suave en Ω_h es oscilatorio en Ω_{2h}. El error se ataca vía la ecuación residual $A_h e = r$.
4. **Recursión:** el problema grueso es de la misma forma $\Rightarrow$ ciclo en V, de costo $O(n)$ y factor de reducción $\rho < 1$ independiente de h.
5. **Precondicionador:** $M =$ un ciclo en V con dato inicial nulo cumple $\sigma(MA_h) \subset [1-\rho, 1+\rho]$ y por lo tanto $\frac{c_2}{c_1} \leq \dfrac{1+\rho}{1-\rho}$, acotado independientemente de h.
6. **Resultado:** GCP con multigrid converge en un número de iteraciones que no crece al refinar la malla. Y se logró por haber usado de dónde viene A_h.
7. **Lo que queda:** las mismas ideas valen en 2D y 3D y para problemas más generales; es ahí donde multigrid muestra toda su potencia.