GMRes: minimización del residuo, convergencia y precondicionamiento

Clase 13 · Capítulo 5 · Secciones 5.8 y 5.9.1–5.9.3

Análisis Numérico (LMA) · Métodos Numéricos II (LCD)

29 de septiembre de 2026

Facultad de Ingeniería Química · UNL

Dónde quedamos

Todo lo hecho hasta ahora supone A sdp

- $Ax = b \iff$ minimizar $\phi(x) = \frac{1}{2} x^T A x - x^T b$ (necesita simetría y positividad).
- GC: $x_k = \operatorname{argmin}_{x \in x_0 + \mathcal{K}_k} \|x - x_*\|_A$, recurrencia de dos términos.
- Cotas: $\|x_k - x_*\|_A \leq \max_{\lambda \in \sigma(A)} |p(\lambda)| \, \|x_0 - x_*\|_A$ para todo $p \in \overline{\mathcal{P}}_k$, usando $A = V \Lambda V^T$ con V ortogonal.

Pero muchos sistemas no son simétricos. Ejemplo (Problema 5.18): agregar un término de convección al problema modelo,

$$-u'' + c\,u' = f \qquad \rightsquigarrow \qquad A = A_h + c\,C, \qquad C = \tfrac{1}{2h} \operatorname{tridiag}(-1, 0, 1) \ \text{(antisimétrica)}.$$

Hoy

¿Qué se conserva de la maquinaria de Krylov cuando A no es sdp? Respuesta: casi todo, cambiando qué se minimiza.

Plan de la clase

1. **5.8 Un puente:** GC sobre las ecuaciones normales (CGNR y CGNE), y su problema.
2. **5.9.1 GMRes y su propiedad de minimización:** residuos y polinomios residuales, terminación finita, cotas para matrices diagonalizables, criterio de parada.
3. **5.9.2 Un resultado de convergencia:** si $\|I - A\|_2 \leq \rho < 1$, el residuo decrece como ρ^k.
4. **5.9.3 Precondicionamiento para GMRes:** a izquierda y a derecha.
5. **Un ejemplo:** el problema con convección, con y sin precondicionar.

La *implementación* de GMRes (Arnoldi, rotaciones de Givens) queda para la próxima clase: hoy definimos el método y estudiamos qué garantiza.

5.8 Un puente: las ecuaciones normales

CGNR y CGNE

Sea A invertible, *no necesariamente simétrica*. Dos maneras de fabricar un sistema sdp:

CGNR

$$Ax = b \iff A^TAx = A^Tb, \qquad A^TA \text{ sdp.}$$

GC minimiza $\|x - x_*\|_{A^TA}$, y

$$\|x - x_*\|^2_{A^TA} = \|A(x - x_*)\|_2^2 = \|b - Ax\|_2^2.$$

Normal equations, minimize the Residual.

CGNE

$$AA^Ty = b, \quad x = A^Ty, \qquad AA^T \text{ sdp.}$$

GC minimiza $\|y - y_*\|_{AA^T}$, y

$$\|y - y_*\|^2_{AA^T} = \|A^T(y - y_*)\|_2^2 = \|x - x_*\|_2^2.$$

Normal equations, minimize the Error.

No hace falta formar A^TA: alcanza con la rutina $\xi \mapsto A^T(A\xi)$.

El problema

$$\kappa_2(A^TA) = \kappa_2(A)^2.$$

Por la Observación 5.20, GC necesita $O(\sqrt{\kappa_2(A^TA)}) = O(\kappa_2(A))$ iteraciones: perdimos la raíz cuadrada. Y además hace falta la acción de A^T.

5.9.1 GMRes y la propiedad de minimización

La definición

Definición (GMRes: Generalized Minimum Residual)

La k-ésima iteración de GMRes es

$$x_k = \underset{x \in x_0 + \mathcal{K}_k}{\operatorname{argmin}} \|b - Ax\|_2, \qquad \mathcal{K}_k = \operatorname{span}\{r_0, Ar_0, \ldots, A^{k-1} r_0\}.$$

- El mismo espacio de búsqueda que GC; otro funcional: el residuo en norma 2, que tiene sentido para cualquier A invertible.
- A diferencia de CGNR/CGNE: no usa A^T, ni eleva al cuadrado el condicionamiento.
- El precio: no hay recurrencia corta. Hay que guardar una base de $\mathcal{K}_k$, así que memoria y costo por iteración crecen con k.

Hoy dejamos de lado *cómo* se calcula ese argmin (próxima clase), y estudiamos las consecuencias de la definición.

Residuos y polinomios residuales

El mismo argumento que para GC:

$$x \in x_0 + \mathcal{K}_k \iff x = x_0 + \sum_{j=0}^{k-1} \gamma_j A^j r_0 \iff b - Ax = r_0 - \sum_{j=1}^{k} \gamma_{j-1} A^j r_0 = p(A) r_0,$$

con $p \in \overline{\mathcal{P}}_k = \{p \in \mathcal{P}_k : \ p(0) = 1\}$, un polinomio residual.

Teorema (5.36)

Si A es no singular y x_k es la k-ésima iteración de GMRes,

$$\|r_k\|_2 = \min_{p \in \overline{\mathcal{P}}_k} \|p(A) r_0\|_2, \qquad \textit{luego} \qquad \|r_k\|_2 \leq \|p(A) r_0\|_2 \leq \|p(A)\|_2 \|r_0\|_2 \quad \forall p \in \overline{\mathcal{P}}_k.$$

Corolario (5.37)

$$\frac{\|r_k\|_2}{\|r_0\|_2} \leq \|p(A)\|_2 \qquad \textit{para todo } p \in \overline{\mathcal{P}}_k.$$

Misma estrategia que con GC: para acotar, alcanza con exhibir un p conveniente.

Terminación finita

Teorema (5.38)

Si $A \in \mathbb{R}^{n\times n}$ es no singular, GMRes encuentra la solución en a lo sumo n pasos.

Demostración. Sea $p(z) = \det(A - zI)$ el polinomio característico, de grado n. Como A es no singular, $p(0) = \det A \neq 0$, y

$$\bar{p}(z) := \frac{p(z)}{p(0)} \in \overline{\mathcal{P}}_n.$$

Por el Teorema de Cayley–Hamilton, $p(A) = 0$, luego $\bar{p}(A) = 0$, y por el Teorema 5.36,

$$\|r_n\|_2 \leq \|\bar{p}(A)r_0\|_2 = 0. \qquad \blacksquare$$

Igual que con GC

Es un resultado teórico: con n grande no se pretende hacer n iteraciones, y el redondeo lo arruina. GMRes se usa como método iterativo.

GC y GMRes, lado a lado

	GC	**GMRes**
Hipótesis	A sdp	A no singular
Espacio	$x_0 + \mathcal{K}_k$	$x_0 + \mathcal{K}_k$
Minimiza	$\|x - x_*\|_A$ (error en norma A)	$\|b - Ax\|_2$ (residuo en norma 2)
Polinomios	$\|x_k - x_*\|_A = \min_p \|p(A)(x_0 - x_*)\|_A$	$\|r_k\|_2 = \min_p \|p(A)r_0\|_2$
Terminación	$\leq n$ pasos	$\leq n$ pasos
Recurrencia	dos términos	no: guarda toda la base
Memoria / iter.	$O(n)$, fija	$O(nk)$, crece con k

Lo que se pierde sin simetría: para A sdp, $A = V\Lambda V^T$ con V ortogonal, y eso daba $\|p(A)\| = \max_{\lambda \in \sigma(A)} |p(\lambda)|$. Sin simetría, esa igualdad ya no vale.

Matrices diagonalizables

Supongamos A diagonalizable: $A = V\Lambda V^{-1}$, con Λ diagonal y V invertible, ambas *posiblemente complejas*. Entonces $p(A) = V\,p(\Lambda)\,V^{-1}$.

Teorema (5.39)

Si $A = V\Lambda V^{-1}$ es no singular y diagonalizable, para todo $p \in \overline{\mathcal{P}}_k$,

$$\frac{\|r_k\|_2}{\|r_0\|_2} \;\leq\; \kappa_2(V) \max_{z\in\sigma(A)} |p(z)|.$$

Demostración. $\|p(A)\|_2 \leq \|V\|_2\,\|p(\Lambda)\|_2\,\|V^{-1}\|_2 = \kappa_2(V)\,\max_{z\in\sigma(A)}|p(z)|$, y se aplica el Corolario 5.37. ■

El precio de la no simetría: el factor $\kappa_2(V)$

- Si A es normal ($AA^T = A^TA$), V es unitaria y $\kappa_2(V) = 1$: todo como en el caso simétrico, salvo que los autovalores pueden ser complejos.
- En general $\kappa_2(V)$ es difícil de calcular, y es grande si A está cerca de no ser diagonalizable.
- Los autovalores viven en $\mathbb{C}$: ahora hay que hacer p chico sobre un conjunto del plano complejo, con $p(0) = 1$.

Dos consecuencias

Corolario (5.40)

Si A es no singular, diagonalizable y tiene solo k autovalores distintos, GMRes termina en a lo sumo k iteraciones.

Corolario (5.41)

Si b es combinación lineal de k autovectores de A, GMRes partiendo de $x_0 = 0$ termina en a lo sumo k iteraciones.

Ejercicio (Problemas 5.19 y 5.20)

Demostrar ambos corolarios. Sugerencia: son los análogos de los Teoremas 5.21 y 5.22 para GC; imitar esas demostraciones usando el Teorema 5.39.

Criterio de parada

Como con GC, se itera hasta que

$$\|r_k\|_2 \leq \mathrm{tol}\,\|b\|_2.$$

Por el Lema 4.10 (error vs. residuo),

$$\frac{\|e_k\|_2}{\|x_*\|_2} \leq \kappa_2(A)\frac{\|r_k\|_2}{\|b\|_2} \qquad \Longrightarrow \qquad \frac{\|e_k\|_2}{\|x_*\|_2} \leq \kappa_2(A)\,\mathrm{tol}.$$

Lo mismo de siempre

Residuo chico no garantiza error chico si A está mal condicionada.

Con GMRes esto es todavía más visible: el método *minimiza el residuo*, así que es justamente el residuo lo que controla, no el error.

(Las matrices no diagonalizables tienen medida cero en $\mathbb{C}^{n\times n}$; hay cotas para ellas, pero no las veremos.)

5.9.2 Un resultado de convergencia

Si A está cerca de la identidad

Teorema (5.42)

Si $\|I - A\|_2 \leq \rho < 1$, *entonces*

$$\|r_k\|_2 \leq \rho^k \|r_0\|_2, \qquad k = 1, 2, \ldots$$

Demostración. Tomamos $p_k(z) = (1-z)^k \in \overline{\mathcal{P}}_k$. Entonces $p_k(A) = (I-A)^k$ y por el Corolario 5.37,

$$\|r_k\|_2 \leq \|(I-A)^k\|_2 \|r_0\|_2 \leq \|I - A\|_2^k \|r_0\|_2 \leq \rho^k \|r_0\|_2. \qquad \blacksquare$$

Observaciones

- No pide simetría, ni diagonalizabilidad, ni saber nada de $\sigma(A)$.
- Es el mismo polinomio que usamos para GC con espectro en $[1-\varepsilon, 1+\varepsilon]$.
- Casi nunca $\|I - A\|_2 < 1$ para la A original... pero sí para una A precondicionada. De ahí la próxima sección.

Del residuo al error

Para $S \in \mathbb{R}^{n\times n}$ invertible, de $\|y\| \le \|S^{-1}\|\,\|Sy\|$ y $\|Sy\| \le \|S\|\,\|y\|$ sale

$$\frac{1}{\kappa(S)}\,\frac{\|Sy\|}{\|S\tilde{y}\|} \;\le\; \frac{\|y\|}{\|\tilde{y}\|} \;\le\; \kappa(S)\,\frac{\|Sy\|}{\|S\tilde{y}\|}, \qquad \forall\, y, \tilde{y} \neq 0.$$

(Es la generalización del Lema 4.10.)

Con $S = A$, $y = e_k := x_* - x_k$ y $\tilde{y} = e_0$, usando $Ae_k = r_k$:

$$\frac{\|e_k\|_2}{\|e_0\|_2} \;\le\; \kappa_2(A)\,\frac{\|r_k\|_2}{\|r_0\|_2} \;\le\; \kappa_2(A)\,\rho^k.$$

En síntesis

Si $\|I - A\|_2 = \rho < 1$:

$$\|e_k\|_2 \le \kappa_2(A)\,\rho^k\,\|e_0\|_2.$$

El *residuo* decrece como ρ^k; el *error*, también, pero con la constante $\kappa_2(A)$ adelante.

Notar que si $\|I - A\|_2 \le \rho < 1$, entonces $\kappa_2(A) \le \frac{1+\rho}{1-\rho}$: en este régimen la constante está controlada.

5.9.3 Precondicionamiento para GMRes

La idea

Para GC necesitábamos que el sistema precondicionado fuera sdp, y eso obligó al truco $S = M^{1/2}$.

Para GMRes no hay ninguna restricción. Solo buscamos $M \approx A^{-1}$ tal que

$$\|I - MA\|_2 =: \rho_I < 1 \qquad \text{o} \qquad \|I - AM\|_2 =: \rho_D < 1,$$

y aplicamos el Teorema 5.42 al sistema precondicionado.

Dos maneras de ubicar M

- **A izquierda:** $MAx = Mb$.
- **A derecha:** $AMy = b$, $x = My$.

Las mismas dos condiciones de siempre: la acción $\xi \mapsto M\xi$ tiene que ser barata, y M tiene que parecerse a A^{-1}.

Precondicionador a izquierda

Si $\|I - MA\|_2 = \rho_I < 1$, aplicamos GMRes a

$$MAx = Mb.$$

El residuo que ve GMRes es el residuo precondicionado $r_k = Mb - MAx_k = M(b - Ax_k)$, y por el Teorema 5.42 y la desigualdad con $S = MA$,

$$\frac{\|e_k\|_2}{\|e_0\|_2} \;\leq\; \kappa_2(MA)\,\frac{\|r_k\|_2}{\|r_0\|_2} \;\leq\; \kappa_2(MA)\,\rho_I^k.$$

La ventaja

Si además $\kappa_2(MA) \ll \kappa_2(A)$, el residuo (precondicionado) relativo se parece mucho más al error relativo: el criterio de parada es más confiable.

Ojo: GMRes minimiza $\|M(b - Ax)\|_2$, no $\|b - Ax\|_2$. Si se quiere controlar el residuo verdadero, hay que calcularlo aparte.

Precondicionador a derecha

Si $\|I - AM\|_2 = \rho_D < 1$, resolvemos

$$(AM)\, y = b \quad \text{con GMRes,} \qquad \text{y luego} \qquad x = My.$$

Ahora el residuo que ve GMRes es

$$r_k = b - AMy_k = b - Ax_k,$$

el residuo verdadero. Por el Teorema 5.42,

$$\frac{\|r_k\|_2}{\|r_0\|_2} \le \rho_D^k, \qquad \frac{\|e_k\|_2}{\|e_0\|_2} \le \kappa_2(A)\, \frac{\|r_k\|_2}{\|r_0\|_2} \le \kappa_2(A)\, \rho_D^k.$$

El balance

Se gana en velocidad de convergencia, pero no necesariamente en la relación residuo–error: la constante sigue siendo $\kappa_2(A)$.

Izquierda vs. derecha

	A izquierda: $MAx = Mb$	**A derecha:** $AMy = b$, $x = My$
Condición	$\|I - MA\|_2 = \rho_I < 1$	$\|I - AM\|_2 = \rho_D < 1$
Qué se minimiza	$\|M(b - Ax)\|_2$ (precondicionado)	$\|b - Ax\|_2$ (verdadero)
Residuo	$\leq \rho_I^k$	$\leq \rho_D^k$
Error relativo	$\leq \kappa_2(MA)\, \rho_I^k$	$\leq \kappa_2(A)\, \rho_D^k$
Paso final	ninguno	$x = My$

Un aspecto práctico importante

No hace falta modificar el algoritmo. GMRes solo usa la matriz a través de productos matriz–vector: basta con darle la rutina $\xi \mapsto M(A\xi)$ o $\xi \mapsto A(M\xi)$.

(Contraste con el GCP, donde hubo que reescribir el algoritmo para que S desapareciera.)

Un ejemplo

El problema con convección

Del Problema 5.18 (con un parámetro c para la intensidad de la convección):

$$A = A_h + c\,C, \qquad A_h = \tfrac{1}{h^2}\mathrm{tridiag}(-1, 2, -1) \text{ (sdp)}, \qquad C = \tfrac{1}{2h}\mathrm{tridiag}(-1, 0, 1) \text{ (antisimétrica)}.$$

A no es simétrica, y $\kappa_2(A) = O(h^{-2})$.

Un precondicionador basado en la estructura

$$M = A_h^{-1} \qquad (\text{“resolver el problema sin convección”}).$$

- **Barato:** aplicar M es resolver un sistema tridiagonal: $O(n)$ (o, más en general, un ciclo en V de la clase pasada).
- **Parecido a A^{-1}:** $MA = I + c\,A_h^{-1}C$. Si la convección es moderada, MA está cerca de I.

Tomamos $b = (1, \ldots, 1)^T$, $x_0 = 0$, tolerancia 10^{-10} en el residuo relativo que ve cada versión.

Los números

$c = 1$

n	sin	izq	der	$\kappa_2(A)$	$\kappa_2(MA)$
31	31	8	9	408	1.31
127	127	8	9	6539	1.33
511	511	8	9	104633	1.33

$c = 10$

n	sin	izq	der	$\kappa_2(A)$	$\kappa_2(MA)$
31	31	16	18	207	6.9
127	127	16	19	3301	7.8
511	511	16	19	52816	8.0

- **Sin precondicionar:** exactamente n iteraciones. GMRes no converge antes de la terminación finita: a mitad de camino el residuo relativo todavía es ≈ 0.2 ($c = 1$) y ≈ 0.6 ($c = 10$).
- **Precondicionado:** un número de iteraciones independiente de n, a izquierda y a derecha.
- $\kappa_2(A)$ crece como h^{-2}, pero $\kappa_2(MA)$ queda acotado: a izquierda, el criterio de parada es confiable.

$c = 1$: el Teorema 5.42 en acción

Para $c = 1$ se mide $\rho_I = \|I - MA\|_2 \approx 0.31 < 1$, casi independiente de n. El teorema garantiza $\|r_k\|_2 / \|r_0\|_2 \leq \rho_I^k$. Para $n = 63$:

k	1	2	3	4	5
cota ρ_I^k	0.31	0.098	0.031	$9.6 \cdot 10^{-3}$	$3.0 \cdot 10^{-3}$
observado	0.063	$3.4 \cdot 10^{-3}$	$1.5 \cdot 10^{-4}$	$6.1 \cdot 10^{-6}$	$2.1 \cdot 10^{-7}$

Lectura

La cota se cumple, y es bastante pesimista: el factor observado por iteración está entre 0.03 y 0.06, no 0.31.

Una razón: $\rho(I - MA) \approx 0.16$, la mitad de $\|I - MA\|_2$. El teorema usa la *norma*, que para matrices no normales puede ser bastante mayor que el radio espectral.

$c = 10$: el teorema se calla, pero GMRes converge

Ahora $\|I - MA\|_2 \approx 3.1 > 1$: el Teorema 5.42 no dice nada. Y sin embargo, 16 iteraciones, independientemente de n. ¿Por qué?

El espectro de MA. Como $MA = I + c\,A_h^{-1}C$ y

$$A_h^{-1}C \;\sim\; A_h^{-1/2}\,C\,A_h^{-1/2} \quad \text{(antisimétrica)},$$

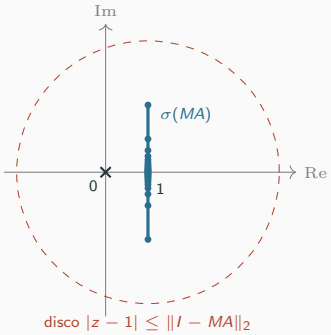
los autovalores de $A_h^{-1}C$ son imaginarios puros, y

$$\sigma(MA) \subset \{1 + it : \; t \in \mathbb{R}\}.$$

Medido: $|t| \leq 1.59$ para todo n.

Moraleja

El teorema es una condición suficiente, no necesaria. El disco $|z-1| \leq \|I - MA\|_2$ contiene al 0, pero el espectro no: queda sobre un segmento acotado, lejos del origen.



$c = 10,\ n = 31.$

Para recordar

1. **CGNR/CGNE** aplican GC a A^TA o AA^T: funcionan, pero $\kappa_2(A^TA) = \kappa_2(A)^2$ y hace falta A^T.
2. **GMRes:** $x_k = \text{argmin}_{x \in x_0 + \mathcal{K}_k} \|b - Ax\|_2$. Mismo espacio que GC, otro funcional. No usa A^T; el precio es guardar toda la base de $\mathcal{K}_k$.
3. $\|r_k\|_2 = \text{mín}_{p \in \overline{\mathcal{P}}_k} \|p(A)r_0\|_2$: para acotar alcanza con exhibir un p. Terminación en $\leq n$ pasos (Cayley–Hamilton).
4. Para $A = V\Lambda V^{-1}$: $\frac{\|r_k\|}{\|r_0\|} \leq \kappa_2(V)\, \text{máx}_{\sigma(A)} |p|$. El factor $\kappa_2(V)$ es el precio de la no simetría ($= 1$ si A es normal).
5. Si $\|I - A\|_2 \leq \rho < 1$: $\|r_k\|_2 \leq \rho^k \|r_0\|_2$ y $\|e_k\|_2 \leq \kappa_2(A)\rho^k \|e_0\|_2$. Condición suficiente, no necesaria.
6. **Precondicionar** sin restricciones de simetría: a izquierda mejora la relación residuo–error ($\kappa_2(MA)$); a derecha minimiza el residuo verdadero. En ambos casos el algoritmo no cambia: solo el producto matriz–vector.
7. **Para hacer:** Problemas 5.19 y 5.20 (Corolarios 5.40 y 5.41).
8. **Próxima:** cómo se calcula el argmin: Arnoldi y rotaciones de Givens (5.9.4–5.9.5).