

Factorización QR

Clases 3 y 4 · Capítulo 3

Análisis Numérico (LMA) · Métodos Numéricos II (LCD)

28 de agosto de 2026

Facultad de Ingeniería Química · UNL

- 3.1 Mínimos cuadrados y ecuaciones normales.
- 3.2 Matrices ortogonales: la idea de QR .
- 3.3 Ortogonalización de Gram–Schmidt.
- 3.4 Matrices de Householder (QR eficiente y estable).
- 3.5 Rotaciones de Givens (matrices Hessenberg).

Objetivo: resolver $\min_x \|Ax - b\|_2$ con $A \in \mathbb{R}^{n \times m}$, $n \geq m$ (sistemas **sobredeterminados**),

de manera **estable**.

3.1 Mínimos cuadrados

Ajuste por mínimos cuadrados

Ajustar puntos (X_i, Y_i) , $i = 1, \dots, n$, por una cuadrática $\alpha X^2 + \beta X + \gamma$: minimizar

$$J(\alpha, \beta, \gamma) = \sum_{i=1}^n [(\alpha X_i^2 + \beta X_i + \gamma) - Y_i]^2.$$

Ajuste por mínimos cuadrados

Ajustar puntos (X_i, Y_i) , $i = 1, \dots, n$, por una cuadrática $\alpha X^2 + \beta X + \gamma$: minimizar

$$J(\alpha, \beta, \gamma) = \sum_{i=1}^n [(\alpha X_i^2 + \beta X_i + \gamma) - Y_i]^2.$$

$$\text{Con } A = \begin{bmatrix} X_1^2 & X_1 & 1 \\ \vdots & \vdots & \vdots \\ X_n^2 & X_n & 1 \end{bmatrix}, \quad b = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}, \quad x = \begin{bmatrix} \alpha \\ \beta \\ \gamma \end{bmatrix} :$$

$$J(x) = \|Ax - b\|_2^2.$$

Problema general: minimizar $\|Ax - b\|_2$ con $A \in \mathbb{R}^{n \times m}$, $b \in \mathbb{R}^n$, $n \geq m$.

Ecuaciones normales

Ax recorre el espacio columna de A : buscamos el punto de $\text{col}(A)$ más cercano a b

$\Rightarrow Ax - b$ ortogonal a las columnas de A :

$$\text{col}_j(A)^T (Ax - b) = 0 \quad \forall j \quad \Longleftrightarrow \quad \boxed{A^T Ax = A^T b} \quad (\text{ecuaciones normales}).$$

Ecuaciones normales

Ax recorre el espacio columna de A : buscamos el punto de $\text{col}(A)$ más cercano a b

$\Rightarrow Ax - b$ ortogonal a las columnas de A :

$$\text{col}_j(A)^T (Ax - b) = 0 \quad \forall j \quad \Longleftrightarrow \quad \boxed{A^T Ax = A^T b} \quad (\text{ecuaciones normales}).$$

- Si las columnas de A son l.i., $A^T A$ es **sdp** $\Rightarrow$ solución única $x = (A^T A)^{-1} A^T b$.
- $(A^T A)^{-1} A^T$ es la **pseudoinversa** de A .
- **Pero** formar $A^T A$ empeora el condicionamiento (se “eleva al cuadrado”).
Buscamos algo mejor: la factorización QR .

3.2 Matrices ortogonales

Definición

$Q \in \mathbb{R}^{n \times m}$ es **ortogonal** si $Q^T Q = I$.

Definición

$Q \in \mathbb{R}^{n \times m}$ es **ortogonal** si $Q^T Q = I$.

- Sus columnas son **ortonormales** ($\text{col}_i(Q) \cdot \text{col}_j(Q) = \delta_{ij}$) $\Rightarrow$ l.i., y $n \geq m$.
- Producto de ortogonales es ortogonal.
- **Isometría**: $\|Qx\|_2 = \|x\|_2$ y $(Qx) \cdot (Qy) = x \cdot y$.

La isometría es la clave: multiplicar por Q^T **no cambia** la norma que minimizamos.

La idea de QR

Si $Q \in \mathbb{R}^{n \times n}$ es ortogonal, $\min \|Ax - b\|_2^2 = \min \|Q^T(Ax - b)\|_2^2$.

Supongamos $Q^T A = R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$, con $R_1 \in \mathbb{R}^{m \times m}$ triangular superior.

Con $c = Q^T b = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}$:

$$\|Ax - b\|_2^2 = \|Rx - c\|_2^2 = \underbrace{\|R_1 x - c_1\|_2^2}_{\text{se puede anular}} + \underbrace{\|c_2\|_2^2}_{\text{fijo}}.$$

La idea de QR

Si $Q \in \mathbb{R}^{n \times n}$ es ortogonal, $\min \|Ax - b\|_2^2 = \min \|Q^T(Ax - b)\|_2^2$.

Supongamos $Q^T A = R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$, con $R_1 \in \mathbb{R}^{m \times m}$ triangular superior.

Con $c = Q^T b = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}$:

$$\|Ax - b\|_2^2 = \|Rx - c\|_2^2 = \underbrace{\|R_1 x - c_1\|_2^2}_{\text{se puede anular}} + \underbrace{\|c_2\|_2^2}_{\text{fijo}}.$$

Conclusión

El mínimo se alcanza resolviendo el sistema triangular

$$R_1 x = (Q^T b)_{1:m}, \quad \text{y} \quad \|Ax - b\|_2^2 = \|(Q^T b)_{m+1:n}\|_2^2.$$

3.3 Ortogonalización de Gram–Schmidt

Dados $v_1, \dots, v_m \in \mathbb{R}^n$ l.i., ortonormalizamos:

$$u_1 = v_1 / \|v_1\|$$

$$w_2 = v_2 - (v_2 \cdot u_1)u_1, \quad u_2 = w_2 / \|w_2\|$$

$$w_3 = v_3 - (v_3 \cdot u_1)u_1 - (v_3 \cdot u_2)u_2, \quad u_3 = w_3 / \|w_3\|$$

$$\vdots$$

Cada u_i es combinación lineal de $v_1, \dots, v_i$ (con coeficiente de v_i no nulo).

Gram–Schmidt da una QR

Poniendo $v_i = \text{col}_i(A)$ y $u_i = \text{col}_i(Q_1)$:

$$\underbrace{\begin{bmatrix} v_1 & \cdots & v_m \end{bmatrix}}_A = \underbrace{\begin{bmatrix} u_1 & \cdots & u_m \end{bmatrix}}_{Q_1} \underbrace{\begin{bmatrix} \times & \times & \cdots & \times \\ 0 & \times & \cdots & \times \\ \vdots & & \ddots & \vdots \\ 0 & \cdots & 0 & \times \end{bmatrix}}_{R_1}.$$

Teorema

Si las columnas de $A \in \mathbb{R}^{n \times m}$ son l.i., existe $A = Q_1 R_1$ con $Q_1 \in \mathbb{R}^{n \times m}$ ortogonal y $R_1 \in \mathbb{R}^{m \times m}$ triangular superior.


(Completando una base ortonormal de $\mathbb{R}^n$ se obtiene la versión $A = QR$ con $Q \in \mathbb{R}^{n \times n}$.) Existe un camino más económico y estable: **Householder**.

3.4 Matrices de Householder

Matrices de Proyección

Definición

$P = I - ww^T$ con $v \in \mathbb{R}^n$, $\|w\|_2 = 1$.




P proyecta x sobre el hiperplano ortogonal a w .

Matrices de Proyección $\rightarrow$ Householder

Definición

$H = I - 2ww^T$ con $w \in \mathbb{R}^n$, $\|w\|_2 = 1$.




H **refleja** x respecto del hiperplano ortogonal a w .

Matrices de Proyección $\rightarrow$ Householder

Definición

$H = I - 2ww^T$ con $w \in \mathbb{R}^n$, $\|w\|_2 = 1$.




H refleja x respecto del hiperplano ortogonal a w . $\rightsquigarrow u = \sqrt{2}w$

Matrices de Householder

Definición

$H = I - uu^T$ con $u \in \mathbb{R}^n$, $\|u\|_2 = \sqrt{2}$.



H refleja x respecto del hiperplano ortogonal a u .

Propiedades de $H = I - uu^T$

- Simétrica: $H^T = H$.
- Ortogonal: $HH = (I - uu^T)^2 = I - 2uu^T + \underbrace{u u^T u u^T}_2 = I$.
- Producto barato: no se arma H , se usa

$$HX = (I - uu^T)X = X - u(u^T X).$$

Cuesta $\sim 4nk$ operaciones (contra $\sim 2n^2k$ armando H).

La idea: construir Q como producto de matrices de Householder.

Teorema

Si $\|x\|_2 = 1$ y


$$u = \frac{1}{\sqrt{1 \pm x_1}}(x \pm e_1),$$

con el signo tal que $1 \pm x_1 > 0$, entonces

$H = I - uu^T$ cumple

$$Hx = \mp e_1.$$

Si $x = \text{col}_1(A)$, entonces $\text{col}_1(HA) = \mp \|x\|_2 e_1$: ¡ceros debajo de la diagonal!



- **Elección del signo:** tomar $\sigma = \text{sgn}(x_1)$, es decir $+1$ si $x_1 \geq 0$, -1 si $x_1 < 0$. Así $\sqrt{1 \pm x_1}$ es lo más grande posible (evita cancelación al dividir).
- Si $\|x\|_2 \neq 1$:

$$u = \frac{1}{\sqrt{1 + \sigma \frac{x_1}{\|x\|_2}}} \left(\frac{x}{\|x\|_2} + \sigma e_1 \right), \quad Hx = -\sigma \|x\|_2 e_1.$$

Aplicamos H_1 (anula la columna 1 debajo de la diagonal):

$$H_1 A = \begin{bmatrix} \rho_1 & r_1^T \\ 0 & A_1 \end{bmatrix}, \quad \rho_1 = -\sigma \|x\|_2.$$

Repetimos sobre la submatriz A_1 con H_2 , luego A_2 con $H_3, \dots$

$$\underbrace{\tilde{H}_m \cdots \tilde{H}_2 H_1}_{Q^T} A = R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}, \quad A = QR.$$

Teorema

Si $A \in \mathbb{R}^{n \times m}$ tiene columnas l.i., existen $Q \in \mathbb{R}^{n \times n}$ ortogonal y $R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$ con R_1 tri. sup. no singular, tales que $A = QR$.

Código: qrhouse

```
function [U,R] = qrhouse(A)
% QR de A:  $A = QR$ . No se arma Q: U guarda los vectores u
% de Householder ( $Q' = H_m \dots H_2 H_1$ ). Ver qrsolve.
[n,m] = size(A);
R = A;   U = zeros(n,m);
for i = 1:m
    normx = norm(R(i:n,i));
    u = R(i:n,i)/normx;
    if u(1) >= 0, sg = 1; else, sg = -1; end
    u(1) = u(1) + sg;
    u = u / sqrt(1 + sg*R(i,i)/normx);
    U(1:n-i+1,i) = u;
    R(i,i) = -sg*normx;   R(i+1:n,i) = 0;
    R(i:n,i+1:m) = R(i:n,i+1:m) - u*(u'*R(i:n,i+1:m));
end
```

Código: qrsolve (mínimos cuadrados)

```
function [x,e] = qrsolve(U,R,b)
% min ||Ax-b|| usando la QR de qrhouse (A = Q R)
[n,m] = size(U);
c = b;
for i = 1:m                % c = Q' b
    u = U(1:n-i+1,i);
    c(i:n) = c(i:n) - u*(u'*c(i:n));
end
x = trisup(R(1:m,:), c(1:m)); % resolver R1 x = c1
if nargout > 1
    e = norm(c(m+1:n));      % ||Ax-b|| = ||c2||
end
```

Nunca se arma Q : se aplican los H_i a b . El residuo sale “gratis”.

Conteo de operaciones ($n \gg k$)

Para el problema mín $\|Ax - b\|_2$ con $A \in \mathbb{R}^{n \times k}$ y $n \gg k$ (muchas más filas que columnas), a orden dominante:

Método	Operaciones	Estabilidad
Ecuaciones normales ($A^T A x = A^T b$ vía Cholesky)	$nk^2 + \frac{1}{3}k^3$ $\approx nk^2$	$\kappa(A^T A) = \kappa(A)^2$ (se pierde precisión)
QR por Gram–Schmidt	$\approx 2nk^2$	mejor (usar GS modificado)
QR por Householder	$2nk^2 - \frac{2}{3}k^3$ $\approx 2nk^2$	backward estable (recomendado)

Las **ecuaciones normales** son las más baratas ($\sim$ la mitad del trabajo), pero formar $A^T A$ **eleva al cuadrado** el número de condición. **Householder** cuesta el doble y es estable: la opción robusta cuando A está mal condicionada.

3.5 Rotaciones de Givens

Definición

H es **upper Hessenberg** si $h_{ij} = 0$ para $i > j + 1$ (nulas debajo de la primera subdiagonal).

$$H = \begin{bmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & 0 & \times & \times \end{bmatrix}$$

Aparecen en métodos iterativos (GMRES) y en el cálculo de **autovalores**. Para ellas hay una QR mucho más económica: las **rotaciones de Givens**.

Una rotación de 2×2 (ortogonal):

$$G = \begin{bmatrix} c & -s \\ s & c \end{bmatrix}, \quad c^2 + s^2 = 1, \quad G \begin{bmatrix} c \\ -s \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

$G_j(c, s)$: la identidad de $n \times n$ con ese bloque en las filas/columnas $j, j+1$. Solo afecta **dos filas** al multiplicar.

Anulamos una a una las entradas de la subdiagonal. Para el cero en $(2, 1)$ rotamos

$$\begin{bmatrix} h_{11} \\ h_{21} \end{bmatrix}:$$

$$c_1 = \frac{h_{11}}{\sqrt{h_{11}^2 + h_{21}^2}}, \quad s_1 = \frac{-h_{21}}{\sqrt{h_{11}^2 + h_{21}^2}}.$$

Luego G_2 anula $(3, 2)$, G_3 anula $(4, 3)$, ...

$$\underbrace{G_p \cdots G_2 G_1}_{Q^T} H = R \text{ (tri. sup.)}, \quad p = \begin{cases} m-1 & n = m \\ m & n > m \end{cases}.$$

Cada G_j toca solo dos filas $\Rightarrow$ muy económico para Hessenberg.

- Mínimos cuadrados mín $\|Ax - b\|_2$: **ecuaciones normales** $A^T Ax = A^T b$ (simple, pero peor condicionado).
- Vía ortogonal: $A = QR \Rightarrow$ resolver $R_1 x = (Q^T b)_{1:m}$; el residuo es $\|(Q^T b)_{m+1:n}\|$.
- **Gram-Schmidt**: construye Q ortonormalizando columnas.
- **Householder**: Q como producto de reflexiones; eficiente y **estable** (no arma Q).
- **Givens**: rotaciones que anulan una entrada por vez; ideal para **Hessenberg**.

Para la próxima

Métodos **iterativos** para sistemas lineales grandes y ralos.