

Métodos iterativos estacionarios para sistemas lineales

Clases 5 y 6 · Capítulo 4

Análisis Numérico (LMA) · Métodos Numéricos II (LCD)

1 y 4 de septiembre de 2026

Facultad de Ingeniería Química · UNL

Clase 5

1. Motivación: ¿por qué iterativos?
2. **4.1** Normas de vectores y matrices.
3. **4.1** Número de condición.

Clase 6

5. **4.2** Métodos estacionarios:
Richardson, Jacobi, Gauss-Seidel, SOR.
6. **4.2** Convergencia: el radio espectral.

¿Por qué métodos iterativos?

Los métodos directos (Gauss, LU) fallan o son costosos cuando. . .

¿Por qué métodos iterativos?

Los métodos directos (Gauss, LU) fallan o son costosos cuando...

- La factorización produce **relleno**: L y U tienen más no-ceros que A (frecuente en matrices ralas de banda).

¿Por qué métodos iterativos?

Los métodos directos (Gauss, LU) fallan o son costosos cuando...

- La factorización produce **relleno**: L y U tienen más no-ceros que A (frecuente en matrices ralas de banda).
- Solo se necesita una solución **aproximada** (p.ej. en cada paso de Newton).

¿Por qué métodos iterativos?

Los métodos directos (Gauss, LU) fallan o son costosos cuando...

- La factorización produce **relleno**: L y U tienen más no-ceros que A (frecuente en matrices ralas de banda).
- Solo se necesita una solución **aproximada** (p.ej. en cada paso de Newton).
- Se tiene una buena aproximación inicial (ecuaciones diferenciales en el tiempo: la solución anterior es un buen punto de partida).

¿Por qué métodos iterativos?

Los métodos directos (Gauss, LU) fallan o son costosos cuando...

- La factorización produce **relleno**: L y U tienen más no-ceros que A (frecuente en matrices ralas de banda).
- Solo se necesita una solución **aproximada** (p.ej. en cada paso de Newton).
- Se tiene una buena aproximación inicial (ecuaciones diferenciales en el tiempo: la solución anterior es un buen punto de partida).
- Solo se dispone del **operador** $x \mapsto Ax$, no de las entradas de A (procesamiento de señales, matrices implícitas).

¿Por qué métodos iterativos?

Los métodos directos (Gauss, LU) fallan o son costosos cuando...

- La factorización produce **relleno**: L y U tienen más no-ceros que A (frecuente en matrices ralas de banda).
- Solo se necesita una solución **aproximada** (p.ej. en cada paso de Newton).
- Se tiene una buena aproximación inicial (ecuaciones diferenciales en el tiempo: la solución anterior es un buen punto de partida).
- Solo se dispone del **operador** $x \mapsto Ax$, no de las entradas de A (procesamiento de señales, matrices implícitas).

Idea central

Generar una sucesión $x_0, x_1, x_2, \dots$ tal que $x_k \rightarrow x = A^{-1}b$.

4.1 Normas de vectores y matrices

Definición

Una **norma** en un espacio vectorial X es $\| \cdot \| : X \rightarrow \mathbb{R}$ con:

- (I) $\|x\| \geq 0$, y $\|x\| = 0 \iff x = 0$.
- (II) $\|\alpha x\| = |\alpha| \|x\|$. (homogeneidad)
- (III) $\|x + y\| \leq \|x\| + \|y\|$. (desigualdad triangular)

Definición

Una **norma** en un espacio vectorial X es $\|\cdot\| : X \rightarrow \mathbb{R}$ con:

- (I) $\|x\| \geq 0$, y $\|x\| = 0 \iff x = 0$.
- (II) $\|\alpha x\| = |\alpha| \|x\|$. (homogeneidad)
- (III) $\|x + y\| \leq \|x\| + \|y\|$. (desigualdad triangular)

Normas p en $\mathbb{R}^n$: $x = (x_1, \dots, x_n)^T$

$$\|x\|_1 = \sum_{i=1}^n |x_i|, \quad \|x\|_2 = \left(\sum_{i=1}^n x_i^2 \right)^{1/2}, \quad \|x\|_\infty = \max_i |x_i|.$$

Definición

Una **norma** en un espacio vectorial X es $\|\cdot\| : X \rightarrow \mathbb{R}$ con:

- (I) $\|x\| \geq 0$, y $\|x\| = 0 \iff x = 0$.
- (II) $\|\alpha x\| = |\alpha| \|x\|$. (homogeneidad)
- (III) $\|x + y\| \leq \|x\| + \|y\|$. (desigualdad triangular)

Normas p en $\mathbb{R}^n$: $x = (x_1, \dots, x_n)^T$

$$\|x\|_1 = \sum_{i=1}^n |x_i|, \quad \|x\|_2 = \left(\sum_{i=1}^n x_i^2 \right)^{1/2}, \quad \|x\|_\infty = \max_i |x_i|.$$

Hecho importante

En $\mathbb{R}^n$, **todas las normas son equivalentes** (hecho que escapa al interés de este curso). En particular, convergencia en una norma implica convergencia en todas.

Producto escalar y desigualdad de Cauchy-Schwarz

Definición

Un **producto escalar** en X es $(\cdot, \cdot) : X \times X \rightarrow \mathbb{R}$ con simetría, bilinealidad y definida positiva.

Producto escalar y desigualdad de Cauchy-Schwarz

Definición

Un **producto escalar** en X es $(\cdot, \cdot) : X \times X \rightarrow \mathbb{R}$ con simetría, bilinealidad y definida positiva.

Definiendo $\|x\| = (x, x)^{1/2}$ se obtiene una norma, *gracias a*:

Teorema (Cauchy-Schwarz)

$|(x, y)| \leq \|x\| \|y\|$ para todo $x, y \in X$.

Producto escalar y desigualdad de Cauchy-Schwarz

Definición

Un **producto escalar** en X es $(\cdot, \cdot) : X \times X \rightarrow \mathbb{R}$ con simetría, bilinealidad y definida positiva.

Definiendo $\|x\| = (x, x)^{1/2}$ se obtiene una norma, *gracias a*:

Teorema (Cauchy-Schwarz)

$|(x, y)| \leq \|x\| \|y\|$ para todo $x, y \in X$.

En $\mathbb{R}^n$: producto escalar estándar $(x, y) = x^T y$, que genera $\|\cdot\|_2$.

$$|x^T y| \leq \|x\|_2 \|y\|_2.$$

Producto escalar y desigualdad de Cauchy-Schwarz

Definición

Un **producto escalar** en X es $(\cdot, \cdot) : X \times X \rightarrow \mathbb{R}$ con simetría, bilinealidad y definida positiva.

Definiendo $\|x\| = (x, x)^{1/2}$ se obtiene una norma, *gracias a*:

Teorema (Cauchy-Schwarz)

$|(x, y)| \leq \|x\| \|y\|$ para todo $x, y \in X$.

En $\mathbb{R}^n$: producto escalar estándar $(x, y) = x^T y$, que genera $\|\cdot\|_2$.

$$|x^T y| \leq \|x\|_2 \|y\|_2.$$

Norma-A: dada $A \in \mathbb{R}^{n \times n}$ **sdp**,

$$(x, y)_A = x^T A y \implies \|x\|_A = (x^T A x)^{1/2}.$$

Normas de matrices — normas inducidas

Dada una norma $\|\cdot\|$ en $\mathbb{R}^n$, la **norma inducida** en $\mathbb{R}^{n \times n}$ es

$$\|A\| = \max_{\substack{x \in \mathbb{R}^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|.$$

Normas de matrices — normas inducidas

Dada una norma $\|\cdot\|$ en $\mathbb{R}^n$, la **norma inducida** en $\mathbb{R}^{n \times n}$ es

$$\|A\| = \max_{\substack{x \in \mathbb{R}^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|.$$

Fórmulas explícitas

$$\|A\|_1 = \max_j \sum_i |a_{ij}| \quad (\text{máx. suma por columnas})$$

$$\|A\|_\infty = \max_i \sum_j |a_{ij}| \quad (\text{máx. suma por filas})$$

$$\|A\|_2 = \sigma_1(A) \quad (\text{mayor valor singular})$$

Normas de matrices — normas inducidas

Dada una norma $\|\cdot\|$ en $\mathbb{R}^n$, la **norma inducida** en $\mathbb{R}^{n \times n}$ es

$$\|A\| = \max_{\substack{x \in \mathbb{R}^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|.$$

Fórmulas explícitas

$$\|A\|_1 = \max_j \sum_i |a_{ij}| \quad (\text{máx. suma por columnas})$$

$$\|A\|_\infty = \max_i \sum_j |a_{ij}| \quad (\text{máx. suma por filas})$$

$$\|A\|_2 = \sigma_1(A) \quad (\text{mayor valor singular})$$

Consistencia: $\|Ax\| \leq \|A\|\|x\|$ y $\|AB\| \leq \|A\|\|B\|$.

Definición

La **norma de Frobenius** de $A \in \mathbb{R}^{n \times n}$ es

$$\|A\|_F = \left(\sum_{i,j=1}^n a_{ij}^2 \right)^{1/2} = \sqrt{\text{tr}(A^T A)}.$$

Definición

La **norma de Frobenius** de $A \in \mathbb{R}^{n \times n}$ es

$$\|A\|_F = \left(\sum_{i,j=1}^n a_{ij}^2 \right)^{1/2} = \sqrt{\text{tr}(A^T A)}.$$

Relación con los valores singulares: $\|A\|_F = \left(\sum_{i=1}^r \sigma_i^2 \right)^{1/2}.$

Definición

La **norma de Frobenius** de $A \in \mathbb{R}^{n \times n}$ es

$$\|A\|_F = \left(\sum_{i,j=1}^n a_{ij}^2 \right)^{1/2} = \sqrt{\text{tr}(A^T A)}.$$

Relación con los valores singulares: $\|A\|_F = \left(\sum_{i=1}^r \sigma_i^2 \right)^{1/2}.$

Propiedad importante

La norma de Frobenius **no es inducida** (en particular $\|I\|_F = \sqrt{n} \neq 1$), pero aun así satisface la consistencia:

$$\|AB\|_F \leq \|A\|_F \|B\|_F.$$

Definición

Para $A \in \mathbb{R}^{n \times n}$ invertible: $\kappa(A) = \|A\| \|A^{-1}\| \geq 1$.

Definición

Para $A \in \mathbb{R}^{n \times n}$ invertible: $\kappa(A) = \|A\| \|A^{-1}\| \geq 1$.

Error relativo vs. residuo relativo

Si $x = A^{-1}b$ y $\tilde{x}$ es una aproximación con residuo $\tilde{b} = A\tilde{x}$:

$$\frac{1}{\kappa(A)} \frac{\|\tilde{b} - b\|}{\|b\|} \leq \frac{\|\tilde{x} - x\|}{\|x\|} \leq \kappa(A) \frac{\|\tilde{b} - b\|}{\|b\|}.$$

Definición

Para $A \in \mathbb{R}^{n \times n}$ invertible: $\kappa(A) = \|A\| \|A^{-1}\| \geq 1$.

Error relativo vs. residuo relativo

Si $x = A^{-1}b$ y $\tilde{x}$ es una aproximación con residuo $\tilde{b} = A\tilde{x}$:

$$\frac{1}{\kappa(A)} \frac{\|\tilde{b} - b\|}{\|b\|} \leq \frac{\|\tilde{x} - x\|}{\|x\|} \leq \kappa(A) \frac{\|\tilde{b} - b\|}{\|b\|}.$$

- $\kappa(A) \approx 1$: problema bien condicionado.
- $\kappa(A) \gg 1$: pequeñas perturbaciones en b provocan grandes errores en x .
- Para A simétrica: $\kappa_2(A) = \lambda_{\text{máx}}/\lambda_{\text{mín}}$.

Número de condición para matrices rectangulares

Sea $A \in \mathbb{R}^{n \times m}$ con $n \geq m$ y rango completo por columnas, con valores singulares $\sigma_1 \geq \dots \geq \sigma_m > 0$.

Número de condición para matrices rectangulares

Sea $A \in \mathbb{R}^{n \times m}$ con $n \geq m$ y rango completo por columnas, con valores singulares $\sigma_1 \geq \dots \geq \sigma_m > 0$.

Definición

$$\kappa_2(A) = \|A\|_2 \|A^+\|_2 = \frac{\sigma_1}{\sigma_m}, \quad \text{donde } A^+ = (A^T A)^{-1} A^T \text{ es la pseudoinversa.}$$

Número de condición para matrices rectangulares

Sea $A \in \mathbb{R}^{n \times m}$ con $n \geq m$ y rango completo por columnas, con valores singulares $\sigma_1 \geq \dots \geq \sigma_m > 0$.

Definición

$$\kappa_2(A) = \|A\|_2 \|A^+\|_2 = \frac{\sigma_1}{\sigma_m}, \quad \text{donde } A^+ = (A^T A)^{-1} A^T \text{ es la pseudoinversa.}$$

Número de condición de las ecuaciones normales

$$\kappa_2(A^T A) = \kappa_2(A)^2.$$

Resolver $\min_x \|Ax - b\|_2$ via $(A^T A)x = A^T b$ **cuadra la condición**.

Por eso es preferible usar la factorización QR de A .

Número de condición para matrices rectangulares

Sea $A \in \mathbb{R}^{n \times m}$ con $n \geq m$ y rango completo por columnas, con valores singulares $\sigma_1 \geq \dots \geq \sigma_m > 0$.

Definición

$$\kappa_2(A) = \|A\|_2 \|A^+\|_2 = \frac{\sigma_1}{\sigma_m}, \quad \text{donde } A^+ = (A^T A)^{-1} A^T \text{ es la pseudoinversa.}$$

Número de condición de las ecuaciones normales

$$\kappa_2(A^T A) = \kappa_2(A)^2.$$

Resolver $\min_x \|Ax - b\|_2$ via $(A^T A)x = A^T b$ **cuadra la condición**.

Por eso es preferible usar la factorización QR de A .

- En MATLAB/OCTAVE: `cond(A)` funciona también para A rectangular.

Clase 6 · Métodos iterativos estacionarios y convergencia

Esquema general: métodos estacionarios

Todos los métodos de esta sección tienen la forma

$$x_{k+1} = M x_k + c, \quad k = 0, 1, 2, \dots$$

con M (matriz de iteración) y c fijos.

Esquema general: métodos estacionarios

Todos los métodos de esta sección tienen la forma

$$x_{k+1} = M x_k + c, \quad k = 0, 1, 2, \dots$$

con M (matriz de iteración) y c fijos.

Si x es la solución de $Ax = b$, entonces $x = Mx + c$, y el **error** $e_k = x_k - x$ satisface

$$e_{k+1} = M e_k = M^{k+1} e_0.$$

Esquema general: métodos estacionarios

Todos los métodos de esta sección tienen la forma

$$x_{k+1} = M x_k + c, \quad k = 0, 1, 2, \dots$$

con M (matriz de iteración) y c fijos.

Si x es la solución de $Ax = b$, entonces $x = Mx + c$, y el **error** $e_k = x_k - x$ satisface

$$e_{k+1} = M e_k = M^{k+1} e_0.$$

Teorema (se demostrará en la clase 6)

La iteración $x_{k+1} = Mx_k + c$ converge para todo x_0 **si y solo si** $\rho(M) < 1$, donde $\rho(M) = \max\{|\lambda| : \lambda \text{ autovalor de } M\}$ es el radio espectral de M .

$$Ax = b \iff x = x - \alpha(Ax - b) \iff x = \underbrace{(I - \alpha A)}_M x + \alpha b$$

$$Ax = b \iff x = x - \alpha(Ax - b) \iff x = \underbrace{(I - \alpha A)}_M x + \alpha b$$

Iteración de Richardson ($\alpha \neq 0$ dado)

$$x_{k+1} = (I - \alpha A) x_k + \alpha b.$$

$$Ax = b \iff x = x - \alpha(Ax - b) \iff x = \underbrace{(I - \alpha A)}_M x + \alpha b$$

Iteración de Richardson ($\alpha \neq 0$ dado)

$$x_{k+1} = (I - \alpha A) x_k + \alpha b.$$

- Matriz de iteración: $M_R = I - \alpha A$.
- Solo requiere el producto $x \mapsto Ax$ (no las entradas de A).
- ¿Cómo elegir α ? (lo veremos en la clase 6.)

Método de Jacobi

De $Ax = b$ se despeja la i -ésima componente:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j \right).$$

Método de Jacobi

De $Ax = b$ se despeja la i -ésima componente:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j \right).$$

Iteración de Jacobi

$$x_{k+1}^i = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_k^j \right), \quad i = 1, \dots, n.$$

Método de Jacobi

De $Ax = b$ se despeja la i -ésima componente:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j \right).$$

Iteración de Jacobi

$$x_{k+1}^i = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_k^j \right), \quad i = 1, \dots, n.$$

En forma matricial, con $A = L + D + U$:

$$x_{k+1} = \underbrace{-D^{-1}(L + U)}_{M_J} x_k + D^{-1}b.$$

Método de Jacobi

De $Ax = b$ se despeja la i -ésima componente:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j \right).$$

Iteración de Jacobi

$$x_{k+1}^i = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_k^j \right), \quad i = 1, \dots, n.$$

En forma matricial, con $A = L + D + U$:

$$x_{k+1} = \underbrace{-D^{-1}(L + U)}_{M_J} x_k + D^{-1}b.$$

$(M_J)_{ij} = -a_{ij}/a_{ii}$ para $i \neq j$; $(M_J)_{ii} = 0$. Calcular D^{-1} es gratis: solo dividir por los elementos de la diagonal.

Método de Gauss-Seidel

Idea: al calcular x_{k+1}^i , **usar ya** los valores $x_{k+1}^1, \dots, x_{k+1}^{i-1}$ (disponibles si se procesa en orden).

Método de Gauss-Seidel

Idea: al calcular x_{k+1}^i , **usar ya** los valores $x_{k+1}^1, \dots, x_{k+1}^{i-1}$ (disponibles si se procesa en orden).

Iteración de Gauss-Seidel

$$x_{k+1}^i = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_{k+1}^j - \sum_{j > i} a_{ij} x_k^j \right).$$

Método de Gauss-Seidel

Idea: al calcular x_{k+1}^i , **usar ya** los valores $x_{k+1}^1, \dots, x_{k+1}^{i-1}$ (disponibles si se procesa en orden).

Iteración de Gauss-Seidel

$$x_{k+1}^i = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_{k+1}^j - \sum_{j > i} a_{ij} x_k^j \right).$$

En forma matricial:

$$x_{k+1} = \underbrace{-(L + D)^{-1}U}_{M_{GS}} x_k + (L + D)^{-1}b.$$

Método de Gauss-Seidel

Idea: al calcular x_{k+1}^i , **usar ya** los valores $x_{k+1}^1, \dots, x_{k+1}^{i-1}$ (disponibles si se procesa en orden).

Iteración de Gauss-Seidel

$$x_{k+1}^i = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_{k+1}^j - \sum_{j > i} a_{ij} x_k^j \right).$$

En forma matricial:

$$x_{k+1} = \underbrace{-(L + D)^{-1}U}_{M_{GS}} x_k + (L + D)^{-1}b.$$

- No requiere almacenar dos copias del vector: actualización *in-place*.
- Para matrices e.d.d.: converge al menos tan rápido como Jacobi.

Método SOR (sobrerrelajación sucesiva)

Dado $\omega \in \mathbb{R} \setminus \{0\}$, se parte de la descomposición $A = \left(\frac{1}{\omega}D + L\right) + \left(\frac{\omega-1}{\omega}D + U\right)$.

Método SOR (sobre-relajación sucesiva)

Dado $\omega \in \mathbb{R} \setminus \{0\}$, se parte de la descomposición $A = \left(\frac{1}{\omega}D + L\right) + \left(\frac{\omega-1}{\omega}D + U\right)$.

Iteración SOR

$$x_{k+1} = \underbrace{-\left(\frac{1}{\omega}D + L\right)^{-1}\left(\frac{\omega-1}{\omega}D + U\right)}_{M_{SOR}^{\omega}} x_k + \left(\frac{1}{\omega}D + L\right)^{-1} b.$$

Método SOR (sobrerrelajación sucesiva)

Dado $\omega \in \mathbb{R} \setminus \{0\}$, se parte de la descomposición $A = \left(\frac{1}{\omega}D + L\right) + \left(\frac{\omega-1}{\omega}D + U\right)$.

Iteración SOR

$$x_{k+1} = \underbrace{-\left(\frac{1}{\omega}D + L\right)^{-1}\left(\frac{\omega-1}{\omega}D + U\right)}_{M_{SOR}^{\omega}} x_k + \left(\frac{1}{\omega}D + L\right)^{-1}b.$$

- $\omega = 1$: Gauss-Seidel.
- $\omega \in (1, 2)$: *sobre*-relajación (acelera la convergencia en muchos casos).
- $\omega \in (0, 1)$: *sub*-relajación (puede estabilizar métodos divergentes).

Método SOR (sobrerelajación sucesiva)

Dado $\omega \in \mathbb{R} \setminus \{0\}$, se parte de la descomposición $A = \left(\frac{1}{\omega}D + L\right) + \left(\frac{\omega-1}{\omega}D + U\right)$.

Iteración SOR

$$x_{k+1} = \underbrace{-\left(\frac{1}{\omega}D + L\right)^{-1}\left(\frac{\omega-1}{\omega}D + U\right)}_{M_{SOR}^{\omega}} x_k + \left(\frac{1}{\omega}D + L\right)^{-1}b.$$

- $\omega = 1$: Gauss-Seidel.
- $\omega \in (1, 2)$: *sobre*-relajación (acelera la convergencia en muchos casos).
- $\omega \in (0, 1)$: *sub*-relajación (puede estabilizar métodos divergentes).

Necesidad de $\omega \in (0, 2)$

Si $\omega \notin (0, 2)$, entonces $\rho(M_{SOR}^{\omega}) \geq 1$ para **toda** A invertible. No hay convergencia posible.

¿Cuándo convergen estos métodos?

Hemos visto varios métodos de la forma

$$x_{k+1} = M x_k + c.$$

¿Cuándo convergen estos métodos?

Hemos visto varios métodos de la forma

$$x_{k+1} = M x_k + c.$$

Primera observación: si existe una norma inducida con $\|M\| < 1$, entonces

$$\|x_{k+1} - x\| \leq \|M\| \|x_k - x\| \leq \|M\|^{k+1} \|x_0 - x\| \rightarrow 0.$$

El método converge *para cualquier* x_0 .

¿Cuándo convergen estos métodos?

Hemos visto varios métodos de la forma

$$x_{k+1} = M x_k + c.$$

Primera observación: si existe una norma inducida con $\|M\| < 1$, entonces

$$\|x_{k+1} - x\| \leq \|M\| \|x_k - x\| \leq \|M\|^{k+1} \|x_0 - x\| \rightarrow 0.$$

El método converge *para cualquier* x_0 .

Convenio: diremos que un método **converge** cuando lo hace a partir de cualquier x_0 .

Ejemplo: calcular normas de la matriz de iteración

Sea

$$M = \begin{bmatrix} 0.5 & 0.7 & 0.1 \\ 0.2 & 0.1 & 0.2 \\ 0.2 & 0.05 & 0.6 \end{bmatrix}.$$

Norma 1 (máx. suma por columnas):

$$\|M\|_1 = ?$$

Norma ∞ (máx. suma por filas):

$$\|M\|_\infty = ?$$

Definición

El **espectro** de $A \in \mathbb{R}^{n \times n}$ es $\sigma(A) = \{\lambda \in \mathbb{C} : \lambda \text{ es autovalor de } A\}$.

El **radio espectral** de A es $\rho(A) = \max\{|\lambda| : \lambda \in \sigma(A)\}$.

Definición

El **espectro** de $A \in \mathbb{R}^{n \times n}$ es $\sigma(A) = \{\lambda \in \mathbb{C} : \lambda \text{ es autovalor de } A\}$.

El **radio espectral** de A es $\rho(A) = \max\{|\lambda| : \lambda \in \sigma(A)\}$.

Teorema (Caracterización del radio espectral)

Para toda $A \in \mathbb{R}^{n \times n}$: $\rho(A) = \inf\{\|A\| : \|\cdot\| \text{ norma inducida}\}$.

Definición

El **espectro** de $A \in \mathbb{R}^{n \times n}$ es $\sigma(A) = \{\lambda \in \mathbb{C} : \lambda \text{ es autovalor de } A\}$.

El **radio espectral** de A es $\rho(A) = \max\{|\lambda| : \lambda \in \sigma(A)\}$.

Teorema (Caracterización del radio espectral)

Para toda $A \in \mathbb{R}^{n \times n}$: $\rho(A) = \inf\{\|A\| : \|\cdot\| \text{ norma inducida}\}$.

Teorema (Descomposición de Schur)

Para toda $A \in \mathbb{C}^{n \times n}$ existe U unitaria ($\bar{U}^T U = I$) tal que $UA\bar{U}^T = T$, con T triangular superior y $\text{diag}(T) = (\lambda_1, \dots, \lambda_n)$ los autovalores de A .

Consecuencias: caracterizaciones de $\rho(A) < 1$

Teorema

Sea $A \in \mathbb{R}^{n \times n}$. Son equivalentes:

- (1) $\rho(A) < 1$;
- (2) $\|A\| < 1$ para alguna norma inducida;
- (3) $\lim_{k \rightarrow \infty} \|A^k\| = 0$ para toda norma inducida;
- (4) $\lim_{k \rightarrow \infty} A^k x = 0$ para todo $x \in \mathbb{R}^n$.

Consecuencias: caracterizaciones de $\rho(A) < 1$

Teorema

Sea $A \in \mathbb{R}^{n \times n}$. Son equivalentes:

- (1) $\rho(A) < 1$;
- (2) $\|A\| < 1$ para alguna norma inducida;
- (3) $\lim_{k \rightarrow \infty} \|A^k\| = 0$ para toda norma inducida;
- (4) $\lim_{k \rightarrow \infty} A^k x = 0$ para todo $x \in \mathbb{R}^n$.

Teorema

Sea $A \in \mathbb{R}^{n \times n}$. Cualquiera sea la norma inducida $\|\cdot\|$: $\rho(A) = \lim_{k \rightarrow \infty} \|A^k\|^{1/k}$.

1. Los métodos iterativos estacionarios tienen la forma $x_{k+1} = Mx_k + c$.
2. Convergen $\iff \rho(M) < 1$; cuanto menor $\rho(M)$, más rápido.