Análisis Numérico (LMA)
Métodos Numéricos II (LCD)

Apuntes sobre algunos temas de

Análisis Numérico (LMA)

Métodos Numéricos II (LCD)

Facultad de Ingeniería Química
Universidad Nacional del Litoral

Eduardo M. Garau, Pedro Morin, Ita Zocola

10 de noviembre de 2026

Presentación

Algunos comentarios sobre Cálculo Numérico:

- El objetivo es el desarrollo de algoritmos para el *cálculo* de soluciones, en general, será *aproximado*.
- El estudio de los algoritmos se enfoca principalmente en ver la relación entre costo computacional y error de aproximación.
- A veces los resultados no son tan *elegantes* como en Álgebra o Análisis. Esto se debe a que estamos más cerca del mundo real y más lejos del mundo ideal en el que se desarrollan estas teorías.
- Tendremos en cuenta la eficiencia a través de la *economía* de cálculo. Si bien un cálculo puede tardar 10 milisegundos en realizarse, hay que tener en cuenta que dicho cálculo puede formar parte de un proyecto más grande, donde ese cálculo deba repetirse 10^4 o 10^6 veces, o incluso más.
- Utilizaremos para la implementación y verificación experimental el MATLAB/OCTAVE. Algunas de las cosas que programaremos ya están implementadas. Igualmente implementaremos una versión propia porque estamos aprendiendo los fundamentos y esto ayuda a comprender, y porque puede suceder que en alguna situación necesitemos implementar algún algoritmo en otro lenguaje, por ejemplo dentro de algún proyecto mayor.

Índice general

1 Una breve introducción a matlab/octave **6**
- 1.1 Manipulación de matrices. . . . 8
- 1.2 Gráficos en el plano. . . . 10
- 1.3 Resolviendo sistemas lineales 13
- 1.4 Creación de archivos de extensión .m. . . . 14
- 1.5 Sentencias de control. . . . 14

2 Métodos directos para sistemas lineales **16**
- 2.1 Breve repaso de Álgebra Lineal 16
- 2.2 Matrices triangulares inferiores 18
- 2.3 Matrices triangulares superiores 21
- 2.4 Matrices llenas. Método de Gauss 22
- 2.5 Factorización LU 24
- 2.6 Problemas con la factorización LU. Pivoteo 26
- 2.7 Factorización de Cholesky. Matrices sdp 30
  - 2.7.1 Matrices simétricas y definidas positivas (sdp) 30

3 Factorización QR **36**
- 3.1 Mínimos cuadrados 36
- 3.2 Matrices ortogonales 37
- 3.3 Ortogonalización de Gram-Schmidt 39
- 3.4 Matrices de Householder 40
- 3.5 Conteo de operaciones y estabilidad 46
- 3.6 Rotaciones de Givens 48
- 3.7 Problemas 50

4 Métodos iterativos estacionarios para sistemas lineales **52**
- 4.1 Normas de vectores y matrices. Número de condición 53
  - 4.1.1 Normas de vectores 53
  - 4.1.2 Normas de matrices 55
  - 4.1.3 Número de condición y error relativo 56
  - 4.1.4 Número de condición para matrices rectangulares 58
  - 4.1.5 Espectro y radio espectral 60
- 4.2 Métodos iterativos estacionarios 64
  - 4.2.1 Convergencia del método de Jacobi 67
  - 4.2.2 Convergencia del método de Gauss-Seidel 69

4.2.3 Convergencia del método SOR . . . 70
4.2.4 Convergencia del método de Richardson . . . 71
4.3 Problemas . . . 74

5 Métodos de descenso para sistemas lineales 77
5.1 Sistemas sdp y minimización de un funcional . . . 77
5.2 Método del descenso más pronunciado (Steepest descent) . . . 79
5.3 Método del gradiente conjugado . . . 82
5.4 Cotas de error para el método del gradiente conjugado . . . 85
5.4.1 El método del gradiente conjugado como método directo . . . 90
5.5 Implementación del método del gradiente conjugado . . . 91
5.6 Precondicionamiento de un sistema y método del GC precondicionado . . . 97
5.6.1 Gradiente conjugado precondicionado (GCP) . . . 97
5.6.2 Precondicionadores genéricos . . . 103
5.7 Un precondicionador basado en la estructura: multigrid en 1D . . . 105
5.7.1 El problema modelo: de dónde sale la matriz . . . 105
5.7.2 La propiedad de suavizado . . . 108
5.7.3 La idea de la corrección en malla gruesa . . . 109
5.7.4 Operadores de transferencia entre mallas . . . 111
5.7.5 El esquema de dos mallas y el ciclo en V . . . 113
5.7.6 Implementación . . . 114
5.7.7 Multigrid como precondicionador del gradiente conjugado . . . 116
5.8 Gradiente conjugado para problemas no simétricos . . . 118
5.9 GMRes . . . 119
5.9.1 La propiedad de minimización y sus consecuencias . . . 119
5.9.2 Un resultado de convergencia para GMRes . . . 121
5.9.3 Precondicionamiento para GMRes . . . 122
5.9.4 Implementación de GMRes . . . 123
5.9.5 Implementación con rotaciones de Givens . . . 128
5.10 Problemas . . . 131

6 Sistemas de ecuaciones no lineales 137
6.1 Métodos de punto fijo . . . 138
6.2 El método de Newton . . . 143
6.2.1 Convergencia global del método de Newton . . . 147
6.3 Problemas . . . 151

7 Métodos numéricos para problemas de autovalores 154
7.1 Repaso de definiciones y propiedades elementales . . . 154
7.2 El método de las potencias . . . 158
7.3 Método de las potencias inversas . . . 163
7.4 Algoritmo QR . . . 165
7.5 Problemas . . . 174

8 Problemas a valores iniciales **178**
8.1 Existencia, unicidad y estabilidad de soluciones . . . 179
8.2 Métodos numéricos de un paso . . . 185
8.2.1 Introducción. Método de Euler . . . 185
8.2.2 Análisis para métodos de un paso . . . 188
8.2.3 Métodos de Runge-Kutta . . . 190
8.2.4 Métodos de Runge-Kutta-Fehlberg (RKF) . . . 192
8.3 Estabilidad de métodos numéricos . . . 194
8.3.1 Región de estabilidad para los métodos de Runge-Kutta . . . 195
8.3.2 Método Retro-Euler o Euler implícito . . . 197
8.4 Métodos multipaso . . . 197
8.4.1 Métodos multipaso de Adams . . . 198
8.4.2 Midpoint . . . 200
8.5 Análisis de métodos multipaso . . . 200
8.5.1 Convergencia y orden de métodos multipaso . . . 202
8.5.2 Criterios para la convergencia de métodos multipaso . . . 205
8.5.3 Estabilidad para métodos multipaso . . . 209
8.6 Un método predictor-corrector . . . 213
8.7 Fórmulas de diferenciación hacia atrás (BDF) . . . 214
8.8 Problemas . . . 215

9 Problemas a valores de borde **219**
9.1 Problemas a valores en los extremos . . . 219
9.2 Método de shooting o de disparo . . . 220
9.3 Diferencias finitas para problemas a valores en los extremos . . . 221
9.3.1 Estabilidad . . . 223
9.3.2 Análisis del error . . . 224
9.3.3 Condición de borde para la derivada . . . 225
9.4 Diferencias finitas en dos dimensiones . . . 226
9.5 Elementos finitos para problemas a valores de borde . . . 228
9.5.1 Formulación débil . . . 228
9.5.2 Aproximación de Galerkin . . . 229
9.5.3 Elementos finitos . . . 231
9.5.4 Análisis del error . . . 234
9.6 Problemas . . . 235

10 Problemas a valores iniciales y de borde. Ecuaciones parabólicas lineales **238**
10.1 Diferencias finitas para la ecuación del calor unidimensional . . . 239
10.1.1 Euler explícito . . . 240
10.1.2 Euler implícito . . . 244
10.1.3 Método del trapecio. Crank-Nicolson . . . 248
10.2 Diferencias finitas para la ecuación del calor bidimensional . . . 252

Capítulo 1

Una breve introducción a matlab/octave

MATLAB es el nombre abreviado de *MATrix LABoratory*. Este es un paquete poderoso e interactivo, diseñado como herramienta importante para manejar problemas de una amplia variedad que requieren de cálculos matriciales. OCTAVE es un software libre, diseñado con la misma estructura que MATLAB/OCTAVE, y todo lo que haremos en este curso puede hacerse con cualquiera de estos dos softwares.

MATLAB/OCTAVE tiene muchos atractivos, entre ellos la capacidad de realizar gráficos de dos y tres dimensiones y el tener un lenguaje de programación propio en el que el usuario puede crear sus propios archivos y funciones. De modo similar, Octave es un software de código abierto y gratuito con utilidades e interfaz comparables a MATLAB. La guía desarrollada en este capítulo, se plantea como base para estos Software, sin distinción.

MATLAB/OCTAVE dispone de un completo help con el que se puede encontrar la información que se desee, y puede disponerse desde la línea de comandos o a través de la ventana HELP.

Algunas consideraciones importantes acerca de MATLAB/OCTAVE:

- Distingue mayúsculas y minúsculas, es decir, a y A son variables distintas.
- El ";" al final de una instrucción evita que el resultado se muestre por pantalla.
- Con las flechas $\uparrow$ y $\downarrow$ se pueden buscar comandos anteriores y con $\leftarrow$ y $\rightarrow$ se puede mover sobre la línea de comando.
- Se considera *comentario* todo lo que se escribe desde el "carácter por ciento"(%) hasta el final de la línea.
- Todos los programas en MATLAB/OCTAVE son archivos de extensión **.m** que deben encontrarse en el directorio activo, como se puede observar en la barra de herramientas, en *Current Folder* (o *Current Directory* dependiendo de la versión de MATLAB/OCTAVE). Para ejecutar un archivo .m es necesario que éste se encuentre en el directorio activo.

  Sugerimos, para mejor organización, crear una carpeta propia de trabajo, por ejemplo de nombre `matematica`, en donde puedas ir guardando tus archivos y programas.

Después de haber creado esta carpeta, desde MATLAB/OCTAVE busca tu carpeta haciendo clic en el botón que tiene $\cdots$ a la derecha del directorio activo y lo aceptas como directorio activo de trabajo.

Las operaciones aritméticas más simples, se escriben como en una calculadora. En la siguiente tabla se muestran algunas sintaxis de las mismas (pensando en a y b números reales):

En MATLAB/OCTAVE	significa:
`a*b`	$\mathtt{a}\,\mathtt{b}$
`a/b`	$\frac{\mathtt{a}}{\mathtt{b}}$
`a^b`	$\mathtt{a}^{\mathtt{b}}$

La prioridad de las operaciones en MATLAB/OCTAVE es la usual. Primero se realizan las potencias, luego las multiplicaciones y divisiones y finalmente las sumas y restas. Por ejemplo:

- `a*b+c/d` es lo mismo que `(a*b)+(c/d)`
- `a^2*b` es lo mismo que `(a^2)*b`
- Si queremos calcular $\mathtt{a}^{2\mathtt{b}}$ debemos usar *paréntesis*: `a^(2*b)`

Las multiplicaciones y divisiones tienen la misma prioridad, lo mismo ocurre con las sumas y restas. Cuando quedan por resolver operaciones con la misma prioridad, MATLAB/OCTAVE las resuelve de izquierda a derecha. Así,

- `a/b*c` es lo mismo que $\frac{\mathtt{a}}{\mathtt{b}}\mathtt{c}$
- Si queremos calcular $\frac{\mathtt{a}}{\mathtt{bc}}$ debemos escribir `a/(b*c)` o también puede ser `a/b/c`

En lenguaje matemático escrito, se suelen utilizar paréntesis ( ), corchetes [ ] y llaves { } para indicar distintos niveles de prioridad dentro de una expresión complicada. En MATLAB/OCTAVE se usan sólo paréntesis a estos efectos. Los corchetes y las llaves tienen otro uso que ya veremos. Por ejemplo:

- Para calcular $\left\{2\left[(3+2)*\mathtt{a}+\frac{\mathtt{b}}{\mathtt{cd}}\right]\right\}^5$ escribimos `(2*((3+2)*a+b/(c*d)))^5` .

Ejercicio 1 (Haciendo cálculos)**.** Investiga las funciones **sqrt**, **log**, **exp**, **sin**, **cos**, **abs**. Puedes practicar con ejemplos.

Realiza las siguientes operaciones con MATLAB/OCTAVE y verifica la respuesta:

a) $\left\{\frac{15}{4}-\left(1-\frac{2}{9}\right)\sqrt{\frac{81}{16}}\right\}^3$ Rta: 8

b) $\dfrac{-3+2^{-5}4}{\sqrt[3]{0.88-7/8}}$ Rta: -16.8131019947240

c) $\ln^2(\text{sen}(\pi/4)) - 2e^{1-3\pi}$ Rta: 0.1197

MATLAB/OCTAVE almacena todos los resultados en la variable `ans` (por *answer*), a menos que asignemos el resultado a otra variable.

Al igual que en un lenguaje de programación, el signo = representa asignación. Por lo tanto a la izquierda del mismo debe ir el nombre de una variable (sin símbolos) a la que se le asignará el resultado de la operación que está a la derecha.

Ejercicio 2. Experimentar qué sucede con las siguientes instrucciones:

```
>> a = 5*8
>> a = a + 5
>> a = 2 * a
>> a = a + 10;
>> a
```

1.1 Manipulación de matrices.

Ejercicio 3 (Sobre Vectores y matrices)**.**

Analiza qué devuelve MATLAB/OCTAVE después de escribir textualmente cada instrucción (si en un item aparecen varias instrucciones, realízala de a una):

a) `A=[1 2 3; 4 5 6; 7 8 9; 10 11 12]`

b) `u=[-8:5]` , `v=[-8:1.5:5]` y `w=linspace(-8,5,10)`

c) `length(v)` y `size(A)`

d) `w(3)` y `A(2,3)`

e) `A(3,:)` y `A(:,3)`

f) `A([2 4],:)`

g) `A([2:4],:)`

h) `A([1 4],[2 3])`

i) `A(2,:)=-4*A(1,:) + A(2,:)`

j) `A(:,[1 3])=A(:,[3 1])`

k) `A(2,:)=[]`

l) `u=u'` y `u=u(end:-1:1)`

m) `b= v([2,5,9])`

n) `C=[A  b']` y `C=[A; b]`

Ejercicio 4 (Matrices especiales)**.**

El objetivo de este ejercicio es conocer ciertas funciones de MATLAB/OCTAVE que permiten fácilmente la creación de matrices con características especiales con las que es posible hacer experimentos.

a) Investiga las funciones **rand**, **zeros**, **ones**, **eye**, **diag**, **triu**, **tril**. Puedes practicar con ejemplos.

b) Introduce las matrices que se indican, utilizando las funciones del item a:

- Un vector u fila de 6 elementos aleatorios enteros entre -8 y 8.
- Un vector v columna de 6 elementos todos iguales a 2.
- Una matriz A de 4×6 con elementos aleatorios enteros entre 0 y 10.
- Una matriz B de 4×6 con elementos aleatorios entre -10 y 10.
- Una matriz C de 6×6 aleatoria triangular superior o inferior.
- Una matriz D diagonal de orden 6 que tenga el vector u como diagonal.
- Una matriz E de 6×6 con elementos aleatorios enteros.
- Una matriz F de 6×8 con elementos aleatorios enteros entre -7 y 5.
- La matriz identidad I de orden 6.
- La matriz nula Z de orden 4×6.

Cuando se utilizan las operaciones aritméticas `+` `-` `*` entre matrices (y/o vectores), debe tenerse en cuenta la compatibilidad para que estas operaciones tengan sentido.

En MATLAB/OCTAVE es posible sumar (restar) dos variables donde, una de ellas es una matriz y la otra un escalar. El resultado de tal operación es otra matriz que se obtiene sumándole (restándole) a cada elemento de la matriz inicial, el escalar dado.

Operaciones tales como `.*` `./` `.^` corresponden a la multiplicación, división y potenciación, respectivamente, elemento a elemento, siempre que las dimensiones de las matrices intervinientes así lo permitan. De esta manera,

1. `A.*B` da como resultado una matriz `C` cuyos elementos son $C_{ij} = A_{ij} \cdot B_{ij}$; mientras que `A*B` es el producto matricial usual entre matrices. Luego, éste podrá realizarse si las dimensiones de las matrices intervinientes así lo permiten.

2. `A./B` da como resultado una matriz `D` cuyos elementos son $D_{ij} = A_{ij}/B_{ij}$ y

3. `A.^n` resulta ser otra matriz cuyos elementos son (A_{ij}^n).

Ejercicio 5 (Operaciones con matrices)**.** Realiza las siguientes operaciones con las matrices definidas en el ejercicio anterior y analiza los resultados o mensajes de error que MATLAB/OCTAVE pudiese devolver.

i) $A + F, \quad A + B \quad$ y $\quad B + A$

ii) $A + Z, \quad Z + A \quad$ y $\quad AZ$

iii) $-3A + 3B$ y $3(B - A)$

iv) $(A + B)F$ y $AF + BF$

v) CE y EC

vi) IE y EI

vii) `v*u` , `u*v` , `u*v'` , `u.*v'` , `u./v'` , `u.^(v')` y `3.^v`

viii) D^3, A^2 y `A.^2`

ix) `F + 2` , `F/2` , `F./2` , `2/F` y `2./F`

x) $(C + E)^2$ y $C^2 + 2CE + E^2$

xi) `log(A)` , `exp(C)` , `sqrt(B)` y `cos(Z)`

xii) `inv(C)` , `inv(E)` , `det(C)` y `det(E)` .

1.2 Gráficos en el plano.

La instrucción `plot` permite dibujar en la pantalla de la PC. Si x e y son vectores de la misma longitud, la orden `plot(x,y)` define atributos de la pantalla gráfica y realiza un gráfico plano de los elementos de x contra los elementos de y. Es decir, si $x = (x_1, x_2, ..., x_n)$ e $y = (y_1, y_2, ..., y_n)$, la orden mencionada da como resultado el gráfico que se obtiene uniendo los puntos (x_i, y_i) consecutivamente. Para realizar el dibujo, la función `plot` establece un sistema de coordenadas con escalas adaptadas en forma automática a los datos que se desean representar. Es posible mediante otras funciones y comandos, modificar el aspecto del dibujo.

Así, si queremos realizar el gráfico de una función $y = f(x)$ para x en un intervalo $[a, b]$, se deben generar los dos vectores x e y necesarios para `plot`. El primero corresponde a las abscisas de los puntos a graficar, y son valores comprendidos entre a y b.

Para dibujar la gráfica de una función f sobre el intervalo $[a, b]$ puedes seguir los siguientes pasos:

```
>> x= a:.1:b; % x es un vector con componentes x(i) equiespaciadas por 0.1 entre a y b
>> y= f(x); % y es un vector cuyas componentes y(i) son los valores f(x(i))
>> plot(x,y) % grafica en el plano y une con segmentos de recta los puntos (x(i),y(i))
```

Ejercicio 6 (Realizando gráficos en el plano)**.**

Realiza los siguientes gráficos:

a) La función seno en el intervalo $[0, 2\pi]$.

b) La función $f(x) = x^2$ en el intervalo $[-1, 1]$.

c) La curva dada por $\begin{cases} x = \cos t \\ y = \sin t \end{cases}$, $t \in [0, 2\pi]$.

Para esto puedes definir el vector `t=0:0.01:2*pi` , luego `x=cos(t)` e `y=sin(t)`

Finalmente escribir `plot(x,y)` .

d) La curva dada por $\begin{cases} x = t\cos t \\ y = t\sin t \end{cases}$, $t \in [0, 6\pi]$.

e) La curva dada por $\begin{cases} x = e^t\cos t \\ y = e^t\sin t \end{cases}$, $t \in [0, 4\pi]$.

f) La curva dada por $\begin{cases} x = \cos t \\ y = \sin t \\ z = t \end{cases}$, $t \in [0, 6\pi]$. (Usar `plot3`)

Ejercicio 7 (Otros comandos asociados a los gráficos)**.**

Ejecuta la siguiente secuencia para dibujar dos funciones en un mismo gráfico:

```
>> x=0:.1:3;
>> y1=x+1;
>> plot(x,y1) % Dibuja y1
>> hold on
>> y2=x.^2;
>> plot(x,y2,'r'); % Dibuja y2 con rojo
>> grid % Realiza un cuadriculado sobre el grafico actual
>> hold off
```

El comando hold on congela el gráfico actual de modo que los siguientes gráficos se superponen en éste. El comando hold off descongela el gráfico actual de manera que el siguiente gráfico se realizará en una nueva grilla y el anterior desaparecerá. El comando grid coloca o quita el cuadriculado sobre el gráfico actual.

El caracter "r" en la segunda ejecución de **plot**, hace que el gráfico se realice con color rojo. En la siguiente tabla están algunas de las opciones para los gráficos:

Colores	Tipo de línea
b azul	. punto
g verde	o círculo
r rojo	x cruz
c celeste	+ más
m magenta	* estrella
y amarillo	s cuadrado
k negro	d diamante
	- línea llena
	: línea de puntos
	-. punto y trazo
	– línea de trazos

Tipeando "help plot" puedes obtener más información sobre esta orden.

Otro modo de realizar gráficos superpuestos es el siguiente:

```
>> x=0:.1:3;
>> y1=x+1;
>> y2=x.^2;
>> plot(x,y1,'g.',x,y2,'r'); % Dibuja y1 punteada en verde e y2
% en linea continua roja
>> grid % Realiza un cuadriculado sobre el grafico actual
```

A continuación tipea y analiza la siguiente secuencia:

```
>> title('Recta y parabola'); % Coloca un titulo en el grafico
>> xlabel('x'); % Escribe "x" en el eje horizontal
>> ylabel('y1 e y2'); % Escribe "y1 e y2" en el eje vertical
>> text(2,3,'y1=x+1'); % Escribe "y1=x+1" en el punto (2,3)
>> gtext('y2=x^2');  % Escribe "y2=x^2" en un lugar elegido con el mouse
```

Con el mouse posiciónate en un punto cerca de la parábola y haciendo clic el texto $y2 = x^2$ aparecerá en el gráfico.

El comando axis(c), donde $c = [X_{\min}, X_{\max}, Y_{\min}, Y_{\max}]$, escala los ejes de manera que el gráfico aparece en el rectángulo $[X_{\min}, X_{\max}] \times [Y_{\min}, Y_{\max}]$.

Ejercicio 8. Graficar los siguientes pares de funciones sobre el intervalo $[0, 1]$:

a) $f(x) = \operatorname{sen}(\pi x)$, $g(x) = \operatorname{sen}(2\pi x)$

b) $f(x) = \cos(\pi x)$, $g(x) = \cos(3\pi x)$

c) $f(x) = \operatorname{sen}^2(4\pi x)$, $g(x) = \cos(8\pi x)$

d) $f(x) = \operatorname{sen}^2(4\pi x)$, $g(x) = \frac{1}{2} - \frac{1}{2}\cos(8\pi x)$

e) $f(x) = \left(\dfrac{1 - \frac{x}{24}}{1 + \frac{x}{24} + \frac{x^2}{384}}\right)^8$, $\qquad g(x) = e^{-x}$

Ejercicio 9. Graficar los siguientes pares de funciones sobre el intervalo $[-\pi, \pi]$:

a) $f(x) = \operatorname{sen}(x)$, $g(x) = x$

b) $f(x) = \operatorname{sen}(x)$, $g(x) = x - \dfrac{x^3}{3!}$

c) $f(x) = \operatorname{sen}(x)$, $g(x) = x - \dfrac{x^3}{3!} + \dfrac{x^5}{5!}$

d) $f(x) = \operatorname{sen}(x)$, $g(x) = x - \dfrac{x^3}{3!} + \dfrac{x^5}{5!} - \dfrac{x^7}{7!}$

Ejercicio 10. Repetir el ejercicio anterior sobre el intervalo $[-2\pi, 2\pi]$.

1.3 Resolviendo sistemas lineales

Si queremos resolver el sistema lineal

$$\begin{aligned} 3x + 5y - z &= 8 \\ x - 6y + z &= 4 \\ x + z &= 2 \end{aligned}$$

lo primero que debemos hacer es *escribirlo en forma matricial*. En este caso, la forma matricial es:

$$\begin{bmatrix} 3 & 5 & -1 \\ 1 & -6 & 1 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 8 \\ 4 \\ 2 \end{bmatrix}$$

Para resolverlo, escribimos las siguientes líneas en MATLAB/OCTAVE

```
>> A = [ 3  5  -1 ; 1  -6  1 ;  1  0  1 ]
>> b = [ 8  4  2 ]'
>> x = A\b
```

El resultado de la resolución del sistema se almacenó en el vector `x`.

En MATLAB/OCTAVE, la *barra invertida* `\` se utiliza para resolver sistemas lineales. Desde el punto de vista matemático, `A\b` es equivalente a $\texttt{A}^{-1}b$, que en MATLAB/OCTAVE también podría hacerse escribiendo `inv(A)*b` . Sin embargo, calcular la inversa de `A` y luego multiplicarla por `b` requiere de muchas más operaciones que resolver el sistema lineal $\texttt{A}\texttt{x} = b$.

Ejercicio 11. Escribir en forma matricial y resolver los siguientes sistemas lineales

a)

$$\begin{aligned} x_1 + x_2 + x_3 + x_4 &= 1 \\ x_1 + 2x_2 + 4x_3 + 8x_4 &= 0 \\ x_1 + 3x_2 + 9x_3 + 27x_4 &= 2 \\ x_1 + 4x_2 + 16x_3 + 64x_4 &= -1 \end{aligned}$$

b) Considerar N = 10 (averiguar el uso de la función `diag` de MATLAB/OCTAVE)

$$\begin{cases} U_1 = 0, & \\ -U_{i-1} + 2U_i - U_{i+1} = 1/N^2, & i = 2, 3, \ldots, N-1, \\ U_N = 0. & \end{cases}$$

Graficar la solución.

c) Considerar N = 100

$$\begin{cases} U_1 = 0, & \\ -U_{i-1} + 2U_i - U_{i+1} = 1/N^2, & i = 2, 3, \ldots, N-1, \\ U_N = 0. & \end{cases}$$

Graficar la solución.

1.4 Creación de archivos de extensión .m.

Un script es una secuencia de comandos que deseamos ejecutar a menudo y que por lo tanto nos gustaría no tener que escribirla cada vez que tenemos que usarla. Para esto podemos guardar la lista de comandos en un archivo de extensión .m y así poder ejecutarla tantas veces como queramos con solamente escribir el nombre del archivo en el prompt de MATLAB/OCTAVE.

La mayoría de las funciones de MATLAB/OCTAVE están en realidad en archivos .m, y se pueden visualizar escribiendo *type xx*, donde *xx* es el nombre de la función. (ej: `type house`).

Para elaborar sus propios scripts o funciones, deberán generar un nuevo archivo de texto con el nombre que ustedes quieran, siempre y cuando termine en .m, para que MATLAB/OCTAVE lo reconozca. Este tipo de archivos se pueden crear, editar y guardar con el mismo MATLAB/OCTAVE o con cualquier editor de textos (ej: *Bloc de notas*).

Para que un archivo .m sea una función, tiene que empezar por la palabra `function` seguida de las variables de salida entre corchetes, luego el símbolo =, el nombre de la función y las variables de entrada entre paréntesis.

Ejemplo: (suma de los primeros n números)

```
function [s]= suma(n)
% function [s] = suma(n)
% suma los primeros números naturales hasta n

   % inicializamos s en cero
   s=0;
   % recorremos los numeros de 1 a n
   for i=1:n,
      % sumamos i a s
      s=s+i;
   end
end
```

Guardar los comandos que aparecen arriba en un archivo de texto llamado *suma.m*. Notar que colocamos el mismo nombre a la función que al archivo. Para usar la función, escribimos

```
>> suma(10)
```

1.5 Sentencias de control.

MATLAB/OCTAVE posee las sentencias de control usuales: *if, for, while* cuya sintaxis puede estudiarse mediante la función *help* o bien en algún manual disponible.

Ejercicio 12 (Sentencias *if, for, while*)**.**

a) Escribir la función `fact` para calcular el factorial de un número:

```
function f = fact(n)
% function f = fact(n)
% Calcula el factorial de la parte entera de n
% Devuelve cero si n < 0

if (n < 0)
   f = 0;
else
   f = 1;
   for i=2:n
      f = f * i;
   end
end
```

Verificar su funcionamiento con algunos ejemplos.

b) Escribir la función `comb` para calcular el número combinatorio $C(n,k)$ dado por

$$C(n,k) = \frac{n!}{k!(n-k)!},$$

(este número se conoce también como coeficiente binomial). La función comienza así:

```
function c = comb(n,k)
% function c = comb(n,k)
% Calcula el numero combinatorio  n! / (k! (n-k)!)

...
```

c) Considere la sucesión numérica dada por

$$x_{n+1} = \frac{1}{2}\left(x_n + \frac{2}{x_n}\right), \qquad n \geq 0, x_0 = 1.$$

Determine el límite de la misma, con un error no mayor que 10^{-8}. Para ello, considere como estimación del error en el paso n-ésimo, a la diferencia entre x_{n+1} y x_n.

Capítulo 2

Métodos directos para sistemas lineales

Para determinar un spline cúbico interpolante se debe resolver un sistema lineal cuya matriz es tridiagonal. En general es de gran tamaño. En problemas de optimización y en discretizaciones de ecuaciones diferenciales surge la necesidad de resolver sistemas lineales. En particular con matrices de gran tamaño y ralas (sparse), o sea, con pocas (relativamente) entradas no nulas.

Dada $A \in \mathbb{R}^{n\times n}$ no-singular y $b \in \mathbb{R}^n$, queremos hallar $x \in \mathbb{R}^n$ tal que $Ax = b$.

Los métodos de resolución de sistemas lineales se clasifican en directos e iterativos.

Directos: Son aquellos que llegan a la solución en un número finito de pasos (en ausencia de errores de redondeo), el ejemplo más conocido es el método de eliminación de Gauss. En general se utilizan para sistemas no muy grandes.

Iterativos: Estos métodos generan una sucesión $\{x_k\}_{k\in\mathbb{N}} \subset \mathbb{R}^n$ tal que x_k converge a la solución x del sistema $Ax = b$. Algunos ejemplos son el método de Jacobi, Gauss-Seidel, SOR (Sobrerrelajación sucesiva), Método del descenso más pronunciado, Gradiente conjugado. Se utilizan para sistemas muy grandes, donde una tolerancia deseada puede lograrse con pocas iteraciones, que resultan en un costo (mucho) menor al de resolver el sistema por un método directo.

2.1 Breve repaso de Álgebra Lineal

Algunas observaciones elementales.

Durante este curso, los vectores serán columna. De este modo, si $x, y \in \mathbb{R}^n$, entonces

- Producto escalar: $x \cdot y = x^T y \in \mathbb{R}$.
- Producto *tensorial*: $x \otimes y = x\, y^T$ es una matriz de $n \times n$ de rango uno, con

$$\text{fila}_i(xy^T) = x_i\, y^T \qquad \text{col}_j(xy^T) = x\, y_j = y_j\, x.$$

Si $A \in \mathbb{R}^{n\times m}$ y $B \in \mathbb{R}^{m\times p}$ entonces $AB \in \mathbb{R}^{n\times p}$ y

- $(AB)_{ij} = \text{fila}_i(A)\,\text{col}_j(B)$;
- $\text{fila}_i(AB) = \text{fila}_i(A)B$;
- $\text{col}_j(AB) = A\,\text{col}_j(B)$.

Si $A \in \mathbb{R}^{n\times m}$ y $x \in \mathbb{R}^m$, entonces $Ax \in \mathbb{R}^n$ y Ax es una combinación lineal de las columnas de A,

$$Ax = x_1\,\text{col}_1(A) + x_2\,\text{col}_2(A) + \cdots + x_m\,\text{col}_m(A),$$

es decir $Ax \in \text{col}(A)$, el *espacio columna* de A.

Si $A \in \mathbb{R}^{n\times m}$ y $x \in \mathbb{R}^n$, entonces $x^TA \in \mathbb{R}^{1\times m}$, es un vector fila de m componentes, y es además una combinación lineal de las filas de A:

$$x^TA = x_1\,\text{fila}_1(A) + x_2\,\text{fila}_2(A) + \cdots + x_n\,\text{fila}_n(A).$$

Si $A \in \mathbb{R}^{n\times m}$ y e_i es el vector de m componentes que cumple $(e_i)_j = \delta_{ij}$, entonces

$$Ae_i = \text{col}_i(A).$$

Si $A \in \mathbb{R}^{n\times m}$ y e_i es el vector de n componentes que cumple $(e_i)_j = \delta_{ij}$, entonces

$$e_i^TA = \text{fila}_i(A).$$

Sistemas lineales de $n \times n$.

Si

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} \qquad \text{y} \qquad b = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

entonces es lo mismo escribir

$$Ax = b \qquad \text{que escribir} \qquad \begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= b_n \end{aligned}$$

En MATLAB/OCTAVE se resuelve con `x=A\b`.

Sabemos de Álgebra Lineal que las siguientes afirmaciones son equivalentes para una matriz dada $A \in \mathbb{R}^{n\times n}$:

(1) Para todo $b \in \mathbb{R}^n$, existe $x \in \mathbb{R}^n$ tal que $Ax = b$.

(2) Si $b \in \mathbb{R}^n$ y existe $x \in \mathbb{R}^n$ tal que $Ax = b$, entonces tal x es único.

(3) Si $Ax = 0$ entonces $x = 0$.

(4) Las columnas de A son linealmente independientes.

(5) Las filas de A son linealmente independientes.

(6) Existe $A^{-1} \in \mathbb{R}^{n\times n}$ tal que $A\,A^{-1} = A^{-1}\,A = I$.

(7) $\det(A) \neq 0$.

Observación 2.1. Si $A \in \mathbb{R}^{30\times 30}$ y $\det(A) = 1$, entonces

$$\det(0.1\,A) = (0.1)^{30}\det(A) = 10^{-30}\det(A) = 10^{-30}.$$

Este ejemplo nos muestra que el determinante pequeño no indica si una matriz es *casi singular*. El *número de condición* da información de este tipo, y lo veremos más adelante.

2.2 Matrices triangulares inferiores

Definición 2.2. Se dice que una matriz $L \in \mathbb{R}^{n\times n}$ es *triangular inferior* si $\ell_{ij} = 0$ siempre que $i < j$. Se dice que una matriz $L \in \mathbb{R}^{n\times n}$ es triangular inferior *unitaria* si es triangular inferior y además $\ell_{ii} = 1$, $i = 1, 2, \ldots, n$. Esquemáticamente, una matriz triangular inferior luce de la siguiente forma

$$L = \begin{bmatrix} \ell_{11} & 0 & 0 & 0 & \ldots & 0 \\ \ell_{21} & \ell_{22} & 0 & 0 & \ldots & 0 \\ \ell_{31} & \ell_{32} & \ell_{33} & 0 & \ldots & 0 \\ \vdots & \vdots & \vdots & \ddots & \ddots & \vdots \\ \vdots & \vdots & \vdots & & \ddots & 0 \\ \ell_{n1} & \ell_{n2} & \ell_{n3} & \ell_{n4} & \ldots & \ell_{nn} \end{bmatrix}$$

y en la triangular inferior unitaria todas las entradas de la diagonal son unos.

Si L es triangular inferior y quiero resolver el sistema $Lx = b$, observamos que $\det(L) = \ell_{11}\ell_{22}\ldots\ell_{nn} \neq 0$ si y solo si $\ell_{ii} \neq 0$ para todo $i = 1, 2, \ldots, n$. Por lo tanto, el sistema tendrá solución única si todos los elementos de la diagonal son no nulos. Para resolverlo observamos cómo luce:

$$\begin{aligned} \ell_{11}x_1 &= b_1 \\ \ell_{21}x_1 + \ell_{22}x_2 &= b_2 \\ \ell_{31}x_1 + \ell_{32}x_2 + \ell_{33}x_3 &= b_3 \\ &\vdots \\ \ell_{n1}x_1 + \ell_{n2}x_2 + \cdots + \ell_{nn}x_n &= b_n. \end{aligned} \tag{2.1}$$

Claramente se ve que la solución de este sistema se puede obtener de la siguiente forma, respetando el orden de las operaciones:

$$\begin{aligned} x_1 &= b_1/\ell_{11} \\ x_2 &= (b_2 - \ell_{21}x_1)/\ell_{22} \\ x_3 &= (b_3 - \ell_{31}x_1 - \ell_{32}x_2)/\ell_{33} \\ &\vdots \\ x_n &= (b_n - \ell_{n1}x_1 - \ell_{n2}x_2 - \cdots - \ell_{n(n-1)}x_{n-1})/\ell_{nn}. \end{aligned}$$

Este procedimiento se conoce como *sustitución hacia adelante* (forward substitution), y es muy simple de programar en MATLAB/OCTAVE.

Primera versión, como se haría en un lenguaje tipo `C` o `Fortran`:

```
function x = triinf(L,b)
% function x = triinf(L,b)
% Resuelve el sistema  L x = b
% suponiendo  L  triangular inferior cuadrada
% con todos los elementos de la diagonal no nulos.
% Solo se utilizan las componentes L_ij con i >= j,
% el resto de la matriz se ignora.

n = length(b);
x = zeros(size(b));  % solo para reservar memoria
for i = 1:n
  x(i) = b(i);
  for j = 1:i-1
    x(i) = x(i) - L(i,j) * x(j);
  end
  x(i) = x(i) / L(i,i);
end
```

Segunda versión, un poquito mejorada

```
function x = triinf(L,b)
% function x = triinf(L,b)
% Resuelve el sistema  L x = b
% suponiendo  L  triangular inferior cuadrada
% con todos los elementos de la diagonal no nulos.
% Solo se utilizan las componentes L_ij con i >= j,
% el resto de la matriz se ignora.

n = length(b);
x = b;
for i = 1:n
  for j = 1:i-1
    x(i) = x(i) - L(i,j) * x(j);
  end
  x(i) = x(i) / L(i,i);
end
```

En MATLAB/OCTAVE conviene *vectorizar* las operaciones, evitando en lo posible el uso de *loops* o *ciclos*. La vectorización inmediata de esta función se obtiene de reemplazar el loop interno por un producto escalar, lo cual implica acceder a la matriz L por *filas*:

```
function x = triinf_filas(L,b)
% function x = triinf_filas(L,b)
% Resuelve el sistema  L x = b
```

```
% suponiendo  L  triangular inferior cuadrada
% con todos los elementos de la diagonal no nulos.
% Solo se utilizan las componentes L_ij con i >= j,
% el resto de la matriz se ignora.
%
% Se accede la matriz  L  por filas.

n = length(b);
x = b;
for i = 1:n
  x(i) = x(i) - L(i,1:i-1) * x(1:i-1);
  x(i) = x(i) / L(i,i);
end
```

Aunque no sea inmediato, este sistema también puede resolverse accediendo a la matriz L por *columnas*, observemos que se puede hacer lo siguiente, a partir de (2.1):

(1) Calcular $x_1 = b_1/\ell_{11}$.

(2) Restar $\ell_{i1}x_1$ a b_i, para $i = 2, \ldots, n$.

(3) Dividir $b_2 - \ell_{21}x_1$ (ya calculado) por ℓ_{22}, obteniendo x_2.

(4) Restar $\ell_{i2}x_2$ a b_i, para $i = 3, \ldots, n$.

(5) ...

Escribamos el código MATLAB/OCTAVE que resulta más claro

```
function x = triinf_cols(L,b)
% function x = triinf_cols(L,b)
% Resuelve el sistema  L x = b
% suponiendo  L  triangular inferior cuadrada
% con todos los elementos de la diagonal no nulos.
% Solo se utilizan las componentes L_ij con i >= j,
% el resto de la matriz se ignora.
%
% Se accede la matriz  L  por columnas.

n = length(b);
x = b;
x(1) = x(1) / L(1,1);
for i = 2:n
  x(i:n) = x(i:n) - x(i-1) * L(i:n,i-1);
  x(i) = x(i) / L(i,i);
end
```

Conteo de operaciones.

Para conocer la *complejidad* del algoritmo, y entender acerca del *costo computacional* hacemos un conteo de operaciones. Los tres algoritmos presentados realizan el mismo número de operaciones, las diferentes velocidades dependerán de cómo se almacenen las matrices en MATLAB/OCTAVE y qué modo de acceso sea más rápido. Contemos las operaciones de `triinf_cols`

Momento	multiplicaciones	sumas	divisiones
antes del for			1
primera iteración	$n-1$	$n-1$	1
segunda iteración	$n-2$	$n-2$	1
tercera iteración	$n-3$	$n-3$	1
$\vdots$	$\vdots$	$\vdots$	$\vdots$
última iteración	1	1	1
total	$(n-1)n/2$	$(n-1)n/2$	n

Por lo tanto el total de operaciones es $(n-1)n + n = n^2$.

Observación 2.3. Vale la pena hacer algunos comentarios a esta altura:

- Cualquiera de las tres versiones que implementamos es más lenta que escribir `L\b` en MATLAB/OCTAVE. Esto se debe a que las rutinas internas de MATLAB/OCTAVE están programadas y ya compiladas en lenguaje de máquina. En cambio `triinf` será *interpretado* por MATLAB/OCTAVE y traducido a medida que se ejecuta.
- Las versiones *vectorizadas* son más rápidas que las no vectorizadas.
- Para lenguajes de programación como Fortran, C, C++, Python, etc., existen rutinas optimizadas para las operaciones siguientes:

  saxpy : $z \leftarrow \alpha x + y$, con α escalar y x, y vectores.

  dot : $a \leftarrow x \cdot y$, con x, y vectores.

  Para vectores largos las rutinas reparten el trabajo en varios procesadores (paralelizan).

2.3 Matrices triangulares superiores

Definición 2.4. Se dice que una matriz $U \in \mathbb{R}^{n\times n}$ es *triangular superior* si $u_{ij} = 0$ siempre que $i > j$. Esquemáticamente, una matriz triangular superior luce de la siguiente forma

$$U = \begin{bmatrix} u_{11} & u_{12} & u_{13} & u_{14} & \dots & u_{1n} \\ 0 & u_{22} & u_{23} & u_{24} & \dots & u_{2n} \\ 0 & 0 & u_{33} & u_{34} & \dots & u_{3n} \\ \vdots & \vdots & 0 & \ddots & \ddots & \vdots \\ \vdots & \vdots & \vdots & & u_{(n-1)(n-1)} & u_{(n-1)n} \\ 0 & 0 & 0 & \dots & 0 & u_{nn} \end{bmatrix}.$$

La resolución de sistemas $U\,x = b$ con U triangular superior es análoga a sistemas triangulares inferiores, haciendo lo que se conoce como *sustitución hacia atrás* (backward substitution). También se puede implementar por filas o por columnas. Queda como ejercicio.

2.4 Matrices llenas. Método de Gauss

Consideremos el problema de resolver $A\,x = b$ con $A \in \mathbb{R}^{n\times n}$, $b \in \mathbb{R}^n$ dados, y A invertible. El método de eliminación de Gauss consiste en realizar operaciones elementales sobre la matriz A y el lado derecho b de manera que el sistema se transforme en un sistema triangular superior.

Método de Gauss.

Primer paso $[A = A^{(0)} \to A^{(1)},\ b = b^{(0)} \to b^{(1)}]$ Restar de las filas 2 a n un múltiplo de la fila 1, para obtener ceros debajo de a_{11}. Esto se logra de la siguiente manera:

$$
\begin{aligned}
&\text{fila}_1(A^{(1)}) = \text{fila}_1(A^{(0)}),\\
&\text{fila}_k(A^{(1)}) = \text{fila}_k(A^{(0)}) - \underbrace{\frac{a_{k1}^{(0)}}{a_{11}^{(0)}}}_{m_{k1}} \text{fila}_1(A^{(0)}), \qquad k = 2, 3, \ldots, n.\\
&\qquad b_1^{(1)} = b_1^{(0)},\\
&\qquad b_k^{(1)} = b_k^{(0)} - m_{k1}\, b_1^{(0)}, \qquad k = 2, 3, \ldots, n.
\end{aligned}
$$

Segundo paso $[A^{(1)} \to A^{(2)},\ b^{(1)} \to b^{(2)}]$: Restar de las filas 3 a n un múltiplo de la fila 2, para obtener ceros debajo de a_{22}. Esto se logra de la siguiente manera:

$$
\begin{aligned}
&\text{fila}_1(A^{(2)}) = \text{fila}_1(A^{(1)}),\\
&\text{fila}_2(A^{(2)}) = \text{fila}_2(A^{(1)}),\\
&\text{fila}_k(A^{(2)}) = \text{fila}_k(A^{(1)}) - \underbrace{\frac{a_{k2}^{(1)}}{a_{22}^{(1)}}}_{m_{k2}} \text{fila}_2(A^{(1)}), \qquad k = 3, \ldots, n.\\
&\qquad b_1^{(2)} = b_1^{(1)},\\
&\qquad b_2^{(2)} = b_2^{(1)},\\
&\qquad b_k^{(2)} = b_k^{(1)} - m_{k2}\, b_2^{(1)}, \qquad k = 3, \ldots, n.
\end{aligned}
$$

Paso j $(j \le n)$ $[A^{(j-1)} \to A^{(j)},\ b^{(j-1)} \to b^{(j)}]$: Restar de las filas $j+1$ a n un múltiplo

de la fila j, para obtener ceros debajo de a_{jj}. Esto se logra de la siguiente manera:

$$\begin{aligned}
\text{fila}_k(A^{(j)}) &= \text{fila}_k(A^{(j-1)}), && k = 1, \ldots, j,\\
\text{fila}_k(A^{(j)}) &= \text{fila}_k(A^{(j-1)}) - \underbrace{\frac{a_{kj}^{(j-1)}}{a_{jj}^{(j-1)}}}_{m_{kj}} \text{fila}_j(A^{(j-1)}), && k = j+1, \ldots, n.\\
b_k^{(j)} &= b_k^{(j-1)}, && k = 1, \ldots, j,\\
b_k^{(j)} &= b_k^{(j-1)} - m_{kj}\, b_j^{(j-1)}, && k = j+1, \ldots, n.
\end{aligned}$$

Al finalizar el paso $n-1$ obtenemos el sistema

$$A^{(n-1)}x = b^{(n-1)},$$

equivalente al original, con la ventaja que $A^{(n-1)} = U$ es triangular superior, y puede resolverse por sustitución hacia atrás.

Conteo de operaciones

Observemos que donde sabemos que el resultado será cero, no hacemos las operaciones, sino que directamente colocamos un cero. Denotaremos con d, m, r las divisiones, multiplicaciones y restas, respectivamente.

Paso	operaciones sobre A	operaciones sobre b	cuántas veces
1	$[1d + (n-1)m + (n-1)r]$	$(1m + 1r)$	$(n-1)$
j, $2 \le j \le n-1$	$[1d + (n-j)m + (n-j)r]$	$(1m + 1r)$	$(n-j)$

Total de operaciones para la *triangulación* sobre la matriz A:[1]

$$\begin{aligned}
\sum_{j=1}^{n-1}(1 + 2(n-j))(n-j) &= \sum_{k=1}^{n-1}(1+2k)k = \sum_{k=1}^{n-1} k + 2\sum_{k=1}^{n-1} k^2\\
&= \frac{(n-1)n}{2} + 2\frac{(n-1)n(2n-1)}{6} = \frac{2}{3}n^3 - \frac{1}{2}n^2 - \frac{1}{6}n \cong \frac{2}{3}n^3.
\end{aligned}$$

Total de operaciones al reducir a forma triangular, realizadas sobre el lado derecho b:

$$\sum_{j=1}^{n-1} 2(n-j) = 2\sum_{j=1}^{n-1} j = (n-1)n = n^2 - n.$$

Hasta aquí, el total de operaciones para reducir a forma triangular un sistema con el método de Gauss es

$$\frac{2}{3}n^3 - \frac{1}{2}n^2 - \frac{1}{6}n + n^2 - n = \frac{2}{3}n^3 + \frac{1}{2}n^2 - \frac{1}{6}n \cong \frac{2}{3}n^3.$$

Si sumamos el número de operaciones para la eliminación hacia atrás (n^2), obtenemos que para resolver un sistema con el método de Gauss, hacen falta

$$\frac{2}{3}n^3 + \frac{1}{2}n^2 - \frac{7}{6}n + n^2 = \frac{2}{3}n^3 + \frac{3}{2}n^2 - \frac{7}{6}n \cong \frac{2}{3}n^3 \quad \text{operaciones.}$$

[1] Estamos usando las fórmulas $\sum_{j=1}^{n} j = \frac{n(n+1)}{2}$ y $\sum_{j=1}^{n} j^2 = \frac{n(n+1)(2n+1)}{6} = \frac{n^3}{3} + \frac{n^2}{2} + \frac{n}{3}$.

2.5 Factorización LU

Recordando que $\text{fila}_i(GA) = \text{fila}_i(G)A$, observamos que

$$A^{(1)} = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ -m_{21} & 1 & 0 & \cdots & 0 \\ -m_{31} & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ -m_{n1} & 0 & \cdots & 0 & 1 \end{bmatrix} A^{(0)}.$$

Más precisamente, el primer paso de la eliminación de Gauss se escribe

$$\text{si } g_1 = \begin{bmatrix} 0 \\ m_{21} \\ \vdots \\ m_{n1} \end{bmatrix}, \quad \text{y } G^1 = I - g_1 e_1^T, \quad \text{entonces } A^{(1)} = G^1 A^{(0)} = G^1 A.$$

Análogamente, el segundo paso se escribe

$$A^{(2)} = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & -m_{32} & 1 & \cdots & 0 \\ \vdots & \vdots & 0 & \ddots & \vdots \\ 0 & -m_{n2} & 0 & \cdots & 1 \end{bmatrix} A^{(1)} = G^2 A^{(1)}, \quad \text{con } g_2 = \begin{bmatrix} 0 \\ 0 \\ m_{32} \\ \vdots \\ m_{n2} \end{bmatrix}, \quad \text{y } G^2 = I - g_2 e_2^T.$$

El j-ésimo paso resulta

$$A^{(j)} = G^j A^{(j-1)}, \quad \text{con } g_j = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ m_{(j+1)j} \\ \vdots \\ m_{nj} \end{bmatrix}, \quad \text{y } G^j = I - g_j e_j^T.$$

Las matrices $G^j = I - g_j e_j^T$ se llaman *matrices de Gauss*.
Es fácil verificar que $(G^j)^{-1} = (I - g_j e_j^T)^{-1} = I + g_j e_j^T$, y que

$$(G^1)^{-1}(G^2)^{-1} \dots (G^{n-1})^{-1} = I + \sum_{j=1}^{n-1} g_j e_j^T = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ m_{21} & 1 & 0 & \cdots & 0 \\ m_{31} & m_{32} & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ m_{n1} & m_{n2} & m_{n3} & \cdots & 1 \end{bmatrix} = L.$$

Conclusión:

El método de eliminación de Gauss produce (si $a_{jj}^{(j-1)} \neq 0$, $j = 1, 2, \dots, n-1$) una factorización $A = LU$ con U triangular superior, L triangular inferior unitaria, además $L_{ij} = m_{ij} = a_{ij}^{(j-1)} / a_{jj}^{(j-1)}$, es el *multiplicador* si $i > j$.

Observación 2.5. • Si $A = LU$, resolver $Ax = b$ se desglosa en la resolución de dos sistemas triangulares:

$$Ax = b \quad \Longrightarrow \quad L\underbrace{Ux}_{y} = b.$$

Resolvemos primero $Ly = b$ ($n^2 - n$ operaciones).

A continuación resolvemos $Ux = y$ (n^2 operaciones).

- Una vez obtenida la factorización ($\frac{2}{3}n^3 - \frac{1}{2}n^2 - \frac{1}{6}n$ operaciones), la resolución del sistema lleva

$$\frac{2}{3}n^3 - \frac{1}{2}n^2 - \frac{1}{6}n + 2n^2 - n = \frac{2}{3}n^3 + \frac{3}{2}n^2 - \frac{7}{6}n \quad \text{operaciones.}$$

Esto es exactamente lo mismo que resolver por el método de Gauss, y no debería sorprendernos.

- Observemos además, que el vector y obtenido al resolver el primer sistema triangular inferior coincide con $b^{(n-1)}$.

- La utilidad de la factorización se ve al resolver muchos sistemas con igual matriz A y diferentes lados derechos b. Para resolver k sistemas utilizando el método de Gauss cada vez se necesitan

$$k(\frac{2}{3}n^3 + \frac{3}{2}n^2 - \frac{7}{6}n) \cong k\frac{2}{3}n^3 \quad \text{operaciones.}$$

Si se factoriza primero y luego se resuelven los dos sistemas triangulares k veces, se necesitan

$$(\frac{2}{3}n^3 - \frac{1}{2}n^2 - \frac{1}{6}n) + k(2n^2 - n) \cong \frac{2}{3}n^3 + kn^2 \quad \text{operaciones.}$$

Observación 2.6. Las matrices L y U se almacenan (en general) en el mismo lugar en que estaba la matriz original A. Los multiplicadores m_{ij} se almacenan en la posición (i, j) que es justamente la posición donde se *produce* un cero.

La descomposición LU puede programarse de la siguiente manera en MATLAB/OCTAVE: Primera versión:

```
function [L,U] = eleu(A)
% function [L,U] = eleu(A)
% descomposicion LU
% L sera triangular inferior unitaria
% U sera triangular superior
% LU = A
n = size(A,1);
L = eye(n);
for j = 1:n
  for i = j+1:n
    L(i,j) = A(i,j) / A(j,j);
```

```
    A(i,j) = 0;
    A(i,j+1:n) = A(i,j+1:n) - L(i,j)*A(j,j+1:n);
  end
end
U = A;
```

Una versión un poco más eficiente aprovechando las operaciones *vectorizadas* de MATLAB/OCTAVE es la siguiente:

```
function [L,U] = eleu(A)
% function [L,U] = eleu(A)
% descomposicion LU
% L sera triangular inferior unitaria
% U sera triangular superior
% LU = A
n = size(A,1);
L = eye(n);
for j = 1:n-1
  L(j+1:n,j) = A(j+1:n,j) / A(j,j);
  A(j+1:n,j) = 0;
  A(j+1:n,j+1:n) = A(j+1:n,j+1:n) - L(j+1:n,j)*A(j,j+1:n);
end
U = A;
```

2.6 Problemas con la factorización LU. Pivoteo

Podría suceder que $a_{11} = 0$ o que $a_{j,j}^{(j-1)} = 0$, en cuyo caso el algoritmo no funciona. Más aún, puede verse que no es posible hallar ℓ y u_{11}, u_{12}, u_{22} tales que

$$\begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ \ell & 1 \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} \\ 0 & u_{22} \end{bmatrix}.$$

Este simple ejemplo muestra que no siempre es posible hallar una factorización LU de A, con L triangular inferior unitaria y U triangular superior.

El siguiente teorema da una condición suficiente para que el algoritmo visto funcione y logre la factorización LU.

Teorema 2.7. *Sea A una matriz de $n \times n$. Si $A_{1:k,1:k}$ es no singular, es decir,* $\det(A_{1:k,1:k}) \neq 0$*, para todo $k = 1, 2, \ldots, n-1$. Entonces existe descomposición LU de A. Más precisamente, existe L triangular inferior unitaria y U triangular superior tales que $A = LU$. Además, si A es invertible, esta descomposición LU es única.*

Demostración. Basta ver que en el proceso de eliminación de Gauss, resulta siempre $a_{j,j}^{(j-1)} \neq 0$ para $j = 1, 2, \ldots, n-1$. Demostremos esto por inducción. Si $j = 1$,

$$a_{1,1}^{(0)} = a_{11} = \det(A_{1:1,1:1}) \neq 0.$$

Supongamos que $a_{j,j}^{(j-1)} \neq 0$, $j = 1, 2, \ldots, k$, y recordemos que $A^{(k)} = G^k G^{k-1} \ldots G^2 G^1 A$. Como las matrices G^j son matrices de Gauss, resulta que[2]

$$\begin{aligned} A^{(k)}_{1:k+1,1:k+1} &= G^k_{1:k+1,1:k+1} \ldots G^2_{1:k+1,1:k+1} G^1_{1:k+1,1:k+1} A_{1:k+1,1:k+1} \\ &= \begin{bmatrix} a_{11}^{(0)} & a_{12}^{(0)} & a_{13}^{(0)} & \ldots & a_{1(k+1)}^{(0)} \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & \ldots & a_{2(k+1)}^{(1)} \\ 0 & 0 & a_{33}^{(2)} & \ldots & a_{3(k+1)}^{(2)} \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & a_{(k+1)(k+1)}^{(k)} \end{bmatrix} \end{aligned}$$

y por lo tanto

$$\begin{aligned} \det(A^{(k)}_{1:k+1,1:k+1}) &= \det(G^k_{1:k+1,1:k+1}) \ldots \det(G^2_{1:k+1,1:k+1}) \det(G^1_{1:k+1,1:k+1}) \det(A_{1:k+1,1:k+1}) \\ &= a_{11}^{(0)} a_{22}^{(1)} \ldots a_{(k+1)(k+1)}^{(k)}, \end{aligned}$$

como esta cantidad es no nula por hipótesis, resulta que $a_{(k+1)(k+1)}^{(k)} \neq 0$, que es lo que se quería demostrar.

Supongamos ahora que A es no singular. Para demostrar la unicidad de la descomposición LU supongamos que hay matrices L_1, L_2, U_1, U_2, tales que L_i es triangular inferior unitaria y U_i es triangular superior, $i = 1, 2$, con

$$L_1 U_1 = L_2 U_2 = A.$$

Luego $L_2^{-1} L_1 = U_2 U_1^{-1}$. Como $L_2^{-1} L_1$ resulta triangular inferior unitaria, y $U_2 U_1^{-1}$ es triangular superior, tenemos que

$$L_2^{-1} L_1 = U_2 U_1^{-1} = I,$$

por lo que $L_1 = L_2$ y $U_1 = U_2$. □

Pivoteo.

Para poder resolver sistemas que no cumplen con las hipótesis del Teorema 2.7 se utiliza el *pivoteo*. El pivoteo (parcial) consiste en intercambiar, en el paso j-ésimo de la eliminación de Gauss, la fila j con la fila k, que contiene al elemento de $A^{(j-1)}_{j:n,j}$ con máximo valor absoluto, antes de realizar las operaciones por filas. De esta manera, uno se asegura que nunca divide por cero, y además que divide por el elemento de módulo máximo, de los posibles *pivotes*. Esto es beneficioso pues dividir por números pequeños aumenta la propagación de errores de redondeo.

El algoritmo luce de la siguiente manera:

```
function [L,U,p] = eleupiv(A)
% function [L,U,p] = eleupiv(A)
% descomposicion LU con pivoteo
% L sera triangular inferior unitaria
```

[2]Esto es cierto por la forma especial de las matrices G^j, pero no es cierto en general; demostrar.

```
% U sera triangular superior
% LU = A(p,:) % permutacion p de las filas de A
n = size(A,1);
L = zeros(n,n);
p = [1:n]';
for j = 1:n-1
  [M, k] = max(abs(A(j:n,j)));
  k = k+j-1; % k=1 corresponde a fila j
  % registramos la permutacion
  p([k j]) = p([j k]);
  % intercambiamos filas de L y de A
  L([k j],:) = L([j k],:);
  A([k j],:) = A([j k],:);
  % ahora eliminamos
  L(j+1:n,j) = A(j+1:n,j) / A(j,j);
  A(j+1:n,j) = 0;
  A(j+1:n,j+1:n) = A(j+1:n,j+1:n) - L(j+1:n,j)*A(j,j+1:n);
end
L = L + eye(n);
U = A;
```

Observación 2.8. Este pivoteo se conoce como *pivoteo parcial*. El *pivoteo total* consiste en hallar el elemento de $A^{(j-1)}_{j:n,j:n}$ con módulo máximo e intercambiar filas y columnas. Es más complicado y en la práctica no se observan beneficios significativos con respecto al pivoteo parcial.

Permutaciones.

Para describir formalmente el proceso de la factorización LU con pivoteo necesitamos hablar de *permutaciones*. Una matriz de permutación elemental es una matriz que se obtiene intercambiando dos filas de una matriz identidad. Además, la matriz de permutación P que se obtiene intercambiando las filas j y k de una matriz identidad, es la misma que se obtiene intercambiando las *columnas* j y k de la identidad.

Es fácil ver que si P se obtiene intercambiando la fila j y k de una matriz identidad, entonces

$$\begin{aligned} PP &= I, \\ P^T &= P, \\ PA &= \text{ se obtiene intercambiando las filas } j \text{ y } k \text{ de } A, \\ AP &= \text{ se obtiene intercambiando las columnas } j \text{ y } k \text{ de } A. \end{aligned}$$

Luego, los pasos del método de Gauss con pivoteo se pueden escribir de la siguiente

manera:

$$\begin{aligned} A^{(1)} &= G^1 P^1 A^{(0)} = G^1 P^1 A \\ A^{(2)} &= G^2 P^2 A^{(1)} = G^2 P^2 G^1 P^1 A \\ &\vdots \\ U = A^{(n-1)} &= G^{n-1} P^{n-1} G^{n-2} P^{n-2} \dots G^2 P^2 G^1 P^1 A \end{aligned}$$

Con P^i una matriz de permutación que se obtiene intercambiando la fila i con una fila $k \geq i$ y $G^i = I - g_i e_i^T$,

$$g_i = (0, \dots, 0, m_{(i+1),i}, \dots, m_{ni})^T, \quad \text{y} \quad m_{\ell i} = \frac{(P^i A^{(i-1)})_{\ell i}}{(P^i A^{(i-1)})_{ii}}.$$

Teorema 2.9. *Si $U = A^{(n-1)}$ de la eliminación de Gauss con pivoteo, entonces*

$$G^{n-1} P^{n-1} G^{n-2} P^{n-2} \dots G^2 P^2 G^1 P^1 A = U,$$

con U triangular superior, y además

$$PA = LU$$

con $P = P^{n-1} P^{n-2} \dots P^2 P^1$ y L triangular inferior unitaria con $|\ell_{ij}| \leq 1$. Además, la k-ésima columna de L, debajo de la diagonal, es una permutación de los multiplicadores del paso k, más precisamente

$$L_{k+1:n,k} = (P^{n-1} \dots P^{k+2} P^{k+1} g_k)_{k+1:n}.$$

Demostración. Por la construcción, se ve que U es triangular superior, veamos ahora que $PA = LU$ y L tiene las características mencionadas, como para cualquier permutación ocurre que $PP = I$, resulta

$$\begin{aligned} U &= G^{n-1} P^{n-1} G^{n-2} P^{n-2} \dots G^2 P^2 G^1 P^1 A \\ &= G^{n-1} (P^{n-1} G^{n-2} P^{n-1}) (P^{n-1} P^{n-2} G^{n-3} P^{n-2} P^{n-1}) \\ &\quad \times (P^{n-1} P^{n-2} P^{n-3} G^{n-4} P^{n-3} P^{n-2} P^{n-1}) \dots \\ &\quad \times P^{n-1} \dots P^3 P^2 G^1 P^2 P^3 \dots P^{n-1} \\ &\quad \times \underbrace{P^{n-1} P^{n-2} \dots P^3 P^2 P^1}_{P} A \\ &= \tilde{G}^{n-1} \tilde{G}^{n-2} \dots \tilde{G}^2 \tilde{G}^1 P A, \end{aligned}$$

donde

$$\begin{aligned} \tilde{G}^k &= P^{n-1} \dots P^{k+1} G^k P^{k+1} \dots P^{n-1} \\ &= I - \underbrace{P^{n-1} \dots P^{k+1} g_k}_{\tilde{g}_k} e_k^T = I - \tilde{g}_k e_k^T. \end{aligned}$$

□

2.7 Factorización de Cholesky. Matrices sdp

2.7.1 Matrices simétricas y definidas positivas (sdp)

Definición 2.10. Se dice que una matriz $A \in \mathbb{R}^{n\times n}$ es simétrica y definida positiva, o brevemente sdp si

$$A^T = A \qquad \text{y} \qquad x^T Ax > 0, \quad \forall x \in \mathbb{R}^n \setminus \{0\}.$$

Se dice *semi*-definida positiva si $x^T Ax \geq 0$, $\forall x \in \mathbb{R}^n$.

Observación 2.11. Vale la pena observar lo siguiente:

- $x^T Ax = (Ax) \cdot x$. Luego, si A es sdp el coseno del ángulo entre Ax y x es > 0, por lo que el ángulo entre x y Ax es agudo. Si pensamos en la transformación $x \to Ax$, vemos que transforma x en otro vector Ax que apunta en una dirección *parecida* a x

- Si A es sdp, entonces A es invertible. En efecto, $Ax = 0$ implica $x^T Ax = 0$, lo que implica $x = 0$, por lo que la única solución del problema homogéneo $Ax = 0$ es la trivial.

- Si A es sdp, entonces es diagonalizable, con todos sus autovalores reales y positivos. Es decir, existe $U \in \mathbb{R}^{n\times n}$ ortogonal $U^T U = I$ con $A = U\Lambda U^T$ y Λ es diagonal con todos los elementos de la diagonal positivos.

- Si $R \in \mathbb{R}^{m\times n}$, entonces $R^T R$ es simétrica y semi-definida positiva, pues $x^T R^T Rx = (Rx)^T (Rx) = \|Rx\|_2^2 \geq 0$ para todo $x \in \mathbb{R}^n$.

- Si las n columnas de R son linealmente independientes, entonces $R^T R$ es sdp (será necesario que $n \leq m$).

- Si A es sdp y escribimos $A = \begin{bmatrix} \alpha & a^T \\ a & A_* \end{bmatrix}$, con $\alpha \in \mathbb{R}$, $a \in \mathbb{R}^{n-1}$ y $A_* \in \mathbb{R}^{(n-1)\times(n-1)}$, entonces $\alpha > 0$ y A_* es sdp. En otras palabras, si $A \in \mathbb{R}^{n\times n}$ es sdp, entonces $a_{11} > 0$ y $A_{2:n,2:n}$ es sdp.

- Si A es sdp, $a_{ii} = e_i^T Ae_i > 0$, $i = 1, 2, \ldots, n$. Es decir, si A es sdp, entonces todos los elementos de la diagonal son positivos.

- Sabemos que toda matriz se puede escribir como suma de una simétrica más una antisimétrica:

$$A = \underbrace{\frac{A + A^T}{2}}_{\text{parte simétrica de } A} + \underbrace{\frac{A - A^T}{2}}_{\text{parte antisimétrica de } A}.$$

  Como $x^T Ax \in \mathbb{R}$, resulta $x^T Ax = (x^T Ax)^T = x^T A^T x$, y por lo tanto,

$$x^T \Big(\frac{A - A^T}{2}\Big) x = -x^T \Big(\frac{A - A^T}{2}\Big) x \quad \Longrightarrow \quad x^T \Big(\frac{A - A^T}{2}\Big) x = 0.$$

En consecuencia

$$x^T A x = x^T \Big(\frac{A + A^T}{2}\Big) x + x^T \Big(\frac{A - A^T}{2}\Big) x = x^T \Big(\frac{A + A^T}{2}\Big) x.$$

Por lo tanto, si una matriz A cumple $x^T A x > 0$ para todo $x \in \mathbb{R}^n \setminus \{0\}$, luego su *parte simétrica* $\frac{A+A^T}{2}$ es sdp.

Teorema 2.12. *Si $A \in \mathbb{R}^{n\times n}$ es sdp, entonces existe R triangular superior (de $n \times n$) tal que $A = R^T R$.*

Observación 2.13. Vale la pena observar lo siguiente:

- La factorización de Cholesky es una factorización LU con $L = R^T$ y $U = R$ (L no es necesariamente unitaria).
- La matriz R se llama factor de Cholesky de A.
- En base a uno de los comentarios anteriores al enunciado, vemos que podríamos haber enunciado el teorema de la siguiente manera:

  > Sea $A \in \mathbb{R}^{n\times n}$, entonces A es sdp si y solo si existe R triangular superior (no singular) tal que $A = R^T R$.

Demostración. La demostración es constructiva. Observemos que si existiera tal matriz R debería cumplir que

$$A = \begin{bmatrix} \alpha & a^T \\ a & A_* \end{bmatrix} = \begin{bmatrix} \rho & 0^T \\ r & R_*^T \end{bmatrix} \begin{bmatrix} \rho & r^T \\ 0 & R_* \end{bmatrix} = \begin{bmatrix} \rho^2 & \rho r^T \\ \rho r & R_*^T R_* + r r^T \end{bmatrix},$$

con $\alpha = a_{11}$, $\rho \in \mathbb{R}$, $r \in \mathbb{R}^{n-1}$ y $A_*, R_* \in \mathbb{R}^{(n-1)\times(n-1)}$, con R_* triangular superior. Para que valga la igualdad se debería cumplir:

1. $\rho^2 = \alpha$;
2. $\rho r = a$;
3. $R_*^T R_* + r r^T = A_*$.

Para que se cumplan las dos primeras, basta con elegir $\rho = \sqrt{\alpha} > 0$ (recordemos que $\alpha = a_{11} > 0$) y $r = \frac{1}{\rho} a$. Para que se cumpla la tercera, observemos que debemos hallar $R_* \in \mathbb{R}^{(n-1)\times(n-1)}$, triangular superior, tal que

$$R_*^T R_* = A_* - r r^T.$$

Si podemos demostrar que $A_* - r r^T$ es sdp, el argumento se sigue por inducción.

Veamos que $A_* - r r^T$ es sdp. Queremos ver que dado $y \in \mathbb{R}^{n-1} \setminus \{0\}$, se cumple $y^T (A_* - r r^T) y > 0$, y para esto veremos si es cierto que existe $x \in \mathbb{R}^n \setminus \{0\}$ tal que $y^T (A_* - r r^T) y = x^T A x$. Proponemos $x = \begin{pmatrix} \eta \\ y \end{pmatrix}$ con $\eta \in \mathbb{R}$ a determinar. Veamos:

$$\begin{aligned} x^T A x &= \begin{pmatrix} \eta & y^T \end{pmatrix} \begin{bmatrix} \alpha & a^T \\ a & A_* \end{bmatrix} \begin{pmatrix} \eta \\ y \end{pmatrix} = \begin{pmatrix} \eta & y^T \end{pmatrix} \begin{pmatrix} \alpha\eta + a^T y \\ a\eta + A_* y \end{pmatrix} \\ &= \alpha\eta^2 + \eta a^T y + \eta y^T a + y^T A_* y = \alpha\eta^2 + 2\eta a^T y + y^T A_* y. \end{aligned}$$

Debemos elegir $\eta \in \mathbb{R}$ para que este último término sea igual a

$$y^T(A_* - rr^T)y = y^T A_* y - y^T rr^T y = y^T A_* y - (r^T y)^2.$$

Así, nos queda planteada la siguiente ecuación para η:

$$\begin{aligned} 0 &= \alpha\eta^2 + 2\eta a^T y + y^T A_* y - [y^T A_* y - (r^T y)^2] = \alpha\eta^2 + 2\eta a^T y + (r^T y)^2 \\ &= \rho^2\eta^2 + 2\eta\rho r^T y + (r^T y)^2 = (\rho\eta + r^T y)^2. \end{aligned}$$

Por lo tanto, tomando $\eta = -r^T y/\rho$ se cumple esa ecuación. Finalmente, tomando $x = \begin{pmatrix} -r^T y/\rho \\ y \end{pmatrix}$ se cumple que $x^T Ax = y^T(A_* - rr^T)y > 0$ porque A es sdp.

Por lo tanto, $A_* - rr^T$ es sdp, y el teorema queda demostrado por inducción. □

Observación 2.14. Dada A una matriz sdp, existe una *única* matriz R triangular superior, *con elementos de la diagonal positivos*, tal que $A = R^T R$.

Observación 2.15. Si D es la matriz diagonal que en la diagonal tiene los mismos elementos que R, entonces

$$A = R^T R = \underbrace{R^T D^{-1}}_{L}\underbrace{DR}_{U} = LU,$$

con L triangular inferior unitaria y U triangular superior. Así, a partir de la factorización de Cholesky se puede obtener la factorización LU y viceversa, a partir de la factorización LU se puede obtener el factor de Cholesky.

Implementación en MATLAB/OCTAVE. Esta es una primera implementación, motivada por la demostración del Teorema 2.12.

```
function R = cholesky(A)
% function R = cholesky(A)
% dada A una matriz sdp
% devuelve el factor R de Cholesky.
% R es triangular superior y cumple A = R'R
% IMPLEMENTACION RECURSIVA (ineficiente)
n = size(A,1);
if (n==1)
  R = sqrt(A);
else
  rho = sqrt(A(1,1));
  r = 1/rho*A(2:n,1);
  R = [rho           ,   r'
       zeros(n-1,1) , cholesky(A(2:n,2:n)-r*r') ];
end
```

Una versión un poco más eficiente se obtiene eliminando la recursión.

```
function R = cholesky(A)
% function R = cholesky(A)
% dada A una matriz sdp
% devuelve el factor R de Cholesky.
% R es triangular superior y cumple A = R'R
% primera version no-recursiva
n = size(A,1);
R = zeros(size(A));
for i=1:n-1
  % primero calculamos la fila i
  R(i,i) = sqrt(A(i,i));
  R(i,i+1:n) = 1/R(i,i) * A(i,i+1:n);
  % Ahora actualizamos el resto de la matriz (hacia abajo)
  A(i+1:n,i+1:n) = A(i+1:n,i+1:n) - R(i,i+1:n)'*R(i,i+1:n); % (*)
end
R(n,n) = sqrt(A(n,n));
```

Observación 2.16. El último algoritmo presentado podría hacerse más eficiente si al momento de actualizar la matriz en el paso `(*)`, solo se actualiza la parte triangular superior de `A(i+1:n,i+1:n)`. De esta manera el número de operaciones se reduce aproximadamente a la mitad. La factorización de Cholesky ya está programada eficientemente en MATLAB/OCTAVE, la función correspondiente se llama `chol`.

Ejercicios

2.1. Demostrar las siguientes afirmaciones:

(a) Si A y B son matrices triangulares inferiores (unitarias) entonces AB es triangular inferior (unitaria).

(b) Si A es triangular inferior unitaria entonces A es invertible y A^{-1} es triangular inferior unitaria.

2.2. Utilizando las funciones `tic` y `toc` de MATLAB/OCTAVE, comparar los tiempos de ejecución de las funciones `triinf`, `triinf_filas` y `triinf_cols` para la resolución de sistemas lineales con matrices triangulares inferiores.

2.3. Considerar la función `triinf_cols` para resolver sistemas triangulares inferiores, y basándose en esto, crear la función `triinfm` que resuelva varios sistemas simultáneamente. Más precisamente, si `L` es una matriz triangular inferior y `b` es una matriz cuyas columnas representan varios términos independientes, entonces `x=triinfm(L,b)` resuelve los distintos sistemas donde la j-ésima columna de `x` contiene la solución del sistema cuyo lado derecho es la j-ésima columna de `b`.

2.4. Basándose en la función `triinf_cols`, crear la función `trisup` para resolver sistemas lineales de matrices triangulares superiores.

2.5. Crear la función `[l,u] = tridilu(d,dmenos,dmas)` que calcule la factorización LU sin pivoteo de una matriz tridiagonal `A` donde

```
A = diag(dmenos(2:n),-1) + diag(d) + diag(dmas(1:n-1),1)
```

Los vectores `l` y `u` son tales que

```
L = diag(ones(n,1)) + diag(l(2:n),-1)
U = diag(u) + diag(dmas(1:n-1),1)
```

Además:

(a) Realizar el conteo de operaciones realizadas por `tridilu` y comparar con la cantidad de operaciones realizadas por la función `eleu` desarrollada en clase.

(b) Crear las funciones `triinfbidi` y `trisupbidi` para resolver sistemas triangulares bidiagonales, donde los argumentos de entrada sean vectores.

(c) Considerar un sistema lineal asociado a la matriz A de $N \times N$ ($N = 100, 1000, 10000$) donde

$$A = \begin{bmatrix} 2 & -1 & & & & \\ -1 & 2 & -1 & & & \\ & -1 & 2 & -1 & & \\ & & & \ddots & & \\ & & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix}.$$

Comparar los tiempos necesarios para hallar la solución del sistema utilizando las funciones `eleu`, `triinf_cols` y `trisup` por un lado, y `tridilu`, `triinfbidi` y `trisupbidi` por otro lado.

2.6. Sean $g_j = (0 \ \dots \ 0 \ m_{j+1,j} \ \dots \ m_{n,j})^T$ para $j = 1, 2, \dots, n-1$ vectores de Gauss. Sean $G_j := I - g_j e_j^T$ las transformaciones de Gauss asociadas a g_j, $j = 1, 2, \dots, n-1$. Demostrar que:

(a) $G_j^{-1} = I + g_j e_j^T$, para $j = 1, 2, \dots, n-1$.

(b) $G_1^{-1} G_2^{-1} \dots G_{n-1}^{-1} = I + \sum_{j=1}^{n-1} g_j e_j^T$.

2.7. Demostrar que la matriz $A = \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix}$ no tiene una factorización LU.

2.8. Considerar $A = \begin{bmatrix} \delta & 1 \\ 1 & 1 \end{bmatrix}$ y $b = \begin{pmatrix} 1+\delta \\ 2 \end{pmatrix}$.

(a) Hallar la solución exacta de $Ax = b$ para $\delta \neq 1$.

(b) Resolver el mismo sistema utilizando las funciones `eleu`, `triinf_cols` y `trisup`, para los valores de $\delta = 10^{-2}, 10^{-4}, 10^{-6}, \dots, 10^{-18}$. Armar una tabla de la forma

```
 delta        x(1)       x(2)
-----------------------------
 10^(-2)      xxxx       xxxx
   .           .          .
   .           .          .
```

Explicar qué sucede (Ayuda: pensar qué ocurre con los errores de redondeo al hacer la eliminación de Gauss.)

2.9. Resolver el sistema del ejercicio anterior utilizando la función `eleupiv` en vez de `eleu`. Realizar la misma tabla y explicar qué ocurre.

2.10. Investigar cómo funciona la función `lu` de MATLAB/OCTAVE. Comparar con la función `eleupiv`.

2.11. Demostrar que si una matriz $A \in \mathbb{R}^{n\times n}$ es *estrictamente diagonalmente dominante* (e.d.d), es decir que sus elementos a_{ij} verifican

$$|a_{ii}| > \sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}|, \qquad i = 1, 2, \ldots, n,$$

entonces resulta ser no singular. (*Sugerencia:* Probar que $Ax = 0 \Rightarrow x = 0$)

2.12. Demostrar que si A es e.d.d., el sistema $Ax = b$ se puede resolver por Eliminación de Gauss sin intercambios de renglones.

2.13. Una matriz cuadrada $A \in \mathbb{R}^{n\times n}$ se dice *simétrica y definida positiva* (sdp) si $A^T = A$ y satisface $x^T Ax > 0$ para todo vector $x \in \mathbb{R}^n$, $x \neq 0$. Decimos que es *semi-definida positiva* si $x^T Ax \geq 0$ para todo $x \in \mathbb{R}^n$. Demostrar:

(a) Si $R \in \mathbb{R}^{m\times n}$, entonces $R^T R$ es simétrica y semi-definida positiva.

(b) Si las columnas de $R \in \mathbb{R}^{m\times n}$ son linealmente independientes, entonces $R^T R$ es sdp.

(c) Si A es sdp, entonces

- **(i)** A es invertible (o no singular).
- **(ii)** Todos los autovalores de A son positivos.
- **(iii)** Los elementos de la diagonal de A son positivos.
- **(iv)** $a_{ij}^2 < a_{ii}a_{jj}$ para cada $i \neq j$.
- **(v)** $\max_{1\leq i,j\leq n} |a_{ij}| \leq \max_{1\leq i\leq n} |a_{ii}|$.

(d) Si A es sdp de orden n y si la escribimos de la forma

$$A = \begin{bmatrix} \alpha & a^T \\ a & A_* \end{bmatrix}$$

con $\alpha \in \mathbb{R}$ y A_* cuadrada de orden $n-1$, entonces $\alpha > 0$ y A_* es sdp.

2.14. Programar una versión recursiva de la factorización de Cholesky. Comparar el funcionamiento de ésta con el de la función `cholesky` dada en clase para matrices de diferentes ordenes de la forma

$$A = \begin{bmatrix} 2 & -1 & & & & \\ -1 & 2 & -1 & & 0 & \\ & -1 & 2 & -1 & & \\ & & \ddots & \ddots & \ddots & \\ & 0 & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix}.$$

Capítulo 3

Factorización QR

3.1 Mínimos cuadrados

Consideremos la situación en que se quiere *ajustar* (*fitear*) una lista dada de puntos (X_i, Y_i), $i = 1, 2, \ldots, n$, por una función cuadrática. Lo más usual es hacer lo que se conoce por *mínimos cuadrados*, que consiste en hallar los parámetros α, β, γ que minimizan el funcional

$$J(\alpha, \beta, \gamma) = \sum_{i=1}^{n} [(\alpha X_i^2 + \beta X_i + \gamma) - Y_i]^2.$$

Si definimos

$$A = \begin{bmatrix} X_1^2 & X_1 & 1 \\ X_2^2 & X_2 & 1 \\ \vdots & \vdots & \vdots \\ X_n^2 & X_n & 1 \end{bmatrix}, \qquad b = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}, \qquad x = \begin{bmatrix} \alpha \\ \beta \\ \gamma \end{bmatrix},$$

entonces $J(\alpha, \beta, \gamma) = \|Ax - b\|_2^2$, y el problema consiste en minimizar $\|Ax - b\|_2^2$, el cuadrado de la norma euclídea del vector $Ax - b$.

Consideremos entonces el problema de minimizar $\|Ax - b\|_2$ para $A \in \mathbb{R}^{n \times m}$, $b \in \mathbb{R}^n$, con $n \geq m$.

Si recordamos que Ax es una combinación lineal de las columnas de A, el problema equivale a hallar el elemento del espacio columna de A que está más cerca de b. Dado que usamos la norma euclídea, esto equivale a hallar $x \in \mathbb{R}^m$ tal que $Ax - b$ es ortogonal a las columnas de A. Es decir

$$\begin{cases} \text{col}_1(A)^T(Ax - b) = 0 \\ \text{col}_2(A)^T(Ax - b) = 0 \\ \qquad\qquad \vdots \\ \text{col}_m(A)^T(Ax - b) = 0 \end{cases} \iff \begin{cases} \text{fila}_1(A^T)(Ax - b) = 0 \\ \text{fila}_2(A^T)(Ax - b) = 0 \\ \qquad\qquad \vdots \\ \text{fila}_m(A^T)(Ax - b) = 0 \end{cases} \iff A^T(Ax - b) = 0.$$

Llegamos así a que para minimizar $\|Ax - b\|_2$ debemos resolver las *ecuaciones normales*

$$A^T A x = A^T b.$$

Si las columnas de A son linealmente independientes, entonces $A^TA \in \mathbb{R}^{m\times m}$ es simétrica y definida positiva (sdp) y el sistema tiene solución única $x = (A^TA)^{-1}A^Tb$. Por este motivo, $(A^TA)^{-1}A^T$ se conoce usualmente como *pseudoinversa* de A.

3.2 Matrices ortogonales

Definición 3.1. Se dice que una matriz $Q \in \mathbb{R}^{n\times m}$ es ortogonal si $Q^TQ = I$.

Observación 3.2. Vale la pena observar lo siguiente:

- Si Q es ortogonal, la entrada ij de Q^TQ es δ_{ij}, por lo que

$$\delta_{ij} = (Q^TQ)_{ij} = \text{fila}_i(Q^T)\,\text{col}_j(Q) = \text{col}_i(Q)^T\,\text{col}_j(Q) = \text{col}_i(Q)\cdot\text{col}_j(Q).$$

  Por lo tanto, las columnas de Q forman un conjunto *ortonormal*, y en consecuencia las columnas de Q son linealmente independientes. Como son m columnas ll.ii. en $\mathbb{R}^n$ necesariamente $n \geq m$.

- Si P y Q son matrices ortogonales y el número de columnas de P coincide con el número de filas de Q, entonces PQ es ortogonal, pues

$$(PQ)^TPQ = Q^TP^TPQ = Q^TIQ = Q^TQ = I.$$

- Si Q es ortogonal, entonces $\|Qx\|_2 = \|x\|_2$ y $(Qx)\cdot(Qy) = x\cdot y$. En efecto

$$(Qx)\cdot(Qy) = (Qx)^T(Qy) = x^TQ^TQy = x^TIy = x^Ty.$$

Recordemos que queremos encontrar una manera de minimizar $\|Ax-b\|_2$ para $A \in \mathbb{R}^{n\times m}$ y $b \in \mathbb{R}^n$ con $n \geq m$. La idea es hallar una manera mejor que la de recurrir a las ecuaciones normales.

Observemos el siguiente razonamiento. Por un lado, si $Q \in \mathbb{R}^{n\times n}$ es ortogonal, el problema equivale a minimizar $\|Q^T(Ax-b)\|_2^2$ (como Q es cuadrada, Q^T también es ortogonal).

Supongamos que es posible encontrar $Q \in \mathbb{R}^{n\times n}$ ortogonal tal que

$$Q^TA = R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} \begin{matrix} m\times m \\ (n-m)\times m \end{matrix}$$

con $R_1 \in \mathbb{R}^{m\times m}$ triangular superior. Luego,

$$\|Q^T(Ax-b)\|_2^2 = \|Q^TAx - Q^Tb\|_2^2 = \|Rx-c\|_2^2,$$

donde $c = Q^Tb = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}$ con $c_1 \in \mathbb{R}^m$ y $c_2 \in \mathbb{R}^{n-m}$. Además, $Rx = \begin{pmatrix} R_1x \\ 0 \end{pmatrix}$. Por lo tanto, queremos minimizar

$$\|Q^T(Ax-b)\|_2^2 = \|Rx-c\|_2^2 = \|R_1x-c_1\|_2^2 + \|c_2\|_2^2.$$

El mínimo se logra tomando x la solución del sistema triangular $R_1x = c_1$ y el mínimo da $\|c_2\|_2^2$.

Conclusión:

Dada $A \in \mathbb{R}^{n\times m}$, $(n \geq m)$, $b \in \mathbb{R}^n$, si existe $Q \in \mathbb{R}^{n\times n}$ ortogonal tal que

$$Q^T A = R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$$

con R_1 triangular superior no singular, entonces, el x que minimiza $\|Ax - b\|_2^2$ es la solución de

$$R_1 x = (Q^T b)_{1:m}$$

y además, $\left\|Ax - b\right\|_2^2 = \left\|(Q^T b)_{m+1:n}\right\|_2^2$.

Observación 3.3. Observemos que a los efectos de hallar la solución x del problema de mínimos cuadrados, basta con obtener las primeras m columnas de Q y las primeras m filas de R. Si llamamos Q y R a estas sub-matrices de las Q y R anteriores, el problema consiste en hallar $Q \in \mathbb{R}^{n\times m}$ ortogonal y $R \in \mathbb{R}^{m\times m}$ triangular superior tales que $A = QR$. A esto nos abocaremos en lo que sigue.

Observación 3.4. Planteando el sistema normal hace falta primero efectuar el producto $A^T A$, luego factorizar (vía Cholesky, por ejemplo; ver la Sección 2.7) y luego resolver dos sistemas triangulares. Utilizando la factorización QR de la Observación 3.3 hay que obtener la factorización, y luego resolver $Rx = Q^T b$. ¿Qué es más costoso computacionalmente?

Para poder responder esta pregunta debemos primero saber el costo de hallar la factorización QR y saber cuándo es posible.

Observemos que si $Q \in \mathbb{R}^{n\times m}$ es ortogonal y $R \in \mathbb{R}^{m\times m}$ triangular superior tales que $A = QR$, entonces, teniendo en cuenta que R es triangular superior:

$$\operatorname{col}_1(A) = Q \operatorname{col}_1(R) = Q \begin{bmatrix} r_{11} \\ 0 \\ \vdots \\ 0 \end{bmatrix} = r_{11} \operatorname{col}_1(Q),$$

$$\operatorname{col}_2(A) = Q \operatorname{col}_2(R) = Q \begin{bmatrix} r_{12} \\ r_{22} \\ 0 \\ \vdots \\ 0 \end{bmatrix} = r_{12} \operatorname{col}_1(Q) + r_{22} \operatorname{col}_2(Q),$$

$$\vdots$$

Es decir, la columna i-ésima de Q es ortogonal a las columnas $1, \ldots, i-1$ de Q, y es combinación lineal de las primeras i columnas de A. Esto tiene una gran reminiscencia de la ortogonalización de Gram-Schmidt. Veamos que este procedimiento nos conduce a una factorización QR.

3.3 Ortogonalización de Gram-Schmidt

Repasemos el procedimiento de ortogonalización de Gram-Schmidt. Dada una familia de m vectores $v_1, v_2, \ldots, v_m \in \mathbb{R}^n$, linealmente independientes, el procedimiento es

$u_1 = v_1/\|v_1\|$, normalizamos

$w_2 = v_2 - (v_2 \cdot u_1)u_1$, restamos a v_2 la componente en la dirección de u_1, (proyectamos en el subespacio ortogonal a u_1)

$u_2 = w_2/\|w_2\|$, normalizamos

$w_3 = v_3 - (v_3 \cdot u_1)u_1 - (v_3 \cdot u_2)u_2$, restamos a v_3 las componentes en las direcciones de u_1 y u_2, (proyectamos en el subespacio ortogonal a u_1 y u_2)

$u_3 = w_3/\|w_3\|$, normalizamos

$\vdots$

De esta manera, resulta que u_i es una combinación lineal de $v_1, \ldots, v_i$, y el factor de v_i es no nulo. Así, resulta que

$$\underbrace{\begin{bmatrix} v_1 & v_2 & \ldots & v_m \end{bmatrix}}_{A} = \underbrace{\begin{bmatrix} u_1 & u_2 & \ldots & u_m \end{bmatrix}}_{Q_1} \underbrace{\begin{bmatrix} \times & \times & \times & \ldots & \times \\ 0 & \times & \times & \ldots & \times \\ 0 & 0 & \times & \ldots & \times \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \ldots & 0 & \times \end{bmatrix}}_{R_1},$$

y los vectores u_i son ortonormales.

Hemos demostrado el siguiente teorema:

Teorema 3.5. *Si las columnas de $A \in \mathbb{R}^{n\times m}$ son linealmente independientes, entonces existe una descomposición QR del siguiente tipo:*

$$\begin{aligned} &Q_1 \in \mathbb{R}^{n\times m} \text{ es ortogonal,} \\ &R_1 \in \mathbb{R}^{m\times m} \text{ es triangular superior,} \\ &A = Q_1 R_1. \end{aligned}$$

Observación 3.6. Bajo las mismas condiciones sobre A existe una descomposición QR del siguiente tipo:

$$\begin{aligned} &Q \in \mathbb{R}^{n\times n} \text{ es ortogonal,} \\ &R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} \in \mathbb{R}^{n\times m} \text{con } R_1 \in \mathbb{R}^{m\times m} \text{ triangular superior,} \\ &A = QR. \end{aligned}$$

La matriz R_1 de esta descomposición es la del teorema, y la Q se obtiene *completando* una base ortonormal de $\mathbb{R}^n$ a partir de las columnas de Q_1.

Pero existe otra manera de obtener la factorización QR, que es muy interesante y más económica, utilizando las *matrices de Householder*.

3.4 Matrices de Householder

El material de esta sección fue extraído de [St, Lecture 8].

Definición 3.7. Una transformación o matriz de Householder es una matriz de la forma

$$H = I - uu^T,$$

con $u \in \mathbb{R}^n$ tal que $\|u\|_2 = \sqrt{2}$.

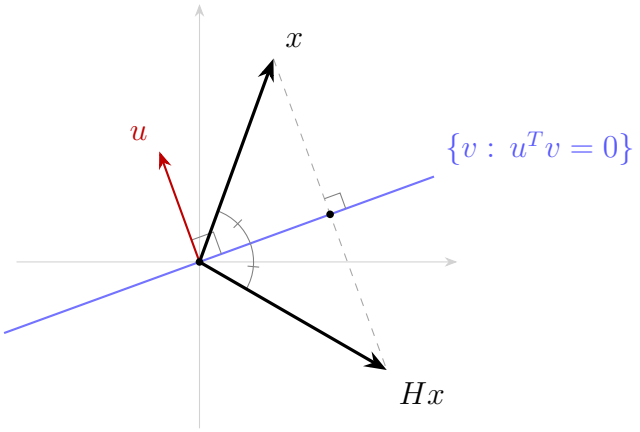


Figura 3.1 La matriz de Householder $H = I - uu^T$ (con $\|u\|_2 = \sqrt{2}$) refleja cada vector x respecto del hiperplano $\{v : u^T v = 0\}$, ortogonal a u: la componente de x en la dirección de u cambia de signo y la componente sobre el hiperplano permanece igual.

Observación 3.8. Vale la pena observar lo siguiente, para una matriz $H = I - uu^T$ de Householder:

- H es simétrica: $H^T = H$ (inmediato)
- H es ortogonal. En efecto

$$H^T H = HH = (I - uu^T)(I - uu^T) = I - 2uu^T + u \underbrace{u^T u}_{\|u\|_2^2} u^T = I - 2uu^T + 2uu^T = I.$$

- Si $X \in \mathbb{R}^{n \times k}$, hay dos maneras (al menos) de calcular HX:
  - Ensamblar H ($\frac{n(n+1)}{2} + n \cong \frac{n^2}{2}$ operaciones), y luego hacer el producto HX que lleva $2n^2k$ operaciones. Totalizando $\cong 2n^2k$ operaciones.
  - Observar lo siguiente:

$$HX = (I - uu^T)X = X - uu^T X = X - u(u^T X).$$

Si hacemos primero $u^T X$ nos lleva $2nk$ operaciones, luego multiplicar u por lo obtenido $u(u^T X)$ nos lleva nk operaciones más. Finalmente, hacer X menos ese resultado nos lleva nk operaciones, totalizando ¡solamente $4nk$ operaciones!

La idea es que la matriz Q sea una composición o producto de matrices de Householder.

Veamos cómo puede construirse una transformación de Householder con ciertas propiedades.

Teorema 3.9. *Sea x un vector unitario ($\|x\|_2 = 1$) y definamos*

$$u = \frac{1}{\sqrt{1 \pm x_1}}(x \pm e_1),$$

donde el signo en $\pm$ se elige de manera que $1 \pm x_1 > 0$. Entonces $H = I - uu^T$ es de Householder y $Hx = \mp e_1$.

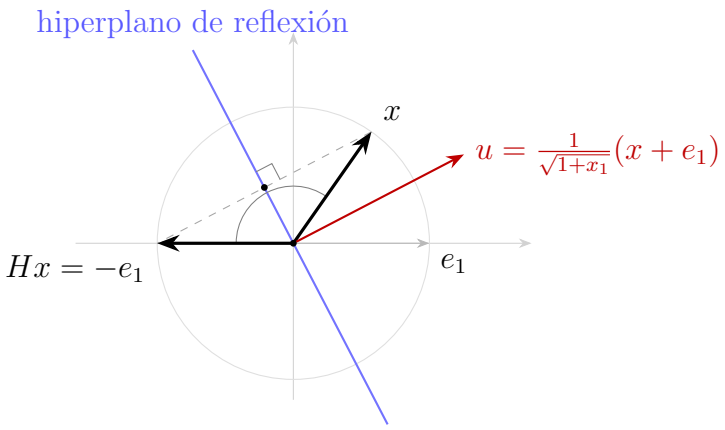


Figura 3.2 Ilustración del Teorema 3.9 en $\mathbb{R}^2$: dado x con $\|x\|_2 = 1$ y $x_1 > 0$ (tomando el signo $+$), la reflexión $H = I - uu^T$ con $u = \frac{1}{\sqrt{1+x_1}}(x + e_1)$ lleva x al eje generado por e_1, resultando $Hx = -e_1$. El hiperplano de reflexión biseca el ángulo entre x y $-e_1$.

Observación 3.10. Antes de demostrarlo observemos para qué puede servir. Si x es la primera columna de una matriz A, y H se construye como en el teorema, entonces

$$HA = \begin{bmatrix} \mp 1 & \times & \dots & \times \\ 0 & \times & \dots & \times \\ \vdots & \vdots & & \vdots \\ 0 & \times & \dots & \times \end{bmatrix}, \quad \text{ó} \quad \operatorname{col}_1(HA) = \mp e_1,$$

donde $\times$ representa números no necesariamente nulos.

Demostración. Veamos primero que $\|u\|_2 = \sqrt{2}$:

$$\begin{aligned} \|u\|_2^2 = u^T u &= \frac{1}{1 \pm x_1}\left((x \pm e_1)^T (x \pm e_1)\right) \\ &= \frac{1}{1 \pm x_1}\left(x^T x \pm 2e_1^T x + e_1^T e_1\right) \\ &= \frac{1}{1 \pm x_1}\left(1 \pm 2x_1 + 1\right) = 2\frac{1 \pm x_1}{1 \pm x_1} = 2. \end{aligned}$$

Veamos ahora cuál es el efecto de H sobre x: Por un lado,

$$Hx = (I - uu^T)x = x - uu^T x = x - u(u^T x),$$

y por otro lado

$$u^T x = \frac{1}{\sqrt{1 \pm x_1}}(x \pm e_1)^T x = \frac{1}{\sqrt{1 \pm x_1}}(x^T x \pm e_1^T x) = \frac{1 \pm x_1}{\sqrt{1 \pm x_1}} = \sqrt{1 \pm x_1}.$$

Por lo tanto

$$Hx = x - u(u^T x) = x - \sqrt{1 \pm x_1}u = x - \sqrt{1 \pm x_1}\frac{1}{\sqrt{1 \pm x_1}}(x \pm e_1) = x - (x \pm e_1) = \mp e_1.$$

□

Observación 3.11. Conviene elegir el signo de manera que $\sqrt{1 \pm x_1}$ sea lo más grande posible, pues dividirá otros números. Observemos que $\|x\|_2 = 1$ implica $-1 \leq x_1 \leq 1$, y que:

$$\begin{aligned} &\text{si } x_1 \text{ está cerca de } 1 \quad \Longrightarrow \quad 1 - x_1 \text{ estará cerca de cero, y} \\ &\text{si } x_1 \text{ está cerca de } -1 \quad \Longrightarrow \quad 1 + x_1 \text{ estará cerca de cero.} \end{aligned}$$

Para evitar inconvenientes, y para que los divisores que aparezcan sean lo más grandes posibles, elegiremos el signo positivo cuando $x_1 > 0$ y negativo cuando $x_1 < 0$.

Observación 3.12. Si $\|x\|_2 \neq 1$, entonces tomamos

$$u = \frac{1}{\sqrt{1 \pm \frac{x_1}{\|x\|_2}}}(\frac{x}{\|x\|_2} \pm e_1),$$

y con $H = I - uu^T$ resulta

$$Hx = \mp \|x\|_2 e_1.$$

A partir del teorema y las observaciones llegamos al siguiente teorema.

Teorema 3.13. *Sea $A \in \mathbb{R}^{n \times m}$ con columnas linealmente independientes. Entonces existen $Q \in \mathbb{R}^{n \times n}$ ortogonal y $R \in \mathbb{R}^{n \times m}$, con $R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$ y $R_1 \in \mathbb{R}^{m \times m}$ triangular superior no singular, tales que $A = QR$.*

Demostración. Haremos la demostración por inducción sobre m. Si $m = 1$, $A = x \in \mathbb{R}^n \setminus \{0\}$ (para cualquier $n \geq 1$). Tomamos $\sigma = 1$ si $x_1 \geq 0$, o $\sigma = -1$ si $x_1 < 0$, y

$$u = \frac{1}{\sqrt{1 + \sigma \frac{x_1}{\|x\|_2}}}(\frac{x}{\|x\|_2} + \sigma e_1), \qquad H = I - uu^T.$$

Luego, por el teorema anterior y las observaciones

$$HA = \begin{bmatrix} -\sigma\|x\|_2 \\ 0 \\ \vdots \\ 0 \end{bmatrix} =: R, \qquad \Longrightarrow A = \underbrace{H}_{Q} R.$$

Supongamos válido el teorema para m (y todo $n \geq m$) y demostrémoslo para $m+1$. Sea $A \in \mathbb{R}^{n\times(m+1)}$ con columnas linealmente independientes. Sea $x = \mathrm{col}_1(A) \neq 0$, tomemos $\sigma = 1$ si $x_1 \geq 0$, o $\sigma = -1$ si $x_1 < 0$ y

$$u = \frac{1}{\sqrt{1+\sigma\frac{x_1}{\|x\|_2}}}\left(\frac{x}{\|x\|_2} + \sigma e_1\right), \qquad H = I - uu^T.$$

Luego

$$HA = \begin{bmatrix} -\sigma\|x\|_2 & r^T \\ 0 & \hat{A} \end{bmatrix}, \quad \text{con } r \in \mathbb{R}^m \text{ y } \hat{A} \in \mathbb{R}^{(n-1)\times m}.$$

Las columnas de $\hat{A}$ son linealmente independientes, pues si no A no tendría $m+1$ columnas linealmente independientes. Por la hipótesis inductiva, existen $\hat{Q} \in \mathbb{R}^{(n-1)\times(n-1)}$ ortogonal y $\hat{R} = \begin{bmatrix} \hat{R}_1 \\ 0 \end{bmatrix} \in \mathbb{R}^{(n-1)\times m}$ con $\hat{R}_1 \in \mathbb{R}^{m\times m}$ triangular superior tales que $\hat{A} = \hat{Q}\hat{R}$. Luego

$$HA = \begin{bmatrix} -\sigma\|x\|_2 & r^T \\ 0 & \hat{Q}\hat{R} \end{bmatrix} = \begin{bmatrix} 1 & 0^T \\ 0 & \hat{Q} \end{bmatrix} \begin{bmatrix} -\sigma\|x\|_2 & r^T \\ 0 & \hat{R} \end{bmatrix},$$

y por lo tanto

$$A = \underbrace{H \begin{bmatrix} 1 & 0^T \\ 0 & \hat{Q} \end{bmatrix}}_{Q} \underbrace{\begin{bmatrix} -\sigma\|x\|_2 & r^T \\ 0 & \hat{R} \end{bmatrix}}_{R}.$$

□

Implementación.

Para implementar el algoritmo seguiremos los pasos de la demostración del teorema.

Dada $A \in \mathbb{R}^{n\times m}$ (con sus columnas linealmente independientes), hacemos (aquí y en lo que sigue usamos la convención $\mathrm{sgn}(x_1) = 1$ si $x_1 \geq 0$ y $\mathrm{sgn}(x_1) = -1$ si $x_1 < 0$)

$$x = \mathrm{col}_1(A), \quad \sigma = \mathrm{sgn}(x_1), \quad u_1 = \frac{1}{\sqrt{1+\sigma\frac{x_1}{\|x\|_2}}}\left(\frac{x}{\|x\|_2} + \sigma e_1\right), \quad H_1 = I - u_1u_1^T.$$

Luego, sabemos que

$$H_1A = \begin{bmatrix} \rho_1 & r_1^T \\ 0 & A_1 \end{bmatrix}, \quad \text{con } \rho_1 = -\sigma\|x\|_2, \text{ y } \begin{bmatrix} r_1^T \\ A_1 \end{bmatrix} = H_1A_{:,2:m}.$$

Y también

$$A = H_1 \begin{bmatrix} \rho_1 & r_1^T \\ 0 & A_1 \end{bmatrix}.$$

Ahora hacemos

$$x = \mathrm{col}_1(A_1) \in \mathbb{R}^{n-1}, \quad \sigma = \mathrm{sgn}(x_1), \quad u_2 = \frac{1}{\sqrt{1+\sigma\frac{x_1}{\|x\|_2}}}\left(\frac{x}{\|x\|_2} + \sigma e_1\right),$$

$$H_2 = I - u_2u_2^T \in \mathbb{R}^{(n-1)\times(n-1)}.$$

Entonces

$$H_2 A_1 = \begin{bmatrix} \rho_2 & r_2^T \\ 0 & A_2 \end{bmatrix}, \quad \text{con } \rho_2 = -\sigma\|x\|_2, \text{ y } \begin{bmatrix} r_2^T \\ A_2 \end{bmatrix} = H_2 (A_1)_{:,2:m-1}.$$

Y también

$$A_1 = H_2 \begin{bmatrix} \rho_2 & r_2^T \\ 0 & A_2 \end{bmatrix},$$

por lo que

$$A = H_1 \begin{bmatrix} \rho_1 & r_1^T \\ 0 & A_1 \end{bmatrix} = H_1 \begin{bmatrix} \rho_1 & & r_1^T \\ & & \\ 0 & H_2 & \begin{bmatrix} \rho_2 & r_2^T \\ 0 & A_2 \end{bmatrix} \end{bmatrix} = H_1 \begin{bmatrix} 1 & 0^T \\ 0 & H_2 \end{bmatrix} \begin{bmatrix} \rho_1 & r_1^T \\ 0 & \rho_2 \quad r_2^T \\ 0 & 0 \quad A_2 \end{bmatrix}.$$

Ahora hacemos

$$x = \text{col}_1(A_2) \in \mathbb{R}^{n-2}, \quad \sigma = \text{sgn}(x_1), \quad u_3 = \frac{1}{\sqrt{1 + \sigma \frac{x_1}{\|x\|_2}}} (\frac{x}{\|x\|_2} + \sigma e_1),$$

$$H_3 = I - u_3 u_3^T \in \mathbb{R}^{(n-2)\times(n-2)}.$$

Entonces

$$H_3 A_2 = \begin{bmatrix} \rho_3 & r_3^T \\ 0 & A_3 \end{bmatrix}, \quad \text{con } \rho_3 = -\sigma\|x\|_2, \text{ y } \begin{bmatrix} r_3^T \\ A_3 \end{bmatrix} = H_3 (A_2)_{:,2:m-2}.$$

Y también

$$A_2 = H_3 \begin{bmatrix} \rho_3 & r_3^T \\ 0 & A_3 \end{bmatrix},$$

por lo que

$$A = H_1 \begin{bmatrix} 1 & 0^T \\ 0 & H_2 \end{bmatrix} \begin{bmatrix} \rho_1 & & r_1^T \\ & \rho_2 & r_2^T \\ 0 & 0 & H_3 \begin{bmatrix} \rho_3 & r_3^T \\ 0 & A_3 \end{bmatrix} \end{bmatrix} = H_1 \begin{bmatrix} 1 & 0^T \\ 0 & H_2 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & \\ 0 & & H_3 \end{bmatrix} \begin{bmatrix} \rho_1 & & r_1^T \\ & \rho_2 & r_2^T \\ 0 & 0 & \rho_3 \quad r_3^T \\ & & 0 \quad A_3 \end{bmatrix}.$$

Así sucesivamente ....

El algoritmo para MATLAB/OCTAVE luce así:

```
function [U,R] = qrhouse(A)
% function [U,R] = qrhouse(A)
%
% Descomposicion QR de A
% La matriz R tiene el mismo tamaño que A pero es triangular superior
% La matriz Q es cuadrada y ortogonal
%  A = Q R
%
% Pero no se calcula Q, sino que se devuelven los vectores u que
% generan las transformaciones de Householder que conforman Q
%
```

```
%  Q' = Qk ... Q2 Q1
%
% con Q1 = H1 = eye(n) - u1 u1'
%     Q2 = [1 zeros(1,n-1); zeros(n-1,1) H2]  y  H2 = eye(n-1) - u2 u2'
%     Q3 = [eye(2) zeros(2,n-2); zeros(n-2,2) H3]
%         y H3  = eye(n-2) - u3 u3'
%     ...
%  uk = U(1:n-k+1, k)
%
% ver qrsolve


[n, m] = size(A);
R = A;
U = zeros(n, m);

for i = 1:m
    normx = norm(R(i:n, i));
    u = R(i:n, i)/normx;
    if (u(1) >= 0)
        sg = 1;
    else
        sg = -1;
    end
    u(1) = u(1) + sg;
    u = u / sqrt(1+sg*R(i,i)/normx);

    U(1:n-i+1, i) = u;
    R(i,i) = -sg*normx;
    R(i+1:n,i) = 0;
    R(i:n,i+1:m) = R(i:n,i+1:m) - u*(u'*R(i:n,i+1:m));
end
```

Esta función se complementa con `qrsolve`, que utiliza la descomposición QR dada por `qrhouse` para resolver un problema de mínimos cuadrados. Utiliza la función `trisup(T,c)`, que resuelve el sistema triangular superior $Tx = c$ mediante sustitución hacia atrás (retrosustitución), como la función `trisup` de los ejercicios del Capítulo 2.

```
function [x,e] = qrsolve(U,R,b)
% function [x,e] = qrsolve(U,R,b)
%
% Utiliza la descomposición QR de A
% para resolver el problema de cuadrados mínimos
%   min || Ax - b ||
%
%  A = Q R
%
```

```
% Pero ingresan como argumentos U y R.
% Q es ortogonal, y las columnas de U contienen los vectores que
% definen las transformaciones de Householder que conforman Q
%
%  Q' = Qk ... Q2 Q1
%
% con Q1 = H1 = eye(n) - u1 u1'
%     Q2 = [1 zeros(1,n-1); zeros(n-1,1) H2]  y  H2 = eye(n-1) - u2 u2'
%     Q3 = [eye(2) zeros(2,n-2); zeros(n-2,2) H3]
%         y H3  = eye(n-2) - u3 u3'
%     ...
%  uk = U(1:n-k+1, k)
%
% el argumento de salida x es la solución
% el argumento opcional de salida e es || Ax - b ||
%
% ver qrhouse

%% Primer paso. Calculamos c = Q' b
c = b;
[n, m] = size(U);

for i = 1:m
    u = U(1:n-i+1, i);
    c(i:n) = c(i:n) - u*(u'*c(i:n));
end

%% Segundo paso. Calculamos x
x = trisup(R(1:m,:),c(1:m));

%% Ultimo paso. Si se pide el error, se calcula e
if nargout > 1
    e = norm(c(m+1:n));
end
```

3.5 Conteo de operaciones y estabilidad

Estamos ahora en condiciones de responder la pregunta que planteamos más arriba: dado el problema de mínimos cuadrados $\min_x \|Ax - b\|_2$ con $A \in \mathbb{R}^{n \times m}$ de rango m y $n \geq m$, ¿conviene resolver las ecuaciones normales o usar la factorización QR?

Conteo de operaciones.

Contamos las operaciones a orden dominante, en el caso $n \gg m$ (muchas más filas que columnas), que es el habitual en mínimos cuadrados.

- *Ecuaciones normales* (vía Cholesky). Formar A^TA cuesta $\cong nm^2$ operaciones: la matriz es simétrica, y cada una de las $\cong m^2/2$ entradas de su triángulo superior es un producto interno de dos columnas de A ($\cong 2n$ operaciones). Formar A^Tb cuesta $\cong 2nm$, la factorización de Cholesky de A^TA cuesta $\cong \frac{1}{3}m^3$, y resolver los dos sistemas triangulares $\cong 2m^2$. En total

$$\cong nm^2 + \tfrac{1}{3}m^3 \cong nm^2 \quad (\text{si } n \gg m).$$

- *QR por Gram–Schmidt.* Ortonormalizar las m columnas de A cuesta $\cong 2nm^2$ operaciones.

- *QR por Householder.* Aplicar las m transformaciones H_i sin ensamblar Q (usando $HX = X - u(u^TX)$) cuesta $\cong 2nm^2 - \frac{2}{3}m^3 \cong 2nm^2$; resolver $R_1x = (Q^Tb)_{1:m}$ y aplicar los H_i a b agregan sólo términos de orden inferior.

Resumimos los costos a orden dominante ($n \gg m$):

Método	Operaciones
Ecuaciones normales (Cholesky)	$nm^2 + \frac{1}{3}m^3 \cong nm^2$
QR por Gram–Schmidt	$\cong 2nm^2$
QR por Householder	$2nm^2 - \frac{2}{3}m^3 \cong 2nm^2$

Así, las ecuaciones normales requieren aproximadamente *la mitad* de las operaciones que la vía QR. Sin embargo, como veremos enseguida, son menos *estables*. El conteo detallado de cada método queda propuesto como ejercicio al final del capítulo.

Estabilidad y número de condición.

Para comparar la *precisión* de los métodos conviene introducir el *número de condición* de una matriz. Para una matriz cuadrada e invertible B, el número de condición en norma 2 es $\kappa_2(B) = \|B\|_2 \, \|B^{-1}\|_2 \geq 1$; mide cuánto puede amplificarse, en el peor caso, el error relativo de la solución de $Bx = c$ frente a perturbaciones en los datos (lo estudiaremos en detalle más adelante, en el capítulo de métodos iterativos). Si B es sdp, resulta $\kappa_2(B) = \lambda_{\max}/\lambda_{\min}$, el cociente entre su mayor y su menor autovalor.

Como A^TA es sdp (lo vimos al plantear las ecuaciones normales), podemos medir el condicionamiento del problema de mínimos cuadrados a través de él. Definimos el número de condición de $A \in \mathbb{R}^{n\times m}$ (de rango m) en norma 2[1] como

$$\kappa_2(A) = \sqrt{\kappa_2(A^TA)} = \sqrt{\frac{\lambda_{\max}(A^TA)}{\lambda_{\min}(A^TA)}}, \qquad \text{de modo que} \qquad \kappa_2(A^TA) = \kappa_2(A)^2.$$

[1]Equivalentemente, en términos de los valores singulares $\sigma_1 \geq \cdots \geq \sigma_m > 0$ de A (las raíces cuadradas de los autovalores de A^TA), es $\kappa_2(A) = \sigma_1/\sigma_m = \|A\|_2 \, \|A^+\|_2$, donde $A^+ = (A^TA)^{-1}A^T$ es la pseudoinversa de A. Para A cuadrada e invertible, $A^+ = A^{-1}$ y se recupera $\kappa_2(A) = \|A\|_2 \, \|A^{-1}\|_2$.

Decimos que un algoritmo es *estable hacia atrás* (*backward stable*) si la solución $\hat{x}$ que produce en aritmética de punto flotante es la solución *exacta* de un problema *levemente perturbado*. Para $\min \|Ax - b\|_2$, esto significa que existen perturbaciones ΔA, Δb con

$$\frac{\|\Delta A\|}{\|A\|}, \quad \frac{\|\Delta b\|}{\|b\|} \;\cong\; \varepsilon_{\text{maq}}$$

(del orden del *épsilon de máquina*, $\varepsilon_{\text{maq}} \approx 2.2 \times 10^{-16}$ en doble precisión) tales que $\hat{x}$ resuelve exactamente $\min \|(A + \Delta A)x - (b + \Delta b)\|_2$. En palabras: el algoritmo no introduce más error que el inevitable al representar los datos en la máquina.

Conviene distinguir el *error hacia adelante* $\|\hat{x} - x\|$ (cuán lejos está la solución calculada de la exacta) del *error hacia atrás* (cuánto hay que perturbar los datos para que $\hat{x}$ sea exacta). Ambos se relacionan, a grandes rasgos, por

$$\text{error hacia adelante} \;\cong\; \kappa_2(A) \times (\text{error hacia atrás}).$$

Por lo tanto, un algoritmo estable hacia atrás produce un error hacia adelante $\cong \kappa_2(A)\,\varepsilon_{\text{maq}}$: lo mejor que puede esperarse dado el condicionamiento del problema.

Observación 3.14. La factorización QR por Householder es estable hacia atrás: Q es un producto de reflexiones, que son isometrías ($\|Qx\|_2 = \|x\|_2$) y por lo tanto no amplifican los errores de redondeo. En cambio, el método de las ecuaciones normales forma A^TA, cuyo número de condición es $\kappa_2(A^TA) = \kappa_2(A)^2$. Aun resolviendo $A^TAx = A^Tb$ de manera perfecta, el error hacia adelante puede ser $\cong \kappa_2(A)^2\,\varepsilon_{\text{maq}}$: se pierde *el doble* de dígitos significativos que con la vía QR. Por eso, cuando A está mal condicionada, se prefiere resolver el problema de mínimos cuadrados mediante la factorización QR (Householder).

3.6 Rotaciones de Givens

Consideraremos en esta sección el caso particular en que queremos hallar la factorización QR de una matriz *upper Hessenberg*. Esta clase de matrices aparece en métodos iterativos para sistemas lineales como el GMRes y también en el cálculo de autovalores.

Definición 3.15. Se dice que una matriz H es *upper Hessenberg* si sus componentes $h_{ij} = 0$ para todo $i > j + 1$. Es decir, las entradas por debajo de la primera subdiagonal son nulas.

Para matrices de tipo *upper Hessenberg*, o simplemente *Hessenberg*, se puede obtener una factorización QR mucho más eficientemente que usando las transformaciones de Householder, utilizando las *rotaciones de Givens*.

Definición 3.16. Una *rotación de Givens* de 2×2 es una matriz de la forma

$$G = \begin{bmatrix} \cos(\theta) & -\operatorname{sen}(\theta) \\ \operatorname{sen}(\theta) & \cos(\theta) \end{bmatrix}$$

considerando $\theta \in [-\pi, \pi]$. Esta matriz es ortogonal y *rota* el vector $\begin{bmatrix} c \\ -s \end{bmatrix} = \begin{bmatrix} \cos(\theta) \\ -\operatorname{sen}(\theta) \end{bmatrix}$ hacia el vector $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$. Es decir,

$$\text{si } c^2 + s^2 = 1, \qquad G = \begin{bmatrix} c & -s \\ s & c \end{bmatrix} \qquad \text{resulta} \quad G \begin{bmatrix} c \\ -s \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Una *rotación de Givens* de $n \times n$ es una matriz identidad de $n \times n$ donde se ha reemplazado un bloque de tamaño 2×2 de la diagonal por una matriz de rotación de Givens de 2×2. Es decir, una matriz de la forma:

$$G = \begin{bmatrix} 1 & 0 & & \dots & & & 0 \\ 0 & \ddots & \ddots & & & & \\ & \ddots & c & -s & & & \\ \vdots & & s & c & 0 & & \vdots \\ & & & 0 & 1 & \ddots & \\ & & & & \ddots & \ddots & 0 \\ 0 & & & \dots & & 0 & 1 \end{bmatrix}.$$

Usaremos la notación $G_j(c, s)$ para indicar una matriz de rotación de Givens de $n \times n$ con la matriz de Givens de 2×2 en las filas y columnas j y $j + 1$.

La idea es utilizar rotaciones de Givens para reducir matrices de Hessenberg a matrices triangulares superiores, de la siguiente manera: Sea H una matriz de Hessenberg de $n \times m$ ($n \geq m$) de rango m. El objetivo es reducirla a triangular superior multiplicándola a izquierda por rotaciones de Givens. Si queremos producir un cero en la posición $(2, 1)$ de la matriz H tenemos que pensar que estamos rotando el vector $\begin{bmatrix} h_{11} \\ h_{21} \end{bmatrix}$. Por ello, definimos $G_1 = G_1(c_1, s_1)$ con

$$c_1 = \frac{h_{11}}{\sqrt{h_{11}^2 + h_{21}^2}} \quad \text{y} \quad s_1 = \frac{-h_{21}}{\sqrt{h_{11}^2 + h_{21}^2}}.$$

Si multiplicamos G_1 por H, en la primera columna de $H^1 = G_1 H$ queda un único elemento no nulo en la posición $(1, 1)$. Vale la pena observar que el producto $G_1 H$ sólo afecta las dos primeras filas de H.

Con la nueva matriz H^1, definimos

$$c_2 = \frac{h_{22}}{\sqrt{h_{22}^2 + h_{32}^2}} \quad \text{y} \quad s_2 = \frac{-h_{32}}{\sqrt{h_{22}^2 + h_{32}^2}},$$

donde ahora h_{22} y h_{32} denotan las entradas correspondientes de H^1, y $G_2 = G_2(c_2, s_2)$, y así sucesivamente, anulando una por una las entradas de la primera subdiagonal. Si $n = m$ la última entrada subdiagonal es la $(m, m-1)$ y bastan $p = m - 1$ pasos; si $n > m$ hay que anular también la entrada $(m + 1, m)$ y hacen falta $p = m$ pasos. Llegamos así a

$$\underbrace{G_p G_{p-1} \dots G_1}_{Q^T} H = R,$$

con R triangular superior y $Q^T = G_p G_{p-1} \dots G_1$ ortogonal de $n \times n$.

Observamos también que al aplicar G_2 la primera columna de H^1 no se modifica, al aplicar G_3 no se modifican la primera y la segunda columna, y así sucesivamente.

Queda pendiente hacer un cálculo del número de operaciones necesario para obtener Q y R.

3.7 Problemas

3.1. Ortogonalización de Gram-Schmidt.

(a) Describir el método de ortogonalización de Gram-Schmidt.

(b) Sea $A \in \mathbb{R}^{n \times k}$, con $n \geq k$ una matriz con columnas linealmente independientes. Demostrar que si se utiliza el método de ortogonalización de Gram-Schmidt con las columnas de A, entonces colocando los vectores de la nueva base como columnas de una matriz Q se obtiene una descomposición QR de A.

3.2. Realizar una función en MATLAB/OCTAVE de nombre `mincuad(A,b)` que resuelva las ecuaciones normales correspondientes al sistema $Ax = b$. ¿Qué pasa si para un sistema rectangular con más filas que columnas escribimos `A\b` en MATLAB/OCTAVE? Verificar y comparar el resultado arrojado por esta última fórmula y el obtenido por la función `mincuad(A,b)`. Utilizando la función *help* indagar el funcionamiento del símbolo `\` y de la función `pinv` e informar brevemente.

3.3. Supongamos que el precio de una casa depende principalmente de dos variables: su edad (x_1) y el área de su superficie cubierta (x_2) en metros cuadrados. Se propone el modelo lineal

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2.$$

Se observaron cinco casas seleccionadas aleatoriamente del mercado y se obtuvieron los siguientes datos:

Precio en miles (y)	Edad en años (x_1)	Superficie cubierta en m^2 $\times$ 100 (x_2)
50	1	1
40	5	1
52	5	2
47	10	2
65	20	3

Encontrar los valores de β_0, β_1, y β_2 que minimizan el error por cuadrados mínimos. ¿Cuál es el error? Estimar el costo de una vivienda de 25 años y 250 m^2 de superficie cubierta.

3.4. Transformaciones de Householder

(a) Programar una función `[x,e] = mincuadqr(A,b)` que resuelva el problema de cuadrados mínimos correspondiente al sistema $Ax = b$, utilizando las dos funciones `[U,R] = qrhouse(A)` y `[x,e] = qrsolve(U,R,b)` vistas en clase.

(b) Utilizando la función `mincuadqr(A,b)`, crear la función `a = ajustar(x,y,n)` que reciba como argumentos:

`x, y`: coordenadas de puntos a ajustar con un polinomio.

`n`: grado del polinomio con el que se ajustarán los puntos.

La salida deben ser los coeficientes del polinomio obtenido, donde `a(1)` es el coeficiente de orden `n`, `a(2)` el de orden `n-1`, y así sucesivamente, hasta `a(n+1)` que es el coeficiente de orden cero.

3.5. Realizar el conteo de operaciones necesarias para resolver el problema de mínimos cuadrados asociado al sistema $Ax = b$ con $A \in \mathbb{R}^{n\times k}$ con n mucho mayor que k mediante:

(a) El *método de las ecuaciones normales*, es decir, resolviendo el sistema $A^TAx = A^Tb$ mediante la descomposición de Cholesky (Sección 2.7).

(b) La descomposición QR de A utilizando el método de Gram-Schmidt.

(c) La descomposición QR de A utilizando las transformaciones de Householder (función `[x,e] = mincuadqr(A,b)`).

3.6. Analizar experimentalmente la velocidad y la precisión (o estabilidad) de las funciones `mincuad(A,b)`, `mincuadqr(A,b)` y \ (de MATLAB/OCTAVE) al resolver el siguiente problema de mínimos cuadrados: $Ax = b$ donde $A \in \mathbb{R}^{n\times 4}$ es la matriz
`A = [a.^3, a.^2, a, ones(n,1)]` para `a = linspace(1,5,n)'`, y el vector b elegido de manera que la solución exacta del problema sea $x = (1, 1, 1, 1)^T$. Considerar distintos valores grandes de n.

3.7. Realizar un conteo de las operaciones necesarias para hallar la factorización QR de una matriz *upper Hessenberg* de $n \times n$.

Capítulo 4

Métodos iterativos estacionarios para sistemas lineales

En este capítulo describiremos algunos métodos iterativos para sistemas lineales. Los métodos *directos* como el método de eliminación de Gauss y sus variantes, como la descomposición LU, el método de Cholesky y adaptaciones a matrices de tipo banda, etc. son los métodos de elección para muchos problemas. Por favor no dejes que nada de lo dicho en este capítulo te haga olvidar esto.

Hay situaciones que requieren un tratamiento diferente al de los métodos directos, y aquí algunos inconvenientes de los métodos directos:

- El método de eliminación de Gauss o descomposición LU, en general, produce un rellenado: las matrices L y U pueden tener elementos no nulos en ubicaciones donde la matriz original A tiene ceros. Si la cantidad de relleno es significativa, aplicar un método directo puede resultar muy costoso. Esto ocurre a menudo en casos en que la matriz es de banda y rala (sparse) dentro de la banda.

- A veces no necesitamos resolver el sistema exactamente, sino que es suficiente una solución aproximada. Por ejemplo en el capítulo que sigue, veremos métodos para sistemas no lineales de ecuaciones en los cuales cada iteración involucra resolver un sistema lineal. Frecuentemente es suficiente resolver el sistema lineal dentro de cada iteración sólo aproximadamente. Se busca en estos casos un balance entre el costo de hallar la solución y el error de aproximación obtenido. Los métodos directos no pueden producir este balance, dado que llegan a la solución recién al completar todas las operaciones que los definen; los cálculos intermedios no dan lugar a soluciones aproximadas.

- A veces tenemos una muy buena aproximación de nuestra solución y queremos encontrar una solución más aproximada a bajo costo. Esto ocurre por ejemplo en ecuaciones diferenciales dependientes del tiempo. A menudo la solución del instante de tiempo anterior es cercana a la solución del próximo instante de tiempo, y es definitivamente provechoso, utilizarla como una aproximación inicial y tratar de mejorarla.

- A veces solamente tenemos una función o rutina que nos da el resultado de hacer el producto matriz vector y no disponemos de la matriz completa, o la tendríamos

con un procedimiento muy costoso. Por ejemplo en aplicaciones del procesamiento digital de señales, a menudo el caso es que sólo tenemos las entradas y las salidas, o sea cuál es la salida, dada una entrada determinada, sin conocer la transformación de manera explícita. Muchos de los métodos iterativos que veremos, solamente necesitan acceso a una función o rutina $x \to Ax$, que permita dado x conocer el resultado Ax, sin necesidad de conocer la matriz completa.

En este capítulo veremos dos tipos de métodos iterativos para la resolución de sistemas lineales. Los primeros se denominan *estacionarios* y consisten en una iteración de la forma $x_{k+1} = Mx_k + c$, con M y c fijos. Los últimos son no estacionarios y están basados en *métodos de descenso*, que sirven para matrices simétricas y definidas positivas (sdp).

En este capítulo usaremos la notación y los resultados básicos de Álgebra Lineal repasados en el Capítulo 2: el producto escalar y el producto tensorial, la escritura de los productos matriciales por filas y por columnas, y la caracterización de las matrices no singulares.

4.1 Normas de vectores y matrices. Número de condición

4.1.1 Normas de vectores

Antes de estudiar los métodos iterativos necesitamos definir *convergencia* en $\mathbb{R}^n$. Lo hacemos definiendo *normas* de vectores y matrices. Recordemos que si X es un espacio vectorial, una norma es una función $\|\cdot\| : X \to \mathbb{R}$ que satisface

(i) $\|x\| \geq 0$, $\forall x \in X$, y $\|x\| = 0$ sii $x = 0$.

(ii) $\|\alpha x\| = |\alpha|\|x\|$, $\forall \alpha \in \mathbb{R}$, $\forall x \in X$. (Homogeneidad)

(iii) $\|x + y\| \leq \|x\| + \|y\|$, $\forall x, y \in X$. (Desigualdad triangular)

También recordemos que dos normas $\|\cdot\|$ y $|||\cdot|||$ en un espacio vectorial X se dicen equivalentes si existe $c > 0$ tal que

$$\frac{1}{c}\|x\| \leq |||x||| \leq c\|x\|, \qquad \forall x \in X.$$

Si el espacio es de dimensión finita, entonces todas las normas son equivalentes. Esto puede demostrarse viendo que cualquier norma es equivalente a la *norma uno*, que, dada una base $\{v_1, v_2, \ldots, v_n\}$ de X se define como

$$\|v\|_1 = \sum_{i=1}^{n} |x_i|, \qquad \text{si } v = \sum_{i=1}^{n} x_i v_i.$$

Las normas más utilizadas en $\mathbb{R}^n$ son las *normas* p, $1 \leq p \leq \infty$, que se definen a continuación para $x = (x_1, x_2, \ldots, x_n)^T$:

$$\|x\|_p = \left(\sum_{i=1}^{n} |x_i|^p\right)^{1/p}, \qquad \text{si } 1 \leq p < \infty,$$

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|, \qquad \text{si } p = \infty.$$

Las más usuales entre estas son:

$$\|x\|_1 = \sum_{i=1}^{n} |x_i|, \qquad \|x\|_2 = \left(\sum_{i=1}^{n} |x_i|^2 \right)^{1/2}, \qquad \|x\|_\infty = \max_{1 \le i \le n} |x_i|.$$

Se deja como ejercicio verificar que las normas $\|\cdot\|_1$ y $\|\cdot\|_\infty$ satisfacen los axiomas de norma (EJERCICIO). Para la norma $\|\cdot\|_2$, la verificación de la desigualdad triangular no es inmediata; para ello es conveniente introducir el siguiente concepto.

Productos escalares.

Un *producto escalar* (o *producto interno*) en un espacio vectorial real X es una función $(\cdot,\cdot) : X \times X \to \mathbb{R}$ que satisface:

(i) $(x, y) = (y, x)$, $\forall x, y \in X$. (Simetría)

(ii) $(\alpha x + \beta y, z) = \alpha(x, z) + \beta(y, z)$, $\forall \alpha, \beta \in \mathbb{R}$, $\forall x, y, z \in X$. (Bilinealidad)

(iii) $(x, x) \ge 0$, $\forall x \in X$, y $(x, x) = 0$ sii $x = 0$. (Definida positiva)

Definiendo $\|x\| = (x, x)^{1/2}$ se obtiene una norma gracias a la siguiente desigualdad fundamental.

Teorema 4.1 (Desigualdad de Cauchy-Schwarz)**.** *Sea $(\cdot,\cdot)$ un producto escalar en X y sea $\|\cdot\|$ la norma que genera. Entonces*

$$|(x, y)| \le \|x\| \, \|y\|, \qquad \forall x, y \in X.$$

Demostración. Si $y = 0$ la desigualdad es trivial. Si $y \neq 0$, para todo $t \in \mathbb{R}$ resulta

$$0 \le \|x - ty\|^2 = (x - ty, x - ty) = \|x\|^2 - 2t(x, y) + t^2\|y\|^2.$$

Eligiendo $t = (x, y)/\|y\|^2$ obtenemos

$$0 \le \|x\|^2 - \frac{(x, y)^2}{\|y\|^2},$$

de donde se sigue la desigualdad. □

Ejemplo 4.2. En $\mathbb{R}^n$, el *producto escalar estándar* es $(x, y) = x^T y = \sum_{i=1}^n x_i y_i$, que genera la norma $\|x\|_2$. La desigualdad de Cauchy-Schwarz toma aquí la forma

$$|x^T y| \le \|x\|_2 \|y\|_2.$$

Más en general, dada $A \in \mathbb{R}^{n \times n}$ simétrica y definida positiva (sdp), la función

$$(x, y)_A = x^T A y$$

es un producto escalar en $\mathbb{R}^n$ (EJERCICIO), que genera la *norma-A*

$$\|x\|_A = (x, x)_A^{1/2} = (x^T A x)^{1/2}.$$

En particular, $\|x\|_I = \|x\|_2$.

Definición 4.3 (Convergencia en $\mathbb{R}^n$)**.** Dada una sucesión $\{x_k\}_{k\in\mathbb{N}} \subset \mathbb{R}^n$. Se dice que x_k tiende a $x \in \mathbb{R}^n$ si $\|x_k - x\| \to 0$ cuando $k \to \infty$, para alguna norma $\|\cdot\|$ de $\mathbb{R}^n$.

Observación 4.4. Puede demostrarse que todas las normas en $\mathbb{R}^n$ son equivalentes (hecho que escapa al interés de este curso). Como consecuencia, si una sucesión converge en alguna norma, entonces converge en todas las normas. En particular $\|x - x_k\|_\infty \to 0$ y luego cada componente $x_k^i \to x^i$, para $i = 1, 2, \ldots, n$, cuando $k \to \infty$.

4.1.2 Normas de matrices

En esta sección hablaremos sobre las normas en el espacio de las matrices. Prestaremos especial atención a las llamadas *normas inducidas*, que se definen como sigue.

Definición 4.5. Dada una norma $\|\cdot\|$ del espacio de vectores $\mathbb{R}^n$, se define la norma inducida por esta como

$$\|A\| = \max_{\substack{x\in\mathbb{R}^n \\ x\neq 0}} \frac{\|Ax\|}{\|x\|}, \qquad \forall A \in \mathbb{R}^{n\times n}.$$

La norma inducida se denota con el mismo símbolo de la norma que la induce, así, por ejemplo

$$\|A\|_1 = \max_{\substack{x\in\mathbb{R}^n \\ x\neq 0}} \frac{\|Ax\|_1}{\|x\|_1} = \max_{\substack{x\in\mathbb{R}^n \\ x\neq 0}} \frac{\sum_{i=1}^n |(Ax)_i|}{\sum_{i=1}^n |x_i|},$$

$$\|A\|_2 = \max_{\substack{x\in\mathbb{R}^n \\ x\neq 0}} \frac{\|Ax\|_2}{\|x\|_2} = \max_{\substack{x\in\mathbb{R}^n \\ x\neq 0}} \frac{\left(\sum_{i=1}^n |(Ax)_i|^2\right)^{1/2}}{\left(\sum_{i=1}^n |x_i|^2\right)^{1/2}},$$

$$\|A\|_\infty = \max_{\substack{x\in\mathbb{R}^n \\ x\neq 0}} \frac{\|Ax\|_\infty}{\|x\|_\infty} = \max_{\substack{x\in\mathbb{R}^n \\ x\neq 0}} \frac{\max_{1\leq i\leq n} |(Ax)_i|}{\max_{1\leq i\leq n} |x_i|}.$$

En MATLAB/OCTAVE. La función `norm` calcula diferentes normas de vectores y matrices. Leer su documentación.

Observación 4.6. Cualquiera sea la norma $\|\cdot\|$ de $\mathbb{R}^n$, la norma inducida de la matriz identidad es 1. En efecto

$$\|I\| = \max_{\substack{x\in\mathbb{R}^n \\ x\neq 0}} \frac{\|Ix\|}{\|x\|} = \max_{\substack{x\in\mathbb{R}^n \\ x\neq 0}} \frac{\|x\|}{\|x\|} = 1.$$

Observación 4.7. Utilizando la *homogeneidad* de la norma puede demostrarse que

$$\|A\| = \max_{\substack{x\in\mathbb{R}^n \\ 0<\|x\|\leq 1}} \frac{\|Ax\|}{\|x\|} = \max_{\substack{x\in\mathbb{R}^n \\ 0<\|x\|\leq 1}} \|Ax\| = \max_{\substack{x\in\mathbb{R}^n \\ \|x\|=1}} \|Ax\|,$$

para toda $A \in \mathbb{R}^{n\times n}$ y toda norma $\|\cdot\|$ de $\mathbb{R}^n$. EJERCICIO.

Un par de propiedades importantes de las normas inducidas se enuncian en el siguiente teorema.

Teorema 4.8 (Consistencia)**.** *Si $\|\cdot\|$ es la norma de $\mathbb{R}^{n\times n}$ inducida por la norma $\|\cdot\|$ de $\mathbb{R}^n$, entonces*

(i) $\|Ax\| \leq \|A\|\|x\|$, $\forall A \in \mathbb{R}^{n\times n}$, $\forall x \in \mathbb{R}^n$;

(ii) $\|AB\| \leq \|A\|\|B\|$, $\forall A, B \in \mathbb{R}^{n\times n}$.

Demostración. EJERCICIO. □

No es difícil verificar (EJERCICIO) que, para $A \in \mathbb{R}^{n\times n}$, resulta

$$\|A\|_1 = \max_{1\leq j\leq n} \sum_{i=1}^{n} |a_{ij}| = \text{el máximo de las sumas por columnas},$$

$$\|A\|_\infty = \max_{1\leq i\leq n} \sum_{j=1}^{n} |a_{ij}| = \text{el máximo de las sumas por filas},$$

$$\|A\|_2 = \max\{\sqrt{\lambda} : \lambda \text{ autovalor de } A^TA\} = \text{máximo } \textit{valor singular} \text{ de } A.$$

En el caso particular de A simétrica, se tiene que

$$\|A\|_2 = \max\{|\lambda| : \lambda \text{ autovalor de } A\}.$$

Esta última afirmación es consecuencia de que si A es simétrica, entonces $A = U\Lambda\bar{U}^T$, con Λ una matriz diagonal que tiene los autovalores de A en la diagonal, y U es *unitaria*, es decir, $\bar{U}^TU = I$. Aquí y en adelante $\bar{U}$ denota la matriz conjugada de U, es decir $(\bar{U})_{ij} = \bar{u}_{ij}$, donde $\bar{u}_{ij}$ es el complejo conjugado de $u_{ij} = (U)_{ij}$.

Otra norma usual de $\mathbb{R}^{n\times n}$, que no es inducida, es la *norma de Frobenius*, definida por

$$\|A\|_F = \left(\sum_{i,j=1}^{n} a_{ij}^2\right)^{1/2} = \sqrt{\text{tr}(A^TA)}.$$

A pesar de no ser inducida, esta norma también cumple que

$$\|AB\|_F \leq \|A\|_F\|B\|_F.$$

Además, si $\{\sigma_i\}_{i=1}^r$ son los valores singulares de A, $\|A\|_F = \left(\sum_{i=1}^{r} \sigma_i^2\right)^{1/2}$.

4.1.3 Número de condición y error relativo

Dada $A \in \mathbb{R}^{n\times n}$ y $b \in \mathbb{R}^n$, consideremos el problema de hallar $x \in \mathbb{R}^n$ tal que $Ax = b$. Supongamos que $\tilde{x} \in \mathbb{R}^n$ es una solución aproximada del sistema. Considerando una norma dada $\|\cdot\|$ de $\mathbb{R}^n$, definimos:

$$\begin{aligned}
\text{error} &= x - \tilde{x},\\
\text{error relativo} &= \frac{\|x-\tilde{x}\|}{\|x\|},\\
\text{residuo} &= A\tilde{x} - b = \tilde{b} - b, \quad \text{si } \tilde{b} = A\tilde{x},\\
\text{residuo relativo} &= \frac{\|\tilde{b}-b\|}{\|b\|}.
\end{aligned}$$

Queremos hallar una estimación para el error relativo $\frac{\|x-\tilde{x}\|}{\|x\|}$ en términos del residuo relativo $\frac{\|\tilde{b}-b\|}{\|b\|}$. Observemos lo siguiente

$$\|\tilde{x} - x\| = \|A^{-1}\tilde{b} - A^{-1}b\| \leq \|A^{-1}\|\|\tilde{b} - b\|,$$

Además,

$$\|Ax\| = \|b\| \quad \Longrightarrow \quad \|b\| \leq \|A\|\|x\|.$$

Luego,

$$\frac{\|\tilde{x} - x\|}{\|x\|} \leq \|A\|\|A^{-1}\|\frac{\|\tilde{b} - b\|}{\|b\|}. \tag{4.1}$$

Análogamente

$$\|\tilde{b} - b\| = \|A\tilde{x} - Ax\| \leq \|A\|\|\tilde{x} - x\|,$$

y

$$\|x\| = \|A^{-1}b\| \leq \|A^{-1}\|\|b\|.$$

Por lo tanto

$$\frac{1}{\|A\|\|A^{-1}\|}\frac{\|\tilde{b} - b\|}{\|b\|} \leq \frac{\|\tilde{x} - x\|}{\|x\|}. \tag{4.2}$$

De (4.1)–(4.2) obtenemos que

$$\frac{1}{\|A\|\|A^{-1}\|}\frac{\|\tilde{b} - b\|}{\|b\|} \leq \frac{\|\tilde{x} - x\|}{\|x\|} \leq \|A\|\|A^{-1}\|\frac{\|\tilde{b} - b\|}{\|b\|}. \tag{4.3}$$

Definición 4.9. Dada una norma inducida $\|\cdot\|$ en el espacio de las matrices de $n \times n$, se define el número de condición para esa norma como

$$\kappa(A) = \|A\|\|A^{-1}\|, \qquad A \in \mathbb{R}^{n\times n}.$$

Resumimos lo demostrado hasta ahora en un Lema:

Lema 4.10. *Si $x \in \mathbb{R}^n \setminus \{0\}$ es la solución de $Ax = b$, entonces, cualquiera sea $\tilde{x} \in \mathbb{R}^n$, se cumple que*

$$\frac{1}{\kappa(A)}\frac{\|\tilde{b} - b\|}{\|b\|} \leq \frac{\|\tilde{x} - x\|}{\|x\|} \leq \kappa(A)\frac{\|\tilde{b} - b\|}{\|b\|},$$

para $\tilde{b} = A\tilde{x}$.

En MATLAB/OCTAVE. La función `cond` calcula el número de condición para diferentes normas y matrices. Leer su documentación, y la de la función `rcond`.

Observación 4.11. El número de condición siempre es mayor o igual a uno:

$$\kappa(A) = \|A\|\|A^{-1}\| \geq \|AA^{-1}\| = \|I\| = 1.$$

Cuando $\kappa(A)$ es pequeño, o cercano a uno, $\kappa(A) \cong 1$ resulta

$$\frac{\|\tilde{x} - x\|}{\|x\|} \cong \frac{\|\tilde{b} - b\|}{\|b\|}$$

Es decir, pequeñas perturbaciones en el lado derecho de la ecuación, producen pequeños cambios en las soluciones. En este caso decimos que el problema $Ax = b$ está *bien condicionado*.

Observación 4.12. Dada la solución x de $Ax = b$, si $\tilde{x}$ es una aproximación de x, entonces

$$\underbrace{\frac{\|\tilde{x} - x\|}{\|x\|}}_{\text{desconocido}} \leq \kappa(A) \underbrace{\frac{\|A\tilde{x} - b\|}{\|b\|}}_{\text{calculable}}.$$

El lado derecho de la desigualdad anterior se utiliza en la implementación de criterios de parada en algunos métodos iterativos.

Observación 4.13. Observemos que multiplicar una matriz por una constante arbitraria no nula, no afecta el número de condición:

$$\kappa(\alpha A) = \|\alpha A\|\|(\alpha A)^{-1}\| = |\alpha|\|A\|\frac{1}{|\alpha|}\|A^{-1}\| = \kappa(A).$$

Existe una estrecha relación entre el número de condición y los autovalores cuando se considera la norma $\|\cdot\|_2$ para matrices simétricas, la misma está dada en el siguiente lema.

Lema 4.14. *Si $A \in \mathbb{R}^{n\times n}$ es simétrica, entonces $\kappa_2(A) = \frac{\lambda_{\max}}{\lambda_{\min}}$, donde $\lambda_{\max}$ y $\lambda_{\min}$ denotan el autovalor de módulo máximo y mínimo de A, respectivamente.*

Demostración. Sea $A \in \mathbb{R}^{n\times n}$ una matriz simétrica, entonces $\|A\|_2 = \rho(A) = \max\{|\lambda| : \lambda \in \sigma(A)\} =: \lambda_{\max}$. Como A es simétrica, A^{-1} resulta simétrica y entonces

$$\begin{aligned}\|A^{-1}\|_2 &= \rho(A^{-1}) = \max\{|\lambda| : \lambda \in \sigma(A^{-1})\} \\ &= \max\{|\lambda| : \lambda^{-1} \in \sigma(A)\} = \max\{|\lambda|^{-1} : \lambda \in \sigma(A)\} \\ &= \frac{1}{\min\{|\lambda| : \lambda \in \sigma(A)\}} =: \frac{1}{\lambda_{\min}}.\end{aligned}$$

Por lo tanto $\kappa_2(A) = \|A\|_2\|A^{-1}\|_2 = \lambda_{\max}\frac{1}{\lambda_{\min}}$. □

4.1.4 Número de condición para matrices rectangulares

La definición de número de condición dada anteriormente se restringe a matrices cuadradas e invertibles. Existe una extensión natural al caso rectangular, motivada por el estudio de *sistemas sobredeterminados*. Dado $A \in \mathbb{R}^{n\times m}$ con $n \geq m$ y $b \in \mathbb{R}^n$, consideramos el *problema de cuadrados mínimos*

$$\min_{x\in\mathbb{R}^m} \|Ax - b\|_2.$$

Cuando A tiene rango completo por columnas, este problema tiene solución única, caracterizada por las ecuaciones normales $A^TAx = A^Tb$.

Pseudoinversa y valores singulares.

La *descomposición en valores singulares* (SVD) de $A \in \mathbb{R}^{n\times m}$ con $n \geq m$ es

$$A = U\Sigma V^T,$$

con $U \in \mathbb{R}^{n\times n}$ y $V \in \mathbb{R}^{m\times m}$ ortogonales, y

$$\Sigma = \begin{bmatrix} \operatorname{diag}(\sigma_1, \sigma_2, \ldots, \sigma_r, 0, \ldots, 0) \\ 0 \end{bmatrix} \in \mathbb{R}^{n\times m},$$

donde $r = \operatorname{rango}(A)$ y $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ son los *valores singulares* de A, definidos como las raíces cuadradas positivas de los autovalores de A^TA. Notemos que $\|A\|_2 = \sigma_1$.

Si A tiene rango completo por columnas ($r = m$), su *pseudoinversa de Moore-Penrose* es

$$A^+ = (A^TA)^{-1}A^T \in \mathbb{R}^{m\times n},$$

la cual satisface $A^+A = I_m$ y puede escribirse en términos de la SVD como $A^+ = V\Sigma^+U^T$, donde $\Sigma^+ = \begin{bmatrix}\operatorname{diag}(\sigma_1^{-1}, \ldots, \sigma_m^{-1}) & 0\end{bmatrix}$. En particular, $\|A^+\|_2 = 1/\sigma_m$.

Definición 4.15. Sea $A \in \mathbb{R}^{n\times m}$ con $n \geq m$ y rango completo por columnas. El *número de condición* de A es

$$\kappa_2(A) = \|A\|_2\|A^+\|_2 = \frac{\sigma_1}{\sigma_m},$$

donde $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_m > 0$ son los valores singulares de A.

Observación 4.16. Esta definición coincide con la anterior cuando A es cuadrada e invertible: en ese caso $A^+ = A^{-1}$, y los valores singulares de A son las raíces cuadradas de los autovalores de A^TA.

La siguiente relación, simple pero de enorme importancia práctica, vincula el número de condición de A con el de la matriz de coeficientes de las ecuaciones normales.

Lema 4.17. *Sea $A \in \mathbb{R}^{n\times m}$ con $n \geq m$ y rango completo por columnas. Entonces*

$$\kappa_2(A^TA) = \kappa_2(A)^2.$$

Demostración. Sea $A = U\Sigma V^T$ la SVD de A. Entonces $A^TA = V(\Sigma^T\Sigma)V^T$, con $\Sigma^T\Sigma = \operatorname{diag}(\sigma_1^2, \ldots, \sigma_m^2)$. Como A^TA es simétrica definida positiva, sus autovalores coinciden con sus valores singulares, y por el Lema anterior

$$\kappa_2(A^TA) = \frac{\sigma_1^2}{\sigma_m^2} = \left(\frac{\sigma_1}{\sigma_m}\right)^2 = \kappa_2(A)^2. \qquad \square$$

Observación 4.18. Este resultado tiene una consecuencia práctica importante. Si $\kappa_2(A)$ es grande, entonces $\kappa_2(A^TA) = \kappa_2(A)^2$ es enormemente mayor. Resolver el problema de cuadrados mínimos mediante las ecuaciones normales $(A^TA)x = A^Tb$ obliga a trabajar con una matriz cuyo número de condición es el cuadrado del de A, lo que puede provocar serios problemas de estabilidad numérica. Por esta razón, en la práctica se prefiere utilizar la factorización QR de A (véase el Capítulo 3), que tiene mejor comportamiento numérico.

Observación 4.19. Análogamente al Lema 4.10, el número de condición controla la sensibilidad de la solución de cuadrados mínimos a perturbaciones en b. Si $x^* = A^+b$ y $\tilde{x} = A^+(b + \delta b)$, entonces

$$\|\tilde{x} - x^*\|_2 \leq \|A^+\|_2\|\delta b\|_2,$$

y en el caso de un sistema compatible ($Ax^* = b$):

$$\frac{\|\tilde{x} - x^*\|_2}{\|x^*\|_2} \leq \kappa_2(A)\frac{\|\delta b\|_2}{\|b\|_2}.$$

En MATLAB/OCTAVE. La función `cond(A)` calcula el número de condición también para matrices rectangulares (mediante la SVD). La función `svd(A)` devuelve la descomposición $A = U\Sigma V^T$.

4.1.5 Espectro y radio espectral

Dada una matriz $A \in \mathbb{R}^{n\times n}$ se define su *espectro* $\sigma(A)$ como el conjunto de autovalores de A, así

$$\sigma(A) = \{\lambda \in \mathbb{C} : \lambda \text{ es autovalor de } A\}.$$

El *radio espectral* $\rho(A)$ de A es el máximo módulo de sus autovalores, más precisamente

$$\rho(A) = \max\{|\lambda| : \lambda \in \sigma(A)\}.$$

Por lo dicho anteriormente,

$$\text{si } A \text{ es simétrica} \quad \Longrightarrow \quad \rho(A) = \|A\|_2.$$

El radio espectral juega un papel fundamental en el estudio de métodos iterativos para sistemas lineales, principalmente debido al siguiente teorema:

Teorema 4.20 (Caracterización del radio espectral)**.** *Sea $A \in \mathbb{R}^{n\times n}$, entonces*

$$\rho(A) = \inf\{\|A\| : \|\cdot\| \textit{ es una norma inducida}\}.$$

Para demostrar este teorema utilizaremos el siguiente teorema, cuya demostración postponemos hasta el final de la sección.

Teorema 4.21 (Descomposición de Schur)**.** *Sea $A \in \mathbb{C}^{n\times n}$. Sean $\lambda_1, \lambda_2, \ldots \lambda_n$ los autovalores de A contados con su multiplicidad algebraica, es decir que son* todos *los ceros de $p(\lambda) := \det(\lambda I - A)$. Entonces existe una matriz unitaria U ($\bar{U}^T U = I$) tal que $UA\bar{U}^T = T$, donde T es triangular superior y* $\operatorname{diag}(T) = (\lambda_1, \lambda_2, \ldots, \lambda_n)$.

Observación 4.22. Si los autovalores de A son reales, entonces existe una matriz real U ortogonal ($U^T U = I$) tal que $UAU^T = T$, con T triangular superior (real) que tiene los autovalores de A en la diagonal. Además, vale la pena enfatizar que esta descomposición es cierta aunque A no sea diagonalizable.

A continuación utilizaremos el Teorema 4.21 de descomposición de Schur para demostrar el Teorema 4.20 de caracterización del radio espectral.

Demostración del Teorema 4.20. Es fácil ver que $\rho(A) \le \|A\|$ para toda norma inducida $\|\cdot\|$ y cualquier matriz cuadrada A (EJERCICIO). Lo más difícil es ver que dada $A \in \mathbb{R}^{n\times n}$, para todo $\varepsilon > 0$ existe una norma inducida $\|\cdot\|$ tal que $\|A\| < \rho(A) + \varepsilon$.

Sean entonces $A \in \mathbb{R}^{n\times n}$ y $\varepsilon > 0$ dados. Por el Teorema 4.21 de descomposición de Schur existe U unitaria tal que $UA\bar{U}^T = T$ con T triangular superior tal que

$$\operatorname{diag}(T) = (\lambda_1, \lambda_2, \ldots, \lambda_n), \quad \text{y} \quad \lambda_i, \quad i = 1, 2, \ldots, n \quad \text{son los autovalores de } A.$$

Entonces T es de la forma

$$T = \begin{bmatrix} \lambda_1 & t_{12} & t_{13} & \dots & t_{1n} \\ 0 & \lambda_2 & t_{23} & \dots & t_{2n} \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \dots & 0 & \lambda_{n-1} & t_{(n-1)n} \\ 0 & \dots & 0 & 0 & \lambda_n \end{bmatrix}.$$

Para $z \in \mathbb{R}$, $z > 0$, definimos

$$D_z = \operatorname{diag}(z, z^2, \dots, z^n) = \begin{bmatrix} z & 0 & 0 & \dots & 0 \\ 0 & z^2 & 0 & \dots & 0 \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & 0 & \dots & z^{n-1} & 0 \\ 0 & 0 & \dots & 0 & z^n \end{bmatrix}$$

Así,

$$D_z U A \bar{U}^T = D_z T = \begin{bmatrix} z\lambda_1 & zt_{12} & zt_{13} & \dots & zt_{1n} \\ 0 & z^2\lambda_2 & z^2 t_{23} & \dots & z^2 t_{2n} \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \dots & 0 & z^{n-1}\lambda_{n-1} & z^{n-1} t_{(n-1)n} \\ 0 & \dots & 0 & 0 & z^n \lambda_n \end{bmatrix},$$

y

$$D_z U A \bar{U}^T D_z^{-1} = D_z T D_z^{-1} = \begin{bmatrix} \lambda_1 & z^{-1}t_{12} & z^{-2}t_{13} & \dots & z^{-(n-1)}t_{1n} \\ 0 & \lambda_2 & z^{-1}t_{23} & \dots & z^{-(n-2)}t_{2n} \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \dots & 0 & \lambda_{n-1} & z^{-1}t_{(n-1)n} \\ 0 & \dots & 0 & 0 & \lambda_n \end{bmatrix},$$

Elegimos ahora z suficientemente grande de manera que

$$\max_{1 \le j \le n} \sum_{i=1}^{j-1} z^{i-j} |t_{ij}| < \varepsilon,$$

y entonces

$$\left\| D_z U A \bar{U}^T D_z^{-1} \right\|_1 = \max_{1 \le j \le n} \left(|\lambda_j| + \sum_{i=1}^{j-1} z^{i-j} |t_{ij}| \right) < \rho(A) + \varepsilon.$$

Faltaría ver que $\left\| D_z U A \bar{U}^T D_z^{-1} \right\|_1$ es una norma inducida de A. Definimos entonces la norma $\|x\| = \left\| D_z U x \right\|_1$ para $x \in \mathbb{R}^n$ (que resulta una norma, verificar), y observemos que

$$\|A\| = \max_{\substack{x \in \mathbb{R}^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|} = \max_{\substack{x \in \mathbb{R}^n \\ x \neq 0}} \frac{\left\| D_z U A x \right\|_1}{\left\| \underbrace{D_z U x}_{y} \right\|_1} = \max_{\substack{y \in \mathbb{R}^n \\ y \neq 0}} \frac{\left\| D_z U A (D_z U)^{-1} y \right\|_1}{\left\| y \right\|_1} = \left\| D_z U A \bar{U}^T D_z^{-1} \right\|_1.$$

□

La importancia del *radio espectral* queda plasmada en el siguiente teorema.

Teorema 4.23. *Sea $A \in \mathbb{R}^{n\times n}$, entonces las siguientes afirmaciones son equivalentes:*

(1) $\rho(A) < 1$.

(2) $\|A\| < 1$ *para alguna norma inducida.*

(3) $\lim_{k\to\infty} \|A^k\| = 0$, *para toda norma inducida* $\|\cdot\|$.

(4) $\lim_{k\to\infty} A^k x = 0$, *para todo vector* $x \in \mathbb{R}^n$.

Demostración. (1) $\Rightarrow$ (2) es inmediato por el Teorema 4.20.

(2) $\Rightarrow$ (3). Supongamos que $\|A\|_* < 1$ para alguna norma inducida $\|\cdot\|_*$. Sea $\|\cdot\|$ una norma inducida cualquiera. Entonces, como todas las normas son equivalentes, por ser el espacio de las matrices de dimensión finita, existe $c > 0$ tal que

$$\|A^k\| \le c\|A^k\|_*, \qquad \forall k \in \mathbb{N}_0.$$

Por el Teorema 4.8 de consistencia, resulta que $\|A^k\|_* \le \|A\|_*^k$ y luego

$$\|A^k\| \le c\|A^k\|_* \le c\|A\|_*^k \to 0, \quad \text{cuando } k \to \infty.$$

(3) $\Rightarrow$ (4). Sea $x \in \mathbb{R}^n$ y sea $\|\cdot\|$ una norma en $\mathbb{R}^n$ y también su norma inducida en $\mathbb{R}^{n\times n}$. Entonces, por el Teorema 4.8 de consistencia

$$\|A^k x - 0\| = \|A^k x\| \le \|A^k\|\|x\| \to 0, \quad \text{cuando } k \to \infty.$$

(4) $\Rightarrow$ (1). Sea $\lambda \in \sigma(A)$ y sea x un autovector asociado a λ, luego

$$Ax = \lambda x, \qquad \text{y} \qquad A^k x = \lambda^k x.$$

Así,

$$\|A^k x\| = |\lambda|^k \|x\|$$

para cualquier norma $\|\cdot\|$ de $\mathbb{R}^n$. Por (4), $\|A^k x\| \to 0$ y por ende $|\lambda|^k\|x\| \to 0$. Como x es un autovector, es no nulo, y por lo tanto $|\lambda|^k \to 0$ cuando $k \to \infty$. Por lo tanto $|\lambda| < 1$. Como $\lambda \in \sigma(A)$ era arbitrario, resulta $\rho(A) = \max_{\lambda\in\sigma(A)} |\lambda| < 1$. □

Teorema 4.24. *Sea $A \in \mathbb{R}^{n\times n}$. Entonces, cualquiera sea la norma inducida $\|\cdot\|$, resulta*

$$\rho(A) = \lim_{k\to\infty} \|A^k\|^{1/k}.$$

Demostración. Veamos primero que $\rho(A) \le \|A^k\|^{1/k}$. Sea $\lambda \in \sigma(A)$ y sea x un autovector asociado a λ. Entonces

$$Ax = \lambda x \implies A^k x = \lambda^k x \implies \|A^k x\| = |\lambda|^k\|x\|$$
$$\implies |\lambda|^k = \frac{\|A^k x\|}{\|x\|} \le \|A^k\| \implies |\lambda| \le \|A^k\|^{1/k} \implies \rho(A) \le \|A^k\|^{1/k}.$$

Veamos ahora que el límite de $\|A^k\|^{1/k}$ es $\rho(A)$. Sea $\varepsilon > 0$ y definimos

$$\tilde{A} = \frac{1}{\rho(A)+\varepsilon}A \quad \Longrightarrow \quad \rho(\tilde{A}) = \frac{1}{\rho(A)+\varepsilon}\rho(A) = \frac{\rho(A)}{\rho(A)+\varepsilon} < 1.$$

Por el Teorema anterior, $\lim_{k\to\infty} \|\tilde{A}^k\| = 0$ y por lo tanto, existe $k_0 \in \mathbb{N}$ tal que

$$\|\tilde{A}^k\| = \frac{\|A^k\|}{(\rho(A)+\varepsilon)^k} < 1, \quad \forall k \geq k_0.$$

Es decir que dado $\varepsilon > 0$, existe $k_0 \in \mathbb{N}$ tal que

$$\rho(A) \leq \|A^k\|^{1/k} \leq \rho(A) + \varepsilon, \quad \forall k \geq k_0.$$

O sea, $\lim_{k\to\infty} \|A^k\|^{1/k} = \rho(A)$. □

Demostración del Teorema 4.21 de descomposición de Schur.

Demostración del Teorema 4.21. Haremos la demostración por inducción sobre el orden n de la matriz. Si $n = 1$, entonces $A = [a_{11}]$, $\lambda_1 = a_{11}$ y el teorema es válido con $T = [a_{11}]$ y $U = [1]$.

Supongamos que la afirmación del teorema es válida para $n-1$ con $n > 1$ y demostrémosla para n.

Sean $\lambda_1, \lambda_2, \ldots, \lambda_n$ los autovalores de A y sea x un autovector correspondiente a λ_1 con $\|x\|_2^2 = \bar{x}^T x = 1$ y $x_1 \geq 0$; notemos que si λ_1 es complejo, entonces algunas componentes de x pueden ser complejas, en ese caso, si x_1 no fuera un número real no-negativo, dividimos todas las componentes de x por x_1 y luego lo normalizamos. Utilizaremos la transformación de Householder

$$H = I - u\bar{u}^T, \qquad \text{con} \quad u = \frac{1}{\sqrt{1+x_1}}(x + e_1),$$

que, como vimos antes, satisface

$$\bar{H}^T = H = H^{-1}, \text{ (H es unitaria)} \qquad \text{y} \quad Hx = -e_1, \quad He_1 = -x.$$

Entonces $HA\bar{H}^T = HAH$ y

$$\text{col}_1(HA\bar{H}^T) = HAHe_1 = -HAx = -\lambda_1 Hx = \lambda_1 e_1.$$

Es decir,

$$HA\bar{H}^T = \begin{bmatrix} \lambda_1 & v^T \\ 0 & \tilde{A} \end{bmatrix}, \quad \text{con} \quad v \in \mathbb{R}^{n-1} \quad \text{y} \quad \tilde{A} \in \mathbb{R}^{(n-1)\times(n-1)}.$$

Además,

$$\lambda \in \sigma(A) \quad \Longleftrightarrow \quad \lambda \in \sigma(HA\bar{H}^T) \quad \Longleftrightarrow \quad \lambda = \lambda_1 \text{ ó } \lambda \in \sigma(\tilde{A}),$$

pues $\det(\lambda I - HA\bar{H}^T) = (\lambda - \lambda_1)\det(\lambda I - \tilde{A})$. Por lo tanto, $\sigma(\tilde{A}) = \{\lambda_2, \ldots, \lambda_n\}$.

Por la hipótesis inductiva, existe $\tilde{U}$ unitaria (de orden $n-1$) tal que

$$\tilde{U}\tilde{A}\bar{\tilde{U}}^T = \tilde{T}, \quad \text{con } \tilde{T} \text{ triangular superior y } \operatorname{diag}(\tilde{T}) = (\lambda_2, \ldots, \lambda_n).$$

Es decir, $\bar{\tilde{U}}^T\tilde{T}\tilde{U} = \tilde{A}$, y luego

$$HA\bar{H}^T = \begin{bmatrix} \lambda_1 & v^T \\ 0 & \bar{\tilde{U}}^T\tilde{T}\tilde{U} \end{bmatrix} = \begin{bmatrix} 1 & 0^T \\ 0 & \bar{\tilde{U}}^T \end{bmatrix} \begin{bmatrix} \lambda_1 & v^T\bar{\tilde{U}}^T \\ 0 & \tilde{T} \end{bmatrix} \begin{bmatrix} 1 & 0^T \\ 0 & \tilde{U} \end{bmatrix},$$

y finalmente

$$\underbrace{\begin{bmatrix} 1 & 0^T \\ 0 & \tilde{U} \end{bmatrix}}_{U} HA\bar{H}^T \underbrace{\begin{bmatrix} 1 & 0^T \\ 0 & \bar{\tilde{U}}^T \end{bmatrix}}_{\bar{U}^T} = \underbrace{\begin{bmatrix} \lambda_1 & v^T\bar{\tilde{U}}^T \\ 0 & \tilde{T} \end{bmatrix}}_{T}.$$

□

4.2 Métodos iterativos estacionarios

Queremos diseñar métodos iterativos para resolver el problema

$$Ax = b,$$

con $A \in \mathbb{R}^{n\times n}$ no singular y $b \in \mathbb{R}^n$ dados.

Método de Richardson.

Una primera idea surge de observar que, si $\alpha \neq 0$,

$$Ax = b \iff x = x - \alpha(Ax - b) \iff x = (I - \alpha A)x + \alpha b,$$

para algún número $\alpha \in \mathbb{R}$. A partir de esta igualdad podemos definir la iteración

$$x_{k+1} = \underbrace{(I - \alpha A)}_{\text{matriz de iteración}} x_k + \alpha b, \qquad k = 0, 1, 2, \ldots,$$

con $x_0 \in \mathbb{R}^n$ dado. Esta iteración se conoce como *método de Richardson*.

Método de Jacobi.

Otra opción surge de considerar que

$$Ax = b \iff \begin{aligned} a_{11}x_1 &= b_1 - (a_{12}x_2 + \cdots + a_{1n}x_n) \\ a_{22}x_2 &= b_2 - (a_{21}x_1) - (a_{23}x_3 + \cdots + a_{2n}x_n) \\ a_{33}x_3 &= b_3 - (a_{31}x_1 + a_{32}x_2) - (a_{34}x_4 + \cdots + a_{3n}x_n) \\ &\vdots \\ a_{nn}x_n &= b_n - (a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{n(n-1)}x_{n-1}). \end{aligned}$$

Esto sugiere, por ejemplo, el siguiente método iterativo. Dado x_0, repetir,

$$\begin{aligned}
x^1_{k+1} &= \left[b_1 - (a_{12}x^2_k + \cdots + a_{1n}x^n_k)\right]/a_{11}\\
x^2_{k+1} &= \left[b_2 - (a_{21}x^1_k) - (a_{23}x^3_k + \cdots + a_{2n}x^n_k)\right]/a_{22}\\
x^3_{k+1} &= \left[b_3 - (a_{31}x^1_k + a_{32}x^2_k) - (a_{34}x^4_k + \cdots + a_{3n}x^n_k)\right]/a_{33}, \qquad k = 0, 1, 2, \ldots.\\
&\vdots\\
x^n_{k+1} &= \left[b_n - (a_{n1}x^1_k + a_{n2}x^2_k + \cdots + a_{n(n-1)}x^{n-1}_k)\right]/a_{nn}
\end{aligned}$$

Este método iterativo se conoce como *método de Jacobi*.

Si escribimos la matriz $A = L+D+U$ con L triangular inferior con ceros en la diagonal, U triangular superior con ceros en la diagonal y D diagonal, entonces la iteración del método de Jacobi puede escribirse en forma matricial como

$$x_{k+1} = D^{-1}[b - (L+U)x_k] = \underbrace{-D^{-1}(L+U)}_{\text{matriz de iteración}}x_k + D^{-1}b,$$

notando que por ser D diagonal, D^{-1} no es costosa de calcular.

Método de Gauss-Seidel.

Si miramos el método de Jacobi, y pensamos en una implementación secuencial donde se calcula primero x^1_{k+1}, luego x^2_{k+1}, y así sucesivamente, uno podría pensar que si sabe que el método converge, entonces x^1_{k+1} es *mejor* que x^1_k, y entonces proponer que para calcular x^2_{k+1} se utilice x^1_{k+1} en su lugar. Si la misma idea se aplica para el cálculo de x^3_{k+1}, y los que siguen, resulta el método de Gauss-Seidel:

$$\begin{aligned}
x^1_{k+1} &= \left[b_1 - (a_{12}x^2_k + \cdots + a_{1n}x^n_k)\right]/a_{11}\\
x^2_{k+1} &= \left[b_2 - (a_{21}x^1_{k+1}) - (a_{23}x^3_k + \cdots + a_{2n}x^n_k)\right]/a_{22}\\
x^3_{k+1} &= \left[b_3 - (a_{31}x^1_{k+1} + a_{32}x^2_{k+1}) - (a_{34}x^4_k + \cdots + a_{3n}x^n_k)\right]/a_{33}.\\
&\vdots\\
x^n_{k+1} &= \left[b_n - (a_{n1}x^1_{k+1} + a_{n2}x^2_{k+1} + \cdots + a_{n(n-1)}x^{n-1}_{k+1})\right]/a_{nn}
\end{aligned}$$

Si descomponemos $A = L + D + U$ como antes, esta iteración puede verse en forma matricial como

$$x_{k+1} = \underbrace{-(L+D)^{-1}U}_{\text{matriz de iteración}}x_k + (L+D)^{-1}b,$$

Método de Sobrerrelajación Sucesiva (SOR).

Dado un número $\omega \in \mathbb{R} \setminus \{0\}$, consideramos la siguiente *partición* de A:

$$A = (\frac{1}{\omega}D + L) + (\frac{\omega - 1}{\omega}D + U),$$

con $A = L + D + U$ como antes. Esto nos conduce al método de *SOR* que consiste en

$$\begin{aligned} x_{k+1} &= (\frac{1}{\omega}D + L)^{-1}[b - (\frac{\omega - 1}{\omega}D + U)x_k] \\ &= \underbrace{-(\frac{1}{\omega}D + L)^{-1}(\frac{\omega - 1}{\omega}D + U)}_{\text{matriz de iteración}} x_k + (\frac{1}{\omega}D + L)^{-1}b. \end{aligned}$$

Observemos que el caso $\omega = 1$ coincide con el método de Gauss-Seidel.

Los métodos descritos son todos métodos de la forma

$$x_{k+1} = Mx_k + c,$$

con M y c dados. En el siguiente teorema se establece una condición necesaria y suficiente sobre M para que tal iteración converja a partir de cualquier x_0.

Teorema 4.25. *Sea $M \in \mathbb{R}^{n\times n}$. Entonces, dado $c \in \mathbb{R}^n$, la iteración*

$$x_{k+1} = Mx_k + c, \qquad k = 0, 1, \ldots,$$

converge para cualquier x_0 inicial si y sólo si $\rho(M) < 1$. Además, si $\rho(M) < 1$, la iteración converge a la única solución de $x = Mx + c$.

Demostración. ($\Leftarrow$): Si $\rho(M) < 1$ entonces existe una norma inducida $\|\cdot\|$ tal que $\|M\| < 1$. Veamos que $I - M$ es invertible para concluir que existe única solución de $x = Mx + c$ y luego demostrar que x_k converge a x.

Observemos que como $\|M\| < 1$ entonces

$$\sum_{k=0}^{N} \|M^k\| \leq \sum_{k=0}^{N} \|M\|^k \leq \sum_{k=0}^{\infty} \|M\|^k = \frac{1}{1 - \|M\|} < \infty,$$

y entonces $\sum_{k=0}^{\infty} M^k$ converge absolutamente. Definimos $N = \sum_{k=0}^{\infty} M^k$ y vemos que

$$N(I - M) = N - NM = \sum_{k=0}^{\infty} M^k - \sum_{k=0}^{\infty} M^k M = \sum_{k=0}^{\infty} M^k - \sum_{k=1}^{\infty} M^k = I.$$

Por lo tanto $N = (I - M)^{-1}$ y $I - M$ es invertible. Luego el sistema

$$x = Mx + c \qquad \Longleftrightarrow \qquad (I - M)x = c$$

tiene solución única que llamamos x. Veamos que cualquiera sea $x_0 \in \mathbb{R}^n$, si definimos

$$x_{k+1} = Mx_k + c, \qquad k = 0, 1, 2, \ldots,$$

resulta que $x_k \to x$. Restando la ecuación para x y la definición de x_k obtenemos la ecuación del error

$$(x_{k+1} - x) = M(x_k - x) = M^2(x_{k-1} - x) = M^{k+1}(x_0 - x).$$

Por lo tanto

$$\|x_{k+1} - x\| \leq \|M^{k+1}\|\|x_0 - x\| \leq \|M\|^{k+1}\|x_0 - x\| \longrightarrow 0 \quad \text{cuando } k \to \infty.$$

($\Rightarrow$): Si el método $x_{k+1} = Mx_k + c$ converge a partir de cualquier x_0, debe converger siempre a x solución de $x = Mx + c$. Si converge para cualquier $c \in \mathbb{R}^n$ dado, entonces el sistema $(I - M)x = c$ tiene solución para todo c por lo que, fijado el c, la solución es única. Resumiendo, dado $c \in \mathbb{R}^n$, la iteración $x_{k+1} = Mx_k + c$ converge, a partir de cualquier x_0, al mismo x, solución única de $x = Mx + c$. Luego

$$x_k - x = M^k(x_0 - x) \longrightarrow 0, \quad \text{cuando } k \to \infty,$$

cualquiera sea x_0. Esto implica que $M^k y \to 0$ para todo $y \in \mathbb{R}^n$ y por el Teorema 4.23 resulta $\rho(M) < 1$. □

Observación 4.26. Notemos que por el Teorema 4.23, la condición $\rho(M) < 1$ es equivalente a que exista una norma inducida $\|\cdot\|$ tal que $\|M\| < 1$.

Observación 4.27. La norma $\|M\| < 1$ da también una noción de la *reducción del error* en cada iteración, pues

$$\|x - x_{k+1}\| \leq \|M\|\|x - x_k\|, \quad k = 0, 1, 2, \ldots.$$

Así, la convergencia en la norma $\|\cdot\|$ será más rápida cuanto más pequeño sea $\|M\|$.

Para demostrar, bajo ciertas condiciones, que los métodos de Jacobi, Gauss-Seidel, SOR y Richardson convergen, veremos que la matriz de iteración correspondiente tiene alguna norma inducida menor a uno.

4.2.1 Convergencia del método de Jacobi

La convergencia del método de Jacobi está garantizada para matrices *estrictamente diagonalmente dominantes*.

Definición 4.28. Una matriz $A \in \mathbb{R}^{n\times n}$ se dice *estrictamente diagonalmente dominante* (edd) si

$$|a_{ii}| > \sum_{j\neq i} |a_{ij}|, \qquad \text{para todo } i = 1, 2, \ldots, n.$$

Teorema 4.29. *Si A es una matriz estrictamente diagonalmente dominante (edd), entonces A es invertible, y dado $b \in \mathbb{R}^n$ el método de Jacobi*

$$x_{k+1} = -D^{-1}(L + U)x_k + \underbrace{D^{-1}b}_{c}, \qquad k = 0, 1, \ldots,$$

converge a la única solución de $Ax = b$ a partir de cualquier iteración inicial x_0.

Además,

$$\|x - x_{k+1}\|_\infty \leq \mu_J\|x - x_k\|_\infty, \quad k = 0, 1, 2, \ldots,$$

con $\mu_J = \max_{1\leq i\leq n} \frac{\sum_{j\neq i}|a_{ij}|}{|a_{ii}|}$, que satisface $\mu_J < 1$ por ser A edd.

Demostración. La demostración consiste en verificar que la norma inducida por la norma infinito de la matriz de iteración del método de Jacobi es menor que uno, usando que A es edd.

Recordemos que la iteración de Jacobi es

$$x_{k+1} = D^{-1}[b - (L+U)x_k] = \underbrace{-D^{-1}(L+U)}_{M_J} x_k + \underbrace{D^{-1}b}_{c},$$

y observemos que

$$M_J = -D^{-1}(L+U) = -\begin{bmatrix} 0 & \frac{a_{12}}{a_{11}} & \frac{a_{13}}{a_{11}} & \cdots & \frac{a_{1n}}{a_{11}} \\ \frac{a_{21}}{a_{22}} & 0 & \frac{a_{23}}{a_{22}} & \cdots & \frac{a_{2n}}{a_{22}} \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ \vdots & & \ddots & \ddots & \\ \frac{a_{n1}}{a_{nn}} & \cdots & \cdots & \frac{a_{n(n-1)}}{a_{nn}} & 0 \end{bmatrix},$$

o más precisamente

$$(M_J)_{ii} = 0, \qquad (M_J)_{ij} = -\frac{a_{ij}}{a_{ii}}, \quad \text{si } i \neq j.$$

La norma infinito de esta matriz es

$$\|M_J\|_\infty = \max_{1\leq i\leq n} \sum_{j=1}^{n} |(M_J)_{ij}| = \max_{1\leq i\leq n} \sum_{j\neq i} \frac{|a_{ij}|}{|a_{ii}|} = \max_{1\leq i\leq n} \frac{\sum_{j\neq i} |a_{ij}|}{|a_{ii}|} < 1,$$

por ser A edd. Esto implica que el problema $x = M_J x + c$ tiene solución única para cada $c \in \mathbb{R}^n$, y como es equivalente a $Ax = b$, se tiene que A es no singular. □

Sin usar la maquinaria abstracta de normas de matrices también se puede demostrar la convergencia de este método, de la siguiente manera más elemental.

Demostración alternativa del Teorema 4.29. Sea $A \in \mathbb{R}^{n\times n}$ edd, sea $b \in \mathbb{R}^n$ dado y sea $x_0 \in \mathbb{R}^n$ cualquier aproximación inicial. Recordemos que por definición, la iteración de Jacobi es

$$x^i_{k+1} = \frac{b_i}{a_{ii}} - \sum_{j\neq i} \frac{a_{ij}}{a_{ii}} x^j_k, \quad i = 1, 2, \ldots, n,$$

y claramente la solución de $Ax = b$ satisface

$$x_i = \frac{b_i}{a_{ii}} - \sum_{j\neq i} \frac{a_{ij}}{a_{ii}} x_j, \quad i = 1, 2, \ldots, n.$$

Luego

$$\underbrace{x^i_{k+1} - x_i}_{e^i_{k+1}} = -\sum_{j\neq i} \frac{a_{ij}}{a_{ii}} (\underbrace{x^j_k - x_j}_{e^j_k}), \quad i = 1, 2, \ldots, n,$$

y por lo tanto

$$|e^i_{k+1}| \leq \sum_{j\neq i} \frac{|a_{ij}|}{|a_{ii}|} |e^j_k| \leq \sum_{j\neq i} \frac{|a_{ij}|}{|a_{ii}|} \|e_k\|_\infty \leq \left(\max_{1\leq i\leq n} \sum_{j\neq i} \frac{|a_{ij}|}{|a_{ii}|} \right) \|e_k\|_\infty.$$

Si definimos $\mu_J = \max_{1\le i\le n} \frac{\sum_{j\neq i}|a_{ij}|}{|a_{ii}|}$ resulta

$$\|e_{k+1}\|_\infty \le \mu_J \|e_k\|_\infty,$$

y $\mu_J < 1$ por ser A edd. □

4.2.2 Convergencia del método de Gauss-Seidel

Para el método de Gauss-Seidel tenemos el siguiente teorema de convergencia.

Teorema 4.30. *Si A es estrictamente diagonalmente dominante (edd), entonces el método de Gauss-Seidel converge a partir de cualquier iteración inicial x_0 a la única solución $x = A^{-1}b$ de $Ax = b$.*

Además, existe $\mu_{GS} < 1$ tal que

$$\|x - x_{k+1}\|_\infty \le \mu_{GS}\|x - x_k\|_\infty, \quad k = 0, 1, 2, \ldots.$$

Más aún, $\mu_{GS} = \max_{1\le i\le n} \frac{\beta_i}{1-\alpha_i}$, con $\alpha_1 = 0$, $\alpha_i = \sum_{j<i} \frac{|a_{ij}|}{|a_{ii}|}$, $i = 2, 3, \ldots, n$, $\beta_i = \sum_{j>i} \frac{|a_{ij}|}{|a_{ii}|}$, $i = 1, 2, \ldots, n-1$, $\beta_n = 0$.

Demostración. Recordemos que de la definición del método de Gauss-Seidel

$$x_{k+1} = (L+D)^{-1}[b - Ux_k] = \underbrace{-(L+D)^{-1}U}_{M_{GS}} x_k + \underbrace{(L+D)^{-1}b}_{c},$$

o bien

$$(L+D)x_{k+1} = b - Ux_k.$$

Además la solución exacta satisface $(L+D)x = b - Ux$. Luego

$$D(x_{k+1} - x) = -L(x_{k+1} - x) - U(x_k - x),$$

y definiendo $e_k = x_k - x$ tenemos que

$$e_{k+1} = -D^{-1}Le_{k+1} - D^{-1}Ue_k.$$

Para $i = 1, 2, \ldots, n$

$$e^i_{k+1} = -\operatorname{fila}_i(D^{-1}L)e_{k+1} - \operatorname{fila}_i(D^{-1}U)e_k,$$

y entonces

$$|e^i_{k+1}| \le \|\operatorname{fila}_i(D^{-1}L)\|_1\|e_{k+1}\|_\infty + \|\operatorname{fila}_i(D^{-1}U)\|_1\|e_k\|_\infty = \alpha_i\|e_{k+1}\|_\infty + \beta_i\|e_k\|_\infty.$$

Puesto que A es edd, resulta que $\alpha_i + \beta_i < 1$ por lo que $\alpha_i < 1$ y $\beta_i < 1$ (ya que son ambos no negativos). Dado k, sea i_0 tal que $\|e_{k+1}\|_\infty = |e^{i_0}_{k+1}|$, entonces

$$\|e_{k+1}\|_\infty(1-\alpha_{i_0}) \le \beta_{i_0}\|e_k\|_\infty \quad \Rightarrow \quad \|e_{k+1}\|_\infty \le \frac{\beta_{i_0}}{1-\alpha_{i_0}}\|e_k\|_\infty \le \underbrace{\max_{1\le i\le n}\frac{\beta_i}{1-\alpha_i}}_{\mu_{GS}}\|e_k\|_\infty.$$

Para asegurar que el algoritmo converge, y finalizar la demostración del teorema, falta ver que $\frac{\beta_i}{1-\alpha_i} < 1$, $i = 1, 2, \ldots, n$. Veremos que $\frac{\beta_i}{1-\alpha_i} < \alpha_i + \beta_i < 1$. La última desigualdad vale por el teorema anterior de convergencia del método de Jacobi. Para ver la primera, observemos que

$$\alpha_i + \beta_i - \frac{\beta_i}{1-\alpha_i} = \frac{\alpha_i - \alpha_i^2 + \beta_i - \alpha_i\beta_i - \beta_i}{1-\alpha_i} = \frac{\alpha_i}{1-\alpha_i}\underbrace{(1-\alpha_i-\beta_i)}_{>0} \geq 0. \qquad \square$$

Observación 4.31. Del último paso de la demostración anterior concluimos que para matrices edd,

$$\mu_J = \max_{1\leq i\leq n}(\alpha_i + \beta_i) \geq \max_{1\leq i\leq n}\frac{\beta_i}{1-\alpha_i} = \mu_{GS},$$

y por lo tanto, para este tipo de matrices, el método de Gauss-Seidel funciona mejor o igual al de Jacobi.

4.2.3 Convergencia del método SOR

Recordemos que el método de sobrerrelajación sucesiva (SOR) es

$$x_{k+1} = \underbrace{-(\frac{1}{\omega}D + L)^{-1}(\frac{\omega-1}{\omega}D + U)}_{M_{SOR}^{\omega}} x_k + (\frac{1}{\omega}D + L)^{-1}b,$$

con x_0 dado.

Para estudiar la convergencia de este método, vemos primero el siguiente teorema:

Teorema 4.32. *Sea $A \in \mathbb{R}^{n\times n}$ sdp. Si $A = A_1 + A_2$ con A_1 invertible y tal que $A_1^T - A_2$ es sdp, entonces $\rho(-A_1^{-1}A_2) < 1$.*

Demostración. Puesto que A es sdp, sabemos que $\|x\|_A = (x^TAx)^{1/2}$ es una norma en $\mathbb{R}^n$, y denotemos también con $\|\cdot\|_A$ a la norma inducida por ésta en $\mathbb{R}^{n\times n}$. Veremos que

$$\|A_1^{-1}A_2\|_A = \max_{\|x\|_A=1}\|A_1^{-1}A_2x\|_A < 1, \tag{4.4}$$

y esto implicará la afirmación del teorema.

Sea $x \in \mathbb{R}^n$ que realiza el máximo de (4.4). Entonces $\|x\|_A = 1$ y $\|A_1^{-1}A_2\|_A = \|A_1^{-1}A_2x\|_A$.

Notemos que

$$A_1^{-1}A_2x = A_1^{-1}(A - A_1)x = \underbrace{A_1^{-1}Ax}_{y} - x,$$

y por lo tanto

$$\|A_1^{-1}A_2x\|_A^2 = \|y - x\|_A^2 = (y-x)^TA(y-x) = y^TAy - x^TAy - y^TAx + x^TAx. \tag{4.5}$$

Como A es simétrica, $x^TAy = y^TAx$ y como $y = A_1^{-1}Ax$, resulta que $x = A^{-1}A_1y$, por lo que

$$x^TAy = y^TAx = y^TA(A^{-1}A_1y) = y^TA_1y = y^TA_1^Ty.$$

Reemplazando esto último en (4.5), resulta

$$\begin{aligned}\|A_1^{-1}A_2x\|_A^2 &= y^TAy - y^T(A_1+A_1^T)y + x^TAx \\ &= x^TAx + y^T(\underbrace{A-A_1}_{A_2} - A_1^T)y = x^TAx - y^T(\underbrace{A_1^T - A_2}_{=K \text{ sdp}})y \\ &= x^TAx - \underbrace{y^TKy}_{>0 \text{ pues } y\neq 0} < x^TAx = \|x\|_A^2 = 1.\end{aligned}$$

Finalmente, $\rho(A_1^{-1}A_2) \leq \|A_1^{-1}A_2x\|_A < 1$. □

Teorema 4.33 (Convergencia del método SOR)**.** *Si A es sdp, entonces el método SOR converge a partir de cualquier $x_0 \in \mathbb{R}^n$, si $\omega \in (0,2)$.*

Demostración. Se deja como ejercicio. Se logra aplicando el teorema anterior. □

Si bien el teorema anterior da una condición suficiente para que SOR converja, el siguiente teorema dice que no es posible obtener un algoritmo convergente si se toma $\omega \notin (0,2)$.

Teorema 4.34. *Dada una matriz invertible $A \in \mathbb{R}^{n\times n}$, y $b \in \mathbb{R}^n$, si $\omega \notin (0,2)$ entonces la matriz de iteración del método SOR tiene radio espectral mayor o igual a uno.*

Demostración. Recordemos que la matriz de iteración de SOR es

$$M_{SOR}^{\omega} = -(\frac{1}{\omega}D + L)^{-1}(\frac{\omega-1}{\omega}D + U),$$

y su determinante es

$$\det(M_{SOR}^{\omega}) = (-1)^n\frac{\det(\frac{\omega-1}{\omega}D+U)}{\det(\frac{1}{\omega}D+L)} = (-1)^n\frac{\det(\frac{\omega-1}{\omega}D)}{\det(\frac{1}{\omega}D)} = (-1)^n\big(\frac{\omega-1}{\omega}\big)^n\omega^n\frac{\det(D)}{\det(D)} = (1-\omega)^n.$$

Si $\omega \notin (0,2)$ entonces $|\omega - 1| \geq 1$. Pero además, como el determinante es el producto de los autovalores,

$$\prod_{\lambda\in\sigma(M_{SOR}^{\omega})} |\lambda| = |\det(M_{SOR}^{\omega})| = |\omega-1|^n \geq 1,$$

por lo que algún autovalor de M_{SOR}^{ω} debe tener módulo mayor o igual a uno, y luego

$$\rho(M_{SOR}^{\omega}) \geq 1.$$ □

4.2.4 Convergencia del método de Richardson

Recordemos que el método de Richardson se basa en la iteración

$$x_{k+1} = (I - \alpha A)x_k + \alpha b, \qquad k = 0,1,2,\ldots,$$

con $\alpha \neq 0$ y x_0 dados.

Consideremos A sdp, y estudiemos $\rho(I-\alpha A)$. Como A es sdp, sus autovalores son todos positivos. Denotamos con $\lambda_{\min}$ y $\lambda_{\max}$ al menor y al mayor autovalor de A, respectivamente. Además, los autovalores de $I-\alpha A$ son $1-\alpha\lambda$ para $\lambda \in \sigma(A)$, más precisamente

$$\sigma(I-\alpha A) = \{1-\alpha\lambda : \lambda \in \sigma(A)\} \subset [1-\alpha\lambda_{\max}, 1-\alpha\lambda_{\min}].$$

Por lo tanto

$$\rho(I-\alpha A) = \max\{|1-\alpha\lambda_{\max}|, |1-\alpha\lambda_{\min}|\}.$$

Así,

$$\begin{aligned}
\rho(I-\alpha A) < 1 \quad &\iff \quad |1-\alpha\lambda_{\max}| < 1 \quad \text{y} \quad |1-\alpha\lambda_{\min}| < 1 \\
&\iff \quad -1 < 1-\alpha\lambda_{\max} < 1 \quad \text{y} \quad -1 < 1-\alpha\lambda_{\min} < 1 \\
&\iff \quad 0 < \alpha < \frac{2}{\lambda_{\max}} \quad \text{y} \quad 0 < \alpha < \frac{2}{\lambda_{\min}} \\
&\iff \quad 0 < \alpha < \frac{2}{\lambda_{\max}},
\end{aligned}$$

pues $\lambda_{\min} \leq \lambda_{\max}$.

Concluimos entonces que

Lema 4.35. *El método de Richardson converge para A sdp, a partir de cualquier $x_0 \in \mathbb{R}^n$ si y solo si*

$$0 < \alpha < \frac{2}{\lambda_{\max}}.$$

Queremos ahora averiguar cuál es el valor de α que minimiza $\rho(I-\alpha A)$. Por lo visto anteriormente,

$$\alpha_{\text{opt}} = \operatorname{argmin} \max\{|1-\alpha\lambda_{\min}|, |1-\alpha\lambda_{\max}|\},$$

es decir, α_{opt} es el valor de α que minimiza la función $\alpha \to \max\{|1-\alpha\lambda_{\min}|, |1-\alpha\lambda_{\max}|\}$. A partir del gráfico de la Figura 4.1 vemos que el mismo se alcanza cuando

$$\alpha\lambda_{\max} - 1 = 1 - \alpha\lambda_{\min} \qquad \iff \qquad \alpha = \frac{2}{\lambda_{\min}+\lambda_{\max}}.$$

En ese caso, además

$$\rho(I-\alpha_{\text{opt}}A) = 1-\alpha_{\text{opt}}\lambda_{\min} = 1 - \frac{2\lambda_{\min}}{\lambda_{\min}+\lambda_{\max}} = \frac{\lambda_{\max}-\lambda_{\min}}{\lambda_{\max}+\lambda_{\min}} = \frac{\frac{\lambda_{\max}}{\lambda_{\min}}-1}{\frac{\lambda_{\max}}{\lambda_{\min}}+1},$$

y como A es sdp, $\kappa_2(A) = \frac{\lambda_{\max}}{\lambda_{\min}}$. Hemos probado entonces el siguiente teorema:

Teorema 4.36. *Si A es sdp, y aplicamos el método de Richardson con $\alpha_{opt} = \dfrac{2}{\lambda_{\min}+\lambda_{\max}}$, a partir de cualquier x_0 obtenemos*

$$\|x - x_{k+1}\|_2 \leq \frac{\kappa_2(A)-1}{\kappa_2(A)+1}\|x-x_k\|_2, \qquad k = 0, 1, 2, \ldots,$$

donde $\kappa_2(A)$ es el número de condición de A con respecto a la norma euclídea de vectores, que satisface

$$\kappa_2(A) = \|A\|_2\|A^{-1}\|_2 = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

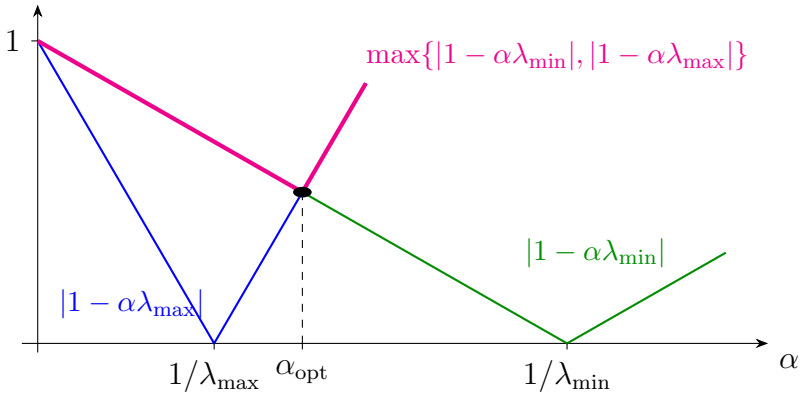


Figura 4.1 Ubicación de $\alpha_{\text{opt}} = \operatorname{argmin} \max\{|1-\alpha\lambda_{\min}|, |1-\alpha\lambda_{\max}|\}$.

Es importante observar que el decrecimiento del error (en norma euclídea) es más lento cuando el número de condición de la matriz es más grande. El mismo decrecimiento del error ocurre cuando se mide el mismo en la norma generada por A, más precisamente, se tiene el siguiente teorema.

Teorema 4.37. *Si A es sdp, y aplicamos el método de Richardson con $\alpha_{opt} = \dfrac{2}{\lambda_{\min}+\lambda_{\max}}$, a partir de cualquier x_0 obtenemos*

$$\|x - x_{k+1}\|_A \leq \frac{\kappa_2(A)-1}{\kappa_2(A)+1}\|x - x_k\|_A, \qquad k = 0, 1, 2, \ldots,$$

donde $\|y\|_A = (y^T A y)^{1/2}$.

Demostración. Para probar la afirmación bastaría ver que $\|I - \alpha_{\text{opt}} A\|_A \leq \frac{\kappa_2(A)-1}{\kappa_2(A)+1}$, es decir

$$\max_{\|v\|_A=1} \|(I - \alpha_{\text{opt}} A)v\|_A \leq \frac{\kappa_2(A)-1}{\kappa_2(A)+1}.$$

Sea entonces $v \in \mathbb{R}^n$ tal que $\|v\|_A = 1$. Observemos que

$$\|(I - \alpha_{\text{opt}} A)v\|_A^2 = v^T (I - \alpha_{\text{opt}} A)^T A (I - \alpha_{\text{opt}} A)v = v^T (I - \alpha_{\text{opt}} A)^T A^{1/2} A^{1/2} (I - \alpha_{\text{opt}} A)v,$$

donde $A^{1/2}$ es la *raíz cuadrada* de A. Como A es sdp, existen $Q \in \mathbb{R}^{n\times n}$ ortogonal y $\Lambda \in \mathbb{R}^{n\times n}$ diagonal (con los autovalores de A en la diagonal) tales que $A = Q\Lambda Q^T$. Como Λ es diagonal y sus entradas son no-negativas, se define $\Lambda^{1/2}$ por $(\Lambda^{1/2})_{ij} = (\Lambda_{ij})^{1/2}$, y cumple $\Lambda^{1/2}\Lambda^{1/2} = \Lambda$. Entonces se define $A^{1/2} = Q\Lambda^{1/2}Q^T$ que cumple

$$A^{1/2}A^{1/2} = Q\Lambda^{1/2}Q^T Q\Lambda^{1/2}Q^T = Q\Lambda^{1/2}\Lambda^{1/2}Q^T = Q\Lambda Q^T = A.$$

Además

$$AA^{1/2} = Q\Lambda Q^T Q\Lambda^{1/2}Q^T = Q\Lambda\Lambda^{1/2}Q^T = Q\Lambda^{1/2}\Lambda Q^T = Q\Lambda^{1/2}Q^T Q\Lambda Q^T = A^{1/2}A,$$

es decir que A conmuta con $A^{1/2}$. Por lo tanto

$$\|(I - \alpha_{\text{opt}} A)v\|_A^2 = \underbrace{v^T A^{1/2}}_{w^T}(I - \alpha_{\text{opt}} A)^T (I - \alpha_{\text{opt}} A)\underbrace{A^{1/2}v}_{w} = \|(I - \alpha_{\text{opt}} A)w\|_2^2.$$

Ahora bien $\|w\|_2^2 = w^T w = v^T A^{1/2} A^{1/2} v = v^T A v = 1$. Finalmente, resulta que cualquiera sea $v \in \mathbb{R}^n$ con $\|v\|_A = 1$,

$$\|(I - \alpha_{\text{opt}} A)v\|_A \leq \max_{\|w\|_2=1} \|(I - \alpha_{\text{opt}} A)w\|_2 = \rho(I - \alpha_{\text{opt}} A) = \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1}.$$

Por lo tanto, $\|I - \alpha_{\text{opt}} A\|_A \leq \frac{\kappa_2(A)-1}{\kappa_2(A)+1}$ y la afirmación se sigue de la consistencia de la norma inducida. □

4.3 Problemas

4.1. Sea $(\cdot, \cdot)$ un producto escalar en un espacio vectorial X. Demostrar que la función $\|x\| = (x, x)^{1/2}$ define una norma en X. *Sugerencia:* la desigualdad triangular se sigue de la desigualdad de Cauchy-Schwarz.

4.2. (a) Demostrar que $\|\cdot\|_1$ y $\|\cdot\|_\infty$ definen normas en $\mathbb{R}^n$.

(b) Demostrar que

$$\|x\|_\infty \leq \|x\|_2 \leq \|x\|_1 \qquad \text{y} \qquad \|x\|_1 \leq \sqrt{n}\|x\|_2 \leq n\|x\|_\infty,$$

para todo $x \in \mathbb{R}^n$. Demostrar que estas estimaciones son *sharp*, mostrando que existe algún x para el que se cumple la igualdad en cada una de estas estimaciones.

(c) Dibujar el conjunto $\{x \in \mathbb{R}^2 : \|x\| = 1\}$ para las normas $\|\cdot\|_1$, $\|\cdot\|_2$, $\|\cdot\|_\infty$ y $\|\cdot\|_A$. Para la norma $\|\cdot\|_A$ tomar $A = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$.

4.3. Si $\|\cdot\|$ denota una norma en $\mathbb{R}^n$, entonces en el espacio de las matrices cuadradas de orden n se define la norma inducida que denotamos con el mismo símbolo de la siguiente manera:

$$\|A\| := \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

Demostrar que:

(a) $\|\cdot\|$ es efectivamente una norma en $\mathbb{R}^{n \times n}$.

(b) $\|A\| = \max_{\|x\| \leq 1} \|Ax\| = \max_{\|x\|=1} \|Ax\| = \max_{0<\|x\|\leq 1} \frac{\|Ax\|}{\|x\|}$.

4.4. Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$ y denotemos también por $\|\cdot\|$ a la norma inducida en el espacio de matrices de $n \times n$. Demostrar que:

(a) $\|Ax\| \leq \|A\|\|x\|$, para toda matriz A y para todo vector x.

(b) $\|AB\| \leq \|A\|\|B\|$, para todo par de matrices A y B.

4.5. Consideremos las normas matriciales inducidas por las normas $\|\cdot\|_1$, $\|\cdot\|_\infty$, y $\|\cdot\|_2$ en $\mathbb{R}^n$. Demostrar que:

(a) $\|A\|_1 = \max\limits_{1\le j\le n} \sum\limits_{i=1}^{n} |a_{ij}|$

(b) $\|A\|_\infty = \max\limits_{1\le i\le n} \sum\limits_{j=1}^{n} |a_{ij}|$

(c) $\|A\|_2 = \max\left\{\sqrt{\lambda} : \lambda \text{ es autovalor de } A^T A\right\}$

(d) Si A es simétrica, $\|A\|_2 = \max\{|\lambda| : \lambda \text{ es autovalor de } A\}$

4.6. Sea $A \in \mathbb{R}^{n\times n}$ una matriz triangular. Probar que sus autovalores son los valores de la diagonal.

4.7. Sea $\rho(A) := \max\{|\lambda| : \lambda \text{ autovalor de } A\}$ el radio espectral de A. Demostrar que:

(a) $\rho(A) \le \|A\|$ para cualquier norma inducida y para toda matriz A.

(b) $\rho(A)$ puede ser cero aunque A no lo sea.

4.8. Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$ y sea $G \in \mathbb{R}^{n\times n}$ una matriz invertible. Demostrar que

$$\|x\|_G := \|Gx\|, \qquad \forall\, x \in \mathbb{R}^n,$$

es una norma en $\mathbb{R}^n$ y que la norma matricial inducida está dada por

$$\|A\|_G = \|GAG^{-1}\|, \qquad \forall\, A \in \mathbb{R}^{n\times n}.$$

4.9. Sea $M \in \mathbb{R}^{n\times n}$. Demostrar que si $\rho(M) \ge 1$ entonces existen $x_0, c \in \mathbb{R}^n$ tales que la iteración

$$x_{k+1} = Mx_k + c, \qquad k \ge 0,$$

no converge.

4.10. Demostrar que si una matriz $A \in \mathbb{R}^{n\times n}$ es *estrictamente diagonalmente dominante* (e.d.d), entonces resulta ser no singular.

(*Sugerencia:* Probar que $Ax = 0 \Rightarrow x = 0$)

4.11. Estudiar analíticamente la convergencia de los métodos de Jacobi y Gauss-Seidel, para cualesquiera valores iniciales, para el sistema

$$\begin{array}{rcrcrcl} x & & & + & z & = & 2 \\ -x & + & y & & & = & 0 \\ x & + & 2y & - & 3z & = & 0 \end{array}$$

Observación: La condición de edd es suficiente pero no necesaria para la convergencia de estos métodos.

Ayuda: ¿Conoces alguna condición necesaria y suficiente para la convergencia de métodos de este tipo?

4.12. Demostrar que si A es sdp, entonces todas las entradas de su diagonal son positivas.

4.13. Demostrar que si A es sdp, entonces el método SOR converge globalmente (i.e., para cualquier aproximación inicial x_0) para cualquier elección de $\omega \in (0, 2)$.

4.14. Programar los métodos de Jacobi, Gauss-Seidel, y SOR y utilizarlos para resolver los siguientes sistemas.

$$(i)\ \begin{bmatrix} 2 & 1 & -1 \\ -2 & -10 & 0 \\ -1 & -1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ -12 \\ 2 \end{bmatrix},\ (ii)\ \begin{bmatrix} 10 & 1 & 2 & 3 & 4 \\ 1 & 9 & -1 & 2 & -3 \\ 2 & -1 & 7 & 3 & -5 \\ 3 & 2 & 3 & 12 & -1 \\ 4 & -3 & -5 & -1 & 15 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} 12 \\ -27 \\ 14 \\ -17 \\ 12 \end{bmatrix}.$$

Para cada uno de los sistemas:

(a) Realizar un gráfico del decrecimiento del error (en escala logarítmica) en términos del número de iteraciones para cada uno de los métodos utilizados. Extraer conclusiones.

(b) Eligiendo alguna norma conveniente, realizar un gráfico de $\frac{\|x_{k+1}-x\|}{\|x_k-x\|}$ en término del número de iteraciones. ¿Cuál es asintóticamente el factor de reducción del error para cada método? Comparar con el radio espectral de cada matriz de iteración.

4.15. Encontrar una matriz A para la cual sea imposible encontrar α de manera que la iteración de Richardson $x_{k+1} = x_k - \alpha \left(Ax_k - b\right)$ converja para todo x_0.

Capítulo 5

Métodos de descenso para sistemas lineales

En este capítulo estudiaremos métodos iterativos para resolver sistemas de ecuaciones lineales asociados a matrices simétricas y definidas positivas, y luego, en las últimas secciones, métodos que no requieren esa hipótesis. Los primeros están basados en el hecho de que la solución de un sistema asociado a una matriz A sdp está caracterizada por ser el punto donde cierto funcional de energía asociado a A alcanza su mínimo.

5.1 Sistemas sdp y minimización de un funcional

Teorema 5.1. *Sean A sdp y $b \in \mathbb{R}^n$. Sea $\phi : \mathbb{R}^n \to \mathbb{R}$ dada por $\phi(x) = \frac{1}{2}x^T Ax - x^T b$. Entonces, el mínimo de ϕ en $\mathbb{R}^n$ se alcanza solo en la solución x_* de $Ax = b$ y el valor mínimo de ϕ es $-\frac{b^T x_*}{2}$.*

Demostración. Sea $x_* := A^{-1}b$ y sea $y \in \mathbb{R}^n$ arbitrario, $y \neq x_*$. Vamos a probar que $\phi(x_*) < \phi(y)$. Llamando $z := y - x_*$ tenemos que

$$\begin{aligned}\phi(y) = \phi(x_* + z) &= \frac{1}{2}(x_* + z)^T A(x_* + z) - (x_* + z)^T b \\ &= \frac{1}{2}x_*^T Ax_* + x_*^T Az + \frac{1}{2}z^T Az - x_*^T b - z^T b \\ &= \phi(x_*) + \frac{1}{2}z^T Az.\end{aligned}$$

Puesto que A es sdp, tenemos que $\frac{1}{2}z^T Az > 0$, y así,

$$\phi(x_*) < \phi(y), \qquad \forall\, y \in \mathbb{R}^n,\ y \neq x_*.$$

Por lo tanto, el mínimo de ϕ se alcanza solo en x_* y

$$\phi(x_*) = \frac{1}{2}x_*^T Ax_* - x_*^T b = -\frac{x_*^T b}{2}.$$

□

Observación 5.2. Para todo $x \in \mathbb{R}^n$,

$$\nabla\phi(x) = Ax - b.$$

Verificación. Escribiendo ϕ en coordenadas,

$$\phi(x) = \frac{1}{2}\sum_{i=1}^{n}\sum_{l=1}^{n} a_{il}x_i x_l - \sum_{i=1}^{n} b_i x_i,$$

y derivando respecto de x_j (los únicos términos que dependen de x_j son los que tienen $i = j$ o $l = j$),

$$\frac{\partial\phi}{\partial x_j}(x) = \frac{1}{2}\left(\sum_{l=1}^{n} a_{jl}x_l + \sum_{i=1}^{n} a_{ij}x_i\right) - b_j = \sum_{l=1}^{n} a_{jl}x_l - b_j = (Ax - b)_j,$$

donde en la anteúltima igualdad usamos que A es *simétrica* ($a_{ij} = a_{ji}$).

Alternativamente, y sin derivar: para $x, z \in \mathbb{R}^n$ y $t \in \mathbb{R}$, la cuenta hecha en la demostración del Teorema anterior (con x en lugar de x_*) da

$$\phi(x + tz) = \phi(x) + t\, z^T(Ax - b) + \frac{t^2}{2} z^T A z, \tag{5.1}$$

de donde $\lim_{t\to 0} \dfrac{\phi(x + tz) - \phi(x)}{t} = z^T(Ax - b)$ para todo z, es decir, $\nabla\phi(x) = Ax - b$.

Notemos que la simetría de A es esencial: si A no fuese simétrica se obtendría $\nabla\phi(x) = \frac{1}{2}(A + A^T)x - b$.

Del teorema anterior se sigue que si A es sdp,

$$\text{Hallar } x_* \text{ tal que } Ax_* = b$$

es equivalente a

$$\text{Hallar } x_* \text{ tal que } x_* \text{ minimiza } \phi \text{ en } \mathbb{R}^n.$$

Por otro lado, el siguiente lema será util al momento de diseñar y entender los métodos para sistemas asociados a matrices sdp.

Lema 5.3. *Sean A sdp, $b \in \mathbb{R}^n$, y x_* la solución de $Ax = b$. Sea $S \subset \mathbb{R}^n$. Entonces, $y \in S$ minimiza ϕ sobre S si y solo si $y \in S$ minimiza $\|\cdot - x_*\|_A$ sobre S.*

Demostración. Se puede demostrar que (ejercicio)

$$\phi(y) = \phi(x_*) + \frac{1}{2}\|y - x_*\|_A^2, \qquad \forall\, y \in \mathbb{R}^n.$$

De esta última afirmación se sigue lo que afirma este lema. □

5.2 Método del descenso más pronunciado (Steepest descent)

La idea es diseñar un método iterativo para hallar la solución x_* del sistema $Ax = b$, "moviéndonos" en la dirección del máximo descenso de ϕ. Más precisamente, dado $x_k \in \mathbb{R}^n$, nos "movemos" en la dirección del descenso más pronunciado $r_k := -\nabla\phi(x_k) = b - Ax_k$ para obtener x_{k+1}; esto es, definimos

$$x_{k+1} = x_k + \alpha r_k,$$

eligiendo $\alpha \in \mathbb{R}$ de manera que $\phi(x_k + \alpha r_k)$ sea lo más chico posible.

Si consideramos $h(\alpha) := \phi(x_k + \alpha r_k)$, para $\alpha \in \mathbb{R}$, tenemos que el mínimo de h se alcanza en $\alpha = \frac{{r_k}^T r_k}{{r_k}^T A r_k}$.

En efecto, usando (5.1) con $x = x_k$, $z = r_k$ y $t = \alpha$, y recordando que $Ax_k - b = -r_k$,

$$h(\alpha) = \phi(x_k) + \alpha\, r_k^T(Ax_k - b) + \frac{\alpha^2}{2} r_k^T A r_k = \phi(x_k) - \alpha\, r_k^T r_k + \frac{\alpha^2}{2} r_k^T A r_k.$$

Es decir, h es un polinomio cuadrático en α con coeficiente principal $\frac{1}{2} r_k^T A r_k > 0$ (pues A es sdp y $r_k \neq 0$); luego h tiene un único mínimo, que se alcanza donde $h'(\alpha) = 0$:

$$h'(\alpha) = -r_k^T r_k + \alpha\, r_k^T A r_k = 0 \qquad \Longleftrightarrow \qquad \alpha = \frac{{r_k}^T r_k}{{r_k}^T A r_k}.$$

Así, dado $x_0 \in \mathbb{R}^n$, la iteración del *método del descenso más pronunciado* está dada por

$$x_{k+1} = x_k + \alpha r_k, \qquad k \geq 0,$$

donde $r_k = b - Ax_k$ y $\alpha = \frac{{r_k}^T r_k}{{r_k}^T A r_k}$.

Observación 5.4. Si quisiéramos minimizar $\phi(x_k + \alpha d_k)$ como función de α, donde $d_k \in \mathbb{R}^n$ es alguna dirección dada, entonces dicho valor de α vendría dado por $\alpha = \frac{{d_k}^T r_k}{{d_k}^T A d_k}$, donde $r_k = b - Ax_k$.

Algoritmo Steepest descent (teórico)

Sean A sdp y $b \in \mathbb{R}^n$. Sea $x_0 \in \mathbb{R}^n$.
$r_0 = b - Ax_0$;
$k = 0$;
mientras $r_k \neq 0$ % $\|r_k\| > \text{tol}$
  $\alpha = \frac{{r_k}^T r_k}{{r_k}^T A r_k}$;
  $x_{k+1} = x_k + \alpha r_k$;
  $r_{k+1} = b - Ax_{k+1}$;
  $k = k + 1$;
fin

Observación 5.5. Recordemos que para la iteración de Richardson

$$x_{k+1} = x_k - \alpha(Ax_k - b) = x_k + \alpha r_k,$$

donde $r_k = b - Ax_k$. Así, el método del descenso más pronunciado es como la iteración de Richardson, pero eligiendo un valor de α en cada paso.

Observación 5.6. En principio en cada iteración del método de Steepest descent se calculan dos productos mat-vec por iteración: Ar_k y Ax_{k+1}.

Notemos que

$$r_{k+1} = b - Ax_{k+1} = b - A(x_k + \alpha r_k) = b - Ax_k - \alpha Ar_k = r_k - \alpha Ar_k.$$

Reemplazando en el algoritmo anterior la línea $r_{k+1} = b - Ax_{k+1}$; por $r_{k+1} = r_k - \alpha Ar_k$; podemos reducir el costo a un solo producto mat-vec por iteración.

Observación 5.7. Notemos que en el algoritmo anterior no hace falta conocer la matriz A, es suficiente disponer de una rutina matriz-vector, esto es, saber cómo actúa A sobre cada vector x, o sea, conocer la acción Ax, para cada x. Esto puede resultar mucho más eficiente en algunos casos.

Ejemplo 5.8. Si A es de 2×2, las curvas de nivel de ϕ son elipses. Cuanto mayor es el cociente $\frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}$ más alargadas son. Pensemos por ejemplo en $A = \begin{pmatrix} \lambda_{\max}(A) & 0 \\ 0 & \lambda_{\min}(A) \end{pmatrix}$. Cuanto más alargadas, más lenta será la convergencia.

Expliquemos esto con más detalle, porque es la clave para entender la lentitud del método.

Las curvas de nivel son elipses centradas en x_*. Por la identidad usada en la demostración del Lema 5.3,

$$\phi(y) = \phi(x_*) + \frac{1}{2}\|y - x_*\|_A^2,$$

de modo que el conjunto de nivel $\{y : \phi(y) = c\}$ es $\{y : \|y - x_*\|_A^2 = 2(c - \phi(x_*))\}$: un elipsoide centrado en x_* (y vacío si $c < \phi(x_*)$). Si $A = V\Lambda V^T$ con V ortogonal y $\Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$, escribiendo $w = V^T(y - x_*)$ el conjunto de nivel se lee

$$\sum_{i=1}^{n} \lambda_i w_i^2 = 2(c - \phi(x_*)),$$

es decir, un elipsoide con ejes en las direcciones de los autovectores de A y semieje i-ésimo proporcional a $1/\sqrt{\lambda_i}$. Por lo tanto,

$$\frac{\text{semieje mayor}}{\text{semieje menor}} = \sqrt{\frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}} = \sqrt{\kappa_2(A)}.$$

Cuando A es un múltiplo de la identidad las curvas de nivel son esferas; cuanto mayor es $\kappa_2(A)$, más alargadas son.

Por qué eso hace lento al método. El residuo $r_k = -\nabla\phi(x_k)$ es ortogonal (en el sentido euclídeo) a la curva de nivel que pasa por x_k, pero *no* apunta hacia el centro x_*, salvo que la curva de nivel sea una esfera o que $x_k - x_*$ sea un autovector de A. Cuanto más alargadas son las elipses, mayor puede ser ese desvío.

Además, la elección óptima de α hace que dos residuos consecutivos sean ortogonales:

$$r_{k+1}^T r_k = 0, \qquad k \geq 0. \tag{5.2}$$

En efecto, si $h(\alpha) = \phi(x_k + \alpha r_k)$, la regla de la cadena y la Observación 5.2 dan

$$h'(\alpha) = \nabla\phi(x_k + \alpha r_k)^T r_k = \big(A(x_k + \alpha r_k) - b\big)^T r_k = -\,r(\alpha)^T r_k,$$

donde $r(\alpha) := b - A(x_k + \alpha r_k)$; evaluando en el α que anula h', que es el que define x_{k+1}, resulta $r(\alpha) = r_{k+1}$ y se obtiene (5.2). Geométricamente: el método avanza en línea recta hasta ser tangente a una curva de nivel, y ahí dobla en ángulo recto. Sobre elipses muy alargadas esto produce el característico *zigzag* de pasos cortos, en el que cada iteración deshace parte del avance de la anterior (Figura 5.1).

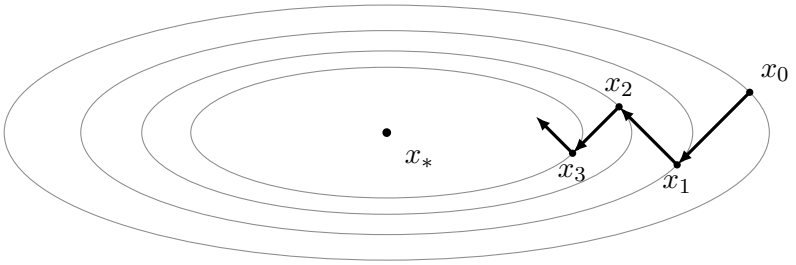


Figura 5.1 Descenso más pronunciado para $A = \mathrm{diag}(\lambda_{\min}, \lambda_{\max})$ con $\kappa_2(A) = 9$ y $b = 0$ (o sea $x_* = 0$), partiendo de $x_0 - x_* = (1/\lambda_{\min}, 1/\lambda_{\max})$. Los residuos consecutivos son ortogonales y el método zigzaguea; en cada paso el error en norma A se reduce exactamente por el factor $\frac{\kappa_2(A)-1}{\kappa_2(A)+1} = 0.8$.

El peor caso se alcanza. El ejemplo de la Figura 5.1 muestra que la cota de convergencia que probaremos a continuación no se puede mejorar. Tomemos $n = 2$, $A = \mathrm{diag}(\lambda_1, \lambda_2)$ con $0 < \lambda_1 < \lambda_2$, y $b = 0$, de modo que $x_* = 0$ y $r_k = -Ax_k$. Si $x_k = \left(\frac{1}{\lambda_1}, \frac{1}{\lambda_2}\right)$, entonces $r_k = -(1, 1)$ y

$$\alpha = \frac{r_k^T r_k}{r_k^T A r_k} = \frac{2}{\lambda_1 + \lambda_2},$$

con lo cual

$$x_{k+1} = \left(\frac{1}{\lambda_1}(1 - \alpha\lambda_1),\ \frac{1}{\lambda_2}(1 - \alpha\lambda_2)\right) = \frac{\lambda_2 - \lambda_1}{\lambda_2 + \lambda_1}\left(\frac{1}{\lambda_1}, -\frac{1}{\lambda_2}\right).$$

El nuevo error tiene la misma forma que el anterior (salvo un cambio de signo en la segunda coordenada, que se repite alternadamente), y por lo tanto

$$\|x_{k+1} - x_*\|_A = \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1}\,\|x_k - x_*\|_A \qquad \text{para todo } k \geq 0,$$

o sea, la desigualdad del teorema siguiente vale con *igualdad* en cada paso. Notemos que, en cambio, si $x_0 - x_*$ es un autovector de A, el método converge en una sola iteración: el problema no es la matriz mal condicionada *en sí*, sino la combinación de un espectro disperso con un error inicial que mezcla las direcciones extremas.

Finalmente, establecemos un resultado de convergencia para el método que estamos estudiando.

Teorema 5.9. *Sea A sdp, $b \in \mathbb{R}^n$, y x_* la solución de $Ax = b$. Sea $x_0 \in \mathbb{R}^n$ y sea $\{x_k\}_{k\in\mathbb{N}}$ la sucesión generada por el método del descenso más pronunciado. Entonces,*

$$\|x_{k+1} - x_*\|_A \leq \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1}\|x_k - x_*\|_A, \qquad k \geq 0. \tag{5.3}$$

Notemos que es la misma estimación de error de Richardson cuando se elige el α óptimo (α_{opt}). ¿Cuál le parece que será entonces la "ventaja" de este método respecto del anterior?

Demostración. Sea $k \geq 0$ arbitrario y fijo, y supongamos que x_k está dado. La iteración de Richardson con α_{opt} da

$$x_{k+1}^R = x_k - \alpha_{\text{opt}}(Ax_k - b) = x_k + \alpha_{\text{opt}} r_k,$$

con $r_k = b - Ax_k$. Por otro lado, para el descenso más pronunciado,

$$x_{k+1} = x_k + \alpha r_k,$$

donde α se elige de modo de minimizar $h(\alpha) := \phi(x_k + \alpha r_k)$. Por el Lema 5.3, esto es equivalente a minimizar $\|x_k + \alpha r_k - x_*\|_A$. Así,

$$\|\underbrace{x_k + \alpha r_k}_{x_{k+1}} - x_*\|_A \leq \|\underbrace{x_k + \alpha_{\text{opt}} r_k}_{x_{k+1}^R} - x_*\|_A.$$

Del teorema de convergencia para la iteración de Richardson se tiene que

$$\|x_{k+1}^R - x_*\|_A \leq \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1}\|x_k - x_*\|_A,$$

y por lo tanto,

$$\|x_{k+1} - x_*\|_A \leq \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1}\|x_k - x_*\|_A,$$

como queríamos demostrar. □

5.3 Método del gradiente conjugado

Seguimos considerando la resolución de un sistema $Ax = b$, donde A es sdp.

Pregunta: ¿Se puede "mejorar" el método del descenso más pronunciado eligiendo "mejor" las direcciones de búsqueda?

El método del gradiente conjugado que estudiaremos en esta sección surgió en 1950 como un método directo. Posteriormente se empezó a usar como método iterativo para

grandes sistemas de ecuaciones lineales y ha sustituido el uso de los métodos iterativos estacionarios como Jacobi, Gauss-Seidel, etc.

Recordemos el algoritmo del método del descenso más pronunciado:
Sea $x_0 \in \mathbb{R}^n$.

$r_0 = b - Ax_0$;

$k = 0$;

mientras $r_k \neq 0$

$x_{k+1} = x_k + \alpha_k r_k$, donde elegimos adecuadamente el valor α_k;

$r_{k+1} = b - Ax_{k+1}$;

$k = k + 1$;

fin

Recordemos que α_k se elige de manera que

$$x_{k+1} \text{ minimiza } \phi \text{ sobre } \{x_k + \alpha r_k \mid \alpha \in \mathbb{R}\}.$$

O sea,

$$\begin{aligned} &x_1 \text{ minimiza } \phi \text{ sobre } \{x_0 + \alpha r_0 \mid \alpha \in \mathbb{R}\} \\ &x_2 \text{ minimiza } \phi \text{ sobre } \{x_0 + \alpha_0 r_0 + \alpha r_1 \mid \alpha \in \mathbb{R}\} \\ &x_3 \text{ minimiza } \phi \text{ sobre } \{x_0 + \alpha_0 r_0 + \alpha_1 r_1 + \alpha r_2 \mid \alpha \in \mathbb{R}\} \\ &\vdots \end{aligned}$$

Dado $x_0 \in \mathbb{R}^n$, definimos una nueva sucesión $\{x_k\}_{k\in\mathbb{N}}$ de la siguiente manera:

$$x_{k+1} \text{ minimiza } \phi \text{ sobre } \underbrace{x_0 + \operatorname{span}\{r_0, r_1, \ldots, r_k\}}_{:=\{x_0+\alpha_0 r_0+\alpha_1 r_1+\cdots+\alpha_k r_k \mid \alpha_0,\alpha_1,\ldots,\alpha_k\in\mathbb{R}\}}, \qquad k \geq 0,$$

donde $r_i = b - Ax_i$, para $i = 0, 1, \ldots, k$.

Recordando que minimizar ϕ es equivalente a minimizar la A-distancia a la solución x_*, se tiene que

x_{k+1} es el punto de $x_0 + \operatorname{span}\{r_0, r_1, \ldots, r_k\}$ más cercano (en norma A) a la solución x_*.

Verificar que tal punto siempre existe, para asegurarse de que x_{k+1} está bien definido!

Así, tenemos el siguiente algoritmo teórico:

Método del gradiente conjugado. (Versión preliminar 1)

Sean A sdp y $b \in \mathbb{R}^n$. Sea $x_0 \in \mathbb{R}^n$.

$r_0 = b - Ax_0$;

$k = 0$;

mientras $r_k \neq 0$

$x_{k+1} = \operatorname{argmin}_{x\in x_0+\operatorname{span}\{r_0,r_1,\ldots,r_k\}} \phi(x)$;

$r_{k+1} = b - Ax_{k+1}$;

$k = k + 1$;

fin

A continuación, nos abocaremos al estudio de ciertas propiedades interesantes del método del gradiente conjugado y de su convergencia. Posteriormente, analizaremos si hay alguna manera computacional relativamente económica para calcular efectivamente los x_k's.

En el siguiente lema demostramos que los residuos r_k son ortogonales.

Lema 5.10. *Sea $\{r_k\}_{k\in\mathbb{N}_0}$ la sucesión de residuos del método del gradiente conjugado. Entonces,*

$$r_k \perp \{r_0, r_1, \ldots, r_{k-1}\}, \qquad k \geq 1.$$

Demostración. Sea $k \geq 1$ arbitrario y fijo. Puesto que $x_k = \operatorname*{argmin}_{x\in x_0+\operatorname{span}\{r_0,\ldots,r_{k-1}\}} \phi(x)$, se tiene que

$$\phi(x_k) \leq \phi(x), \qquad \forall\, x \in x_0 + \operatorname{span}\{r_0, \ldots, r_{k-1}\}.$$

Sea $\xi \in \operatorname{span}\{r_0, \ldots, r_{k-1}\}$ arbitrario. Entonces $\phi(x_k) \leq \phi(x_k + t\xi)$, para todo $t \in \mathbb{R}$. Así, la función $f_\xi(t) := \phi(x_k + t\xi)$ alcanza su mínimo en $t = 0$, y por lo tanto, $f'_\xi(0) = 0$.

Puesto que

$$f'_\xi(t) = \xi^T \nabla\phi(x_k + t\xi), \qquad \forall\, t \in \mathbb{R},$$

se tiene que

$$f'_\xi(0) = \xi^T \nabla\phi(x_k) = \xi^T \underbrace{(Ax_k - b)}_{=-r_k} = 0,$$

y así, $r_k \perp \xi$. Puesto que $\xi \in \operatorname{span}\{r_0, \ldots, r_{k-1}\}$ es arbitrario,

$$r_k \perp \{r_0, r_1, \ldots, r_{k-1}\}.$$

□

Observación 5.11. Si $r_k \neq 0$ entonces $\{r_0, r_1, \ldots, r_k\}$ es linealmente independiente.

Lema 5.12. *Si $r_k \neq 0$ entonces*

$$\operatorname{span}\{r_0, r_1, \ldots, r_k\} = \operatorname{span}\{r_0, Ar_0, \ldots, A^k r_0\}, \qquad \textit{para todo } k \geq 0.$$

El espacio $\mathcal{K}_{k+1} := \operatorname{span}\{r_0, Ar_0, \ldots, A^k r_0\}$ se llama *espacio de Krylov*.

Demostración. Demostraremos el resultado haciendo inducción sobre k.

Notemos que si $k = 0$, $\operatorname{span}\{r_0\} = \mathcal{K}_1$. Supongamos ahora que

$$\operatorname{span}\{r_0, \ldots, r_k\} = \mathcal{K}_{k+1}, \qquad \text{(Hip. ind.)}$$

y veamos que $\operatorname{span}\{r_0, \ldots, r_k, r_{k+1}\} = \mathcal{K}_{k+2}$, siempre que $r_{k+1} \neq 0$.

Demostramos primero que $\operatorname{span}\{r_0, \ldots, r_k, r_{k+1}\} \subset \mathcal{K}_{k+2}$. Para esto, notemos que por hipótesis inductiva,

$$r_i \in \mathcal{K}_{k+1} \subset \mathcal{K}_{k+2}, \qquad \text{para } i = 0, \ldots, k.$$

Solo resta ver entonces que $r_{k+1} \in \mathcal{K}_{k+2}$. Puesto que $r_{k+1} = b - Ax_{k+1}$, donde $x_{k+1} = x_0 + \xi$, con $\xi \in \operatorname{span}\{r_0, \ldots, r_k\} \underbrace{=}_{\text{por hip. ind.}} \mathcal{K}_{k+1}$, se tiene que

$$r_{k+1} = b - Ax_{k+1} = b - Ax_0 - A\xi = \underbrace{r_0}_{\in\mathcal{K}_{k+2}} - \underbrace{A\xi}_{\substack{\in\mathcal{K}_{k+2},\\ \text{pues } \xi\in\mathcal{K}_{k+1}}} \in \mathcal{K}_{k+2}.$$

Por lo tanto, $\operatorname{span}\{r_0, \ldots, r_k, r_{k+1}\} \subset \mathcal{K}_{k+2}$.

Ahora bien, puesto que $r_{k+1} \neq 0$, tenemos que $\operatorname{span}\{r_0, \ldots, r_k, r_{k+1}\}$ es un subespacio de dimensión $k + 2$ del espacio de Krylov $\mathcal{K}_{k+2}$ que tiene dimensión a lo sumo $k + 2$, y así, necesariamente, $\operatorname{span}\{r_0, \ldots, r_k, r_{k+1}\} = \mathcal{K}_{k+2}$, como queríamos demostrar. □

5.4 Cotas de error para el método del gradiente conjugado

Recordemos que de la definición de x_k se sigue que x_k minimiza ϕ en $x_0 + \mathcal{K}_k$, y esto ocurre, si y solo si

$$\|x_k - x_*\|_A \leq \|w - x_*\|_A, \qquad \forall\, w \in x_0 + \mathcal{K}_k.$$

Si $w \in x_0 + \mathcal{K}_k$, entonces $w = x_0 + \sum_{i=0}^{k-1} \gamma_i A^i r_0$, con $\gamma_0, \ldots, \gamma_{k-1} \in \mathbb{R}$. Entonces,

$$\begin{aligned}
w - x_* &= x_0 - x_* + \sum_{i=0}^{k-1} \gamma_i A^i r_0 \\
&= x_0 - x_* + \sum_{i=0}^{k-1} \gamma_i A^i (b - Ax_0) \\
&= x_0 - x_* + \sum_{i=0}^{k-1} \gamma_i A^i (Ax_* - Ax_0) \\
&= x_0 - x_* + \sum_{i=0}^{k-1} \gamma_i A^{i+1} (x_* - x_0) \\
&= \left(I - \sum_{i=0}^{k-1} \gamma_i A^{i+1} \right) (x_0 - x_*) \\
&= p_k(A)(x_0 - x_*),
\end{aligned}$$

donde $p_k(z) = 1 - \sum_{i=0}^{k-1} \gamma_i z^{i+1}$. Notemos que $p_k \in \mathcal{P}_k$ y que $p_k(0) = 1$.

Definimos el conjunto $\overline{\mathcal{P}}_k$ de polinomios residuales de grado $\leq k$ de la siguiente manera:

$$\overline{\mathcal{P}}_k := \{p \in \mathcal{P}_k \mid p(0) = 1\}.$$

Así, hemos demostrado el siguiente teorema.

Teorema 5.13. *Sean A sdp y $b \in \mathbb{R}^n$. Sea x_* la solución del sistema $Ax = b$. Si $\{x_k\}_{k\in\mathbb{N}}$ denota la sucesión generada por el método del gradiente conjugado partiendo de un vector inicial $x_0 \in \mathbb{R}^n$, entonces,*

$$\|x_k - x_*\|_A = \min_{p \in \overline{\mathcal{P}}_k} \|p(A)(x_0 - x_*)\|_A, \qquad k \geq 0.$$

Corolario 5.14. *Sean A sdp y $b \in \mathbb{R}^n$. Sea x_* la solución del sistema $Ax = b$. Si $\{x_k\}_{k\in\mathbb{N}}$ denota la sucesión generada por el método del gradiente conjugado partiendo de un vector inicial $x_0 \in \mathbb{R}^n$, entonces,*

$$\|x_k - x_*\|_A \leq \max_{\lambda \in \sigma(A)} |p(\lambda)| \|x_0 - x_*\|_A, \qquad \forall\, p \in \overline{\mathcal{P}}_k.$$

Demostración. Del teorema anterior se sigue que

$$\|x_k - x_*\|_A \leq \|p(A)\|_A \|x_0 - x_*\|_A,$$

para todo $p \in \overline{\mathcal{P}}_k$. Por lo tanto es suficiente demostrar que

$$\|p(A)\|_A \leq \max_{\lambda \in \sigma(A)} |p(\lambda)|, \qquad \forall\, p \in \overline{\mathcal{P}}_k. \tag{5.4}$$

Sea $p \in \overline{\mathcal{P}}_k$. Entonces, para todo $x \in \mathbb{R}^n$ se tiene que

$$\begin{aligned}\|p(A)x\|_A^2 &= (p(A)x)^T A(p(A)x) = (A^{\frac{1}{2}}p(A)x)^T(A^{\frac{1}{2}}p(A)x) = \|A^{\frac{1}{2}}p(A)x\|_2^2 \\ &= \|p(A)A^{\frac{1}{2}}x\|_2^2 \leq \|p(A)\|_2^2\|A^{\frac{1}{2}}x\|_2^2.\end{aligned}$$

Puesto que $\|A^{\frac{1}{2}}x\|_2^2 = (A^{\frac{1}{2}}x)^T(A^{\frac{1}{2}}x) = x^TA^{\frac{1}{2}}A^{\frac{1}{2}}x = x^TAx = \|x\|_A^2$, tenemos que

$$\|p(A)x\|_A \leq \|p(A)\|_2\|x\|_A, \qquad \text{para todo } x \in \mathbb{R}^n,$$

y así,

$$\|p(A)\|_A \leq \|p(A)\|_2.$$

En consecuencia, para demostrar (5.4) es suficiente demostrar que

$$\|p(A)\|_2 \leq \max_{\lambda \in \sigma(A)} |p(\lambda)|, \qquad \forall\, p \in \overline{\mathcal{P}}_k. \tag{5.5}$$

Puesto que A es simétrica, tenemos que A es diagonalizable y que existe una base ortonormal de vectores propios. Si $\lambda_1, \ldots, \lambda_n$ son los autovalores de A, entonces,

$$A = V\Lambda V^T, \qquad \text{donde } \Lambda = \begin{pmatrix} \lambda_1 & 0 & \ldots & 0 \\ 0 & \lambda_2 & \ldots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \ldots & \lambda_n \end{pmatrix},$$

y V es una matriz ortogonal ($VV^T = I$) cuyas columnas son correspondientes vectores propios.

Sea $p \in \overline{\mathcal{P}}_k$. Entonces, $p(z) = 1 - \sum_{i=0}^{k-1} \gamma_i z^{i+1}$ para algunos $\gamma_0, \gamma_1, \ldots, \gamma_{k-1} \in \mathbb{R}$. Así, puesto que $VV^T = I$,

$$\begin{aligned}p(A) &= I - \sum_{i=0}^{k-1} \gamma_i A^{i+1} = I - \sum_{i=0}^{k-1} \gamma_i (V\Lambda V^T)^{i+1} \\ &= I - \sum_{i=0}^{k-1} \gamma_i V\Lambda^{i+1}V^T = V\left(I - \sum_{i=0}^{k-1} \gamma_i \Lambda^{i+1}\right)V^T = Vp(\Lambda)V^T.\end{aligned}$$

Es fácil verificar que

$$p(\Lambda) = \begin{pmatrix} p(\lambda_1) & 0 & \ldots & 0 \\ 0 & p(\lambda_2) & \ldots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \ldots & p(\lambda_n) \end{pmatrix},$$

y en consecuencia, $p(A)$ es diagonalizable y

$$\sigma(p(A)) = \{p(\lambda) \mid \lambda \in \sigma(A)\}.$$

Finalmente, puesto que $p(A)$ es simétrica, $\|p(A)\|_2 = \rho(p(A))$ y así, (5.5) queda demostrada. □

La utilidad del resultado anterior radica en que si se dispone de información sobre el espectro de A, se pueden construir un polinomio residual conveniente y obtener una cota para el error de las iteraciones del método del gradiente conjugado.

Veamos algunos ejemplos de cómo hacer esto. En todos ellos la estrategia es la misma: elegir un $p \in \overline{\mathcal{P}}_k$ que sea *chico sobre el espectro de* A, sin preocuparse por lo que p hace fuera de él, y aplicar el Corolario 5.14.

Ejemplo 5.15 (Espectro agrupado alrededor de un punto)**.** Supongamos que $\sigma(A) \subset [1-\varepsilon, 1+\varepsilon]$ con $0 < \varepsilon < 1$. Tomando

$$p(z) = (1-z)^k \in \overline{\mathcal{P}}_k,$$

se tiene $|p(\lambda)| = |1-\lambda|^k \leq \varepsilon^k$ para todo $\lambda \in \sigma(A)$, y por lo tanto

$$\|x_k - x_*\|_A \leq \varepsilon^k \, \|x_0 - x_*\|_A.$$

Si ε es chico la convergencia es muy rápida, *independientemente de* n. Este es exactamente el efecto que busca un buen precondicionador (Sección 5.6): no achicar los autovalores, sino *agruparlos*.

Ejemplo 5.16 (Pocos autovalores distintos)**.** Si A tiene solamente m autovalores distintos $\mu_1, \ldots, \mu_m$, tomamos

$$p(z) = \prod_{j=1}^{m} \left(1 - \frac{z}{\mu_j}\right) \in \overline{\mathcal{P}}_m.$$

Entonces $p(\lambda) = 0$ para todo $\lambda \in \sigma(A)$ y el corolario da $\|x_m - x_*\|_A \leq 0$, es decir, $x_m = x_*$: el método termina en a lo sumo m pasos. Volveremos sobre esto en la Sección 5.4.1.

Ejemplo 5.17 (Autovalores aislados: el espectro "casi" agrupado)**.** El caso realmente interesante es el intermedio: la mayoría de los autovalores agrupados y unos pocos lejos. Supongamos que

$$\sigma(A) \subset [a, b] \cup \{\mu_1, \ldots, \mu_m\},$$

con $0 < a \leq b$ y m autovalores aislados $\mu_j > b$. La idea es *gastar* m factores del polinomio en anular los autovalores aislados, y usar los $k-m$ grados de libertad restantes sobre el intervalo. Para $k \geq m$ tomamos

$$p(z) = \underbrace{\prod_{j=1}^{m} \left(1 - \frac{z}{\mu_j}\right)}_{=:q(z)} \cdot p_{k-m}(z),$$

donde $p_{k-m} \in \overline{\mathcal{P}}_{k-m}$ es el polinomio de Tchebychev normalizado sobre $[a, b]$ que aparece en la demostración del Teorema siguiente. Como $p(0) = q(0)p_{k-m}(0) = 1$, resulta $p \in \overline{\mathcal{P}}_k$. Además p se anula en cada μ_j, y sobre $[a, b]$,

$$\max_{\lambda \in [a,b]} |p(\lambda)| \leq C \max_{\lambda \in [a,b]} |p_{k-m}(\lambda)| \leq 2\, C \left(\frac{\sqrt{b/a} - 1}{\sqrt{b/a} + 1}\right)^{k-m}, \qquad C := \max_{\lambda \in [a,b]} |q(\lambda)|.$$

En consecuencia,

$$\|x_k - x_*\|_A \leq 2\,C \left(\frac{\sqrt{b/a} - 1}{\sqrt{b/a} + 1} \right)^{k-m} \|x_0 - x_*\|_A, \qquad k \geq m.$$

Lo notable es que, salvo las primeras m iteraciones y la constante C, la velocidad de convergencia está gobernada por b/a y *no* por $\kappa_2(A) = \mu_{\max}/a$. Por ejemplo, si $\sigma(A) \subset [1,2] \cup \{1000\}$, entonces $\kappa_2(A) = 1000$ y la cota general del Teorema siguiente da un factor

$$\frac{\sqrt{1000} - 1}{\sqrt{1000} + 1} \approx 0.939$$

por iteración, mientras que con $m = 1$, $a = 1$, $b = 2$ y $C = \max_{\lambda \in [1,2]} |1 - \lambda/1000| \leq 1$ obtenemos

$$\|x_k - x_*\|_A \leq 2 \left(\frac{\sqrt{2} - 1}{\sqrt{2} + 1} \right)^{k-1} \|x_0 - x_*\|_A \approx 2\,(0.172)^{k-1} \|x_0 - x_*\|_A.$$

Para reducir el error en un factor 10^{-6}, la primera cota pide unas 230 iteraciones y la segunda, unas 9. Esto explica una observación experimental frecuente: *el gradiente conjugado suele andar mucho mejor que lo que predice la cota basada solo en* $\kappa_2(A)$, sobre todo cuando el espectro está agrupado con pocos valores extremos.

Observación 5.18. Vale la pena insistir en la lógica de estos argumentos: el Corolario 5.14 vale para *todo* $p \in \overline{\mathcal{P}}_k$, y el gradiente conjugado no "sabe" cuál elegimos ni lo calcula. Nosotros elegimos un p conveniente solo para *estimar* el error; el método siempre hace algo al menos tan bueno como el mejor de esos p. Por eso todas las cotas obtenidas de esta manera son cotas superiores, y cualquier información adicional sobre $\sigma(A)$ puede dar una cota mejor.

Teorema 5.19. *Sea A sdp, $b \in \mathbb{R}^n$, y x_* la solución de $Ax = b$. Sea $x_0 \in \mathbb{R}^n$ y sea $\{x_k\}_{k \in \mathbb{N}}$ la sucesión generada por el método del gradiente conjugado. Entonces,*

$$\|x_k - x_*\|_A \leq 2 \left(\frac{\sqrt{\kappa_2(A)} - 1}{\sqrt{\kappa_2(A)} + 1} \right)^{k} \|x_0 - x_*\|_A, \qquad k \geq 0. \tag{5.6}$$

Demostración. Sean $0 < \lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n$ los autovalores de A, y sean $\lambda_{\min} = \lambda_1$ y $\lambda_{\max} = \lambda_n$ el menor y el mayor de ellos.

Recordemos los polinomios de Tchebychev definidos por:

$$\begin{cases} T_0(x) = 1, \\ T_1(x) = x, \\ T_k(x) = 2xT_{k-1}(x) - T_{k-2}(x), \qquad k = 2, 3, \ldots \end{cases}$$

Sabemos que $T_k \in \mathcal{P}_k$ y que

$$T_k(x) = \cos(k \cos^{-1}(x)), \qquad x \in [-1, 1],$$

donde la función $\cos : [0,\pi] \to [-1,1]$. Teniendo en cuenta la biyección $x : [\lambda_{\min}, \lambda_{\max}] \to [-1,1]$ dada por $x(\lambda) = \frac{\lambda - \frac{\lambda_{\max}+\lambda_{\min}}{2}}{\frac{\lambda_{\max}-\lambda_{\min}}{2}}$, definimos

$$p_k(\lambda) := \frac{T_k(x(\lambda))}{T_k(x(0))} \in \overline{\mathcal{P}}_k.$$

Para aplicar el Corolario 5.14, tenemos que acotar $\max_{\lambda\in\sigma(A)} |p_k(\lambda)|$. Puesto que $\max_{x\in[-1,1]} |T_k(x)| \leq 1$, se tiene que

$$\max_{\lambda\in\sigma(A)} |p_k(\lambda)| \leq \max_{\lambda_{\min}\leq\lambda\leq\lambda_{\max}} |p_k(\lambda)| = \max_{\lambda_{\min}\leq\lambda\leq\lambda_{\max}} \frac{|T_k(x(\lambda))|}{|T_k(x(0))|} \leq \frac{1}{|T_k(x(0))|}, \tag{5.7}$$

y en consecuencia, es suficiente acotar por debajo $|T_k(x(0))|$. Por un lado, llamando $c = \kappa_2(A) = \frac{\lambda_{\max}}{\lambda_{\min}}$, tenemos

$$x(0) = -\frac{\lambda_{\max}+\lambda_{\min}}{\lambda_{\max}-\lambda_{\min}} = -\frac{c+1}{c-1} = \frac{1}{2}\Big(\underbrace{-\frac{\sqrt{c}-1}{\sqrt{c}+1}}_{=:z} + \Big(\underbrace{-\frac{\sqrt{c}+1}{\sqrt{c}-1}}_{=\frac{1}{z}}\Big)\Big).$$

Por otro lado, es fácil ver que (ejercicio!), si $z \neq 0$,

$$x(0) = \frac{z+z^{-1}}{2} \qquad \Longrightarrow \qquad T_k(x(0)) = \frac{z^k + z^{-k}}{2}.$$

Así,

$$T_k(x(0)) = \frac{1}{2}\Big(\Big(-\frac{\sqrt{c}-1}{\sqrt{c}+1}\Big)^k + \Big(-\frac{\sqrt{c}+1}{\sqrt{c}-1}\Big)^k\Big) = (-1)^k\frac{1}{2}\Big(\Big(\frac{\sqrt{c}-1}{\sqrt{c}+1}\Big)^k + \Big(\frac{\sqrt{c}+1}{\sqrt{c}-1}\Big)^k\Big),$$

y luego,

$$|T_k(x(0))| \geq \frac{1}{2}\Big(\frac{\sqrt{c}+1}{\sqrt{c}-1}\Big)^k. \tag{5.8}$$

De (5.7) y (5.8), teniendo en cuenta el Corolario 5.14, concluye la demostración. □

Observación 5.20 (Cuántas iteraciones hacen falta)**.** De la cota (5.6) se deduce cuántas iteraciones alcanzan para reducir el error en un factor dado, y es de aquí que sale la afirmación de que el gradiente conjugado necesita $O(\sqrt{\kappa_2(A)})$ iteraciones.

Fijemos una tolerancia $\varepsilon > 0$ y preguntémonos cuántas iteraciones garantizan que

$$\|x_k - x_*\|_A \leq \varepsilon \, \|x_0 - x_*\|_A.$$

Escribiendo $\kappa = \kappa_2(A)$ y $r = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$, por (5.6) basta con que $2r^k \leq \varepsilon$, es decir, con que

$$k \ln\frac{1}{r} \;\geq\; \ln\frac{2}{\varepsilon} \qquad \Longleftrightarrow \qquad k \;\geq\; \frac{\ln(2/\varepsilon)}{\ln(1/r)}. \tag{5.9}$$

Toda la dependencia en κ está en $\ln\frac{1}{r}$, que podemos pensar como la *tasa de convergencia por iteración*. Para estimarla, escribimos r como "uno menos algo chico":

$$r = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1} = 1 - t, \qquad t := \frac{2}{\sqrt{\kappa}+1} \in (0,1),$$

y usamos que $\ln(1-t) \le -t$, o sea $\ln \frac{1}{1-t} \ge t$, de donde

$$\ln \frac{1}{r} \;\ge\; \frac{2}{\sqrt{\kappa}+1}.$$

Reemplazando en (5.9), vemos que alcanza con tomar

$$k \;\ge\; \frac{\sqrt{\kappa_2(A)}+1}{2} \ln \frac{2}{\varepsilon}, \tag{5.10}$$

ya que ese k verifica $k \ln \frac{1}{r} \ge \ln \frac{2}{\varepsilon}$. Con ε fijo, el segundo factor es una constante, y por lo tanto

$$k = O\big(\sqrt{\kappa_2(A)}\big).$$

La estimación de $\ln \frac{1}{r}$ no es floja: como $\ln \frac{1}{1-t} = t + \frac{t^2}{2} + \cdots$, para κ grande vale $\ln \frac{1}{r} = \frac{2}{\sqrt{\kappa}} + O(\kappa^{-3/2})$, de modo que el orden $\sqrt{\kappa}$ es el correcto.

El mismo razonamiento aplicado al método del descenso más pronunciado, cuyo factor por iteración es $\frac{\kappa-1}{\kappa+1} = 1 - \frac{2}{\kappa+1}$, da $k = O(\kappa_2(A))$: reaparece aquí la diferencia entre κ y $\sqrt{\kappa}$ señalada más arriba.

Dos advertencias. Primero, (5.10) es una cota *superior*: dice que esa cantidad de iteraciones *alcanza*, no que sea necesaria; como ya observamos, el gradiente conjugado suele comportarse bastante mejor que lo que predice (5.6), sobre todo si el espectro está agrupado. Segundo, la dependencia en la tolerancia es apenas logarítmica: pedir una cifra más de precisión cuesta un número *fijo* de iteraciones adicionales, mientras que duplicar $\sqrt{\kappa}$ duplica el total. Por eso tiene sentido hablar de "las iteraciones necesarias para una tolerancia fija" sin especificar cuál es.

5.4.1 El método del gradiente conjugado como método directo

Es claro que el método del gradiente conjugado converge en a lo sumo n pasos, ya que si $r_n = b - Ax_n$ fuera no nulo, el conjunto $\{r_0, r_1, \ldots, r_n\}$ sería linealmente independiente en $\mathbb{R}^n$, lo cual no es posible. Más aún, tenemos el siguiente resultado.

Teorema 5.21. *Sea A sdp y $b \in \mathbb{R}^n$. Si A tiene k autovalores distintos entonces el método del gradiente conjugado para resolver el sistema $Ax = b$ converge a la solución en a lo sumo k pasos, partiendo de cualquier valor inicial.*

Demostración. Sean $\lambda_1, \lambda_2, \ldots, \lambda_k$ los $k \le n$ autovalores distintos de A. Definamos

$$p_k(z) := \frac{(\lambda_1 - z)(\lambda_2 - z)\ldots(\lambda_k - z)}{\lambda_1 \lambda_2 \ldots \lambda_k} \in \overline{\mathcal{P}}_k.$$

Puesto que $\max_{\lambda \in \sigma(A)} |p_k(\lambda)| = 0$, del Corolario 5.14 se sigue que

$$\|x_k - x_*\|_A \le \underbrace{\max_{\lambda \in \sigma(A)} |p_k(\lambda)|}_{=0} \|x_0 - x_*\|_A = 0,$$

y así, $x_k = x_*$, como queríamos demostrar. □

Teorema 5.22. *Sea A sdp y $b \in \mathbb{R}^n$. Si b es una combinación lineal de k autovectores de A entonces el método del gradiente conjugado para resolver el sistema $Ax = b$, partiendo de $x_0 = 0$, converge a la solución en a lo sumo k pasos.*

Demostración. La demostración se deja como ejercicio. Sugerencia: Utilizar el Teorema 5.13. □

En la práctica, no es cierto en general que el método del gradiente conjugado converja en un número finito de pasos, debido a los errores de redondeo en los cálculos computacionales. En la actualidad, este método se utiliza como método iterativo para sistemas con matrices de gran tamaño (por ejemplo, $n = 100000$). En este caso, no se pretende realizar las n iteraciones para *alcanzar* la raíz. En vez de esto, se utiliza algún criterio de parada en las iteraciones, dependiendo de una tolerancia admisible para el error.

5.5 Implementación del método del gradiente conjugado

En esta sección suponemos que A es sdp, $b \in \mathbb{R}^n$, y x_* denota la solución de $Ax = b$. Dado $x_0 \in \mathbb{R}^n$, consideramos $\{x_k\}_{k\in\mathbb{N}}$ la sucesión generada por el método del gradiente conjugado.

Recordemos que

$$x_{k+1} = \underset{x\in x_0+\mathcal{K}_{k+1}}{\operatorname{argmin}} \ \phi(x), \qquad k \geq 0,$$

donde $\mathcal{K}_{k+1} = \operatorname{span}\{r_0, r_1, \ldots, r_k\} = \operatorname{span}\{r_0, Ar_0, \ldots, A^k r_0\}$.

Veremos que una vez que x_k está determinado, o bien, $x_k = x_*$, o bien, existe una dirección de búsqueda d_{k+1} (fácil de obtener) tal que

$$x_{k+1} = x_k + \alpha_{k+1} d_{k+1}, \qquad \text{para algún } \alpha_{k+1} \in \mathbb{R}.$$

Lema 5.23. *Para todo $k \in \mathbb{N}$,*

$$x_{k+1} - x_k \in \mathcal{K}_{k+1}, \qquad y \qquad (x_{k+1} - x_k)^T A\xi = 0, \quad \forall\, \xi \in \mathcal{K}_k.$$

Demostración. Sea $k \in \mathbb{N}$. Sabemos que $x_k = x_0 + w_k$, con $w_k \in \mathcal{K}_k$, y que $x_{k+1} = x_0 + w_{k+1}$, con $w_{k+1} \in \mathcal{K}_{k+1}$. Así, puesto que $\mathcal{K}_k \subset \mathcal{K}_{k+1}$,

$$x_{k+1} - x_k = \underbrace{w_{k+1}}_{\in\mathcal{K}_{k+1}} - \underbrace{w_k}_{\in\mathcal{K}_k} \in \mathcal{K}_{k+1}.$$

Además, si $\xi \in \mathcal{K}_k$,

$$(x_{k+1} - x_k)^T A\xi = \xi^T A(x_{k+1} - x_k) = \xi^T (\underbrace{Ax_{k+1} - b}_{=-r_{k+1}} + \underbrace{b - Ax_k}_{=r_k}) = \xi^T (r_k - r_{k+1}) = 0,$$

ya que tanto r_k como r_{k+1} son ortogonales a $\mathcal{K}_k = \operatorname{span}\{r_0, r_1, \ldots, r_{k-1}\}$. □

Para cada $k \in \mathbb{N}$, si $r_k \neq 0$, existe una única dirección en $\mathcal{K}_{k+1} = \text{span}\{r_0, r_1, \ldots, r_k\}$ que es A-ortogonal a $\mathcal{K}_k = \text{span}\{r_0, r_1, \ldots, r_{k-1}\}$, puesto que $\mathcal{K}_k \subset \mathcal{K}_{k+1}$ y que $\dim(\mathcal{K}_k) = k$ y $\dim(\mathcal{K}_{k+1}) = k+1$. En particular, existe un único $w_k \in \mathcal{K}_k$ tal que $d_{k+1} := r_k + w_k$ es A ortogonal a $\mathcal{K}_k$.

Así, tenemos la siguiente consecuencia del lema anterior.

Corolario 5.24. *Sea $d_1 = r_0$ y sea $\{d_{k+1}\}_{k\in\mathbb{N}}$ la sucesión definida arriba. Entonces, si $k \in \mathbb{N}_0$ y $r_k \neq 0$, se tiene que*

$$x_{k+1} = x_k + \alpha_{k+1} d_{k+1},$$

donde $\alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}}$.

Demostración. Sea $k \in \mathbb{N}$. Por el lema anterior tenemos que

$$x_{k+1} - x_k \in \mathcal{K}_{k+1}, \qquad \text{y} \qquad x_{k+1} - x_k \perp_A \mathcal{K}_k,$$

es decir, $x_{k+1} - x_k$ es una dirección en $\mathcal{K}_{k+1}$ que es A-ortogonal a $\mathcal{K}_k$. Por lo tanto, existe $\alpha_{k+1} \in \mathbb{R}$ tal que

$$x_{k+1} - x_k = \alpha_{k+1} d_{k+1},$$

o sea,

$$x_{k+1} = x_k + \alpha_{k+1} d_{k+1}.$$

Puesto que $x_{k+1} = \underset{x \in x_0 + \mathcal{K}_{k+1}}{\text{argmin}} \ \phi(x)$, tenemos que α_{k+1} debe satisfacer que

$$\alpha_{k+1} = \underset{\alpha\in\mathbb{R}}{\text{argmin}}\, \phi(x_k + \alpha d_{k+1}).$$

Teniendo en cuenta la Observación 5.4, concluimos que

$$\alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}}.$$

□

Ahora estamos en condiciones de escribir la siguiente versión mejorada del algoritmo anterior:

Método del gradiente conjugado. (Versión preliminar 2)

Sean A sdp y $b \in \mathbb{R}^n$. Sea $x_0 \in \mathbb{R}^n$.
$r_0 = b - Ax_0$;
$k = 0$;
mientras $r_k \neq 0$
    Calcular la dirección de búsqueda d_{k+1};
    $\alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}}$;
    $x_{k+1} = x_k + \alpha_{k+1} d_{k+1}$;
    $r_{k+1} = b - Ax_{k+1}$;
    $k = k + 1$;
fin

Antes de determinar una fórmula para calcular las direcciones de búsqueda d_k, demostramos que éstas también generan el espacio de Krylov. Más precisamente, tenemos el siguiente resultado.

Lema 5.25. *Sea $k \in \mathbb{N}$. Si $r_{k-1} \neq 0$, entonces $\{d_1, \ldots, d_k\}$ es A-ortogonal y*

$$\mathcal{K}_k = \operatorname{span}\{d_1, \ldots, d_k\}.$$

Demostración. Puesto que $d_1 = r_0$, tenemos que $\mathcal{K}_1 = \operatorname{span}\{d_1\}$. Supongamos que

$$\mathcal{K}_k = \operatorname{span} \underbrace{\{d_1, \ldots, d_k\}}_{A\text{-ortogonal}}, \qquad \text{(Hip. ind.)}$$

y veamos que si $r_k \neq 0$,

$$\mathcal{K}_{k+1} = \operatorname{span} \underbrace{\{d_1, \ldots, d_{k+1}\}}_{A\text{-ortogonal}}.$$

Por hipótesis inductiva se tiene que $\{d_1, \ldots, d_k\}$ es A-ortogonal y que $\{d_1, \ldots, d_k\} \subset \mathcal{K}_k \subset \mathcal{K}_{k+1}$. Además, de la definición de d_{k+1} se sigue que $d_{k+1} \in \mathcal{K}_{k+1}$, y que d_{k+1} es A-ortogonal a $\mathcal{K}_k = \operatorname{span}\{d_1, \ldots, d_k\}$. En consecuencia,

$$\operatorname{span} \underbrace{\{d_1, \ldots, d_{k+1}\}}_{A\text{-ortogonal}} \subset \mathcal{K}_{k+1}.$$

Puesto que $r_k \neq 0$, se tiene que $d_1, \ldots, d_{k+1}$ son no nulos, y en consecuencia, generan un subespacio de dimensión $k+1$ del espacio de Krylov $\mathcal{K}_{k+1}$ que tiene dimensión $k+1$. Así,

$$\operatorname{span} \underbrace{\{d_1, \ldots, d_{k+1}\}}_{A\text{-ortogonal}} = \mathcal{K}_{k+1},$$

como queríamos demostrar. □

Teorema 5.26. *Sea $k \in \mathbb{N}$. Si $r_{k-1} \neq 0$, entonces*

$$d_{k+1} = r_k + \beta_{k+1} d_k,$$

donde $\beta_{k+1} = -\frac{r_k^T A d_k}{d_k^T A d_k}$.

Demostración. Sabemos que existe un único $w_k \in \mathcal{K}_k$ tal que $d_{k+1} = r_k + w_k$. Por el lema anterior, tenemos que $\mathcal{K}_k = \operatorname{span}\{d_1, \ldots, d_k\}$ y por lo tanto, $w_k = \sum_{i=1}^{k} \gamma_i d_i$, para algunos $\gamma_1, \ldots, \gamma_k \in \mathbb{R}$, y luego,

$$d_{k+1} = r_k + \sum_{i=1}^{k} \gamma_i d_i.$$

De la definición de d_{k+1} se sigue que $d_{k+1} \perp_A \mathcal{K}_k = \operatorname{span}\{d_1, \ldots, d_k\}$, y por lo tanto,

$$d_{k+1}^T A d_j = 0, \qquad j = 1, \ldots, k.$$

Así,

$$d_{k+1}^T A d_j = \left(r_k^T + \sum_{i=1}^{k} \gamma_i d_i^T \right) A d_j = r_k^T A d_j + \sum_{i=1}^{k} \gamma_i \underbrace{d_i^T A d_j}_{=0,\text{ si } i \neq j} = r_k^T A d_j + \gamma_j d_j^T A d_j = 0,$$

y de aquí,

$$\gamma_j = -\frac{r_k^T A d_j}{d_j^T A d_j}, \qquad j = 1, \ldots, k.$$

En consecuencia, para completar la demostración, es suficiente probar que $\gamma_j = 0$, para $j = 1, \ldots, k-1$, y esto último es equivalente a probar que

$$r_k^T A d_j = 0, \qquad j = 1, \ldots, k-1.$$

Finalmente, esta última afirmación se cumple ya que $Ad_j \in \mathcal{K}_{j+1} \subset \mathcal{K}_k$, para $j = 1, \ldots, k-1$, teniendo en cuenta que $r_k \perp \{r_0, r_1, \ldots, r_{k-1}\} = \mathcal{K}_k$. □

Ahora que tenemos una fórmula para calcular las direcciones de búsqueda d_k el algoritmo queda de la siguiente manera:

Método del gradiente conjugado. (Versión preliminar 3)

Sean A sdp y $b \in \mathbb{R}^n$. Sea $x_0 \in \mathbb{R}^n$.
$r_0 = b - Ax_0$;
$k = 0$;
mientras $r_k \neq 0$
  si $k = 0$
    $d_1 = r_0$;
  si no
    $\beta_{k+1} = -\frac{r_k^T A d_k}{d_k^T A d_k}$;
    $d_{k+1} = r_k + \beta_{k+1} d_k$;
  fin si
  $\alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}}$;
  $x_{k+1} = x_k + \alpha_{k+1} d_{k+1}$;
  $r_{k+1} = b - Ax_{k+1}$;
  $k = k + 1$;
fin

En el siguiente lema damos expresiones alternativas para el cálculo de los coeficientes α_k y β_k, de manera de hacer más eficiente nuestro algoritmo.

Lema 5.27. *Si $r_k \neq 0$, entonces*

$$\alpha_{k+1} = \frac{\|r_k\|_2^2}{\|d_{k+1}\|_A^2} = \frac{r_k^T r_k}{d_{k+1}^T A d_{k+1}}, \qquad y \qquad \beta_{k+1} = \frac{\|r_k\|_2^2}{\|r_{k-1}\|_2^2} = \frac{r_k^T r_k}{r_{k-1}^T r_{k-1}}.$$

Demostración. Notemos que

$$d_{k+1}^T r_k = (r_k + \beta_{k+1} d_k)^T r_k = r_k^T r_k + \beta_{k+1} \underbrace{d_k^T r_k}_{=0} = r_k^T r_k,$$

ya que $d_k \in \mathcal{K}_k$ y $r_k \perp \mathcal{K}_k$. En consecuencia, $\alpha_{k+1} = \frac{d_{k+1}^T r_k}{d_{k+1}^T A d_{k+1}} = \frac{r_k^T r_k}{d_{k+1}^T A d_{k+1}}$.

Por otro lado, puesto que $r_k = b - Ax_k = b - Ax_{k-1} + A(x_{k-1} - x_k) = r_{k-1} - \alpha_k A d_k$ se tiene que

$$Ad_k = \frac{1}{\alpha_k}(r_{k-1} - r_k).$$

Así, usando que $\alpha_k = \frac{r_{k-1}^T r_{k-1}}{d_k^T A d_k}$ y que $r_k \perp r_{k-1}$,

$$\beta_{k+1} = -\frac{r_k^T A d_k}{d_k^T A d_k} = -\frac{r_k^T (r_{k-1} - r_k)}{\alpha_k d_k^T A d_k} = \frac{r_k^T r_k}{r_{k-1}^T r_{k-1}},$$

como queríamos demostrar. □

Reemplazando las fórmulas que indica el teorema, obtenemos el siguiente algoritmo del Gradiente Conjugado, que aún no es implementable, porque los vectores y cantidades que aparecen tienen subíndices.

Método del gradiente conjugado. (Versión final, con subíndices)

Sean A sdp y $b \in \mathbb{R}^n$.
Sea $x_0 \in \mathbb{R}^n$.
$r_0 = b - Ax_0$;
$\rho_0 = \|r_0\|_2^2$;
$k = 0$;
mientras $\rho_k \neq 0$
    si $k = 0$
        $d_1 = r_0$;
    si no
        $\beta_{k+1} = \frac{\rho_k}{\rho_{k-1}}$ % $= \frac{r_k^T r_k}{r_{k-1}^T r_{k-1}}$
        $d_{k+1} = r_k + \beta_{k+1} d_k$;
    fin si
    $w_{k+1} = Ad_{k+1}$
    $\alpha_{k+1} = \frac{\rho_k}{d_{k+1}^T w_{k+1}}$ % $= \frac{r_k^T r_k}{d_{k+1}^T A d_{k+1}}$
    $x_{k+1} = x_k + \alpha_{k+1} d_{k+1}$;
    $r_{k+1} = b - Ax_{k+1}$;
    $\rho_{k+1} = \|r_{k+1}\|_2^2$;
    $k = k + 1$;
fin

Antes de escribir cómo queda el algoritmo del método del gradiente conjugado hacemos una observación respecto del criterio de parada. Sabemos que

$$\frac{\|x_k - x_*\|_2}{\|x_*\|_2} \leq \kappa_2(A) \frac{\| \overbrace{b - Ax_k}^{=r_k} \|_2}{\|b\|_2}.$$

Dada una tolerancia tol, lo usual es pedir que

$$\|r_k\|_2 < \text{tol}\, \|b\|_2,$$

y así, el error relativo a la salida del algoritmo será

$$\frac{\|x_k - x_*\|_2}{\|x_*\|_2} \leq \kappa_2(A)\, \text{tol}\,.$$

Ahora sí, presentamos el algoritmo para el método del gradiente conjugado.

Método del gradiente conjugado.

Sean A sdp y $b \in \mathbb{R}^n$ y sean
$x \in \mathbb{R}^n$ (iterando inicial),
$\text{tol} \in \mathbb{R}_+$ (tolerancia para el error relativo),
`maxiter` $\in \mathbb{N}$ (tope de iteraciones).

$r = b - Ax$; % residuo inicial
$\rho = r^T r$; % $\rho = \|r\|_2^2$
$\text{TOL} = \text{tol}^2\, b^T b$; % $\text{TOL} = \text{tol}^2\, \|b\|_2^2$
$k = 0$;
mientras ($\rho > \text{TOL}$ y $k <$ `maxiter`) % $\frac{\|r\|_2}{\|b\|_2} > \text{tol}$
    si $k = 0$
        $d = r$;
    sino
        $\beta = \frac{\rho}{\rho_{old}}$;
        $d = r + \beta d$;
    fin si
    $w = Ad$;
    $\alpha = \frac{\rho}{d^T w}$;
    $x = x + \alpha d$;
    $r = r - \alpha w$; % $r_{k+1} = b - Ax_{k+1} = b - Ax_k + A(x_k - x_{k+1}) = r_k - \alpha_{k+1} A d_{k+1}$
    $\rho_{old} = \rho$;
    $\rho = r^T r$;
    $k = k + 1$;
fin

Observación 5.28. (1) Notemos que, al igual que ocurría con el método del descenso más pronunciado, no es necesario almacenar la matriz A, sino que es suficiente con disponer de una rutina para calcular el producto Ax, para cada vector x.

(2) Almacenamiento. Se necesitan guardar cuatro vectores: x, w, d y r.

(3) Costo por iteración.

- 1 producto mat-vec (Ad).
- 2 productos escalares ($d^T w$ y $r^T r$).
- 3 operaciones axpy, es decir, del tipo $ax + y$, con $a \in \mathbb{R}$, $x, y \in \mathbb{R}^n$ ($d = r + \beta d$, $x = x + \alpha d$ y $r = r - \alpha w$).

(4) Notar que no es necesario almacenar una base para el espacio de Krylov $(d_1, \dots, d_k, \dots)$. Esta es una ventaja que se tiene por el hecho de que A es sdp. Existen métodos de espacios de Krylov para matrices que no son sdp (por ejemplo, GMRes), pero en este caso es necesario ir guardando las direcciones de búsqueda.

5.6 Precondicionamiento de un sistema y método del GC precondicionado

En general, cuando queremos resolver un sistema $Ax = b$ con un método iterativo, la convergencia depende del número de condición de A, $\kappa(A)$. Si pudiéramos determinar una matriz M invertible tal que M *sea como* A^{-1} *en algún sentido*, entonces el sistema $Ax = b$, sería equivalente al sistema $MAx = Mb$.

Si $M \approx A^{-1}$ entonces $MA \approx I$, y por lo tanto, el sistema $MAx = Mb$ está mejor condicionado.

5.6.1 Gradiente conjugado precondicionado (GCP)

Vimos que si $\kappa_2(A)$ es grande, la convergencia del método del gradiente conjugado puede ser muy lenta. Supongamos que disponemos de una matriz M sdp tal que $M \approx A^{-1}$ en el siguiente sentido: existen constantes c_1, c_2 tales que

$$c_1 \leq \frac{x^T M x}{x^T A^{-1} x} \leq c_2, \qquad \forall\, x \neq 0.$$

Si c_2/c_1 es pequeño (cercano a 1) diremos que M es un buen precondicionador de A.

El sistema $Ax = b$ es equivalente al sistema $MAx = Mb$. Aunque A y M son sdp, no podemos garantizar que MA es sdp y por lo tanto, no podemos utilizar el método del gradiente conjugado para resolver el sistema $MAx = Mb$.

Si S denota la raíz cuadrada de M, es decir, si S es sdp y tal que $S^2 = M$, se tiene que

$$Ax = b \iff MAx = Mb \iff S^2 Ax = S^2 b \iff SAx = Sb.$$

Así, resolver el sistema $Ax = b$ es equivalente a resolver

$$\begin{cases} SASy = Sb \\ x = Sy. \end{cases}$$

Se deja como ejercicio verificar que SAS es sdp, y por lo tanto, podemos aplicar el método del gradiente conjugado para resolver el sistema $SASy = Sb$. Más aún, se puede demostrar (ejercicio!) que

$$\kappa_2(SAS) \leq \frac{c_2}{c_1}.$$

Si $\frac{c_2}{c_1}$ es pequeño, la convergencia del método del gradiente conjugado aplicado al sistema $SASy = Sb$ será más rápida. Pero no conocemos y no queremos calcular $S = M^{\frac{1}{2}}$! Supongamos por el momento que disponemos de la matriz S y apliquemos el método del gradiente conjugado para resolver el sistema $SASy = Sb$. Llamemos $\{y_k\}_{k\in\mathbb{N}}$ a la sucesión generada por dicho algoritmo, y denotemos por $\tilde{r}_k := Sb - SASy_k$ al residuo en el paso k, y por $\tilde{d}_{k+1}$ a la dirección de búsqueda para obtener y_{k+1} a partir de y_k.

Método del gradiente conjugado aplicado a $SASy = Sb$.

Sea $y_0 \in \mathbb{R}^n$.
$\tilde{r}_0 = Sb - SASy_0$;
$\tilde{\rho}_0 = \|\tilde{r}_0\|_2^2$;
$k = 0$;
mientras $\tilde{\rho}_k \neq 0$
    si $k = 0$
        $\tilde{d}_1 = \tilde{r}_0$;
    sino
        $\tilde{\beta}_{k+1} = \frac{\tilde{\rho}_k}{\tilde{\rho}_{k-1}}$;
        $\tilde{d}_{k+1} = \tilde{r}_k + \tilde{\beta}_{k+1}\tilde{d}_k$;
    fin si
    $\tilde{w}_{k+1} = SAS\tilde{d}_{k+1}$;
    $\tilde{\alpha}_{k+1} = \frac{\tilde{\rho}_k}{\tilde{d}_{k+1}^T\tilde{w}_{k+1}}$;
    $y_{k+1} = y_k + \tilde{\alpha}_{k+1}\tilde{d}_{k+1}$;
    $\tilde{r}_{k+1} = \tilde{r}_k - \tilde{\alpha}_{k+1}\tilde{w}_{k+1}$;
    $\tilde{\rho}_{k+1} = \|\tilde{r}_{k+1}\|_2^2$;
    $k = k + 1$;
fin

Definamos ahora $x_k := Sy_k$. Si y_k converge a la solución y_* de $SASy = Sb$, entonces x_k converge a la solución x_* de $Ax = b$. Más concretamente, puesto que $\kappa_2(SAS) \leq \frac{c_2}{c_1}$,

tenemos que

$$\|y_k - y_*\|_{SAS} \leq 2\left(\frac{\sqrt{\frac{c_2}{c_1}}-1}{\sqrt{\frac{c_2}{c_1}}+1}\right)^k \|y_0 - y_*\|_{SAS}, \qquad k \geq 0. \tag{5.11}$$

Además, ya que $\|z\|_{SAS}^2 = z^T SASz = (Sz)^T A(Sz) = \|Sz\|_A^2$, para todo $z \in \mathbb{R}^n$, la desigualdad anterior nos da

$$\|x_k - x_*\|_A \leq 2\left(\frac{\sqrt{\frac{c_2}{c_1}}-1}{\sqrt{\frac{c_2}{c_1}}+1}\right)^k \|x_0 - x_*\|_A, \qquad k \geq 0. \tag{5.12}$$

Por lo tanto, si $M = S^2$ es un buen precondicionador de A, esta nueva sucesión x_k converge más rápidamente a la solución x_* del sistema $Ax = b$ que la sucesión generada por el método del gradiente conjugado aplicado directamente al sistema $Ax = b$.

A continuación, reescribiremos el algoritmo anterior pensando en calcular la sucesión $x_k := Sy_k$ en vez de y_k. Para esto, definimos el residuo $r_k := b - Ax_k$ y notamos que

$$r_k = b - Ax_k = b - ASy_k = S^{-1}(Sb - SASy_k) = S^{-1}\tilde{r}_k.$$

Por otro lado, puesto que $y_{k+1} = y_k + \tilde{\alpha}_{k+1}\tilde{d}_{k+1}$ se tiene que

$$Sy_{k+1} = Sy_k + \tilde{\alpha}_{k+1}S\tilde{d}_{k+1},$$

o equivalentemente, que

$$x_{k+1} = x_k + \tilde{\alpha}_{k+1}d_{k+1},$$

donde la dirección de búsqueda d_{k+1} está dada por $d_{k+1} := S\tilde{d}_{k+1}$. Así,

$$\begin{cases} d_1 = S\tilde{d}_1 = S\tilde{r}_0 = S^2 r_0 = Mr_0, \\ d_{k+1} = S\tilde{d}_{k+1} = S(\tilde{r}_k + \tilde{\beta}_{k+1}\tilde{d}_k) = S\tilde{r}_k + \tilde{\beta}_{k+1}d_k = S^2 r_k + \tilde{\beta}_{k+1}d_k = Mr_k + \tilde{\beta}_{k+1}d_k, \quad k \geq 1. \end{cases}$$

Además, para los coeficientes $\tilde{\alpha}_{k+1}$ y $\tilde{\beta}_{k+1}$ se tiene que

$$\tilde{\alpha}_{k+1} = \frac{\tilde{r}_k^T\tilde{r}_k}{\tilde{d}_{k+1}^T SAS\tilde{d}_{k+1}} = \frac{(Sr_k)^T(Sr_k)}{(S\tilde{d}_{k+1})^T A(S\tilde{d}_{k+1})} = \frac{r_k^T SSr_k}{d_{k+1}^T Ad_{k+1}} = \frac{r_k^T Mr_k}{d_{k+1}^T Ad_{k+1}},$$

y

$$\tilde{\beta}_{k+1} = \frac{\tilde{r}_k^T\tilde{r}_k}{\tilde{r}_{k-1}^T\tilde{r}_{k-1}} = \frac{r_k^T Mr_k}{r_{k-1}^T Mr_{k-1}}.$$

Antes de escribir cómo queda el algoritmo, hacemos una observación sobre el criterio de parada. Puesto que

$$\frac{\|y_k - y_*\|_2}{\|y_*\|_2} \leq \kappa_2(SAS)\frac{\|\tilde{r}_k\|_2}{\|Sb\|_2},$$

se tiene que

$$\frac{\|x_k - x_*\|_{M^{-1}}}{\|x_*\|_{M^{-1}}} \leq \kappa_2(SAS)\frac{\|r_k\|_M}{\|b\|_M}.$$

En general, se suele parar el algoritmo cuando

$$\frac{\|r_k\|_M}{\|b\|_M} < \text{tol},$$

donde tol es una tolerancia dada.

Ahora bien, el criterio de parada controla el error en la norma $\|\cdot\|_{M^{-1}}$, mientras que toda la teoría de convergencia del método está escrita en la norma $\|\cdot\|_A$. El siguiente lema muestra que, si M es un buen precondicionador, ambas normas son *equivalentes con constantes cercanas entre sí*, de modo que controlar una es esencialmente lo mismo que controlar la otra.

Lema 5.29. *Sean A y M sdp, y supongamos que existen $0 < c_1 \le c_2$ tales que*

$$c_1 \le \frac{x^T M x}{x^T A^{-1} x} \le c_2, \qquad \forall\, x \in \mathbb{R}^n \setminus \{0\}.$$

Entonces, para todo $v \in \mathbb{R}^n$,

$$\frac{1}{c_2}\,\|v\|_A^2 \;\le\; \|v\|_{M^{-1}}^2 \;\le\; \frac{1}{c_1}\,\|v\|_A^2,$$

o equivalentemente,

$$\sqrt{c_1}\,\|v\|_{M^{-1}} \;\le\; \|v\|_A \;\le\; \sqrt{c_2}\,\|v\|_{M^{-1}}. \tag{5.13}$$

Demostración. Observemos primero que si B es sdp, entonces para todo $v \in \mathbb{R}^n$

$$v^T B^{-1} v = \max_{x \neq 0} \frac{(x^T v)^2}{x^T B x}. \tag{5.14}$$

En efecto, escribiendo $x^T v = (B^{\frac{1}{2}} x)^T (B^{-\frac{1}{2}} v)$, la desigualdad de Cauchy-Schwarz da $(x^T v)^2 \le (x^T B x)(v^T B^{-1} v)$ para todo x, y la igualdad se alcanza tomando $x = B^{-1} v$.

Sea ahora $v \in \mathbb{R}^n$, $v \neq 0$. Aplicando (5.14) con $B = M$ y con $B = A^{-1}$ obtenemos

$$\|v\|_{M^{-1}}^2 = v^T M^{-1} v = \max_{x \neq 0} \frac{(x^T v)^2}{x^T M x}, \qquad \|v\|_A^2 = v^T A v = \max_{x \neq 0} \frac{(x^T v)^2}{x^T A^{-1} x}.$$

Por hipótesis, $c_1\, x^T A^{-1} x \le x^T M x \le c_2\, x^T A^{-1} x$ para todo $x \neq 0$, y por lo tanto

$$\frac{1}{c_2} \cdot \frac{(x^T v)^2}{x^T A^{-1} x} \;\le\; \frac{(x^T v)^2}{x^T M x} \;\le\; \frac{1}{c_1} \cdot \frac{(x^T v)^2}{x^T A^{-1} x}, \qquad \forall\, x \neq 0.$$

Tomando máximo sobre $x \neq 0$ en los tres miembros resulta

$$\frac{1}{c_2}\,\|v\|_A^2 \le \|v\|_{M^{-1}}^2 \le \frac{1}{c_1}\,\|v\|_A^2,$$

que es lo que queríamos probar. □

Observación 5.30. La equivalencia (5.13) tiene "ancho" $\sqrt{c_2/c_1}$, que es precisamente la cantidad que mide la calidad del precondicionador. En el caso extremo $M = A^{-1}$ se tiene $c_1 = c_2 = 1$ y $M^{-1} = A$: las dos normas coinciden. Si $\frac{c_2}{c_1} \approx 1$, las normas $\|\cdot\|_{M^{-1}}$ y $\|\cdot\|_A$ son casi indistinguibles.

Combinando (5.13) (aplicada a $v = x_k - x_*$ y a $v = x_*$) con la estimación anterior y con $\kappa_2(SAS) \leq \frac{c_2}{c_1}$, obtenemos una cota para el error relativo *en la norma* A al salir del algoritmo:

$$\frac{\|x_k - x_*\|_A}{\|x_*\|_A} \leq \sqrt{\frac{c_2}{c_1}}\, \frac{\|x_k - x_*\|_{M^{-1}}}{\|x_*\|_{M^{-1}}} \leq \sqrt{\frac{c_2}{c_1}}\, \kappa_2(SAS)\, \frac{\|r_k\|_M}{\|b\|_M} \leq \left(\frac{c_2}{c_1}\right)^{\frac{3}{2}} \mathrm{tol}\,.$$

Es decir: el criterio de parada $\frac{\|r_k\|_M}{\|b\|_M} < \mathrm{tol}$ garantiza un error relativo en norma A del orden de tol, con una constante que *no* depende de $\kappa_2(A)$ sino solamente de la calidad del precondicionador. Comparar con lo que ocurre en el gradiente conjugado sin precondicionar, donde la constante es $\kappa_2(A)$.

Método del gradiente conjugado precondicionado.

Sean A sdp y $b \in \mathbb{R}^n$ y sean
M sdp (precondicionador de A, i.e., $M \approx A^{-1}$),
$x \in \mathbb{R}^n$ (iterando inicial),
$\text{tol} \in \mathbb{R}_+$ (tolerancia para el error relativo en norma M),
`maxiter` $\in \mathbb{N}$ (tope de iteraciones).

$r = b - Ax$; % residuo inicial
$z = Mr$,
$\rho = r^T z$; % $\rho = \|r\|_M^2$
$\text{TOL} = \text{tol}^2\, b^T M b$; % $\text{TOL} = \text{tol}^2\, \|b\|_M^2$
$k = 0$;
mientras ($\rho > \text{TOL}$ y $k <$ `maxiter`) % $\frac{\|r\|_M}{\|b\|_M} > \text{tol}$
  si $k = 0$
    $d = z$; %$d = Mr$
  sino
    $\beta = \frac{\rho}{\rho_{old}}$;
    $d = z + \beta d$;
  fin si
  $w = Ad$;
  $\alpha = \frac{\rho}{d^T w}$;
  $x = x + \alpha d$;
  $r = r - \alpha w$;
  $z = Mr$,
  $\rho_{old} = \rho$;
  $\rho = r^T z$;
  $k = k + 1$;
fin

Observación 5.31. (1) Notemos que finalmente para implementar el GCP no se necesita conocer (calcular) la raíz cuadrada S del precondicionador M. Esto fue una herramienta teórica en la deducción del método.

(2) El costo de este algoritmo es solo un producto mat-vec más por iteración que el gradiente conjugado sin precondicionar.

(3) No es necesario conocer M, basta con disponer de una rutina $\xi \to M\xi$.

En general, un *buen precondicionador* para una matriz A sdp es una matriz M sdp tal que

- La acción $\xi \to M\xi$ es "fácil" de calcular.

- $M \approx A^{-1}$ en el siguiente sentido: existen constantes c_1, c_2 tales que

$$c_1 \leq \frac{x^T M x}{x^T A^{-1} x} \leq c_2, \qquad \forall\, x \neq 0, \qquad \text{con } \frac{c_2}{c_1} \approx 1.$$

  Así, la sucesión $\{x_k\}_{k\in\mathbb{N}_0}$ generada por el gradiente conjugado precondicionado satisface

$$\|x_k - x_*\|_A \leq 2 \left(\frac{\sqrt{\frac{c_2}{c_1}} - 1}{\sqrt{\frac{c_2}{c_1}} + 1} \right)^k \|x_0 - x_*\|_A, \qquad k \geq 0.$$

Si tomáramos $M = I$, la acción $\xi \to M\xi$ es trivial de calcular, pero $\frac{c_2}{c_1}$ puede ser muy grande. Por otro lado, la "mejor elección" para satisfacer la segunda condición sería tomar $M = A^{-1}$ (y así, $c_1 = c_2 = 1$), pero la acción $\xi \to M\xi$ es tan costosa de calcular como resolver el problema original!

En general, para construir un buen precondicionador M para una matriz A hay que lograr un adecuado equilibrio entre ambas condiciones, y es necesario saber *de dónde proviene* la matriz A (por ejemplo, de la discretización de una ecuación diferencial) y usar esa información para diseñar M.

El método del gradiente conjugado precondicionado está implementado en MATLAB/OCTAVE a través de la función `pcg`. Es importante tener en cuenta que para MATLAB/OCTAVE, el precondicionador M es una aproximación de A, y no de A^{-1}, como hemos supuesto. En este caso, las condiciones dadas para un buen precondicionador deben reemplazarse por las siguientes:

- Es "fácil" resolver sistemas con matriz M (es decir, la acción $\xi \to M^{-1}\xi$ es "fácil" de calcular).
- $M \approx A$ en el siguiente sentido: existen constantes c_1, c_2 tales que

$$c_1 \leq \frac{x^T M x}{x^T A x} \leq c_2, \qquad \forall\, x \neq 0, \qquad \text{con } \frac{c_2}{c_1} \approx 1.$$

5.6.2 Precondicionadores genéricos

Existen algunos precondicionadores *genéricos*, es decir, que se construyen para cualquier A, pero en estos casos, no deberíamos esperar un cambio *dramático* en la convergencia de un método iterativo aplicado al sistema precondicionado respecto del método aplicado al sistema sin precondicionar.

Consideremos el sistema

$$Ax = b.$$

Si M es una matriz invertible, entonces

$$Ax = b \quad \Longleftrightarrow \quad MAx = Mb \quad \Longleftrightarrow \quad x = (I - MA)x + Mb.$$

Teniendo en cuenta que la iteración

$$x_{k+1} = (I - MA)x_k + Mb,$$

converge si y solo si $\rho(I - MA) < 1$, a veces se elige la matriz M de manera que

$$I - MA = B,$$

donde B es la matriz de iteración de un método iterativo estacionario.

Precondicionamiento diagonal.

Para el método de Jacobi, la matriz de iteración viene dada por

$$B_J = -D^{-1}(L+U),$$

donde D, L y U son la parte diagonal, la parte triangular inferior estricta, y la parte triangular superior estricta de A, respectivamente. Buscamos M_J tal que $I - M_J A = B_J$, o equivalentemente,

$$M_J A = I + D^{-1}(L+U) = D^{-1}(\underbrace{D+L+U}_{=A}).$$

Luego,

$$M_J = D^{-1}.$$

Esta elección para la matriz M se conoce como *precondicionamiento diagonal o de Jacobi*. Notemos que la acción $\xi \to M_J \xi$ es fácil de realizar.

Precondicionador de Gauss-Seidel simétrico.

Recordemos que la matriz de iteración del método de Gauss-Seidel viene dada por

$$B_{GS} = -(L+D)^{-1}U.$$

Por otro lado, el *método de Gauss-Seidel hacia atrás* tiene la matriz de iteración

$$B_{BGS} = -(U+D)^{-1}L.$$

Finalmente, el *método de Gauss-Seidel simétrico* consiste en aplicar una vez Gauss-Seidel (hacia adelante) y una vez Gauss-Seidel hacia atrás. Así, la matriz de iteración en este caso viene dada por

$$B_{SGS} = B_{BGS}B_{GS} = (U+D)^{-1}L(L+D)^{-1}U.$$

Si A es simétrica, se tiene que $U = L^T$ y

$$B_{SGS} = (L^T+D)^{-1}L(L+D)^{-1}L^T.$$

En este caso, el precondicionador de Gauss-Seidel simétrico está definido por

$$M_{SGS} = (L^T+D)^{-1}D(L+D)^{-1},$$

ya que

$$\begin{aligned} I - M_{SGS}A &= I - (L^T+D)^{-1}D(L+D)^{-1}(L+D+L^T) \\ &= (L^T+D)^{-1}(L^T+D-D(I+(L+D)^{-1}L^T)) \\ &= (L^T+D)^{-1}(L^T - D(L+D)^{-1}L^T) \\ &= (L^T+D)^{-1}(\underbrace{L^T((L+D)^{-1}L^T)^{-1} - D}_{=L})(L+D)^{-1}L^T \\ &= B_{SGS}. \end{aligned}$$

Notar que $\xi \to M_{SGS}\xi$ consiste en resolver un sistema triangular inferior, multiplicar una matriz diagonal por un vector y finalmente resolver un sistema triangular superior.

Precondicionadores de factorización incompleta.

Supongamos que $A = R^T R + E$, donde R es una matriz triangular superior y E es "pequeña". Podemos tomar

$$M = (R^T R)^{-1} = R^{-1}(R^T)^{-1},$$

observando que la acción $\xi \to M\xi$ consiste en resolver un sistema triangular inferior (con sustitución hacia adelante) seguido de un sistema triangular superior (con sustitución hacia atrás).

La función `cholinc` de MATLAB/OCTAVE calcula factorizaciones incompletas de matrices.

5.7 Un precondicionador basado en la estructura: multigrid en 1D

Los precondicionadores de la sección anterior son *genéricos*: se construyen a partir de las entradas de A, sin usar *de dónde proviene* la matriz. Como anticipamos, los precondicionadores más efectivos suelen aprovechar el origen del sistema. En esta sección presentamos, sobre un problema modelo unidimensional, las ideas del método *multigrid* (o de *multimalla*), que da lugar tanto a un método iterativo con costo óptimo como a uno de los mejores precondicionadores conocidos.

Observación 5.32 (Qué hace falta saber para leer esta sección)**.** El problema modelo se obtiene discretizando una ecuación diferencial, y por eso la primera subsección explica de dónde sale la matriz. Esa explicación es *autocontenida*: solo se usa la definición de derivada, y no se necesita ningún resultado sobre ecuaciones diferenciales. De ahí en adelante, todo lo que hacemos es álgebra lineal con una matriz concreta: el lector que prefiera saltear la deducción puede tomar el sistema (5.16) como dato y seguir leyendo desde la propiedad de suavizado sin más.

5.7.1 El problema modelo: de dónde sale la matriz

Supongamos que queremos determinar una función u definida en el intervalo $[0, 1]$, de la que sabemos dos cosas: cuánto vale en los extremos,

$$u(0) = u(1) = 0,$$

y cuánto vale su derivada segunda en cada punto interior,

$$-u''(x) = f(x), \qquad x \in (0, 1),$$

donde f es una función conocida. Un problema de este tipo —una ecuación que involucra derivadas de la incógnita, más datos en los extremos del intervalo— se llama *problema de valores de borde*. Es el modelo más simple de una familia de problemas que aparecen constantemente en aplicaciones: la temperatura de estado estacionario de una barra cuyos extremos se mantienen a temperatura 0 y que recibe calor a razón f, o la forma que toma

una cuerda elástica tensa, sujeta en sus extremos y sometida a una carga f, entre muchos otros.

Para lo que sigue *no necesitamos saber nada sobre este tipo de problemas*: ni si tienen solución, ni cómo son sus soluciones, ni ninguna técnica para resolverlos. Solo vamos a transformarlo en un sistema lineal, y a partir de ahí trabajaremos exclusivamente con ese sistema.

De la derivada al cociente incremental. La idea es reemplazar las derivadas por cocientes incrementales, que es de donde provienen. Recordemos que

$$u'(x) = \lim_{h\to 0} \frac{u(x+h) - u(x)}{h},$$

de modo que, para h pequeño, $u'(x) \approx \frac{u(x+h)-u(x)}{h}$: la derivada es aproximadamente la pendiente del segmento que une dos puntos cercanos del gráfico de u.

Introducimos entonces una malla uniforme de $[0,1]$ con paso $h = \frac{1}{n+1}$ y nodos

$$x_i = ih, \qquad i = 0, 1, \ldots, n+1,$$

de modo que $x_0 = 0$ y $x_{n+1} = 1$ son los extremos del intervalo, y $x_1, \ldots, x_n$ son los nodos interiores. Llamamos u_i a la aproximación de $u(x_i)$ que vamos a calcular. Por el dato del borde, $u_0 = u_{n+1} = 0$.

Para aproximar u'' aplicamos la idea dos veces. Las pendientes a la derecha y a la izquierda del nodo x_i son, respectivamente,

$$\frac{u_{i+1} - u_i}{h} \approx u'\big(x_i + \tfrac{h}{2}\big), \qquad \frac{u_i - u_{i-1}}{h} \approx u'\big(x_i - \tfrac{h}{2}\big),$$

y u'' es la derivada de u', es decir, la razón de cambio de esas pendientes:

$$u''(x_i) \;\approx\; \frac{1}{h}\left(\frac{u_{i+1} - u_i}{h} - \frac{u_i - u_{i-1}}{h}\right) = \frac{u_{i-1} - 2u_i + u_{i+1}}{h^2}. \tag{5.15}$$

Esta aproximación se llama *diferencia centrada de segundo orden*; desarrollando $u(x_i \pm h)$ por Taylor alrededor de x_i se verifica (ejercicio) que el error cometido es $O(h^2)$, o sea que la aproximación mejora rápidamente al achicar h.

El sistema lineal. Imponiendo $-u''(x_i) = f(x_i)$ en cada nodo interior y usando (5.15), obtenemos

$$\frac{-u_{i-1} + 2u_i - u_{i+1}}{h^2} = f_i, \qquad i = 1, \ldots, n, \qquad f_i := f(x_i),$$

con la convención $u_0 = u_{n+1} = 0$. Esto es un sistema de n ecuaciones lineales con n incógnitas $u_1, \ldots, u_n$:

$$A_h\, u = f, \qquad A_h = \frac{1}{h^2}\begin{pmatrix} 2 & -1 & & \\ -1 & 2 & -1 & \\ & \ddots & \ddots & \ddots \\ & & -1 & 2 \end{pmatrix} \in \mathbb{R}^{n\times n}, \tag{5.16}$$

donde $u = (u_1, \ldots, u_n)^T$ y $f = (f_1, \ldots, f_n)^T$. *A partir de aquí olvidamos el problema continuo: nuestro objetivo es resolver el sistema* (5.16).

Observación 5.33. La matriz tridiag$(-1, 2, -1)$ no es una curiosidad de este problema: salvo constantes, es la misma que aparece al calcular splines cúbicos interpolantes, mencionados al comienzo del Capítulo 2, y reaparece en incontables aplicaciones. Es el ejemplo canónico de matriz *rala*, *sdp* y *mal condicionada*, que es exactamente la combinación que motivó este capítulo.

Autovalores y autovectores. La matriz A_h es claramente simétrica. Lo notable de este problema modelo es que conocemos *exactamente* sus autovalores y autovectores. Para $k = 1, \dots, n$ definimos $\varphi^{(k)} \in \mathbb{R}^n$ por

$$\varphi_i^{(k)} = \operatorname{sen}\left(\frac{ki\pi}{n+1}\right) = \operatorname{sen}(k\pi x_i), \qquad i = 1, \dots, n, \tag{5.17}$$

es decir, $\varphi^{(k)}$ es el vector que se obtiene *muestreando* la función $\operatorname{sen}(k\pi x)$ en los nodos interiores de la malla. Usando la identidad $\operatorname{sen}(\theta - \psi) + \operatorname{sen}(\theta + \psi) = 2 \operatorname{sen}\theta \cos\psi$ con $\theta = k\pi x_i$ y $\psi = k\pi h$, se verifica que

$$(A_h \varphi^{(k)})_i = \frac{1}{h^2}\big(- \varphi_{i-1}^{(k)} + 2\varphi_i^{(k)} - \varphi_{i+1}^{(k)}\big) = \frac{2}{h^2}\big(1 - \cos(k\pi h)\big)\, \varphi_i^{(k)}$$

(la fórmula vale también en $i = 1$ y en $i = n$, porque $\varphi_0^{(k)} = \operatorname{sen}(0) = 0$ y $\varphi_{n+1}^{(k)} = \operatorname{sen}(k\pi) = 0$). Es decir, $\varphi^{(k)}$ es autovector de A_h con autovalor

$$\lambda_k = \frac{2}{h^2}\big(1 - \cos(k\pi h)\big) = \frac{4}{h^2} \operatorname{sen}^2\left(\frac{k\pi h}{2}\right), \qquad k = 1, \dots, n. \tag{5.18}$$

Como todos los λ_k son positivos, A_h es sdp. Además, los autovalores son distintos dos a dos, de modo que los n autovectores $\varphi^{(1)}, \dots, \varphi^{(n)}$ son ortogonales y forman una base de $\mathbb{R}^n$: *todo vector de* $\mathbb{R}^n$ *se escribe de manera única como combinación lineal de los* $\varphi^{(k)}$. Esta observación es la herramienta central de toda la sección.

Vectores suaves y vectores oscilatorios. Conviene *ver* los vectores de $\mathbb{R}^n$: a un vector $v = (v_1, \dots, v_n)^T$ le asociamos los puntos (x_i, v_i) del plano, unidos por segmentos. Con esa imagen, la familia $\{\varphi^{(k)}\}$ se interpreta de manera muy natural: el índice k mide cuántas oscilaciones hace el vector a lo largo de la malla, y lo llamamos la *frecuencia* del modo. Los modos con k chico se llaman *suaves* (sus componentes varían poco de un nodo al siguiente) y los de k grande, *oscilatorios* (Figura 5.2). Notemos que la frecuencia es relativa a la malla: k "chico" o "grande" significa chico o grande *comparado con* n.

El número de condición. Los autovalores (5.18) crecen con k. Para h pequeño,

$$\lambda_1 = \frac{4}{h^2} \operatorname{sen}^2\left(\frac{\pi h}{2}\right) \approx \pi^2, \qquad \lambda_n = \frac{4}{h^2} \operatorname{sen}^2\left(\frac{n\pi h}{2}\right) \approx \frac{4}{h^2},$$

de modo que

$$\kappa_2(A_h) = \frac{\lambda_n}{\lambda_1} \approx \frac{4}{\pi^2 h^2} = O(h^{-2}) = O(n^2). \tag{5.19}$$

El número de condición crece como h^{-2}: al refinar la malla, el sistema se vuelve cada vez peor condicionado. Por (5.19) y la Observación 5.20, el método del gradiente conjugado necesita del orden de $\sqrt{\kappa_2(A_h)} = O(h^{-1}) = O(n)$ iteraciones para reducir el error a una tolerancia fija, y como cada iteración cuesta $O(n)$ (la matriz es rala), el costo total es $O(n^2)$. El objetivo de multigrid es resolver (5.16) con costo *óptimo* $O(n)$.

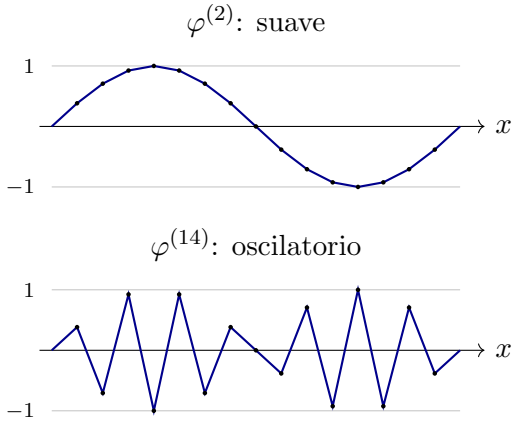


Figura 5.2 Dos autovectores de A_h para $n = 15$, dibujados como los puntos $(x_i, \varphi_i^{(k)})$ unidos por segmentos. Arriba, un modo suave; abajo, uno oscilatorio, que cambia de signo en casi cada nodo.

5.7.2 La propiedad de suavizado

La primera pieza de multigrid es un método iterativo estacionario simple, que usaremos *no* para resolver el sistema sino para *suavizar* el error. Consideremos el método de *Jacobi amortiguado* con parámetro $\omega \in (0, 1]$: siendo $D = \frac{2}{h^2} I$ la diagonal de A_h, la iteración es

$$u_{m+1} = u_m + \omega D^{-1}\big(f - A_h u_m\big) = u_m + \omega \frac{h^2}{2}\, r_m, \tag{5.20}$$

donde $r_m = f - A_h u_m$ es el residuo. (Con $\omega = 1$ se recupera el método de Jacobi del Capítulo 4: en efecto, la iteración de Jacobi $u_{m+1} = D^{-1}\big[f - (L+U)u_m\big]$ se reescribe, sumando y restando Du_m, como $u_{m+1} = u_m + D^{-1}(f - A_h u_m)$. El parámetro ω simplemente acorta el paso.) Si u_* es la solución exacta de (5.16) y $e_m = u_m - u_*$ es el error, restando $u_* = u_* + \omega D^{-1}(f - A_h u_*)$ de (5.20) obtenemos

$$e_{m+1} = R_\omega\, e_m, \qquad R_\omega := I - \omega D^{-1} A_h = I - \omega \frac{h^2}{2} A_h.$$

La clave está en que R_ω tiene los *mismos* autovectores que A_h: como $A_h \varphi^{(k)} = \lambda_k \varphi^{(k)}$, resulta

$$R_\omega \varphi^{(k)} = \mu_k \varphi^{(k)}, \qquad \mu_k = 1 - \omega \frac{h^2}{2}\lambda_k = 1 - 2\omega\, \operatorname{sen}^2\!\left(\frac{k\pi h}{2}\right), \qquad k = 1, \dots, n.$$

Como los $\varphi^{(k)}$ son base de $\mathbb{R}^n$, podemos escribir el error inicial como $e_0 = \sum_{k=1}^{n} c_k \varphi^{(k)}$, y entonces

$$e_m = R_\omega^m e_0 = \sum_{k=1}^{n} c_k\, \mu_k^m\, \varphi^{(k)}. \tag{5.21}$$

O sea: *cada modo del error se amortigua, de manera independiente de los demás, por un factor μ_k en cada iteración.* Analicemos μ_k según la frecuencia:

- **Modos suaves** (k chico): $\mu_k = 1 - 2\omega \operatorname{sen}^2(k\pi h/2) \approx 1 - 2\omega \left(\frac{k\pi h}{2}\right)^2 \approx 1$. Estos modos casi no se reducen.

- **Modos oscilatorios** (k grande, digamos $\frac{n+1}{2} \le k \le n$): aquí $\frac{k\pi h}{2} \in [\frac{\pi}{4}, \frac{\pi}{2}]$, con lo cual $\operatorname{sen}^2(k\pi h/2) \in [\frac{1}{2}, 1]$ y los μ_k quedan lejos de 1.

Esto explica, de paso, por qué los métodos estacionarios del Capítulo 4 convergen tan lentamente para esta matriz: el radio espectral de R_ω es $\max_k |\mu_k| \approx 1$, y está gobernado por los modos suaves.

Definimos el *factor de suavizado* como el peor factor de amortiguamiento sobre los modos oscilatorios,

$$\mu_{\text{suav}}(\omega) := \max_{\frac{n+1}{2} \le k \le n} |\mu_k| = \max_{\frac{\pi}{4} \le \theta \le \frac{\pi}{2}} \left|1 - 2\omega \operatorname{sen}^2\theta\right|.$$

Este máximo es fácil de calcular: llamando $s = \operatorname{sen}^2\theta$, cuando θ recorre $[\frac{\pi}{4}, \frac{\pi}{2}]$ el valor de s recorre $[\frac{1}{2}, 1]$, y $1 - 2\omega s$ es una función lineal decreciente de s; su módulo alcanza el máximo en alguno de los extremos, de donde

$$\mu_{\text{suav}}(\omega) = \max\left\{|1-\omega|,\ |1-2\omega|\right\}.$$

Para $\omega \in (0, 1]$ el primer término crece y el segundo decrece al aumentar ω, de modo que el mínimo se alcanza cuando ambos coinciden: $1 - \omega = 2\omega - 1$, es decir,

$$\omega = \frac{2}{3}, \qquad \mu_{\text{suav}}\left(\tfrac{2}{3}\right) = \frac{1}{3},$$

y esto ocurre *independientemente de* h.

Es decir: con $\omega = \frac{2}{3}$, cada barrido de Jacobi amortiguado reduce todos los modos oscilatorios del error al menos en un factor $\frac{1}{3}$, sin importar cuán fina sea la malla (Figura 5.3). En cambio, los modos suaves sobreviven casi intactos. Por eso decimos que la relajación *no resuelve* el sistema, pero *suaviza* el error: luego de unos pocos barridos, e_m es un vector suave, como ilustra la Figura 5.4.

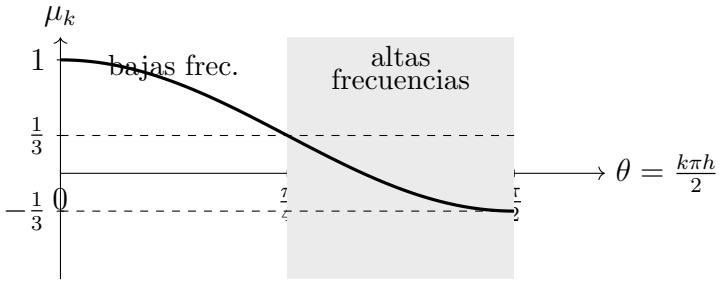


Figura 5.3 Factor de amortiguamiento $\mu_k = 1 - 2\omega \operatorname{sen}^2(k\pi h/2)$ del Jacobi amortiguado con $\omega = \frac{2}{3}$, en función de la frecuencia $\theta = \frac{k\pi h}{2}$. En la región de altas frecuencias ($\theta \in [\frac{\pi}{4}, \frac{\pi}{2}]$) se cumple $|\mu_k| \le \frac{1}{3}$; en cambio, los modos suaves (θ cerca de 0) tienen $\mu_k \approx 1$ y casi no se reducen.

5.7.3 La idea de la corrección en malla gruesa

¿Cómo atacamos los modos suaves, que la relajación no reduce? La observación central de multigrid es la siguiente: *un modo que es suave en la malla fina se ve más oscilatorio en una malla más gruesa.*

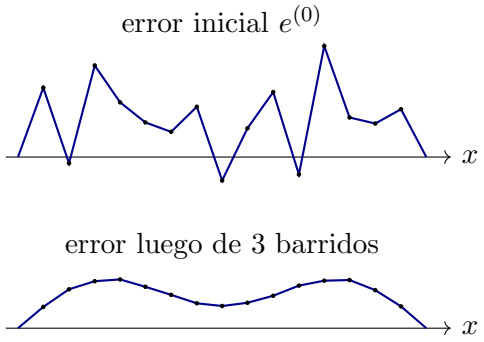


Figura 5.4 Efecto del suavizado ($n = 15$, $\omega = \frac{2}{3}$). El error inicial mezcla modos suaves y oscilatorios; tres barridos de Jacobi amortiguado eliminan casi por completo las componentes oscilatorias y dejan un error *suave*. Notar que el error *no* se hizo chico: solo cambió de forma. Los dos gráficos están en la misma escala vertical.

Esto se ve de inmediato en la fórmula (5.17). Supongamos que n es impar y consideremos la *malla gruesa* formada por los nodos de índice par, x_{2j} con $j = 1, \ldots, n_c$, donde $n_c = \frac{n-1}{2}$: es una malla del mismo intervalo, con paso $2h$ y la mitad de los puntos. Si muestreamos el modo $\varphi^{(k)}$ de la malla fina en esos nodos, obtenemos el vector de componentes

$$\varphi^{(k)}_{2j} = \operatorname{sen}\left(\frac{k\,(2j)\,\pi}{n+1}\right) = \operatorname{sen}\left(\frac{k\,j\,\pi}{n_c+1}\right), \qquad j = 1, \ldots, n_c,$$

donde usamos que $n_c + 1 = \frac{n+1}{2}$. Pero esa es exactamente la fórmula (5.17) del modo número k *de la malla gruesa*. En otras palabras: el modo k de la malla fina se transforma en el modo k de la malla gruesa. Como la malla gruesa tiene la mitad de modos ($n_c \approx n/2$ en vez de n), la frecuencia *relativa* del modo se duplicó: un k que era chico comparado con n puede ser grande comparado con n_c (Figura 5.5).

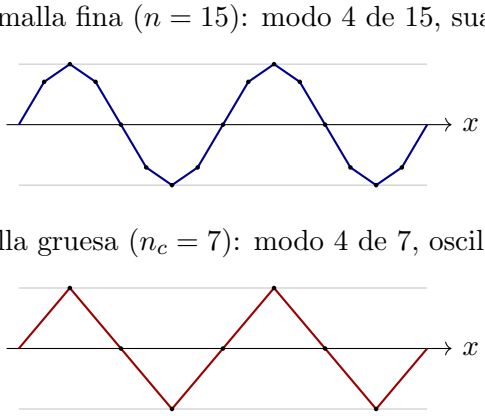


Figura 5.5 El mismo modo, visto en dos mallas. Arriba, $\varphi^{(4)}$ en la malla fina de 15 nodos: es un modo de frecuencia baja respecto de esa malla. Abajo, sus valores en los 7 nodos de la malla gruesa: ahora cambia de signo de un nodo al siguiente, o sea que es un modo *oscilatorio* respecto de la malla gruesa, y por lo tanto la relajación sí lo reduce.

Por lo tanto, si trasladamos el problema del error a una malla gruesa, allí ese error se vuelve accesible a la relajación; y además la malla gruesa tiene la mitad de incógnitas, con lo cual es más barata de tratar.

Falta un ingrediente: la incógnita del problema es u, no el error. Pero el error satisface un sistema con la misma matriz. En efecto, si u es una aproximación cualquiera y $e = u_* - u$, entonces

$$A_h\, e = A_h u_* - A_h u = f - A_h u =: r, \tag{5.22}$$

donde r es el residuo, que *sí* podemos calcular. La igualdad (5.22) se llama *ecuación residual*: es un sistema con la misma matriz A_h y con dato el residuo. Resolverla exactamente equivaldría a resolver el problema original; pero como después de suavizar sabemos que e es suave, podemos aproximarlo resolviendo una versión de (5.22) en la malla gruesa, que es un problema de la misma forma pero con la mitad de incógnitas. Una vez obtenida esa corrección aproximada, la llevamos de vuelta a la malla fina y corregimos $u \leftarrow u + e$.

5.7.4 Operadores de transferencia entre mallas

Para hacer precisa la idea anterior necesitamos operadores que trasladen vectores entre la malla fina Ω_h (con n puntos interiores) y la malla gruesa Ω_{2h} (con $n_c = \frac{n-1}{2}$ puntos interiores y paso $2h$). Para que el proceso pueda repetirse suponemos que $n + 1 = 2^L$ para algún $L \in \mathbb{N}$; en particular n es impar y n_c es entero. El punto grueso j coincide con el punto fino $2j$, es decir, $x_j^{2h} = x_{2j}^h$ (Figura 5.6).

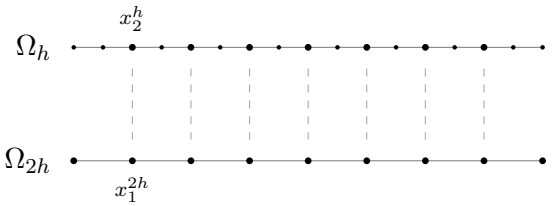


Figura 5.6 Malla fina y malla gruesa para $n = 15$ ($n_c = 7$). Los nodos de la malla gruesa son los de índice par de la fina; los de índice impar existen solo en la malla fina.

Prolongación (interpolación). El operador de prolongación $I_{2h}^h : \mathbb{R}^{n_c} \to \mathbb{R}^n$ lleva un vector de la malla gruesa a la fina por interpolación lineal:

$$\big(I_{2h}^h v\big)_{2j} = v_j, \qquad \big(I_{2h}^h v\big)_{2j+1} = \tfrac{1}{2}\big(v_j + v_{j+1}\big),$$

con la convención $v_0 = v_{n_c+1} = 0$. En los nodos que comparten ambas mallas se copia el valor; en los nodos intermedios se promedian los vecinos.

Restricción. El operador de restricción $I_h^{2h} : \mathbb{R}^n \to \mathbb{R}^{n_c}$ lleva un vector de la malla fina a la gruesa. Usamos la *ponderación completa* (*full weighting*):

$$\big(I_h^{2h} w\big)_j = \tfrac{1}{4}\big(w_{2j-1} + 2w_{2j} + w_{2j+1}\big), \qquad j = 1, \dots, n_c.$$

Es decir, el valor grueso es un promedio pesado del valor fino correspondiente y de sus dos vecinos. (Podría pensarse en simplemente copiar, $\big(I_h^{2h} w\big)_j = w_{2j}$; el promedio funciona

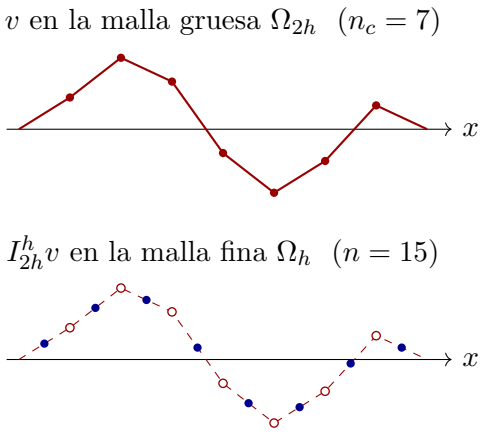
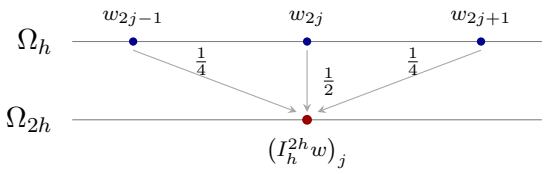


Figura 5.7 El operador de prolongación. Arriba, un vector $v \in \mathbb{R}^{n_c}$ de la malla gruesa. Abajo, el vector $I_{2h}^h v \in \mathbb{R}^n$: en los nodos que ambas mallas comparten (círculos blancos) se *copia* el valor de v, y en los nodos intermedios (puntos llenos) se pone el promedio de los dos vecinos. Los valores nuevos caen exactamente sobre los segmentos que unen los viejos (línea de trazos): por eso decimos que I_{2h}^h *interpola linealmente*.

mejor porque no ignora la información de los nodos impares, y porque hace valer la relación (5.23) de más abajo.)

El peso $\frac{1}{4}(1,2,1)$ se suele representar con el siguiente diagrama, llamado *estarcido* (*stencil*) del operador:



Estos dos operadores no son independientes: se verifica directamente que

$$I_h^{2h} = \tfrac{1}{2}\big(I_{2h}^h\big)^T. \tag{5.23}$$

Esta relación *variacional* entre restricción y prolongación es la que garantiza que el operador de dos mallas resulte simétrico, algo esencial para poder usar multigrid como precondicionador del gradiente conjugado.

Operador grueso. Finalmente, en la malla gruesa usamos la matriz de la misma familia (5.16), pero con n_c incógnitas y paso $2h$:

$$A_{2h} = \frac{1}{(2h)^2}\begin{pmatrix} 2 & -1 & & \\ -1 & 2 & -1 & \\ & \ddots & \ddots & \ddots \\ & & -1 & 2 \end{pmatrix} \in \mathbb{R}^{n_c \times n_c}.$$

Puede probarse (ejercicio) que esta elección coincide con el *operador de Galerkin* $A_{2h} = I_h^{2h} A_h I_{2h}^h$, otra manera estándar de construir el problema grueso.

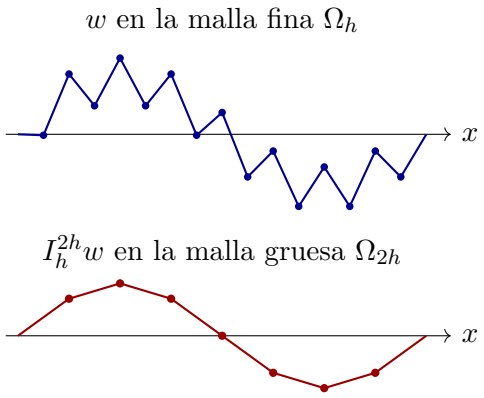


Figura 5.8 El operador de restricción. Arriba, un vector w de la malla fina, formado por una parte suave más una oscilación de la forma $(-1)^i$. Abajo, su restricción $I_h^{2h} w$: el promedio pesado $\frac{1}{4}(1, 2, 1)$ *cancela exactamente* la componente oscilatoria y reproduce la parte suave (aquí, multiplicada por $\cos^2(\pi h/2) \approx 0.96$). Ambos gráficos están en la misma escala vertical. Si en lugar de promediar se copiara el valor, $\left(I_h^{2h} w\right)_j = w_{2j}$, la oscilación *no* se cancelaría y aparecería en la malla gruesa disfrazada de componente suave.

5.7.5 El esquema de dos mallas y el ciclo en V

Reuniendo las piezas, una iteración del *esquema de dos mallas* para $A_h u = f$, partiendo de una aproximación u, consiste en:

(1) *Pre-suavizado.* Aplicar ν_1 barridos de Jacobi amortiguado a $A_h u = f$.

(2) *Residuo.* Calcular $r = f - A_h u$.

(3) *Restricción.* Trasladar el residuo a la malla gruesa: $r_{2h} = I_h^{2h} r$.

(4) *Corrección gruesa.* Resolver $A_{2h} e_{2h} = r_{2h}$.

(5) *Prolongación y corrección.* Interpolar y corregir: $u \leftarrow u + I_{2h}^h e_{2h}$.

(6) *Post-suavizado.* Aplicar ν_2 barridos de Jacobi amortiguado a $A_h u = f$.

El pre-suavizado elimina los modos oscilatorios del error; la corrección gruesa se ocupa de los modos suaves; el post-suavizado limpia las nuevas componentes oscilatorias que introduce la interpolación.

Queda un punto: el paso (4) requiere resolver un sistema con la matriz A_{2h} de la malla gruesa. Pero *ese* sistema tiene exactamente la misma estructura que el original, solo que con la mitad de las incógnitas. Entonces, en lugar de resolverlo de forma exacta, podemos aplicarle *recursivamente* el mismo esquema de dos mallas, bajando a una malla aún más gruesa, y así sucesivamente, hasta llegar a una malla tan pequeña (por ejemplo, un solo punto interior) que el sistema se resuelva de manera directa. Esta recursión es el *ciclo en V* (o *V-cycle*), esquematizado en la Figura 5.9.

El costo de un ciclo en V es proporcional al trabajo en la malla fina más el de todas las mallas gruesas. Como cada nivel tiene aproximadamente la mitad de puntos que el

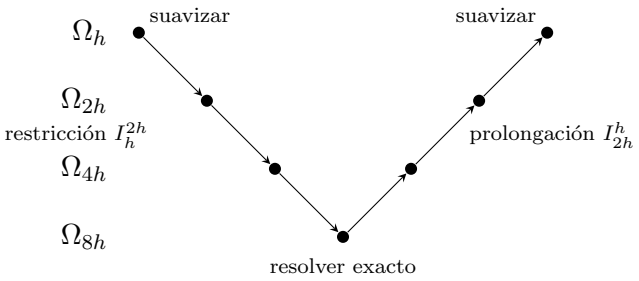


Figura 5.9 Un ciclo en V con cuatro niveles. En la rama descendente se suaviza y se restringe el residuo hacia mallas cada vez más gruesas; en el nivel más grueso se resuelve en forma exacta; en la rama ascendente se prolonga la corrección y se vuelve a suavizar.

anterior, el costo total es

$$c\,n\left(1+\tfrac{1}{2}+\tfrac{1}{4}+\cdots\right) \le 2cn = O(n),$$

es decir, *lineal* en el número de incógnitas. Además, el factor de reducción del error de un ciclo en V está acotado por una constante $\rho < 1$ *independiente de* h: es el Teorema 5.34, que enunciamos más abajo. Combinando ambos hechos: para reducir el error a una tolerancia fija hace falta un número de ciclos independiente de n, y cada ciclo cuesta $O(n)$, de modo que multigrid resuelve el problema de Poisson con costo óptimo $O(n)$, muy por debajo del $O(n^2)$ del gradiente conjugado sin precondicionar.

5.7.6 Implementación

A continuación damos una implementación del ciclo en V en MATLAB/OCTAVE. El suavizador es el Jacobi amortiguado (5.20) (matriz-libre, aprovechando la estructura tridiagonal); `restringir` y `prolongar` implementan I_h^{2h} e I_{2h}^h, y `vciclo` es la función recursiva. Seguimos la convención de nombres en minúscula del resto del texto.

```
function u = jacobiamortiguado(u,f,h,nu)
% function u = jacobiamortiguado(u,f,h,nu)
% Aplica nu barridos de Jacobi amortiguado (omega=2/3) al
% sistema de Poisson 1D A_h u = f sobre la malla interior de paso h.
% u, f son vectores columna de largo n (nodos interiores).
n = length(u);
omega = 2/3;
for m = 1:nu
   % residuo r = f - A_h u, con A_h = tridiag(-1,2,-1)/h^2
   Au = (2*u - [u(2:n);0] - [0;u(1:n-1)]) / h^2;
   u = u + omega * (h^2/2) * (f - Au);
end

function rc = restringir(r)
% function rc = restringir(r)
% Ponderacion completa (full weighting) de la malla fina a la gruesa.
```

```
% r: vector de largo n (n impar) en la malla fina.
% rc: vector de largo nc=(n-1)/2 en la malla gruesa.
n = length(r);
nc = (n-1)/2;
rc = zeros(nc,1);
for j = 1:nc
   rc(j) = ( r(2*j-1) + 2*r(2*j) + r(2*j+1) ) / 4;
end


function v = prolongar(vc)
% function v = prolongar(vc)
% Interpolacion lineal de la malla gruesa a la fina.
% vc: vector de largo nc en la malla gruesa.
% v: vector de largo n=2*nc+1 en la malla fina.
nc = length(vc);
n = 2*nc+1;
v = zeros(n,1);
vext = [0; vc; 0];            % agrega los ceros del borde
for j = 1:nc
   v(2*j) = vc(j);            % nodos comunes: se copia
end
for j = 0:nc
   v(2*j+1) = ( vext(j+1) + vext(j+2) ) / 2;   % nodos intermedios: promedio
end


function u = vciclo(u,f,h,nu1,nu2)
% function u = vciclo(u,f,h,nu1,nu2)
% Un ciclo en V para el sistema de Poisson 1D A_h u = f.
% nu1, nu2: numero de barridos de pre- y post-suavizado.
n = length(u);
if n == 1
   u = f * h^2 / 2;          % malla mas gruesa: A_h es escalar 2/h^2
   return
end
u = jacobiamortiguado(u,f,h,nu1);          % (1) pre-suavizado
Au = (2*u - [u(2:n);0] - [0;u(1:n-1)]) / h^2;
r  = f - Au;                               % (2) residuo
rc = restringir(r);                        % (3) restriccion
ec = zeros(length(rc),1);
ec = vciclo(ec,rc,2*h,nu1,nu2);            % (4) correccion gruesa (recursiva)
u  = u + prolongar(ec);                    % (5) prolongacion y correccion
u  = jacobiamortiguado(u,f,h,nu2);         % (6) post-suavizado
```

Iterando la función `vciclo` hasta que el residuo sea suficientemente pequeño se obtiene un método iterativo (multigrid) que resuelve el sistema con costo óptimo.

5.7.7 Multigrid como precondicionador del gradiente conjugado

Volvamos a nuestro tema. Un ciclo en V define, de manera natural, una acción lineal $\xi \mapsto M\xi$: dado un vector ξ, aplicamos *un* ciclo en V al sistema $A_h e = \xi$ partiendo de $e = 0$, y el resultado es $M\xi$. Es decir, M es el operador "un ciclo en V con dato inicial nulo". Este M tiene justamente las dos propiedades que pedíamos de un buen precondicionador:

- La acción $\xi \mapsto M\xi$ es *barata*: cuesta $O(n)$, por lo visto arriba.
- $M \approx A_h^{-1}$ en el sentido de la Sección 5.6, con $\frac{c_2}{c_1}$ acotado *independientemente de* h. Esto no es evidente, y lo deducimos a continuación del hecho de que un ciclo en V reduce el error en un factor $\rho < 1$ independiente de h.

Para que M sea sdp —y así poder usar el gradiente conjugado precondicionado— basta con simetrizar el ciclo: tomar $\nu_1 = \nu_2$ y usar un suavizador simétrico. El Jacobi amortiguado ya es simétrico (pues D^{-1} lo es), y la relación variacional (5.23) entre restricción y prolongación garantiza que el operador de dos mallas resultante sea simétrico. Supondremos de aquí en más que se hicieron esas elecciones, de modo que M es sdp.

De la convergencia del ciclo en V a la cota del número de condición. Veamos con cuidado cómo se encadenan los dos hechos, porque el argumento es instructivo y usa todo lo visto en las dos secciones anteriores. Consta de tres pasos.

Paso 1: el ciclo en V es un método iterativo estacionario con matriz M. Un ciclo en V aplicado a $A_h u = f$ partiendo de una aproximación u produce una nueva aproximación que depende de manera afín de u y de f; además, es *consistente*, en el sentido de que si u ya es la solución exacta, el ciclo la deja fija (el residuo es nulo, y entonces todos los suavizados y correcciones no cambian nada). Por lo tanto el ciclo se escribe como

$$u \longmapsto u + M\big(f - A_h u\big) \tag{5.24}$$

para cierta matriz M, y tomando $u = 0$ y $f = \xi$ vemos que ese M es exactamente el operador "un ciclo en V con dato inicial nulo" definido arriba. Es decir, multigrid es un método estacionario como los del Capítulo 4, cuya matriz de iteración es

$$E := I - MA_h,$$

ya que si u_* es la solución exacta, restando $u_* = u_* + M(f - A_h u_*)$ de (5.24) se obtiene que el nuevo error es E por el error viejo.

Paso 2: la convergencia del ciclo acota el espectro de MA_h. Aquí usamos el resultado central de la teoría de multigrid, cuya demostración excede los alcances de este curso.

Teorema 5.34 (Convergencia del ciclo en V)**.** *Consideremos el ciclo en V para el sistema (5.16), con Jacobi amortiguado ($\omega = \frac{2}{3}$) como suavizador, $\nu_1 = \nu_2 = \nu \geq 1$ barridos de pre- y post-suavizado, y los operadores de transferencia I_h^{2h}, I_{2h}^h definidos arriba. Sea $E = I - MA_h$ su matriz de iteración. Entonces existe una constante $\rho < 1$,* independiente de h y de la cantidad de niveles*, tal que*

$$\|Ev\|_{A_h} \leq \rho \, \|v\|_{A_h}, \qquad \forall\, v \in \mathbb{R}^n. \tag{5.25}$$

Además, ρ se puede hacer tan chico como se quiera aumentando el número ν de barridos de suavizado.

Referencias. Una presentación accesible, con el análisis de dos mallas para este mismo problema modelo, puede verse en [BHM]; el tratamiento completo —incluyendo la independencia respecto de la cantidad de niveles, que es la parte difícil, y la extensión a problemas más generales— está en [TOS].
Lo esencial de (5.25) es que ρ *no depende de* h: por más que refinemos la malla, cada ciclo en V reduce el error en norma A_h por el mismo factor. Es el mismo tipo de enunciado que vimos para los métodos estacionarios del Capítulo 4, pero allí el factor análogo tendía a 1 al refinar.

Observemos ahora que MA_h es autoadjunta respecto del producto escalar $\langle u, v\rangle_{A_h} := u^T A_h v$: si M y A_h son simétricas,

$$\langle MA_h u,\, v\rangle_{A_h} = (MA_h u)^T A_h v = u^T A_h M A_h v = \langle u,\, MA_h v\rangle_{A_h}.$$

Lo mismo vale entonces para $E = I - MA_h$. En consecuencia E es diagonalizable con autovalores reales, y su radio espectral está acotado por su norma: por (5.25),

$$|\lambda| \le \rho \qquad \text{para todo } \lambda \in \sigma(E) = \sigma(I - MA_h).$$

Como $\sigma(I - MA_h) = \{1 - \nu : \nu \in \sigma(MA_h)\}$, esto dice precisamente que

$$\sigma(MA_h) \subset [\,1 - \rho,\ 1 + \rho\,]. \tag{5.26}$$

Es decir: *el sistema precondicionado tiene todos sus autovalores agrupados alrededor de* 1, que es exactamente la situación ideal del Ejemplo 5.17 y la que persigue todo precondicionador.

Paso 3: de $\sigma(MA_h)$ *a* $\frac{c_2}{c_1}$ *y a* $\kappa_2(SA_hS)$. Sea $S = M^{\frac12}$. Por un lado, SA_hS y MA_h son semejantes, ya que $SA_hS = S^{-1}(S^2A_h)S = S^{-1}(MA_h)S$, y por lo tanto tienen el mismo espectro. Por otro lado, las mejores constantes c_1, c_2 de la definición de precondicionador son también autovalores de MA_h: escribiendo $x = A_h^{\frac12} z$ resulta

$$\frac{x^T M x}{x^T A_h^{-1} x} = \frac{z^T A_h^{\frac12} M A_h^{\frac12} z}{z^T z},$$

de modo que el cociente recorre exactamente el intervalo $[\lambda_{\min}(B), \lambda_{\max}(B)]$ con $B := A_h^{\frac12} M A_h^{\frac12}$, y B es semejante a MA_h (pues $B = A_h^{\frac12}(MA_h)A_h^{-\frac12}$). Juntando todo,

$$c_1 = \lambda_{\min}(MA_h), \qquad c_2 = \lambda_{\max}(MA_h), \qquad \frac{c_2}{c_1} = \kappa_2(SA_hS),$$

y por (5.26),

$$\boxed{\kappa_2(SA_hS) = \frac{c_2}{c_1} \le \frac{1+\rho}{1-\rho}} \tag{5.27}$$

que *no depende de* h, porque ρ no depende de h.

Qué significa en la práctica. Reemplazando (5.27) en la cota de convergencia del gradiente conjugado precondicionado, el error en norma A_h se reduce en cada iteración por el factor

$$\frac{\sqrt{\frac{c_2}{c_1}} - 1}{\sqrt{\frac{c_2}{c_1}} + 1} \le \frac{\sqrt{\frac{1+\rho}{1-\rho}} - 1}{\sqrt{\frac{1+\rho}{1-\rho}} + 1}.$$

Por ejemplo, con un valor típico $\rho = 0.1$ se obtiene $\frac{c_2}{c_1} \leq 1.22$ y un factor de reducción menor que 0.05 por iteración: unas 5 iteraciones alcanzan para ganar seis cifras, *cualquiera sea* n. Comparar con el gradiente conjugado sin precondicionar, que para esta matriz necesita $O(n)$ iteraciones.

A diferencia de los precondicionadores genéricos, cuya mejora sobre el sistema sin precondicionar es modesta, el precondicionador multigrid logra que el número de condición del sistema precondicionado quede *acotado independientemente de* h. En consecuencia, el gradiente conjugado precondicionado con multigrid converge en un número de iteraciones que *no crece* al refinar la malla: es el escenario ideal anticipado al comienzo de la sección, y se logra precisamente por haber usado la información sobre *de dónde proviene* la matriz A_h.

Observación 5.35. Aunque presentamos multigrid sobre un problema modelo unidimensional por simplicidad, las mismas ideas —suavizado, corrección en malla gruesa, transferencia entre mallas y recursión— se extienden a dos y tres dimensiones y a problemas más generales, y es en esos casos donde multigrid muestra toda su potencia como resolvedor y como precondicionador de costo óptimo.

5.8 Gradiente conjugado para problemas no simétricos

Supongamos que tenemos una matriz invertible A, no necesariamente simétrica, y consideramos el sistema

$$Ax = b.$$

CGNR.

El sistema $Ax = b$ es equivalente al sistema normal dado por

$$A^T Ax = A^T b,$$

donde ahora sí, la matriz del sistema, es decir, $A^T A$, es sdp. Por lo tanto, podemos aplicar el método del gradiente conjugado a este sistema, observando que no es necesario calcular el producto $A^T A$, sino que es suficiente proveer la rutina $\xi \to A^T(A\xi)$. Por otro lado, es importante mencionar que este método puede no resultar conveniente ya que

$$\kappa_2(A^T A) \approx \kappa_2(A)^2,$$

y así, el número de condición del sistema normal empeora si $\kappa_2(A)$ es grande.

Puesto que GC aplicado al sistema normal minimiza $\| \cdot - x_*\|_{A^T A}$ sobre $x_0 + \mathcal{K}_k$ en el nivel k y puesto que

$$\|x - x_*\|^2_{A^T A} = (x - x_*)^T A^T A(x - x_*) = (A(x - x_*))^T A(x - x_*) = \|A(x - x_*)\|_2^2 = \|Ax - b\|_2^2,$$

este método se conoce como CGNR (Conjugate Gradient on the Normal equations to minimize the Residual).

CGNE.

El sistema $Ax = b$ es equivalente al siguiente:

$$\begin{cases} AA^T y = b \\ x = A^T y. \end{cases}$$

En este caso, podemos aplicar GC para resolver el sistema $AA^T y = b$, puesto que AA^T es sdp. Notemos que en cada paso k, se minimiza $\| \cdot - y_* \|_{AA^T}$ sobre $y_0 + \mathcal{K}_k$. Tomando $x = A^T y$, se tiene que

$$\|y - y_*\|^2_{AA^T} = (y-y_*)^T AA^T (y-y_*) = (A^T(y-y_*))^T A^T (y-y_*) = \|A^T(y-y_*)\|_2^2 = \|x - x_*\|_2^2,$$

y por esto, este método se conoce como CGNE (Conjugate Gradient on the Normal equations to minimize the Error).

5.9 GMRes

5.9.1 La propiedad de minimización y sus consecuencias

El método GMRes (Generalized Minimum Residual) es un método de subespacio de Krylov para matrices que no son sdp. A diferencia de CGNR y CGNE, la iteración de GMRes no requiere el cálculo de la acción de A^T sobre un vector, lo cual puede ser ventajoso en algunos casos. Sin embargo, requiere el almacenamiento de una base para $\mathcal{K}_k$, y por lo tanto el almacenamiento necesario es mayor.

La k-ésima iteración de GMRes es la solución al problema de mínimos cuadrados siguiente

$$x_k = \underset{x \in x_0 + \mathcal{K}_k}{\operatorname{argmin}} \|b - Ax\|_2, \tag{5.28}$$

donde $\mathcal{K}_k := \operatorname{span}\{r_0, Ar_0, \ldots, A^{k-1} r_0\}$

Dejamos para más adelante la implementación efectiva (y eficiente) de cada iteración y nos enfocamos a continuación en las consecuencias que se desprenden de esta definición.

El análisis que sigue es parecido al que se hizo para GC. Observemos que

$$x \in x_0 + \mathcal{K}_k \qquad \Longleftrightarrow \qquad x = x_0 + \sum_{j=0}^{k-1} \gamma_j A^j r_0,$$

y luego

$$r = b - Ax = b - Ax_0 - \sum_{j=0}^{k-1} \gamma_j A^{j+1} r_0 = r_0 - \sum_{j=1}^{k} \gamma_{j-1} A^j r_0.$$

Es decir, $x \in x_0 + \mathcal{K}_k$ si y solo si $r = b - Ax = p(A) r_0$, con $p \in \overline{\mathcal{P}}_k$, un polinomio *residual* ($p(0) = 1$) de grado $\leq k$.

Queda entonces demostrado el siguiente teorema:

Teorema 5.36. *Sea A una matriz no singular y sea x_k la k-ésima iteración de GMRes. Entonces*

$$\|r_k\|_2 = \min_{p \in \overline{\mathcal{P}}_k} \|p(A)r_0\|_2,$$

que implica

$$\|r_k\|_2 \leq \|p(A)r_0\|_2 \leq \|p(A)\|_2 \|r_0\|_2, \tag{5.29}$$

para todo $p \in \overline{\mathcal{P}}_k$.

Inmediatamente tenemos el siguiente corolario.

Corolario 5.37. *Sea A una matriz no singular y sea x_k la k-ésima iteración de GMRes. Entonces, cualquiera sea $p \in \overline{\mathcal{P}}_k$*

$$\frac{\|r_k\|_2}{\|r_0\|_2} \leq \|p(A)\|_2.$$

Podemos ahora aplicar el corolario para demostrar que GMRes termina en un número finito de pasos.

Teorema 5.38. *Sea $A \in \mathbb{R}^{n \times n}$ una matriz no singular, entonces GMRes encontrará la solución, a lo sumo, en n pasos.*

Demostración. El polinomio característico de A es $p(z) = \det(A - zI)$, y es de grado n. Como A es no singular, resulta $p(0) = \det(A) \neq 0$ y entonces consideramos el polinomio residual

$$\bar{p}(z) := \frac{p(z)}{p(0)} \in \overline{\mathcal{P}}_n.$$

El Teorema de Cayley-Hamilton dice que el polinomio característico de una matriz A aplicado a la misma matriz A da la matriz nula. En este caso, $p(A) = 0$, y por lo tanto $\bar{p}(A) = 0$, que a su vez, por el Teorema 5.36, implica

$$r_n = b - Ax_n = 0,$$

y x_n es la solución. □

En la sección 5.3 hemos usado que para A simétrica hay una base ortonormal de autovectores, es decir $A = V\Lambda V^T$, con V ortogonal y Λ diagonal, conteniendo los autovalores de A en la diagonal. Esto sirvió para construir polinomios que permitieron obtener cotas para el decrecimiento del error. No podemos hacer lo mismo si A no es simétrica. Sin embargo, si suponemos A diagonalizable, podemos usar (5.29) e información sobre los autovalores de A para obtener cotas de decrecimiento similares a las obtenidas para GC. Supongamos que A es diagonalizable, y entonces existe una matriz no singular (*posiblemente compleja*) V tal que

$$A = V\Lambda V^{-1}.$$

Aquí Λ es una matriz diagonal (*posiblemente compleja*) con los autovalores de A sobre la diagonal, y las columnas de V son los autovectores correspondientes. Además, $A^k = V\Lambda^k V^{-1}$. Si A es normal[1] las columnas de V son ortonormales y $V^{-1} = \bar{V}^T = V^H$.

Se puede usar la estructura de matrices diagonalizables para probar el siguiente resultado, análogo al Corolario 5.14 para GC.

[1]Se dice que una matriz A es normal si A conmuta con A^T, i.e., $AA^T = A^T A$.

Teorema 5.39. *Sea $A = V\Lambda V^{-1}$ una matriz no singular diagonalizable, con Λ diagonal y sea x_k la k-ésima iteración de GMRes. Entonces, para todo $p \in \overline{\mathcal{P}}_k$, resulta*

$$\frac{\|r_k\|_2}{\|r_0\|_2} \leq \kappa_2(V) \max_{z\in\sigma(A)} |p(z)|. \tag{5.30}$$

Demostración. Sea $p \in \overline{\mathcal{P}}_k$. Entonces $p(A) = Vp(\Lambda)V^{-1}$ y luego

$$\|p(A)\|_2 \leq \|V\|_2\|V^{-1}\|_2\|p(\Lambda)\|_2 = \kappa_2(V) \max_{z\in\sigma(A)} |p(z)|. \qquad \square$$

Observemos que si A es normal, entonces V es ortogonal y $\|V\|_2 = \|V^{-1}\|_2 = 1$, por lo que $\kappa_2(V) = 1$. En general es difícil calcular $\kappa_2(V)$, y se espera que sea grande si V está cerca de ser no diagonalizable.

Enunciamos ahora un par de consecuencias sencillas de (5.30).

Corolario 5.40. *Sea A no singular y diagonalizable. Si A tiene solo k autovalores distintos, entonces GMRes terminará en a lo sumo k iteraciones.*

Corolario 5.41. *Sea A una matriz no singular. Si b es una combinación lineal de k autovectores de A, entonces el método GMRes aplicado a la resolución de $Ax = b$, partiendo de $x_0 = 0$ terminará en a lo sumo k iteraciones.*

Criterio de parada.

Como ocurre con GC, el método GMRes se considera usualmente un método iterativo. La tasa de convergencia para matrices diagonalizables involucra $\kappa_2(V)$, pero igualmente se asemeja a GC. También se han hallado tasas de convergencia para matrices no diagonalizables, pero dado que el conjunto de tales matrices tiene medida cero en el espacio de las matrices complejas de $n \times n$, no las analizaremos en este curso.

Como ocurre con GC terminaremos las iteraciones de GMRes cuando

$$\|r_k\|_2 \leq \text{tol } \|b\|_2.$$

Según el Lema 4.10, $\frac{\|e_k\|}{\|x_*\|} \leq \kappa(A)\frac{\|r_k\|}{\|b\|}$. Por lo tanto, el criterio de parada garantizará que

$$\frac{\|e_k\|_2}{\|x_*\|_2} \leq \kappa_2(A) \text{ tol},$$

es decir, el error relativo estará acotado por la tolerancia tol multiplicada por el número de condición de A.

5.9.2 Un resultado de convergencia para GMRes

El siguiente teorema simple nos dice que si A *está cerca* de la matriz identidad I, el residuo tiende a cero de manera lineal.

Teorema 5.42. *Sea A una matriz tal que $\|I - A\|_2 \leq \rho < 1$. Entonces*

$$\|r_k\|_2 \leq \rho^k\|r_0\|_2, \qquad k = 1, 2, \ldots.$$

Demostración. Consideremos $p_k(z) = (1-z)^k$, entonces $p_k \in \overline{\mathcal{P}}_k$ y $p_k(A) = (I-A)^k$, por lo tanto, el Corolario 5.37 implica que

$$\|r_k\|_2 \leq \|(I-A)^k\|_2 \|r_0\|_2 \leq \|(I-A)\|_2^k \|r_0\|_2 \leq \rho^k \|r_0\|_2.$$

□

En el Lema 4.10 vimos que

$$\frac{1}{\kappa(A)} \frac{\|A\tilde{x} - Ax\|}{\|Ax\|} \leq \frac{\|\tilde{x} - x\|}{\|x\|} \leq \kappa(A) \frac{\|A\tilde{x} - Ax\|}{\|Ax\|}.$$

La base para demostrar esto era que, en general, para $S \in \mathbb{R}^{n\times n}$ invertible,

$$\|y\| \leq \|S^{-1}Sy\| \leq \|S^{-1}\| \|Sy\|, \qquad \text{y} \qquad \|Sy\| \leq \|S\| \|y\|, \qquad \forall y \in \mathbb{R}^n.$$

En consecuencia,

$$\frac{\|Sy\|}{\|S\|} \leq \|y\| \leq \|S^{-1}\| \|Sy\|, \quad \text{y} \quad \frac{1}{\|S^{-1}\| \|S\tilde{y}\|} \leq \frac{1}{\|\tilde{y}\|} \leq \frac{\|S\|}{\|S\tilde{y}\|}, \qquad \forall y, \tilde{y} \in \mathbb{R}^n.$$

Finalmente

$$\frac{1}{\|S\| \|S^{-1}\|} \frac{\|Sy\|}{\|S\tilde{y}\|} \leq \frac{\|y\|}{\|\tilde{y}\|} \leq \|S\| \|S^{-1}\| \frac{\|Sy\|}{\|S\tilde{y}\|}, \qquad \forall y, \tilde{y} \in \mathbb{R}^n,$$

o lo que es lo mismo

$$\frac{1}{\kappa(S)} \frac{\|Sy\|}{\|S\tilde{y}\|} \leq \frac{\|y\|}{\|\tilde{y}\|} \leq \kappa(S) \frac{\|Sy\|}{\|S\tilde{y}\|}, \qquad \forall y, \tilde{y} \in \mathbb{R}^n. \tag{5.31}$$

Aplicando esta última desigualdad para $S = A$, $y = e_k := x_* - x_k$, $\tilde{y} = e_0 := x_* - x_0$, obtenemos

$$\frac{\|e_k\|_2}{\|e_0\|} \leq \kappa_2(A) \frac{\|Ae_k\|_2}{\|Ae_0\|_2} = \kappa_2(A) \frac{\|r_k\|_2}{\|r_0\|_2} \leq \kappa_2(A) \rho^k.$$

En síntesis, si $\|I - A\|_2 = \rho < 1$, el método GMRes produce soluciones aproximadas que satisfacen

$$\|e_k\|_2 \leq \kappa_2(A) \|e_0\| \rho^k, \qquad k = 1, 2, \ldots.$$

5.9.3 Precondicionamiento para GMRes

El precondicionamiento para GMRes es diferente del que se hace para GC. No debemos ahora preocuparnos porque el sistema precondicionado sea sdp y todo se reduce a hallar una matriz M que sea aproximada a A^{-1} para que se logre $\|I - MA\|_2 =: \rho_I < 1$ o $\|I - AM\|_2 =: \rho_D < 1$.

Precondicionador a izquierda.

Si disponemos de una matriz M que sea aproximada a A^{-1} de manera que

$$\|I - MA\|_2 = \rho_I < 1,$$

podemos utilizar GMRes para resolver el sistema equivalente

$$MAx = Mb,$$

y las iteraciones de GMRes satisfarán

$$\frac{\|e_k\|_2}{\|e_0\|_2} \leq \kappa_2(MA)\frac{\|r_k\|_2}{\|r_0\|_2} \leq \kappa_2(MA)\rho_I^k,$$

aquí $r_k = Mb - MAx_k$. Si además $\kappa_2(MA) \ll \kappa_2(A)$, el residuo relativo es más aproximado al error relativo y el criterio de parada será más preciso.

Precondicionador a derecha.

Si disponemos de una matriz M que sea aproximada a A^{-1} de manera que

$$\|I - AM\|_2 = \rho_D < 1,$$

entonces consideramos el siguiente problema equivalente a $Ax = b$:

$$AMy = b, \qquad x = My.$$

La idea es entonces resolver $(AM)y = b$ utilizando GMRes y luego obtener x multiplicando M por y. En este caso, el residuo satisface

$$\frac{\|r_k\|_2}{\|r_0\|_2} \leq \rho_D^k,$$

donde $r_k = b - AMy_k$, que coincide con $b - Ax_k$ y luego el error relativo cumple

$$\frac{\|e_k\|_2}{\|e_0\|_2} \leq \kappa_2(A)\frac{\|r_k\|_2}{\|r_0\|_2} \leq \kappa_2(A)\rho_D^k.$$

Si bien se gana en velocidad de convergencia, puede no ganarse nada en cómo se relaciona el residuo con el error.

Un aspecto importante de GMRes precondicionado es que no hace falta modificar el algoritmo, basta con aplicar el algoritmo al sistema $MAx = Mb$ o a $AMy = b$ y luego calcular $x = My$.

5.9.4 Implementación de GMRes

Comenzamos recordando que x_k resuelve un problema de mínimos cuadrados:

$$x_k = \underset{x \in x_0 + \mathcal{K}_k}{\operatorname{argmin}} \|b - Ax\|_2.$$

Supongamos que $\{v_1, v_2, \ldots, v_k\}$ es una base ortonormal de $\mathcal{K}_k$, por lo que

$$z \in \mathcal{K}_k \quad \Longleftrightarrow \quad z = \sum_{\ell=1}^{k} y_\ell v_\ell = \underbrace{\begin{bmatrix} v_1 & v_2 & \ldots & v_k \end{bmatrix}}_{V_k} \underbrace{\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_k \end{bmatrix}}_{y},$$

con $V_k \in \mathbb{R}^{n\times k}$, $y \in \mathbb{R}^k$. El problema resulta entonces equivalente a hallar $y \in \mathbb{R}^k$ que minimice

$$\|b - A(x_0 + V_k y)\|_2 = \|r_0 - AV_k y\|_2.$$

Es decir que queremos

$$\text{minimizar } \|r_0 - AV_k y\|_2, \quad \text{para } y \in \mathbb{R}^k. \tag{5.32}$$

Este es un problema estándar de mínimos cuadrados que podría resolverse, por ejemplo, con una factorización QR de AV_k. El problema es que sería necesario calcular el producto de A por V_k en cada iteración del algoritmo.

Si utilizamos ortogonalización de Gram-Schmidt, podemos representar la solución de (5.32) eficientemente. La ortogonalización de Gram-Schmidt aplicada al espacio de Krylov $\mathcal{K}_k$ se llama *proceso de Arnoldi*. Dados x_k, b, un mapeo $\xi \to A\xi$, y una dimensión k, el proceso de Arnoldi resulta:

Algoritmo de Arnoldi.

Dada $A \in \mathbb{R}^{n\times n}$, $x_0, b \in \mathbb{R}^n$ y $k \in \mathbb{N}$.

$r_0 = b - Ax_0$;

$v_1 = r_0/\|r_0\|_2$;

Para $i = 1, 2, \ldots, k-1$, hacer

$w_{i+1} = Av_i$;

$z_{i+1} = w_{i+1} - \sum_{j=1}^{i} (w_{i+1}^T v_j) v_j$;

$v_{i+1} = z_{i+1}/\|z_{i+1}\|_2$;

Fin Para

El vector $w_{i+1} = Av_i$ pertenece a $\mathcal{K}_{i+1}$. Si en algún paso $w_{i+1} \in \mathcal{K}_i$, la dimensión del espacio no aumenta, resulta $z_{i+1} = 0$ y el algoritmo falla (ocurre un *breakdown*). El siguiente lema dice que en este caso, resulta que la solución del problema pertenece a $x_0 + \mathcal{K}_i$, y por lo tanto ya no hace falta buscar más vectores v_i.

Lema 5.43. *Sea A no singular y sean v_j, $j = 1, 2, \ldots,$ los vectores generados por el algoritmo de Arnoldi. Sea i el menor entero para el cual*

$$z_{i+1} = Av_i - \sum_{j=1}^{i} (Av_i^T v_j) v_j = 0.$$

Entonces $x = A^{-1}b \in x_0 + \mathcal{K}_i$.

Demostración. Por la construcción del algoritmo, $Av_j \in \mathcal{K}_{j+1}$ para $j = 1, 2, \ldots, i$, y por hipótesis $\{v_1, v_2, \ldots, v_i\}$ es una base ortonormal de $\mathcal{K}_i$. Como $z_{i+1} = 0$ resulta que $Av_i \in \mathcal{K}_i$, y luego $A\mathcal{K}_i \subset \mathcal{K}_i$. Si armamos la matriz $V_i = \begin{bmatrix} v_1 & v_2 & \ldots & v_i \end{bmatrix}$, resulta que

$$AV_i = V_i H,$$

con H una matriz de $i \times i$, que es no singular pues A es inversible. Tomando $\beta = \|r_0\|_2$ y $e_1 = (1, 0, \ldots, 0)^T \in \mathbb{R}^i$ tenemos

$$\|r_i\|_2 = \|b - Ax_i\|_2 = \|r_0 - A(x_i - x_0)\|_2.$$

Como $x_i - x_0 \in \mathcal{K}_i$ existe $y \in \mathbb{R}^i$ tal que $x_i - x_0 = V_i y$, y como $r_0 = \beta V_i e_1$

$$\|r_i\|_2 = \|\beta V_i e_1 - AV_i y\|_2 = \|V_i \beta e_1 - V_i H y\|_2 = \|V_i(\beta e_1 - Hy)\|_2 = \|\beta e_1 - Hy\|_2,$$

la última igualdad es consecuencia de que V_i es ortogonal. La elección $y = \beta H^{-1} e_1$ es la que da $\|r_i\|_2 = 0$ que es el mínimo residuo sobre $x_0 + \mathcal{K}_i$. □

Si el proceso de Arnoldi no falla, podemos usarlo para implementar GMRes de manera eficiente. Llamemos

$$h_{ji} := (Av_i)^T v_j, \qquad 1 \le i \le k,\ 1 \le j \le k+1.$$

Por la construcción de Arnoldi, la matriz $H \in \mathbb{R}^{(k+1)\times k}$ cuyas entradas son las h_{ji} recién definidas resulta una matriz Hessenberg superior[2]. En efecto, por la construcción, $v_{i+1} \perp v_j$ para $j = 1, 2, \ldots, i$, y $Av_j \in \operatorname{span}\{v_1, v_2, \ldots, v_{j+1}\}$, luego $v_{i+1} \perp Av_j$ para $j = 1, 2, \ldots, i-1$.

Además, a menos que el proceso termine prematuramente, construye matrices V_k con columnas ortonormales, tal que

$$\underbrace{A}_{n\times n}\underbrace{V_k}_{n\times k} = \underbrace{V_{k+1}}_{n\times(k+1)}\underbrace{H_k}_{(k+1)\times k}.$$

Luego, para algún $y_k \in \mathbb{R}^k$,

$$r_k = b - Ax_k = r_0 - A(x_k - x_0) = V_{k+1}\underbrace{(\beta e_1 - H_k y_k)}_{\in\mathbb{R}^{k+1}}.$$

Es decir, $x_k = x_0 + V_k y_k$, con $y_k = \operatorname*{argmin}_{y\in\mathbb{R}^k} \|\beta e_1 - H_k y\|_2$. Más aún, $\|r_k\|_2 = \|b - Ax_k\|_2$ puede calcularse sin necesidad de conocer x_k. En efecto, por la ortogonalidad de V_{k+1} resulta

$$\|r_k\|_2 = \|V_{k+1}(\beta e_1 - H_k y_k)\|_2 = \|\beta e_1 - H_k y_k\|_2.$$

Recordemos que el objetivo es hallar, dado $\mathrm{tol} > 0$, un vector $x \in \mathbb{R}^n$ tal que

$$\|b - Ax\|_2 \le \mathrm{tol}\,\|b\|_2.$$

La entrada del algoritmo es una iteración inicial $x_0 \in \mathbb{R}^n$, el vector del lado derecho $b \in \mathbb{R}^n$, un mapeo $\xi \to A\xi$ que representamos con A y la tolerancia tol. Limitamos

[2]Una matriz H se dice *Hessenberg superior* si $h_{ij} = 0$, para todo $i > j + 1$.

además el máximo de iteraciones por $k_{\max}$. La salida del algoritmo será el vector x que satisfaga $\|b - Ax\|_2 \leq \text{tol}\,\|b\|_2$ o bien que se obtenga después de $k_{\max}$ iteraciones.

Método GMRes. (Versión preliminar 1)

Dada $A \in \mathbb{R}^{n\times n}$, $x_0, b \in \mathbb{R}^n$, tol > 0 y $k_{\max} \in \mathbb{N}$.

$r_0 = b - Ax_0$;

$\beta = \rho = \|r_0\|_2$;

$v_1 = r_0/\rho$;

$k = 0$

Mientras $\rho > \text{tol}\,\|b\|_2$ y $k < k_{\max}$, hacer

$k = k + 1$;

$w = Av_k$

Para $j = 1, \ldots, k$, hacer

$h_{jk} = w^T v_j$; $\quad$ % $= (Av_k)^T v_j$

Fin Para

$v_{k+1} = w - \sum_{j=1}^{k} h_{jk} v_j$; $\quad$ % (*!)

$h_{k+1,k} = \|v_{k+1}\|_2$;

$v_{k+1} = v_{k+1}/h_{k+1,k}$;

$y_k = \text{argmin}_{y\in\mathbb{R}^k} \|\beta e_1 - H_k y\|_2$; $\quad$ % (*)

$\rho = \|\beta e_1 - H_k y_k\|_2$; $\quad$ % (**)

Fin Mientras

$x_k = x_0 + V_k y_k$.

Observación 5.44. Vale la pena hacer algunas observaciones:

- El vector x_k se calcula sólo al final, y no se necesita durante las iteraciones.
- Este método requiere que se almacene la base ortonormal del espacio de Krylov a medida que se ejecuta la iteración. Esto quiere decir que para realizar k iteraciones de GMRes se deben almacenar k vectores de longitud n. Para problemas con n grande, esto puede ser un problema. Una manera de implementar esto es restringir $k_{\max}$ a lo que permita la memoria disponible, ejecutar GMRes y chequear el residuo $b - Ax_k$ al finalizar, si $k = k_{max}$ (si $k < k_{\max}$ entonces ya se logró el objetivo). Si la norma del residuo es mayor que tol $\|b\|_2$, entonces se vuelve a llamar a GMRes con $x_0 = x_{k_{\max}}$. No hay una teoría de convergencia para el algoritmo con *restart*, y en efecto, puede disminuir la velocidad de convergencia. Sin embargo, cuando funciona (muy a menudo), reduce significativamente el costo de almacenamiento de la iteración.

- Este algoritmo puede implementarse fácilmente en MATLAB/OCTAVE y el paso (*) puede resolverse directamente con la barra invertida "\" en $O(k^3)$ operaciones. Esto está bien cuando $k \ll n$, que es lo más usual. Otra opción, más recomendable es usar `qrhouse` y `qrsolve` que permiten resolver los pasos (*) y (**) simultáneamente.

- Un problema más grave con este algoritmo es que los vectores v_j pueden no ser ortogonales por errores de cancelación. Si esto ocurre, el residuo y la solución aproximada pueden ser poco precisos. Un remedio parcial a este problema consiste en reemplazar la ortogonalización de Gram-Schmidt clásica de (*!) por la siguiente modificación

  Para $j = 1, \ldots, k$

  $w = w - (w^T v_j) v_j;$

  Fin Para

  $v_{k+1} = w;$

  Los dos algoritmos coinciden cuando la precisión de los cálculos es infinita, pero la forma modificada mantiene mejor la ortogonalidad en la práctica.

Para ver la influencia de esta mejora, basta tomar $\delta = 10^{-7}$, considerar la matriz $A = \begin{bmatrix} 1 & 1 & 1 \\ \delta & \delta & 0 \\ \delta & 0 & \delta \end{bmatrix}$ y ortogonalizar usando MATLAB/OCTAVE utilizando Gram-Schmidt y su modificación. Hacer y ver cuanto se diferencia $V^T V$ de la matriz identidad en cada caso.

Con la modificación propuesta a Gram-Schmidt, el algoritmo resulta:

Método GMRes. (Versión preliminar 2)

Dada $A \in \mathbb{R}^{n\times n}$, $x_0, b \in \mathbb{R}^n$, tol > 0 y $k_{\max} \in \mathbb{N}$.

$r_0 = b - Ax_0$;

$\beta = \rho = \|r_0\|_2$;

$v_1 = r_0/\rho$;

$k = 0$

Mientras $\rho >$ tol $\|b\|_2$ y $k < k_{\max}$, hacer

$k = k + 1$;

$v_{k+1} = Av_k$

Para $j = 1, \ldots, k$, hacer

$h_{jk} = v_{k+1}^T v_j$;

$v_{k+1} = v_{k+1} - h_{jk}v_j$;

Fin Para

$h_{k+1,k} = \|v_{k+1}\|_2$;

$v_{k+1} = v_{k+1}/h_{k+1,k}$;

$y_k = \text{argmin}_{y\in\mathbb{R}^k} \|\beta e_1 - H_k y\|_2$; % (*)

$\rho = \|\beta e_1 - H_k y_k\|_2$; % (**)

Fin Mientras

$x_k = x_0 + V_k y_k$.

Aún con la modificación a Gram-Schmidt, se puede perder la ortogonalidad en las columnas de V_k. Se puede chequear la pérdida de ortogonalidad y reortogonalizar si es necesario, o usar métodos más estables para crear la matriz V. Estas implementaciones más complejas son necesarias cuando A es mal condicionada o si $k_{\max}$ es grande. No entraremos en más detalles sobre esto en este curso.

Observación 5.45. Una última observación es que la matriz H_{k+1} *contiene* a la H_k en el sentido de que se agrega una fila y una columna en cada iteración. Una manera de hacer más eficientes los pasos (*)–(**) se obtiene manteniendo la factorización QR de H_k y calculando solo lo necesario para obtener la factorización QR de H_{k+1}. Con una implementación eficiente que tenga en cuenta esto, se logra que cada iteración de GMRes necesite $O(nk)$ operaciones. Veremos esto en la subsección siguiente.

5.9.5 Implementación con rotaciones de Givens

En los pasos (*)–(**) de la versión preliminar 2 de GMRes tenemos que calcular

$$y_k = \underset{y\in\mathbb{R}^k}{\text{argmin}} \|\beta e_1 - H_k y\|_2, \qquad \text{y} \qquad \rho = \|\beta e_1 - H_k y_k\|_2.$$

Por un lado, como H_k es upper Hessenberg de $(k+1)\times k$, podemos hallar su factorización QR usando las rotaciones de Givens, como se explica en la Sección 3.6, Q será una composición o multiplicación de rotaciones de Givens de $(k+1)\times(k+1)$ y R una matriz triangular superior de $(k+1)\times k$.

Suponiendo que $R_k = Q_k^T H_k$,

$$\|\beta e_1 - H_k y_k\|_2 = \|Q_k^T(\beta e_1 - H_k y_k)\|_2 = \|\underbrace{Q_k^T \beta e_1}_{g} - \underbrace{Q_k^T H_k}_{R_k} y_k\|_2,$$

tenemos que:

- el mínimo se encuentra en $y_k = (R_k)_{1:k,1:k} \backslash g_{1:k}$, resolviendo un sistema triangular;
- y el mínimo valor es $\rho = |g_{k+1}|$.

Por último, es importante notar que no hace falta realizar completamente dichas factorizaciones en cada paso, por el siguiente motivo. Pensemos inductivamente:

- H_{k+1} se obtiene a partir de H_k agregándole una columna y completando con ceros:

$$H_{k+1} = \left[\begin{array}{ccc|c} & & & h_{1,k+1} \\ & & & h_{2,k+1} \\ & H_k & & \vdots \\ & & & \\ & & & h_{k+1,k+1} \\ \hline 0 & 0 \cdots & 0 & h_{k+2,k+1} \end{array}\right] = \begin{bmatrix} H_k & h_{1:k+1,k+1} \\ 0^T & h_{k+2,k+1} \end{bmatrix}$$

- Luego, si $H_k = Q_k R_k$,

$$H_{k+1} = \begin{bmatrix} Q_k R_k & h_{1:k+1,k+1} \\ 0^T & h_{k+2,k+1} \end{bmatrix} = \begin{bmatrix} Q_k & 0 \\ 0^T & 1 \end{bmatrix} \begin{bmatrix} R_k & Q_k^T h_{1:k+1,k+1} \\ 0^T & h_{k+2,k+1} \end{bmatrix}.$$

  Esto es casi una factorización QR de H_{k+1}, sólo nos falta hacer un cero donde está $h_{k+2,k+1}$. Para ello, insertamos una rotación de Givens $G_{k+1} := G_{k+1}(c_{k+1}, s_{k+1})$ y obtenemos

$$\begin{aligned} H_{k+1} &= \begin{bmatrix} Q_k & 0 \\ 0^T & 1 \end{bmatrix} G_{k+1}^T G_{k+1} \begin{bmatrix} R_k & Q_k^T h_{1:k+1,k+1} \\ 0^T & h_{k+2,k+1} \end{bmatrix} \\ &= \begin{bmatrix} Q_k & 0 \\ 0^T & 1 \end{bmatrix} G_{k+1}^T R_{k+1}. \end{aligned}$$

- Para ir terminando, observamos que G_{k+1} sólo afecta las filas $k+1$ y $k+2$ de la matriz a la que multiplica a su derecha, y además la última fila de R_k consta de todos ceros. Por lo tanto

$$R_{k+1} = \left[\begin{array}{cc|c} & & \\ R_k & & G_{k+1} Q_k^T h_{1:k+2,k+1} \\ & & \\ \hline 0^T & & \end{array}\right],$$

  es decir, R_{k+1} se obtiene agregando una columna a R_k con $G_{k+1} Q_k^T h_{k+1}$.

- Por último, observamos que

$$Q_{k+1} = G_1^T G_2^T \dots G_{k+1}^T = (G_{k+1} G_k \dots G_2 G_1)^T. \tag{5.33}$$

Así llegamos a la siguiente versión eficiente del algoritmo de GMRes, donde en lugar de almacenar H_k sólo almacenamos R_k (almacenamos R_k en el lugar que ocuparía H_k) y para acceder a Q_k vamos guardando los coeficientes $(c_1, s_1), \dots, (c_k, s_k)$ de las matrices de Givens que dan lugar a Q_k según la fórmula (5.33)

Método GMRes. (Versión final)

Dada $A \in \mathbb{R}^{n\times n}$, $x_0, b \in \mathbb{R}^n$, tol > 0 y $k_{\max} \in \mathbb{N}$.

$r_0 = b - Ax_0$;

$\beta = \rho = \|r_0\|_2$;

$v_1 = r_0/\rho$;

$g = \beta e_1 \in \mathbb{R}^{k_{\max}+1}$; % vector al que se le aplican las rotaciones

$k = 0$

Mientras $\rho >$ tol $\|b\|_2$ y $k < k_{\max}$, hacer

$k = k + 1$;

$v_{k+1} = Av_k$

Para $j = 1, \dots, k$, hacer

$h_{jk} = v_{k+1}^T v_j$;

$v_{k+1} = v_{k+1} - h_{jk} v_j$;

Fin Para

$h_{k+1,k} = \|v_{k+1}\|_2$;

$v_{k+1} = v_{k+1}/h_{k+1,k}$;

Si $k > 1$, entonces

$h_{1:k+1,k} = Q_{k-1}^T h_{1:k+1,k}$; % reemplazar $\mathrm{col}_k(H)$ por $Q_{k-1}^T \mathrm{col}_k(H)$ (†)

$\nu = \sqrt{h_{k,k}^2 + h_{k+1,k}^2}$;

$c_k = h_{k,k}/\nu$; $s_k = -h_{k+1,k}/\nu$; % $k-$ésima rotación de Givens G_k

$h_{k,k} = \nu$; $h_{k+1,k} = 0$ % aplicar G_k a $\mathrm{col}_k(H)$

$g = G_k(c_k, s_k)g$; % solo modifica g_k y g_{k+1}

$\rho = |g_{k+1}|$; % (**) $= \|b - Ax_k\|_2$, sin calcular x_k

Fin Mientras

$y_k = \texttt{trisup}(H_{1:k,1:k}, g_{1:k})$; % una sola vez, al final

$x_k = x_0 + V_k y_k$.

Por último observamos que en el paso (†) tenemos que aplicar Q_{k-1}^T al vector h_k. Esto se implementa a través del sucesivo cálculo de rotaciones de Givens de 2×2 a subvectores de h_k, de la siguiente manera:

$$h \leftarrow Q_{k-1}^T h = G_{k-1} G_{k-2} \dots G_2 G_1 h \quad \Longleftrightarrow \quad \begin{cases} \text{Paso } (1) & h_{1:2} = G_1 h_{1:2} \\ \text{Paso } (2) & h_{2:3} = G_2 h_{2:3} \\ & \vdots \\ \text{Paso } (k-1) & h_{k-1:k} = G_{k-1} h_{k-1:k} \end{cases}$$

Esto se puede programar de la siguiente forma

```
for j=1:k-1
    G = [c(j) -s(j); s(j) c(j)];
    H(j:j+1,k) = G*H(j:j+1,k);
end
```

Queda como ejercicio la implementación de un algoritmo que incorpore el *restart*.

Existen otros métodos iterativos basados en espacios de Krylov, pero escapan a este curso, y los vistos alcanzan para tener una idea sobre las bases de estos métodos.

5.10 Problemas

5.1. Sea $A \in \mathbb{R}^{n \times n}$ sdp. Demostrar que existe una única matriz $B \in \mathbb{R}^{n \times n}$ sdp tal que $B^2 = A$. En este caso, la matriz B se denota por $A^{\frac{1}{2}}$ y se llama la *raíz cuadrada* de A.

5.2. Sea A una matriz sdp y $b \in \mathbb{R}^n$, y sea $\phi : \mathbb{R}^n \to \mathbb{R}$ definida por

$$\phi(x) = \frac{1}{2} x^T A x - b^T x.$$

Demostrar que si x^* es la solución exacta de $Ax = b$, entonces

$$\phi(y) = \phi(x^*) + \frac{1}{2} \|y - x^*\|_A^2.$$

5.3. Para resolver el sistema lineal $Ax = b$ con el método del descenso más pronunciado y con el método del gradiente conjugado en MATLAB/OCTAVE, programar las funciones `[x, iter, X] = descmaspron(A,b,x0,tol,max_iter)` y `[x, iter, X] = gradconj(A,b,x0,tol,max_iter)`, respectivamente. Aquí, `x0` es el iterando inicial, `tol` es una tolerancia para la norma 2 del residuo, `max_iter` es la cantidad máxima de iteraciones permitidas, `x` es la aproximación obtenida con las `iter` iteraciones realizadas, y las columnas de la matriz `X` son las sucesivas aproximaciones generadas por el método. Realizar la programación de manera que el primer argumento `A` pueda ser tanto la matriz del sistema en forma explícita como una rutina que devuelve el producto matriz-vector para cada vector dado.

Importante: Puede calcular solo un producto matriz-vector por iteración.

5.4. Dada la matriz $A = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$ y el vector $b = \begin{pmatrix} 1 \\ -2 \end{pmatrix}$, dibujar las curvas de nivel de la energía del sistema $Ax = b$ y sus gradientes. Observar las direcciones de los mismos. Intentar determinar visualmente la posición del mínimo de dicha función.

(a) Determinar la solución del sistema mediante el método del descenso más pronunciado, tratando de visualizar las aproximaciones y las direcciones que se toman en cada paso. Considerar una tolerancia de 10^{-3}.

(b) Determinar la solución del sistema mediante el método del gradiente conjugado, visualizando las aproximaciones y las direcciones que se toman en cada paso hasta llegar a la solución.

5.5. Consideramos el problema de hallar la función u que satisface

$$\begin{cases} -u''(x) = f(x), & x \in (0,1) \\ \\ u(0) = u(1) = 0, \end{cases}$$

donde $f(x) = \pi^2 \operatorname{sen}(\pi x)$. Se puede verificar fácilmente que la solución de este problema es $u(x) = \operatorname{sen}(\pi x)$. Dada una partición del intervalo $[0,1]$ en $N+1$ intervalos de igual longitud $[x_0, x_1]$, $[x_1, x_2]$, $[x_2, x_3]$, ..., $[x_N, x_{N+1}]$ donde $x_0 = 0$ y $x_{N+1} = 1$, la discretización de este problema por diferencias finitas se reduce a resolver el sistema $A\mathbf{x} = b$ donde A es la matriz tridiagonal cuadrada de tamaño N que tiene 2 sobre la diagonal principal y -1 en las otras posiciones no-nulas, y el vector $b = h^2(f(x_1), f(x_2), \ldots, f(x_N))^T$, donde $h = \frac{1}{N+1}$ es la longitud de cada subintervalo.

El vector solución $\mathbf{x}$ aproxima los valores de la solución u en los puntos $x_1, x_2, \ldots, x_N$, es decir, $\mathbf{x} \approx (u(x_1), u(x_2), \ldots, u(x_N))^T$.

Considerando distintos valores de N ($N = 10, 50, 100, ...$):

(a) Cargar la matriz A en formato sparse, utilizando la función `spdiags` de MATLAB/OCTAVE. Cargar también el vector de términos independientes b.

(b) Utilizar los métodos de Jacobi, Gauss-Seidel y SOR para resolver el sistema lineal. Realizar un gráfico del error (en escala logarítmica) de cada método en función de la cantidad de iteraciones. Obtener conclusiones.

Sugerencia: Para calcular el error, utilizar como solución exacta la solución del sistema dada por el comando \ de MATLAB/OCTAVE.

(c) Analizar para diversos valores de α el comportamiento del método de Richardson. Comparar los resultados obtenidos en el item anterior.

(d) Investigar el comportamiento de los métodos del descenso más pronunciado y del gradiente conjugado para resolver el sistema lineal.

5.6. Crear una función `matvec` que para cada vector x devuelva el resultado de Ax, sin realizar el producto de manera explícita, donde

$$A = \begin{bmatrix} 2 & -1 & & & & \\ -1 & 2 & -1 & & 0 & \\ & -1 & 2 & -1 & & \\ & & \ddots & \ddots & \ddots & \\ & 0 & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix}.$$

Ayuda: Tratar de interpretar la acción de A sobre un vector dado x, y "transformarlo" según esta acción sin utilizar la matriz A.

5.7. Consideramos el problema de hallar la función u que satisface el siguiente problema de valores de borde

$$\begin{cases} -\Delta u(x,y) = f(x,y), & (x,y) \in (0,1)\times(0,1) \\ u(x,0) = u(x,1) = 0, & x \in [0,1] \\ u(0,y) = u(1,y) = 0, & y \in [0,1] \end{cases}$$

donde $f(x,y) = -2\,[x(x-1) + y(y-1)]$. Si consideramos una malla uniforme de tamaño $h = \frac{1}{N+1}$, sobre la que los nodos interiores se enumeran de izquierda a derecha y de abajo hacia arriba, la discretización de este problema por diferencias finitas se reduce a resolver el sistema $A\mathbf{x} = b$ donde A es la matriz cuadrada de tamaño N^2 expresada en bloques como

$$A = \begin{pmatrix} B & -I_N & & & & \\ -I_N & B & -I_N & & & \\ & -I_N & B & -I_N & & \\ & & & \ddots & & \\ & & & -I_N & B & -I_N \\ & & & & -I_N & B \end{pmatrix},$$

donde la matriz B de tamaño N está dada por $B = \begin{pmatrix} 4 & -1 & & & & \\ -1 & 4 & -1 & & & \\ & -1 & 4 & -1 & & \\ & & & \ddots & & \\ & & & -1 & 4 & -1 \\ & & & & -1 & 4 \end{pmatrix}$, e I_N es la matriz identidad de orden N. Las componentes del vector de términos independientes b son h^2 por el valor de f en los correspondientes puntos de la grilla (enumerados de izquierda a derecha y de abajo hacia arriba).

El vector solución $\mathbf{x}$ aproxima los valores de la solución u en los respectivos puntos de la grilla.

Considerando distintos valores de N ($N = 10, 50, 100, ...$), repetir los items (a), (b), (c) y (d) del Ejercicio 5.5.

5.8. Consideremos la cota (5.6) del Teorema 5.19 para las iteraciones del método de gradiente conjugado:

$$\|x_k - x_*\|_A \leq 2\|x_0 - x_*\|_A \left(\frac{\sqrt{\kappa_2(A)} - 1}{\sqrt{\kappa_2(A)} + 1}\right)^k.$$

Este ejercicio consiste en ver que esta cota puede ser demasiado pesimista en algunos casos. Veamos el siguiente ejemplo: Supongamos que los autovalores de una matriz simétrica A se encuentran contenidos en $[1, 1.5] \cup [399, 400] =: I$.

(a) Dar una estimación de $\kappa_2(A)$ y calcular $\dfrac{\sqrt{\kappa_2(A)} - 1}{\sqrt{\kappa_2(A)} + 1}$.

(b) Tomar el polinomio $p_{3k}(z) = \dfrac{(1.25-z)^k(400-z)^{2k}}{(1.25)^k\,(400)^{2k}}$ y considerar la estimación

$$\|x_{3k} - x_*\|_A \leq \|x_0 - x_*\|_A \max_{z\in I} |p_{3k}(z)|.$$

¿Cuál de las dos cotas es mejor? Graficar el comportamiento de las cotas como función de k y sacar conclusiones.

5.9. Sea $A \in \mathbb{R}^{n\times n}$. Demostrar que si $S \in \mathbb{R}^{n\times n}$ es invertible, entonces $\sigma(S^2A) = \sigma(SAS)$.

5.10. Sean A y S sdp, y $M = S^2$. Demostrar que si

$$c_1 \leq \frac{x^TMx}{x^TA^{-1}x} \leq c_2, \qquad \forall x \in \mathbb{R}^n \setminus \{0\},$$

entonces

$$\kappa_2(SAS) \leq \frac{c_2}{c_1}.$$

Observación: Cuando se buscan precondicionadores M que sean "cercanos" a A^{-1}, se entiende que sean cercanos en este sentido:

$$c_1 \leq \frac{x^TMx}{x^TA^{-1}x} \leq c_2, \qquad \forall x \in \mathbb{R}^n \setminus \{0\}, \qquad \text{con } \frac{c_2}{c_1} \text{ pequeño.}$$

5.11. (a) Modificar la función `gradconj` del Ejercicio 5.3 para implementar el método del gradiente conjugado precondicionado a través de la función `[x, iter, X] = gradconjp(A,b,precon,x0,tol,max_iter)`. Aquí, `precon` es el precondicionador a usar, dado como matriz en forma explícita o como una rutina que devuelve el producto matriz-vector para cada vector dado.

(b) Comparar el comportamiento del método del gradiente conjugado usual y del método precondicionado con el precondicionador de Cholesky incompleto para la resolución del sistema del Ejercicio 5.5 y/o 5.7.

5.12. (Multigrid como método iterativo.) Implementar en MATLAB/OCTAVE las funciones `jacobiamortiguado`, `restringir`, `prolongar` y `vciclo` de la Sección 5.7.

Para los experimentos, tomar $n = 2^L - 1$ y $h = \frac{1}{n+1}$, elegir un vector $u_* \in \mathbb{R}^n$ cualquiera (por ejemplo, $(u_*)_i = x_i(1-x_i)\,\mathrm{sen}(\pi x_i)$, o un vector aleatorio) y definir $f = A_h u_*$. De este modo se conoce *exactamente* la solución del sistema discreto $A_h u = f$, y se puede medir el error verdadero y no solo el residuo.

(a) *Test de consistencia.* Verificar que si se parte de $u = u_*$, un ciclo en V devuelve u_* (a menos de error de redondeo). Explicar por qué esto tiene que ser así, y por qué es una buena manera de detectar errores de programación.

(b) *Test de la relación variacional.* Construir las matrices de I_{2h}^h e I_h^{2h} aplicando las funciones a los vectores de la base canónica, y verificar numéricamente la identidad (5.23).

(c) Partiendo de $u = 0$, iterar $u \leftarrow \texttt{vciclo}(u, f, h, \nu, \nu)$ hasta que $\frac{\|f - A_h u\|_2}{\|f\|_2} < 10^{-10}$, con $\nu = 1$. Registrar la cantidad de ciclos necesarios para $L = 5, 6, \ldots, 11$. ¿Crece con n?

(d) Calcular, en cada ciclo, el cociente $\frac{\|r_{k+1}\|_2}{\|r_k\|_2}$. Verificar que se estabiliza en un valor ρ que casi no depende de h, y comparar los valores de ρ obtenidos con $\nu = 1, 2, 3$. Contrastar con el Teorema 5.34.

(e) *Comparación con el suavizador solo.* Repetir el item (c) usando únicamente `jacobiamortiguado` (es decir, sin corrección en malla gruesa), con una tolerancia más modesta como 10^{-6} y valores chicos de L. Verificar que la cantidad de barridos crece como $O(n^2)$, y explicar la diferencia a la luz de la propiedad de suavizado.

5.13. (Multigrid como precondicionador del gradiente conjugado.) Usando las funciones del Problema 5.12 y la implementación del gradiente conjugado precondicionado de la Sección 5.6, tomar como precondicionador la acción

$$\xi \longmapsto M\xi = \texttt{vciclo}(0, \xi, h, \nu, \nu),$$

es decir, un ciclo en V con dato inicial nulo.

(a) Construir la matriz M aplicando esa acción a los vectores de la base canónica (para n chico, digamos $n = 31$). Verificar numéricamente que M es simétrica cuando $\nu_1 = \nu_2$, y que *deja de serlo* si se toma $\nu_1 \neq \nu_2$. ¿Por qué importa?

(b) Calcular $\sigma(MA_h)$ y verificar que está contenido en un intervalo alrededor de 1. Comparar $\kappa_2(MA_h) = \frac{c_2}{c_1}$ con la cota $\frac{1+\rho}{1-\rho}$ de (5.27), usando el ρ medido en el Problema 5.12(d).

(c) Resolver el sistema con gradiente conjugado precondicionado, con la misma tolerancia que antes, para $L = 5, 6, \ldots, 12$. Verificar que la cantidad de iteraciones *no crece* con n. Comparar $\nu = 1$ con $\nu = 2$.

(d) Verificar que la cota de error del gradiente conjugado precondicionado, con el $\frac{c_2}{c_1}$ medido en (b), es consistente con la cantidad de iteraciones observada.

5.14. (Comparación de los cuatro métodos.) Para el mismo sistema de los dos problemas anteriores y para $L = 5, 6, \ldots, 12$, armar una tabla con la cantidad de iteraciones que necesita cada uno de los siguientes métodos para alcanzar una tolerancia fija:

(i) gradiente conjugado sin precondicionar;

(ii) gradiente conjugado con precondicionamiento diagonal (Jacobi);

(iii) multigrid solo, como método iterativo (Problema 5.12);

(iv) gradiente conjugado precondicionado con multigrid (Problema 5.13).

(a) Graficar, en escala logarítmica en ambos ejes, la cantidad de iteraciones en función de n. Identificar cuáles curvas tienen pendiente ≈ 1 y cuáles son horizontales, y relacionarlo con las cotas teóricas $O(\sqrt{\kappa_2(A_h)}) = O(n)$ y $O(1)$.

(b) Observar qué ocurre con el precondicionamiento diagonal. *Sugerencia:* mirar la diagonal de A_h. ¿Qué dice esto sobre cuándo conviene usar un precondicionador genérico?

(c) Comparar (iii) con (iv): ¿cuántos ciclos en V usa cada uno? Dado que el costo de una iteración de (iv) es esencialmente el de un ciclo en V más el de un producto mat-vec, ¿cuál de los dos resulta más barato? Interpretar el resultado: el gradiente conjugado actúa como un *acelerador* de multigrid.

(d) Estimar el costo total de cada método en operaciones (recordando que un ciclo en V cuesta $O(n)$ y que una iteración de gradiente conjugado también) y verificar que solo (iii) y (iv) alcanzan el costo óptimo $O(n)$.

(e) *(Opcional.)* Repetir las mediciones con la matriz del Problema 5.18, que incluye un término de convección y *no* es simétrica. ¿Qué falla? ¿Qué habría que cambiar?

5.15. Programar el algoritmo de GMRes con las rotaciones de Givens para que sea lo más eficiente posible.

5.16. Programar el algoritmo de GMRes con *Restart*.

5.17. Comparar el comportamiento del método del gradiente conjugado y de GMRes para resolver el sistema lineal dado en el ejercicio 5.5.

5.18. Consideramos el problema de hallar la función u que satisface

$$\begin{cases} -u''(x) + u' = f(x), & x \in (0,1) \\ \\ u(0) = u(1) = 0, \end{cases}$$

donde $f(x) = \pi^2 \operatorname{sen}(\pi x) + \pi \cos(\pi x)$. Se puede verificar fácilmente que la solución de este problema es $u(x) = \operatorname{sen}(\pi x)$. Dada una partición del intervalo $[0,1]$ en $N+1$ intervalos de igual longitud $[x_0, x_1]$, $[x_1, x_2]$, $[x_2, x_3]$, ..., $[x_N, x_{N+1}]$ donde $x_0 = 0$ y $x_{N+1} = 1$, la discretización de este problema por diferencias finitas se reduce a resolver el sistema $A\mathbf{x} = b$ donde

$$A = \frac{1}{h^2}\begin{bmatrix} 2 & -1 & & & & \\ -1 & 2 & -1 & & 0 & \\ & -1 & 2 & -1 & & \\ & & \ddots & \ddots & \ddots & \\ & 0 & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix} + \frac{1}{2h}\begin{bmatrix} 0 & 1 & & & & \\ -1 & 0 & 1 & & 0 & \\ & -1 & 0 & 1 & & \\ & & \ddots & \ddots & \ddots & \\ & 0 & & -1 & 0 & 1 \\ & & & & -1 & 0 \end{bmatrix},$$

y el vector $b = (f(x_1), f(x_2), \ldots, f(x_N))^T$, donde $h = \frac{1}{N+1}$ es la longitud de cada subintervalo.

El vector solución $\mathbf{x}$ aproxima los valores de la solución u en los puntos $x_1, x_2, \ldots, x_N$, es decir, $\mathbf{x} \approx (u(x_1), u(x_2), \ldots, u(x_N))^T$.

Considerando distintos valores de N ($N = 10, 50, 100, ...$), comparar el comportamiento de GMRes, CGNE, CGNR para resolver el sistema lineal.

5.19. Demostrar el Corolario 5.40.

5.20. Demostrar el Corolario 5.41.

Capítulo 6

Sistemas de ecuaciones no lineales

En este capítulo estudiaremos métodos para resolver sistemas de ecuaciones no lineales. En general, para $n \in \mathbb{N}$, un sistema de n ecuaciones con n incógnitas $(x_1, x_2, \ldots, x_n)$ viene dado por

$$\begin{cases} f_1(x_1, x_2, \ldots, x_n) = 0 \\ f_2(x_1, x_2, \ldots, x_n) = 0 \\ \quad \vdots \\ f_n(x_1, x_2, \ldots, x_n) = 0, \end{cases} \tag{6.1}$$

donde $f_i : D \subset \mathbb{R}^n \to \mathbb{R}$, para $i = 1, 2, \ldots, n$. El sistema (6.1) siempre puede escribirse como

$$F(x) = 0, \tag{6.2}$$

donde $F : D \subset \mathbb{R}^n \to \mathbb{R}^n$ está dada por $F(x) = \begin{pmatrix} f_1(x) \\ f_2(x) \\ \vdots \\ f_n(x) \end{pmatrix}$, para $x \in D$.

Ejemplo 6.1. Para $n = 1$, un sistema de una ecuación con una incógnita es simplemente *una ecuación no lineal*, por ejemplo, hallar $x \in \mathbb{R}$ tal que

$$x - \tan x + 1 = 0.$$

Ejemplo 6.2. Para $n = 2$, se tiene un sistema de dos ecuaciones con dos incógnitas, cuya solución en general representa la intersección de dos curvas en el plano, por ejemplo, hallar $(x_1, x_2) \in \mathbb{R}^2$ tales que

$$\begin{cases} x_1^2 + x_2^2 = 1 \\ \frac{x_1^2}{9} + 4x_2^2 = 1. \end{cases}$$

Cuando un sistema de n ecuaciones con n incógnitas es lineal, la solución o las soluciones representan la intersección de n hiperplanos en $\mathbb{R}^n$, y en este caso sabemos que existen sólo tres posibilidades, a saber: tiene una única solución, tiene infinitas soluciones, o no tiene ninguna. En el caso de un sistema *no lineal* de n ecuaciones con n incógnitas la solución o las soluciones (si existen) corresponden a la intersección de n hipersuperficies

en $\mathbb{R}^n$ y pueden darse todas las posibilidades, es decir, puede no tener solución, o puede tener una cantidad finita o infinita de soluciones.

La necesidad de resolver sistemas de ecuaciones no lineales surge, por ejemplo, cuando se quiere hallar el mínimo de una función de varias variables $f : \mathbb{R}^n \to \mathbb{R}$. Sabemos que si f es diferenciable y alcanza su mínimo en un valor $x_* \in \mathbb{R}^n$ entonces

$$\nabla f(x_*) = 0,$$

es decir, x_* debe ser solución del sistema no lineal (6.2) con $F(x) := \nabla f(x)$.

Otra situación en donde surge la necesidad de resolver un sistema de ecuaciones no lineales, es al aplicar métodos implícitos para resolver problemas de valores iniciales (PVI).

En este capítulo estudiaremos métodos numéricos para resolver sistemas de ecuaciones no lineales. Antes de presentar estos métodos, recordamos algunos conceptos de cálculo en varias variables. En lo que sigue, $\|\cdot\|$ denota una norma en $\mathbb{R}^n$.

Definición 6.3 (Función diferenciable)**.** Sea $D \subset \mathbb{R}^n$ abierto y sea $F : D \to \mathbb{R}^n$. Decimos que F *es diferenciable en* $x_0 \in D$ si existe $J \in \mathbb{R}^{n\times n}$ tal que

$$\lim_{x\to x_0} \frac{\|F(x) - F(x_0) - J(x - x_0)\|}{\|x - x_0\|} = 0.$$

En este caso, la matriz J se llama *matriz jacobiana* de F en x_0 y se denota por $F'(x_0)$.

Se puede demostrar que si F es diferenciable en x_0, la matriz jacobiana es única y viene dada por

$$F'(x_0) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1}(x_0) & \frac{\partial f_1}{\partial x_2}(x_0) & \cdots & \frac{\partial f_1}{\partial x_n}(x_0) \\ \frac{\partial f_2}{\partial x_1}(x_0) & \frac{\partial f_2}{\partial x_2}(x_0) & \cdots & \frac{\partial f_2}{\partial x_n}(x_0) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1}(x_0) & \frac{\partial f_n}{\partial x_2}(x_0) & \cdots & \frac{\partial f_n}{\partial x_n}(x_0) \end{pmatrix} = \begin{pmatrix} \nabla f_1(x_0)^T \\ \nabla f_2(x_0)^T \\ \vdots \\ \nabla f_n(x_0)^T \end{pmatrix}, \text{ si } F(x) = \begin{pmatrix} f_1(x) \\ f_2(x) \\ \vdots \\ f_n(x) \end{pmatrix};$$

es decir, diferenciabilidad en x_0 implica existencia de todas las derivadas parciales en x_0.

Definición 6.4 (Función continuamente diferenciable)**.** Sea $D \subset \mathbb{R}^n$ abierto y sea $F : D \to \mathbb{R}^n$ con $F(x) = \begin{pmatrix} f_1(x) \\ f_2(x) \\ \vdots \\ f_n(x) \end{pmatrix}$. Decimos que F *es continuamente diferenciable en* $x_0 \in D$ si $\frac{\partial f_i}{\partial x_j}$ es continua en x_0, para $i, j = 1, 2, \ldots, n$.

6.1 Métodos de punto fijo

Dado el sistema $F(x) = 0$, queremos transformarlo en una ecuación (vectorial) de la forma $x = G(x)$, donde $G : D \subset \mathbb{R}^n \to \mathbb{R}^n$ es, en general, una función no lineal. La *iteración de punto fijo* asociada a la función G se define por:

$$x_{k+1} = G(x_k), \qquad k = 0, 1, \ldots \tag{6.3}$$

donde $x_0 \in D$ es un valor inicial dado. En este caso, la función G se llama *función de iteración*.

Observación 6.5. Sea $F(x) = Ax - b$, donde $A \in \mathbb{R}^{n\times n}$ y $b \in \mathbb{R}^n$. Si reescribimos el sistema $F(x) = 0$ como $x = G(x)$ donde $G(x) = Mx + c$, para $M \in \mathbb{R}^{n\times n}$ y $c \in \mathbb{R}^n$, entonces la iteración de punto fijo (6.3) es un método iterativo estacionario para el sistema lineal $F(x) = 0$ ($Ax = b$). Así, podemos pensar la iteración de punto fijo (6.3) como una generalización al caso de sistemas no lineales de los métodos iterativos estacionarios definidos para sistemas lineales.

Definición 6.6 (Punto fijo)**.** Decimos que $x_* \in D$ es *un punto fijo* de $G : D \subset \mathbb{R}^n \to \mathbb{R}^n$ si

$$x_* = G(x_*).$$

Definición 6.7 (Punto de atracción)**.** Sea $G : D \subset \mathbb{R}^n \to \mathbb{R}^n$ y sea $x_* \in D$ un punto fijo de G. Decimos que x_* es *un punto de atracción de* G, o equivalentemente, que *la iteración* (6.3) *converge localmente a* x_*, si existe $\delta > 0$ tal que para todo $x_0 \in B(x_*, \delta)$ se cumple que $x_{k+1} := G(x_k) \in B(x_*, \delta)$, para todo $k = 0, 1, \ldots$ y

$$\lim_{k\to\infty} x_k = x_*.$$

El siguiente resultado nos da una condición suficiente para determinar cuándo un punto fijo de G es un punto de atracción.

Teorema 6.8 (Teorema de Ostrowski)**.** *Sea $G : \mathbb{R}^n \to \mathbb{R}^n$ diferenciable en un punto $x_* \in \mathbb{R}^n$ tal que $x_* = G(x_*)$. Si $\rho(G'(x_*)) < 1$ entonces x_* es un punto de atracción.*

Observación 6.9. Notemos que este resultado es una generalización del teorema de convergencia de métodos iterativos estacionarios para sistemas lineales (ver Teorema 4.25), ya que si $G(x) = Mx + c$, se tiene que $G'(x) = M$ para todo $x \in \mathbb{R}^n$. Notemos en particular que en el caso de que el sistema es no lineal este teorema es sólo una condición suficiente para la convergencia y por otro lado, que ésta se garantiza sólo localmente, es decir, partiendo de un valor inicial x_0 suficientemente cerca de x_*.

Demostración del Teorema 6.8. Sea $\sigma := \rho(G'(x_*)) < 1$ y elijamos $\varepsilon > 0$ (fijo) tal que $\sigma + 2\varepsilon < 1$. Por el Teorema 4.20, sabemos que existe una norma inducida $\|\cdot\|$ tal que

$$\|G'(x_*)\| < \sigma + \varepsilon.$$

Por otro lado, puesto que G es diferenciable en x_*, existe $\delta > 0$ tal que si $x \in B(x_*, \delta)$ entonces

$$\|G(x) - G(x_*) - G'(x_*)(x - x_*)\| < \varepsilon\|x - x_*\|.$$

Sea $x_0 \in B(x_*, \delta)$ y $x_{k+1} := G(x_k)$, para $k = 0, 1, 2, \ldots$. Notemos que si $x_k \in B(x_*, \delta)$, para algún $k \in \mathbb{N}_0$,

$$\begin{aligned}\|x_{k+1} - x_*\| = \|G(x_k) - G(x_*)\| &\le \|G(x_k) - G(x_*) - G'(x_*)(x_k - x_*)\| + \|G'(x_*)(x_k - x_*)\| \\ &< \varepsilon\|x_k - x_*\| + (\sigma + \varepsilon)\|x_k - x_*\| = (\sigma + 2\varepsilon)\|x_k - x_*\| < \|x_k - x_*\|,\end{aligned}$$

y en consecuencia, $x_{k+1} \in B(x_*, \delta)$. Así, tenemos que $x_k \in B(x_*, \delta)$, para todo $k \in \mathbb{N}_0$. Por otro lado, de la última estimación se sigue también que

$$\|x_{k+1} - x_*\| \le (\sigma + 2\varepsilon)^{k+1}\|x_0 - x_*\|, \qquad k = 0, 1, \ldots$$

Puesto que $\sigma + 2\varepsilon < 1$, tenemos que $x_k \to x_*$ cuando $k \to \infty$, lo que concluye la demostración. □

En el resultado anterior se necesita conocer de antemano la existencia de un punto fijo de la función de iteración, y más aún, se pide que ésta sea diferenciable en dicho punto. A continuación establecemos un resultado que garantiza la existencia de un único punto fijo y la convergencia de la iteración correspondiente sin pedir diferenciabilidad. Recordamos antes dos conceptos que serán importantes.

Definición 6.10 (Función Lipschitz)**.** Decimos que $G : D \subset \mathbb{R}^n \to \mathbb{R}^n$ es *Lipschitz continua* sobre D con constante $\gamma > 0$ si

$$\|G(x) - G(y)\| \leq \gamma \|x - y\|, \qquad \forall\, x, y \in D.$$

Definición 6.11 (Contracción)**.** Decimos que $G : D \subset \mathbb{R}^n \to \mathbb{R}^n$ es *una contracción* en D con la norma $\|\cdot\|$ si G es Lipschitz continua con constante $0 < \gamma < 1$, es decir, si existe $\gamma \in (0, 1)$ tal que

$$\|G(x) - G(y)\| \leq \gamma \|x - y\|, \qquad \forall\, x, y \in D.$$

Teorema 6.12 (Contraction Mapping Theorem)**.** *Sea $D \subset \mathbb{R}^n$ cerrado. Sea $G : D \to D$ una contracción en D (con alguna norma $\|\cdot\|$) con constante $0 < \gamma < 1$. Entonces, existe un único punto fijo x_* de G en D y x_* es un punto de atracción de G. Más aún, para todo $x_0 \in D$, la iteración*

$$x_{k+1} = G(x_k), \qquad k = 0, 1, \ldots$$

está bien definida y se cumplen:

- *Convergencia lineal:*

$$\|x_{k+1} - x_*\| \leq \gamma \|x_k - x_*\|, \qquad k = 0, 1, \ldots$$

- *Estimación del error:*

$$\|x_k - x_*\| \leq \frac{\gamma^k}{1 - \gamma} \|x_1 - x_0\|, \qquad k = 0, 1, \ldots$$

Demostración. Sea $x_0 \in D$. Puesto que $G : D \to D$, la iteración

$$x_{k+1} := G(x_k), \qquad k = 0, 1, 2, \ldots$$

está bien definida. Demostraremos ahora que $\{x_k\}_{k \in \mathbb{N}_0}$ es una sucesión de Cauchy.

Puesto que G es una contracción, tenemos que

$$\|x_{i+1} - x_i\| = \|G(x_i) - G(x_{i-1})\| \leq \gamma \|x_i - x_{i-1}\| \leq \cdots \leq \gamma^i \|x_1 - x_0\|,$$

y luego, para $k \in \mathbb{N}_0$ y $p \in \mathbb{N}$,

$$\begin{aligned} \|x_{k+p} - x_k\| &\leq \sum_{i=k}^{k+p-1} \|x_{i+1} - x_i\| \leq \left(\sum_{i=k}^{k+p-1} \gamma^i \right) \|x_1 - x_0\| \\ &= \frac{\gamma^k - \gamma^{k+p}}{1 - \gamma} \|x_1 - x_0\| \leq \frac{\gamma^k}{1 - \gamma} \|x_1 - x_0\|. \end{aligned}$$

Teniendo en cuenta que $\gamma < 1$, concluimos que $\{x_k\}_{k\in\mathbb{N}}$ es una sucesión de Cauchy en $\mathbb{R}^n$. En consecuencia, existe $x_* \in \mathbb{R}^n$ tal que

$$\lim_{k\to\infty} x_k = x_*.$$

Puesto que D es cerrado y que $\{x_k\}_{k\in\mathbb{N}} \subset D$, se tiene que $x_* \in D$. Por otro lado, puesto que G es continua se tiene que

$$\lim_{k\to\infty} G(x_k) = G(x_*),$$

y como $G(x_k) = x_{k+1}$, tenemos que $x_* = G(x_*)$, es decir, que x_* es un punto fijo de G.

Es fácil verificar que x_* es el único punto fijo de G. En efecto, si $y_* \in D$ es un punto fijo de G distinto de x_*, entonces

$$\|y_* - x_*\| = \|G(y_*) - G(x_*)\| \leq \gamma\|y_* - x_*\| < \|y_* - x_*\|,$$

lo cual no puede ocurrir.

Hasta aquí hemos demostrado que G tiene un único punto fijo $x_* \in D$, y que para cualquier $x_0 \in D$, la iteración de punto fijo $x_{k+1} = G(x_k)$, para $k \in \mathbb{N}_0$, está bien definida y converge a x_*. Sólo resta ver que la convergencia es lineal y la estimación de error.

Usando nuevamente que G es una contracción, tenemos que

$$\|x_{k+1} - x_*\| = \|G(x_k) - G(x_*)\| \leq \gamma\|x_k - x_*\|, \qquad k = 0, 1, 2, \ldots,$$

y por lo tanto, $\{x_k\}_{k\in\mathbb{N}}$ converge linealmente. Finalmente, recordando que

$$\|x_{k+p} - x_k\| \leq \frac{\gamma^k}{1-\gamma}\|x_1 - x_0\|, \qquad \forall k \in \mathbb{N}_0,\ p \in \mathbb{N},$$

y tomando el límite cuando p tiende a infinito, obtenemos la estimación de error deseada. □

Observación 6.13. Si $D = \mathbb{R}^n$ y $G(x) := Mx + c$, notemos que G es una contracción en alguna norma si y sólo si $\rho(M) < 1$. En efecto, si para alguna norma $\|\cdot\|$ y algún $0 < \gamma < 1$ se cumple que

$$\|G(x) - G(y)\| \leq \gamma\|x - y\|, \qquad \forall\, x, y \in \mathbb{R}^n,$$

se tiene que

$$\rho(M) \leq \|M\| = \sup_{z\in\mathbb{R}^n} \frac{\|Mz\|}{\|z\|} = \sup_{z\in\mathbb{R}^n} \frac{\|G(z) - G(0)\|}{\|z\|} \leq \gamma < 1.$$

Por otro lado, si $\rho(M) < 1$, por el Teorema 4.20 sabemos que existe una norma inducida $\|\cdot\|$ tal que $\|M\| < 1$, y por lo tanto,

$$\|G(x) - G(y)\| = \|Mx + c - (My + c)\| = \|M(x - y)\| \leq \|M\|\|x - y\|, \qquad \forall\, x, y \in \mathbb{R}^n,$$

lo que demuestra que G es una contracción en la norma $\|\cdot\|$.

Así, podemos ver al Teorema 6.12 como una generalización al caso no lineal del Teorema 4.25, que establece una caracterización de la convergencia de métodos de punto fijo asociados a sistemas lineales.

A continuación, y para concluir esta sección, nos proponemos establecer un criterio para determinar cuándo una función diferenciable G es una contracción en alguna norma (ver Corolario 6.19 debajo) y así poder utilizar el Teorema 6.12.

Definición 6.14 (Integral de funciones vectoriales)**.** Sea $H : [a, b] \to \mathbb{R}^n$. Si $H(t) = \begin{pmatrix} h_1(t) \\ h_2(t) \\ \vdots \\ h_n(t) \end{pmatrix}$, entonces $\displaystyle\int_a^b H(t)dt := \begin{pmatrix} \int_a^b h_1(t)\ dt \\ \int_a^b h_2(t)\ dt \\ \vdots \\ \int_a^b h_n(t)\ dt \end{pmatrix}$.

Definición 6.15 (Conjunto convexo en $\mathbb{R}^n$)**.** Un conjunto $D \subset \mathbb{R}^n$ es *convexo* si para todo par de puntos de D, el segmento que los une está contenido en D, esto es, si

$$\forall\, x, y \in D, \quad t \in [0, 1], \qquad tx + (1 - t)y \in D.$$

El siguiente teorema es una generalización del Teorema Fundamental del Cálculo para funciones de varias variables.

Teorema 6.16 (Teorema Fundamental del Cálculo)**.** *Sea $D \subset \mathbb{R}^n$ convexo. Si $G : D \to \mathbb{R}^n$ es continuamente diferenciable en D entonces*

$$G(y) - G(x) = \int_0^1 G'(x + t(y - x))(y - x)\ dt, \qquad \forall\, x, y \in D.$$

Demostración. Sea $G = \begin{pmatrix} g_1 \\ g_2 \\ \vdots \\ g_n \end{pmatrix}$ y sean $x, y \in D$ fijos. Para $i = 1, 2, \ldots, n$, definimos $h_i(t) := g_i(x + t(y - x))$, para $t \in [0, 1]$. Entonces, $h_i'(t) = \nabla g_i(x + t(y - x))^T(y - x)$ y por el Teorema Fundamental del Cálculo tenemos que

$$g_i(y) - g_i(x) = h_i(1) - h_i(0) = \int_0^1 h_i'(t)\ dt = \int_0^1 \nabla g_i(x + t(y - x))^T(y - x)\ dt,$$

lo que concluye la demostración. □

Teorema 6.17. *Si $H : [a, b] \to \mathbb{R}^n$ es continua entonces, para cualquier norma de $\mathbb{R}^n$,*

$$\left\| \int_a^b H(t)\ dt \right\| \leq \int_a^b \|H(t)\|\ dt.$$

Demostración. La demostración se deja como ejercicio (ver Ejercicio 6.7). □

Como consecuencia de los dos últimos teoremas tenemos el siguiente resultado.

Teorema 6.18. *Sea $D \subset \mathbb{R}^n$ convexo. Si $G : D \to \mathbb{R}^n$ es continuamente diferenciable en D entonces*

$$\|G(y) - G(x)\| \leq \max_{t \in [0,1]} \|G'(x + t(y - x))\| \|y - x\|, \qquad \forall\, x, y \in D;$$

aquí, $\|\cdot\|$ denota tanto una norma de $\mathbb{R}^n$ como la norma inducida por ella en el espacio de las matrices.

Demostración. Por el Teorema 6.16 se tiene que

$$G(y) - G(x) = \int_0^1 G'(x + t(y - x))(y - x)\ dt, \qquad \forall\, x, y \in D.$$

Teniendo en cuenta ahora el Teorema 6.17 obtenemos

$$\begin{aligned}\|G(y) - G(x)\| &\leq \int_0^1 \|G'(x + t(y - x))(y - x)\|\ dt \leq \int_0^1 \|G'(x + t(y - x))\|\|y - x\|\ dt \\ &\leq \max_{t\in[0,1]} \|G'(x + t(y - x))\|\|y - x\|.\end{aligned}$$

□

Finalmente, una aplicación inmediata del teorema anterior nos permite establecer el siguiente corolario.

Corolario 6.19. *Sea $D \subset \mathbb{R}^n$ convexo. Si $G : D \to \mathbb{R}^n$ es continuamente diferenciable en D y existe $\alpha > 0$ tal que*

$$\|G'(x)\| \leq \alpha, \qquad \forall\, x \in D,$$

entonces

$$\|G(x) - G(y)\| \leq \alpha\|x - y\|, \qquad \forall\, x, y \in D.$$

6.2 El método de Newton

Consideremos el sistema $F(x) = 0$, y supongamos que F es continuamente diferenciable en un entorno de una solución x_* del sistema. Dada una aproximación x_k de la solución, consideramos la aproximación lineal afín de F dada por

$$P(x) := F(x_k) + F'(x_k)(x - x_k),$$

y definimos x_{k+1} tal que $P(x_{k+1}) = 0$, es decir,

$$F'(x_k)(x_{k+1} - x_k) = -F(x_k),$$

o, suponiendo que $F'(x_k)$ es invertible,

$$x_{k+1} = x_k - (F'(x_k))^{-1}F(x_k).$$

La iteración anterior corresponde al *método de Newton*. En la práctica no se calcula nunca explícitamente la matriz $(F'(x_k))^{-1}$, sino que se resuelve un sistema lineal asociado a la matriz $F'(x_k)$. Más precisamente, dado x_k se obtiene x_{k+1} de la siguiente manera:

$$\begin{cases}\text{Hallar } h \in \mathbb{R}^n \text{ tal que } F'(x_k)h = F(x_k). \\ x_{k+1} = x_k - h.\end{cases} \tag{6.4}$$

Notemos que el método de Newton es una iteración de punto fijo cuya función de iteración es

$$G(x) := x - (F'(x))^{-1}F(x).$$

La primera pregunta importante que surge es bajo qué hipótesis la iteración de Newton está bien definida. Notemos que en particular se necesita que la matriz jacobiana de F sea invertible. Los siguientes resultados nos llevaran a saber en qué circunstancias ésto ocurre.

Lema 6.20 (Perturbación de la matriz Identidad)**.** *Sea $M \in \mathbb{R}^{n\times n}$. Si $\|M\| < 1$ para alguna norma inducida, entonces $I - M$ es invertible y*

$$\|(I-M)^{-1}\| \leq \frac{1}{1-\|M\|}.$$

Demostración. Ver demostración del Teorema 4.25. □

Lema 6.21 (Perturbación de una matriz invertible)**.** *Sea $A \in \mathbb{R}^{n\times n}$ invertible y $E \in \mathbb{R}^{n\times n}$ tal que $\|E\| < \frac{1}{\|A^{-1}\|}$. Entonces, $A + E$ es invertible y*

$$\|(A+E)^{-1}\| \leq \frac{\|A^{-1}\|}{1-\|A^{-1}\|\|E\|}.$$

Demostración. Puesto que A es invertible, $A + E = A(I + A^{-1}E)$. Si llamamos $M := -A^{-1}E$, tenemos que $\|M\| = \|A^{-1}E\| \leq \|A^{-1}\|\|E\| < 1$, y por el lema anterior tenemos que $I-M$ es invertible y que $\|(I-M)^{-1}\| \leq \frac{1}{1-\|M\|}$. En consecuencia, $A+E = A(I-M)$ es invertible y

$$\|(A+E)^{-1}\| = \|(A(I-M))^{-1}\| = \|(I-M)^{-1}A^{-1}\| \leq \frac{\|A^{-1}\|}{1-\|M\|} \leq \frac{\|A^{-1}\|}{1-\|A^{-1}\|\|E\|}.$$

□

Como consecuencia del último lema se tiene el siguiente corolario.

Corolario 6.22. *Sea $C : D \subset \mathbb{R}^n \to \mathbb{R}^{n\times n}$ continua en $x_* \in D$. Si $C(x_*)$ es invertible, entonces existe $\delta > 0$ tal que para todo $x \in B(x_*, \delta)$, $C(x)$ es invertible y más aún, $\|C(x)^{-1}\| \leq 2\|C(x_*)^{-1}\|$.*

Demostración. Notemos que para cada $x \in D$, la matriz $C(x)$ puede verse como una perturbación de $C(x_*)$, esto es,

$$C(x) = \underbrace{C(x_*)}_{=:A} + \underbrace{(C(x) - C(x_*))}_{=:E}.$$

Puesto que C es continua en x_*, sabemos que existe $\delta > 0$ tal que

$$\|C(x) - C(x_*)\| < \frac{1}{2\|C(x_*)^{-1}\|}, \qquad \text{si } x \in B(x_*, \delta).$$

Por el lema anterior, tenemos que $C(x)$ es invertible para todo $x \in B(x_*, \delta)$ y que

$$\|C(x)^{-1}\| \leq \frac{\|C(x_*)^{-1}\|}{1-\|C(x_*)^{-1}\|\|C(x)-C(x_*)\|} < \frac{\|C(x_*)^{-1}\|}{1-\|C(x_*)^{-1}\|\frac{1}{2\|C(x_*)^{-1}\|}} = 2\|C(x_*)^{-1}\|.$$

□

Ahora estamos en condiciones de establecer cuándo la iteración de Newton está bien definida.

Teorema 6.23 (Buena definición del método de Newton y primer resultado de convergencia local)**.** *Sea $D \subset \mathbb{R}^n$ abierto y supongamos que $F : D \to \mathbb{R}^n$ es diferenciable en D. Sea $x_* \in D$ un cero de F (i.e., $F(x_*) = 0$). Si F' es continua en x_* y $F'(x_*)$ es invertible entonces se cumple lo siguiente:*

- Buena definición: *$G(x) := x - (F'(x))^{-1}F(x)$ está bien definida en un entorno de x_*.*
- Convergencia local: *La iteración*

$$x_{k+1} = x_k - (F'(x_k))^{-1}F(x_k), \qquad k = 0, 1, 2, \ldots$$

  converge localmente a x_*.

- Velocidad de convergencia superlineal: *Si x_0 se elige suficientemente cerca de x_* entonces*

$$\lim_{k\to\infty} \frac{\|x_{k+1} - x_*\|}{\|x_k - x_*\|} = 0.$$

Demostración.

• Tomando $C = F'$ en el Corolario 6.22 tenemos la buena definición del método de Newton.

• Puesto que $F(x_*) = 0$, se tiene que $x_* = G(x_*)$. Además, se puede demostrar (ver Ejercicio 6.8) que G es diferenciable en x_* y que $G'(x_*) = 0$. Por el Teorema de Ostrowski (Teorema 6.8), ya que $\rho(G'(x_*)) = 0 < 1$, se tiene que x_* es un punto de atracción de G.

• Puesto que G es diferenciable en x_* tenemos que

$$\lim_{x\to x_*} \frac{\|G(x) - G(x_*) - G'(x_*)(x - x_*)\|}{\|x - x_*\|} = 0.$$

Considerando que $G(x_*) = x_*$ y que $G'(x_*) = 0$, la igualdad anterior puede reescribirse como

$$\lim_{x\to x_*} \frac{\|G(x) - x_*\|}{\|x - x_*\|} = 0.$$

Puesto que x_* es un punto de atracción de G, podemos tomar x_0 suficientemente cerca de x_* de modo que

$$x_{k+1} := G(x_k) \to x_*, \qquad \text{cuando } k \to \infty.$$

Por lo tanto,

$$\lim_{k\to\infty} \frac{\|x_{k+1} - x_*\|}{\|x_k - x_*\|} = 0,$$

lo que concluye la demostración. □

Si en el teorema anterior reemplazamos la hipótesis de continuidad de F' en x_*, por una hipótesis un poco más fuerte (ver (6.5)) tenemos que el orden de convergencia de la iteración de Newton es cuadrático, como se muestra en el siguiente resultado.

Teorema 6.24 (Segundo resultado de convergencia local: Convergencia cuadrática)**.** *Sea $D \subset \mathbb{R}^n$ abierto y supongamos que $F : D \to \mathbb{R}^n$ es diferenciable en D. Sea $x_* \in D$ un cero de F (i.e., $F(x_*) = 0$). Supongamos que existen $\delta > 0$ y $L > 0$ tales que*

$$\|F'(x) - F'(x_*)\| \leq L\|x - x_*\|, \qquad \forall\, x \in B(x_*, \delta). \tag{6.5}$$

Entonces, si $F'(x_*)$ es invertible, existe $c > 0$ tal que si x_0 se elige suficientemente cerca de x_*, la iteración

$$x_{k+1} = x_k - (F'(x_k))^{-1}F(x_k), \qquad k = 0, 1, 2, \ldots$$

converge cuadráticamente, es decir,

$$\|x_{k+1} - x_*\| \leq c\|x_k - x_*\|^2, \qquad k = 0, 1, 2, \ldots$$

Observación 6.25 (Condiciones suficientes para que se cumpla (6.5))**.** Si F' es Lipschitz continua en un entorno de x_* entonces en particular se cumple (6.5). Por otro lado, F' es Lipschitz continua si y sólo si $\frac{\partial f_i}{\partial x_j}$ es Lipschitz continua, para $i, j = 1, 2, \ldots, n$. Notemos además que para esto es suficiente que $\frac{\partial^2 f_i}{\partial x_j \partial x_k}$ estén acotadas en un entorno de x_*, para $i, j, k = 1, 2, \ldots, n$. Finalmente, notemos también que para que se cumpla la última condición, es suficiente que F sea dos veces continuamente diferenciable en un entorno de x_*, es decir, que $\frac{\partial^2 f_i}{\partial x_j \partial x_k}$ sean continuas en un entorno de x_*, para $i, j, k = 1, 2, \ldots, n$.

Demostración del Teorema 6.24. Veamos primero que (6.5) implica que

$$\|F(x) - F(x_*) - F'(x_*)(x - x_*)\| \leq \frac{L}{2}\|x - x_*\|^2, \qquad \forall\, x \in B(x_*, \delta). \tag{6.6}$$

Por el Teorema 6.16 se tiene que

$$F(x) - F(x_*) = \int_0^1 F'(x_* + t(x - x_*))(x - x_*)\, dt, \qquad \forall\, x \in B(x_*, \delta).$$

En consecuencia,

$$\begin{aligned}
\|F(x) - F(x_*) - F'(x_*)(x - x_*)\| &= \left\| \int_0^1 (F'(x_* + t(x - x_*)) - F'(x_*))(x - x_*)\, dt \right\| \\
&\leq \int_0^1 \|(F'(x_* + t(x - x_*)) - F'(x_*))(x - x_*)\|\, dt \\
&\leq \int_0^1 \|F'(x_* + t(x - x_*)) - F'(x_*)\|\|x - x_*\|\, dt \\
&\leq \int_0^1 L\|t(x - x_*)\|\|x - x_*\|\, dt \\
&= L\|x - x_*\|^2 \int_0^1 t\, dt \\
&= \frac{L}{2}\|x - x_*\|^2,
\end{aligned}$$

para todo $x \in B(x_*, \delta)$, y así, (6.6) queda demostrada.

Ahora bien, si $x \in B(x_*, \delta)$, tenemos que

$$\begin{aligned}
\|G(x) - G(x_*)\| &= \|x - F'(x)^{-1}F(x) - x_*\| \\
&= \| - F'(x)^{-1}[F(x) - \underbrace{F(x_*)}_{=0} - F'(x)(x - x_*)]\| \\
&= \| - F'(x)^{-1}[F(x) - F(x_*) - F'(x_*)(x - x_*) - (F'(x) - F'(x_*))(x - x_*)]\| \\
&\leq \|F'(x)^{-1}\|\Big[\|F(x) - F(x_*) - F'(x_*)(x - x_*)\| + \|F'(x) - F'(x_*)\|\|x - x_*\|\Big] \\
&\leq \|F'(x)^{-1}\|\Big[\frac{L}{2}\|x - x_*\|^2 + L\|x - x_*\|^2\Big] \\
&= \|F'(x)^{-1}\|\frac{3L}{2}\|x - x_*\|^2.
\end{aligned}$$

Puesto que $C := F'$ es continua en x_* y que $C(x_*) = F'(x_*)$ es invertible, por el Corolario 6.22, tenemos que existe $\delta' > 0$ tal que $C(x) = F'(x)$ es invertible para $x \in B(x_*, \delta')$ y

$$\|F'(x)^{-1}\| \leq 2\|F'(x_*)^{-1}\|, \qquad \forall\, x \in B(x_*, \delta').$$

Por lo tanto,

$$\|G(x) - G(x_*)\| \leq \underbrace{3L\|F'(x_*)^{-1}\|}_{=:c}\|x - x_*\|^2, \qquad \forall\, x \in B(x_*, \delta) \cap B(x_*, \delta').$$

Finalmente, puesto que x_* es un punto de atracción de G, podemos elegir $\delta'' > 0$ con $\delta'' \leq \min\{\delta, \delta'\}$ tal que para todo $x_0 \in B(x_*, \delta'')$, $x_{k+1} = G(x_k) \in B(x_*, \delta'')$ y así, $\|x_{k+1} - x_*\| = \|G(x_k) - G(x_*)\| \leq c\|x_k - x_*\|^2$, $k = 0, 1, 2, \ldots$. □

6.2.1 Convergencia global del método de Newton

En esta sección nos proponemos estudiar en qué casos el método de Newton converge partiendo de cualquier valor inicial.

Observación 6.26 (Convergencia global de métodos de punto fijo)**.** Si $G : \mathbb{R}^n \to \mathbb{R}^n$ es una contracción, entonces por el Teorema 6.12 tenemos que partiendo de cualquier $x_0 \in \mathbb{R}^n$, la iteración

$$x_{k+1} := G(x_k), \qquad k = 0, 1, 2, \ldots$$

converge a un punto fijo x_* de G (que existe y es único).

La observación anterior nos da un resultado de convergencia global, pero es díficil que la hipótesis se cumpla en problemas concretos. A continuación veremos un resultado de convergencia global para el método de Newton, bajo ciertas hipótesis sobre la función F, que incluyen el concepto de *convexidad*.

Definición 6.27 (Función convexa)**.** Decimos que una función $f : \mathbb{R}^n \to \mathbb{R}$ es *convexa* si

$$f(tx + (1 - t)y) \leq tf(x) + (1 - t)f(y), \qquad \forall\, t \in [0, 1],\ x, y \in \mathbb{R}^n.$$

Además, una función $F : \mathbb{R}^n \to \mathbb{R}^n$ con $F = \begin{pmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{pmatrix}$ es *convexa* si f_i es convexa para todo $i = 1, 2, \ldots, n$.

Proposición 6.28 (Caracterización de las funciones convexas)**.** *Sea $f : \mathbb{R}^n \to \mathbb{R}$ diferenciable. Entonces, f es convexa si y sólo si*

$$f(y) - f(x) \geq \nabla f(x)^T (y - x), \qquad \forall\, x, y \in \mathbb{R}^n.$$

Si $n = 1$, tenemos que $\nabla f(x) = f'(x)$, y la caracterización dice que una función es convexa si y sólo si el gráfico de f está por arriba de su recta tangente en todos los puntos, es decir,

$$f(y) \geq f(x) + f'(x)(y - x), \qquad \forall\, x, y \in \mathbb{R}.$$

Demostración. ($\Rightarrow$) Sean $x, y \in \mathbb{R}^n$, y sea $0 < h < 1$. Puesto que f es convexa, tenemos que

$$f((1-h)x + hy) \leq (1-h)f(x) + hf(y).$$

Teniendo en cuenta que $(1-h)x + hy = x + h(y - x)$, obtenemos

$$\frac{f(x + h(y-x)) - f(x)}{h} \leq f(y) - f(x),$$

y tomando el límite para $h \to 0$,

$$\nabla f(x)^T (y - x) \leq f(y) - f(x),$$

como queríamos demostrar.

($\Leftarrow$) Sean $x, y \in \mathbb{R}^n$, y sea $0 < t < 1$. Queremos demostrar que

$$f(tx + (1-t)y) \leq tf(x) + (1-t)f(y). \tag{6.7}$$

Sea $z := tx + (1-t)y$. Por hipótesis,

$$f(x) - f(z) \geq \nabla f(z)^T (x - z), \tag{6.8}$$

y

$$f(y) - f(z) \geq \nabla f(z)^T (y - z). \tag{6.9}$$

Multiplicando (6.8) por t y (6.9) por $1 - t$ y sumando miembro a miembro, obtenemos

$$tf(x) + (1-t)f(y) - f(z) \geq \nabla f(z)^T (tx - tz + (1-t)y - z + tz) = \nabla f(z)^T 0,$$

de donde se sigue (6.7) y por lo tanto, que f es convexa. □

Teorema 6.29 (Teorema de Newton-Baluev: Convergencia global del método de Newton)**.** *Sea $F : \mathbb{R}^n \to \mathbb{R}^n$ convexa. Supongamos que F es continuamente diferenciable en $\mathbb{R}^n$, que $F'(x)$ es invertible y que las entradas de $F'(x)^{-1}$ son no negativas, para todo $x \in \mathbb{R}^n$. Entonces, si existe $x_* \in \mathbb{R}^n$ tal que $F(x_*) = 0$, este cero es único y la iteración*

$$x_{k+1} := x_k - F'(x_k)^{-1} F(x_k), \qquad k = 0, 1, 2, \ldots$$

converge a x_**, partiendo de cualquier valor inicial* $x_0 \in \mathbb{R}^n$*. Más aún, si* $x_* = (x_*^{(1)}, x_*^{(2)}, \ldots, x_*^{(n)})^T$ *y* $x_k = (x_k^{(1)}, x_k^{(2)}, \ldots, x_k^{(n)})^T$*, para* $k \in \mathbb{N}$*, entonces*

$$x_*^{(i)} \leq \cdots \leq x_{k+1}^{(i)} \leq x_k^{(i)} \leq \cdots \leq x_1^{(i)}, \qquad i = 1, 2, \ldots, n.$$

Observación 6.30. Notemos que si $n = 1$, es decir, si $F : \mathbb{R} \to \mathbb{R}$ entonces la matriz jacobiana de F en x es la derivada de F en x, y las hipótesis del teorema anterior equivalen a pedir que $F \in \mathcal{C}^1$, F convexa y que $F'(x) > 0$ para todo $x \in \mathbb{R}$. En este caso, si existe un cero x_* de F, éste es único y la sucesión del método de Newton converge decrecientemente a x_*, partiendo de cualquier $x_0 \in \mathbb{R}$.

Demostración del Teorema 6.29. En esta demostración utilizaremos la notación $x \geq 0$ para un vector $x = (x^{(1)}, x^{(2)}, \ldots, x^{(n)})^T \in \mathbb{R}^n$ si satisface

$$x^{(i)} \geq 0, \qquad \forall\, i = 1, 2, \ldots, n.$$

Sea $x_0 \in \mathbb{R}^n$ arbitrario, y consideremos la iteración de Newton

$$x_{k+1} := x_k - F'(x_k)^{-1} F(x_k), \qquad k = 0, 1, 2, \ldots \tag{6.10}$$

Sea $F = \begin{pmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{pmatrix}$. Puesto que F es convexa, tenemos que f_i es convexa, para $i = 1, 2, \ldots, n$. Para cada $k \in \mathbb{N}_0$, de la Proposición 6.28, y teniendo en cuenta (6.10), se sigue que

$$f_i(x_{k+1}) - f_i(x_k) \geq \nabla f_i(x_k)^T (x_{k+1} - x_k) = -f_i(x_k), \qquad i = 1, 2, \ldots, n,$$

y así,

$$f_i(x_{k+1}) \geq 0, \qquad i = 1, 2, \ldots, n.$$

Considerando la notación introducida al principio de esta demostración, la última desigualdad implica que

$$F(x_k) \geq 0, \qquad k = 1, 2, \ldots$$

Ahora vamos a demostrar que $\{x_k^{(i)}\}_{k \in \mathbb{N}}$ es una sucesión decreciente, para cada $i = 1, 2, \ldots, n$. En efecto, puesto que las entradas de $F'(x_k)^{-1}$ son no negativas y que $F(x_k) \geq 0$, de (6.10) se sigue que

$$x_k - x_{k+1} = F'(x_k)^{-1} F(x_k) \geq 0,$$

lo que significa que

$$x_{k+1}^{(i)} \leq x_k^{(i)}, \qquad i = 1, 2, \ldots, n.$$

Por otro lado, veamos que $\{x_k^{(i)}\}_{k \in \mathbb{N}}$ está acotada inferiormente por $x_*^{(i)}$, para cada $i = 1, 2, \ldots, n$; es decir, veamos que para $k = 1, 2, \ldots$ se tiene que

$$x_*^{(i)} \leq x_k^{(i)}, \qquad i = 1, 2, \ldots, n. \tag{6.11}$$

Sea $k \in \mathbb{N}$. Haciendo uso de la Proposición 6.28 nuevamente, tenemos que

$$\underbrace{f_i(x_*)}_{=0} - f_i(x_k) \geq \nabla f_i(x_k)^T (x_* - x_k), \qquad i = 1, 2, \ldots, n,$$

o equivalentemente,

$$-f_i(x_k) - \nabla f_i(x_k)^T (x_* - x_k) \geq 0, \qquad i = 1, 2, \ldots, n.$$

La última desigualdad puede reescribirse en la nueva notación como

$$-F(x_k) - F'(x_k)(x_* - x_k) \geq 0.$$

Ya que las entradas de $F'(x_k)^{-1}$ son no negativas, tenemos que

$$F'(x_k)^{-1}[-F(x_k) - F'(x_k)(x_* - x_k)] \geq 0.$$

En consecuencia,

$$-F'(x_k)^{-1} F(x_k) + (x_k - x_*) \geq 0,$$

y luego

$$x_k - x_* \geq \underbrace{F'(x_k)^{-1}}_{\geq 0} \overbrace{F(x_k)}^{\geq 0},$$

y finalmente,

$$x_k - x_* \geq 0,$$

de donde se sigue (6.11). Puesto que toda sucesión monótona decreciente y acotada inferiormente converge, tenemos que existe $y^{(i)} \in \mathbb{R}$ tal que

$$\lim_{k \to \infty} x_k^{(i)} = y^{(i)}, \qquad i = 1, 2, \ldots, n.$$

Definiendo $y := \begin{pmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{pmatrix}$, tenemos entonces que

$$\lim_{k \to \infty} x_k = y.$$

Sólo resta ver que y es un cero de F y que F tiene un único cero (en particular, $y = x_*$). Utilizando la continuidad de F y de F', y la definición de la iteración (6.10) tenemos que

$$F(y) = \lim_{k \to \infty} F(x_k) = \lim_{k \to \infty} F'(x_k)(x_k - x_{k+1}) = F'(y)(y - y) = 0.$$

Así, y es un cero de F. Se deja como ejercicio demostrar que F tiene un único cero. Como ayuda, suponer que existen dos ceros x_* y y_* y utilizar la condición de convexidad de F (aplicada a x_* e y_*) dada por la Proposición 6.28. □

6.3 Problemas

6.1. Consideremos la iteración de punto fijo asociada a una función $G : \mathbb{R} \to \mathbb{R}$.

(a) Si $G(x) := x - x^3$, demostrar que aunque $G'(0) = 1 (\not< 1)$, el punto 0 es un punto de atracción de G.

(b) Si $G(x) := x + x^3$, demostrar que $G'(0) = 1$, y que el punto 0 *no* es un punto de atracción de G.

6.2. Sea $G : D \subset \mathbb{R}^n \to \mathbb{R}^n$. Sea $x_* \in D$ un punto fijo de G. Demostrar que si G es continuamente diferenciable en un entorno de x_* y $\rho(G'(x_*)) < 1$, entonces G es una contracción en alguna bola cerrada centrada en x_*.

6.3. Supongamos que $G : \mathbb{R}^n \to \mathbb{R}^n$ tiene la propiedad que para todo conjunto cerrado y acotado $C \subset \mathbb{R}^n$ existe una constante $\alpha_C < 1$ tal que

$$\|G(x) - G(y)\| \leq \alpha_C \|x - y\|, \qquad \forall x, y \in C.$$

Supongamos además que G tiene un punto fijo x_*. Mostrar que x_* es único y que las iteraciones $x_{k+1} = G(x_k)$, $k = 0, 1, \ldots$ convergen a x_* para cualquier x_0. Dar un ejemplo en $\mathbb{R}^1$ que muestre que la condición sobre G no es suficiente para garantizar la existencia de un punto fijo.

6.4. Considerar el sistema

$$x = \frac{\frac{1}{2}}{1 + (x + y)^2} \qquad y = \frac{\frac{1}{2}}{1 + (x - y)^2}.$$

Encontrar un conjunto acotado $D \subset \mathbb{R}^2$ donde se pueda aplicar el Teorema 6.12.

Ayuda: ¿Cuál es el signo de las componentes de la solución del sistema? ¿Cuáles son los máximos valores posibles para dichas componentes según las ecuaciones del sistema?

6.5. Considerar el sistema

$$x = 1 + h\frac{e^{-x^2}}{1 + y^2} \qquad y = \frac{1}{2} + h \tan^{-1}(x^2 + y^2).$$

Mostrar que si h se elige suficientemente chico, entonces este sistema tiene una única solución x_* dentro de alguna región rectangular. Más aún, mostrar que la iteración de punto fijo (propuesta en la forma que viene dado el sistema) converge a dicha solución.

6.6. El Teorema 6.16 puede interpretarse también como la generalización del Teorema del Valor Medio del Cálculo Diferencial a funciones de valores vectoriales. En el siguiente ejemplo se muestra que una generalización, quizás más natural que la del mencionado teorema, no es posible.

Sea $G : \mathbb{R}^2 \to \mathbb{R}^2$ definida por

$$G\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} x_1^3 \\ x_1^2 \end{pmatrix}.$$

Sean $x = (0, 0)^T$ e $y = (1, 1)^T$. Demostrar que no existe ningún $z \in \mathbb{R}^2$ tal que

$$G(x) - G(y) = G'(z)(x - y).$$

6.7. Demostrar el Teorema 6.17.

6.8. Sea $D \subset \mathbb{R}^n$ abierto. Sea $F : D \to \mathbb{R}^n$ diferenciable en D. Sea $x_* \in D$ tal que $F(x_*) = 0$. En la primera parte del Teorema 6.23 vimos que si F' es continua en x_* y $F'(x_*)$ es invertible, entonces

$$G(x) := x - F'(x)^{-1}F(x),$$

está bien definida en un entorno de x_*. Demostrar que, además, G es diferenciable en x_* y que $G'(x_*) = 0$.

6.9. Considerar un sistema no lineal

$$F(x) = 0,$$

donde $F : D \subset \mathbb{R}^n \to \mathbb{R}^n$. Escribir una función `[x,iter,X]=newton(F, DF, x0, miter,tol)` para resolver el sistema por el método de Newton. Los parámetros de entrada son una referencia `F` a la función $F(x)$, una referencia `DF` a la matriz jacobiana $F'(x)$, un punto inicial `x0`, el máximo número de iteraciones permitido `miter` y una tolerancia `tol` permitida. Los parámetros de salida son la aproximación `x` de una solución del sistema, la cantidad de iteraciones realizadas `iter` y la matriz `X` cuyas columnas son las sucesivas aproximaciones que se calcularon.

Sugerencia: Para resolver el sistema lineal necesario en cada iteración utilizar el comando "\" de MATLAB/OCTAVE.

6.10. Estudiar la convergencia y el orden experimental de la misma (si corresponde) al aplicar el método de Newton al sistema

$$x^2 + y^2 = 4 \qquad x^2 - y^2 = 1,$$

utilizando como valor inicial $\begin{pmatrix} 1.6 \\ 1.2 \end{pmatrix}$.

6.11. (a) El siguiente sistema tiene cuatro ceros en el dominio $(-4, 4) \times (-4, 4)$

$$f(x, y) = x^2 + xy^3 - 9 = 0, \qquad g(x, y) = 3x^2y - y^3 - 4 = 0$$

Utilizar `meshgrid` y `contour` para graficar las curvas de nivel cero de f y g en el mismo dibujo y así determinar puntos iniciales para hallar cada una de las cuatro soluciones.

(b) Utilizar la función `newton` para calcular las cuatro soluciones del sistema del item anterior. ¿Cuál fue el número de iteraciones realizadas en cada caso? Estimar la velocidad de convergencia.

(c) Definir la función $h(x, y) = f(x, y)^2 + g(x, y)^2$. Luego, los ceros del sistema corresponden a los mínimos de h. Utilizar la función `fminsearch` de MATLAB/OCTAVE para aproximar los cuatro ceros.

6.12. Utilizar el método de Newton para hallar todas las raíces de cada uno de los siguientes sistemas no lineales. Utilizar gráficos para escoger valores iniciales.

(a) $x^2 + y^2 - 2x - 2y + 1 = 0 \qquad x + y - 2xy = 0.$

(b) $x^2 + 2xy + y^2 - x + y - 4 = 0 \qquad 5x^2 - 6xy + 5y^2 + 16x - 16y + 12 = 0.$

6.13. Usar el método de Newton para hallar el mínimo valor de

$$f(x, y) = x^4 + xy + (1 + y)^2.$$

Experimentar con varios valores iniciales y observar los patrones de convergencia.

6.14. Considerar la iteración de Newton en una dimensión para la función $F(x) = x^2$.

(a) Demostrar que la iteración converge localmente a $x_* = 0$ pero que la rapidez de convergencia no es cuadrática.

(b) Mostrar qué hipótesis del Teorema 6.24 no se cumple.

6.15. Repetir el ejercicio anterior considerando la función $F(x) = x + x^{1+\alpha}$, donde $0 < \alpha < 1$.

6.16. La iteración

$$x_{k+1} = x_k - F'(x_0)^{-1} F(x_k), \qquad k = 0, 1, \ldots$$

se conoce como *iteración simplificada de Newton*. Demostrar que si F es diferenciable en un entorno de un punto x_* tal que $F(x_*) = 0$, si F' es continua en x_*, y $F'(x_*)$ es invertible, entonces esta iteración converge localmente a x_*.

6.17. Sea $h > 0$ un parámetro fijo. Sea $F : \mathbb{R}^n \to \mathbb{R}^n$ dada por $F(x) = Ax + \Phi(x)$ donde

$$A = \begin{bmatrix} 2 & -1 & & & & \\ -1 & 2 & -1 & & 0 & \\ & -1 & 2 & -1 & & \\ & & \ddots & \ddots & \ddots & \\ & 0 & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix}, \qquad \Phi(x) = h^2 \begin{bmatrix} f(x^{(1)}) \\ f(x^{(2)}) \\ f(x^{(3)}) \\ \vdots \\ f(x^{(n-1)}) \\ f(x^{(n)}) \end{bmatrix},$$

con $x = (x^{(1)}, x^{(2)}, x^{(3)}, \ldots, x^{(n-1)}, x^{(n)})^T$ y $f(t) = t^3$.

(a) Usando que A es invertible, demostrar que el método de Newton aplicado al sistema $F(x) = 0$ converge localmente a $x_* = 0$.

(b) Estudiar el orden de convergencia del método de Newton para este caso.

6.18. Considerar las funciones $F : \mathbb{R} \to \mathbb{R}$ dadas por $F(x) = \tan^{-1} x$ y $F(x) = 2x + \operatorname{sen} x$. Mostrar que para ambas funciones se satisfacen todas las hipótesis del Teorema 6.29 (de Newton-Baluev), excepto la convexidad, y que la iteración de Newton correspondiente no converge globalmente.

Capítulo 7

Métodos numéricos para problemas de autovalores

A lo largo de esta sección consideraremos matrices y vectores con componentes complejas. Además, denotaremos con A^H a la matriz conjugada transpuesta de A, y análogamente para vectores. De esta manera, el producto escalar de $x, y \in \mathbb{C}^n$ es $x \cdot y = y^H x$, y como trabajamos sobre los complejos, $y \cdot x = x^H y = \overline{y^H x} = \overline{x \cdot y}$.

7.1 Repaso de definiciones y propiedades elementales

Dada una matriz $A \in \mathbb{C}^{n \times n}$, se dice que $\lambda \in \mathbb{C}$ es un autovalor de A si existe $x \in \mathbb{C}^n$, $x \neq 0$ tal que

$$Ax = \lambda x.$$

En ese caso, (λ, x) es un *autopar* de A.

De la definición se desprende que $\lambda \in \mathbb{C}$ es un autovalor de A si y sólo si $A - \lambda I$ no es invertible, lo que ocurre si y sólo si $\det(\lambda I - A) = 0$. Por lo tanto, los autovalores de A satisfacen la ecuación característica

$$p(\lambda) := \det(\lambda I - A) = 0.$$

La función $p(\lambda)$ resulta un polinomio cuyo término de orden máximo es λ^n. Se llama *polinomio característico* de A, y tiene una única factorización de la forma

$$p(\lambda) = (\lambda - \lambda_1)(\lambda - \lambda_2) \dots (\lambda - \lambda_n).$$

Si contamos cada λ_i por el número de veces que aparece en la factorización concluimos que

> Una matriz de orden n tiene n autovalores contando multiplicidades en el polinomio característico. Los autovalores y sus multiplicidades son únicos.

Por qué los métodos serán iterativos

Los métodos generales para hallar autovalores y autovectores son necesariamente iterativos. Para ver esto, consideremos un polinomio mónico cualquiera

$$q(t) = c_0 + c_1 t + c_2 t^2 + \cdots + c_{n-1} t^{n-1} + t^n,$$

y la siguiente matriz asociada:

$$C_q = \begin{bmatrix} -c_{n-1} & -c_{n-2} & \dots & -c_1 & -c_0 \\ 1 & 0 & \dots & 0 & 0 \\ 0 & 1 & \ddots & \dots & 0 \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \dots & 0 & 1 & 0 \end{bmatrix}.$$

Es fácil ver que el polinomio característico de C_q es q. En consecuencia, cualquier algoritmo para resolver el problema general de autovalores se puede usar para resolver ecuaciones polinomiales.

En el siglo XIX Niels Abel demostró que no es posible hallar por métodos directos las raíces de polinomios de grado mayor o igual a 5. Por lo tanto no hay manera de resolver problemas generales de autovalores para matrices de orden ≥ 5 por métodos directos, y debemos recurrir a métodos iterativos.

Más aún, la función `roots` de MATLAB/OCTAVE calcula los ceros de un polinomio recurriendo a un algoritmo iterativo para el cálculo de autovalores de la matriz asociada al mismo.

Autovalores a izquierda.

Observamos que, por un lado, $\det(A) = \det(A^T)$ y que $\det(\overline{A}) = \overline{\det(A)}$ (aquí $\overline{z}$ denota el conjugado de z). Por lo tanto,

$$\det(A) = 0 \iff \det(A^T) = 0 \iff \det(\overline{A}) = 0 \iff \det(A^H) = 0,$$

y en consecuencia

$$A \text{ es singular} \iff A^T \text{ es singular} \iff \overline{A} \text{ es singular} \iff A^H \text{ es singular.}$$

Análogamente

$$\det(\lambda I - A) = 0 \iff \det(\lambda I - A^T) = 0 \iff \det(\overline{\lambda} I - \overline{A}) = 0 \iff \det(\overline{\lambda} I - A^H) = 0.$$

Por lo tanto, los autovalores de A y de A^T coinciden. Los autovalores de A^H y $\overline{A}$ también coinciden, y son los conjugados de los autovalores de A.

Si A es *hermítica* ($A^H = A$), lo anterior dice que el *conjunto* de sus autovalores es invariante por conjugación. Eso todavía no alcanza para concluir que cada autovalor sea real: el espectro de cualquier matriz real tiene esa misma propiedad, y sin embargo puede tener autovalores complejos. Veamos entonces que los autovalores de una matriz hermítica sí son reales. En efecto, si λ es autovalor de A, entonces existe un autovector x tal que $Ax = \lambda x$, y luego

$$x^H A x = \lambda x^H x = \lambda \|x\|_2^2.$$

Por otro lado, $x^H Ax = (A^H x)^H x = (Ax)^H x = (\lambda x)^H x = \overline{\lambda}\|x\|_2^2$, así que

$$\lambda\|x\|_2^2 = \overline{\lambda}\|x\|_2^2 \implies \lambda = \overline{\lambda} \text{ (porque } x \neq 0).$$

Si λ es autovalor de A, entonces $\bar{\lambda}$ es un autovalor de A^H, y existe un autovector y que satisface $A^H y = \bar{\lambda} y$, que en términos de la matriz original se lee

$$y^H A = \lambda y^H.$$

El vector y^H se llama *autovector a izquierda* de A correspondiente a λ. Los autovectores a izquierda de A son los conjugados transpuestos de los autovectores de A^H.

Matrices reales

Si la matriz $A \in \mathbb{R}^{n\times n}$, entonces los coeficientes de su polinomio característico son reales. Sabemos que las raíces complejas de polinomios con coeficientes reales ocurren de a pares conjugados. Más aún, si (λ, x) es un autopar de A, entonces $(\bar{\lambda}, \bar{x})$ es también un autopar.

Multiplicidad y matrices defectuosas

La multiplicidad de un autovalor como raíz del polinomio característico se llama *multiplicidad algebraica* del autovalor.

La *multiplicidad geométrica* de un autovalor es la dimensión del espacio generado por todos los autovectores correspondientes a ese autovalor, es decir:

$$\text{multiplicidad geométrica de } \lambda = \dim\left\{v \in \mathbb{C}^n : Av = \lambda v\right\}.$$

Siempre ocurre que

$$\text{multiplicidad geométrica de } \lambda \leq \text{multiplicidad algebraica de } \lambda.$$

Puede ocurrir que la multiplicidad geométrica de un autovalor sea *estrictamente menor* que la algebraica. En ese caso se dice que el autovalor es *defectuoso*. Si una matriz contiene un autovalor defectuoso, también se dice que la matriz es *defectuosa*.

Un ejemplo de matriz defectuosa es

$$A = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix},$$

donde $\lambda = 2$ es un autovalor de multiplicidad algebraica 2 y geométrica 1.

Por último recordamos que si una matriz es defectuosa, entonces no es diagonalizable. Es decir, si A es defectuosa, no existe una matriz invertible V y una matriz diagonal Λ tal que $A = V\Lambda V^{-1}$.

Si una matriz es no defectuosa, entonces es diagonalizable, es decir, existe una matriz invertible V y una matriz diagonal Λ tal que $A = V\Lambda V^{-1}$.

Forma de Jordan canónica

El resultado más general dice que para toda matriz $A \in \mathbb{C}^{n\times n}$ existe una matriz no singular $V \in \mathbb{C}^{n\times n}$ tal que

$$V^{-1}AV = \operatorname{diag}\big(J_{m_1}(\lambda_1), J_{m_2}(\lambda_2), \ldots, J_{m_k}(\lambda_k)\big),$$

donde $J_m(\lambda) \in \mathbb{C}^{m\times m}$ son bloques de Jordan, que tienen la forma

$$J_m(\lambda) = \begin{bmatrix} \lambda & 1 & 0 & 0 & \ldots & 0 \\ 0 & \lambda & 1 & 0 & \ldots & 0 \\ 0 & 0 & \lambda & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \ddots & \vdots \\ 0 & 0 & \ldots & 0 & \lambda & 1 \\ 0 & 0 & \ldots & 0 & 0 & \lambda \end{bmatrix}.$$

Matrices hermíticas

Para saber si una matriz es diagonalizable, casi no hay otra opción que tratar de calcular los autovectores y ver qué ocurre. Sin embargo, hay una clase muy importante de matrices que se saben diagonalizables, y son las hermíticas. Las matrices de componentes reales y simétricas son hermíticas.

Si $A \in \mathbb{C}^{n\times n}$ es hermítica, entonces $a_{ii} = \bar{a}_{ii}$, y luego los elementos de la diagonal son reales.

Es interesante observar que si U es unitaria, es decir $U^H = U^{-1}$, entonces la transformación de similaridad U^HAU es hermítica, en efecto,

$$(U^HAU)^H = U^HA^H(U^H)^H = U^HAU.$$

Por otro lado, por el Teorema 4.21 de descomposición de Schur existe U unitaria tal que $U^HAU = T$ con T triangular superior tal que

$$\operatorname{diag}(T) = (\lambda_1, \lambda_2, \ldots, \lambda_n), \quad \text{y } \lambda_i,\ i = 1, 2, \ldots, n \text{ son los autovalores de } A.$$

Pero por lo antedicho, T es hermítica y los elementos de su diagonal son reales, como además es triangular superior, resulta diagonal. Por lo tanto

> Si $A \in \mathbb{C}^{n\times n}$ es hermítica, entonces existe una matriz unitaria U tal que
>
> $$U^HAU = \operatorname{diag}(\lambda_1, \ldots, \lambda_n),$$
>
> donde los números λ_i son reales. Equivalentemente, toda matriz hermítica tiene autovalores reales y sus autovectores pueden elegirse para formar una base ortonormal de $\mathbb{C}^n$.

Vale la pena observar que las matrices hermíticas son una subclase de la clase de matrices *normales*. Una matriz A se dice normal si $AA^H = A^HA$. Se puede demostrar que para matrices normales, la matriz T de Schur es diagonal, aunque sus autovalores pueden ser complejos.

7.2 El método de las potencias

La idea del primer método que veremos es que al aplicar repetidas veces una matriz a un mismo vector, se destaca el *efecto* del autovalor de módulo máximo. Ya vislumbramos esto cuando vimos que para toda matriz A y cualquier norma inducida $\|A^k\|^{1/k} \to \rho(A)$.

Dado un vector inicial u_0, definimos

$$u_k = \sigma_{k-1} A u_{k-1}, \quad \text{con} \quad \sigma_{k-1} = \frac{1}{\|Au_{k-1}\|} \qquad k = 1, 2, \ldots. \tag{7.1}$$

Los factores de escala σ_{k-1} están para evitar que $\|u_k\|$ tienda a cero o a infinito.

Conviene observar, antes que nada, que la recursión (7.1) no hace otra cosa que normalizar las potencias $A^k u_0$.

Lema 7.1. *Sea $u_0 \in \mathbb{C}^n$ con $\|u_0\| = 1$, y supongamos que $A^k u_0 \neq 0$ para todo k. Entonces la recursión (7.1) está bien definida y*

$$u_k = \frac{A^k u_0}{\|A^k u_0\|}, \qquad k = 0, 1, 2, \ldots$$

Demostración. Por inducción. Para $k = 0$ la fórmula se reduce a $\|u_0\| = 1$. Si vale para k, entonces

$$Au_k = \frac{A^{k+1} u_0}{\|A^k u_0\|} \neq 0,$$

de modo que σ_k está bien definido y, al normalizar, el factor $\|A^k u_0\|$ se cancela:

$$u_{k+1} = \frac{Au_k}{\|Au_k\|} = \frac{A^{k+1} u_0 / \|A^k u_0\|}{\|A^{k+1} u_0\| / \|A^k u_0\|} = \frac{A^{k+1} u_0}{\|A^{k+1} u_0\|}. \qquad \square$$

De esta manera, el análisis de convergencia se reduce a estudiar las potencias $A^k u_0$, y normalizar recién al final.

Para analizar la convergencia supondremos que los autovalores de A (repetidos acorde a su multiplicidad algebraica) pueden ordenarse de la siguiente manera:

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \cdots \geq |\lambda_n|.$$

Si esto ocurre decimos que λ_1 es el autovalor *dominante* de A, y es necesariamente simple. En este caso, el bloque de Jordan correspondiente a λ_1 en la descomposición de Jordan es la matriz $[\lambda_1]$ de 1×1, y luego

$$X = \begin{bmatrix} x_1 & X_2 \end{bmatrix}, \qquad x_1 \in \mathbb{C}^n, \ \|x_1\|_2 = 1, \quad X_2 \in \mathbb{C}^{n \times (n-1)},$$

tal que

$$X^{-1} A X = \begin{bmatrix} \lambda_1 & 0^T \\ 0 & B \end{bmatrix}, \qquad \text{con } B \in \mathbb{C}^{(n-1)\times(n-1)}.$$

Notemos que x_1 es un autovector (a derecha) correspondiente a λ_1, y si particionamos

$$X^{-1} = \begin{bmatrix} y_1^H \\ Y_2^H \end{bmatrix}, \qquad y_1 \in \mathbb{C}^n, \ Y_2 \in \mathbb{C}^{n \times (n-1)},$$

resulta que y_1^H es un autovector a izquierda correspondiente a λ_1.

Escribamos ahora

$$X^{-1}u_0 = \begin{bmatrix} \nu_0 \\ w_0 \end{bmatrix}, \qquad \nu_0 = y_1^H u_0 \in \mathbb{C}, \quad w_0 \in \mathbb{C}^{n-1}.$$

Como $A = X \begin{bmatrix} \lambda_1 & 0^T \\ 0 & B \end{bmatrix} X^{-1}$, resulta

$$A^k = X \begin{bmatrix} \lambda_1^k & 0^T \\ 0 & B^k \end{bmatrix} X^{-1},$$

y por lo tanto

$$A^k u_0 = X \begin{bmatrix} \lambda_1^k \nu_0 \\ B^k w_0 \end{bmatrix} = \lambda_1^k \big(\nu_0 x_1 + z_k\big), \qquad \text{con} \quad z_k := X_2 (B/\lambda_1)^k w_0. \tag{7.2}$$

Como $\rho(B/\lambda_1) = |\lambda_2|/|\lambda_1| < 1$, tenemos $(B/\lambda_1)^k \to 0$ y luego $z_k \to 0$.

Supongamos ahora que $\nu_0 = y_1^H u_0 \neq 0$. La primera componente de $X^{-1}A^k u_0$ es $\lambda_1^k \nu_0 \neq 0$ y, como X es inversible, resulta $A^k u_0 \neq 0$ para todo k; el Lema 7.1 se aplica. Normalizando (7.2) y escribiendo $\lambda_1^k = |\lambda_1|^k (\lambda_1/|\lambda_1|)^k$, el factor $|\lambda_1|^k$ se cancela y queda

$$u_k = \frac{A^k u_0}{\|A^k u_0\|} = \Big(\frac{\lambda_1}{|\lambda_1|}\Big)^k \frac{\nu_0 x_1 + z_k}{\|\nu_0 x_1 + z_k\|}.$$

Finalmente, como $z_k \to 0$ y $\nu_0 x_1 \neq 0$, y recordando que $\|x_1\|_2 = 1$,

$$\frac{\nu_0 x_1 + z_k}{\|\nu_0 x_1 + z_k\|} \to \frac{\nu_0 x_1}{\|\nu_0 x_1\|} = \frac{\nu_0}{|\nu_0|}\, x_1.$$

En consecuencia, si definimos $\omega_k = \Big(\dfrac{|\lambda_1|}{\lambda_1}\Big)^k \dfrac{|\nu_0|}{\nu_0}$, que cumple $|\omega_k| = 1$, resulta $\omega_k u_k \to x_1$.

Hemos demostrado la siguiente proposición.

Proposición 7.2. *Sea $A \in \mathbb{C}^{n\times n}$ tal que sus autovalores pueden ordenarse de manera que*

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \cdots \geq |\lambda_n|,$$

y sean x_1 un autovector a derecha correspondiente a λ_1, normalizado de manera que $\|x_1\|_2 = 1$, e y_1^H un autovector a izquierda correspondiente a λ_1 (al ser λ_1 simple, ambos quedan determinados salvo un factor multiplicativo, del que no dependen ni la hipótesis ni la conclusión que siguen). Si $y_1^H u_0 \neq 0$, la sucesión de vectores generada por la recursión

$$u_k = \sigma_{k-1} A u_{k-1}, \qquad k = 1, 2, \ldots, \qquad \sigma_{k-1} = \frac{1}{\|A u_{k-1}\|},$$

converge, en dirección, a x_1. Más precisamente, existen números $\omega_k \in \mathbb{C}$, $|\omega_k| = 1$ tales que

$$\omega_k u_k \to x_1, \qquad \text{cuando } k \to \infty.$$

La tasa de convergencia es, asintóticamente, como $(|\lambda_2/\lambda_1| + \varepsilon)^k$ para cualquier $\varepsilon > 0$.

Observación 7.3. Vale la pena hacer algunos comentarios:

- Si $\Sigma_{\lambda_1} = \{v \in \mathbb{C}^n \setminus \{0\} : Av = \lambda_1 v\}$ y $\tilde{\Sigma}_{\lambda_1} = \{v \in \Sigma_{\lambda_1} : \|v\|_2 = 1\}$ denotan el conjunto de autovectores y autovectores normalizados correspondientes a λ_1, entonces la proposición anterior implica que

$$\operatorname{dist}(u_k, \Sigma_{\lambda_1}) \leq \operatorname{dist}(u_k, \tilde{\Sigma}_{\lambda_1}) \to 0, \qquad \text{cuando } k \to \infty,$$

  donde $\operatorname{dist}(u, \Sigma) = \min_{v \in \Sigma} \|u - v\|_2$, denota la distancia de un vector u a un conjunto Σ. Para demostrar esto es suficiente observar que si $\omega_k \in \mathbb{C}$, $|\omega_k| = 1$, entonces

$$\|\omega_k u_k - x_1\| = \|u_k - \overline{\omega_k}\, x_1\|$$

  y que $\overline{\omega_k}\, x_1 \in \tilde{\Sigma}_{\lambda_1}$ siempre que $x_1 \in \tilde{\Sigma}_{\lambda_1}$.

- La cota sobre la tasa de convergencia es consecuencia de que dado $\varepsilon > 0$ existe una constante C, dependiente de B y ε tal que

$$\|(B/\lambda_1)^k\| \leq C(\rho(B/\lambda_1) + \varepsilon)^k \leq C(|\lambda_2/\lambda_1| + \varepsilon)^k.$$

- Si $y_1^H u_0 \neq 0$, decimos que u_0 tiene una componente no nula en la dirección de x_1. Esta condición no puede verificarse directamente pues no conocemos y_1. Más aún, no es suficiente que $y_1^H u_0$ sea no nulo, debería ser *grande* relativo a $\|u_0\|$ para que el método converja en un número razonable de iteraciones. En general, salvo que se conozca algo del problema, u_0 se elige al azar.

- El método de las potencias es muy atractivo por su simplicidad, cada iteración requiere un producto matriz-vector y una normalización (escalamiento).

- Sin embargo, el método de las potencias tiene desventajas importantes. Sólo garantiza converger a un autovalor dominante, que en general podría no existir. Por ejemplo, si la matriz A es real y el autovalor de módulo máximo es complejo, su complejo conjugado es también de módulo máximo, y no hay autovalor dominante. Aún cuando haya un autovalor dominante λ_1, si $|\lambda_2|$ es cercano a $|\lambda_1|$ entonces la convergencia puede ser demasiado lenta.

- En síntesis, el método de las potencias se considera una herramienta para un propósito especial, para casos en que uno sabe que tiene un autovalor dominante con $|\lambda_2|/|\lambda_1|$ pequeño. No se considera un algoritmo general.

El cociente de Rayleigh.

Supongamos que tenemos una aproximación x de un autovector de A y queremos obtener una aproximación del autovalor correspondiente. Una manera natural sería hallar el número $\mu \in \mathbb{C}$ que minimiza

$$\|Ax - \mu x\|_2.$$

Esto es un problema de mínimos cuadrados con x jugando el rol de la matriz, Ax el rol del vector a ser aproximado, y μ el único parámetro a *ajustar*. Las ecuaciones normales entonces lucen así:

$$(x^H x)\mu = x^H (Ax),$$

por lo que

$$\mu = \frac{x^H A x}{x^H x}.$$

El cociente $\dfrac{x^H A x}{x^H x}$ se llama *cociente de Rayleigh* y juega un papel preponderante en la teoría y práctica computacional de problemas de autovalores.

Basándonos en esta observación, definimos el siguiente algoritmo para la aproximación simultánea del autovalor dominante y un autovector asociado:

Método de las potencias. (versión preliminar)

Dada $A \in \mathbb{R}^{n\times n}$, $u_0 \in \mathbb{C}^n$

$u_0 = u_0/\|u_0\|_2$

$k = 0$

Repetir:

$k = k + 1$

$v_k = Au_{k-1}$

$u_k = v_k/\|v_k\|_2$

$\mu_k = u_k^H A u_k$

Fin repetir

Claramente el algoritmo puede mejorarse para realizar sólo un producto matriz-vector en cada iteración, como sigue

Método de las potencias.

Dada $A \in \mathbb{R}^{n\times n}$, $u_0 \in \mathbb{C}^n$, $tol > 0$ y $k_{\max} \in \mathbb{N}$.

$u_0 = u_0/\|u_0\|_2$

$v_1 = Au_0$

$k = 0$

Repetir:

$k = k + 1$

$u_k = v_k/\|v_k\|_2$

$v_{k+1} = Au_k$

$\mu_k = u_k^H v_{k+1}$ % $u_k^H A u_k$

$r_k = v_{k+1} - \mu_k u_k$ % $Au_k - \mu_k u_k$

Hasta que $\|r_k\|_2 \leq tol\,|\mu_k|$ o $k = k_{\max}$

Observación 7.4. Es interesante observar la relación entre el error de los autovectores y el error de los autovalores. Supongamos que (λ, x) es un autopar de A con $\|x\|_2 = 1$, y

sea $(\tilde{\lambda}, u)$ un autopar aproximado, que cumple $\|u\|_2 = 1$ y $\tilde{\lambda} = u^H Au$, entonces

$$\begin{aligned}\lambda - \tilde{\lambda} &= x^H Ax - u^H Au \\ &= x^H Ax - x^H Au + x^H Au - u^H Au \\ &= x^H A(x-u) + (x^H - u^H)Au.\end{aligned}$$

Por lo tanto

$$|\lambda - \tilde{\lambda}| \leq (\|Au\|_2 + \|Ax\|_2)\|x-u\|_2 \leq 2\|A\|_2\|x-u\|_2.$$

Por lo tanto, si el autovector u es cercano a x, el autovalor $\tilde{\lambda}$ será cercano a λ.

Notemos, finalmente, que el método de las potencias da, en principio, una sucesión u_k tal que, para cada k, existe $\omega_k \in \mathbb{C}$, $|\omega_k| = 1$, tal que $\omega_k u_k \to x_1$; tal ω_k es desconocido. Sin embargo, es fácil verificar que

$$(\omega_k u_k)^H A(\omega_k u_k) = \overline{\omega_k}\omega_k u_k^H Au_k = u_k^H Au_k.$$

Luego, si en cada paso del algoritmo definimos $\mu_k = u_k^H Au_k$, resultará

$$|\lambda_1 - \mu_k| = |x_1^H Ax_1 - u_k^H Au_k| = |x_1^H Ax_1 - (\omega_k u_k)^H A(\omega_k u_k)| \leq 2\|A\|_2\|x_1 - \omega_k u_k\|_2.$$

Es decir, el error en la aproximación del autovalor está acotado por $2\|A\|_2$ multiplicado por el error en la aproximación del autovector.

Observación 7.5 (Criterio de parada)**.** El algoritmo calcula, sin costo adicional, el *residuo*

$$r_k = Au_k - \mu_k u_k = v_{k+1} - \mu_k u_k,$$

pues el producto $v_{k+1} = Au_k$ ya fue realizado. El residuo mide cuánto le falta a (μ_k, u_k) para ser un autopar, y lo hace en un sentido preciso: como $\|u_k\|_2 = 1$,

$$\big(A - r_k u_k^H\big)u_k = Au_k - r_k = \mu_k u_k,$$

es decir, (μ_k, u_k) es un autopar *exacto* de la matriz $A - r_k u_k^H$, que difiere de A en $\|r_k u_k^H\|_2 = \|r_k\|_2$. Luego, si $\|r_k\|_2$ es pequeño comparado con $\|A\|_2$, entonces μ_k es un autovalor exacto de una matriz cercana a A.

Si además A es hermítica podemos afirmar algo sobre los autovalores de la propia A. En efecto, por lo visto en la Sección 7.1 existe una base ortonormal de autovectores $\{x_j\}$; escribiendo $u_k = \sum_j c_j x_j$, con $\sum_j |c_j|^2 = 1$, resulta

$$r_k = \sum_j (\lambda_j - \mu_k)c_j x_j, \qquad \text{y entonces} \qquad \|r_k\|_2^2 = \sum_j |\lambda_j - \mu_k|^2 |c_j|^2 \geq \min_j |\lambda_j - \mu_k|^2.$$

Es decir,

$$\min_j |\lambda_j - \mu_k| \leq \|r_k\|_2 :$$

hay un autovalor de A a distancia no mayor que $\|r_k\|_2$ de μ_k.

Esto justifica el test de parada $\|r_k\|_2 \leq tol\,|\mu_k|$ del algoritmo, que es relativo y no requiere calcular $\|A\|_2$: por la Observación 7.4 se tiene $\mu_k \to \lambda_1$, y si A es hermítica $|\lambda_1| = \rho(A) = \|A\|_2$.

Observación 7.6. Consideremos el algoritmo anterior, pero supongamos que cambiamos las líneas $v_{k+1} = Au_k$ por

$$v_{k+1} : \text{ solución del sistema } Av = u_k.$$

Es decir, $v_{k+1} = A^{-1}u_k$. En ese caso, estaríamos aproximando el autovalor dominante de A^{-1}, que es el inverso del autovalor de módulo mínimo de A.

7.3 Método de las potencias inversas

Una posible mejora para el método de las potencias sería transformar la matriz para que los autovalores estén mejor ubicados, de manera que la convergencia sea más rápida. Una opción sería *trasladar* (shift) la matriz, cambiándola por $A-\mu I$ de manera que el cociente entre el módulo del autovalor dominante y el sub-dominante sea mayor. El cambio más dramático se obtiene cuando se combina una traslación con una *inversión*.

Sea μ una aproximación de un autovalor simple λ_1 de A. Recordemos que los autovalores de $A - \mu I$ son $\lambda_i - \mu$, más precisamente

$$\sigma(A - \mu I) = \sigma(A) - \mu = \{\lambda - \mu : \lambda \in \sigma(A)\},$$

y los autovalores de $(A - \mu I)^{-1}$ son $(\lambda_i - \mu)^{-1}$, o bien,

$$\sigma\left((A - \mu I)^{-1}\right) = \left\{\frac{1}{\lambda - \mu} : \lambda \in \sigma(A)\right\}.$$

Luego, si μ está suficientemente cerca de λ_1, resulta que $\frac{1}{\lambda_1-\mu}$ será un autovalor dominante de $(A - \mu I)^{-1}$. En efecto, cuando $\mu \to \lambda_1$, $\frac{1}{\lambda_1-\mu} \to \infty$ mientras que $\frac{1}{\lambda_i-\mu}$ tiende a un número finito para cada $i \neq 1$.

Esto permite cuantificar la ganancia.

Proposición 7.7. *Sea $A \in \mathbb{C}^{n\times n}$, sea λ_1 un autovalor simple de A, con autovectores a derecha e izquierda x_1 (normalizado de manera que $\|x_1\|_2 = 1$) e y_1^H, y sea $\mu \in \mathbb{C}$, $\mu \notin \sigma(A)$, tal que*

$$|\lambda_1 - \mu| < |\lambda_i - \mu| \qquad \text{para todo } \lambda_i \in \sigma(A),\ \lambda_i \neq \lambda_1.$$

Si $y_1^H u_0 \neq 0$, la sucesión generada por el método de las potencias inversas converge en dirección a x_1, con tasa asintótica

$$\Big(\rho_\mu + \varepsilon\Big)^k, \qquad \text{donde } \ \rho_\mu := \max_{\lambda_i \neq \lambda_1} \left|\frac{\lambda_1 - \mu}{\lambda_i - \mu}\right|,$$

para cualquier $\varepsilon > 0$. Además $\mu_k \to \lambda_1$.

Demostración. Si (λ, x) es un autopar de A con $\lambda \neq \mu$, entonces $(A - \mu I)x = (\lambda - \mu)x$ y, aplicando $(A - \mu I)^{-1}$ a ambos miembros y dividiendo por $\lambda - \mu$,

$$(A - \mu I)^{-1}x = \frac{1}{\lambda - \mu}\, x.$$

Es decir, $B := (A - \mu I)^{-1}$ tiene autovalores $(\lambda_i - \mu)^{-1}$ y *los mismos autovectores que* A; el mismo cálculo con autovectores a izquierda da lo propio. La hipótesis sobre μ dice exactamente que

$$\left|\frac{1}{\lambda_1 - \mu}\right| > \left|\frac{1}{\lambda_i - \mu}\right|, \qquad \lambda_i \neq \lambda_1,$$

o sea que $\theta_1 := (\lambda_1 - \mu)^{-1}$ es el autovalor dominante de B, con autovectores x_1 e y_1^H.

Como el método de las potencias inversas no es otra cosa que el método de las potencias aplicado a B, la Proposición 7.2 da la convergencia en dirección a x_1 con tasa $(|\theta_2/\theta_1|+\varepsilon)^k$, donde θ_2 es el segundo autovalor de B en módulo. Y

$$\left|\frac{\theta_2}{\theta_1}\right| = \max_{\lambda_i \neq \lambda_1} \frac{|\lambda_1 - \mu|}{|\lambda_i - \mu|} = \rho_\mu.$$

Finalmente, $u_k^H v_{k+1} = u_k^H B u_k$ es el cociente de Rayleigh de B en u_k, que converge a θ_1 por la Observación 7.4; luego $\mu_k = (u_k^H v_{k+1})^{-1} + \mu \to \theta_1^{-1} + \mu = \lambda_1$. □

Conviene leer con cuidado el valor de ρ_μ: es proporcional a $|\lambda_1 - \mu|$. A diferencia del método de las potencias, cuya razón $|\lambda_2/\lambda_1|$ está determinada por la matriz y no puede mejorarse, acá la velocidad de convergencia está en nuestras manos a través del shift. Por ejemplo, si $|\lambda_1 - \mu| \approx 10^{-3}$ y los restantes autovalores distan $O(1)$ de μ, resulta $\rho_\mu \approx 10^{-3}$ y cada iteración agrega unos tres dígitos correctos. Notemos también que la calidad de μ afecta la *velocidad*, no el límite: mientras se cumpla la hipótesis, el método converge al mismo x_1.

Entonces dada una aproximación μ del autovalor que se quiere calcular, el algoritmo de las potencias inversas es el siguiente:

Método de las potencias inversas.

Dada $A \in \mathbb{R}^{n\times n}$, $u_0 \in \mathbb{C}^n$, $\mu \in \mathbb{C}$

$u_0 = u_0/\|u_0\|_2$

$v_1 = (A - \mu I)^{-1} u_0$

$k = 0$

Repetir:

$k = k + 1$

$u_k = v_k/\|v_k\|_2$

$v_{k+1} = (A - \mu I)^{-1} u_k$

$$\mu_k = \frac{1}{u_k^H v_{k+1}} + \mu$$

Fin repetir

Por supuesto, en las líneas donde dice $v_{k+1} = (A - \mu I)^{-1} u_k$ debe entenderse:

$$v_{k+1}: \text{ solución del sistema } (A - \mu I)v = u_k.$$

El método de las potencias inversas puede ser muy rápido si conocemos un parámetro *shift* cercano al autovalor buscado, y podría combinarse con el de las potencias de la sección anterior, para *acelerar* la convergencia una vez que se sabe que se está cerca.

Observación 7.8 (El mal condicionamiento no es un obstáculo)**.** Si μ es una buena aproximación de λ_1, la matriz $A-\mu I$ es casi singular y $\kappa_2(A-\mu I)$ es enorme. Es natural entonces desconfiar del vector que se obtiene al resolver $(A-\mu I)v = u_k$ en aritmética de punto flotante. Sin embargo el método funciona, y la razón es instructiva.

Los algoritmos de resolución de sistemas que vimos son estables hacia atrás (ver la Sección 3.5): el vector calculado $\hat{v}$ es la solución *exacta* de un sistema levemente perturbado,

$$(A - \mu I + E)\,\hat{v} = u_k, \qquad \|E\|_2 \cong \varepsilon_{\text{maq}}\|A\|_2.$$

El error hacia adelante es, en efecto, del orden de $\kappa_2(A-\mu I)\varepsilon_{\text{maq}}$, es decir enorme. Pero esa amplificación ocurre en la dirección en la que $(A-\mu I)^{-1}$ es grande, que es justamente la dirección de x_1: el vector calculado tiene una componente desmesurada en la dirección que estamos buscando. Como el paso siguiente del algoritmo normaliza, el factor espurio desaparece y lo que queda es una aproximación de x_1 tan buena como lo permite una perturbación de tamaño $\varepsilon_{\text{maq}}\|A\|_2$ en los datos. El mal condicionamiento, acá, juega a favor. (En el caso extremo en que $A-\mu I$ resulte numéricamente singular, basta perturbar μ levemente.)

En cambio, las razones por las que no conviene actualizar el shift, tomando $\mu = \mu_k$ en cada paso, son otras dos: habría que factorizar $A-\mu I$ nuevamente en cada iteración, con un costo $O(n^3)$ por paso en lugar de una única factorización al comenzar; y con un shift variable se pierde el control sobre a cuál autovalor converge el método. Si se acepta ese costo, tomar como shift el cociente de Rayleigh de u_k en cada paso da la llamada *iteración del cociente de Rayleigh*, que para matrices hermíticas converge cúbicamente.

Observación 7.9. Las ventajas del método de las potencias inversas son que converge muy rápido y que se pueden obtener todos los autovalores, siempre que se tenga una buena aproximación de cada uno de ellos. Las desventajas son que se requiere una buena aproximación del autovalor buscado y que debe resolverse un sistema en cada iteración. Aunque cada paso del algoritmo es más costoso, pues se debe resolver un sistema de ecuaciones, igualmente puede llegar a ser conveniente, por dos razones:

- Si la matriz es llena y/o pequeña, puede factorizarse antes de comenzar la iteración, y en cada paso, la resolución llevará $O(n^2)$ operaciones correspondientes a resolver dos sistemas triangulares.
- Si la matriz es grande y rala (sparse) se puede utilizar un método iterativo, y probablemente la convergencia será rápida si en cada resolución del sistema lineal se utiliza la u_k del paso anterior.

7.4 Algoritmo QR

El algoritmo QR es un método basado en la factorización QR, cuyo objetivo es obtener una descomposición de Schur de una matriz A. El Teorema 4.21 de descomposición de Schur afirma que dada $A \in \mathbb{C}^{n\times n}$, existe una matriz unitaria U tal que

$$U^H A U = T, \quad \text{con } T \text{ triangular superior,}$$

tal que t_{ii} son los autovalores de A. La demostración de esta descomposición se basó en el conocimiento de los autovalores y autovectores. El objetivo ahora es diseñar métodos

para calcular los autovalores y por eso debemos hallar una manera iterativa y constructiva de hallar la descomposición de Schur.

El algoritmo QR es un algoritmo iterativo para hallar la descomposición de Schur de una matriz A. Comenzando con $A_0 = A$, procede a reducir A iterativamente a forma triangular por una sucesión de transformaciones de similaridad unitarias:

$$A_{k+1} = Q_k^H A_k Q_k, \qquad k = 0, 1, 2, \ldots.$$

Las matrices Q serían fáciles de obtener si conociéramos los autovalores y autovectores, pero como no los conocemos, explotaremos la conexión del algoritmo con el método de las potencias inversas.

Partimos de la matriz $A_0 = A$ y para cada $k \geq 0$, hacemos lo siguiente:

- Sean Q_k, R_k tales que $A_k = Q_k R_k$, $Q_k^H Q_k = I$ y R_k es triangular superior (factorización QR de A_k)
- Definimos $A_{k+1} = R_k Q_k$ (invertimos el orden de Q_k y R_k).

De esta manera, resulta que

$$A_{k+1} = R_k Q_k = (Q_k^H A_k) Q_k = Q_k^H A_k Q_k,$$

por lo que A_{k+1} y A_k son (unitariamente) similares, y no sólo eso.

Teorema 7.10. *Si tomamos las matrices Q_k, R_k, A_k definidas arriba y definimos*

$$P_k = Q_0\, Q_1\, \ldots\, Q_k, \quad \text{y} \quad U_k = R_k\, R_{k-1}\, \ldots\, R_0,$$

entonces:

(a) *A_{k+1} es unitariamente similar a A_k:* $A_{k+1} = Q_k^H A_k Q_k$.

(b) $A_{k+1} = (Q_0\, Q_1\, \ldots\, Q_k)^H\, A\, (Q_0\, Q_1\, \ldots\, Q_k) = P_k^H A P_k$.

(c) $A^{k+1} = P_k\, U_k$. ***Atención.*** *Aquí es una* ***potencia*** *de A.*

Demostración. (a) Como Q_k es unitaria, de $A_k = Q_k R_k$ se sigue que $R_k = Q_k^H A_k$, y por lo tanto

$$A_{k+1} = R_k Q_k = Q_k^H A_k Q_k,$$

como ya observamos antes del enunciado.

(b) Por inducción en k. Para $k = 0$ es (a), pues $P_0 = Q_0$ y $A_0 = A$. Si la fórmula vale para $k-1$, es decir si $A_k = P_{k-1}^H A P_{k-1}$, entonces por (a)

$$A_{k+1} = Q_k^H A_k Q_k = Q_k^H P_{k-1}^H A P_{k-1} Q_k = (P_{k-1} Q_k)^H A\, (P_{k-1} Q_k) = P_k^H A P_k.$$

(c) También por inducción. Para $k = 0$, $A^1 = A = A_0 = Q_0 R_0 = P_0 U_0$. Supongamos que $A^k = P_{k-1} U_{k-1}$. Multiplicando la identidad $A_k = P_{k-1}^H A P_{k-1}$ de (b) por P_{k-1} a izquierda resulta $A P_{k-1} = P_{k-1} A_k$, y entonces

$$A^{k+1} = A\, A^k = A\, P_{k-1} U_{k-1} = P_{k-1} A_k U_{k-1} = P_{k-1} Q_k R_k U_{k-1} = (P_{k-1} Q_k)(R_k U_{k-1}) = P_k U_k,$$

donde usamos $A_k = Q_k R_k$ y las definiciones $P_k = P_{k-1} Q_k$, $U_k = R_k U_{k-1}$. □

Observemos que P_k es unitaria y U_k es triangular superior, por ser productos de matrices unitarias y de matrices triangulares superiores, respectivamente. La igualdad (c) dice entonces que $P_k U_k$ *es una factorización QR de la potencia A^{k+1}*: el algoritmo QR calcula las factorizaciones QR de $A, A^2, A^3, \ldots$ sin formar nunca esas potencias. Ésta es la raíz de la conexión con los métodos de las potencias anunciada más arriba.

Teorema 7.11. *Sea A una matriz de $n \times n$ que cumple las siguientes hipótesis:*

(a) *Los autovalores λ_i de A tienen módulo diferente:*

$$|\lambda_1| > |\lambda_2| > \cdots > |\lambda_n|.$$

(b) *La forma de Jordan de A es $A = XDX^{-1}$, con $D = \operatorname{diag}(\lambda_1, \lambda_2, \ldots, \lambda_n)$, y la matriz X^{-1} tiene una factorización LU, es decir, existe L triangular inferior unitaria y U triangular superior tal que $X^{-1} = LU$.*

Entonces las matrices A_i, Q_i, R_i del algoritmo QR tienen las siguientes propiedades de convergencia: Existen matrices de fase

$$S_k = \operatorname{diag}(\sigma_1^{(k)}, \sigma_2^{(k)}, \ldots, \sigma_n^{(k)}), \quad |\sigma_i^{(k)}| = 1,$$

tales que $\lim_{k\to\infty} S_{k-1}^H Q_k S_k = I$, *y*

$$\lim_{k\to\infty} S_k^H R_k S_{k-1} = \lim_{k\to\infty} S_{k-1}^H A_k S_{k-1} = \begin{bmatrix} \lambda_1 & \times & \cdots & \times \\ 0 & \lambda_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \times \\ 0 & \cdots & 0 & \lambda_n \end{bmatrix}$$

Demostración. No veremos la demostración de este teorema en este curso. Quienes deseen, pueden verla en el libro [SB, Theorem (6.6.4.12)]. □

Observación 7.12 (La conexión con los métodos de las potencias)**.** Aunque no demostremos el Teorema 7.11, el Teorema 7.10(c) permite entender de dónde proviene la convergencia, y en particular por qué las esquinas $(1,1)$ y (n,n) de A_k tienden a λ_1 y λ_n.

La esquina $(1,1)$: el método de las potencias. Miremos la primera columna de la identidad $A^{k+1} = P_k U_k$. Como U_k es triangular superior, $U_k e_1 = (U_k)_{11} e_1$, y entonces

$$A^{k+1} e_1 = P_k U_k e_1 = (U_k)_{11}\, P_k e_1.$$

Es decir, la primera columna de P_k es $A^{k+1}e_1$ normalizada —normalizada porque P_k es unitaria—, que por el Lema 7.1 es, salvo un factor de módulo uno, el iterado del método de las potencias con dato inicial $u_0 = e_1$. Por otro lado, el Teorema 7.10(b) dice que $A_{k+1} = P_k^H A P_k$, de modo que

$$(A_{k+1})_{11} = (P_k e_1)^H A\, (P_k e_1)$$

es el cociente de Rayleigh de ese iterado (que no se altera al multiplicarlo por un escalar de módulo uno, como vimos en la Observación 7.4). Por lo tanto $(A_{k+1})_{11}$ es el μ_k del método de las potencias con $u_0 = e_1$, y $(A_{k+1})_{11} \to \lambda_1$ con tasa $|\lambda_2/\lambda_1|$.

Esto explica, de paso, la hipótesis (b) del Teorema 7.11: el método de las potencias requiere $y_1^H u_0 \neq 0$, y aquí $y_1^H e_1 = (X^{-1})_{11} = (LU)_{11} = u_{11} \neq 0$ precisamente porque X^{-1} admite factorización LU.

La esquina (n,n): el método de las potencias inversas. Supongamos además que A es inversible, es decir que $\lambda_n \neq 0$; el caso $\lambda_n = 0$ queda fuera de este argumento, aunque la conclusión del Teorema 7.11 sigue siendo válida.

Para hacer el mismo razonamiento en el otro extremo necesitamos pasar de la primera a la última columna, y para eso conviene invertir la identidad $A^{k+1} = P_k U_k$. Como P_k es unitaria,

$$\left(A^{k+1}\right)^{-1} = U_k^{-1} P_k^H,$$

y conjugando y transponiendo,

$$\left(A^{-H}\right)^{k+1} = \left(\left(A^{k+1}\right)^{-1}\right)^H = \left(U_k^{-1} P_k^H\right)^H = P_k \left(U_k^{-1}\right)^H = P_k\, U_k^{-H}.$$

La inversa de una matriz triangular superior es triangular superior, y la conjugada transpuesta de una triangular superior es triangular inferior; por lo tanto U_k^{-H} es triangular *inferior*, y en consecuencia su última columna es un múltiplo de e_n:

$$U_k^{-H} e_n = (U_k^{-H})_{nn}\, e_n, \qquad \text{con} \quad (U_k^{-H})_{nn} = \overline{\left(\frac{1}{(U_k)_{nn}}\right)} \neq 0.$$

Resulta entonces

$$\left(A^{-H}\right)^{k+1} e_n = P_k\, U_k^{-H} e_n = (U_k^{-H})_{nn}\, P_k e_n,$$

es decir que la última columna de P_k es $\left(A^{-H}\right)^{k+1} e_n$ normalizada —otra vez, normalizada porque P_k es unitaria—, que por el Lema 7.1 es, salvo un factor de módulo uno, el iterado del método de las potencias aplicado a la matriz

$$B := A^{-H}$$

con dato inicial e_n.

Veamos cuáles son los autovalores y autovectores de B. Si y_i^H es un autovector a izquierda de A correspondiente a λ_i, es decir $y_i^H A = \lambda_i y_i^H$, entonces conjugando y transponiendo se obtiene $A^H y_i = \overline{\lambda_i}\, y_i$, como vimos en la Sección 7.1; aplicando A^{-H} a ambos miembros y dividiendo por $\overline{\lambda_i} \neq 0$,

$$B\, y_i = A^{-H} y_i = \frac{1}{\overline{\lambda_i}}\, y_i.$$

Los autovalores de B son entonces los $\overline{\lambda_i}^{-1}$, con autovectores los autovectores a izquierda y_i de A. Como $\left|\overline{\lambda_i}^{-1}\right| = 1/|\lambda_i|$, la hipótesis (a) del Teorema 7.11 se traduce en

$$\frac{1}{|\lambda_n|} > \frac{1}{|\lambda_{n-1}|} > \cdots > \frac{1}{|\lambda_1|},$$

de modo que el autovalor dominante de B es $\overline{\lambda_n}^{-1}$ —el que corresponde al autovalor de A de módulo *mínimo*— y su autovector es y_n.

Resta verificar la hipótesis de no degeneración del método de las potencias para B y el dato inicial e_n, que pide que el autovector a izquierda de B correspondiente a $\overline{\lambda_n}^{-1}$ tenga componente no nula en e_n. Ahora bien, $z^H B = \overline{\lambda_n}^{-1} z^H$ equivale a $A^{-1} z = \lambda_n^{-1} z$, o sea a $Az = \lambda_n z$: el autovector a izquierda de B es el autovector a derecha x_n de A. La condición es entonces $x_n^H e_n \neq 0$, es decir que la última componente de x_n no se anule, y

eso vuelve a estar garantizado por la hipótesis (b): de $X^{-1} = LU$ se sigue $X = U^{-1}L^{-1}$ y, como U^{-1} es triangular superior y L^{-1} es triangular inferior unitaria,

$$X_{nn} = \left(U^{-1}L^{-1}\right)_{nn} = (U^{-1})_{nn}\,(L^{-1})_{nn} = \frac{1}{u_{nn}} \neq 0.$$

Las condiciones de no degeneración en los dos extremos son, así, las dos caras de la misma hipótesis.

Estamos entonces en las hipótesis de la Proposición 7.2 aplicada a B, que da la convergencia en dirección de $P_k e_n$ a y_n, con tasa

$$\left|\frac{\overline{\lambda_{n-1}}^{-1}}{\overline{\lambda_n}^{-1}}\right| = \frac{|\lambda_n|}{|\lambda_{n-1}|}.$$

Finalmente, tomando y_n unitario, de $y_n^H A = \lambda_n y_n^H$ se sigue $y_n^H A y_n = \lambda_n y_n^H y_n = \lambda_n$; y como el cociente de Rayleigh no se altera al multiplicar el vector por un escalar de módulo uno,

$$(A_{k+1})_{nn} = (P_k e_n)^H A\,(P_k e_n) \longrightarrow y_n^H A y_n = \lambda_n,$$

con la misma tasa $|\lambda_n/\lambda_{n-1}|$, por la Observación 7.4. Ésta es la conexión con el método de las potencias inversas anunciada al comienzo de la sección. Notemos que es también la razón por la cual las variantes del algoritmo que emplean *shifts* los toman de la esquina (n, n): es allí donde hay una iteración inversa esperando un buen shift.

El resto de la matriz. Las dos esquinas son los casos extremos de un mismo hecho. Como U_k es triangular superior, para cada j las primeras j columnas de P_k generan el mismo subespacio que $A^{k+1}\langle e_1, \ldots, e_j\rangle$. Es decir, el algoritmo QR ejecuta el método de las potencias simultáneamente sobre los subespacios encajados

$$\langle e_1\rangle \subset \langle e_1, e_2\rangle \subset \cdots \subset \mathbb{C}^n,$$

ortonormalizando en cada paso. Cada uno de ellos converge al subespacio invariante dominante de su dimensión, con tasa $|\lambda_{j+1}/\lambda_j|$, y que todos los subespacios encajados converjan a los invariantes es precisamente que A_k se vuelva triangular. De ahí proviene el $\max_i |\lambda_{i+1}/\lambda_i|$ de la cota de la observación siguiente.

Observación 7.13. Veamos algunos comentarios:

- La hipótesis (b) se usa sólo para asegurar que los elementos de la diagonal de A_k convergen a los autovalores λ_i en su orden natural: $|\lambda_1| > |\lambda_2| > \cdots > |\lambda_n|$.
- De la demostración surge que

$$\left\| S_{k-1}^H A_k S_{k-1} - \begin{bmatrix} \lambda_1 & \times & \ldots & \times \\ 0 & \lambda_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \times \\ 0 & \ldots & 0 & \lambda_n \end{bmatrix} \right\| \leq C \left(\max_{1 \leq i \leq n-1} \frac{|\lambda_{i+1}|}{|\lambda_i|} \right)^k.$$

  Observemos también que $\left(S_{k-1}^H A_k S_{k-1}\right)_{ii} = \left(A_k\right)_{ii} \to \lambda_i$, cuando $k \to \infty$.

¿Qué ocurre en el caso que haya autovalores con el mismo módulo? Consideremos el caso en que

$$|\lambda_1| > \cdots > |\lambda_r| = |\lambda_{r+1}| > \cdots > |\lambda_n|.$$

En este caso ocurre lo siguiente:

(a) $\lim_{k\to\infty} a_{ij}^{(k)} = 0$ para todo $i > j$, excepto cuando $i = r+1$ y $j = r$.

(b) $\lim_{k\to\infty} a_{ii}^{(k)} = \lambda_i$, para $i \neq r, r+1$.

(c) Aunque las matrices de dos por dos

$$\begin{bmatrix} a_{r,r}^{(k)} & a_{r,r+1}^{(k)} \\ a_{r+1,r}^{(k)} & a_{r+1,r+1}^{(k)} \end{bmatrix}$$

en general divergen, sus autovalores convergen a λ_r y λ_{r+1}.

Dicho de otra manera, la convergencia de la sucesión de matrices A_i ocurre en las posiciones denotadas por λ_j y 0 en el siguiente esquema, y los autovalores de la submatriz de 2×2 indicada por $*$ convergen a λ_r y λ_{r+1}:

$$A_k \xrightarrow[k\to\infty]{} \begin{bmatrix} \lambda_1 & \times & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \times \\ 0 & \lambda_2 & \ddots & & & & & & \vdots \\ & \ddots & \ddots & \times & & & & & \vdots \\ & & 0 & \lambda_{r-1} & \times & & & & \vdots \\ & & & 0 & * & * & & & \vdots \\ & & & & * & * & \times & & \vdots \\ & & & & & 0 & \lambda_{r+2} & \ddots & \vdots \\ & & & & & & \ddots & \ddots & \times \\ 0 & & & & & & & 0 & \lambda_n \end{bmatrix}$$

Eficiencia. Aunque el algoritmo QR tiene excelentes propiedades de convergencia, la manera presentada no es muy práctica. En primer lugar, requiere que calculemos la factorización QR de A_k en cada paso. Para una matriz llena, este proceso requiere $O(n^3)$ operaciones y conduce a un algoritmo de complejidad $O(n^4)$. Es altamente deseable mejorar el algoritmo para que sea $O(n^3)$. Una manera de hacer esto es hallar, antes de comenzar la iteración, una matriz upper Hessenberg que sea similar a A. Esto resulta provechoso por dos motivos:

(i) Si se aplica el paso

$$[Q, R] = \texttt{qrhouse}(A_k), \qquad A_{k+1} = RQ,$$

a una matriz upper Hessenberg A_k, entonces A_{k+1} también es upper Hessenberg. Aquí, `qrhouse`() es la función que genera la factorización QR con las matrices de Householder de la sección 3.4.

(ii) El costo de realizar el paso del punto anterior cuando la matriz A_k es upper Hessenberg es $O(n^2)$ y no $O(n^3)$.

(iii) Dada una matriz llena A, se puede obtener una matriz similar A_0 de tipo upper Hessenberg, con $O(n^3)$ operaciones.

Los dos primeros puntos se dejan como ejercicio, ver Problemas 7.14 y 7.15.

Veamos el procedimiento para lograr (iii). La idea es utilizar las ideas de la factorización QR para hacer ceros debajo de la diagonal. El problema es que, para mantener matrices similares, tenemos que multiplicar a izquierda y a derecha por una matriz y su inversa.

Veamos primero por qué no se podría llegar a una matriz triangular directamente.

Hay una razón de fondo, y es la misma que abre el capítulo: si existiera un procedimiento que en una cantidad finita de pasos llevara cualquier matriz a una triangular similar, los elementos diagonales de esa triangular serían los autovalores de A, y tendríamos un método directo para calcular autovalores de matrices de cualquier orden, cosa que sabemos imposible (Sección 7.1). Todo método ha de ser iterativo, y lo más que puede pretenderse de un procedimiento finito es acercarse a una triangular. La forma upper Hessenberg es exactamente eso.

Vale la pena, de todos modos, ver qué es lo que falla concretamente al intentar anular toda la primera columna. La dificultad es que aquí, a diferencia de lo que ocurre con la factorización QR, no basta multiplicar a izquierda: para no alterar los autovalores necesitamos una transformación de similaridad, es decir multiplicar también a derecha por Q^H, y esa segunda multiplicación puede destruir los ceros recién creados. Precisemos. Sea Q unitaria tal que $Q\,\mathrm{col}_1(A) = \alpha e_1$ para algún $\alpha \in \mathbb{C}$ —por ejemplo, la matriz de Householder construida a partir de $\mathrm{col}_1(A)$—, de modo que la primera columna de QA tiene ceros en las posiciones 2 a n. ¿Sobreviven esos ceros al multiplicar por Q^H a derecha? Como la primera columna de QAQ^H es QAQ^He_1, resulta:

- Si $Q^He_1 = e_1$, la primera columna de QAQ^H es $QAe_1 = Q\,\mathrm{col}_1(A)$, y los ceros que hicimos quedan donde están.
- Si $Q^He_1 \neq e_1$, la primera columna de QAQ^H es una combinación de varias columnas de QA, y en general los ceros se pierden.

El problema es que una Q que deje fija la primera coordenada no puede anular las posiciones 2 a n de la primera columna. En efecto, si Q es unitaria y $Qe_1 = e_1$, entonces la primera columna de Q es e_1 y, por ortogonalidad, todas las demás tienen primera componente nula; es decir

$$Q = \begin{bmatrix} 1 & 0^T \\ 0 & \tilde{Q} \end{bmatrix}, \qquad \tilde{Q} \text{ unitaria}, \qquad \text{y entonces} \qquad Q\,\mathrm{col}_1(A) = \begin{bmatrix} a_{11} \\ \tilde{Q}A_{2:n,1} \end{bmatrix}.$$

Como $\tilde{Q}$ es inversible, $\tilde{Q}A_{2:n,1} = 0$ sólo si $A_{2:n,1} = 0$, o sea sólo si la primera columna ya tenía los ceros buscados.

En resumen: anular toda la primera columna obliga a mezclar la primera fila con las demás, y en cuanto hacemos eso la multiplicación por Q^H a derecha vuelve a mezclar la primera columna con las demás y arruina el trabajo. Si en cambio nos conformamos con

anular las posiciones 3 a n —dejando viva la subdiagonal— alcanza con una Q que fije la primera coordenada, y entonces los ceros sobreviven a la multiplicación a derecha. Ésa es la razón por la cual la forma upper Hessenberg se alcanza en finitos pasos y la triangular no.

La idea entonces es transformar la matriz en lo más parecido a una triangular posible, y esto es una matriz upper Hessenberg. El procedimiento es como sigue:

Paso 0. Sea $A^{(0)} = A$.

Paso 1. Consideramos $x = A^{(0)}_{2:n,1}$, es decir, la primera columna de A sin su primera componente. Tomamos $u = \dfrac{x/\|x\|_2 \pm e_1}{\sqrt{x_1/\|x\|_2 \pm 1}}$ que resulta un vector con $\|u\| = \sqrt{2}$ y si definimos la matriz de Householder $H_1 = I - uu^H$ resulta $H_1 x = \mp\|x\|_2 e_1$. Tomamos ahora

$$Q_1 = \begin{bmatrix} 1 & 0^T \\ 0 & H_1 \end{bmatrix}$$

y resulta que si definimos $A^{(1)} = Q_1 A^{(0)} Q_1^H$, entonces

$$A^{(1)} = \begin{bmatrix} a_{11} & A^{(0)}_{1,2:n} H_1^H \\ H_1 x & H_1 A^{(0)}_{2:n,2:n} H_1^H \end{bmatrix} = \begin{bmatrix} a_{11} & \times & \cdots & \times \\ \times & & & \\ 0 & & H_1 A^{(0)}_{2:n,2:n} H_1^H & \\ \vdots & & & \\ 0 & & & \end{bmatrix}.$$

Esto se debe a que multiplicar por Q_1^H a derecha no modifica la primera columna de $Q_1 A^{(0)}$, sólo sus columnas de la 2 a la n.

Paso 2. Consideramos ahora $x = A^{(1)}_{3:n,2}$, es decir, la segunda columna de $A^{(1)}$ sin sus dos primeras componentes. Tomamos $u = \dfrac{x/\|x\|_2 \pm e_1}{\sqrt{x_1/\|x\|_2 \pm 1}}$ (de $n-2$ componentes) y si definimos la matriz de Householder $H_2 = I - uu^H$ resulta $H_2 x = \mp\|x\|_2 e_1$. Tomamos ahora

$$Q_2 = \begin{bmatrix} 1 & 0 & 0^T \\ 0 & 1 & 0^T \\ 0 & 0 & H_2 \end{bmatrix}$$

y resulta que si definimos $A^{(2)} = Q_2 A^{(1)} Q_2^H$, entonces

$$A^{(2)} = \begin{bmatrix} \times & \times & \times & \cdots & \times \\ \times & \times & \times & \cdots & \times \\ 0 & \times & \times & \cdots & \times \\ 0 & 0 & \times & \cdots & \times \\ \vdots & \vdots & \times & \cdots & \times \\ 0 & 0 & \times & \cdots & \times \end{bmatrix}.$$

Paso 3. Continuamos con este proceso hasta que $A^{(n-2)}$ resulta upper Hessenberg y similar a A.

Queda como ejercicio ver que este procedimiento se puede realizar con $O(n^3)$ operaciones.

El algoritmo QR con shifts. La Observación 7.12 muestra que en la esquina (n,n) de A_k hay un método de las potencias inversas, y la Proposición 7.7 dice que ese método se acelera enormemente con un buen shift. De la combinación de ambas cosas sale la variante que se usa en la práctica: dada una sucesión de números $\mu_0, \mu_1, \ldots$, se define

$$A_k - \mu_k I = Q_k R_k \quad \text{(factorización } QR\text{)}, \qquad A_{k+1} = R_k Q_k + \mu_k I.$$

La similaridad se conserva cualesquiera sean los shifts: de $R_k = Q_k^H (A_k - \mu_k I)$ resulta

$$A_{k+1} = Q_k^H (A_k - \mu_k I) Q_k + \mu_k I = Q_k^H A_k Q_k,$$

de modo que todas las A_k siguen siendo unitariamente similares a A, y el Teorema 7.10(b) sigue valiendo con la misma demostración, pues sólo usa esta identidad. Lo que cambia es la velocidad, y el Teorema 7.10(c) se generaliza así:

Proposición 7.14. *Con las notaciones anteriores, y $P_k = Q_0 Q_1 \ldots Q_k$, $U_k = R_k R_{k-1} \ldots R_0$, vale*

$$(A - \mu_k I)(A - \mu_{k-1} I) \cdots (A - \mu_0 I) = P_k U_k.$$

Demostración. Por inducción. Para $k = 0$ es la definición: $A - \mu_0 I = A_0 - \mu_0 I = Q_0 R_0 = P_0 U_0$. Llamemos $M_k = (A - \mu_k I) \cdots (A - \mu_0 I)$ y supongamos que $M_{k-1} = P_{k-1} U_{k-1}$. De $A_k = P_{k-1}^H A P_{k-1}$ se sigue que $(A - \mu_k I) P_{k-1} = P_{k-1}(A_k - \mu_k I)$, y entonces

$$M_k = (A - \mu_k I) M_{k-1} = (A - \mu_k I) P_{k-1} U_{k-1} = P_{k-1}(A_k - \mu_k I) U_{k-1} = P_{k-1} Q_k R_k U_{k-1} = P_k U_k.$$

□

Repitiendo con M_k el cálculo que hicimos con A^{k+1} en la Observación 7.12, es decir invirtiendo y conjugando, obtenemos

$$M_k^{-H} e_n = (U_k^{-H})_{nn} \, P_k e_n, \qquad \text{con} \quad M_k^{-H} = (A^H - \bar{\mu}_0 I)^{-1} \cdots (A^H - \bar{\mu}_k I)^{-1}.$$

La última columna de P_k es entonces el método de las potencias inversas *con shifts* aplicado a A^H: en el paso k el error se contrae, aproximadamente, en el factor

$$\max_{i \neq n} \left| \frac{\lambda_n - \mu_k}{\lambda_i - \mu_k} \right|,$$

que es diminuto apenas μ_k se acerque a λ_n.

¿De dónde sacar los μ_k? La misma Observación 7.12 responde: $(A_k)_{nn}$ *ya* es una aproximación de λ_n, pues es el cociente de Rayleigh de la última columna de P_{k-1}. Tomar

$$\mu_k = (A_k)_{nn}$$

equivale entonces a actualizar el shift con el cociente de Rayleigh en cada paso, es decir a la iteración del cociente de Rayleigh mencionada en la Observación 7.8, con su convergencia cúbica para matrices hermíticas. Acá no hay que pagar por refactorizar: el paso del algoritmo QR cuesta lo mismo con shift que sin él.

En la práctica, el elemento subdiagonal $a^{(k)}_{n,n-1}$ se vuelve despreciable en unas pocas iteraciones. Cuando eso ocurre se declara $\lambda_n \approx (A_k)_{nn}$, se descartan la última fila y la última columna, y se continúa con la submatriz principal de $(n-1)\times(n-1)$. Este procedimiento se llama *deflación*, y es lo que lleva el costo total a $O(n^3)$: unas pocas iteraciones de $O(n^2)$ por cada autovalor.

El shift $\mu_k = (A_k)_{nn}$ puede fallar, y el ejemplo más simple es

$$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix},$$

cuyos autovalores son ± 1, iguales en módulo (el caso contemplado en la Observación 7.13). Aquí $a_{22} = 0$, con lo cual el shift es nulo; la factorización QR de A es $Q = A$, $R = I$, y entonces $A_1 = RQ = A$: el algoritmo se queda quieto para siempre. El remedio habitual es el *shift de Wilkinson*, que consiste en tomar como μ_k el autovalor del bloque de 2×2 inferior derecho

$$\begin{bmatrix} a^{(k)}_{n-1,n-1} & a^{(k)}_{n-1,n} \\ a^{(k)}_{n,n-1} & a^{(k)}_{n,n} \end{bmatrix}$$

más cercano a $a^{(k)}_{n,n}$. En el ejemplo anterior da $\mu_0 = 1$ y el algoritmo converge en un solo paso. Cuando A es real y ese bloque tiene autovalores complejos conjugados, el shift de Wilkinson es complejo; para no abandonar la aritmética real se usa la variante de *doble shift*, que aplica el par conjugado en un único paso.

7.5 Problemas

7.1. Programar el método de las potencias y verificar la tasa de convergencia con una matriz de 5×5 de la que conozca los autovalores.

7.2. Método de las potencias: Para $N \in \mathbb{N}$, considerar la matriz

$$A_N = \begin{bmatrix} 2 & -1 & & & & \\ -1 & 2 & -1 & & 0 & \\ & -1 & 2 & -1 & & \\ & & \ddots & \ddots & \ddots & \\ & 0 & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix} \in \mathbb{R}^{N\times N}.$$

(a) Verificar que si $1 \le i \le N$, el vector $x_i \in \mathbb{R}^N$ definido por $(x_i)_j = \operatorname{sen}(\frac{\pi i j}{N+1})$ es un autovector de A_N correspondiente al autovalor $\lambda_i = 4\operatorname{sen}^2 \frac{\pi i}{2(N+1)}$.

(b) Verificar el orden de convergencia del método de las potencias para distintos valores de N (5, 15, 50). Comparar con el orden previsto por la teoría.

7.3. Programar el método de las potencias inversas y verificar la tasa de convergencia con una matriz de 5×5 de la que conozca los autovalores.

7.4. Método de las potencias inversas: Para $N \in \mathbb{N}$, considerar la matriz

$$A_N = \begin{bmatrix} 2 & -1 & & & & \\ -1 & 2 & -1 & & 0 & \\ & -1 & 2 & -1 & & \\ & & \ddots & \ddots & \ddots & \\ & 0 & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix} \in \mathbb{R}^{N \times N}.$$

Verificar el orden de convergencia del método de las potencias inversas para distintos valores de N (5, 15, 50). Comparar con el orden previsto por la teoría.

7.5. Programar el método de las potencias inversas con shift que haga lo siguiente: comience con $\mu = 0$ y luego, en cada paso actualice μ al valor de λ aproximado. Verificar la tasa de convergencia con una matriz de 5×5 de la que conozca los autovalores.

7.6. Para $N \in \mathbb{N}$, considerar la matriz

$$A_N = \begin{bmatrix} 2 & -1 & & & & \\ -1 & 2 & -1 & & 0 & \\ & -1 & 2 & -1 & & \\ & & \ddots & \ddots & \ddots & \\ & 0 & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix} \in \mathbb{R}^{N \times N}.$$

Comparar la convergencia del método de las potencias inversas con y sin shift, para distintos valores de N (5, 15, 50, 100).

7.7. Implementar el algoritmo QR usando la función `qr` existente en MATLAB/OCTAVE. Detener el algoritmo cuando el máximo cambio de la diagonal de A es menor a una tolerancia dada. Verificar experimentalmente (con algunos ejemplos aleatorios) que el algoritmo mantiene la estructura Hessenberg (comenzar con una tridiagonal no-simétrica). ¿Qué ocurre al comenzar con una tridiagonal simétrica?

7.8. Método QR: Para $N \in \mathbb{N}$, considerar la matriz

$$A_N = \begin{bmatrix} 2 & -1 & & & & \\ -1 & 2 & -1 & & 0 & \\ & -1 & 2 & -1 & & \\ & & \ddots & \ddots & \ddots & \\ & 0 & & -1 & 2 & -1 \\ & & & & -1 & 2 \end{bmatrix} \in \mathbb{R}^{N \times N}.$$

(a) Demostrar que si $1 \leq i \leq N$, el vector $x_i \in \mathbb{R}^N$ definido por $(x_i)_j = \operatorname{sen}(\frac{\pi ij}{N+1})$ es un autovector de A_N correspondiente al autovalor $\lambda_i = 4 \operatorname{sen}^2 \frac{\pi i}{2(N+1)}$.

(b) Verificar el orden de convergencia de los autovalores para distintos valores de N (5, 15, 50). Comparar con el orden previsto por la teoría.

7.9. Algoritmo QR con shift y deflación: Para $N \in \mathbb{N}$, considerar la matriz A_N del problema anterior.

(a) Modificar la implementación del Problema 7.7 para incorporar el shift de Rayleigh $\mu_k = (A_k)_{nn}$ y la deflación: cuando $|a^{(k)}_{n,n-1}|$ resulte menor que una tolerancia dada, aceptar $(A_k)_{nn}$ como autovalor y continuar con la submatriz principal de $(n-1) \times (n-1)$.

(b) Comparar, para $N = 5$, 15 y 50, el número total de iteraciones que requiere el algoritmo del ítem anterior con el que requiere el algoritmo QR sin shift para la misma tolerancia.

(c) Al aproximar cada autovalor, graficar $|a^{(k)}_{n,n-1}|$ en función de k (escala logarítmica) y verificar que decrece cúbicamente, como corresponde a una matriz hermítica.

(d) ¿Qué ocurre si se aplica el algoritmo con shift de Rayleigh a la matriz $\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$? Explicar lo observado y verificar que el shift de Wilkinson resuelve el problema.

7.10. Construir una matriz de 5×5 con un autovalor de multiplicidad geométrica y algebraica 2, y los otros con multiplicidad 1. Probar el algoritmo QR, ver e informar qué ocurre (este es un caso en que las hipótesis del teorema de convergencia no se cumplen).

7.11. Construir una matriz de 5×5 con un autovalor de multiplicidad geométrica 1 y algebraica 2, y los otros con multiplicidad 1. Probar el algoritmo QR, ver e informar qué ocurre (este es otro caso en el que las hipótesis del teorema de convergencia no se cumplen).

7.12. Sea $A \in \mathbb{C}^{n\times n}$ una matriz no singular. Demostrar que si Q, R, $\tilde{Q}$, $\tilde{R}$ cumplen

$$A = QR = \tilde{Q}\tilde{R}, \qquad Q^H Q = \tilde{Q}^H \tilde{Q} = I, \quad R,\ \tilde{R} \text{ son triangulares superiores,}$$

entonces existen números complejos ω_i, $|\omega_i| = 1$, $i = 1, 2, \ldots, n$ tales que

$$\tilde{Q} = QS, \quad \tilde{R} = S^H R, \quad \text{con } S = \operatorname{diag}(\omega_1, \omega_2, \ldots, \omega_n).$$

7.13. Demostrar que la propiedad upper Hessenberg es cerrada por el producto. Es decir, dadas A, B dos matrices de orden n upper Hessenberg, probar que AB también es upper Hessenberg.

7.14. Demostrar que el algoritmo QR mantiene la propiedad upper Hessenberg de las matrices. Más precisamente, sea $A \in \mathbb{C}^{n\times n}$ upper Hessenberg, y consideremos la factorización QR generada por la función que utiliza las matrices de Householder de la sección 3.4, y cumple:

$$A = QR, \quad Q^H Q = I, \quad R \text{ triangular superior} \tag{7.3}$$

Sea

$$\tilde{A} = RQ,$$

y demostrar que entonces $\tilde{A}$ es upper Hessenberg.

Si no supiéramos con qué algoritmo se obtuvo la factorización QR, y sólo se sabe que se dispone de Q y R con las propiedades de (7.3), ¿es cierto que entonces $\tilde{A} = RQ$ es upper Hessenberg? (Esta pregunta se le ocurrió al profesor un domingo a la noche, y no sabe aún la respuesta) (Esa misma noche, un rato más tarde, reordenando los problemas, se le ocurrió que el problema que ahora figura inmediatamente antes que este puede ser útil).

7.15. Demostrar que el algoritmo QR mantiene la hermiticidad de las matrices. Más precisamente, sea $A \in \mathbb{C}^{n\times n}$ hermítica, demostrar que si

$$A = QR, \quad Q^H Q = I, \quad R \text{ triangular superior} \quad \text{y} \quad \tilde{A} = RQ,$$

entonces $\tilde{A}$ es hermítica.

Suponiendo que se cumplen las hipótesis del Teorema 7.11. ¿A qué tiende la sucesión de matrices $\{A_k\}_{k\geq 1}$ producida por el algoritmo QR cuando A es hermítica? ¿Qué se puede decir de la sucesión $\{P_k\}_{k\geq 1}$?

Capítulo 8

Problemas a valores iniciales

En este capítulo veremos métodos numéricos para problemas a valores iniciales de ecuaciones diferenciales ordinarias.

Un problema a valores iniciales (PVI) para una ecuación diferencial ordinaria (EDO) es un problema de la forma

$$\text{(PVI)} \begin{cases} y' = f(t, y) \\ y(t_0) = y_0. \end{cases}$$

Aquí $f : I \times D \to \mathbb{R}^d$, $D \subset \mathbb{R}^d$, $I \subset \mathbb{R}$ es un intervalo (de tiempo) que contiene a t_0, e $y_0 \in \mathbb{R}^d$ es el *dato inicial*.

Definición 8.1. Se dice que $y \in C^1(J)$ es solución de (PVI) sobre J, donde J es un intervalo si

(1) $J \subset I$;

(2) $y(t) \in D$ y $y'(t) = f(t, y(t))$, para todo $t \in J$;

(3) $t_0 \in J$, $y(t_0) = y_0$.

Ejemplo 8.2. Si consideramos el PVI

$$\begin{cases} y' = -5y, \\ y(0) = 3, \end{cases}$$

con $f : \mathbb{R} \times \mathbb{R} \to \mathbb{R}$, $f(t, y) = -5y$, la familia de soluciones que cumple la ecuación diferencial $y' = -5y$ es la clase de todas las funciones $y(t) = Ce^{-5t}$ con C constante arbitraria. Al *imponer* la condición inicial $y(0) = 3$ se tiene que la solución al PVI es la que corresponde a $C = 3$, es decir $y(t) = 3e^{-5t}$ es la solución sobre $\mathbb{R}$.

Ejemplo 8.3. El siguiente PVI corresponde a un modelo de los más elementales de *predador-presa*:

$$\begin{cases} y_1' = 2y_1y_2 - 3y_1, \\ y_2' = -y_1y_2 + 5y_2, \\ y_1(0) = \alpha, \\ y_2(0) = \beta. \end{cases} \quad \text{Es equivalente a} \quad \begin{cases} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}' = \begin{bmatrix} 2y_1y_2 - 3y_1 \\ -y_1y_2 + 5y_2 \end{bmatrix}, \\ \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}(0) = \begin{bmatrix} \alpha \\ \beta \end{bmatrix}. \end{cases}$$

Ejemplo 8.4. El modelo para un péndulo ideal de longitud L y masa m, bajo el efecto de una fuerza de gravedad g, sin rozamiento es

$$\begin{cases} \theta'' = -\dfrac{g}{L}\sin(\theta) \\ \theta(0) = \theta_0, \\ \theta'(0) = v_0. \end{cases}$$

Si bien no parece a simple vista un PVI porque hay derivadas de orden dos, si definimos el vector $y = \begin{bmatrix} \theta \\ \theta' \end{bmatrix}$, es equivalente al problema (PVI) con

$$f(t,y) = \begin{bmatrix} y_2 \\ -\frac{g}{L}\sin(y_1) \end{bmatrix} \qquad \text{y} \qquad y_0 = \begin{bmatrix} \theta_0 \\ v_0 \end{bmatrix}$$

Observación 8.5. Para entender un poco mejor este tipo de problemas es importante observar que si y es una solución de (PVI) sobre J entonces

$$y(t) = y_0 + \int_{t_0}^{t} f(s, y(s))\, ds, \qquad \text{para todo } t \in J. \tag{8.1}$$

Recíprocamente, si $y \in C(J)$ y se cumple (8.1) para f continua, entonces $y \in C^1(J)$ y por el teorema fundamental del cálculo, y es solución de (PVI).

8.1 Existencia, unicidad y estabilidad de soluciones

Para desarrollar y estudiar métodos numéricos hace falta comprender bien lo que se quiere calcular. Por ello, comenzaremos estudiando algunas propiedades cualitativas de las (soluciones de las) ecuaciones diferenciales.

Existencia y unicidad

El siguiente teorema da condiciones suficientes para que (PVI) tenga solución, y en caso que la tenga, sea única.

Teorema 8.6. *Sea $I = [a,b]$, $D = \mathbb{R}^d$, $f : I \times D \to \mathbb{R}^d$ continua tal que satisface una condición Lipschitz en la variable y, más precisamente:*

$$|f(t,y) - f(t,z)| \leq U|y - z|, \quad \text{para todo } y, z \in D,\ t \in I. \tag{8.2}$$

Si $t_0 \in I$, $y_0 \in D$, entonces existe una única solución de (PVI) en $[a,b]$.

Demostración. Para la demostración utilizaremos el método de *las aproximaciones sucesivas de Picard*. Definimos $y_k : I \to \mathbb{R}^d$ inductivamente como sigue:

$$\begin{aligned} y_0(t) &= y_0, \qquad t \in [a,b], \\ y_{k+1}(t) &= y_0 + \int_{t_0}^{t} f(s, y_k(s))\, ds, \qquad t \in [a,b], \quad k = 0, 1, \ldots. \end{aligned}$$

Luego

$$
\begin{aligned}
|y_2(t) - y_1(t)| &\le \left| \int_{t_0}^{t} f(s, y_1(s)) - f(s, y_0(s))\, ds \right| \le U \underbrace{\max_{s\in[a,b]} |y_1(s) - y_0|}_{A} |t - t_0| \\
&= UA|t - t_0|, \\
|y_3(t) - y_2(t)| &\le \left| \int_{t_0}^{t} f(s, y_2(s)) - f(s, y_1(s))\, ds \right| \le U \left| \int_{t_0}^{t} |y_2(s) - y_1(s)|\, ds \right| \\
&\le U^2 A \left| \int_{t_0}^{t} |s - t_0|\, ds \right| \\
&= A\frac{U^2|t - t_0|^2}{2}, \\
&\vdots
\end{aligned}
$$

Por inducción llegamos a que

$$
|y_{k+1}(t) - y_k(t)| \le A\frac{U^k|t - t_0|^k}{k!} \qquad \Longrightarrow \qquad \max_{t\in[a,b]} |y_{k+1}(t) - y_k(t)| \le A\frac{U^k|b - a|^k}{k!}.
$$

Entonces, como

$$
y_n(t) = y_0 + \sum_{k=1}^{n} \big(y_k(t) - y_{k-1}(t)\big)
$$

y como la serie $\sum_{k=0}^{\infty} A\frac{(U(b-a))^k}{k!} = Ae^{U(b-a)}$ converge, resulta que y_n converge uniformemente a una función continua y en $[a, b]$.

Además, cualquiera sea $t \in [a, b]$,

$$
\left| \int_{t_0}^{t} f(s, y_k(s))\, ds - \int_{t_0}^{t} f(s, y(s))\, ds \right| \le U(b - a) \max_{s\in[a,b]} |y_k(s) - y(s)| \to 0,
$$

y por lo tanto

$$
y(t) = y_0 + \int_{t_0}^{t} f(s, y(s))\, ds, \qquad t \in [a, b].
$$

Finalmente, y es solución de (8.1) y por ser f continua, resulta que y es solución de (PVI).

Para ver la unicidad, supongamos que y_1, y_2 son soluciones de (PVI). Entonces

$$
y_1(t) - y_2(t) = \int_{t_0}^{t} f(s, y_1(s)) - f(s, y_2(s))\, ds.
$$

Si consideramos $t \ge t_0$ resulta que

$$
|y_1(t) - y_2(t)| \le \int_{t_0}^{t} |f(s, y_1(s)) - f(s, y_2(s))|\, ds \le U \int_{t_0}^{t} |y_1(s) - y_2(s)|\, ds.
$$

Por el Lema de Gronwall (Lema 8.7) resulta que

$$
|y_1(t) - y_2(t)| \le 0\, e^{U(t-t_0)} = 0, \quad t \ge t_0.
$$

Para el caso $t \leq t_0$ hacemos el cambio de variables $\tau = t_0 - t$ y obtenemos

$$|y_1(t_0 - \tau) - y_2(t_0 - \tau)| \leq U \int_0^\tau |y_1(t_0 - s) - y_2(t_0 - s)|\, ds, \quad \tau \geq 0.$$

Nuevamente por la desigualdad de Gronwall,

$$|y_1(t_0 - \tau) - y_2(t_0 - \tau)| \leq 0\, e^{U\tau} = 0, \quad \tau \geq 0.$$

□

Lema 8.7 (Gronwall)**.** *Sea $g : [a, b] \to \mathbb{R}$ continua con $g(t) \geq 0$ en $[a, b]$ y $g(a) = g_0$. Supongamos que se cumple alguna de las siguientes hipótesis:*

(1) *$U \geq 0$, $g(t) \leq g_0 + U \int_a^t g(s)\, ds$, $t \in [a, b]$;*

(2) *$U \in \mathbb{R}$, g diferenciable en (a, b) y $g'(t) \leq Ug(t)$, $t \in [a, b]$.*

Entonces

$$g(t) \leq g_0 e^{U(t-a)}, \quad t \in [a, b].$$

Demostración. Supongamos primero que se cumple (1). En ese caso definimos $G(t) = g_0 + U \int_a^t g(s)\, ds$ y vemos que la hipótesis implica

$$G'(t) = Ug(t) \leq UG(t) \quad \text{(aquí es importante que } U \geq 0\text{)}.$$

Luego $G'(t) - UG(t) \leq 0$ y multiplicando por $e^{-U(t-a)} \geq 0$ obtenemos

$$\frac{d}{dt}\left(e^{-U(t-a)}G(t)\right) \leq 0,$$

que a su vez implica

$$e^{-U(t-a)}G(t) \leq e^{-U(a-a)}G(a) = g_0, \quad t \in [a, b].$$

Finalmente, por la hipótesis (1),

$$g(t) \leq G(t) \leq e^{U(t-a)}g_0, \quad t \in [a, b].$$

Supongamos ahora que se cumple la hipótesis (2). Entonces

$$g'(t) - Ug(t) \leq 0 \quad \Rightarrow \quad \frac{d}{dt}\left(e^{-U(t-a)}g(t)\right) = e^{-U(t-a)}g'(t) - Ue^{-U(t-a)}g(t) \leq 0,$$

y por lo tanto

$$e^{-U(t-a)}g(t) \leq e^{-U(a-a)}g(a) = g_0, \quad t \in [a, b].$$

Multiplicando ambos miembros por $e^{U(t-a)}$ obtenemos la afirmación del lema. □

Observación 8.8. El resultado que se obtiene bajo la hipótesis (1) se conoce como *Lema de Gronwall integral* y el que se obtiene bajo la hipótesis (2) es el *Lema de Gronwall diferencial*. Para el primero hace falta que $U \geq 0$ mientras que el segundo vale para cualquier valor de $U \in \mathbb{R}$. También vale el siguiente resultado que se demuestra de manera análoga al Lema de Gronwall diferencial.

Sea $g : [a, b] \to \mathbb{R}$ continua con $g(t) \geq 0$ en $[a, b]$ y $g(a) = g_0$. Si $U \in \mathbb{R}$, g es diferenciable en (a, b) y $g'(t) \geq Lg(t)$, $t \in [a, b]$, entonces

$$g(t) \geq g_0 e^{L(t-a)}, \quad t \in [a, b].$$

Observación 8.9. Si debilitamos la condición de Lipschitz (8.2) de f por la de *localmente Lipschitz*, es decir, si solo suponemos que para cada $D \subset \mathbb{R}^d$ acotado existe una constante U_D tal que

$$|f(t, y) - f(t, z)| \leq U_D |y - z|, \quad \text{para todo } y, z \in D,\ t \in I.$$

entonces solo se puede garantizar existencia *local* de la solución. Es decir, existe $\delta > 0$ tal que (PVI) tiene solución en $(t_0 - \delta, t_0 + \delta) \cap I$.

Un ejemplo de existencia local viene dado por el PVI

$$\begin{cases} y' = y^2 \\ y(0) = 1. \end{cases}$$

En este caso, el intervalo I es todo $\mathbb{R}$, pero la única solución es

$$y(t) = \frac{1}{1 - t},$$

que solo existe en $(-\infty, 1)$. Se dice que hay un *blow-up* en $t = 1$ o que la solución *explota* en $t = 1$.

Observación 8.10. Si solo suponemos que f es continua en ambas variables, se puede asegurar existencia local (con una demostración más complicada) pero no se puede asegurar la unicidad de soluciones. El típico ejemplo viene dado por el PVI siguiente:

$$\begin{cases} y' = 2\sqrt{y} \\ y(0) = 0. \end{cases}$$

En este caso, el intervalo I es todo $\mathbb{R}$, y cualquiera sea $c \geq 0$ la siguiente función es una solución del PVI en todo $\mathbb{R}$:

$$y(t) = \begin{cases} 0, & t \leq c, \\ (t - c)^2, & t > c. \end{cases}$$

En casos como este suele decirse que hay *bifurcaciones*.

Estabilidad de soluciones

El concepto de estabilidad para problemas a valores iniciales se refiere a la dependencia de la solución sobre el dato inicial. A lo largo de esta sección consideraremos lo que ocurre para t *a la derecha* del punto donde se da la condición inicial, es decir $t \geq t_0 = a$. En el siguiente teorema se establece el resultado principal de esta sección.

Teorema 8.11. *Sea $I = [a, b]$ y supongamos que $f : I \times \mathbb{R}^d \to \mathbb{R}^d$ es continua de ambas variables, diferenciable con respecto a $y \in \mathbb{R}^d$, con matriz diferencial*

$$\frac{\partial f}{\partial y} = \left(\frac{\partial f_i}{\partial y_j}\right)_{i,j=1}^{d}.$$

Supongamos además que existen constantes L, U tales que

$$L|x|^2 \leq \frac{\partial f}{\partial y}(t, y)x \cdot x \leq U|x|^2, \quad t \in [a, b],\ y \in \mathbb{R}^d,\ x \in \mathbb{R}^d. \tag{8.3}$$

Si y, z denotan soluciones a los siguientes problemas,

$$\begin{cases} y' = f(t, y), \\ y(a) = y_0, \end{cases} \qquad \begin{cases} z' = f(t, z), \\ z(a) = z_0. \end{cases}$$

entonces

$$|y_0 - z_0|e^{L(t-a)} \leq |y(t) - z(t)| \leq |y_0 - z_0|e^{U(t-a)}, \qquad t \in [a, b].$$

Observación 8.12. En el caso $d = 1$, la condición (8.3) es equivalente a

$$L \leq \frac{\partial f}{\partial y}(t, y) \leq U, \quad t \in [a, b],\ y \in \mathbb{R}.$$

Si $d \geq 1$ y A es una matriz de $d \times d$, entonces $Ax \cdot x = x^T Ax$ siempre que x sea un vector *columna*. Si A es simétrica, $L|x|^2 \leq x^T Ax \leq U|x|^2$ se cumple tomando L, U iguales al mínimo y máximo autovalor de A, respectivamente. En efecto, si A es simétrica, es diagonalizable con $A = V\Lambda V^T$, donde V, Λ son matrices reales con V ortogonal ($V^T V = VV^T = I$) y Λ diagonal con los autovalores de A sobre la diagonal. Luego

$$x^T Ax = \underbrace{x^T V}_{y^T} \Lambda \underbrace{V^T x}_{y} = y^T \Lambda y = \sum_{i=1}^{d} \Lambda_{ii} y_i^2.$$

Si llamamos $\lambda_{\max} = \max_{1 \leq i \leq d} \Lambda_{ii}$, $\lambda_{\min} = \min_{1 \leq i \leq d} \Lambda_{ii}$, y observamos que

$$\sum_{i=1}^{d} y_i^2 = |y|^2 = y^T y = x^T VV^T x = x^T x = |x|^2,$$

llegamos a que

$$\lambda_{\min}|x|^2 \leq x^T Ax \leq \lambda_{\max}|x|^2.$$

Demostración del Teorema 8.11. Sean $y(t)$ y $z(t)$ como en las hipótesis del teorema, entonces

$$(y - z)'(t) = y'(t) - z'(t) = f(t, y(t)) - f(t, z(t)).$$

Observemos que si, fijado t, definimos $\varphi : [0, 1] \to \mathbb{R}^d$ por $\varphi(s) = f(t, sy(t) + (1 - s)z(t))$ entonces $\varphi(0) = f(t, z(t))$ y $\varphi(1) = f(t, y(t))$. Luego

$$f(t, y(t)) - f(t, z(t)) = \varphi(1) - \varphi(0) = \int_0^1 \frac{d\varphi}{ds}\, ds = \int_0^1 \frac{\partial f}{\partial y}(t, sy(t) + (1-s)z(t))(y(t) - z(t))\, ds.$$

Es decir

$$(y-z)'(t) = \int_0^1 \frac{\partial f}{\partial y}(t, sy(t) + (1-s)z(t))(y-z)(t)\, ds,$$

y multiplicando a ambos lados escalarmente por el vector $(y-z)(t)$,

$$(y-z)'(t) \cdot (y-z)(t) = \int_0^1 \frac{\partial f}{\partial y}(t, sy(t) + (1-s)z(t))(y-z)(t) \cdot (y-z)(t)\, ds.$$

El miembro izquierdo satisface

$$(y-z)'(t) \cdot (y-z)(t) = \frac{1}{2}\frac{d}{dt}\Big(|(y-z)(t)|^2\Big),$$

y por (8.3) el integrando satisface

$$L|(y-z)(t)|^2 \leq \frac{\partial f}{\partial y}(t, sy(t) + (1-s)z(t))(y-z)(t) \cdot (y-z)(t) \leq U|(y-z)(t)|^2.$$

Por lo tanto,

$$2L|(y-z)(t)|^2 \leq \frac{d}{dt}\Big(|(y-z)(t)|^2\Big) \leq 2U|(y-z)(t)|^2.$$

Finalmente, por la desigualdad de Gronwall diferencial, aplicada a la función $g(t) = |(y-z)(t)|^2$ obtenemos

$$|y_0 - z_0|^2 e^{2L(t-a)} \leq |(y-z)(t)|^2 \leq |y_0 - z_0|^2 e^{2U(t-a)},$$

que inmediatamente implica la afirmación del teorema. □

Ejemplo 8.13. Consideremos el PVI siguiente

$$\begin{cases} y' = -2y + e^{-t}, \\ y(0) = y_0. \end{cases}$$

La solución está dada por

$$y(t) = e^{-t} + (y_0 - 1)e^{-2t}, \qquad t \geq 0.$$

La diferencia entre las soluciones y, z con dato inicial y_0, z_0 es

$$y(t) - z(t) = (y_0 - z_0)e^{-2t}, \qquad t \geq 0,$$

y se *acercan* exponencialmente a medida que t crece. En este caso $L = U = \dfrac{\partial f}{\partial y} = -2$.

Ejemplo 8.14. Consideremos el siguiente PVI:

$$\begin{cases} y' = 2y - 3e^{-t}, \\ y(0) = y_0. \end{cases}$$

Este problema tiene solución

$$y(t) = e^{-t} + (y_0 - 1)e^{2t}, \qquad t \geq 0.$$

En particular, la solución para $y_0 = 1$ es $y(t) = e^{-t}$, que *luce estable*. Sin embargo, la diferencia entre dos soluciones con dato inicial y_0, z_0 es

$$y(t) - z(t) = (y_0 - z_0)e^{2t}, \qquad t \geq 0.$$

Es decir que las soluciones *se alejan* exponencialmente a medida que t crece. En este caso $L = U = 2$.

8.2 Métodos numéricos de un paso

Los métodos numéricos para ecuaciones diferenciales ordinarias brindan una manera de calcular valores *aproximados* de la solución exacta $y(t)$ en un conjunto *discreto* de puntos del intervalo $[a, b]$ donde interesa calcular la solución.

En general se obtiene una sucesión $a = t_0 < t_1 < t_2 < \cdots < t_N = b$ de instantes de tiempo y valores (vectores) $Y_0, Y_1, \ldots, Y_N$ que sean aproximaciones de $y_0, y(t_1), \ldots, y(t_N)$.

8.2.1 Introducción. Método de Euler

Si interpretamos geométricamente un PVI vemos que resolver el problema consiste en hallar la curva del plano que pasa por (t_0, y_0) y que en cada punto (t, y) de la curva, la tangente tiene pendiente $f(t, y)$.

A partir de esta interpretación surge la siguiente idea.

> A partir del punto (t_0, Y_0) *avanzar* por un pequeño paso de tiempo con la pendiente que debe tener la curva en (t_0, Y_0), es decir, con pendiente $f(t_0, Y_0)$, hasta un punto (t_1, Y_1).

Más precisamente:

$$\frac{Y_1 - Y_0}{t_1 - t_0} = f(t_0, Y_0) \quad \Longrightarrow \quad Y_1 = Y_0 + (t_1 - t_0) f(t_0, Y_0).$$

Es decir, una vez decidido el paso de tiempo $\Delta t_1 = t_1 - t_0$, Y_1 se calcula a partir de la fórmula $Y_1 = Y_0 + \Delta t_1 f(t_0, Y_0)$.

Si repetimos este procedimiento a partir de (t_1, Y_1) obtenemos el siguiente método, llamado *Método de Euler*:

$$\begin{aligned} Y_0 &= y_0 \\ Y_1 &= Y_0 + \Delta t_1 f(t_0, Y_0) \\ Y_2 &= Y_1 + \Delta t_2 f(t_1, Y_1) \\ Y_3 &= Y_2 + \Delta t_3 f(t_2, Y_2) \\ &\vdots \end{aligned}$$

En MATLAB/OCTAVE podría programarse de la siguiente manera, para $\Delta t = h = (b - a)/N$ constante:

```
function [t,Y] = euler(f, a, b, Y0, N)
% function [t,Y] = euler(f, a, b, Y0, N)
% Resuelve la ecuacion y' = f(t,y)
% por el metodo de Euler, en el intervalo [a,b]
% con condicion inicial y(a) = Y0.
% Se utiliza delta t = (b-a) / N.
% Es decir, N es el numero de pasos del metodo.
% f(t,Y) es una funcion de dos argumentos,
%   t: escalar
```

```
%   Y: vector columna del mismo tamano que Y0
%
% Salida:
% t: vector columna de instantes de tiempo en que se calcula Y
% Y: matriz donde la fila i es la aproximacion de y(t(i))

h = (b-a)/N;
t = linspace(a,b,N+1)';
Y = zeros(N+1,length(Y0));
Y(1,:) = Y0;
for i = 1:N
  Y(i+1,:) = Y(i,:) + h * f(t(i), Y(i,:)')';
end
```

Análisis del error

El método de Euler, como otros métodos numéricos, produce una sucesión $\{(t_n, Y_n)\}_{n=0}^N$, con $Y_n \approx y_n := y(t_n)$. Queremos estudiar el error global $e_n := |Y_n - y(t_n)|$ y en particular estamos interesados en

$$\max_{1\leq n\leq N} e_n = \max_{a\leq t_n\leq b} |Y_n - y(t_n)|.$$

Para realizar un primer análisis observamos que en general $Y_1 \neq y(t_1)$ y que en el primer paso ya cometemos algún error. En el segundo paso, comenzamos a partir de (t_1, Y_1) que no se encuentra en la trayectoria de la solución buscada sino en otra, y a partir de ahí, el error se *propagará* y a la vez se combinará con los errores de los pasos siguientes. Para ver el efecto de todos los errores *locales* sobre el error global hace falta ser más precisos.

Supongamos que el método produjo una sucesión $\{(t_n, Y_n)\}_{n=0}^N$, con $Y_n \approx y(t_n)$. Definimos $y_n(t)$ como la solución (exacta) del siguiente PVI

$$(\text{PVI})_n \begin{cases} y_n' = f(t, y_n), & t_n \leq t \leq b, \\ y_n(t_n) = Y_n. \end{cases}$$

Es decir, y_n es la solución de la EDO cuyo gráfico pasa por (t_n, Y_n). Entonces, $\varepsilon_n := y_n(t_{n+1}) - Y_{n+1}$ es el error *local* que produjo el método en el paso n. Es decir, ε_n mide cuánto nos alejamos en el paso n de la solución que pasa por (t_n, Y_n).

En la Figura 8.1 se ilustra la situación: cada paso del método nos deja sobre una trayectoria *nueva* de la misma ecuación, y el error local ε_n es el salto vertical que se produce en t_{n+1} entre la trayectoria sobre la que veníamos y el valor calculado.

Para fijar ideas, consideremos el caso escalar en que $\dfrac{\partial f}{\partial y} \leq 0$, es decir, vale (8.3) con $U = 0$. Entonces, por el Teorema 8.11 resulta que las soluciones y_n no se alejan entre sí, más precisamente, si $t \geq t_{j+1}$,

$$|y_j(t) - y_{j+1}(t)| \leq |y_j(t_{j+1}) - y_{j+1}(t_{j+1})| = |y_j(t_{j+1}) - Y_{j+1}| = \varepsilon_j.$$

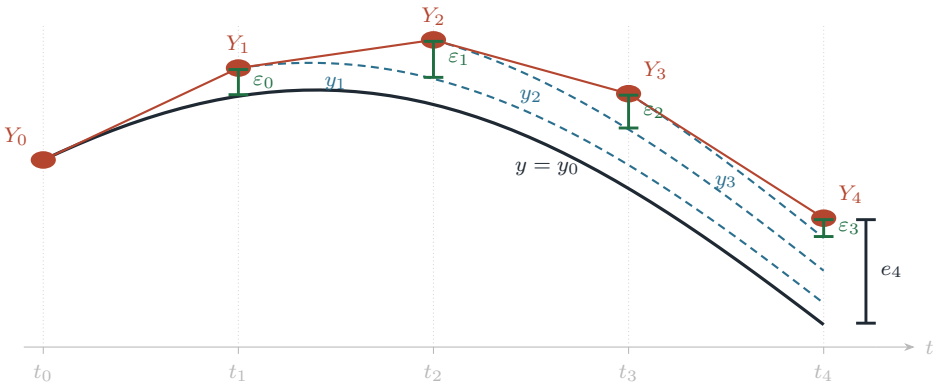


Figura 8.1 El abanico de soluciones y_n. La curva gruesa es la solución $y = y_0$ del (PVI) original; cada curva punteada es la solución exacta que pasa por el punto calculado (t_n, Y_n). El error local ε_n es el salto en t_{n+1}, y el error global e_4 es la distancia final a y_0. El dibujo corresponde a un caso con $\dfrac{\partial f}{\partial y} \leq 0$: las trayectorias se juntan y por eso $e_4 = 0{,}469$ resulta *menor* que la suma $\varepsilon_0 + \varepsilon_1 + \varepsilon_2 + \varepsilon_3 = 0{,}540$.

Por lo tanto

$$\begin{aligned} e_n &= |Y_n - y(t_n)| = |Y_n - y_0(t_n)| \\ &\leq |Y_n - y_{n-1}(t_n)| + |y_{n-1}(t_n) - y_{n-2}(t_n)| + \cdots + |y_1(t_n) - y_0(t_n)| \\ &\leq \varepsilon_{n-1} + \varepsilon_{n-2} + \cdots + \varepsilon_0. \end{aligned}$$

Por lo tanto, el máximo error global puede acotarse por

$$\max_{1\leq n\leq N} e_n \leq \sum_{n=0}^{N-1} \varepsilon_n \leq N \max_{0\leq n\leq N-1} \varepsilon_n. \tag{8.4}$$

Observación 8.15. Si suponemos[1] $\dfrac{\partial f}{\partial y} \leq U$, con $U \in \mathbb{R}$, de manera análoga obtenemos

$$\max_{1\leq n\leq N} e_n \leq e^{U_+(b-a)} \sum_{n=0}^{N-1} \varepsilon_n \leq e^{U_+(b-a)} N \max_{0\leq n\leq N-1} \varepsilon_n,$$

donde $U_+ = \max\{U, 0\} = \begin{cases} U, & \text{si } U \geq 0, \\ 0, & \text{si } U < 0. \end{cases}$

Hasta aquí, el análisis que hemos hecho es independiente del método, si es Euler o algún otro. Veamos cómo se puede acotar ε_n para el método de Euler.

Una herramienta muy utilizada para estimar y acotar el error en los métodos numéricos es el Teorema de Taylor, que enunciamos a continuación:

[1] De ahora en adelante, cuando escribamos $A \leq B$ con A una matriz de $d \times d$ o un escalar y B una matriz de $d \times d$ o un escalar, entenderemos que $Ax \cdot x \leq Bx \cdot x$, para todo $x \in \mathbb{R}^d$.

Teorema 8.16 (Teorema de Taylor)**.** *Sea $f \in C^{n+1}(I)$, donde I es un intervalo que contiene a t_0. Entonces, para cada $t \in I$ existe ξ_t entre t_0 y t tal que*

$$f(t) = f(t_0)+(t-t_0)f'(t_0)+\frac{(t-t_0)^2}{2!}f''(t_0)+\cdots+\frac{(t-t_0)^n}{n!}f^{(n)}(t_0)+\frac{(t-t_0)^{n+1}}{(n+1)!}f^{(n+1)}(\xi_t).$$

Usando el teorema de Taylor y considerando que $h = (b-a)/N$ y que $t_j = t_0 + jh$, $j = 0, 1, \ldots, N$, tenemos que

$$y_n(t_{n+1}) = y_n(t_n) + hy_n'(t_n) + \frac{h^2}{2}y_n''(\xi_n) = \underbrace{Y_n + hf(t_n, Y_n)}_{Y_{n+1}} + \frac{h^2}{2}y_n''(\xi_n)$$

para algún ξ_n, con $t_n < \xi_n < t_{n+1}$. Por lo tanto,

$$\varepsilon_n = |y_n(t_{n+1}) - Y_{n+1}| = |y_n(t_{n+1}) - [Y_n + hf(t_n, Y_n)]| = \frac{h^2}{2}|y_n''(\xi_n)|$$

y si existe $M > 0$ tal que $\max_{a\le t\le b}|y_n''(t)| \le M$, $n = 0, 1, \ldots, N-1$, entonces

$$\varepsilon_n \le \frac{Mh^2}{2}, \quad n = 0, 1, \ldots, N-1.$$

Finalmente, acotamos el error global usando (8.4):

$$\max_{0\le n\le N}|Y_n - y(t_n)| \le N \max_{0\le n\le N-1}\varepsilon_n \le N\frac{Mh^2}{2} = \underbrace{Nh}_{b-a}\frac{Mh}{2} = \frac{M(b-a)}{2}h.$$

Concluimos entonces que si todas las soluciones de la EDO tienen derivada segunda acotada uniformemente por M, el método de Euler produce una solución con máximo error acotado por $\dfrac{M(b-a)}{2}h = \text{Const.}\times h$. Se dice que el método de Euler es de orden uno (la potencia de h). La demostración que hemos visto es muy simple, y analizando el caso $\dfrac{\partial f}{\partial y} \le 0$, permite entender la idea general que si un método produce en un paso un error de orden h^{k+1} entonces el error global será de orden h^k. Lo negativo de la demostración vista es que requiere que *todas* las trayectorias tengan derivada segunda acotada, en la sección siguiente veremos que se puede mejorar la demostración requiriendo que solo la solución exacta $y = y_0$ tenga derivada segunda acotada. Por otro lado, vale la pena notar que como $y' = f(t, y)$,

$$y''(t) = f_t(t, y(t)) + f_y(t, y(t))y'(t) = f_t(t, y(t)) + f_y(t, y(t))f(t, y(t)),$$

por lo que la hipótesis se puede verificar mirando la función $f_t + f_y f$ sin conocer las soluciones exactas.

8.2.2 Análisis para métodos de un paso

Consideremos el método de un paso general

$$Y_n = Y_{n-1} + h\varphi(t_{n-1}, Y_{n-1}, h),$$

donde φ representa la fórmula que se utiliza, y que involucra a la función f. Para el método de Euler, $\varphi(t, Y, h) = f(t, Y)$.

El *error local de truncamiento* de este método se define como τ_n que cumple

$$y(t_n) = y(t_{n-1}) + h\varphi(t_{n-1}, y(t_{n-1}), h) + h\tau_n,$$

con y la solución de (PVI), es decir,

$$h\tau_n = y(t_n) - [y(t_{n-1}) + h\varphi(t_{n-1}, y(t_{n-1}), h)].$$

En palabras, $h\tau_n$ mide el error que cometería el método al realizar un paso, a partir de $(t_{n-1}, y(t_{n-1}))$, donde y es la solución del PVI original.

Con el Teorema de Taylor estimamos τ_n para el método de Euler,

$$h\tau_n = y(t_n) - [y(t_{n-1}) + hf(t_{n-1}, y(t_{n-1}))] = y(t_n) - [y(t_{n-1}) + hy'(t_{n-1})] = \frac{h^2}{2}y''(\xi_n),$$

y por lo tanto $\tau_n = \frac{y''(\xi_n)}{2}h$.

El teorema general para el análisis del error es el siguiente:

Teorema 8.17. *Consideremos el método de un paso*

$$Y_n = Y_{n-1} + h\varphi(t_{n-1}, Y_{n-1}, h), \quad n = 1, 2, \ldots, N,$$

con $h = (b-a)/N$. Supongamos que φ es Lipschitz continua de la segunda variable, para h suficientemente pequeño. Más precisamente, supongamos que existe $h_0 > 0$ tal que

$$|\varphi(t, y, h) - \varphi(t, z, h)| \leq K|y - z|, \quad y, z \in \mathbb{R}^d,\ t \in [a, b],\ h \leq h_0.$$

Entonces, si $h \leq h_0$,

$$e_n = |Y_n - y(t_n)| \leq e^{K(t_n - t_0)}|Y_0 - y_0| + \tilde{\tau}_n \frac{e^{K(t_n - t_0)} - 1}{K},$$

donde $\tilde{\tau}_n = \max_{1 \leq i \leq n} |\tau_i|$.

Demostración. Consideremos $1 \leq n \leq N$ fijo, y $0 \leq i \leq n$, entonces

$$\begin{aligned} Y_i &= Y_{i-1} + h\varphi(t_{i-1}, Y_{i-1}, h), \\ y(t_i) &= y(t_{i-1}) + h\varphi(t_{i-1}, y(t_{i-1}), h) + h\tau_i. \end{aligned}$$

Entonces, para $e_i := |Y_i - y(t_i)|$,

$$\begin{aligned} e_i &\leq e_{i-1} + h|\varphi(t_{i-1}, Y_{i-1}, h) - \varphi(t_{i-1}, y(t_{i-1}), h)| + h|\tau_i| \\ &\leq e_{i-1} + hKe_{i-1} + h|\tau_i| = \underbrace{(1 + hK)}_{A_h} e_{i-1} + h|\tau_i| \\ &\leq A_h e_{i-1} + h \underbrace{\max_{1 \leq j \leq n} |\tau_j|}_{\tilde{\tau}_n} = A_h e_{i-1} + h\tilde{\tau}_n. \end{aligned}$$

Por lo tanto

$$\begin{aligned}
e_1 &\le A_h e_0 + h\tilde{\tau}_n,\\
e_2 &\le A_h e_1 + h\tilde{\tau}_n \le A_h^2 e_0 + hA_h\tilde{\tau}_n + h\tilde{\tau}_n = A_h^2 e_0 + h(1+A_h)\tilde{\tau}_n,\\
e_3 &\le A_h e_2 + h\tilde{\tau}_n \le A_h^3 e_0 + A_h h(1+A_h)\tilde{\tau}_n + h\tilde{\tau}_n = A_h^3 e_0 + h(1+A_h+A_h^2)\tilde{\tau}_n,\\
&\vdots\\
e_n &\le A_h^n e_0 + h(1+A_h+\cdots+A_h^{n-1})\tilde{\tau}_n.
\end{aligned}$$

Ahora bien, $A_h^n = (1+hK)^n \le e^{nhK}$, pues $0 < 1+x \le e^x$ para $x \ge 0$. Entonces

$$1 + A_h + \cdots + A_h^{n-1} = \frac{A_h^n - 1}{A_h - 1} = \frac{(1+hK)^n - 1}{1+hK-1} \le \frac{e^{nhK}-1}{hK},$$

y por lo tanto

$$e_n \le e^{nhK} e_0 + \frac{e^{nhK}-1}{K}\tilde{\tau}_n.$$

Como $nh = t_n - t_0$ se sigue la afirmación del teorema. □

Observación 8.18. Si $\tilde{\tau}_N \to 0$ cuando $h \to 0$ entonces

$$\max_{1\le n\le N} |Y_n - y(t_n)| \to 0, \quad \text{cuando } h \to 0,$$

si también $e_0 \to 0$ cuando $h \to 0$. Si bien todos los métodos numéricos proponen $Y_0 = y_0$ suele ocurrir en la práctica que y_0 no se conoce exactamente, sino con algún error, por ejemplo, un error de medición, y es por eso que se hace necesario considerar este error al realizar el análisis del error del método.

Definición 8.19. Si $\tilde{\tau}_h := \tilde{\tau}_N = O(h^p)$—bajo ciertas hipótesis de regularidad de la solución y de (PVI)—entonces $\max_{1\le n\le N} e_n = O(h^p)$ (si $y_0 = Y_0$) y por eso se dice que el método *es de orden p*.

Observación 8.20. El método de Euler es de orden uno, si la solución exacta tiene y'' acotada. En efecto, $h\tilde{\tau}_h \le \max_{a\le t\le b} |y''(t)|\frac{h^2}{2}$ y por lo tanto $\tilde{\tau}_h = O(h)$.

8.2.3 Métodos de Runge-Kutta

Hemos visto el método de Euler, que resulta de orden uno, y en cada paso realiza una evaluación de la función f. Nos preguntamos: ¿Se podrá definir un método que utilizando dos evaluaciones de f en cada paso resulte de orden 2? La respuesta es positiva, veamos cómo puede lograrse.

Proponemos un método como el siguiente:

$$\begin{cases}
k_1 = hf(t_n, Y_n)\\
k_2 = hf(t_n + \alpha h, Y_n + \alpha k_1)\\
Y_{n+1} = Y_n + \underbrace{ak_1 + bk_2}_{h\varphi(t_n, Y_n, h)}
\end{cases}$$

¿Se pueden elegir α, a, b para que $\tilde{\tau}_h = O(h^2)$?

Recordemos que $h\tau_{n+1} = y(t_{n+1}) - (y(t_n) + h\varphi(t_n, y(t_n), h))$. Denotamos entonces con $\tilde{k}_i$ a las correspondientes a y en lugar de Y, más precisamente

$$\begin{aligned}
\tilde{k}_1 &= hf(t_n, y(t_n)) =: hf^n \\
\tilde{k}_2 &= hf(t_n + \alpha h, y(t_n) + \alpha\tilde{k}_1) \\
&= h\left[f(t_n, y(t_n)) + \alpha h f_t(t_n, y(t_n)) + \alpha\tilde{k}_1 f_y(t_n, y(t_n)) + O\big(\alpha^2(h + \tilde{k}_1)^2\big)\right] \\
&= h\left[f^n + \alpha h f_t^n + \alpha\tilde{k}_1 f_y^n + O\big(\alpha^2(h + \tilde{k}_1)^2\big)\right] \\
&= h\left[f^n + \alpha h f_t^n + \alpha h f^n f_y^n + O\big(\alpha^2(h + \tilde{k}_1)^2\big)\right].
\end{aligned}$$

Aquí hemos utilizado el teorema de Taylor, y $O\big(\alpha^2(h + \tilde{k}_1)^2\big) = O(h^2)$ depende de derivadas segundas de f (y/o terceras de y). Luego

$$\begin{aligned}
h\varphi(t_n, y(t_n), h) &= a\tilde{k}_1 + b\tilde{k}_2 \\
&= h\big[af^n + bf^n + b\alpha h f_t^n + b\alpha h f^n f_y^n + O(h^2)\big] \\
&= (a+b)hf^n + b\alpha h^2\Big[f_t^n + f^n f_y^n\Big] + O(h^3).
\end{aligned}$$

Por otro lado, aplicando Taylor a la solución exacta y obtenemos

$$\begin{aligned}
y(t_{n+1}) - y(t_n) &= hy'(t_n) + \frac{h^2}{2}y''(t_n) + \frac{h^3}{6}y'''(\xi_n) \\
&= hf^n + \frac{h^2}{2}\Big[f_t^n + f^n f_y^n\Big] + O(h^3).
\end{aligned}$$

Luego

$$\begin{aligned}
h\tau_{n+1} &= (y(t_{n+1}) - y(t_n)) - h\varphi(t_n, y(t_n), h) \\
&= h\Big[(a+b) - 1\Big]f^n + h^2\Big[b\alpha - \frac{1}{2}\Big]\Big[f_t^n + f^n f_y^n\Big] + O(h^3).
\end{aligned}$$

Por lo tanto, resulta que $\tau_n = O(h^2)$ si

$$a + b = 1 \qquad \text{y} \qquad \alpha b = \frac{1}{2}.$$

Este sistema de ecuaciones no-lineales tiene infinitas soluciones, y da bastante libertad de elección. La elección *natural* o más *simétrica* es $a = b = 1/2$, $\alpha = 1$ y da el clásico método de Runge-Kutta de orden dos:

$$(RK2)\begin{cases} k_1 = hf(t_n, Y_n) \\ k_2 = hf(t_n + h, Y_n + k_1) \\ Y_{n+1} = Y_n + \dfrac{k_1 + k_2}{2} \end{cases}$$

Cabe aclarar que el método convergerá con orden dos cuando las derivadas de hasta orden tres de y (y dos de f) estén acotadas.

De manera análoga, pero con cuentas más engorrosas puede deducirse el método de Runge-Kutta de orden cuatro:

$$(RK4)\begin{cases} k_1 = hf(t_n, Y_n) \\ k_2 = hf(t_n + \dfrac{h}{2}, Y_n + \dfrac{k_1}{2}) \\ k_3 = hf(t_n + \dfrac{h}{2}, Y_n + \dfrac{k_2}{2}) \\ k_4 = hf(t_n + h, Y_n + k_3) \\ Y_{n+1} = Y_n + \dfrac{k_1 + 2k_2 + 2k_3 + k_4}{6} \end{cases}$$

Cabe aclarar aquí que el método de Runge-Kutta de orden cuatro convergerá con ese orden cuando las derivadas de hasta orden cinco de y (y cuatro de f) estén acotadas.

8.2.4 Métodos de Runge-Kutta-Fehlberg (RKF)

Son métodos de paso *adaptativo*, basados en los de Runge-Kutta. El error local de truncamiento se estima en términos de la diferencia entre una solución calculada Y_{n+1} y otra solución $\hat{Y}_{n+1}$ asociada a un método de orden superior. El objetivo es lograr un error global menor que una tolerancia dada, a un costo bajo.

El método RKF45 se diseña de la siguiente manera (a grandes rasgos). Primero se buscan dos métodos de Runge-Kutta, uno de orden 4 y otro de orden 5, pero de manera que los cálculos realizados para uno de ellos sirvan para el otro. Aquí se aprovecha la libertad de elección de los coeficientes k_i en la definición del método.

Sin demostrar todos los detalles, con el objetivo de comprender cómo se define el método, decimos lo siguiente:

Es posible elegir α_j, β_{ji}, $i = 1, 2, \ldots, j-1$, $j = 2, 3, \ldots, 6$, γ_j, $j = 1, 2, \ldots, 5$, $\hat{\gamma}_j$, $j = 1, 2, \ldots, 6$ de manera que se cumple lo siguiente[2]. Si definimos

$$\begin{aligned} k_1 &= hf(t_n, Y_n), \\ k_j &= hf(t_n + \alpha_j h, Y_n + \sum_{i=1}^{j-1} \beta_{ji} k_i), \quad j = 2, 3, \ldots, 6, \end{aligned}$$

con $h = h_{n+1} = t_{n+1} - t_n$, y

$$\begin{aligned} Y_{n+1} &= Y_n + \sum_{j=1}^{5} \gamma_j k_j, \\ \hat{Y}_{n+1} &= Y_n + \sum_{j=1}^{6} \hat{\gamma}_j k_j, \end{aligned}$$

entonces Y_{n+1} corresponde a un método de Runge-Kutta de orden 4 y $\hat{Y}_{n+1}$ a uno de orden 5. Es importante destacar que si bien $\gamma_j \neq \hat{\gamma}_j$, los coeficientes α_j y β_{ji} son los mismos para ambos métodos. Por lo tanto el costo, medido en número de evaluaciones

[2]Los valores pueden encontrarse en las tablas 6.25 y 6.26 de la página 430 de [A]

de la función $f(t,y)$, es el mismo tanto para calcular $\hat{Y}_{n+1}$ como para calcular Y_{n+1} y $\hat{Y}_{n+1}$ simultáneamente.

En la notación de la Sección 8.2.1 resulta que

$$\varepsilon_n := |Y_{n+1} - y_n(t_{n+1})| = O(h^5),$$
$$\hat{\varepsilon}_n := |\hat{Y}_{n+1} - y_n(t_{n+1})| = O(h^6),$$

donde

$$\begin{cases} y_n' = f(t, y_n), \\ y_n(t_n) = Y_n. \end{cases}$$

Luego

$$\varepsilon_n = |Y_{n+1} - y_n(t_{n+1})| \leq \underbrace{|Y_{n+1} - \hat{Y}_{n+1}|}_{O(h^5)} + \underbrace{|\hat{Y}_{n+1} - y_n(t_{n+1})|}_{O(h^6)} \approx |\hat{Y}_{n+1} - Y_{n+1}| = O(h^5).$$

La idea del método adaptativo es la siguiente: Fijar los parámetros $0 < A << 1$, $0 < P < 1 < Q$, y una tolerancia `tol`; en cada paso hacer lo siguiente:

(1) Dado (t_n, Y_n) y h_{n+1}, calcular Y_{n+1} e $\hat{Y}_{n+1}$

(2) Calcular $T_n = |Y_{n+1} - \hat{Y}_{n+1}|$

(3) Si $T_n < h_{n+1}\texttt{tol}/(b-a)$

  Aceptar Y_{n+1} y definir $t_{n+1} = t_n + h_{n+1}$.

  Si $T_n < Ah_n\texttt{tol}/(b-a)$ % (*) si es mucho más pequeño que lo deseado

    $h_{n+2} = Qh_{n+1}$ % agrandar un poco h para la próxima

  Fin Si

 Si no

  % no aceptamos Y_{n+1}

  $h_{n+1} = Ph_{n+1}$ % (**) achicar h y re-calcular

  Ir a (1)

 Fin Si

(4) $n = n + 1$;

Observación 8.21.

- Cuando el algoritmo termina, digamos, en N pasos, resulta que

$$\sum_{n=0}^{N} \varepsilon_n \approx \sum_{n=0}^{N} T_n \leq \sum_{n=0}^{N} \frac{h_n \texttt{tol}}{b-a} = \texttt{tol},$$

y por lo tanto, en virtud del Comentario 8.15,

$$\max_{0 \leq n \leq N+1} |y(t_n) - Y_n| \leq e^{U_+(b-a)}\,\texttt{tol},$$

si $\dfrac{\partial f}{\partial y} \leq U$.

- El paso marcado con (*) sirve para *agrandar* el paso de discretización h_n cuando el error es mucho más pequeño que lo deseado. Esto permite ahorrar operaciones.
- El paso marcado con (**) permite *reducir* el paso de discretización h_n cuando el error es más grande que lo permitido.

Observación 8.22. La idea de este método RKF45 es la base de la función `ode45` de MATLAB/OCTAVE, que tiene además otros algoritmos adaptativos para EDOs: `ode23`, `ode15s`, `ode23s`. Los que terminan en `s` están diseñados para problemas *stiff*, que usan métodos implícitos y son especialmente aptos para problemas donde $\dfrac{\partial f}{\partial y}$ tiene autovalores muy negativos.

8.3 Estabilidad de métodos numéricos

En general, un método numérico se dice *estable* cuando los errores cometidos en pasos iniciales o intermedios no *se propagan* o crecen mucho hacia los pasos siguientes. Las perturbaciones pueden deberse, por ejemplo, a errores de redondeo, o a cálculos aproximados de algunas cantidades. En el caso de métodos para PVI, es usual que el cálculo de f tenga errores dado que puede provenir de la resolución de algún otro problema no-lineal.

Cuando consideramos un método de un paso genérico, tenemos los siguientes cálculos:

$$\begin{aligned} \text{valor calculado} \qquad & \tilde{Y}_{n+1} = \tilde{Y}_n + h\tilde{\varphi}(t_n, \tilde{Y}_n, h), \\ \text{valor } \textit{ideal} \qquad & Y_{n+1} = \tilde{Y}_n + h\varphi(t_n, \tilde{Y}_n, h). \end{aligned}$$

El error *local* es ahora

$$\tilde{\varepsilon}_n = |\tilde{Y}_{n+1} - y_n(t_{n+1})| \leq \underbrace{|\tilde{Y}_{n+1} - Y_{n+1}|}_{\delta_n} + \underbrace{|Y_{n+1} - y_n(t_{n+1})|}_{\varepsilon_n}.$$

Análogamente a lo hecho en la Sección 8.2.1 obtenemos

$$\max_{1\leq n\leq N} |\tilde{Y}_n - y(t_n)| \leq e^{U_+(b-a)} \sum_{n=0}^{N-1} \big(\varepsilon_n + \delta_n\big),$$

donde $U \in \mathbb{R}$ es alguna cota superior para $\dfrac{\partial f}{\partial y}$, es decir, $\dfrac{\partial f}{\partial y} \leq U$, y $U_+ = \max\{U, 0\}$. Por lo tanto, el efecto de los errores cometidos en todos los pasos se propaga acorde a la estabilidad de la ecuación diferencial, independientemente del método que se utilice.

El concepto de estabilidad más estudiado en métodos numéricos para ecuaciones diferenciales tiene que ver con el comportamiento del método al resolver el siguiente PVI para $\lambda \in \mathbb{C}$:

$$\begin{cases} y' = \lambda y, & t > 0, \\ y(0) = 1, \end{cases}$$

cuya solución exacta para $\lambda = \lambda_R + i\lambda_I$ es

$$y(t) = e^{\lambda t} = e^{\lambda_R t}\Big(\cos \lambda_I t + i \sin \lambda_I t\Big).$$

La misma se mantiene acotada para todo $t \geq 0$ si y solo si $\lambda_R = \operatorname{Re} \lambda \leq 0$.

Definición 8.23. La región de estabilidad de un método numérico para EDO se define como el conjunto de $h\lambda \in \mathbb{C}$ tal que el método aplicado a

$$\begin{cases} y' = \lambda y, & t > 0, \\ y(0) = 1, \end{cases}$$

produce una sucesión $\{Y_n\}_{n=1}^{\infty}$ acotada.

La motivación principal para esta definición es que si un método numérico no produce soluciones acotadas para $\lambda \in \mathbb{C}$ con $\lambda_R \leq 0$, entonces no podemos esperar que funcione bien en problemas más complejos.

Consideramos valores de λ complejos porque están relacionados con los autovalores en el caso en que queramos resolver *sistemas* de ecuaciones diferenciales ordinarias. En el caso de sistemas, las soluciones exactas de los PVI son acotadas cuando todos los autovalores tengan parte real negativa o cero.

8.3.1 Región de estabilidad para los métodos de Runge-Kutta

Región de estabilidad para el método de Euler.

Notemos que el método de Euler aplicado al problema modelo produce la sucesión

$$\begin{aligned} Y_0 &= 1, \\ Y_{n+1} &= Y_n + h\lambda Y_n = (1 + h\lambda)Y_n = (1 + h\lambda)^{n+1}, \end{aligned}$$

por lo que la sucesión $\{Y_n\}_{n=1}^{\infty}$ será acotada si y solo si $|1 + h\lambda| \leq 1$. Por lo tanto, la región de estabilidad para el método de Euler es

$$R_{\text{Euler}} = \{z \in \mathbb{C} : |1 + z| < 1\} = B(-1, 1).$$

Observación 8.24.

- Se consideran números complejos, pues el comportamiento para problemas vectoriales está relacionado con los autovalores de $\dfrac{\partial f}{\partial y}$, que pueden ser complejos.
- Si $\operatorname{Re}\lambda > 0$ no hay ningún valor de $h > 0$ tal que $h\lambda \in R$, pero la solución exacta tampoco es acotada.
- Si $\lambda < 0$, h debe satisfacer $h \leq -2/\lambda$, así que debe ser muy pequeño cuando $|\lambda|$ es grande.
- Cuando se quieren diseñar métodos más estables, se entiende que se desean métodos con una mayor región de estabilidad.
- Cuando un problema $y' = f(t, y)$ tiene $\dfrac{\partial f}{\partial y}$ con autovalores de parte real *muy negativa* (que exige h muy pequeño) se dice que la EDO es *stiff* (rígida). Esta situación es muy común en problemas que involucran reacciones químicas.

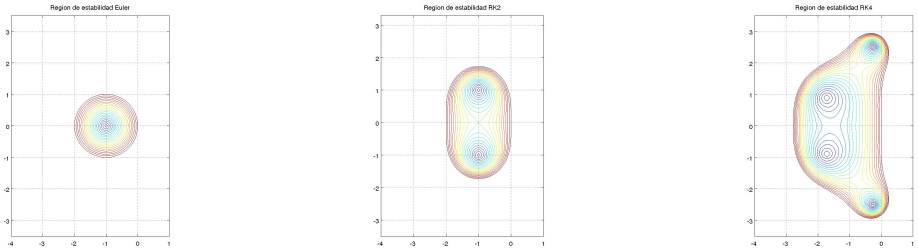


Figura 8.2 Regiones de estabilidad para métodos de Runge-Kutta. Euler o RK1 (izquierda), RK2 (medio), RK4 (derecha).

Región de estabilidad para RK2.

Dado Y_n, el método RK2 aplicado al problema modelo produce el siguiente Y_{n+1}:

$$\begin{aligned} k_1 &= h\lambda Y_n, \\ k_2 &= h\lambda(Y_n + k_1) = h\lambda(Y_n + h\lambda Y_n) = [h\lambda + (h\lambda)^2]Y_n, \\ Y_{n+1} &= Y_n + \frac{k_1 + k_2}{2} = Y_n \left(1 + \frac{h\lambda}{2} + \frac{h\lambda}{2} + \frac{(h\lambda)^2}{2}\right) \\ &= Y_n \left(1 + h\lambda + \frac{(h\lambda)^2}{2}\right). \end{aligned}$$

Luego, $Y_n = \left(1 + h\lambda + \frac{(h\lambda)^2}{2}\right)^n$ y el método es estable si y solo si

$$h\lambda \in R_{\text{RK2}} := \{z \in \mathbb{C} : |1 + z + \frac{z^2}{2}| \leq 1\}.$$

La región R de estabilidad de RK2 puede verse en la Figura 8.2.

Región de estabilidad de RK4.

Análogamente a como se hizo para RK2 se puede ver que la región de estabilidad de RK4 es

$$R_{\text{RK4}} := \left\{ z \in \mathbb{C} : \left| 1 + z + \frac{z^2}{2} + \frac{z^3}{3!} + \frac{z^4}{4!} \right| \leq 1 \right\},$$

que se ilustra en la Figura 8.2.

Las regiones de estabilidad de los métodos explícitos de un paso vistos hasta el momento son bastante pequeñas. Regiones de estabilidad más grandes se obtienen al utilizar métodos implícitos.

8.3.2 Método Retro-Euler o Euler implícito

El método de Euler se puede obtener a partir de la fórmula de Taylor alrededor de t_n, en efecto

$$\begin{aligned} y(t_{n+1}) &= y(t_n) + hy'(t_n) + O(h^2) \\ y(t_{n+1}) &\approx y(t_n) + hf(t_n, y(t_n)) \\ Y_{n+1} &= Y_n + hf(t_n, Y_n) \end{aligned}$$

Si usamos la fórmula de Taylor alrededor de t_{n+1} obtenemos

$$\begin{aligned} y(t_n) &= y(t_{n+1}) - hy'(t_{n+1}) + O(h^2) \\ y(t_{n+1}) &= y(t_n) + hy'(t_{n+1}) + O(h^2) \\ y(t_{n+1}) &\approx y(t_n) + hf(t_{n+1}, y(t_{n+1})) \\ Y_{n+1} &= Y_n + hf(t_{n+1}, Y_{n+1}) \end{aligned}$$

El método de Euler implícito o Retro Euler se define entonces por la iteración

$$Y_{n+1} = Y_n + hf(t_{n+1}, Y_{n+1}),$$

Es decir, Y_{n+1} es la solución Y de la ecuación algebraica

$$Y = Y_n + hf(t_{n+1}, Y).$$

Este método implica resolver, en cada paso, una ecuación o sistema de ecuaciones que en general será no lineal. En cada paso se puede resolver con un método tipo Newton (por ejemplo). Este método tiene un costo adicional de resolver un sistema no lineal en cada paso de tiempo, pero permite tomar h mucho más grande que el método de Euler explícito, en especial cuando $\dfrac{\partial f}{\partial y} < 0$ y $\left|\dfrac{\partial f}{\partial y}\right|$ es grande (ecuaciones stiff). Veamos la región de estabilidad de Retro Euler (RE). Si aplicamos la definición $Y_{n+1} = Y_n + hf(t_{n+1}, Y_{n+1})$ al problema modelo $y' = \lambda y$ obtenemos que

$$Y_{n+1} = Y_n + h\lambda Y_{n+1} \qquad \Rightarrow \qquad Y_{n+1} = \frac{1}{1-h\lambda} Y_n = \Big(\frac{1}{1-h\lambda}\Big)^{n+1} Y_0.$$

Por lo tanto, el método resultará estable cuando $h\lambda$ pertenezca a la región de estabilidad

$$R_{\text{RE}} = \Big\{ z \in \mathbb{C} : \Big|\frac{1}{1-z}\Big| \leq 1 \Big\} = \{ z \in \mathbb{C} : |1-z| \geq 1 \} = B(1,1)^c,$$

que contiene a todo el semiplano complejo $\{z \in \mathbb{C} : \operatorname{Re} z \leq 0\}$. En este caso se dice que el método es *incondicionalmente estable*, pues h no debe cumplir ninguna *condición* para que el método sea estable, cuando $\operatorname{Re}\lambda \leq 0$.

8.4 Métodos multipaso

Los métodos multipaso utilizan el valor de Y_n y también algunos valores de Y_{n-j} para el cálculo de Y_{n+1}. Si bien los métodos de Runge-Kutta realizan varios cálculos o pasos para calcular el valor de Y_{n+1} a partir de Y_n, no se consideran multipaso.

8.4.1 Métodos multipaso de Adams

Los métodos multipaso de Adams constituyen *una familia de métodos multipaso*, que se construyen a partir de la idea que se presenta a continuación.

Consideremos el PVI

$$\begin{cases} y' = f(t,y), & \text{en } [a,b], \\ y(a) = y_0. \end{cases}$$

Los métodos multipaso de Adams parten de la siguiente igualdad, que se cumple para la solución del (PVI):

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} y'(t)\,dt = y(t_n) + \int_{t_n}^{t_{n+1}} f(t,y(t))\,dt, \quad n = 0,1,\ldots,N. \tag{8.5}$$

Consideremos, una partición uniforme de $[a,b]$, es decir, $h = (b-a)/N$ y $t_n = a + nh$, $n = 0,1,\ldots,N$.

Si ahora fijamos $k \in \mathbb{N}$ y tomamos $n \geq k$, podemos definir el polinomio $q_k \in \mathcal{P}_k$ que interpola a $f(t_{n-j}, y(t_{n-j}))$ para ciertos índices j entre -1 y k. Entonces, resultará que

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} f(t,y(t))\,dt \approx y(t_n) + \int_{t_n}^{t_{n+1}} q_k(t)\,dt. \tag{8.6}$$

Tenemos al menos dos opciones para elegir el polinomio q_k:

Métodos explicitos: Elegimos $q_k \in \mathcal{P}_k$ como el polinomio que interpola a $f(t,y(t))$ en $t = t_{n-j}$, $j = 0,1,\ldots,k$, como son $k+1$ puntos, q_k está unívocamente determinado. En este caso, resulta que la integral a la derecha de (8.6) es una fórmula que involucra h, y $f_{n-j} := f(t_{n-j}, y(t_{n-j}))$, para $j = 0,1,\ldots,k$, y que denotaremos con $F_k^{AB}(h, f_n, f_{n-1}, \ldots, f_{n-k})$. Más precisamente, tenemos

$$y(t_{n+1}) \approx y(t_n) + F_k^{AB}(h, f_n, f_{n-1}, \ldots, f_{n-k}).$$

En base a esta *igualdad aproximada* se define el método de *Adams-Bashforth* de orden $k+1$ como

$$Y_{n+1} = Y_n + F_k^{AB}(h, f(t_n,Y_n), f(t_{n-1},Y_{n-1}), \ldots, f(t_{n-k},Y_{n-k})), \tag{8.7}$$

para $n = k, k+1, \ldots, N-1$, que resulta un método *explícito*, pues Y_{n+1} está *despejado* a la izquierda de la igualdad. Los (primeros) valores Y_1, Y_2, …, Y_k deben calcularse por otro método. Más adelante veremos cómo elegirlos de manera adecuada para mantener la precisión del método.

Métodos implícitos: Elegimos $q_k \in \mathcal{P}_k$ como el polinomio que interpola a $f(t,y(t))$ para $t = t_{n-j}$, $j = -1,0,1,\ldots,k-1$ (nuevamente $k+1$ puntos). En este caso, resulta que la integral a la derecha de (8.6) es una fórmula que involucra h, f_{n-j}, $j = -1,0,\ldots,k-1$, y que denotaremos con $F_k^{AM}(h, f_{n+1}, f_n, f_{n-1}, \ldots, f_{n-k+1})$. Más precisamente, tenemos

$$y(t_{n+1}) \approx y(t_n) + F_k^{AM}(h, f_{n+1}, f_n, f_{n-1}, \ldots, f_{n-k+1}).$$

En base a esta *igualdad aproximada* se define el método de *Adams-Moulton* de orden $k+1$ como

$$Y_{n+1} = Y_n + F_k^{AM}(h, f(t_{n+1}, Y_{n+1}), f(t_n, Y_n), \ldots, f(t_{n-k+1}, Y_{n-k+1})) \tag{8.8}$$

para $n = k-1, k, \ldots, N-1$, que resulta un método *implícito*, pues Y_{n+1} es solución de la ecuación

$$Y = Y_n + F_k^{AM}(h, f(t_{n+1}, Y), f(t_n, Y_n), \ldots, f(t_{n-k+1}, Y_{n-k+1})).$$

Como antes, los primeros valores Y_1, Y_2, …, Y_{k-1} deben calcularse por otro método. Más adelante veremos cómo elegirlos de manera adecuada para mantener la precisión del método.

Ejemplos de métodos de Adams-Bashforth.

Si consideramos $k = 0$, q_0 es el polinomio de grado cero (función constante) que interpola $f(t_n, y(t_n))$ y resulta

$$F_0^{AB}(h, f_n) = \int_{t_n}^{t_{n+1}} q_0(t)\, dt = \int_{t_n}^{t_{n+1}} f(t_n, y(t_n))\, dt = hf(t_n, y(t_n)).$$

El método de Adams-Bashforth de orden *uno* es entonces

$$Y_{n+1} = Y_n + hf(t_n, Y_n),$$

y coincide con el método explícito de Euler.

Si consideramos $k = 1$, q_1 es el polinomio de grado uno (función lineal) que interpola $f(t, y(t))$ en $t = t_n, t_{n-1}$ y resulta, denotando $f_n = f(t_n, y(t_n))$,

$$\begin{aligned} F_1^{AB}(h, f_n, f_{n-1}) &= \int_{t_n}^{t_{n+1}} q_1(t)\, dt = \int_{t_n}^{t_{n+1}} f_n + (t - t_n)\frac{f_n - f_{n-1}}{t_n - t_{n-1}}\, dt \\ &= hf_n + \frac{h^2}{2}\frac{f_n - f_{n-1}}{h} = h\frac{3f_n - f_{n-1}}{2}. \end{aligned}$$

El método de Adams-Bashforth de orden *dos* es entonces

$$Y_{n+1} = Y_n + \frac{h}{2}\big[3f(t_n, Y_n) - f(t_{n-1}, Y_{n-1})\big].$$

Análogamente se obtiene el método de Adams-Bashforth de orden *tres* que resulta

$$Y_{n+1} = Y_n + \frac{h}{12}\Big[23f(t_n, Y_n) - 16f(t_{n-1}, Y_{n-1}) + 5f(t_{n-2}, Y_{n-2})\Big].$$

Ejemplos de Métodos de Adams-Moulton.

Si consideramos $k = 0$, q_0 es el polinomio de grado cero (función constante) que interpola $f(t_{n+1}, y(t_{n+1})) = f_{n+1}$ y resulta

$$F_0^{AM}(h, f_{n+1}) = \int_{t_n}^{t_{n+1}} q_0(t)\, dt = \int_{t_n}^{t_{n+1}} f_{n+1}\, dt = hf_{n+1} = hf(t_{n+1}, y(t_{n+1})).$$

El método de Adams-Moulton de orden *uno* es entonces

$$Y_{n+1} = Y_n + hf(t_{n+1}, Y_{n+1}),$$

y coincide con el método de Euler *implícito* o Retro-Euler.

Si consideramos $k = 1$, q_1 es el polinomio de grado uno (función lineal) que interpola $f(t, y(t))$ en $t = t_{n+1}, t_n$ y resulta

$$F_1^{AM}(h, f_{n+1}, f_n) = \int_{t_n}^{t_{n+1}} q_1(t)\, dt = h\frac{f_n + f_{n+1}}{2} = \frac{h}{2}\big[f_n + f_{n+1}\big].$$

El método de Adams-Moulton de orden *dos* es entonces

$$Y_{n+1} = Y_n + \frac{h}{2}\Big[f(t_n, Y_n) + f(t_{n+1}, Y_{n+1})\Big].$$

Este método se conoce también como *método del trapecio*, dado que coincide con el método que se obtiene reemplazando la integral de la derecha en (8.5) por la regla del trapecio.

Análogamente se obtiene el método de Adams-Moulton de orden *tres* que resulta

$$Y_{n+1} = Y_n + \frac{h}{12}\Big[5f(t_{n+1}, Y_{n+1}) + 8f(t_n, Y_n) - 1f(t_{n-1}, Y_{n-1})\Big].$$

8.4.2 Midpoint

Otro método multipaso, que no pertenece a la familia de los métodos de Adams es el método Midpoint, que surge de observar que

$$y(t_{n+1}) = y(t_{n-1}) + \int_{t_{n-1}}^{t_{n+1}} f(t, y(t))\, dt \approx y(t_{n-1}) + 2hf(t_n, y(t_n)).$$

El método resulta

$$Y_{n+1} = Y_{n-1} + 2hf(t_n, Y_n).$$

En la próxima sección haremos un análisis de error y estabilidad de métodos multipasos en general, sin importar cómo hayan sido obtenidos.

8.5 Análisis de métodos multipaso

Consideremos un método multipaso genérico como el que sigue:

$$Y_{n+1} = \sum_{j=0}^{p} a_j Y_{n-j} + h\sum_{j=-1}^{p} b_j f(t_{n-j}, Y_{n-j}), \tag{8.9}$$

para algún $p \in \mathbb{N}$ y algunos valores a_j, b_j. Diremos que este método es de $p+1$ pasos si $a_p \neq 0$ o $b_p \neq 0$.

Notemos que si $b_{-1} = 0$ el método resulta *explícito* mientras que si $b_{-1} \neq 0$ el método resulta *implícito*. Aquí estamos considerando dado un intervalo $[a, b]$ donde se quiere hallar la solución, y una partición uniforme, es decir, dado $N \in \mathbb{N}$, $h = (b-a)/N$, $t_n = a + nh$, $n = 0, 1, \ldots, N$.

Recordemos que estamos queriendo resolver un PVI para la ecuación $y' = f(t, y)$, y entonces

$$f(t_{n-j}, Y_{n-j}) \approx y'(t_{n-j}).$$

Definición 8.25 (Error de truncamiento)**.** El *error (local) de truncamiento* del método multipaso (8.9) se define, para $y \in C^1[a,b]$ y para $p \leq n \leq N$ como

$$T_n(y) = y(t_{n+1}) - \left[\sum_{j=0}^{p} a_j y(t_{n-j}) + h \sum_{j=-1}^{p} b_j y'(t_{n-j})\right].$$

Esta cantidad mide cuánto falla la fórmula al predecir el valor de $y(t_{n+1})$ usando algunos valores de $y(t_{n-j})$ e $y'(t_{n-j})$.

Definición 8.26 (Consistencia)**.** Se dice que el método multipaso (8.9) es *consistente* si para toda $y \in C^2[a,b]$ se cumple que

$$\tau_h(y) := \max_{p \leq n \leq N} \frac{|T_n(y)|}{h} \longrightarrow 0, \quad \text{cuando } h \to 0. \tag{8.10}$$

Esta condición de consistencia será *necesaria* para la convergencia del método multipaso, es decir, para que el máximo error $\max_{1 \leq n \leq N} |Y_n - y(t_n)|$ tienda a cero (ver Proposiciones 8.31–8.33 y Teorema 8.28 a continuación).

El orden de un método multipaso se define como sigue:

Definición 8.27 (Orden)**.** Se dice que el método multipaso (8.9) es *de orden* m para $m \in \mathbb{N}$, si para toda $y \in C^{m+1}[a,b]$ se cumple que

$$\tau_h(y) = O(h^m), \quad \text{cuando } h \to 0, \tag{8.11}$$

o, lo que es lo mismo, para cada $y \in C^{m+1}[a,b]$ existen $C \in \mathbb{R}$ y $h_0 > 0$ tales que

$$\frac{\tau_h(y)}{h^m} \leq C, \quad \text{para todo } 0 < h < h_0.$$

A continuación obtendremos acotaciones para $\tau_h(y)$, para los métodos de Adams. Lo haremos partiendo de la definición de los mismos, considerando que surgen de reemplazar el integrando en (8.7) por un polinomio que interpola $f(t, y(t))$ en ciertos puntos.

Orden de los métodos de Adams-Bashforth.

Consideremos el método de Adams-Bashforth de orden $p+1$, que luce

$$Y_{n+1} = Y_n + h \sum_{j=0}^{p} b_j f_{n-j}$$

Donde los números b_j, $j = 0, 1, \ldots, p$ se determinan de manera que

$$h \sum_{j=0}^{p} b_j f_{n-j} = \int_{t_n}^{t_{n+1}} Q(t)\, dt,$$

para $Q \in \mathcal{P}_p$ que cumple $Q(t_{n-j}) = f_{n-j}$, $j = 0, 1, \ldots, p$.

El error local de truncamiento es, para $y \in C^1$

$$T_n(y) = y(t_{n+1}) - \Big[y(t_n) + h\sum_{j=0}^{p} b_j y'(t_{n-j})\Big].$$

Por lo que acabamos de recordar sobre la definición del método, resulta que, si $q \in \mathcal{P}_p$ cumple $q(t_{n-j}) = y'(t_{n-j})$ entonces

$$h\sum_{j=0}^{p} b_j y'(t_{n-j}) = \int_{t_n}^{t_{n+1}} q(t)\,dt,$$

y como $y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} y'(t)\,dt$ resulta

$$T_n(y) = \int_{t_n}^{t_{n+1}} y'(t) - q(t)\,dt.$$

Según la fórmula del error de interpolación, si $y \in C^{p+2}$, y $t_n \le t \le t_{n+1}$

$$|y'(t) - q(t)| = \frac{(t-t_n)(t-t_{n-1})\dots(t-t_{n-p})}{(p+1)!}|y^{(p+2)}(\xi)|,$$

para algún $\xi \in (t_{n-p}, t_{n+1})$. Luego, si $M := \max_{[a,b]} |y^{(p+2)}|$ resulta

$$|y'(t) - q(t)| \le \frac{h\cdot 2h\cdots ph\cdot(p+1)h}{(p+1)!}M \le h^{p+1}M,$$

y luego

$$|T_n(y)| \le \int_{t_n}^{t_{n+1}} Mh^{p+1}\,dt = Mh^{p+2}.$$

Finalmente, resulta

$$\tau_h(y) = \max_{p\le n\le N}\frac{|T_n(y)|}{h} \le Mh^{p+1},$$

y el método de Adams-Bashforth de orden $p+1$ tiene orden $p+1$.

Orden de los métodos de Adams-Moulton.

Análogamente se demuestra que los métodos de Adams-Moulton de orden $p+1$ tienen orden $p+1$. Queda como ejercicio.

8.5.1 Convergencia y orden de métodos multipaso

El siguiente teorema relaciona los conceptos de consistencia y orden con los de convergencia y orden de convergencia del método multipaso.

Teorema 8.28. *Consideremos el PVI*

$$\begin{cases} y' = f(t,y), & \text{en } [a,b],\\ y(a) = y_0, \end{cases}$$

para $f : [a,b] \times \mathbb{R}^d \to \mathbb{R}^d$ *que satisface la condición de Lipschitz*

$$|f(t,y) - f(t,z)| \leq U|y-z|, \qquad t \in [a,b], \quad y,z \in \mathbb{R}^d.$$

Si lo resolvemos utilizando el método multipaso (8.9)*, y suponemos que los coeficientes* $a_j \geq 0$*,* $j = 0,1,\ldots,p$ *y* $\sum_{j=0}^{p} a_j = 1$*, entonces, si los errores iniciales satisfacen*

$$\eta_h(y) = \max_{0\leq i\leq p} |Y_i - y(t_i)| \longrightarrow 0, \quad \textit{cuando } h \to 0,$$

el método es convergente y

$$\max_{0\leq n\leq N} |Y_n - y(t_n)| \leq c_1\eta(h) + c_2\tau(h),$$

para constantes c_1*,* c_2 *que dependen de la constante Lipschitz de* f*.*

Si el método es de orden m*, las primeras* Y_n*,* $n = 0,1,\ldots,p$ *se eligen de manera que* $\eta(h) = O(h^m)$*, y la solución exacta* $y \in C^{m+1}[a,b]$*, entonces la velocidad de convergencia del método es* $O(h^m)$*.*

Observación 8.29. Observemos que si utilizamos un método multipaso con orden $\tau_h(y) = O(h^m)$, el método resultará de orden $O(h^m)$ solo si la manera de calcular los primeros $Y_1, Y_2, \ldots, Y_p$ garantiza que $\eta_h(y) = O(h^m)$.

Ejemplo 8.30. Si queremos utilizar el método de Adams-Bashforth orden dos, que cumple $\tau_h(y) = O(h^2)$. ¿Qué método deberíamos utilizar para el cálculo de Y_1 para que el error global del método sea $O(h^2)$? ¿Se puede usar Euler? La respuesta es afirmativa, pues si utilizamos Euler, se cumple que

$$|y(t_1) - Y_1| \leq \frac{h^2}{2} \max_{t_0\leq t\leq t_1} |y''(t)|.$$

Aunque el error *global* del método de Euler es de orden *uno*, el error local cometido en un paso es de orden dos, y por eso se puede utilizar.

De manera análoga, para que el error global al utilizar el método de Adams-Bashforth de orden tres sea efectivamente $O(h^3)$, basta con utilizar RK2 para el cálculo de Y_1 y Y_2, pero no es suficiente utilizar Euler.

Demostración del Teorema 8.28. Sea y la solución del PVI, que cumple $y'(t) = f(t,y(t))$ y observemos que para $n \geq p$,

$$y(t_{n+1}) = \sum_{j=0}^{p} a_j y(t_{n-j}) + h \sum_{j=-1}^{p} b_j \underbrace{f(t_{n-j}, y(t_{n-j}))}_{y'(t_{n-j})} + T_n(y),$$

$$Y_{n+1} = \sum_{j=0}^{p} a_j Y_{n-j} + h \sum_{j=-1}^{p} b_j f(t_{n-j}, Y_{n-j}).$$

Definiendo $e_n := y(t_n) - Y_n$ obtenemos

$$e_{n+1} = \sum_{j=0}^{p} a_j e_{n-j} + h \sum_{j=-1}^{p} b_j \left[f(t_{n-j}, y(t_{n-j})) - f(t_{n-j}, Y_{n-j})\right] + T_n(y),$$

y luego, por la desigualdad triangular y la condición Lipschitz de f, definiendo $E_n := \max_{0\le j\le n}|e_j|$, tenemos que

$$\begin{aligned}
|e_{n+1}| &\le \sum_{j=0}^{p} a_j|e_{n-j}| + h\sum_{j=-1}^{p}|b_j|\,|f(t_{n-j},y(t_{n-j})) - f(t_{n-j},Y_{n-j})| + h\tau_h(y)\\
&\le \sum_{j=0}^{p} a_j|e_{n-j}| + h\sum_{j=-1}^{p}|b_j|\,U\,\big|\underbrace{y(t_{n-j})-Y_{n-j}}_{e_{n-j}}\big| + h\tau_h(y)\\
&\le \underbrace{\sum_{j=0}^{p} a_j}_{1}\,E_n + h\,\underbrace{U\sum_{j=-1}^{p}|b_j|}_{C}\,E_{n+1} + h\tau_h(y).
\end{aligned}$$

Resumiendo,

$$|e_{n+1}| \le E_n + hCE_{n+1} + h\tau_h(y), \qquad n = p, p+1, \dots, N.$$

Como $E_1 \le E_2 \le \cdots \le E_N$, resulta que, para $k \le n$

$$|e_{k+1}| \le E_k + hCE_{k+1} + h\tau_h(y) \le E_n + hCE_{n+1} + h\tau_h(y),$$

y por lo tanto,

$$\max_{0\le k\le n+1}|e_k| = E_{n+1} \le E_n + hCE_{n+1} + h\tau_h(y), \qquad n = p, p+1, \dots, N,$$

que a su vez implica

$$(1-hC)E_{n+1} \le E_n + h\tau_h(y), \qquad n = p, p+1, \dots, N.$$

Si consideramos $h < \frac{1}{2C} =: c_3$, resulta $1 - hC > \frac{1}{2}$ y $\frac{1}{1-hC} = 1 + hC + (hC)^2 + \cdots \le 1 + 2hC < 2$, por lo que

$$E_{n+1} \le \frac{1}{1-hC}E_n + \frac{h}{1-hC}\tau_h(y) \le (1+2hC)E_n + 2h\tau_h(y), \qquad n = p, p+1, \dots, N.$$

Por lo tanto,

$$\begin{aligned}
E_{p+1} &\le (1+2hC)E_p + 2h\tau_h(y),\\[2ex]
E_{p+2} &\le (1+2hC)E_{p+1} + 2h\tau_h(y)\\
&\le (1+2hC)^2E_p + (1+2hC)2h\tau_h(y) + 2h\tau_h(y),\\[2ex]
E_{p+3} &\le (1+2hC)E_{p+2} + 2h\tau_h(y)\\
&\le (1+2hC)^3E_p + (1+2hC)^2 2h\tau_h(y) + (1+2hC)2h\tau_h(y) + 2h\tau_h(y)\\
&= (1+2hC)^3E_p + \Big[(1+2hC)^2 + (1+2hC) + 1\Big]2h\tau_h(y),\\
&\;\;\vdots\\
E_{p+n} &\le (1+2hC)^n \underbrace{E_p}_{\eta_h(y)} + \Big[(1+2hC)^{n-1} + \cdots + (1+2hC) + 1\Big]2h\tau_h(y)\\
&= (1+2hC)^n\eta_h(y) + \frac{(1+2hC)^n - 1}{1+2hC-1}2h\tau_h(y).
\end{aligned}$$

Recordando que $(1+2hC)^n \le e^{2hnC} \le e^{2hNC} = e^{2(b-a)C} =: c_1$ obtenemos

$$E_{p+n} \le c_1 \eta_h(y) + \underbrace{\frac{c_1 - 1}{C}}_{c_2} \tau_h(y),$$

que inmediatamente implica la afirmación del teorema. □

8.5.2 Criterios para la convergencia de métodos multipaso

Las siguientes proposiciones dan condiciones necesarias y suficientes sobre los coeficientes a_j, b_j que definen el método multipaso (8.9) para que cumplan las definiciones de consistencia y orden anteriores. Estas condiciones permiten saber si un método converge, y cuál es su orden, verificando ciertas condiciones algebraicas sobre los coeficientes.

Proposición 8.31. *El método multipaso* (8.9) *es consistente si y solo si*

$$\sum_{j=0}^{p} a_j = 1 \quad y \quad -\sum_{j=0}^{p} j a_j + \sum_{j=-1}^{p} b_j = 1. \tag{8.12}$$

Demostración. Observemos que T_n es lineal, es decir, si $\alpha, \beta \in \mathbb{R}$ y $v, w \in C^2$, entonces

$$T_n(\alpha v + \beta w) = \alpha T_n(v) + \beta T_n(w).$$

Por el teorema de Taylor (ver Teorema 8.32), si $y \in C^2$

$$y(t) = y(t_n) + y'(t_n)(t - t_n) + R_2(t), \quad \text{con} \quad R_2(t) = \int_{t_n}^{t} (t-s) y''(s)\, ds.$$

Luego

$$\begin{aligned} T_n(y) &= T_n(\underbrace{y(t_n)}_{\text{función constante}}) + T_n(\underbrace{y'(t_n)(\cdot - t_n)}_{\text{función lineal}}) + T_n(R_2) \\ &= y(t_n) T_n(1) + y'(t_n) T_n(\cdot - t_n) + T_n(R_2). \end{aligned}$$

Ahora bien, por un lado

$$T_n(1) = 1 - \sum_{j=0}^{p} a_j\, 1 - \sum_{j=-1}^{p} b_j\, 0 = 1 - \sum_{j=0}^{p} a_j =: c_0, \qquad \text{y}$$

$$\begin{aligned} T_n((\cdot - t_n)) &= (t_{n+1} - t_n) - \left[\sum_{j=0}^{p} a_j (t_{n-j} - t_n) + h \sum_{j=-1}^{p} b_j\, 1 \right] \\ &= h - \left[\sum_{j=0}^{p} a_j (-jh) + h \sum_{j=-1}^{p} b_j \right] = h \left\{ 1 - \left[\sum_{j=0}^{p} -j a_j + \sum_{j=-1}^{p} b_j \right] \right\} =: c_1 h. \end{aligned}$$

Por otro lado,

$$T_n(R_2) = R_2(t_{n+1}) - \left[\sum_{j=0}^{p} a_j R_2(t_{n-j}) + h \sum_{j=-1}^{p} b_j R_2'(t_{n-j}) \right].$$

Como $R_2(t) = \int_{t_n}^t (t-s)y''(s)\,ds$, tenemos $R_2'(t) = \int_{t_n}^t y''(s)\,ds$ y resulta $T_n(R_2) = \zeta_n h^2$ con

$$|\zeta_n| := \frac{|T_n(R_2)|}{h^2} \le \frac{1}{2}M\left\{1 + \sum_{j=0}^{p}|a_j|j^2 + \sum_{j=-1}^{p}|b_j||j|\right\},$$

con $M = \max_{[a,b]}|y''|$. En síntesis, $|\zeta_n| \le C$, con C una constante que depende del máximo de $|y''|$ en $[a,b]$ y de los coeficientes a_j, b_j que definen el método multipaso.

Resumiendo, tenemos que

$$T_n(y) = y(t_n)c_0 + hy'(t_n)c_1 + h^2\zeta_n,$$

con

$$c_0 = 1 - \sum_{j=0}^{p} a_j, \qquad c_1 = 1 - \left[\sum_{j=0}^{p}(-j)a_j + \sum_{j=-1}^{p} b_j\right], \qquad |\zeta_n| \le C.$$

Luego

$$\frac{T_n(y)}{h} = \frac{1}{h}y(t_n)c_0 + y'(t_n)c_1 + h\zeta_n.$$

Si se cumple (8.12), entonces $c_0 = c_1 = 0$ y para $y \in C^2[a,b]$ resulta

$$\tau_h(y) = \max_{p\le n\le N}\frac{|T_n(y)|}{h} \le Ch \longrightarrow 0,$$

para $h \to 0$, por lo que el método es consistente.

Para probar la recíproca, supongamos que $\tau_h(y) \to 0$ cuando $h \to 0$ para toda $y \in C^2$. En particular, para $y = 1$, resulta $\tau_h(y) = \frac{1}{h}|c_0|$ luego c_0 debe ser cero. Para $y(t) = t$ resulta ahora $\tau_h(y) = |c_1|$ y por lo tanto debe ser $c_1 = 0$. □

En la proposición anterior y en la que sigue usamos la siguiente versión del teorema de Taylor, cuya demostración puede encontrarse en cualquier libro de Cálculo en una variable.

Teorema 8.32. *Si $y \in C^{k+1}(a,b)$ y $x_0 \in (a,b)$, entonces, para $x \in (a,b)$,*

$$y(x) = y(x_0) + (x-x_0)y'(x_0) + \frac{(x-x_0)^2}{2!}y''(x_0) + \cdots + \frac{(x-x_0)^k}{k!}y^{(k)}(x_0) + R_{k+1}(x),$$

con $R_{k+1}(x) = \dfrac{1}{k!}\displaystyle\int_{x_0}^{x}(s-x_0)^k y^{(k+1)}(x_0+x-s)\,ds = \frac{1}{k!}\int_{x_0}^{x}(x-s)^k y^{(k+1)}(s)\,ds.$

Proposición 8.33. *El método multipaso (8.9) es de orden m si y solo si es consistente y además*

$$\sum_{j=0}^{p}(-j)^i a_j + i\sum_{j=-1}^{p}(-j)^{i-1}b_j = 1, \qquad i = 2,3,\ldots,m. \tag{8.13}$$

Observemos que la condición (8.12) es equivalente a las condiciones (8.13) para $i = 0, 1$.

Demostración. La demostración sigue los mismos pasos de la demostración de la proposición anterior. Comenzamos viendo que por el teorema de Taylor,

$$y(t) = \sum_{i=0}^{m} \frac{(t-t_n)^i}{i!} y^{(i)}(t_n) + R_{m+1}(t) \qquad \text{con} \quad R_{m+1}(t) = \frac{1}{m!} \int_{t_n}^{t} (t-s)^m y^{(m+1)}(s)\, ds.$$

Luego, por la linealidad de T_n resulta

$$T_n(y) = \sum_{i=0}^{m} \frac{y^{(i)}(t_n)}{i!} T_n((\cdot - t_n)^i) + T_n(R_{m+1}).$$

Veamos qué es $T_n((\cdot - t_n)^i)$, para $i = 0, 1, \ldots, m$.

Para $i = 0$, $(t-t_n)^0 = 1$, y ya vimos que $T_n(1) = 1 - \sum_{j=0}^{p} a_j =: c_0$. Para $i = 1$, ya vimos que $T_n(\cdot - t_n) = c_1 h$, con $c_1 = 1 - \left[\sum_{j=0}^{p} -j a_j + \sum_{j=-1}^{p} b_j \right]$. Para i general

$$\begin{aligned} T_n((\cdot - t_n)^i) &= (t_{n+1} - t_n)^i - \left[\sum_{j=0}^{p} a_j (t_{n-j} - t_n)^i + h \sum_{j=-1}^{p} b_j i (t_{n-j} - t_n)^{i-1} \right] \\ &= h^i - \left[\sum_{j=0}^{p} a_j (-jh)^i + h \sum_{j=-1}^{p} i b_j (-jh)^{i-1} \right] \\ &= h^i \left\{ 1 - \left[\sum_{j=0}^{p} (-j)^i a_j + i \sum_{j=-1}^{p} (-j)^{i-1} b_j \right] \right\} =: c_i h^i. \end{aligned}$$

Así, para $i = 0, 1, \ldots, m$,

$$T_n((\cdot - t_n)^i) = c_i h^i, \quad \text{con} \quad \begin{cases} c_0 = 1 - \displaystyle\sum_{j=0}^{p} a_j, \\ c_i = 1 - \left[\displaystyle\sum_{j=0}^{p} (-j)^i a_j + i \sum_{j=-1}^{p} (-j)^{i-1} b_j \right], \quad i = 1, 2, \ldots, m. \end{cases}$$

Por lo tanto

$$T_n(y) = \sum_{i=0}^{m} \frac{c_i y^{(i)}(t_n)}{i!} h^i + T_n(R_{m+1}).$$

Veremos a continuación que

$$T_n(R_{m+1}) = \zeta_n h^{m+1}, \qquad \text{donde} \quad |\zeta_n| \le C, \tag{8.14}$$

con C una constante que depende del máximo de $|y^{(m+1)}|$ en $[a, b]$ y de los coeficientes a_j, b_j que definen el método multipaso.

Si vale (8.14) entonces resulta que

$$T_n(y) = \sum_{i=0}^{m} \frac{c_i y^{(i)}(t_n)}{i!} h^i + \zeta_n h^{m+1},$$

y por lo tanto

$$\tau_h(y) = \max_{p\le n\le N} \frac{|T_n(y)|}{h} \le \sum_{i=0}^{m} \frac{|c_i y^{(i)}(t_n)|}{i!} h^{i-1} + |\zeta_n| h^m.$$

para $y \in C^{m+1}$. Si vale (8.13) entonces $c_0 = c_1 = \cdots = c_m = 0$ y por lo tanto

$$\tau_h(y) \le |\zeta_n| h^m \le C h^m,$$

por lo que el método es de orden m.

Supongamos ahora que el método es de orden m, entonces, para $h \to 0$ resulta

$$\frac{\tau_h(y)}{h^m} \le C.$$

Considerando los casos particulares $y = t^i$, $i = 0, 1, \ldots, m$ obtenemos que

$$\tau_h(y) = c_i y^{(i)}(t_n) h^{i-1} = c_i i! h^{i-1}$$

y luego $\tau_h(y)/h^m = c_i i! h^{i-m-1}$ es acotado solo si $c_i = 0$.

Para finalizar la demostración falta ver que vale (8.14). Por definición de T_n,

$$\begin{aligned} \zeta_n &:= \frac{T_n(R_{m+1})}{h^{m+1}} \\ &= \frac{1}{h^{m+1}} \left[R_{m+1}(t_{n+1}) - \sum_{j=0}^{p} a_j R_{m+1}(t_{n-j}) - h \sum_{j=-1}^{p} b_j R'_{m+1}(t_{n-j}) \right]. \end{aligned} \tag{8.15}$$

Recordemos ahora que $R_{m+1}(t) = \frac{1}{m!} \int_{t_n}^{t} (t-s)^m y^{(m+1)}(s)\, ds$, luego, para $j = -1, 0, 1, \ldots, p$,

$$\left|R_{m+1}(t_{n-j})\right| = \frac{1}{m!} \left| \int_{t_n}^{t_{n-j}} (t_{n-j} - s)^m y^{(m+1)}(s)\, ds \right| \le \frac{1}{m!} |j| h (|j| h)^m M \le \frac{p^{m+1}}{m!} M h^{m+1},$$

si $M := \max_{a\le t\le b} |y^{(m+1)}(t)|$. Por otro lado, para $j = -1, 0, 1, \ldots, p$,

$$\left|R'_{m+1}(t_{n-j})\right| = \frac{1}{m!} \left| \int_{t_n}^{t_{n-j}} m(t_{n-j} - s)^{m-1} y^{(m+1)}(s)\, ds \right| \le \frac{m}{m!} p^m M h^m.$$

Luego, a partir de (8.15) y de las dos últimas acotaciones obtenemos

$$\left|\zeta_n\right| \le \left[1 + \sum_{j=0}^{p} |a_j| + m \sum_{j=-1}^{p} |b_j| \right] \frac{p^{m+1} M}{m!} =: C.$$

Claramente C depende de la definición del método y de $M := \max_{[a,b]} |y^{(m+1)}|$, y la demostración está concluida. □

8.5.3 Estabilidad para métodos multipaso

Recordemos que el estudio de regiones de estabilidad se basa en considerar el comportamiento del método numérico cuando es aplicado al PVI particular

$$\begin{cases} y' = \lambda y, & t > 0, \\ y(0) = 1, \end{cases}$$

con especial atención al caso $\lambda \in \mathbb{C}$, $\operatorname{Re}\lambda \leq 0$.

La región de estabilidad del método multipaso (8.9) se define como sigue:

$$R = \{h\lambda \in \mathbb{C} : \{Y_n\}_{n\geq 0} \text{ es acotada, para cualquier elección de } Y_0, Y_1, \ldots, Y_p\}.$$

Se entiende que la sucesión $\{Y_n\}_{n\geq 0}$ se define a partir de $Y_0, Y_1, \ldots, Y_p$ con la fórmula del método multipaso, más precisamente

$$Y_{n+1} = \sum_{j=0}^{p} a_j Y_{n-j} + h \sum_{j=-1}^{p} b_j f(t_{n-j}, Y_{n-j}), \qquad n = p, p+1, \ldots.$$

En el caso modelo $f(t, y) = \lambda y$ resulta

$$Y_{n+1} = \sum_{j=0}^{p} a_j Y_{n-j} + h\lambda \sum_{j=-1}^{p} b_j Y_{n-j}$$

y el problema de hallar la región de estabilidad se traduce en hallar el conjunto de los $h\lambda$ para los que todas las sucesiones obtenidas a partir de

$$\begin{cases} Y_{n+1} = \displaystyle\sum_{j=0}^{p} a_j Y_{n-j} + h\lambda \sum_{j=-1}^{p} b_j Y_{n-j} \\ \left.\begin{matrix} Y_0 \\ Y_1 \\ \vdots \\ Y_p \end{matrix}\right\} \text{ arbitrarios,} \end{cases} \tag{8.16}$$

sean acotadas.

Para $h\lambda$ fijo, la ecuación en (8.16) es una *ecuación en diferencias* de orden $p+1$, donde la incógnita es la sucesión $\{Y_n\}_{n\geq 0}$ y las condiciones iniciales son los valores preestablecidos de $Y_0, Y_1, \ldots, Y_p$. Similarmente a lo que ocurre con EDO de orden $p+1$, las soluciones de la *ecuación en diferencias* (8.16) son combinaciones lineales de $p+1$ soluciones linealmente independientes. Dichas soluciones se obtienen proponiendo soluciones de la forma $Y_n = r^n$ para algún $r \in \mathbb{C}$. En este caso r debe satisfacer

$$r^{n+1} = \sum_{j=0}^{p} a_j r^{n-j} + \lambda h \sum_{j=-1}^{p} b_j r^{n-j}, \qquad n \geq p.$$

Dividiendo por r^{n-p} obtenemos la ecuación equivalente

$$r^{p+1} = \sum_{j=0}^{p} a_j r^{p-j} + \lambda h \sum_{j=-1}^{p} b_j r^{p-j},$$

que es a su vez equivalente a

$$q(r) := (1 - h\lambda b_{-1}) r^{p+1} - \sum_{j=0}^{p} (a_j + \lambda h b_j) r^{p-j} = 0.$$

Dado $h\lambda \in \mathbb{C}$, $q(r)$ es un polinomio de grado $p+1$ en r y tiene $p+1$ ceros $r_0, r_1, \ldots, r_p$. Si un r_i es un cero simple de q entonces r_i^n es una solución de la ecuación en (8.16). Si r_i es un cero múltiple con multiplicidad m_i de q, entonces las soluciones linealmente independientes son

$$r_i^n, \quad n r_i^n, \quad n^2 r_i^n, \quad \ldots \quad , n^{m_i - 1} r_i^n.$$

La solución general de (8.16) resulta entonces

$$\sum_{i=0}^{N_r} \sum_{j=0}^{m_i - 1} \alpha_{ij} n^j r_i^n,$$

donde N_r es el número de raíces distintas de $q(r)$ y α_{ij} se determinan para cumplir las condiciones iniciales (valores de $Y_0, Y_1, \ldots, Y_p$). La sucesión obtenida resulta acotada para cualquier elección de α_{ij} si y solo si las raíces simples de $q(r)$ tienen módulo menor o igual a uno y las múltiples tienen módulo menor (estricto) que uno.

Además, la sucesión obtenida tiende a cero para cualquier elección de α_{ij} si y solo si todas las raíces de $q(r)$ tienen módulo menor que uno (tanto las simples como las múltiples). Esto se debe a que si $r_i \in \mathbb{C}$, $|r_i| < 1$, entonces

$$n^k r_i^n \longrightarrow 0, \quad \text{cuando } n \to \infty,$$

para cualquier $k \in \mathbb{Z}$.

Para simplificar el análisis definiremos la región de *estabilidad fuerte* de un método, como el conjunto de $h\lambda \in \mathbb{C}$ tales que la sucesión $\{Y_n\}_{n \geq 0}$ tiende a cero. Más precisamente, definimos

$$\mathbf{R} = \{h\lambda \in \mathbb{C} : \{Y_n\}_{n \geq 0} \textit{ tiende a cero}, \text{ para cualquier elección de } Y_0, Y_1, \ldots, Y_p\}.$$

Por lo tanto, $h\lambda \in \mathbf{R}$ si y solo si todas las raíces del polinomio $q(r)$ tienen módulo menor (estricto) que uno, sin importar la multiplicidad.

Región de estabilidad de Adams-Bashforth de orden 2 (AB2)

El método AB2 tiene la fórmula

$$Y_{n+1} = Y_n + \frac{h}{2}\Big[3f(t_n, Y_n) - f(t_{n-1}, Y_{n-1})\Big].$$

Si consideramos $f(t,y) = \lambda y$ tenemos

$$Y_{n+1} = Y_n + \frac{h}{2}\Big[3\lambda Y_n - \lambda Y_{n-1}\Big] = \left(1 + \frac{3h\lambda}{2}\right) Y_n - \frac{h\lambda}{2} Y_{n-1}.$$

Buscamos soluciones de la forma $Y_n = r^n$, que entonces r debe satisfacer

$$r^{n+1} = \left(1 + \frac{3h\lambda}{2}\right) r^n - \frac{h\lambda}{2} r^{n-1},$$
$$r^2 = \left(1 + \frac{3h\lambda}{2}\right) r - \frac{h\lambda}{2},$$

es decir, la ecuación cuadrática

$$r^2 - \left(1 + \frac{3h\lambda}{2}\right) r + \frac{h\lambda}{2} = 0,$$

con soluciones

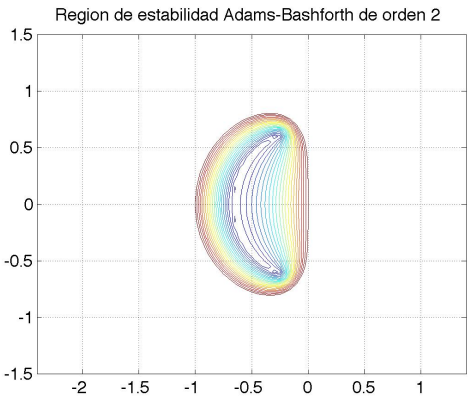
$$r_{1,2} = \frac{\left(1 + \frac{3h\lambda}{2}\right) \pm \sqrt{\left(1 + \frac{3h\lambda}{2}\right)^2 - 4\frac{h\lambda}{2}}}{2} = \left(\frac{1}{2} + \frac{3h\lambda}{4}\right) \pm \sqrt{\left(\frac{1}{2} + \frac{3h\lambda}{4}\right)^2 - \frac{h\lambda}{2}}.$$

Luego, la región de estabilidad fuerte del método AB2 es

$$\mathbf{R}_{AB2} = \left\{ z \in \mathbb{C} : \max\{|r_1|, |r_2|\} < 1, \text{ con } r_{1,2} = \left(\frac{1}{2} + \frac{3h\lambda}{4}\right) \pm \sqrt{\left(\frac{1}{2} + \frac{3h\lambda}{4}\right)^2 - \frac{h\lambda}{2}} \right\}.$$

Para graficarla utilizamos el siguiente código en MATLAB/OCTAVE:

```
% reg_estab_ab2.m
[re,im] = meshgrid(-2:.05:1,-2:.05:2);
z = re + i*im;
d = sqrt((1/2+3/4*z).^2-z/2);
r1 = (1/2+3/4*z)+d;
r2 = (1/2+3/4*z)-d;
val = max(abs(r1),abs(r2));
contour(re, im, val, [.02:.02:1])
grid
axis equal
title('Region de estabilidad de AB2')
print -djpeg reg_estab_ab2
print -deps2c reg_estab_ab2
```



Región de estabilidad de Adams-Moulton de orden 2 (AM2)

El método AM2 tiene la fórmula

$$Y_{n+1} = Y_n + \frac{h}{2}\Big[f(t_n, Y_n) + f(t_{n+1}, Y_{n+1})\Big].$$

Si consideramos $f(t,y) = \lambda y$ tenemos

$$Y_{n+1} = Y_n + \frac{h}{2}\Big[\lambda Y_n + \lambda Y_{n+1}\Big] = \left(1 + \frac{h\lambda}{2}\right) Y_n + \frac{h\lambda}{2} Y_{n+1}.$$

En este caso, resulta

$$\begin{aligned} Y_{n+1} &= \left(1 + \frac{h\lambda}{2}\right) Y_n + \frac{h\lambda}{2} Y_{n+1}, \\ Y_{n+1}\left(1 - \frac{h\lambda}{2}\right) &= Y_n \left(1 + \frac{h\lambda}{2}\right), \\ Y_{n+1} &= Y_n \frac{1 + \frac{h\lambda}{2}}{1 - \frac{h\lambda}{2}}. \end{aligned}$$

Luego Y_n tiende a cero si y solo si

$$\left| \frac{1 + \frac{h\lambda}{2}}{1 - \frac{h\lambda}{2}} \right| < 1.$$

Por lo tanto, la región de estabilidad resulta

$$\mathbf{R}_{AM2} = \left\{ z \in \mathbb{C} : \left| \frac{1 + \frac{z}{2}}{1 - \frac{z}{2}} \right| < 1 \right\}.$$

Esta región de estabilidad puede hallarse analíticamente, pues

$$\begin{aligned} \left| \frac{1 + \frac{z}{2}}{1 - \frac{z}{2}} \right| < 1 &\iff \left| 1 + \frac{z}{2} \right| < \left| 1 - \frac{z}{2} \right| \\ &\iff \left| 1 + \frac{z}{2} \right|^2 < \left| 1 - \frac{z}{2} \right|^2 \\ &\iff \left(1 + \frac{\operatorname{Re} z}{2} \right)^2 + \left(\frac{\operatorname{Im} z}{2} \right)^2 < \left(1 - \frac{\operatorname{Re} z}{2} \right)^2 + \left(\frac{\operatorname{Im} z}{2} \right)^2 \\ &\iff 1 + \operatorname{Re} z + \frac{(\operatorname{Re} z)^2}{4} < 1 - \operatorname{Re} z + \frac{(\operatorname{Re} z)^2}{4} \\ &\iff \operatorname{Re} z < -\operatorname{Re} z \quad \iff \quad \operatorname{Re} z < 0. \end{aligned}$$

Por lo tanto

$$\mathbf{R}_{AM2} = \{ z \in \mathbb{C} : \operatorname{Re} z < 0 \}.$$

Regiones de estabilidad para AB3, AM3.

Análogamente a como se hizo para AB2 y AM2, puede verse que las regiones de estabilidad de AB3 y AM3 son las siguientes:

$$\mathbf{R}_{AB3} = \left\{ z \in \mathbb{C} : \max_{i=1,2,3} |r_i| < 1, \text{ con } r_i \text{ cero de } -r^3 + (1 + \frac{23z}{12})r^2 - \frac{16z}{12} r + \frac{5z}{12} \right\},$$

$$\mathbf{R}_{AM3} = \left\{ z \in \mathbb{C} : \max_{i=1,2} |r_i| < 1, \text{ con } r_i \text{ cero de } (-1 + \frac{5z}{12})r^2 + (1 + \frac{8z}{12})r - \frac{z}{12} \right\}$$

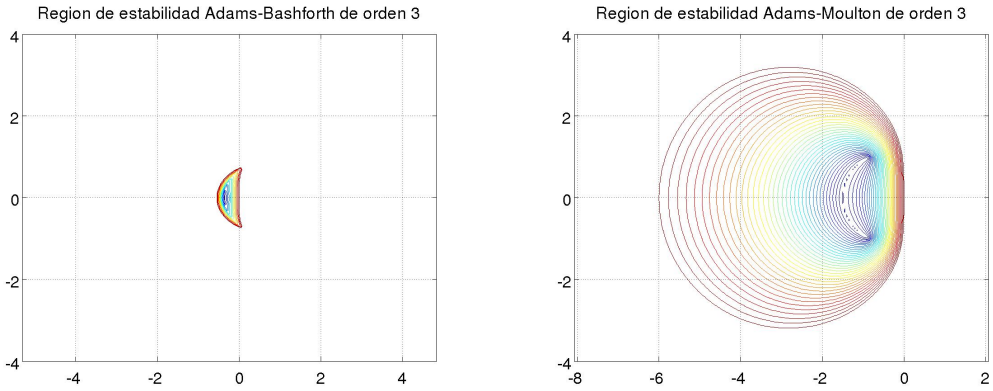


Figura 8.3 Regiones de estabilidad para métodos de Adams-Bashforth (izquierda) y Adams-Moulton (derecha) de orden tres.

Las regiones se pueden graficar con los siguientes códigos para MATLAB/OCTAVE:

```
% reg_estab_ab3.m
[re,im] = meshgrid(-6:.05:1,-4:.05:4);
i = sqrt(-1);
z = re + i*im;
[n,m] = size(z);
val = zeros(n,m);
for ii=1:n
  for jj=1:m
    Z = z(ii,jj);
    p = [-1 1+23/12*Z -16/12*Z 5/12*Z];
    val(ii,jj) = max(abs(roots(p)));
  end
end

contour(re, im, val, [.5:.02:1])
grid
axis equal
title('Region de estabilidad de AB3')

print -djpeg reg_estab_ab3
print -deps2c reg_estab_ab3
```

```
% reg_estab_am3.m
[re,im] = meshgrid(-6:.05:1,-4:.05:4);
i = sqrt(-1);
z = re + i*im;
[n,m] = size(z);
val = zeros(n,m);
for ii=1:n
  for jj=1:m
    Z = z(ii,jj);
    p = [-1+5/12*Z 1+8/12*Z -Z/12];
    val(ii,jj) = max(abs(roots(p)));
  end
end

contour(re, im, val, [.02:.02:1])
grid
axis equal
title('Region de estabilidad AM3')

print -djpeg reg_estab_am3
print -deps2c reg_estab_am3
```

Como puede verse en la Figura 8.3 el método implícito tiene una región de estabilidad mayor que el método explícito del mismo orden.

8.6 Un método predictor-corrector

La idea de un método predictor-corrector es *predecir* Y_{n+1} con un método explícito, y después *corregir* el valor colocando la predicción en el lado derecho de una fórmula implícita. El objetivo es lograr un método que al final resulta *explícito* pero que gane un

poco de estabilidad al usar la fórmula implícita. Por ejemplo, si usamos las fórmulas de Adams-Bashforth-Moulton de orden 3, el método resulta:

$$\text{Predicción (AB3):} \quad Y_{n+1}^{(\mathbf{P})} = Y_n + \frac{h}{12}\Big[23f(t_n, Y_n) - 16f(t_{n-1}, Y_{n-1}) + 5f(t_{n-2}, Y_{n-2})\Big],$$
$$\text{Corrección (AM3):} \quad Y_{n+1} = Y_n + \frac{h}{12}\Big[5f(t_{n+1}, Y_{n+1}^{(\mathbf{P})}) + 8f(t_n, Y_n) - 1f(t_{n-1}, Y_{n-1})\Big].$$

Queda como ejercicio hallar y graficar la región de estabilidad de este método, y también demostrar que tiene un error global de orden $O(h^3)$.

8.7 Fórmulas de diferenciación hacia atrás (BDF)

Las fórmulas de diferenciación hacia atrás, o BDF, por su sigla en inglés (*Backward Differentiation Formulas*) constituyen otra manera de obtener métodos multipaso. Tratando de obtener mayores regiones de estabilidad las BDF proveen métodos implícitos. La propuesta es la siguiente. Dado un entero positivo p, sea $q \in \mathcal{P}_p$ el polinomio de grado $\leq p$ que interpola $y(t)$ en t_{n-j}, para $j = -1, 0, 1, \ldots, p-1$. Notemos que ahora estamos interpolando $y(t)$ y no $f(t, y(t))$ como hacíamos con los métodos de Adams. Si llamamos $\ell_{j,n}$ a la función de la base de Lagrange[3] para polinomios correspondiente a los puntos t_{n-j}, $j = -1, 0, 1, \ldots, p-1$, entonces

$$q(t) = \sum_{j=-1}^{p-1} y(t_{n-j})\ell_{j,n}(t).$$

La idea de las BDF es aproximar $y'(t_{n+1})$ por $q'(t_{n+1})$, es decir

$$q'(t_{n+1}) = \sum_{j=-1}^{p-1} y(t_{n-j})\ell'_{j,n}(t_{n+1}) \approx y'(t_{n+1}) = f(t_{n+1}, y(t_{n+1})).$$

En base a esta aproximación se obtiene el método BDF de orden p: Y_{n+1} es la solución de:

$$\sum_{j=-1}^{p-1} Y_{n-j}\ell'_{j,n}(t_{n+1}) = f(t_{n+1}, Y_{n+1}),$$

que despejando resulta

$$Y_{n+1} = \sum_{j=0}^{p-1} \alpha_j Y_{n-j} + h\beta f(t_{n+1}, Y_{n+1}),$$

[3]La función de Lagrange $\ell_{j,n} \in \mathcal{P}_p$ cumple $\ell_{j,n}(t_{n-i}) = \delta_{i,j}$ para $i = -1, 0, 1, \ldots, p-1$. Una fórmula está dada por

$$\ell_{j,n}(t) = \frac{\prod\limits_{\substack{-1\leq i\leq p \\ i\neq j}} (t - t_{n-i})}{\prod\limits_{\substack{-1\leq i\leq p \\ i\neq j}} (t_{n-j} - t_{n-i})}.$$

para $\beta = \frac{1}{h\ell'_{-1,n}(t_{n+1})}$ y $\alpha_j = -\frac{\ell'_{j,n}(t_{n+1})}{\ell'_{-1,n}(t_{n+1})}$. Resulta que α_j y β son constantes fijas, independientes de la partición, siempre que esta sea uniforme.

Para $p = 1$ se obtiene $\beta = \alpha_1 = 1$ y resulta el método de Euler implícito.

Para $p = 2$, resulta $\beta = \frac{2}{3}$, $\alpha_1 = \frac{4}{3}$, $\alpha_2 = -\frac{1}{3}$.

Para $p = 3$, resulta $\beta = \frac{6}{11}$, $\alpha_1 = \frac{18}{11}$, $\alpha_2 = -\frac{9}{11}$, $\alpha_3 = \frac{2}{11}$.

Un aspecto muy interesante de estos métodos es que sus regiones de estabilidad contienen a *todo el eje real negativo*, para $p < 6$.

8.8 Problemas

8.1. Explicar por qué falla el método de Euler al aproximar la solución $y(t) = \left(\frac{2}{3}t\right)^{\frac{3}{2}}$, para $t \geq 0$, del PVI $y' = y^{\frac{1}{3}}$, $y(0) = 0$.

8.2. La trayectoria de una partícula que se mueve en el plano está dada por la curva $(x_1(t), x_2(t))$, donde las funciones x_1 y x_2 son la solución del siguiente sistema de ecuaciones diferenciales:

$$\begin{cases} x_1'(t) &= -x_2(t) \\ \\ x_2'(t) &= x_1(t) - x_2(t) \end{cases}$$

Resolver este sistema en el intervalo $[0, 20]$ con el método de Euler utilizando paso $h = 0.05$ y graficar la trayectoria de la partícula, sabiendo que en tiempo $t = 0$ se encontraba en el punto $(1, -1)$. Realizar nuevamente el gráfico utilizando la solución obtenida con el comando `ode45` de MATLAB/OCTAVE.

8.3. Resolver los siguientes PVI mediante los métodos de Euler, RK2 y RK4. Estudiar el orden experimental de convergencia de cada método.

(a)

$$\begin{cases} \dfrac{dy}{dx} = \dfrac{y}{x} - \left(\dfrac{y}{x}\right)^2 & 1 < x < 2 \\ y(1) = 1 \end{cases}$$

Solución exacta: $y(x) = x/(1 + \ln(x))$

(b)

$$\begin{cases} \dfrac{dy}{dx} = -y + (2 + x)|x| & -1 < x < 1 \\ y(-1) = e - 1 \end{cases}$$

Solución exacta: $y(x) = x|x| + e^{-x}$

8.4. Resolver numéricamente con al menos dos métodos diferentes, el PVI

$$\begin{cases} y^{(3)} + 4y'' + 5y' + 2y = -4\,\mathrm{sen}\,t - 2\cos t \\ y(0) = 1 \\ y'(0) = 0 \\ y''(0) = -1 \end{cases}$$

Comparar los resultados con los valores de la solución exacta $y(t) = \cos t$. Estudiar el orden experimental de convergencia en términos del paso h.

8.5. Considerar el problema

$$\begin{cases} y'(t) = -500y(t) - \operatorname{sen}(t) + 500\cos(t), & 0 \le t \le 2\pi, \\ y(0) = 1, \end{cases}$$

cuya solución exacta es $y(t) = \cos(t)$.

Resolverlo numéricamente con el método de Euler y el método de Euler implícito, usando $N = 10$, 20, 50, 100, 200, 500, 1000, 2000, 5000, 10 000, ...

Graficar algunas soluciones para ver lo que ocurre.

Elaborar una tabla con el error global producido por cada uno de los métodos para cada N. Determinar el valor de N (de entre los utilizados) para el que el error global en cada caso está acotado por 10^{-3}, 10^{-4}, 10^{-5} y 10^{-6}. Obtener conclusiones.

8.6. Considerar el método de Adams–Bashforth de tres pasos siguiente

$$Y_{n+1} = Y_n + \frac{h}{12}\left[23f(t_n, Y_n) - 16f(t_{n-1}, Y_{n-1}) + 5f(t_{n-2}, Y_{n-2})\right]$$

para $n = 2, 3, \cdots, N-1$, en la resolución del PVI

$$y' = 1 + (t-y)^2, \quad 2 \le t \le 3,$$

con condición inicial $y(2) = 1$, cuya solución es $y(t) = t + 1/(1-t)$.

Para aplicar el método se necesitan tres valores iniciales $Y_0 = 1$, Y_1 e Y_2. Estos dos últimos deberían obtenerse mediante algún otro método apropiado.

Determinar empíricamente el orden del método dado calculando los valores iniciales mediante

(a) el método de Euler,

(b) el método RK2,

(c) el método RK4.

8.7. Acotar el error local de truncamiento para el método de Adams–Moulton de p pasos (AM_{p+1}). ¿Cuál es el orden global del método?

8.8. Determinar el orden del método Midpoint y determinar la región de estabilidad.

8.9. Se pueden obtener métodos multipasos para el PVI

$$\begin{cases} y' = f(t, y), & t_0 \le t \le b, \\ y(t_0) = y_0. \end{cases}$$

mediante integración numérica. En efecto, integrando la ecuación diferencial sobre el intervalo $[t_{n-r}, t_{n+1}]$, se obtiene

$$y(t_{n+1}) = y(t_{n-r}) + \int_{t_{n-r}}^{t_{n+1}} f(t, y(t))\, dt,$$

para algún $r \geq 0$, y para todo $n \geq r$. Se aproxima la integral mediante una cuadratura de la forma $\sum_{i=0}^{k} \omega_i f(t_i, y(t_i))$ que resulte exacta para polinomios de grado menor o igual que k, para algún $0 \leq k \leq n$ y para algún conjunto de puntos nodales $\{t_i\}$.

Obtener un método de dos pasos usando la regla de Simpson para la integral sobre el intervalo $[t_{n-1}, t_{n+1}]$. Estudiar la consistencia, la convergencia y determinar la región de estabilidad. Este método se conoce con el nombre de *Método de Milne*.

8.10. Dado el método explícito de dos pasos

$$Y_{n+1} = -4Y_n + 5Y_{n-1} + h[4f(t_n, Y_n) + 2f(t_{n-1}, Y_{n-1})], \quad \text{para } n = 1, \cdots, N-1$$

con valores iniciales Y_0 e Y_1.

(a) Demostrar que es consistente.

(b) Determinar el orden.

(c) Considerar la aplicación de este método multipaso al PVI

$$\begin{cases} y' = 0 = f(t, y) & 0 \leq t \leq 1 \\ y(0) = 0 \end{cases}$$

con

i) $Y_0 = Y_1 = 0$.

ii) $Y_0 = h^2, \quad Y_1 = -5h^2$.

Determinar Y_N en cada caso y notar que este debería ser una aproximación de $y(1) = 0$. ¿Converge el método? Explicar por qué esto no contradice el Teorema 8.28 visto en clase.

8.11. Resolver numéricamente el siguiente PVI

$$\begin{cases} \dfrac{dy}{dx} = -y^2, & 0 \leq x \leq 10, \\ y(0) = 1, \end{cases}$$

usando los métodos:

(a) Midpoint;

(b) Predictor-corrector: Euler-Trapecio;

(c) Predictor-corrector: Midpoint-Trapecio;

Sabiendo que la solución exacta es $y(x) = \frac{1}{1+x}$, determinar el orden experimental de convergencia de cada uno de los métodos propuestos. ¿Cree usted que algún método es mejor que otro? ¿Por qué?

8.12. Hallar la región de estabilidad del método predictor-corrector presentado en la Sección 8.6. Comparar con las regiones de AB3 y AM3.

8.13. Considerar el siguiente método predictor–corrector

$$Y_{n+1}^{(P)} = Y_n + \frac{h}{12}\left[23f(t_n, Y_n) - 16f(t_{n-1}, Y_{n-1}) + 5f(t_{n-2}, Y_{n-2})\right]$$
$$Y_{n+1} = Y_n + \frac{h}{24}\left[9f(t_{n+1}, Y_{n+1}^{(P)}) + 19f(t_n, Y_n) - 5f(t_{n-1}, Y_{n-1}) + f(t_{n-2}, Y_{n-2})\right]$$

(a) Determinar el orden de cada una de las fórmulas dadas.

(b) Aplicar el método predictor-corrector para determinar una aproximación a la solución del PVI

$$\begin{cases} y' = \dfrac{1}{1+t^2} - 2y^2, & 0 \le t \le 10, \\ y(0) = 0, \end{cases}$$

cuya solución exacta es $y(t) = t/(1+t^2)$. Considerar los valores iniciales exactos para comenzar con el método predictor y determinar empíricamente el orden del método predictor–corrector. Comparar con el orden teórico calculado en el item anterior.

8.14. Obtener las fórmulas BDF de dos, tres y cuatro pasos. Determinar el orden de cada una de ellas y graficar sus regiones de estabilidad.

Capítulo 9

Problemas a valores de borde

En este capítulo consideramos problemas de ecuaciones diferenciales de segundo orden donde las condiciones no se dan en un mismo punto, sino *en el borde* del dominio. Consideraremos intervalos en una dimensión y también dominios bidimensionales.

9.1 Problemas a valores en los extremos

En esta sección consideraremos problemas sobre intervalos de $\mathbb{R}$ con condiciones de borde que están *separadas*. Más precisamente, consideramos problemas como

$$\frac{d^2y}{dx^2} = f(x, y, \frac{dy}{dx}), \qquad x \in (a, b), \tag{9.1}$$

con alguno de los siguientes pares de condiciones de borde *separadas*:

(i) $y(a) = \alpha$, $y(b) = \beta$;

(ii) $y(a) = \alpha$, $\frac{dy}{dx}(b) = \tilde{\beta}$;

(iii) $\frac{dy}{dx}(a) = \tilde{\alpha}$, $y(b) = \beta$;

(iv) $\frac{dy}{dx}(a) = \tilde{\alpha}$, $\frac{dy}{dx}(b) = \tilde{\beta}$;

con α y β dados.

Observación 9.1. Cuando hemos considerado problemas a valores iniciales, los datos están dados en un solo punto. Si tenemos una EDO de orden dos y prescribimos el valor de y y $\frac{dy}{dx}$ en un mismo punto, la solución es única (bajo la hipótesis de Lipschitzidad, por supuesto). En cambio, si prescribimos valores de y y/o $\frac{dy}{dx}$ en diferentes puntos, la teoría es un poco más complicada.

Ejemplo 9.2. Consideremos el problema a valores de borde (PVB) siguiente:

$$\frac{d^2y}{dx^2} = -\pi^2 y, \quad \text{en } (0,1), \qquad y(0) = 0, \quad y(1) = 0.$$

La función $y \equiv 0$ es solución, pero también $y(x) = \text{sen}(\pi x)$ es solución, y por ende hay infinitas soluciones. ¿Cuáles son? Este ejemplo es importante para saber que no es suficiente *tener dos condiciones* para garantizar unicidad.

Para problemas a valores de borde como los que consideramos aquí, no hay una teoría general para problemas no-lineales. Los estudios existentes se centran en diferentes clases de problemas no-lineales, y quedan fuera del alcance de este curso. Aquí consideraremos la siguiente familia de ecuaciones *lineales* de segundo orden:

$$-\frac{d^2y}{dx^2} + p(x)\frac{dy}{dx} + q(x)y = g(x), \qquad x \in (a,b), \tag{9.2}$$

con $p, q, g : [a,b] \to \mathbb{R}$ funciones continuas dadas.

Los siguientes teoremas que enunciamos sin demostración dan condiciones suficientes para la unicidad de soluciones.

Teorema 9.3. *Consideremos el problema (9.2) con condiciones de borde (i), (ii) o (iii) y supongamos que $q(x) \geq 0$ en $[a,b]$. Si el problema tiene solución, entonces es única.*

Observación 9.4. En el ejemplo anterior, con múltiples soluciones, $q(x) = -\pi^2 < 0$.

Teorema 9.5. *Consideremos el problema (9.2) con condiciones de borde (iv) y supongamos que $q(x) \geq 0$ en $[a,b]$ y que existe $x_0 \in [a,b]$ tal que $q(x_0) > 0$. Si el problema tiene solución, entonces es única.*

Observación 9.6. La hipótesis que exista x_0 tal que $q(x_0) > 0$ es necesaria. En efecto, supongamos que y es solución de

$$-\frac{d^2y}{dx^2} + p(x)\frac{dy}{dx} = g(x), \qquad \frac{dy}{dx}(a) = \tilde{\alpha}, \quad \frac{dy}{dx}(b) = \tilde{\beta}.$$

Entonces, para cualquier constante C, $u(x) = y(x) + C$ también es solución. Verificar.

9.2 Método de shooting o de disparo

Consideremos como ejemplo el problema

$$\begin{aligned} &\frac{d^2y}{dx^2} = f(x, y, \frac{dy}{dx}), \quad x \in (a,b), \\ &y(a) = \alpha, \quad y(b) = \beta. \end{aligned}$$

El método de shooting consiste en resolver un problema a valores iniciales y *ajustar* o *aproximar* la pendiente inicial para lograr que $y(b) = \beta$. Más precisamente, un método de shooting para este problema consiste en definir $r : \mathbb{R} \to \mathbb{R}$ como $r(t) = y^t(b) - \beta$, para $t \in \mathbb{R}$, donde y^t es solución del siguiente PVI

$$\begin{aligned} \frac{d^2y^t}{dx^2} &= f(x, y^t, \frac{dy^t}{dx}), \quad x \in (a,b), \\ y^t(a) &= \alpha, \\ \frac{dy^t}{dx}(a) &= t. \end{aligned}$$

El siguiente paso es hallar el valor de t tal que $r(t) = 0$, lo que puede aproximarse usando algún método numérico para (sistemas de) ecuaciones no-lineales. Es interesante notar

que si $f(x, y, \dot{y}) = p(x)\dot{y} + q(x)y - g(x)$ (es decir, la EDO es lineal), entonces la función $r(t)$ también es lineal, y el valor de t que logra $r(t) = 0$ puede hallarse calculando y^t solo dos veces.

Si resolvemos el PVI por un método numérico para PVI, con paso h, entonces obtenemos una función $r_h(t) = Y_h^t(b) - \beta$. El método entonces consiste en aplicar algún método iterativo para la solución de ecuaciones (no lineales) a la ecuación $r_h(t) = 0$. Aquí se ve la necesidad de contar con métodos que converjan en pocas iteraciones, y que necesiten pocas evaluaciones de la función $r_h(t)$, dado que la evaluación de $r_h(t)$ requiere del cálculo de la solución de un PVI en un intervalo.

Si bien la idea es interesante, los métodos de shooting no son muy utilizados en la práctica, y no pueden generalizarse a problemas a valores de borde en 2 y 3 dimensiones. Los métodos numéricos más utilizados para problemas a valores de borde son los métodos de *diferencias finitas* y los de *elementos finitos*.

9.3 Diferencias finitas para problemas a valores en los extremos

Consideremos el problema a valores de borde

$$\begin{aligned} -\frac{d^2y}{dx^2} + p(x)\frac{dy}{dx} + q(x)y = g(x), \quad x \in (a, b), \\ y(a) = \alpha, \quad y(b) = \beta. \end{aligned}$$

El método de diferencias finitas consiste en lo siguiente, particionar el intervalo $[a, b]$ en $N \in \mathbb{N}$ subintervalos de longitud $h := \frac{b-a}{N}$, y reemplazar las derivadas de la ecuación por *diferencias finitas*.

Sabemos que si h es pequeño entonces

$$\begin{aligned} \frac{dy}{dx}(x) &\approx \frac{y(x+h) - y(x)}{h} && \text{(diferencia adelantada)}, \\ \frac{dy}{dx}(x) &\approx \frac{y(x) - y(x-h)}{h} && \text{(diferencia atrasada)}, \\ \frac{dy}{dx}(x) &\approx \frac{y(x+h) - y(x-h)}{2h} && \text{(diferencia centrada)}, \end{aligned}$$

y también

$$\begin{aligned} \frac{d^2y}{dx^2}(x) &\approx \frac{\frac{dy}{dx}(x + \frac{h}{2}) - \frac{dy}{dx}(x - \frac{h}{2})}{h} \\ &\approx \frac{\frac{y(x+h)-y(x)}{h} - \frac{y(x)-y(x-h)}{h}}{h} && \text{(diferencia centrada)} \times 2 \\ &= \frac{y(x+h) - 2y(x) + y(x-h)}{h^2}. \end{aligned}$$

Si llamamos $x_i = a + ih$, $i = 0, 1, \ldots, N$ tenemos que

$$\begin{cases} \dfrac{-y(x_{i+1}) + 2y(x_i) - y(x_{i-1})}{h^2} + p(x_i)\dfrac{y(x_{i+1}) - y(x_{i-1})}{2h} + q(x_i)y(x_i) \approx g(x_i), \\ \qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad i = 1, 2, \ldots, N-1, \\ \qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad y(x_0) = y(a) = \alpha, \\ \qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad y(x_N) = y(b) = \beta. \end{cases}$$

Definimos entonces la solución aproximada $\{Y_i\}_{i=0}^N$, reemplazando $y(x_i)$ por Y_i y $\approx$ por $=$ en la expresión anterior:

$$\begin{cases} \dfrac{-Y_{i+1} + 2Y_i - Y_{i-1}}{h^2} + p(x_i)\dfrac{Y_{i+1} - Y_{i-1}}{2h} + q(x_i)Y_i = g(x_i), \\ \qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad i = 1, 2, \ldots, N-1, \\ \qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad Y_0 = \alpha, \\ \qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad Y_N = \beta. \end{cases} \tag{9.3}$$

Esto último resulta un sistema de $N+1$ ecuaciones con $N+1$ incógnitas $Y_0, Y_1, \ldots, Y_N$, que resultarán aproximaciones de $y(x_0), y(x_1), \ldots, y(x_N)$.

La implementación computacional consiste en armar el sistema lineal y resolverlo mediante algún método apropiado para dicho sistema. Denotando por p_i, q_i, g_i a $p(x_i)$, $q(x_i)$ y $g(x_i)$, respectivamente, el sistema resulta:

$$M_h \begin{bmatrix} Y_0 \\ Y_1 \\ \vdots \\ Y_{N-1} \\ Y_N \end{bmatrix} = \begin{bmatrix} \alpha \\ g_1 \\ g_2 \\ \vdots \\ g_{N-1} \\ \beta \end{bmatrix}, \tag{9.4a}$$

con

$$M_h = \begin{bmatrix} 1 & 0 & 0 & \ldots & \ldots & 0 \\ -\frac{1}{h^2} - \frac{p_1}{2h} & \frac{2}{h^2} + q_1 & -\frac{1}{h^2} + \frac{p_1}{2h} & 0 & \ldots & 0 \\ 0 & -\frac{1}{h^2} - \frac{p_2}{2h} & \frac{2}{h^2} + q_2 & -\frac{1}{h^2} + \frac{p_2}{2h} & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \ddots & 0 \\ 0 & \ldots & 0 & -\frac{1}{h^2} - \frac{p_{N-1}}{2h} & \frac{2}{h^2} + q_{N-1} & -\frac{1}{h^2} + \frac{p_{N-1}}{2h} \\ 0 & 0 & \ldots & \ldots & 0 & 1 \end{bmatrix} \tag{9.4b}$$

que es equivalente al sistema de $(N-1) \times (N-1)$ siguiente

$$\overline{M_h} \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_{N-2} \\ Y_{N-1} \end{bmatrix} = \begin{bmatrix} g_1 + \left(\frac{1}{h^2} + \frac{p_1}{2h}\right)\alpha \\ g_2 \\ \vdots \\ g_{N-2} \\ g_{N-1} + \left(\frac{1}{h^2} - \frac{p_{N-1}}{2h}\right)\beta \end{bmatrix} \tag{9.5a}$$

con

$$\overline{M_h} = \begin{bmatrix} \frac{2}{h^2}+q_1 & -\frac{1}{h^2}+\frac{p_1}{2h} & 0 & \dots & 0 \\ -\frac{1}{h^2}-\frac{p_2}{2h} & \frac{2}{h^2}+q_2 & -\frac{1}{h^2}+\frac{p_2}{2h} & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & -\frac{1}{h^2}-\frac{p_{N-1}}{2h} & \frac{2}{h^2}+q_{N-1} \end{bmatrix} \tag{9.5b}$$

y con

$$Y_0 = \alpha, \qquad Y_N = \beta. \tag{9.5c}$$

Vale la pena observar que la matriz $\overline{M_h}$ del sistema (9.5) será simétrica si $p \equiv 0$.

9.3.1 Estabilidad

Para ver que el sistema tiene solución y para el análisis del error cometido por el método numérico, lo que haremos es esencialmente acotar la inversa de la matriz M_h. Estudiaremos el caso más sencillo en que $q \geq \gamma > 0$ en $[a,b]$. El resultado es también válido si solo suponemos $q \geq 0$ en $[a,b]$ pero la demostración es más complicada, y queda fuera del alcance de este curso. Los interesados pueden encontrarla en la Sección 4.1 de [LT].

Teorema 9.7. *Sea M_h la matriz definida en (9.4) y supongamos que $q(x) \geq \gamma > 0$ para todo $x \in [a,b]$. Entonces, si $h \leq \frac{2}{\max_{[a,b]}|p|}$ y $e = (e_0, e_1, \dots, e_N)^T$ y $\tau = (\tau_0, \tau_1, \dots, \tau_N)^T$ satisfacen $M_h e = \tau$, resulta que*

$$\|e\|_\infty \leq \max\left\{1, \frac{1}{\gamma}\right\} \|\tau\|_\infty, \tag{9.6}$$

donde hemos denotado $\|v\|_\infty = \max_{0\leq i\leq N} |v_i|$.

Demostración. Supongamos que q, h, e y τ cumplen las hipótesis del teorema. Entonces

$$M_h \begin{bmatrix} e_0 \\ e_1 \\ \vdots \\ e_N \end{bmatrix} = \begin{bmatrix} \tau_0 \\ \tau_1 \\ \vdots \\ \tau_N \end{bmatrix},$$

que a su vez implica que $e_0 = \tau_0$, $e_N = \tau_N$ y

$$\Big(\frac{2}{h^2}+q_i\Big)e_i = \Big(\frac{p_i}{2h}+\frac{1}{h^2}\Big)e_{i-1} + \Big(-\frac{p_i}{2h}+\frac{1}{h^2}\Big)e_{i+1} + \tau_i, \qquad i = 1,2,\dots,N-1.$$

Por lo tanto

$$\Big(2+h^2q_i\Big)|e_i| \leq \Big(\Big|\frac{hp_i}{2}+1\Big|+\Big|-\frac{hp_i}{2}+1\Big|\Big)\max\{|e_{i-1}|,|e_{i+1}|\}+h^2|\tau_i|, \qquad i = 1,2,\dots,N-1.$$

Como $h \leq \dfrac{2}{\max_{[a,b]}|p|}$ resulta $\frac{h|p_i|}{2} \leq 1$ y entonces[1] $\big|\frac{hp_i}{2}+1\big| + \big|-\frac{hp_i}{2}+1\big| = 2$ y por lo tanto

$$\big(2+h^2q_i\big)|e_i| \leq 2\|e\|_\infty + h^2|\tau_i|, \qquad i = 1,2,\dots,N-1.$$

[1] Pues $|1+x|+|1-x| = 2$ para $|x| \leq 1$.

Como $q(x) \geq \gamma > 0$ para todo $x \in [a,b]$ resulta

$$\big(2+\gamma h^2\big)|e_i| \leq 2\|e\|_\infty + h^2\|\tau\|_\infty, \qquad i = 1, 2, \ldots, N-1.$$

Sea ahora i un índice tal que $\|e\|_\infty = |e_i|$. Pueden ocurrir dos casos:

(1) $i = 0$ o $i = N$. En este caso, $\|e\|_\infty = |e_i| = |\tau_i| \leq \|\tau\|_\infty$, es decir

$$\|e\|_\infty \leq \|\tau\|_\infty.$$

(2) $1 \leq i \leq N-1$. En este caso

$$\big(2+\gamma h^2\big)\|e\|_\infty = \big(2+\gamma h^2\big)|e_i| \leq 2\|e\|_\infty + h^2\|\tau\|_\infty,$$

y entonces $\gamma h^2\|e\|_\infty \leq h^2\|\tau\|_\infty$ que implica

$$\|e\|_\infty \leq \frac{1}{\gamma}\|\tau\|_\infty.$$

Resumiendo, siempre se cumple que $\|e\|_\infty \leq \|\tau\|_\infty$ o $\|e\|_\infty \leq \frac{1}{\gamma}\|\tau\|_\infty$, y esto es equivalente a (9.6), que es lo que se quería demostrar. □

Observación 9.8. Si $p \equiv 0$ el resultado del teorema anterior vale para todo $h > 0$.

La cota (9.6) es un resultado de *estabilidad* pues acota la solución e en términos del lado derecho τ y lo más importante, es que la cota *no depende del parámetro de discretización* h.

La existencia de solución es consecuencia de la estabilidad, en efecto, tenemos el siguiente corolario.

Corolario 9.9. *Sea M_h la matriz definida en (9.4) y supongamos que $q(x) \geq \gamma > 0$ para todo $x \in [a,b]$. Entonces, si $h \leq \frac{2}{\max_{[a,b]}|p|}$, existe una única solución $\{Y_i\}_{i=0}^N$ de (9.4), que además cumple*

$$\max_{0\leq i\leq N}|Y_i| \leq \max\left\{1, \frac{1}{\gamma}\right\} \max\{|\alpha|, |\beta|, \max_{[a,b]}|g|\}.$$

Demostración. Para ver que el sistema tiene solución para cualquier α, β y g basta ver que la única solución del problema homogéneo es la trivial. Esta última afirmación se sigue del Teorema 9.7, pues $\tau = 0$ implica $e = 0$. La acotación es también consecuencia del mismo teorema, aplicado a $\tau = [\alpha\ g_1\ g_2 \ldots\ g_{N-1}\ \beta]^T$. □

9.3.2 Análisis del error

Las fórmulas de diferencias finitas que hemos utilizado en la obtención del método cumplen las siguientes identidades para algún ξ:

$$\begin{aligned}
\frac{dy}{dx}(x) &= \frac{y(x+h)-y(x)}{h} + \frac{h}{2}\frac{d^2y}{dx^2}(\xi) && \text{si } y \text{ es } C^2,\\
\frac{dy}{dx}(x) &= \frac{y(x)-y(x-h)}{h} + \frac{h}{2}\frac{d^2y}{dx^2}(\xi) && \text{si } y \text{ es } C^2,\\
\frac{dy}{dx}(x) &= \frac{y(x+h)-y(x-h)}{2h} + \frac{h^2}{6}\frac{d^3y}{dx^3}(\xi) && \text{si } y \text{ es } C^3,\\
\frac{d^2y}{dx^2}(x) &= \frac{y(x+h)-2y(x)+y(x-h)}{h^2} + \frac{h^2}{12}\frac{d^4y}{dx^4}(\xi) && \text{si } y \text{ es } C^4.
\end{aligned}$$

Luego, si definimos el vector *error*

$$e = \begin{bmatrix} y(x_0) - Y_0 \\ y(x_1) - Y_1 \\ \vdots \\ y(x_{N-1}) - Y_{N-1} \\ y(x_N) - Y_N \end{bmatrix}$$

resulta que

$$M_h e = \begin{bmatrix} \tau_0^h \\ \tau_1^h \\ \vdots \\ \tau_N^h \end{bmatrix} =: \tau^h,$$

con $\tau_0^h = 0$, $\tau_N^h = 0$,

$$\tau_i^h = -\frac{h^2}{12}\frac{d^4y}{dx^4}(\xi_i) + p(x_i)\frac{h^2}{6}\frac{d^3y}{dx^3}(\eta_i), \quad \text{para algún } \xi_i, \eta_i \in [a,b], \quad i = 1, 2, \ldots, N-1.$$

En consecuencia, $\|\tau^h\|_\infty \leq Ch^2$ con C una constante que depende de las derivadas hasta orden cuatro de la solución exacta y y del coeficiente p de la ecuación diferencial.

Como consecuencia del Teorema 9.7 obtenemos que

Corolario 9.10. *Supongamos que $q(x) \geq \gamma > 0$ para todo $x \in [a,b]$ y que $h \leq 2/\max_{[a,b]} |p|$. Entonces existe una única solución $\{Y_i\}_{i=0}^N$ de (9.4), que cumple*

$$\max_{0 \leq i \leq N} |y(x_i) - Y_i| \leq Ch^2,$$

con C una constante que depende de las derivadas hasta orden cuatro de la solución exacta y, de γ y del coeficiente p.

9.3.3 Condición de borde para la derivada

Consideremos el problema a valores de borde

$$-\frac{d^2y}{dx^2} + p(x)\frac{dy}{dx} + q(x)y = g(x), \quad x \in (a,b),$$
$$\frac{dy}{dx}(a) = 0, \quad y(b) = \beta.$$

La diferencia con el problema que hemos estado estudiando se encuentra en la condición de borde en $x = a$ donde se prescribe el valor de $\frac{dy}{dx}(a)$ en lugar del valor de $y(a)$. Para fijar ideas supondremos que se prescribe el valor cero. Nos preguntamos de qué manera puede introducirse esta condición en el sistema. Hay varias y solo veremos dos de ellas:

(1) Utilizando diferencias adelantadas.

(2) Utilizando diferencias centradas.

Utilizando diferencias adelantadas.

Esta manera es la más sencilla y natural. Dado que la función está definida a la derecha de $x = a$, parece natural utilizar la aproximación

$$\frac{dy}{dx}(a) \approx \frac{y(x_1) - y(x_0)}{h},$$

e imponer en (9.3) la ecuación $\frac{Y_1 - Y_0}{h} = 0$ en lugar de $Y_0 = \alpha$. El problema es que el error de truncamiento de esta primera ecuación es de orden $O(h)$ pues

$$\frac{dy}{dx}(a) = \frac{y(x_1) - y(x_0)}{h} + \frac{h}{2}\frac{d^2y}{dx^2}(\xi), \quad \text{si } y \in C^2.$$

Este error hará que el error (global) del método sea $O(h)$ solo por culpa de la aplicación de esta condición de borde.

Utilizando diferencias centradas.

Esta manera es un poco anti-natural, pero es más precisa que la anterior. La idea es utilizar diferencias centradas, a través de la aproximación

$$\frac{dy}{dx}(a) = \frac{y(a+h) - y(a-h)}{2h} + \frac{h^2}{6}\frac{d^3y}{dx^3}(\xi), \quad \text{si } y \in C^3.$$

Lo bueno de esta opción es que el error de truncamiento de la condición de borde es $O(h^2)$. Lo aparentemente complicado es la aparición del punto $x_{-1} := a - h$ que cae fuera del dominio, y se denomina *nodo ficticio* de la partición. Como agregamos un nodo y eliminamos una ecuación ($Y_0 = \alpha$) debemos agregar dos ecuaciones. La primera que agregamos es la que representa la condición de borde $\frac{dy}{dx}(a) = 0$, y es

$$Y_{-1} - Y_1 = 0.$$

Como ahora el borde se *trasladó* hacia la izquierda, el $a = x_0$ es como un *nodo interior*, y entonces imponemos sobre él la ecuación diferencial, a través de

$$\frac{-Y_1 + 2Y_0 - Y_{-1}}{h^2} + p(x_0)\frac{Y_1 - Y_{-1}}{2h} + q(x_0)Y_0 = g(x_0).$$

Notamos que si usamos la primera de estas ecuaciones para reemplazar Y_{-1} por Y_1 en la segunda, podemos ignorar directamente Y_{-1} y solo tenemos que cambiar en (9.3) la ecuación $Y_0 = \alpha$ por

$$\frac{2Y_0 - 2Y_1}{h^2} + q(x_0)Y_0 = g(x_0).$$

El análisis de error para estos casos es similar al anterior y se deja como ejercicio.

9.4 Diferencias finitas en dos dimensiones

El método de diferencias finitas se extiende naturalmente a dominios bidimensionales de forma rectangular o que sean uniones finitas de rectángulos, y el análisis puede hacerse

de manera similar. Lo complicado es numerar los nodos con un solo índice, y encontrar la manera automática de armar la matriz del sistema, pero pensando un poco es posible.

Consideremos el problema modelo sobre el dominio $\Omega = (0,1) \times (0,1) \subset \mathbb{R}^2$ que consiste en hallar $u = u(x,y)$, $u : \bar{\Omega} \to \mathbb{R}$ tal que

$$\begin{aligned} -\Delta u + p(x,y) \cdot \nabla u + q(x,y)u &= g(x,y), && (x,y) \in \Omega, \\ u(x,y) &= \alpha(x,y), && (x,y) \in \partial\Omega. \end{aligned} \tag{9.7}$$

Aquí suponemos que $p : \bar{\Omega} \to \mathbb{R}^2$ y $q, g : \bar{\Omega} \to \mathbb{R}$ son funciones continuas.

Dado $N \in \mathbb{N}$, definimos $h = 1/N$ y $x_i = ih$, $y_j = jh$ $i, j = 0, 1, \ldots, N$, y resulta, denotando $u_{i,j} = u(x_i, y_j)$,

$$\begin{aligned} \Delta u(x_i, y_j) &= \frac{\partial^2 u}{\partial x^2}(x_i, y_j) + \frac{\partial^2 u}{\partial y^2}(x_i, y_j) \\ &= \frac{u_{i+1,j} - 2u_{i,j} + u_{i-1,j}}{h^2} + \frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,j}, y_j) + \frac{u_{i,j+1} - 2u_{i,j} + u_{i,j-1}}{h^2} + \frac{h^2}{12}\frac{\partial^4 u}{\partial y^4}(x_i, \eta_{i,j}) \\ &= \frac{u_{i+1,j} + u_{i,j+1} - 4u_{i,j} + u_{i-1,j} + u_{i,j-1}}{h^2} + \frac{h^2}{12}\left[\frac{\partial^4 u}{\partial x^4}(\xi_{i,j}, y_j) + \frac{\partial^4 u}{\partial y^4}(x_i, \eta_{i,j})\right] \end{aligned}$$

Para las derivadas parciales de primer orden tenemos, igual que antes,

$$\begin{aligned} \frac{\partial u}{\partial x}(x_i, y_j) &= \frac{u_{i+1,j} - u_{i-1,j}}{2h} + \frac{h^2}{6}\frac{\partial^3 u}{\partial x^3}(\xi^{i,j}, y_j), \\ \frac{\partial u}{\partial y}(x_i, y_j) &= \frac{u_{i,j+1} - u_{i,j-1}}{2h} + \frac{h^2}{6}\frac{\partial^3 u}{\partial y^3}(x_i, \eta^{i,j}). \end{aligned}$$

Por lo tanto, si la solución $u(x,y)$ de (9.7) es C^4 en $\bar{\Omega}$, satisface

$$\begin{aligned} &\frac{-u_{i+1,j} - u_{i,j+1} + 4u_{i,j} - u_{i-1,j} - u_{i,j-1}}{h^2} \\ &+ p^1_{i,j}\frac{u_{i+1,j} - u_{i-1,j}}{2h} + p^2_{i,j}\frac{u_{i,j+1} - u_{i,j-1}}{2h} + q_{i,j}u_{i,j} = g_{i,j} + O(h^2) \end{aligned}$$

para $i, j = 1, 2, \ldots, N-1$. Aquí p^1, p^2 denotan las componentes del campo vectorial p y $p^{(k)}_{i,j}$, $q_{i,j}$, $g_{i,j}$ denotan la evaluación de $p^{(k)}$, q y g en (x_i, y_j), respectivamente.

A partir de estas expresiones, definimos $U_{i,j}$, aproximaciones de $u_{i,j}$ a través de las siguientes igualdades:

$$\begin{aligned} &\frac{-U_{i+1,j} - U_{i,j+1} + 4U_{i,j} - U_{i-1,j} - U_{i,j-1}}{h^2} \\ &+ p^{(1)}_{i,j}\frac{U_{i+1,j} - U_{i-1,j}}{2h} + p^{(2)}_{i,j}\frac{U_{i,j+1} - U_{i,j-1}}{2h} \\ &+ q_{i,j}U_{i,j} = g_{i,j}, && i, j = 1, 2, \ldots, N-1, \\ &U_{0,j} = \alpha(0, y_j), \quad U_{N,j} = \alpha(1, y_j), && j = 0, 1, \ldots, N, \\ &U_{i,0} = \alpha(x_i, 0), \quad U_{i,N} = \alpha(x_i, 1), && i = 0, 1, \ldots, N. \end{aligned} \tag{9.8}$$

Esto resulta en un sistema de $(N+1)^2$ ecuaciones lineales con $(N+1)^2$ incógnitas.

Procediendo como en el Teorema 9.7 se demuestra que si h es suficientemente pequeño, el sistema tiene solución única y además se cumple que

$$\max_{0\le i,j\le N} |u(x_i, y_j) - U_{i,j}| \le Ch^2,$$

con C una constante que depende de derivadas de hasta orden cuatro de u y de los coeficientes $p(x, y)$, $q(x, y)$ de la EDP.

Observación 9.11. Para implementarlo debemos numerar los nodos e incógnitas con un solo índice, por ejemplo $k = (i-1)(N+1)+j$. Al hacer esto, el sistema resulta con una matriz pentadiagonal en lugar de tridiagonal.

9.5 Elementos finitos para problemas a valores de borde

Consideremos el problema a valores de borde

$$\begin{aligned} -\frac{d^2y}{dx^2} + p(x)\frac{dy}{dx} + q(x)y = g(x), \quad x \in (a,b), \\ y(a) = 0, \quad \frac{dy}{dx}(b) = 0. \end{aligned} \tag{9.9}$$

9.5.1 Formulación débil

Comenzamos observando lo siguiente: si y es una solución y v es una función perteneciente al espacio $\mathbb{V}$, con

$$\mathbb{V} = \{v \in C^0[a,b] : v \text{ es } C^1 \text{ a trozos y } v(a) = 0\},$$

entonces, integrando por partes obtenemos

$$\begin{aligned} \int_a^b -\frac{d^2y}{dx^2} v\,dx &= -\frac{dy}{dx}v\Big|_a^b + \int_a^b \frac{dy}{dx}\frac{dv}{dx}\,dx \\ &= \frac{dy}{dx}(a)\underbrace{v(a)}_{=0} - \underbrace{\frac{dy}{dx}(b)}\,v(b) + \int_a^b \frac{dy}{dx}\frac{dv}{dx}\,dx \\ &= \int_a^b \frac{dy}{dx}\frac{dv}{dx}\,dx. \end{aligned}$$

Por lo tanto, si y es una solución de (9.9), resulta que

$$y \in \mathbb{V}: \quad \int_a^b \frac{dy}{dx}\frac{dv}{dx} + p\frac{dy}{dx}v + qyv\,dx = \int_a^b gv, \quad \forall v \in \mathbb{V}. \tag{9.10}$$

Si definimos $B : \mathbb{V}\times\mathbb{V} \to \mathbb{R}$ por

$$B[v,w] = \int_a^b \frac{dv}{dx}\frac{dw}{dx} + p\frac{dv}{dx}w + qvw\,dx, \quad v, w \in \mathbb{V},$$

resulta una *forma bilineal*, es decir,

- $B[\lambda_1 v_1 + \lambda_2 v_2, w] = \lambda_1 B[v_1, w] + \lambda_2 B[v_2, w]$ para $\lambda_1, \lambda_2 \in \mathbb{R}$ y $v_1, v_2, w \in \mathbb{V}$.
- $B[v, \lambda_1 w_1 + \lambda_2 w_2] = \lambda_1 B[v, w_1] + \lambda_2 B[v, w_2]$ para $\lambda_1, \lambda_2 \in \mathbb{R}$ y $v, w_1, w_2 \in \mathbb{V}$.

Si definimos el *funcional* $\ell : \mathbb{V} \to \mathbb{R}$ como

$$\ell(v) = \int_a^b g(x)v(x)\,dx, \qquad v \in \mathbb{V},$$

este resulta *lineal*, pues

$$\ell(\lambda_1 v_1 + \lambda_2 v_2) = \lambda_1 \ell(v_1) + \lambda_2 \ell(v_2), \qquad \text{para } \lambda_1, \lambda_2 \in \mathbb{R} \text{ y } v_1, v_2 \in \mathbb{V}.$$

La ecuación (9.10) puede entonces escribirse como

$$y \in \mathbb{V} : \qquad B[y, v] = \ell(v), \quad \forall v \in \mathbb{V}. \tag{9.11}$$

Tanto (9.10) como su formulación equivalente (9.11) son formulaciones *débiles* de la ecuación (9.9). Es importante destacar que la formulación débil no plantea la búsqueda de una función y sobre $[a, b]$ que cumpla cierta propiedad en cada punto del intervalo $[a, b]$ (que son infinitos). En lugar de eso plantea hallar una función y definida en $[a, b]$ que cumpla una identidad integral, para muchas (infinitas) funciones de prueba v.

9.5.2 Aproximación de Galerkin

El método de elementos finitos se basa en las *aproximaciones de Galerkin*, que se definen como sigue: considerar un subespacio $\mathbb{V}_h$ de dimensión finita del espacio $\mathbb{V}$, y definir la aproximación de Galerkin Y por

$$Y \in \mathbb{V}_h : \qquad B[Y, V] = \ell(V), \quad \forall V \in \mathbb{V}_h. \tag{9.12}$$

Es decir, la aproximación de Galerkin se obtiene resolviendo el mismo tipo de problema, cambiando solamente el espacio por uno de dimensión finita, con la esperanza de que el mismo pueda calcularse en tiempo finito.

Sea $\{\phi_1, \phi_2, \ldots, \phi_N\}$ una base del espacio $\mathbb{V}_h$ de dimensión finita N. Entonces, como $B[\cdot, \cdot]$ es bilineal y ℓ es lineal, el problema es equivalente a:

$$Y \in \mathbb{V}_h : \qquad B[Y, \phi_i] = \ell(\phi_i), \quad i = 1, 2, \ldots, N.$$

Además, si existe tal solución Y se tiene que escribir como

$$Y(x) = \sum_{j=1}^{N} Y_j \phi_j(x),$$

para ciertos valores $Y_j \in \mathbb{R}$, $j = 1, 2, \ldots, N$.

Por lo tanto, la solución de (9.12) existe si y solo si existe solución $\bar{Y} = [Y_1\ Y_2\ \ldots Y_N]^T$ del sistema

$$B\Big[\sum_{j=1}^{N} Y_j \phi_j, \phi_i\Big] = \ell(\phi_i), \quad i = 1, 2, \ldots, N,$$

que, nuevamente por la bilinealidad de $B[\cdot,\cdot]$ es equivalente al sistema

$$\sum_{j=1}^{N} Y_j B[\phi_j, \phi_i] = \ell(\phi_i), \quad i = 1, 2, \ldots, N.$$

En forma matricial, el sistema se escribe como

$$K\bar{Y} = \bar{F}, \qquad \text{con } K_{ij} = B[\phi_j, \phi_i], \quad \text{y } F_i = \ell(\phi_i), \quad i, j = 1, 2, \ldots, N. \tag{9.13}$$

Para fijar ideas, consideraremos de ahora en adelante el caso particular en que $p \equiv 0$ y $q(x) \geq \gamma > 0$, $x \in [a, b]$. En ese caso resulta que la forma bilineal es, además simétrica

$$B[v, w] = B[w, v], \qquad v, w \in \mathbb{V},$$

y *coercitiva*

$$B[v, v] = \int_a^b \left(\frac{dv}{dx}\right)^2 + q(x)v^2\, dx =: \|v\|_{\mathbb{V}}^2 \geq \int_a^b \left(\frac{dv}{dx}\right)^2 + \gamma v^2\, dx \geq 0, \quad v \in \mathbb{V}. \tag{9.14}$$

Esto implica que la matriz K es *simétrica*, pues $K_{ij} = B[\phi_j, \phi_i] = B[\phi_i, \phi_j] = K_{ji}$. Para $\bar{V} \in \mathbb{R}^N$, resulta que

$$\bar{V}^T K \bar{V} = \sum_{i,j=1}^{N} V_i V_j B[\phi_j, \phi_i] = \sum_{i,j=1}^{N} B[V_j\phi_j, V_i\phi_i] = B\Big[\sum_{j=1}^{N} V_j\phi_j, \sum_{i=1}^{N} V_i\phi_i\Big] = B[V, V] = \|V\|_{\mathbb{V}}^2,$$

si $V(x) = \sum_{j=1}^{N} V_j\phi_j(x)$. Por lo tanto K es también *definida positiva* y en consecuencia *invertible*. Hemos demostrado entonces el siguiente teorema.

Teorema 9.12. *Supongamos que $q(x) \geq \gamma > 0$ en $[a, b]$ y que la forma bilineal $B : \mathbb{V} \times \mathbb{V} \to \mathbb{R}$ y el funcional lineal $\ell : \mathbb{V} \to \mathbb{R}$ están definidos por*

$$B[v, w] = \int_a^b \frac{dv}{dx}\frac{dw}{dx} + qvw\, dx, \quad \ell(v) = \int_a^b gv\, dx,$$

para $v, w \in \mathbb{V}$. Entonces, cualquiera sea el espacio de dimensión finita $\mathbb{V}_h \subset \mathbb{V}$ existe una única aproximación de Galerkin Y definida por

$$Y \in \mathbb{V}_h : \qquad B[Y, V] = \ell(V), \quad V \in \mathbb{V}_h.$$

Como ya mencionamos, estamos considerando el caso particular de ecuación en que $p \equiv 0$ y $q(x) \geq \gamma > 0$ en $[a, b]$. En este caso, $B[v, w]$ es un producto escalar en $\mathbb{V}$, $\mathbb{V}_h$, que además genera la norma $\|\cdot\|_{\mathbb{V}}$ definida en (9.14). Por esta razón, la aproximación de Galerkin da una aproximación óptima de la solución exacta y.

Teorema 9.13. *Bajo las hipótesis del Teorema 9.12, la aproximación de Galerkin Y es una aproximación óptima de y en el siguiente sentido:*

$$\|y - Y\|_{\mathbb{V}} = \min_{V \in \mathbb{V}_h} \|y - V\|_{\mathbb{V}}.$$

Demostración. Sea y la solución de (9.11) y Y la solución de (9.12), entonces, para $V \in \mathbb{V}_h \subset \mathbb{V}$ se cumple que

$$\left.\begin{aligned} B[y,V] &= \ell(V) \\ B[Y,V] &= \ell(V) \end{aligned}\right\} \quad \Longrightarrow \quad B[y-Y,V] = 0.$$

Es decir, el error $y - Y$ es ortogonal al espacio de dimensión finita $\mathbb{V}_h$; esta propiedad se conoce como *ortogonalidad de Galerkin*. En otras palabras, Y es la *proyección ortogonal* de la solución exacta y sobre el espacio de aproximación $\mathbb{V}_h$, y por lo tanto será la función de $\mathbb{V}_h$ más cercana a y en la norma correspondiente al producto escalar en el que vale la ortogonalidad. Más precisamente, cualquiera sea $V \in \mathbb{V}_h$,

$$\|y-Y\|_{\mathbb{V}}^2 = B[y-Y,y-Y] = B[y-Y,y-V] + \underbrace{B[y-Y,V-Y]}_{=0} \leq \|y-Y\|_{\mathbb{V}}\|y-V\|_{\mathbb{V}},$$

la última desigualdad es la de Cauchy-Schwarz, que vale porque la norma $\|\cdot\|_{\mathbb{V}}$ es la generada por el producto escalar $B[\cdot,\cdot]$. Resumiendo, tenemos que, cualquiera sea $V \in \mathbb{V}_h$,

$$\|y-Y\|_{\mathbb{V}}^2 \leq \|y-Y\|_{\mathbb{V}}\|y-V\|_{\mathbb{V}} \quad \Longrightarrow \quad \|y-Y\|_{\mathbb{V}} \leq \|y-V\|_{\mathbb{V}}.$$

Luego, $\|y-Y\|_{\mathbb{V}} \leq \min\limits_{V\in\mathbb{V}_h} \|y-V\|_{\mathbb{V}}$ y como $Y \in \mathbb{V}_h$, vale la igualdad. □

El último teorema nos dice que la aproximación de Galerkin es la mejor aproximación desde el espacio de dimensión finita $\mathbb{V}_h$, pero no nos da una medida de el error. Para poder cuantificar el error hace falta precisar qué espacio estamos considerando. Hay muchas posibilidades, pero los más usados, por varios motivos, son los espacios de *elementos finitos*.

9.5.3 Elementos finitos

Esencialmente los espacios de elementos finitos son los que se obtienen particionando el dominio en un *número finito de elementos*, que en una dimensión son intervalos y en más dimensiones pueden ser triángulos/tetraedros, o también cuadriláteros/hexaedros.

Consideraremos los elementos finitos de Lagrange, que se definen como sigue, en dimensión 1. Tomemos una partición $a = x_0 < x_1 < \cdots < x_N = b$ del intervalo $[a,b]$ y llamemos $h = \max\limits_{1\leq i\leq N} \underbrace{x_i - x_{i-1}}_{h_i}$. El parámetro h es un indicador de cuán fina es la partición, y lo usaremos también como subíndice del espacio obtenido. Definimos el espacio de elementos finitos de Lagrange de grado $r \in \mathbb{N}$ como

$$\begin{aligned} \mathbb{V}_h^r &= \{V \in C^0[a,b] : V\big|_{[x_{i-1},x_i]} \in \mathcal{P}_r, i = 1,2,\ldots,N\} \cap \mathbb{V} \\ &= \{V \in C^0[a,b] : V\big|_{[x_{i-1},x_i]} \in \mathcal{P}_r, i = 1,2,\ldots,N \text{ y } V(a) = 0\}. \end{aligned} \tag{9.15}$$

Es decir, $\mathbb{V}_h^r$ es el conjunto de funciones continuas en $[a,b]$ que cumplen la condición de borde (esencial) de valer cero en $x = a$ y que restringidas a cada subintervalo de la partición, son polinomios de grado $\leq r$.

Fijada la partición y el grado polinomial, la solución discreta se define como la función Y que cumple

$$Y \in \mathbb{V}_h^r : \qquad B[Y, V] = \ell(V), \quad \forall V \in \mathbb{V}_h.$$

Para calcularla, debemos definir una base, y luego ensamblar la matriz K y el lado derecho $\bar{F}$ de (9.13).

Consideremos el caso $r = 1$ de elementos lineales a trozos. Se define la *base nodal* como la base de funciones $\phi_i \in \mathbb{V}_h = \mathbb{V}_h^1$, $i = 1, 2, \ldots, N$, que cumplen

$$\phi_i(x_j) = \delta_{ij} = \begin{cases} 1 & \text{si } i = j, \\ 0, & \text{si } i \neq j. \end{cases}$$

Con esta definición, el *soporte* de la función de base ϕ_i es el intervalo $[x_{i-1}, x_{i+1}]$ para $i = 1, 2, \ldots, N-1$ y el soporte de ϕ_N es $[x_{N-1}, x_N] = [x_{N-1}, b]$.

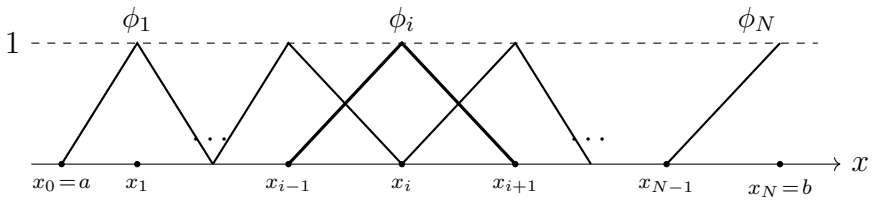


Figura 9.1 Funciones de la base nodal para elementos finitos lineales a trozos ($r = 1$). Cada ϕ_i vale 1 en el nodo x_i y 0 en los demás nodos, y su soporte es $[x_{i-1}, x_{i+1}]$. En el borde de Neumann $x_N = b$, la función ϕ_N es un "medio sombrero" de soporte $[x_{N-1}, x_N]$. No hay función de base asociada al nodo $x_0 = a$ debido a la condición de Dirichlet.

De esta manera, $|\operatorname{sop}(\phi_i) \cap \operatorname{sop}(\phi_j)| = 0$ si $|i - j| > 1$ y esto implica que

$$K_{ij} = \int_a^b \frac{d\phi_j}{dx}\frac{d\phi_i}{dx} + q\phi_j\phi_i\, dx = \int_{\operatorname{sop}(\phi_i)\cap\operatorname{sop}(\phi_j)} \frac{d\phi_j}{dx}\frac{d\phi_i}{dx} + q\phi_j\phi_i\, dx = 0, \quad \text{si } |i-j| > 1,$$

que a su vez nos dice que la matriz será tridiagonal.

Ensamblado de la matriz y el lado derecho

Veremos ahora cuánto valen las componentes K_{ij} y las F_i de la matriz K del sistema a resolver y del lado derecho $\bar{F}$, considerando elementos finitos *lineales*, es decir $r = 1$.

Ya vimos que $K_{ij} = 0$ si $|i - j| \geq 2$, por lo tanto, para cada $i = 1, 2, \ldots, N$ debemos calcular $K_{i,i-1}$, $K_{i,i}$ y $K_{i,i+1}$.

Para $i = 2, 3, \ldots, N$,

$$\begin{aligned} K_{i,i-1} &= \int_a^b \frac{d\phi_{i-1}}{dx}\frac{d\phi_i}{dx} + q\phi_{i-1}\phi_i\, dx \\ &= \int_{x_{i-1}}^{x_i} \frac{d\phi_{i-1}}{dx}\frac{d\phi_i}{dx}\, dx + \int_{x_{i-1}}^{x_i} q\phi_{i-1}\phi_i\, dx \end{aligned}$$

Ahora calculemos las integrales. Como estamos considerando elementos lineales, las derivadas de ϕ_{i-1}, ϕ_i son constantes sobre cada intervalo $[x_{i-1}, x_i]$ y

$$\frac{d\phi_{i-1}}{dx} = -\frac{1}{h_i}, \qquad \frac{d\phi_i}{dx} = \frac{1}{h_i}.$$

Por lo tanto

$$\int_{x_{i-1}}^{x_i} \frac{d\phi_{i-1}}{dx}\frac{d\phi_i}{dx} = h_i\Big(-\frac{1}{h_i}\Big)\frac{1}{h_i} = -\frac{1}{h_i}.$$

Para calcular la otra integral, utilizamos la regla de Simpson, que será exacta para q constante sobre $[x_{i-1}, x_i]$, llamando $m_i = \frac{x_{i-1}+x_i}{2}$ al punto medio de $[x_{i-1}, x_i]$ tenemos:

$$\int_{x_{i-1}}^{x_i} q\phi_{i-1}\phi_i\,dx \approx \frac{h_i}{6}\Big[q(x_{i-1})\underbrace{\phi_{i-1}(x_{i-1})}_{=1}\underbrace{\phi_i(x_{i-1})}_{=0} + 4q(m_i)\underbrace{\phi_{i-1}(m_i)}_{=1/2}\underbrace{\phi_i(m_i)}_{=1/2} + q(x_i)\underbrace{\phi_{i-1}(x_i)}_{=0}\underbrace{\phi_i(x_i)}_{=1}\Big]$$
$$= \frac{h_i}{6}q(m_i).$$

Recordando que K es simétrica, tenemos que

$$K_{i-1,i} = K_{i,i-1} = -\frac{1}{h_i} + \frac{q(m_i)h_i}{6}, \qquad i = 2, 3, \ldots, N.$$

Para calcular los elementos que están sobre la diagonal, observamos que para $i = 1, 2, \ldots, N$,

$$K_{i,i} = \int_a^b \frac{d\phi_i}{dx}\frac{d\phi_i}{dx} + q\phi_i\phi_i\,dx = \int_{x_{i-1}}^{x_{i+1}} \frac{d\phi_i}{dx}\frac{d\phi_i}{dx} + q\phi_i\phi_i\,dx$$
$$= \int_{x_{i-1}}^{x_i} \frac{d\phi_i}{dx}\frac{d\phi_i}{dx} + q\phi_i\phi_i\,dx + \int_{x_i}^{x_{i+1}} \frac{d\phi_i}{dx}\frac{d\phi_i}{dx} + q\phi_i\phi_i\,dx.$$

Luego, haciendo cálculos análogos a los que hicimos en el párrafo anterior obtenemos

$$K_{i,i} = \Big[\frac{1}{h_i} + \frac{1}{h_{i+1}}\Big] + \frac{1}{6}\Big[h_i q(m_i) + (h_i + h_{i+1})q(x_i) + h_{i+1}q(m_{i+1})\Big],$$

para $i = 1, 2, \ldots, N-1$, y

$$K_{N,N} \approx \frac{1}{h_N} + \frac{1}{6}\Big[h_N q(m_N) + h_N q(x_N)\Big].$$

El lado derecho $\bar{F}$ tiene componentes

$$F_i = \ell(\phi_i) = \int_a^b g\phi_i\,dx = \int_{x_{i-1}}^{x_{i+1}} g\phi_i\,dx = \int_{x_{i-1}}^{x_i} g\phi_i\,dx + \int_{x_i}^{x_{i+1}} g\phi_i\,dx,$$

y usando la regla de Simpson para las integrales obtenemos

$$F_i \approx \frac{1}{6}\Big[2h_i g(m_i) + (h_i + h_{i+1})g(x_i) + 2h_{i+1}g(m_{i+1})\Big],$$

para $i = 1, 2, \ldots, N-1$, y

$$F_N \approx \frac{1}{6}\Big[2h_N g(m_N) + h_N g(x_N)\Big].$$

9.5.4 Análisis del error

El análisis del error es muy sencillo una vez que se tiene el resultado de optimalidad del Teorema 9.13. En efecto, como $\|u-U\|_{\mathbb{V}} \le \|u-V\|_{\mathbb{V}}$ para toda $V \in \mathbb{V}_h^r$ entonces

$$\|u-U\|_{\mathbb{V}} \le \|u-\bar{U}\|_{\mathbb{V}},$$

si $\bar{U} \in \mathbb{V}_h^r$ es la *interpolada de Lagrange de* u. La interpolada de Lagrange de u es la función $\bar{U} \in \mathbb{V}_h^r$ que cumple:

$$\bar{U}\big(x_{i-1}+\frac{j}{r}(x_i-x_{i-1})\big) = u\big(x_{i-1}+\frac{j}{r}(x_i-x_{i-1})\big), \qquad 0 \le j \le r, \quad i=1,2,\ldots,N.$$

Es decir:

- Si $r=1$, $\bar{U}$ es la función lineal a trozos sobre la partición, que coincide con u en los *nodos* x_i de la partición.
- Si $r=2$, $\bar{U}$ es la función *cuadrática* a trozos sobre la partición, que coincide con u en los *nodos* x_i de la partición y en los puntos medios de cada subintervalo $[x_{i-1},x_i]$.
- Para $r \in \mathbb{N}$ genérico, $\bar{U}$ es un polinomio de grado $\le r$ en cada intervalo $[x_{i-1},x_i]$ y coincide con u en $r+1$ puntos de dicho intervalo, que llamaremos

$$n_j^i = x_{i-1}+\frac{j}{r}(x_i-x_{i-1}), \qquad j=0,1,\ldots,r.$$

Utilizando el teorema del error de interpolación tenemos el siguiente resultado:

Teorema 9.14. *Si utilizamos elementos finitos de grado r y $u \in C^{r+1}$ entonces*

$$\|u-U\|_{\mathbb{V}} \le \|u-\bar{U}\|_{\mathbb{V}} \le Ch^r,$$

con $h = \max\limits_{i=1,2,\ldots,N} |x_i-x_{i-1}|$ y C una constante que depende de $M := \max_{[a,b]} |u^{(r+1)}|$, de la longitud del $(b-a)$ del intervalo donde está planteado el problema y de $Q = \max\limits_{[a,b]} q$, el máximo del coeficiente $q(x)$ de la ecuación diferencial.

Demostración. Dado un i fijo, $\bar{U}$ es un polinomio de grado r que coincide con u en $r+1$ puntos n_j^i, $j=0,1,\ldots,r$ del intervalo $[x_{i-1},x_i]$. Luego, por el teorema del error de interpolación, para cada $x \in [x_{i-1},x_i]$ existe $\xi_x \in [x_{i-1},x_i]$ tal que

$$u(x)-\bar{U}(x) = \frac{(x-n_0^i)(x-n_1^i)\ldots(x-n_r^i)}{(r+1)!}u^{(r+1)}(\xi_x),$$

y como $|x-n_j^i| \le (x_i-x_{i-1}) \le h$, $j=0,1,\ldots,r$, resulta

$$|u(x)-\bar{U}(x)| \le \frac{(x_i-x_{i-1})^{r+1}}{(r+1)!}\max_{[x_{i-1},x_i]}|u^{(r+1)}| \le \frac{M}{(r+1)!}h^{r+1}.$$

Luego

$$\int_{x_{i-1}}^{x_i} |u(x)-\bar{U}(x)|^2\,dx \le \int_{x_{i-1}}^{x_i} \left(\frac{M}{(r+1)!}\right)^2 h^{2(r+1)}\,dx,$$

y por lo tanto, sumando para i desde 1 hasta N obtenemos

$$\int_a^b |u(x) - \bar{U}(x)|^2 \, dx \leq \int_a^b \left(\frac{M}{(r+1)!}\right)^2 h^{2(r+1)} \, dx \leq (b-a) \left(\frac{M}{(r+1)!}\right)^2 h^{2(r+1)}. \quad (9.16)$$

Por otro lado, como $u - \bar{U}$ tiene $r+1$ ceros en $[x_{i-1}, x_i]$, la función $\frac{d}{dx}(u - \bar{U}) = \frac{du}{dx} - \frac{d\bar{U}}{dx}$ tiene r ceros en ese intervalo, y por lo tanto $\frac{d\bar{U}}{dx}$ es un polinomio de grado $\leq r-1$ que coincide con $\frac{du}{dx}$ en r puntos. Análogamente, obtenemos que

$$\int_a^b \left|\frac{d}{dx}\Big(u(x) - \bar{U}(x)\Big)\right|^2 dx \leq (b-a) \left(\frac{M}{r!}\right)^2 h^{2r}. \quad (9.17)$$

Sumando (9.16) y (9.17) obtenemos que

$$\begin{aligned} \|u - \bar{U}\|_{\mathbb{V}}^2 &= \int_a^b \left|\frac{d}{dx}\Big(u(x) - \bar{U}(x)\Big)\right|^2 dx + \int_a^b q(x)|u(x) - \bar{U}(x)|^2 \, dx \\ &\leq (b-a)Q \left(\frac{M}{(r+1)!}\right)^2 h^{2(r+1)} + (b-a) \left(\frac{M}{r!}\right)^2 h^{2r}. \end{aligned}$$

Como $h \leq b - a$ obtenemos

$$\|u - \bar{U}\|_{\mathbb{V}}^2 \leq \left[(b-a)^3 Q \left(\frac{M}{(r+1)!}\right)^2 + (b-a) \left(\frac{M}{r!}\right)^2\right] h^{2r}.$$

Tomando raíz cuadrada a ambos lados de esta última desigualdad obtenemos lo que se quería demostrar para $C = \left[(b-a)^3 Q \left(\frac{M}{(r+1)!}\right)^2 + (b-a)\left(\frac{M}{r!}\right)^2\right]^{1/2}$. □

Observación 9.15. Utilizando *argumentos de dualidad* puede demostrarse que si sólo miramos el error L^2 se obtiene un orden de convergencia mayor, en efecto

$$\|u - U\|_{L^2(a,b)} \leq C h^{r+1},$$

para una constante C que depende de $M := \max_{[a,b]} |u^{(r+1)}|$, de Q y de $(b-a)$. Pero la demostración queda fuera del alcance de este curso.

9.6 Problemas

9.1. Demostrar que:

(a) Si y es C^2, $\frac{dy}{dx}(x) = \frac{y(x+h)-y(x)}{h} + \frac{h}{2}\frac{d^2y}{dx^2}(\xi)$, para algún $\xi \in (x, x+h)$.

(b) Si y es C^2, $\frac{dy}{dx}(x) = \frac{y(x)-y(x-h)}{h} + \frac{h}{2}\frac{d^2y}{dx^2}(\xi)$, para algún $\xi \in (x-h, x)$.

(c) Si y es C^3, $\frac{dy}{dx}(x) = \frac{y(x+h)-y(x-h)}{2h} + \frac{h^2}{6}\frac{d^3y}{dx^3}(\xi)$, para algún $\xi \in (x-h, x+h)$.

(d) Si y es C^4, $\frac{d^2y}{dx^2}(x) = \frac{y(x+h)-2y(x)+y(x-h)}{h^2} + \frac{h^2}{12}\frac{d^4y}{dx^4}(\xi)$, para algún $\xi \in (x-h, x+h)$.

9.2. Considerar el siguiente problema a valores de borde

$$u''(x) = u(x) - \left(\frac{9\pi^2}{4} + 1\right)\cos\left(\frac{3\pi}{2}x\right), \quad x \in (0,1), \qquad u'(0) = 0 \quad u(1) = 0.$$

(a) Verificar que $u(x) = \cos\left(\frac{3\pi}{2}x\right)$ es solución.

(b) Plantear la discretización del problema usando el método de diferencias finitas, discretizando la condición de borde $u'(0) = 0$ de las dos maneras descriptas en clase.

(c) Calcular el orden experimental de convergencia que se obtiene con cada una de las discretizaciones.

(d) ¿Existe alguna diferencia entre estos órdenes de convergencia? Si existe, ¿a qué cree usted que se debe?

9.3. (a) Plantear la discretización del problema del ejercicio anterior usando el método de elementos finitos con polinomios lineales a trozos.

(b) Graficar $\|u - u_h\|_{L^\infty[0,1]}$ en términos de h y analizar el orden experimental de convergencia.

9.4. Utilizar el método de diferencias finitas para hallar la solución del siguiente problema de convección-difusión estacionario:

$$\begin{aligned} -0.003\frac{d^2y}{dx^2} + \frac{dy}{dx} + 2y = 1, \qquad & 0 < x < 1, \\ y(0) = 0, \quad y(1) = 0. & \end{aligned}$$

Utilizar $N = 10, 20, 50, 100, 200, 500, 1000, 2000, \ldots$. ¿Para qué valor de N le parece que la solución hallada es *razonable*? ¿Cómo se relaciona con los resultados de la teoría?

9.5. La ecuación para el estado estacionario de la temperatura en una barra unidimensional de longitud 1 con un término fuente, que se encuentra aislada en $x = 1$ y se mantiene constantemente a temperatura 0 en $x = 0$ es

$$-y''(x) = e^{-(x-1/2)^2} \quad x \in (0,1), \qquad y(0) = 0 \quad y'(1) = 0.$$

Calcular y graficar el perfil de temperatura en la barra. Decir cuál es la máxima temperatura alcanzada.

9.6. Consideremos el problema de difusión

$$-\Delta u(x,y) = \operatorname{sen}(\pi x)\operatorname{sen}(\pi y), \qquad (x,y) \in \Omega := (0,1)^2,$$

con condiciones de Dirichlet homogéneas

$$u(x,y) = 0 \qquad (x,y) \in \partial\Omega,$$

cuya solución exacta es $u(x,y) = \frac{1}{2\pi^2}\operatorname{sen}(\pi x)\operatorname{sen}(\pi y)$. Resolver por el método de diferencias finitas visto en clase y calcular el orden experimental de convergencia.

9.7. Demostrar que

$$\Delta u(x_i, y_j) = \frac{u_{i+1,j} + u_{i,j+1} - 4u_{i,j} + u_{i-1,j} + u_{i,j-1}}{h^2} + \frac{h^2}{12}\left[\frac{\partial^4 u}{\partial x^4}(\xi, y_j) + \frac{\partial^4 u}{\partial y^4}(x_i, \eta)\right]$$

9.8. Suponer que $q(x, y) \geq \gamma > 0$ para $(x, y) \in [0, 1]^2$. Demostrar que si $h < 2/\max_\Omega |p^{(k)}|$, $k = 1, 2$, y si $\{e_{i,j}\}_{i,j=0}^N$ y $\{\tau_{i,j}\}_{i,j=0}^N$ satisfacen

$$\begin{aligned}
&\frac{-e_{i+1,j} - e_{i,j+1} + 4e_{i,j} - e_{i-1,j} - e_{i,j-1}}{h^2} \\
&+ p_{i,j}^{(1)} \frac{e_{i+1,j} - e_{i-1,j}}{2h} + p_{i,j}^{(2)} \frac{e_{i,j+1} - e_{i,j-1}}{2h} + q_{i,j} e_{i,j} = \tau_{i,j} \qquad i, j = 1, 2, \ldots, N-1, \\
&e_{0,j} = \tau_{0,j}, \quad e_{N,j} = \tau_{N,j}, \qquad j = 0, 1, \ldots, N, \\
&e_{i,0} = \tau_{i,0}, \quad e_{i,N} = \tau_{i,N}, \qquad i = 0, 1, \ldots, N,
\end{aligned}$$

entonces

$$\max_{0 \leq i,j \leq N} |e_{i,j}| \leq \max\{1, \frac{1}{\gamma}\} \max_{0 \leq i,j \leq N} |\tau_{i,j}|.$$

Concluir que bajo las mismas hipótesis sobre p, q, h, el sistema (9.8) tiene solución única y se cumple que

$$\max_{0 \leq i,j \leq N} |U_{i,j}| \leq \max\{1, \frac{1}{\gamma}\} \max\{\max_{\partial\Omega} |\alpha|, \max_{\bar{\Omega}} |g|\},$$

y también que

$$\max_{0 \leq i,j \leq N} |u(x_i, y_j) - U_{i,j}| \leq Ch^2,$$

con C una constante que depende de derivadas de hasta orden cuatro de u y de los coeficientes $p(x, y)$, $q(x, y)$ de la EDP, si la solución exacta u de (9.7) es C^4 en $\bar{\Omega}$.

9.9. Consideremos el problema de difusión reacción

$$-\Delta u(x, y) + e^{x+y} u(x, y) = 1, \qquad (x, y) \in \Omega := (0, 1)^2,$$

con condiciones de Dirichlet inhomogéneas

$$u(x, y) = 1 - x \qquad (x, y) \in \partial\Omega.$$

(a) Plantear la discretización del problema mediante el método de diferencias finitas (discretización de 5 puntos).

(b) Resolver el sistema para un valor de h pequeño y graficar la solución obtenida. Graficar la solución para diferentes h y elegir el h para el cual ya no se observen cambios significativos.

9.10. Utilizar el método de diferencias finitas para hallar la solución del siguiente problema de convección-difusión estacionario en $\Omega = (0, 1) \times (0, 1)$:

$$\begin{aligned}
-0.001\, \Delta u + \begin{bmatrix} 2 \\ 1 \end{bmatrix} \cdot \nabla u &= 1, \qquad \text{en } \Omega, \\
u &= 0, \qquad \text{en } \partial\Omega.
\end{aligned}$$

Utilizar $N = 10, 20, 50, 100, 200, 500, 1000, 2000, \ldots$. ¿Para qué valor de N le parece que la solución hallada es *razonable*? ¿Cómo se relaciona con los resultados de la teoría?

Capítulo 10

Problemas a valores iniciales y de borde. Ecuaciones parabólicas lineales

En este capítulo consideraremos la ecuación del calor (difusión) no-estacionaria en una y dos dimensiones. La ecuación del calor es el ejemplo clásico de ecuación parabólica lineal. Para fijar ideas sin complicar la notación, estudiaremos el caso en que no hay convección ni reacción, y las condiciones de borde de tipo Dirichlet. Más precisamente, en una dimensión, estudiaremos métodos numéricos para la ecuación

$$\begin{cases} \dfrac{\partial u}{\partial t} - k\dfrac{\partial^2 u}{\partial x^2} = f(x,t), & 0 < x < L, \quad 0 < t < T, \\ u(0,t) = \alpha(t), \quad u(L,t) = \beta(t), & 0 \le t \le T, \\ u(x,0) = u^0(x), & 0 \le x \le L. \end{cases} \tag{10.1}$$

Aquí, L, k son parámetros positivos fijos y $f(x,t)$, $\alpha(t)$, $\beta(t)$, $u^0(x)$ son los datos del problema. La incógnita es la función $u = u(x,t)$ que está definida para $0 \le x \le L$, $0 \le t \le T$.

En dos dimensiones, estudiaremos métodos numéricos para la ecuación sobre $\Omega = (0,L) \times (0,L)$,

$$\begin{cases} \dfrac{\partial u}{\partial t} - k\left[\dfrac{\partial^2 u}{\partial x^2} + \dfrac{\partial^2 u}{\partial y^2}\right] = f(x,y;t), & (x,y) \in \Omega, \quad 0 < t < T, \\ u(x,y;t) = \alpha(x,y;t), & (x,y) \in \partial\Omega, \quad 0 \le t \le T, \\ u(x,y;0) = u^0(x,y), & (x,y) \in \bar{\Omega}. \end{cases}$$

Aquí, L, k son parámetros positivos fijos y $f(x,y;t)$, $\alpha(x,y;t)$, $u^0(x,y)$ son los datos del problema. La incógnita es la función $u = u(x,y;t)$ que está definida para $0 \le x \le L$, $0 \le y \le L$, $0 \le t \le T$.

10.1 Diferencias finitas para la ecuación del calor unidimensional

Consideramos entonces la ecuación del calor unidimensional

$$\frac{\partial u}{\partial t} = k\frac{\partial^2 u}{\partial x^2} + f(x,t), \qquad 0 < x < L, \quad 0 < t < T,$$

con condiciones de borde

$$u(0,t) = \alpha(t), \quad u(L,t) = \beta(t), \qquad 0 \le t \le T,$$

y condición inicial

$$u(x,0) = u^0(x), \quad 0 \le x \le L.$$

Para obtener un método numérico basado en diferencias finitas tomamos un entero positivo N y definimos los nodos $x_i = ih$, $i = 0, 1, \ldots, N$, con $h = L/N$. Observamos que

$$\frac{\partial^2 u}{\partial x^2}(x_i,t) \approx \frac{u(x_{i+1},t) - 2u(x_i,t) + u(x_{i-1},t)}{h^2}, \qquad i = 1, 2, \ldots, N-1,$$

con un error de aproximación $\dfrac{h^2}{12}\dfrac{\partial^4 u}{\partial x^4}(\xi_{i,t},t)$ para algún $\xi_{i,t} \in (x_{i-1}, x_{i+1})$.

Definimos ahora $u_i(t) \approx u(x_i,t)$, $i = 0, 1, \ldots, N$ como las soluciones del siguiente sistema de ecuaciones diferenciales, que resulta de reemplazar la derivada espacial de orden dos, por su aproximación por un cociente incremental:

$$\begin{aligned} u_0(t) &= \alpha(t), \\ \frac{du_i}{dt} &= k\frac{u_{i+1}(t) - 2u_i(t) + u_{i-1}(t)}{h^2} + f(x_i,t), \\ u_N(t) &= \beta(t). \end{aligned}$$

Si agregamos a este sistema las condiciones iniciales $u_i(0) = u^0(x_i)$, $i = 1, 2, \ldots, N-1$, hemos obtenido un PVI para el vector $\bar{u} = (u_1, u_2, \ldots, u_{N-1})^T$. En forma matricial/vectorial, el PVI puede escribirse como

$$\begin{cases} \dfrac{d}{dt}\bar{u} = -k\,\underbrace{\dfrac{1}{h^2}\begin{bmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{bmatrix}}_{M_h}\bar{u} + \begin{bmatrix} f(x_1,t) + \frac{k}{h^2}\alpha(t) \\ f(x_2,t) \\ \vdots \\ f(x_{N-2},t) \\ f(x_{N-1},t) + \frac{k}{h^2}\beta(t) \end{bmatrix}, \ 0 < t < T, \\ \bar{u}(0) = \begin{bmatrix} u^0(x_1) \\ u^0(x_2) \\ \vdots \\ u^0(x_{N-1}) \end{bmatrix}. \end{cases} \tag{10.2}$$

Para resolverlo se pueden utilizar algunos de los métodos para problemas a valores iniciales, y el error cometido por la discretización de estos métodos se combinará con el error cometido en la semi-discretización espacial aquí introducida. Para comprender mejor el rol de ambas discretizaciones, veremos a continuación tres discretizaciones temporales concretas: Euler explícito, Euler implícito y trapecio.

10.1.1 Euler explícito

En esta sección utilizaremos el método de Euler explícito para discretizar el PVI (10.2). Utilizamos un parámetro de discretización *temporal* $\Delta t := T/M$, para algún $M \in \mathbb{N}$ (el parámetro de discretización *espacial* es h) y llamamos U^n a la aproximación de $\bar{u}(t_n)$, donde $t_n = n\,\Delta t$. Luego, reemplazando $\frac{d\bar{u}}{dt}(t_n)$ por $\frac{U^{n+1}-U^n}{\Delta t}$ obtenemos

$$\frac{U^{n+1}-U^n}{\Delta t} = -kM_hU^n + F^n, \quad n = 0,1,2,\ldots, \qquad \text{con } F^n = \begin{bmatrix} f(x_1,t_n) + \frac{k}{h^2}\alpha(t_n) \\ f(x_2,t_n) \\ \vdots \\ f(x_{N-2},t_n) \\ f(x_{N-1},t_n) + \frac{k}{h^2}\beta(t_n) \end{bmatrix},$$

es decir

$$\begin{aligned} U^{n+1} &= U^n - k\Delta t M_h U^n + \Delta t F^n, \\ &= (I - k\Delta t M_h)U^n + \Delta t F^n, \quad n = 0,1,2,\ldots,M-1 \\ U^0 = \bar{u}(0) &= \begin{bmatrix} u^0(x_1) \\ u^0(x_2) \\ \vdots \\ u^0(x_{N-1}) \end{bmatrix}. \end{aligned} \tag{10.3}$$

Para comprender mejor el efecto de cada paso temporal, desmenuzamos lo que quiere decir la fórmula $U^{n+1} = (I - k\Delta t M_h)U^n + \Delta t F^n$ para cada componente:

$$\begin{aligned} U_1^{n+1} &= \Big(1 - 2k\frac{\Delta t}{h^2}\Big)U_1^n + k\frac{\Delta t}{h^2}U_2^n + \Delta t f(x_1,t_n) + k\frac{\Delta t}{h^2}\alpha(t_n), \\ U_i^{n+1} &= k\frac{\Delta t}{h^2}U_{i-1}^n + \Big(1 - 2k\frac{\Delta t}{h^2}\Big)U_i^n + k\frac{\Delta t}{h^2}U_{i+1}^n + \Delta t f(x_i,t_n), \qquad i = 2,\ldots,N-2, \\ U_{N-1}^{n+1} &= \Big(1 - 2k\frac{\Delta t}{h^2}\Big)U_{N-1}^n + k\frac{\Delta t}{h^2}U_{N-2}^n + \Delta t f(x_{N-1},t_n) + k\frac{\Delta t}{h^2}\beta(t_n). \end{aligned}$$

Definiendo $\lambda = \frac{k\Delta t}{h^2}$ y reordenando, resulta, para $n = 0,1,\ldots,M-1$

$$\begin{aligned} U_1^{n+1} &= \lambda\alpha(t_n) + \big(1 - 2\lambda\big)U_1^n + \lambda U_2^n + \Delta t f(x_1,t_n), \\ U_i^{n+1} &= \lambda U_{i-1}^n + \big(1 - 2\lambda\big)U_i^n + \lambda U_{i+1}^n + \Delta t f(x_i,t_n), \qquad i = 2,\ldots,N-2, \\ U_{N-1}^{n+1} &= \lambda U_{N-2}^n + \big(1 - 2\lambda\big)U_{N-1}^n + \lambda\beta(t_n) + \Delta t f(x_{N-1},t_n). \end{aligned}$$

Si llamamos $U_0^n = \alpha(t_n)$ y $U_N^n = \beta(t_n)$, entonces, para todo $i = 1,2,\ldots,N-1$ se cumple

$$U_i^{n+1} = \lambda U_{i-1}^n + \big(1 - 2\lambda\big)U_i^n + \lambda U_{i+1}^n + \Delta t f(x_i,t_n). \tag{10.4}$$

Implementación en MATLAB/OCTAVE

Existen al menos dos maneras de implementar este método en MATLAB/OCTAVE. La primera, y más natural a partir de (10.3) consiste en ensamblar la matriz $I - k\Delta t M_h$ (usando `spdiags`) y luego realizar un producto matriz vector en cada paso.

```
%% Ecuacion del calor en un intervalo
%% Resolucion con Euler EXPLICITO
%% Datos del problema
% Longitud del intervalo y tiempo final
L = 1;    T = 2;
% coeficiente de difusividad
k = 1;
% dato inicial y termino fuente
u0 = @(x) sin(pi*x);
f = @(x,t) zeros(size(x));
% datos de borde
alpha = @(t) 0;   beta = @(t) 0;

%% Parametros de resolucion
N = 20;  M = 800;
h = L/N; dt = T/M;

%% Resolucion - Inicializacion
x = linspace(0,L,N+1)';  U = u0(x);
plot(x,U); title('Condicion inicial'); ejes = axis;
pause

%% Ensamblado de la matriz
ksobreh2 = k/h^2;  unos = ones(N-1,1);
Mat = -unos*(dt*ksobreh2*[-1 2 -1]);
Mat(:,2) = Mat(:,2) + unos;
Mat = spdiags(Mat, [-1 0 1], N-1, N-1);
% ahora M tiene I - k dt Mh

%% Resolucion
t = 0;
while (t < T)
  F = f(x(2:N),t) ;
  F(1) = F(1) + ksobreh2*U(1);    F(N-1) = F(N-1) + ksobreh2*U(N+1);
  U(2:N) = Mat * U(2:N) + dt*F;
  t = t+dt;
  U(1) = alpha(t); U(N+1) = beta(t);
  plot(x,U); title(sprintf('Solucion a tiempo t=%6.4f',t)); axis(ejes);
  pause(1/24);
end
```

Otra posibilidad es escribir un código *matrix-free*, que se obtiene reemplazando las secciones `%% Ensamblado de la matriz` y `%% Resolucion` por la siguiente

```
%% Resolucion sin ensamblado (matrix-free)
ksobreh2 = k/h^2;
lambda = dt*ksobreh2;
t = 0;
while (t < T)
  F = f(x(2:N),t) ;
  % el borde ya entra por U(1) y U(N+1) en el stencil de abajo (no hay que corregir F)

  U(2:N) = lambda*U(1:N-1) + (1-2*lambda)*U(2:N) + lambda*U(3:N+1) + dt*F;

  t = t+dt;
  U(1) = alpha(t); U(N+1) = beta(t);
  plot(x,U); title(sprintf('Solucion a tiempo t=%6.4f',t)); axis(ejes);
  pause(1/24);
end
```

Estabilidad

Observemos que por la desigualdad triangular, para $i = 1, 2, \ldots, N-1$ se cumple

$$|U_i^{n+1}| \leq \lambda |U_{i-1}^n| + \big|1 - 2\lambda\big||U_i^n| + \lambda |U_{i+1}^n| + \Delta t |f(x_i, t_n)|.$$

Si $\lambda = \dfrac{k\Delta t}{h^2} \leq \dfrac{1}{2}$, o lo que es lo mismo $\Delta t \leq \dfrac{h^2}{2k}$ resulta $1 - 2\lambda \geq 0$ y entonces

$$\begin{aligned} |U_i^{n+1}| &\leq \lambda |U_{i-1}^n| + \big(1 - 2\lambda\big)|U_i^n| + \lambda |U_{i+1}^n| + \Delta t |f(x_i, t_n)| \\ &\leq \max_{0 \leq j \leq N} |U_j^n| + \Delta t \max_{1 \leq j \leq N-1} |f(x_j, t_n)|, \\ &\leq \max\Big\{|\alpha(t_n)|, |\beta(t_n)|, \max_{1 \leq j \leq N-1} |U_j^n|\Big\} + \Delta t \max_{0 \leq x \leq L} |f(x, t_n)|, \end{aligned}$$

para $i = 1, 2, \ldots, N-1$.

Por lo tanto,

$$\max_{0 \leq i \leq N} |U_i^{n+1}| \leq \max\Big\{ \max_{0 \leq t \leq T} |\alpha(t)|, \max_{0 \leq t \leq T} |\beta(t)|, \max_{1 \leq j \leq N-1} |U_j^n|\Big\} + \Delta t \max_{0 \leq x \leq L, 0 \leq t \leq T} |f(x,t)|,$$

para $n = 0, 1, \ldots, M-1$.

A partir de esta desigualdad podemos demostrar fácilmente el siguiente teorema o resultado de estabilidad *condicional*:

Teorema 10.1. *Dados $N, M \in \mathbb{N}$, si $h = L/N$ y $\Delta t = T/M$ satisfacen que $\lambda := \dfrac{k\Delta t}{h^2} \leq \dfrac{1}{2}$ entonces definiendo*

$$\bar{\alpha} = \max_{0 \leq t \leq T} |\alpha(t)|, \quad \bar{\beta} = \max_{0 \leq t \leq T} |\beta(t)|, \quad \bar{f} = \max_{0 \leq x \leq L, 0 \leq t \leq T} |f(x,t)|, \quad \overline{u^0} = \max_{0 \leq x \leq L} |u^0(x)|,$$

si U^n se definen por (10.3) resulta

$$\max_{0 \leq i \leq N,\, 0 \leq n \leq M} |U_i^n| = \max_{0 \leq n \leq M} \|U^n\|_\infty \leq \max\{\bar{\alpha}, \bar{\beta}, \overline{u^0}\} + T\bar{f}.$$

Demostración. La demostración de este teorema se deja como ejercicio. □

Acotación del error

En primer lugar observemos qué error cometemos al aplicar la fórmula en diferencias a la solución exacta $u(x,t)$ del problema. Para ello, comenzamos deduciendo, por teorema de Taylor, que si $\dfrac{\partial^4 u}{\partial x^4}$ y $\dfrac{\partial^2 u}{\partial t^2}$ son continuas, entonces, dado $1 \le i \le N-1$ y $0 \le n \le M-1$, para algún $t_n < \eta_{i,n} < t_{n+1}$ y algún $x_{i-1} < \xi_{i,n} < x_{i+1}$ se cumple

$$\begin{aligned}\frac{u(x_i,t_{n+1})-u(x_i,t_n)}{\Delta t} &= \frac{\partial u}{\partial t}(x_i,t_n) + \frac{\Delta t}{2}\frac{\partial^2 u}{\partial t^2}(x_i,\eta_{i,n}),\\ \frac{u(x_{i+1},t_n)-2u(x_i,t_n)+u(x_{i-1},t_n)}{h^2} &= \frac{\partial^2 u}{\partial x^2}(x_i,t_n) + \frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,n},t_n).\end{aligned}$$

Luego, multiplicando la segunda igualdad por el coeficiente de difusividad k y restando, obtenemos

$$\begin{aligned}\frac{u(x_i,t_{n+1})-u(x_i,t_n)}{\Delta t} - k\frac{u(x_{i+1},t_n)-2u(x_i,t_n)+u(x_{i-1},t_n)}{h^2}&\\ = f(x_i,t_n) + \frac{\Delta t}{2}\frac{\partial^2 u}{\partial t^2}(x_i,\eta_{i,n}) - k\frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,n},t_n),&\quad (10.5)\end{aligned}$$

donde hemos utilizado que u es solución de la ecuación diferencial, y por ende

$$\frac{\partial u}{\partial t}(x_i,t_n) - k\frac{\partial^2 u}{\partial x^2}(x_i,t_n) = f(x_i,t_n).$$

Multiplicando (10.5) por Δt y recordando que $\lambda = \frac{k\Delta t}{h^2}$ tenemos que

$$\begin{aligned}u(x_i,t_{n+1}) - u(x_i,t_n) - \lambda\Big[u(x_{i+1},t_n)-2u(x_i,t_n)+u(x_{i-1},t_n)\Big]&\\ = \Delta t f(x_i,t_n) + \Delta t\Big[\frac{\Delta t}{2}\frac{\partial^2 u}{\partial t^2}(x_i,\eta_{i,n}) - k\frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,n},t_n)\Big],&\end{aligned}$$

es decir

$$\begin{aligned}u(x_i,t_{n+1}) = \lambda u(x_{i-1},t_n) + (1-2\lambda)u(x_i,t_n) + \lambda u(x_{i+1},t_n) + \Delta t f(x_i,t_n)&\\ + \Delta t\Big[\frac{\Delta t}{2}\frac{\partial^2 u}{\partial t^2}(x_i,\eta_{i,n}) - k\frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,n},t_n)\Big].&\end{aligned}$$

Recordamos que por definición, $U_0^n = \alpha(t_n) = u(0,t_n)$ y $U_N^n = \beta(t_n) = u(L,t_n)$, y para todo $i = 1,2,\dots,N-1$ se cumple (ver (10.4))

$$U_i^{n+1} = \lambda U_{i-1}^n + \big(1-2\lambda\big)U_i^n + \lambda U_{i+1}^n + \Delta t f(x_i,t_n).$$

Restando estas igualdades de las expresiones anteriores vemos que el error e_i^n, definido por

$$e_i^n := u(x_i,t_n) - U_i^n$$

satisface, para $n = 0,1,\dots,M-1$,

$$\begin{aligned}&e_0^{n+1} = 0,\\ &e_i^{n+1} = \lambda e_{i-1}^n + \big(1-2\lambda\big)e_i^n + \lambda e_{i+1}^n + \Delta t\Big[\frac{\Delta t}{2}\frac{\partial^2 u}{\partial t^2}(x_i,\eta_{i,n}) - k\frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,n},t_n)\Big],\\ &\qquad\qquad i = 1,2,\dots,N-1,\\ &e_N^{n+1} = 0.\end{aligned}$$

Una vez que hemos obtenido la ecuación para el error, recurrimos al teorema de estabilidad Teorema 10.1 —aplicado a e^n en lugar de U^n—, y obtenemos el siguiente teorema de estimación del error.

Teorema 10.2. *Supongamos que la solución $u(x,t)$ del problema (10.1) cumple que*

$$\max_{0\le x\le L,\, 0\le t\le T}\left|\frac{\partial^2 u}{\partial t^2}(x,t)\right| \le \mathbb{M}_1, \qquad y \qquad \max_{0\le x\le L,\, 0\le t\le T}\left|\frac{\partial^4 u}{\partial x^4}(x,t)\right| \le \mathbb{M}_2.$$

Dados $N, M \in \mathbb{N}$, si $h = L/N$ y $\Delta t = T/M$ satisfacen que $\lambda := \dfrac{k\Delta t}{h^2} \le \dfrac{1}{2}$ entonces el máximo error cometido por el método de diferencias finitas explícito (10.3) es menor o igual que $T\left(\dfrac{\mathbb{M}_1}{2}\Delta t + k\dfrac{\mathbb{M}_2}{12}h^2\right)$. Más precisamente, si U_i^n, $0 \le i \le N$, $0 \le n \le M$ son obtenidos con las fórmulas (10.3), entonces

$$\max_{0\le i\le N,\, 0\le n\le M} |u(x_i,t_n) - U_i^n| \le T\left(\frac{\mathbb{M}_1}{2}\Delta t + k\frac{\mathbb{M}_2}{12}h^2\right) \le \mathbb{M}T(\Delta t + h^2),$$

si $\mathbb{M} = \max\{\mathbb{M}_1/2, k\,\mathbb{M}_2/12\}$.

Observación 10.3. La restricción $\lambda := \dfrac{k\Delta t}{h^2} \le \dfrac{1}{2}$ puede ser muy exigente en algunas situaciones, pues si h es pequeño, h^2 es bastante más pequeño, y esto forzaría a tener Δt mucho más pequeño que el error de aproximación deseado, implicando un gran esfuerzo computacional. Este problema de estabilidad se debe a que el sistema de ecuaciones diferenciales ordinarias (10.2) es rígido o *stiff*, pues los autovalores de M_h van de 1 a $1/h^2$. Para resolver esta restricción se recurre a métodos implícitos o semi-implícitos, como los que veremos en las secciones siguientes.

10.1.2 Euler implícito

En esta sección utilizaremos el método de Euler implícito para discretizar el PVI (10.2), con la esperanza de obtener estabilidad para valores mayores de Δt.

Utilizamos, como antes, un parámetro de discretización *temporal* $\Delta t := T/M$, para algún $M \in \mathbb{N}$ (el parámetro de discretización *espacial* es h) y llamamos U^n a la aproximación de $\bar{u}(t_n)$, donde $t_n = n\,\Delta t$. Luego, reemplazando $\frac{d\bar{u}}{dt}(t_{n+1})$ por $\frac{U^{n+1}-U^n}{\Delta t}$ obtenemos

$$\frac{U^{n+1}-U^n}{\Delta t} = -kM_hU^{n+1} + F^{n+1}, \quad n = 0,1,2,\ldots,$$

con

$$F^{n+1} = \begin{bmatrix} f(x_1,t_{n+1}) + \frac{k}{h^2}\alpha(t_{n+1}) \\ f(x_2,t_{n+1}) \\ \vdots \\ f(x_{N-2},t_{n+1}) \\ f(x_{N-1},t_{n+1}) + \frac{k}{h^2}\beta(t_{n+1}) \end{bmatrix},$$

es decir

$$U^{n+1} + k\Delta t M_h U^{n+1} = U^n + \Delta t F^{n+1}.$$

El método resulta entonces

$$(I + k\Delta t M_h)U^{n+1} = U^n + \Delta t F^{n+1}, \quad n = 0, 1, 2, \ldots, M-1,$$
$$U^0 = \bar{u}(0) = \begin{bmatrix} u^0(x_1) \\ u^0(x_2) \\ \vdots \\ u^0(x_{N-1}) \end{bmatrix}, \tag{10.6}$$

con

$$F^{n+1} = \begin{bmatrix} f(x_1, t_{n+1}) \\ f(x_2, t_{n+1}) \\ \vdots \\ f(x_{N-2}, t_{n+1}) \\ f(x_{N-1}, t_{n+1}) \end{bmatrix} + \begin{bmatrix} \frac{k}{h^2}\alpha(t_{n+1}) \\ 0 \\ \vdots \\ 0 \\ \frac{k}{h^2}\beta(t_{n+1}) \end{bmatrix}.$$

Observamos inmediatamente que este método implica la resolución de un sistema de ecuaciones en cada paso de tiempo. Esto es siempre más costoso que realizar las operaciones de un paso de tiempo del método explícito de la sección anterior. Lo importante, que veremos aquí, es que no hay restricciones sobre Δt para obtener estabilidad.

Implementación en MATLAB/OCTAVE

Para esta versión implícita del método de diferencias finitas para la ecuación del calor, hay que resolver, en cada paso de tiempo, un sistema lineal para la matriz $I + k\Delta t M_h$. La siguiente implementación consiste en ensamblar esta matriz y resolver el sistema indicado en cada paso de tiempo.

```
%% Ecuacion del calor en un intervalo
%% Resolucion con Euler IMPLICITO
%% Datos del problema
% Longitud del intervalo y tiempo final
L = 1;    T = 2;
% coeficiente de difusividad
k = 1;
% dato inicial y termino fuente
u0 = @(x) sin(pi*x);
f = @(x,t) zeros(size(x));
% datos de borde
alpha = @(t) 0;   beta = @(t) 0;

%% Parametros de resolucion
N = 20;  M = 40;
h = L/N; dt = T/M;

%% Resolucion - Inicializacion
x = linspace(0,L,N+1)';  U = u0(x);
plot(x,U); title('Condicion inicial'); ejes = axis;
pause

%% Ensamblado de la matriz
ksobreh2 = k/h^2;  unos = ones(N-1,1);
Mat = unos*(dt*ksobreh2*[-1 2 -1]);
Mat(:,2) = Mat(:,2) + unos;
Mat = spdiags(Mat, [-1 0 1], N-1, N-1);
% ahora M tiene I + k dt Mh

%% Resolucion
t = 0;
while (t < T)
  t = t+dt;
  U(1) = alpha(t); U(N+1) = beta(t);
  F = f(x(2:N),t) ;   % f en t_{n+1} (metodo implicito)
  F(1) = F(1) + ksobreh2*U(1);    F(N-1) = F(N-1) + ksobreh2*U(N+1);
  U(2:N) = Mat \ ( U(2:N) + dt*F );
  plot(x,U); title(sprintf('Solucion a tiempo t=%6.4f',t)); axis(ejes);
  pause(1/24);
end
```

Estabilidad

Para comprender mejor el efecto de cada paso temporal, y para ver si el sistema de ecuaciones tiene solución, desmenuzamos lo que quiere decir la fórmula $(I + k\Delta t M_h)U^{n+1} = U^n + \Delta t F^{n+1}$ en términos de sus componentes: Recordando que $\lambda = \frac{k\Delta t}{h^2}$ resulta, para

$n = 0, 1, \ldots, M-1$

$$\begin{aligned}
-\lambda\alpha(t_{n+1}) + (1+2\lambda)U_1^{n+1} - \lambda U_2^{n+1} &= U_1^n + \Delta t f(x_1, t_{n+1}),\\
-\lambda U_{i-1}^{n+1} + (1+2\lambda)U_i^{n+1} - \lambda U_{i+1}^{n+1} &= U_i^n + \Delta t f(x_i, t_{n+1}), \qquad i = 2, \ldots, N-2,\\
-\lambda U_{N-2}^{n+1} + (1+2\lambda)U_{N-1}^{n+1} - \lambda\beta(t_{n+1}) &= U_{N-1}^n + \Delta t f(x_{N-1}, t_{n+1}).
\end{aligned}$$

Si llamamos, como antes, $U_0^n = \alpha(t_n)$ y $U_N^n = \beta(t_n)$, entonces, para todo $n = 0, 1, 2, \ldots, M-1$ se cumple

$$-\lambda U_{i-1}^{n+1} + (1+2\lambda)U_i^{n+1} - \lambda U_{i+1}^{n+1} = U_i^n + \Delta t f(x_i, t_{n+1}), \qquad i = 1, 2, \ldots, N-1. \tag{10.7}$$

Luego, para $i = 1, 2, \ldots, N-1$,

$$(1+2\lambda)U_i^{n+1} = \lambda U_{i-1}^{n+1} + \lambda U_{i+1}^{n+1} + U_i^n + \Delta t f(x_i, t_{n+1}),$$

que implica

$$\begin{aligned}
(1+2\lambda)|U_i^{n+1}| &\le \lambda|U_{i-1}^{n+1}| + \lambda|U_{i+1}^{n+1}| + |U_i^n| + \Delta t|f(x_i, t_{n+1})|\\
&\le \lambda\|U^{n+1}\|_\infty + \lambda\|U^{n+1}\|_\infty + \|U^n\|_\infty + \Delta t \max_{0\le x\le L}|f(x, t_{n+1})|.
\end{aligned} \tag{10.8}$$

A partir de esta acotación, podemos demostrar el siguiente resultado de estabilidad *incondicional*:

Teorema 10.4. *Dados $N, M \in \mathbb{N}$, si $h = L/N$ y $\Delta t = T/M$, entonces definiendo*

$$\bar\alpha = \max_{0\le t\le T}|\alpha(t)|, \quad \bar\beta = \max_{0\le t\le T}|\beta(t)|, \quad \bar f = \max_{0\le x\le L, 0\le t\le T}|f(x,t)|, \quad \overline{u^0} = \max_{0\le x\le L}|u^0(x)|,$$

si U^n se definen por (10.6) resulta

$$\max_{0\le n\le M}\|U^n\|_\infty \le \max\{\bar\alpha, \bar\beta, \overline{u^0}\} + T\bar f.$$

Demostración. La afirmación del teorema se sigue, por inducción, a partir de la siguiente acotación:

$$\|U^{n+1}\|_\infty \le \max\{\bar\alpha, \bar\beta, \|U^n\|_\infty\} + \Delta t\bar f, \qquad n = 0, 1, \ldots, M-1. \tag{10.9}$$

En efecto, por (10.8) resulta

$$(1+2\lambda)|U_i^{n+1}| \le \lambda\|U^{n+1}\|_\infty + \lambda\|U^{n+1}\|_\infty + \|U^n\|_\infty + \Delta t \max_{0\le x\le L}|f(x, t_{n+1})|, \tag{10.10}$$

para $i = 1, 2, \ldots, N-1$ y $n = 0, 1, \ldots, M-1$. Fijado n, sea i tal que $\|U^{n+1}\|_\infty = |U_i^{n+1}|$. Si $i = 0$ o $i = N$ entonces $\|U^{n+1}\|_\infty \le \max\{\bar\alpha, \bar\beta\}$. Si $1 \le i \le N-1$ entonces por (10.10)

$$(1+2\lambda)\|U^{n+1}\| \le \lambda\|U^{n+1}\|_\infty + \lambda\|U^{n+1}\|_\infty + \|U^n\|_\infty + \Delta t \max_{0\le x\le L}|f(x, t_{n+1})|,$$

que implica

$$\|U^{n+1}\|_\infty \le \|U^n\|_\infty + \Delta t \max_{0\le x\le L}|f(x, t_{n+1})|.$$

En consecuencia, vale (10.9). □

Observación 10.5. En la demostración de este resultado de estabilidad, sólo se utiliza que $\lambda = \dfrac{k\Delta t}{h^2}$ es positivo, pero no hace falta que sea *menor que* $1/2$. Por eso se dice que el método de Euler implícito es *incondicional* o *absolutamente* estable para este problema.

Acotación del error

En primer lugar observemos qué error cometemos al aplicar la fórmula en diferencias a la solución exacta $u(x,t)$ del problema. Análogamente a como se hizo para el método explícito, por teorema de Taylor deducimos que

$$u(x_i,t_{n+1}) - u(x_i,t_n) - \lambda\Big[u(x_{i+1},t_{n+1}) - 2u(x_i,t_{n+1}) + u(x_{i-1},t_{n+1})\Big] \\ = \Delta t f(x_i,t_{n+1}) + \Delta t\Big[-\frac{\Delta t}{2}\frac{\partial^2 u}{\partial t^2}(x_i,\eta_{i,n}) - k\frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,n},t_{n+1})\Big],$$

para algún $\xi_{i,n} \in (x_{i-1},x_{i+1})$ y algún $\eta_{i,n} \in (t_n,t_{n+1})$, es decir

$$-\lambda u(x_{i-1},t_{n+1}) + (1+2\lambda)u(x_i,t_{n+1}) - \lambda u(x_{i+1},t_{n+1}) = u(x_i,t_n) + \Delta t f(x_i,t_{n+1}) \\ + \Delta t\Big[-\frac{\Delta t}{2}\frac{\partial^2 u}{\partial t^2}(x_i,\eta_{i,n}) - k\frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,n},t_{n+1})\Big].$$

Restando la igualdad (10.7) de esta última expresión, vemos que el error $e_i^n := u(x_i,t_n) - U_i^n$ satisface, para $n = 0,1,\ldots,M-1$,

$$e_0^{n+1} = 0,$$
$$-\lambda e_{i-1}^{n+1} + (1+2\lambda)e_i^{n+1} - \lambda e_{i+1}^{n+1} = e_i^n + \Delta t\Big[-\frac{\Delta t}{2}\frac{\partial^2 u}{\partial t^2}(x_i,\eta_{i,n}) - k\frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,n},t_{n+1})\Big], \quad i = 1,2,\ldots,N-1,$$
$$e_N^{n+1} = 0.$$

Apelando al Teorema 10.4 —aplicado a e^n en lugar de U^n—, obtenemos el siguiente teorema de estimación del error.

Teorema 10.6. *Supongamos que la solución $u(x,t)$ del problema (10.1) cumple que*

$$\max_{0\le x\le L,\,0\le t\le T}\left|\frac{\partial^2 u}{\partial t^2}(x,t)\right| \le \mathbb{M}_1, \qquad y \qquad \max_{0\le x\le L,\,0\le t\le T}\left|\frac{\partial^4 u}{\partial x^4}(x,t)\right| \le \mathbb{M}_2.$$

Dados $N,M \in \mathbb{N}$, si $h = L/N$ y $\Delta t = T/M$, entonces el máximo error cometido por el método de diferencias finitas implícito (10.6) es menor o igual que $T\left(\frac{\mathbb{M}_1}{2}\Delta t + k\frac{\mathbb{M}_2}{12}h^2\right)$. Más precisamente, si U_i^n, $0 \le i \le N$, $0 \le n \le M$ son obtenidos con las fórmulas (10.6), entonces

$$\max_{0\le i\le N,\,0\le n\le M}|u(x_i,t_n) - U_i^n| \le T\left(\frac{\mathbb{M}_1}{2}\Delta t + k\frac{\mathbb{M}_2}{12}h^2\right) \le \mathbb{M}T(\Delta t + h^2),$$

si $\mathbb{M} = \max\{\mathbb{M}_1/2, k\,\mathbb{M}_2/12\}$.

10.1.3 Método del trapecio. Crank-Nicolson

En esta sección proponemos una discretización de segundo orden para la variable tiempo, utilizando el método del trapecio. Obtenemos así un método de orden $\Delta t^2 + h^2$. Utilizamos, como antes, un parámetro de discretización *temporal* $\Delta t := T/M$, para algún

$M \in \mathbb{N}$ (el parámetro de discretización *espacial* es h) y llamamos U^n a la aproximación de $\bar{u}(t_n)$, donde $t_n = n\,\Delta t$.

Para obtener un método de orden dos en Δt aproximamos $\dfrac{\partial \bar{u}}{\partial t}$ por una diferencia *centrada*, más precisamente, reemplazamos $\dfrac{\partial \bar{u}}{\partial t}(t_{n+1/2})$ por $\frac{\bar{u}(t_{n+1})-\bar{u}(t_n)}{\Delta t}$ y $M_h\bar{u}(t_{n+1/2})$ por $\frac{1}{2}M_h\left(\bar{u}(t_n)+\bar{u}(t_{n+1})\right)$, obteniendo el siguiente método[1]

$$\frac{U^{n+1}-U^n}{\Delta t} = -\frac{k}{2}M_h\left[U^{n+1}+U^n\right] + F^{n+1/2}, \quad n = 0,1,2,\ldots,$$

$$\text{con } F^{n+1/2} = \frac{1}{2}\left[F^n + F^{n+1}\right] \approx \begin{bmatrix} f(x_1,t_{n+1/2}) + \frac{k}{2h^2}\left[\alpha(t_n)+\alpha(t_{n+1})\right] \\ f(x_2,t_{n+1/2}) \\ \vdots \\ f(x_{N-2},t_{n+1/2}) \\ f(x_{N-1},t_{n+1/2}) + \frac{k}{2h^2}\left[\beta(t_n)+\beta(t_{n+1})\right] \end{bmatrix}, \text{ es decir}$$

$$U^{n+1} + \frac{k}{2}\Delta t M_h U^{n+1} = U^n - \frac{k}{2}\Delta t M_h U^n + \Delta t F^{n+1/2}.$$

El método resulta entonces

$$\begin{aligned} (I + \frac{k}{2}\Delta t M_h)U^{n+1} &= (I - \frac{k}{2}\Delta t M_h)U^n + \Delta t F^{n+1/2}, \quad n = 0,1,2,\ldots,M-1, \\ U^0 = \bar{u}(0) &= \begin{bmatrix} u^0(x_1) \\ u^0(x_2) \\ \vdots \\ u^0(x_{N-1}) \end{bmatrix}. \end{aligned} \tag{10.11}$$

Observamos inmediatamente que este método también implica la resolución de un sistema de ecuaciones en cada paso de tiempo. Esto es siempre más costoso que realizar las operaciones de un paso de tiempo del método explícito. Lo importante, que veremos aquí, es que no hay restricciones sobre Δt para obtener estabilidad, y además el error es de orden cuadrático en Δt.

Implementación en MATLAB/OCTAVE

Para esta versión implícita del método de diferencias finitas para la ecuación del calor, hay que resolver, en cada paso de tiempo, un sistema lineal para la matriz $I + \frac{k}{2}\Delta t M_h$. La implementación se deja como ejercicio.

Estabilidad

Para estudiar la estabilidad del método de Crank-Nicolson observamos que, para $n = 0,1,2,\ldots,M-1$,

$$(I + \frac{k}{2}\Delta t M_h)U^{n+1} = (I - \frac{k}{2}\Delta t M_h)U^n + \Delta t F^{n+1/2}, \tag{10.12}$$

[1] Aquí $t_{n+1/2} = n\Delta t + \frac{\Delta t}{2} = (n+1/2)\Delta t$.

Como M_h es simétrica, existe una base ortonormal de autovectores $\{V_i\}_{i=0}^N$ de M_h con correspondientes autovalores $\{\lambda_i\}_{i=0}^N$. Estos autovalores λ_i son todos positivos (ver ejercicio 10.5). Por lo tanto, si V es la matriz que tiene $V_0, V_1, \ldots, V_N$ como columnas resulta

$$M_h = V\Lambda V^T, \qquad V^T M_h V = \Lambda, \qquad V^T V = VV^T = I,$$

con $\Lambda = \text{diag}(\lambda_0, \lambda_1, \ldots, \lambda_N)$. Además, cualquiera sea $\Delta t > 0$, V diagonaliza también a $(I \pm \frac{k}{2}\Delta t M_h)$:

$$(I \pm \frac{k}{2}\Delta t M_h) = V(I \pm \frac{k}{2}\Delta t \Lambda)V^T, \qquad (I \pm \frac{k}{2}\Delta t \Lambda) = V^T(I \pm \frac{k}{2}\Delta t M_h)V,$$

Multiplicando (10.12) por V^T a izquierda obtenemos

$$V^T(I + \frac{k}{2}\Delta t M_h)VV^T U^{n+1} = V^T(I - \frac{k}{2}\Delta t M_h)VV^T U^n + \Delta t V^T F^{n+1/2},$$

y llamando $\tilde{U}^n = V^T U^n$, $\tilde{F}^n = V^T F^n$, resulta

$$(I + \frac{k}{2}\Delta t \Lambda)\tilde{U}^{n+1} = (I - \frac{k}{2}\Delta t \Lambda)\tilde{U}^n + \Delta t \tilde{F}^{n+1/2}.$$

Como $(I \pm \frac{k}{2}\Delta t \Lambda) = \text{diag}(1 \pm \frac{k}{2}\Delta t \lambda_0, 1 \pm \frac{k}{2}\Delta t \lambda_1, \ldots, 1 \pm \frac{k}{2}\Delta t \lambda_N)$, resulta que cada componente de $\tilde{U}^{n+1}$ satisface

$$\tilde{U}_i^{n+1} = \frac{1 - \frac{k}{2}\Delta t \lambda_i}{1 + \frac{k}{2}\Delta t \lambda_i}\tilde{U}_i^n + \Delta t \frac{1}{1 + \frac{k}{2}\Delta t \lambda_i}\tilde{F}_i^{n+1/2},$$

$i = 0, 1, \ldots, N$. Ahora bien, cualquiera sea $\Delta t > 0$

$$\left|\frac{1 - \frac{k}{2}\Delta t \lambda_i}{1 + \frac{k}{2}\Delta t \lambda_i}\right| < 1, \quad \text{y} \quad \left|\frac{1}{1 + \frac{k}{2}\Delta t \lambda_i}\right| < 1,$$

por lo que

$$\left|\tilde{U}_i^{n+1}\right| \leq \left|\tilde{U}_i^n\right| + \Delta t \left|\tilde{F}_i^{n+1/2}\right|,$$

y luego, por la desigualdad triangular en $\mathbb{R}^{N+1}$,

$$\left(\sum_{i=0}^N \left|\tilde{U}_i^{n+1}\right|^2\right)^{1/2} \leq \left(\sum_{i=0}^N \left|\tilde{U}_i^n\right|^2\right)^{1/2} + \Delta t \left(\sum_{i=0}^N \left|\tilde{F}_i^{n+1/2}\right|^2\right)^{1/2},$$

que podemos escribir como

$$\|\tilde{U}^{n+1}\|_2 \leq \|\tilde{U}^n\|_2 + \Delta t \|\tilde{F}^{n+1/2}\|_2.$$

Como $\left\|\tilde{U}^n\right\|_2^2 = (\tilde{U}^n)^T\tilde{U}^n = (U^n)^T VV^T U^n = (U^n)^T U^n = \left\|U^n\right\|_2^2$ y $\left\|\tilde{F}^{n+1/2}\right\|_2^2 = \left\|F^{n+1/2}\right\|_2^2$ resulta

$$\left\|U^{n+1}\right\|_2 \leq \left\|U^n\right\|_2 + \Delta t \left\|F^{n+1/2}\right\|_2.$$

A partir de esta última acotación se demuestra el siguiente resultado de estabilidad *incondicional* para el método de Crank-Nicolson.

Teorema 10.7. *Dados $N, M \in \mathbb{N}$, si $h = L/N$ y $\Delta t = T/M$, entonces definiendo*

$$\bar{\alpha} = \max_{0\le t\le T} |\alpha(t)|, \quad \bar{\beta} = \max_{0\le t\le T} |\beta(t)|,$$

si U^n se definen por (10.11) resulta

$$\begin{aligned}\max_{0\le n\le M} \|U^n\|_2 &\le \left(\bar{\alpha}^2 + \bar{\beta}^2 + \|U^0\|_2^2\right)^{1/2} + \sum_{n=0}^{M} \Delta t \left(\sum_{i=0}^{N} |f(x_i, t_{n+1/2})|^2\right)^{1/2} \\ &\le \left(\bar{\alpha}^2 + \bar{\beta}^2 + \|U^0\|_2^2\right)^{1/2} + T\sqrt{N+1} \max_{0\le x\le L, 0\le t\le T} |f(x,t)|.\end{aligned}$$

Demostración. La demostración de este teorema se deja como ejercicio. □

Acotación del error

Para acotar el error utilizaremos la estabilidad del método y el hecho que

$$\begin{aligned}u(x_i, t_{n+1}) - u(x_i, t_n) - \frac{\lambda}{2}\Big[u(x_{i+1}, t_{n+1}) - 2u(x_i, t_{n+1}) + u(x_{i-1}, t_{n+1})\Big] \\ = \frac{\lambda}{2}\Big[u(x_{i+1}, t_n) - 2u(x_i, t_n) + u(x_{i-1}, t_n)\Big] + \Delta t f(x_i, t_{n+1/2}) \\ + \Delta t\Big[\frac{\Delta t^2}{3}\frac{\partial^3 u}{\partial t^3}(x_i, \eta_{i,n}) + k\frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,n}, t_{n+1})\Big],\end{aligned}$$

para algún $\xi_{i,n} \in (x_{i-1}, x_{i+1})$ y algún $\eta_{i,n} \in (t_n, t_{n+1})$.

Análogamente a lo hecho en secciones anteriores, vemos que el error $e_i^n := u(x_i, t_n) - U_i^n$ satisface, para $n = 0, 1, \ldots, M-1$,

$$\begin{aligned} e_0^{n+1} &= 0, \\ -\frac{\lambda}{2}e_{i-1}^{n+1} + (1+\lambda)e_i^{n+1} - \frac{\lambda}{2}e_{i+1}^{n+1} &= \frac{\lambda}{2}e_{i-1}^n + (1-\lambda)e_i^n - \frac{\lambda}{2}e_{i+1}^n \\ &\quad + \Delta t\Big[\frac{\Delta t^2}{3}\frac{\partial^3 u}{\partial t^3}(x_i, \eta_{i,n}) + k\frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,n}, t_{n+1})\Big], \\ &\qquad\qquad i = 1, 2, \ldots, N-1, \\ e_N^{n+1} &= 0.\end{aligned}$$

Apelando al Teorema 10.7 —aplicado a e^n en lugar de U^n—, obtenemos el siguiente teorema de estimación del error.

Teorema 10.8. *Supongamos que la solución $u(x,t)$ del problema (10.1) cumple que*

$$\max_{0\le x\le L, 0\le t\le T} \left|\frac{\partial^3 u}{\partial t^3}(x,t)\right| \le \mathbb{M}_1, \qquad y \qquad \max_{0\le x\le L, 0\le t\le T} \left|\frac{\partial^4 u}{\partial x^4}(x,t)\right| \le \mathbb{M}_2.$$

Dados $N, M \in \mathbb{N}$, si $h = L/N$ y $\Delta t = T/M$, entonces el máximo error, medido en norma $\|\cdot\|_2$ cometido por el método de Crank-Nicolson (10.11) es menor o igual que

$\sqrt{N+1}T\left(\frac{\mathbb{M}_1}{3}\Delta t^2 + k\frac{\mathbb{M}_2}{12}h^2\right)$. *Más precisamente, si* U_i^n, $0 \le i \le N$, $0 \le n \le M$ *son obtenidos con las fórmulas* (10.11), *entonces*

$$\max_{0\le n\le M}\Big(\sum_{i=0}^{N}|u(x_i,t_n)-U_i^n|^2\Big)^{1/2} \le T\sqrt{N+1}\left(\frac{\mathbb{M}_1}{3}\Delta t^2 + k\frac{\mathbb{M}_2}{12}h^2\right) \le \mathbb{M}T\sqrt{N+1}(\Delta t^2+h^2),$$

si $\mathbb{M} = \max\{\mathbb{M}_1/3, \mathbb{M}_2/12\}$. *Si dividimos por* $\sqrt{N+1}$ *obtenemos*

$$\max_{0\le n\le M}\Big(\frac{1}{N+1}\sum_{i=0}^{N}|u(x_i,t_n)-U_i^n|^2\Big)^{1/2} \le T\left(\frac{\mathbb{M}_1}{3}\Delta t^2 + k\frac{\mathbb{M}_2}{12}h^2\right) \le \mathbb{M}T(\Delta t^2+h^2).$$

Demostración. La demostración se deja como ejercicio. □

Observación 10.9. El término $\left(\frac{1}{N+1}\sum_{i=0}^{N}|u(x_i,t_n)-U_i^n|^2\right)^{1/2} = \left(\frac{1}{N+1}\sum_{i=0}^{N}|e_i^n|^2\right)^{1/2}$ es una aproximación por la regla del rectángulo de la integral

$$\Big(\int_0^L e(x,t_n)^2\,dx\Big)^{1/2}.$$

De esta manera, el teorema 10.8 establece una estimación del máximo (en t) error en $L^2(0,L)$.

10.2 Diferencias finitas para la ecuación del calor bidimensional

En dos dimensiones, estudiaremos métodos numéricos para la ecuación sobre $\Omega = (0,L)\times(0,L)$,

$$\begin{cases} \dfrac{\partial u}{\partial t} = k\left[\dfrac{\partial^2 u}{\partial x^2} + \dfrac{\partial^2 u}{\partial y^2}\right] + f(x,y;t), & (x,y)\in\Omega, \quad 0<t<T, \\ u(x,y;t) = \alpha(x,y;t), & (x,y)\in\partial\Omega, \quad 0\le t\le T, \\ u(x,y;0) = u^0(x,y), & (x,y)\in\bar{\Omega}. \end{cases} \tag{10.13}$$

Aquí, L, k son parámetros positivos fijos y $f(x,y;t)$, $\alpha(x,y;t)$, $u^0(x,y)$ son los datos del problema. La incógnita es la función $u = u(x,y;t)$ que está definida para $0 \le x \le L$, $0 \le y \le L$, $0 \le t \le T$.

Todo lo hecho en la sección anterior puede repetirse en este problema bidimensional. Lo esencial es aproximar $\Delta u = \dfrac{\partial^2 u}{\partial x^2} + \dfrac{\partial^2 u}{\partial y^2}$ de la siguiente manera, por cocientes incrementales. Dado $N \in \mathbb{N}$, definimos $h = L/N$ y $x_i = ih$, $y_j = jh$ $i,j = 0,1,\dots,N$, y resulta, denotando $u_{i,j} = u(x_i,y_j)$,

$$\begin{aligned} \Delta u(x_i,y_j) &= \frac{\partial^2 u}{\partial x^2}(x_i,y_j) + \frac{\partial^2 u}{\partial y^2}(x_i,y_j) \\ &= \frac{u_{i+1,j}-2u_{i,j}+u_{i-1,j}}{h^2} + \frac{h^2}{12}\frac{\partial^4 u}{\partial x^4}(\xi_{i,j},y_j) + \frac{u_{i,j+1}-2u_{i,j}+u_{i,j-1}}{h^2} + \frac{h^2}{12}\frac{\partial^4 u}{\partial y^4}(x_i,\eta_{i,j}) \\ &= \frac{u_{i+1,j}+u_{i,j+1}-4u_{i,j}+u_{i-1,j}+u_{i,j-1}}{h^2} + \frac{h^2}{12}\Big[\frac{\partial^4 u}{\partial x^4}(\xi_{i,j},y_j) + \frac{\partial^4 u}{\partial y^4}(x_i,\eta_{i,j})\Big]. \end{aligned}$$

Resulta entonces el siguiente PVI para un sistema de ecuaciones diferenciales ordinarias para $u_{i,j}$, $i, j = 0, 1, \ldots, N$:

$$
\begin{aligned}
&u_{i,j}(t) = \alpha(x_i, y_j; t), \\
&\qquad\qquad\qquad\qquad\qquad\qquad \text{si } i = 0 \text{ o } i = N \text{ o } j = 0 \text{ o } j = N; \\
&\frac{du_{i,j}}{dt} = k\frac{u_{i+1,j} + u_{i,j+1} - 4u_{i,j} + u_{i-1,j} + u_{i,j-1}}{h^2} + f(x_i, y_j, t), \\
&\qquad\qquad\qquad\qquad\qquad\qquad \text{si } 0 < i < N \text{ y } 0 < j < N; \\
&u_{i,j}(0) = u^0(x_i, y_j), \\
&\qquad\qquad\qquad\qquad\qquad\qquad \text{si } 0 \le i \le N \text{ y } 0 \le j \le N.
\end{aligned}
$$

Los métodos de Euler explícito, implícito y el del trapecio se obtienen de manera análoga a lo hecho en la sección anterior, aunque debemos admitir que un poco más engorrosa.

La descripción de dichos métodos y su análisis de estabilidad y acotación del error se deja como ejercicio.

Ejercicios

10.1. Demostrar el Teorema 10.1.

10.2. Consideremos la ecuación de difusión

$$
\begin{cases}
\dfrac{\partial u}{\partial t} - \dfrac{\partial^2 u}{\partial x^2} = 0, \qquad 0 < x < 1, \quad 0 < t < 2, \\
\qquad u(0,t) = 0, \quad u(L,t) = 0, \qquad 0 \le t \le 2, \\
\qquad u(x,0) = \operatorname{sen}(\pi x), \quad 0 \le x \le 1,
\end{cases}
$$

cuya solución exacta es $u(x,t) = \operatorname{sen}(\pi x)e^{-\pi^2 t}$.

(a) Resolverla con el método de diferencias finitas que utiliza Euler explícito, tomando $N = 20$, y $M = 10, 20, 40, 80, 160$. Explique qué observa y para qué valor de M la solución es *razonable*.

(b) Verificar el orden experimental de convergencia. Para esto, fijar $\lambda = 1/4$, tomar $N = 20, 40, 80, 160, 320, 640, 1280$ y M para que $\lambda = \Delta t/h^2$ se mantenga igual a $1/4$.

10.3. Considerar el problema

$$
\begin{cases}
\dfrac{\partial u}{\partial t} - \dfrac{\partial^2 u}{\partial x^2} = 0, \qquad 0 < x < 1, \quad 0 < t < 1, \\
\qquad u(0,t) = 0, \quad u(L,t) = 0, \qquad 0 \le t \le 1, \\
\qquad u(x,0) = \operatorname{sen}(\pi x) + \dfrac{1}{2}\operatorname{sen}(2\pi x), \quad 0 \le x \le 1,
\end{cases}
$$

cuya solución exacta es $u(x,t) = \operatorname{sen}(\pi x)e^{-\pi^2 t} + \frac{1}{2}\operatorname{sen}(2\pi x)e^{-4\pi^2 t}$.

(a) Considerar los tres métodos de diferencias finitas estudiados con $N = 50$. Calcular el máximo error con $\Delta t = 1/40, 1/80, 1/160, 1/320, 1/640, 1/1280, 1/2560, 1/5120, 1/10240$, y el tiempo de cpu utilizado. Determinar qué método es mejor para cada Δt.

(b) Determinar qué método y con qué parámetro Δt (de los probados) es mejor cuando se quiere un error menor a 0.01, 0.001, 0.0001.

10.4. Repetir el ejercicio anterior pero en el intervalo temporal $0 \leq t \leq 10$.

10.5. Demostrar que cualquiera sea $\Delta t > 0$, los autovalores de $(I+\frac{k}{2}\Delta t M_h)^{-1}(I-\frac{k}{2}\Delta t M_h)$ y de $(I+\frac{k}{2}\Delta t M_h)^{-1}$ tienen módulo menor que uno. Ayuda: seguir los siguientes pasos.

(a) Demostrar que M_h es diagonalizable y que todos sus autovalores son positivos.

(b) Demostrar que los autovectores de M_h coinciden con los de $I \pm \frac{k}{2}\Delta t M_h$.

(c) Demostrar que los autovalores de $I \pm \frac{k}{2}\Delta t M_h$ son $1 \pm \frac{k}{2}\Delta t\sigma$, con σ autovalor de M_h, con el mismo autovector correspondiente.

(d) Demostrar que los autovalores de $(I+\frac{k}{2}\Delta t M_h)^{-1}$ son $(1+\frac{k}{2}\Delta t\sigma)^{-1}$, con σ autovalor de M_h, con el mismo autovector correspondiente.

(e) Demostrar que los autovalores de $(I+\frac{k}{2}\Delta t M_h)^{-1}(I-\frac{k}{2}\Delta t M_h)$ son $(1-\frac{k}{2}\Delta t\sigma)/(1+\frac{k}{2}\Delta t\sigma)$, con σ autovalor de M_h, con el mismo autovector correspondiente.

10.6. Demostrar el Teorema 10.7.

10.7. Demostrar el Teorema 10.8.

10.8. Obtener e implementar los métodos de Euler explícito, implícito y de Crank-Nicolson para el problema de difusión bidimensional.

10.9. Demostrar que el método de Euler explícito para difusión bidimensional es estable para $\lambda = \dfrac{k\Delta t}{h^2} \leq \dfrac{1}{2}$.

10.10. Demostrar resultados de estabilidad incondicional análogos a los de los Teoremas 10.4 y 10.7 para difusión bidimensional.

10.11. Demostrar resultados de acotación del error análogos a los de los Teoremas 10.2, 10.6 y 10.8 para difusión bidimensional.

Bibliografía

[A] K.E. Atkinson, *An introduction to Numerical Analysis*, 2nd edition, John Wiley & Sons, 1989. 192

[SB] J. Stoer, R. Bulirsch, *Introduction to Numerical Analysis*, 2nd edition, Springer-Verlag, 1992. 167

[LT] Stig Larsson, Vidar Thomée, *Partial Differential Equations with Numerical Methods*, Springer, 2005. 223

[BHM] W.L. Briggs, V.E. Henson, S.F. McCormick, *A Multigrid Tutorial*, 2nd edition, SIAM, 2000. 117

[TOS] U. Trottenberg, C.W. Oosterlee, A. Schüller, *Multigrid*, Academic Press, 2001. 117

[St] G.W. Stewart, *Afternotes goes to graduate school*, SIAM, 1996. 40